



计算机工程与应用
Computer Engineering and Applications
ISSN 1002-8331,CN 11-2127/TP

《计算机工程与应用》网络首发论文

题目: LMF-DETR: 一种用于钢表面缺陷检测的特征增强算法
作者: 宋志函, 赵磊, 薛晓军, 刘辉, 李恒
网络首发日期: 2026-08-06
引用格式: 宋志函, 赵磊, 薛晓军, 刘辉, 李恒. LMF-DETR: 一种用于钢表面缺陷检测的特征增强算法[J/OL]. 计算机工程与应用.
<https://link.cnki.net/urlid/11.2127.TP.20260806.1239.008>



网络首发: 在编辑部工作流程中,稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定,且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件,可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定;学术研究成果具有创新性、科学性和先进性,符合编辑部对刊文的录用要求,不存在学术不端行为及其他侵权行为;稿件内容应基本符合国家有关书刊编辑、出版的技术标准,正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性,录用定稿一经发布,不得修改论文题目、作者、机构名称和学术内容,只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约,在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版,以单篇或整期出版形式,在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z),所以签约期刊的网络版上网络首发论文视为正式出版。

LMF-DETR: 一种用于钢表面缺陷检测的特征增强算法

宋志函, 赵磊⁺, 薛晓军, 刘辉, 李恒

昆明理工大学 信息工程与自动化学院, 昆明 650032

⁺ 通信作者 E-mail: zhaolei@kust.edu.cn

摘要: 针对钢材表面缺陷检测中结构模糊、对比度低及缺陷尺寸高度不均衡导致单一模型难以稳定识别的问题, 提出一种多特征增强端到端检测模型(Laplacian-of-Gaussian and Multi-scale Feature enhanced DETR, LMF-DETR)。该模型在三个层面进行系统性优化: 底层特征建模、阶段内特征融合及多尺度特征扩散。首先, 基于拉普拉斯-高斯算子设计的特征增强主干模块(Feature Enhancement with Gauss-Laplacian Stem, FEG-LStem), 用于增强边缘与纹理感知能力; 其次, 引入改进的多尺度注意力网络模块(improved Multi-scale Attention Network, iMANet), 以实现多尺度特征的高效阶段内交互; 最后, 构建两阶段特征聚焦扩散金字塔网络(Feature Diffusion Pyramid Network, FDPN), 以提升多尺度特征对齐度与语义一致性。在 GC10-DET 和 NEU-DET 数据集上的实验结果表明, LMF-DETR 的平均精度均值(mAP@0.5)较基线模型分别提升 10.2 个百分点和 6.3 个百分点, 在提高检测精度的同时保持可控计算开销。

关键词: 钢材表面缺陷检测; 多尺度特征增强; 基于 Transformer 的检测; 特征金字塔网络

文献标志码:A 中图分类号:TP391.4 doi: 10.3778/j.issn.1002-8331.2604-0139

LMF-DETR: A Feature Enhancement Algorithm for Steel Surface Defect Detection

SONG Zhihan, ZHAO Lei⁺, XUE Xiaojun, LIU Hui, LI Heng

School of Information Engineering and Automation, Kunming University of Science and Technology, Kunming 650032, China

Abstract: To address the challenges of blurry structures, low contrast, and highly imbalanced defect sizes in steel surface defect detection, which hinder stable recognition by a single model, an end-to-end detection model with multi-feature enhancement, termed Laplacian-of-Gaussian and Multi-scale Feature enhanced DETR (LMF-DETR), is proposed. The model is systematically optimized at three levels: low-level feature modeling, intra-stage feature fusion, and multi-scale feature diffusion. First, a Feature Enhancement with Gauss-Laplacian Stem (FEG-LStem) module, designed based on the Laplacian-of-Gaussian operator, enhances edge and texture perception. Second, an improved Multi-scale Attention Network (iMANet) module is introduced to enable efficient intra-stage interaction of multi-scale features. Finally, a two-stage Feature Diffusion Pyramid Network (FDPN) is constructed to improve multi-scale feature alignment and semantic consistency. Experimental results on the GC10-DET and NEU-DET datasets show that LMF-DETR achieves an improvement in mAP@0.5 of 10.2 percentage points and 6.3 percentage points over the baseline model, respectively, while maintaining controlled computational overhead.

基金项目: 国家自然科学基金项目(62263016); 云南省高校服务重点产业科技专项项目(FWCYQYCT2024003)。

作者简介: 宋志函(2001—), 男, 硕士研究生, 研究方向为计算机视觉; 赵磊(1978—), 男, 硕士研究生, 工程师, 电子技术、图像处理。

Key words: Surface defect detection of steel; multi-scale feature enhancement; Transformer-based detection; feature pyramid network

随着工业制造技术的飞速发展,金属材料已成为众多行业不可或缺的核心要素,支撑着各类应用中关键部件的结构基础。然而复杂的制造工艺会导致金属表面产生裂纹、孔洞、腐蚀等各类潜在缺陷。这些瑕疵绝非表面问题,它们会严重削弱产品的结构强度与可靠性,可能引发安全隐患、增加设备故障风险并降低生产效率。因此,对金属表面缺陷进行精准检测与全面分析、维持工业生产高标准、保障产品安全及提升运营效率具有重要意义^[1]。

早期金属表面缺陷检测主要依赖阈值分割^[2]、边缘检测及手工特征(如灰度统计、Gabor、LBP)^[3]。这类方法在成像条件理想、缺陷形态单一的场景下有效,但由于高度依赖人工先验设计^[4],面对光照变化剧烈、背景纹理复杂的真实工业环境时,往往缺乏足够的泛化能力与鲁棒性^[5]。随着深度学习的发展,以 Faster R-CNN 和 YOLO 为代表的 CNN 目标检测模型已广泛应用,在两阶段算法中,向宽等^[6]将 Faster R-CNN 算法应用到铝材表面缺陷检测上,应用了感兴趣区域校准(ROI align)算法和 K-means 优化锚框,提升了铝材缺陷检测精度。在单阶段算法中,CHU 等^[7]提出了一种基于改进 YOLOv8 的轻量化钢表面缺陷检测网络 YOLO-SDS。通过替换骨干网络实现轻量化优化,同时引入轻量级模块 DWR 和 C2f 特征提取模块,增强多尺度特征提取能力;高春艳等^[8]提出一种高精度实时的缺陷检测算法 CDN-YOLOv7,通过结合 CARAFE 轻量化上采样算子、级联注意力机制和解耦头设计,显著提升了钢材表面缺陷检测的精度。陶友凤等^[9]提出了 RCD-YOLO 模型,通过轻量化骨干网络 R-HGNet 降低模型复杂度,同时结合 CARAFE 上采样算子和 C2f-DWR 模块增强多尺度特征融合,并引入 Inner-CIOU 损失函数优化小目标定位精度,实现了钢材表面缺陷检测精度和效率的显著提升。

在钢材表面缺陷检测任务中,上述方法在提高钢材表面缺陷检测精度、增强特征表达能力以及优化特征融合等方面取得了一定进展。但面对钢材表面缺陷检测这一特定任务,现有 CNN 模型仍存在固有的局限性:一方面以 Faster R-CNN 为代表的两阶段方法虽然精度较高,但区域提议网络(RPN)也带来了不小的计算开销,且随着网络层数的加深和不断的下采样操作,微小缺陷(如细微划痕、点坑)的关键纹理和边缘细节极易在深层特征图中丢失^[10];另一方面,以 YOLO 和 SSD 为代表的单阶段方法虽大幅提升了推理速度,但其基于固定网格的密集预测机制在处理分布密集或尺度突变的目标时容易出现漏检^[11]。更重要

的是, CNN 主要依赖局部感受野进行特征提取,在复杂多变的背景噪声下,对全局上下文的感知不足,导致缺陷特征与背景纹理的辨识度欠佳^[12]。为规避传统检测算法中锚框设计与 NMS 后处理的固有局限,Carion, N.等人提出 DETR^[13]无锚框端到端检测范式。该方法引入 Transformer 架构,借助自注意力机制实现全局上下文与长距离依赖建模;并将检测建模为直接集合预测问题,通过匈牙利二分图匹配实现预测与真值的唯一对应,彻底摒弃锚框与 NMS,简化了检测流程;Huang 等^[14]人提出 DEIM,其核心贡献为稠密一对一匹配策略(Dense O2O)和配合匹配感知损失(MAL),对不同质量的匹配赋予差异化监督强度。但在 Transformer 框架中,因其性能高度依赖于前端(Backbone 或 Stem)提取出的特征图质量。钢材表面缺陷类型往往具有对比度极低、边界模糊等物理特性;如果网络在底层阶段未能充分提取和表征高频的边缘与纹理细节,后续全局建模难以发挥优势。

综上,针对钢材表面缺陷特点,有必要从特征提取、阶段内融合与多尺度传播等层面重构端到端检测框架。本文提出特征增强的端到端检测模型 LMF-DETR。主要贡献包括:

(1) 设计了拉普拉斯-高斯前端特征提取模块(FEG-LStem):在网络初期强化边缘与纹理特征的提取,为后续检测提供判别性更强的特征表示。

(2) 提出了阶段内特征融合模块(iMANet):通过多分支架构和轻量级通道注意力,实现局部细节、上下文与原始特征的高效交互。

(3) 构建了多尺度特征融合网络(FDPN):简化融合路径并引入高效卷积,在保持高精度的同时提升多尺度特征对齐度与语义一致性。

1 LMF-DETR 算法

1.1 网络模型结构

针对上述现有方法在低级特征建模、阶段内信息交互及多尺度融合效率方面的不足,本章提出了一种新型端到端检测框架——LMF-DETR。基于 DEIM 框架,该模型通过系统引入三个核心创新模块,构建了从细粒度局部感知到高效全局推理的增强路径。这三个模块分别提升了初始特征可区分性、深化阶段内特征融合以及优化多尺度特征整合,从而全面提高模型对钢材表面微小缺陷、低对比度缺陷及纹理混淆缺陷的检测能力。LMF-DETR 的整体架构如图 1 所示。

输入图像首先通过 FEG-LStem 模块进行增强型初始特征提取,该模块强化了边缘与纹理结构,并为

网络提供更具区分度的低级特征。随后, 这些特征经过主干网络的多阶段处理, 每个阶段均嵌入 iMANet 模块以促进局部细节与上下文信息的深度融合, 从而生成多层次特征图。经过编码器全局建模后, 不同阶段输出的多尺度特征被送入 FDPN 模块。该模块通过

自下而上与自上而下的双重路径实现高效特征融合与对齐, 最终形成具有增强语义一致性和空间精度的特征金字塔。最后, 经处理的特征序列通过 Transformer 解码器与目标查询进行交互, 缺陷的类别信息及边界框由预测头输出。




图 1 LMF-DETR 网络结构

Fig.1 Structure of the LMF-DETR network

1.2 颈部网络结构

在复杂的工业成像环境中, 微小缺陷的频率谱与背景噪声高度重叠, 导致传统检测框架常在初始特征提取阶段陷入关键信息丢失的困境^[15]。为此, 本文设计了 FEG-LStem 模块, 创新性地将传统数字图像处理中的经典边缘感知理论与现代轻量级卷积神经网络架构深度融合。该模块的核心逻辑在于: 通过多尺度 LoG 算子构建显式边缘聚焦路径, 迫使网络在初始阶段对高频精细信息进行注意力增强。在可承受的计算负担的情况下, 这种设计方式有效缓解了深度模型难以从源数据中建模低对比度纹理的技术难点, 为端到端检测框架在极端工作条件下的性能突破奠定了坚实基础。FEG-LStem 模块如图 2 所示。

1.2.1 LoG 边缘感知功能增强

高斯拉普拉斯 (LoG) 滤波器将高斯平滑与拉普拉斯算子相结合^[16], 在有效抑制噪声的同时增强图像中的边缘和纹理信息。设输入图像为 $I \in \mathbb{R}^{H \times W \times 3}$, 位置 $x=(i, j)$ 处的二维 LoG 滤波器定义如下:

$$LoG_{\sigma}^{k \times k} = \frac{1}{\pi \sigma^4} \left(1 - \frac{i^2 + j^2}{\sigma^2} \right) e^{-\frac{i^2 + j^2}{2\sigma^2}} \quad (1)$$

i 和 j 为滤波器的坐标索引, 其定义基于 $G_{\sigma}^{k \times k}(x)$ 给出, 具体如下:

$$G_{\sigma}^{k \times k}(x) = \frac{1}{2\pi \sigma^2} e^{-\frac{i^2 + j^2}{2\sigma^2}} \quad (2)$$

在钢材表面中, 缺陷的物理尺度分布具有特定的特征。我们固定了三组参数 σ (0.7/ 1.0/ 1.3) 强制模型从三个独立的维度观察特征, 以保证特征的多样性, 而非可学习 σ , 这是因为 DETR 类模型因其复杂的自注意力机制, 本身就面临收敛慢、训练不稳定的问题。同时在钢材缺陷小数据集场景下, 可学习参数易拟合数据噪声, 引发过拟合。将 σ 固定, 本质上是为模型提供了一个低级特征归纳偏置。这使得 Backbone 无需在训练初期浪费梯度去探索基础的边缘检测逻辑, 从而能够将学习能力集中在更高层语义提取上。




图2 FEG-LStem网络结构

Fig.2 Network structure of FEG-LStem

本文参数选取依据奈奎斯特采样定理与高斯核离散化特性。为抑制频谱混叠现象, 高斯平滑核的标准差需满足约束条件 $\sigma \geq \frac{1}{\sqrt{2}} \approx 0.707$ 。参数上限 $\sigma=1.3$ 是由感受野与计算开销共同决定的。LoG 核的有效截断尺寸与 σ 成正比, LoG 算子的有效感受野(截断窗口)通常根据 $K = 2[3\sigma] + 1$, $\sigma=1.3$ 对应 9×9 的感受野。可覆盖大多数钢材表面缺陷的边界尺度。持续增大 σ 会提升卷积核尺寸, 既违背 Stem 模块轻量化设计目标, 也会造成邻近微小缺陷特征相互干扰。

同时, 考虑到离散化连续的 LoG 函数时, 空间支持范围 $k \times k$ 的设定基于高斯函数的截断原则与中心对称约束^[17]。根据高斯分布特性, 其绝大部分能量集中在 $[-3\sigma, 3\sigma]$ 的半径范围内。为在保留 >95% 梯度能量的同时避免冗余计算, 本文设定滤波器半径 r 范围为 $[-2\sigma, 3\sigma]$ 。对于用于捕捉微细高频结构的较小尺度(如 $\sigma=0.7$), 采用 5×5 的紧凑核尺寸; 对于捕捉大尺度模糊缺陷区域的较大尺度(如 $\sigma=1.3$), 则扩展为 9×9 的核尺寸。此外, 采用奇数尺寸确保了卷积核严格的中心对称性, 有效避免了特征提取过程中的空间相位偏移, 实现了多尺度感受野与网络计算效率的最佳权衡^[18]。

通过 LoG 滤波器, 网络能在特征提取初期明确感知钢表面缺陷的边缘、纹理及局部梯度变化, 从而为后续深度建模提供更多的结构输入特征。

1.2.2 数据增强策略与 LoG 先验的平衡

本文研究 Pipeline 基于 DEIM 框架构建, 依靠 Mosaic、Mixup 策略实现密集一对一匹配监督, 并非依赖高斯模糊提升模型鲁棒性。同时, 引入数据增强预热策略以缓解模块冲突: 训练前 4 个轮次关闭复杂图像增强操作, 降低图像变换干扰, 简化模型注意力学习难度, 保证 FEG-LStem 输出的边缘基础特征可被

稳定学习, 该策略使 LoG 卷积先验能够优先引导模型捕捉缺陷边界特征。此外, 本文未引入强模糊类增广手段, 保障了训练全程 LoG 分支输出的特征信噪比, 实现数据增强与底层先验模块的协同稳定训练。

1.2.3 初始特征生成与融合

为避免传统卷积在茎部阶段引发的高计算冗余问题, FEG-LStem 引入了 GhostConv^[19] 技术来构建高效的特征投影路径。该技术以固有特征提取与线性变换优化为核心, 采用少量标准卷积完成基础特征建模, 结合深度可分离卷积实现剩余特征推导。在保证模型特征表达能力不变的条件下, 降低了网络参数量与计算复杂度。这种设计使得 LoG 响应能够高效映射至高维特征空间, 有效提升了边缘与纹理特征的表达能力。

在初始特征生成之后, FEG-LStem 模块进一步嵌入了 ECA 注意力机制。该机制通过自适应地建模通道间的依赖关系, 有效增强了缺陷的关键特征表达能力。随后特征被输入 DRFD 模块, 该模块通过基于 DWConv 的双分支多尺度结构融合不同尺度的梯度与纹理信息^[20], 并在从 $[H/2, W/2]$ 到 $[H/4, W/4]$ 的二次下采样过程中逐步提升结构表征能力, 为后续主干网络提供稳定的低级特征输入。

1.2.4 FEG-LStem 模型的局限性与分析

FEG-LStem 模块可适配常规与低对比度工业检测场景, 但在极端工况下存在结构与物理特性带来的固有局限。

该模块依托图像二阶梯度分布完成特征提取, 相机过曝像素饱和或极暗光照工况会造成局部梯度信息缺失, 导致边缘先验提取机制失效。当背景密集椒盐噪声的高频频段与缺陷特征频段重合时, $\sigma=0.7$ 的小

尺度 LoG 分支将产生伪特征响应, 提升背景误检占比。

固定尺度 LoG 算子存在感受野上限, 本文 $\sigma=1.3$ 的参数设置可覆盖多数带钢缺陷边界尺度, 但无法适配大面积氧化铁皮、成片水渍等超大尺度连续缺陷。此类场景下, 算子仅能激活缺陷边缘特征, 缺陷内部存在特征缺失。若网络深层语义无法弥补该特征缺失, 会出现预测框碎片化问题。后续研究可通过注意力机制实现感受野尺度的动态自适应调整, 以解决固定卷积核尺度带来的适配性约束问题。

1.3 iMANet 结构

为解决钢材表面缺陷检测中跨尺度语义交互不足的固有挑战, 本文设计了阶段内增强路径 iMANet 结构, 如图 3 所示。该结构在确保特征多样性的同时, 有效控制了参数尺度。与单一特征堆叠方法不同, iMANet 其设计逻辑为: 通过 MANet 分支对微小点蚀和线性缺陷进行特征筛选与增强处理, 同时借助 iRMB 模块逆残差结构, 在高维空间中还原缺陷边界

特征。此类的异构模块级联架构, 让网络可以在复杂工业场景自适应提取判别特征, 有效缓解深层传播里多尺度特征衰减问题。

iMANet 的整体特征转换过程可形式化描述为:

$$\left. \begin{aligned} X_{mid} &= \text{Conv}_1(X_{in}) \\ X_1 &= \text{Conv}_2(X_{mid}) \\ X_2 &= \text{DwConv}(\text{Conv}_3(X_{mid})) \\ X_3, X_4 &= \text{Split}(X_{mid}) \\ X_5 &= \text{iRMB}(X_4) + X_4 \\ X_6 &= \text{iRMB}(X_5) + X_5 \\ &\vdots \\ X_{4+n} &= \text{iRMB}(X_{3+n}) + X_{3+n} \end{aligned} \right\} n \quad (3)$$

其中, X_{mid} 的通道数为 $2c$ 。 $X_1, X_2, \dots, X_{4+n}$ 各具有 c 个通道。最后, 我们通过拼接操作和 1×1 卷积对这些特征的语义信息进行融合与压缩, 生成具有 $2c$ 个通道的 X_{out} , 具体如下:

$$X_{(out)} = \text{Conv}_c(X_1 \parallel X_2 \parallel \dots \parallel X_{(4+n)}) \quad (4)$$




图 3 iMANet 网络结构
Fig.3 Network structure of iMANet

1.3.1 MANet 多分支特征聚合结构

iMANet 采用四分支并行架构实现多尺度特征聚合, 各分支在空间感受野和语义层面形成互补关系。基础结构分支用于保留整体几何形态与上下文信息; 细粒度纹理分支通过增强边缘特征和局部梯度响应, 适用于细长裂纹的表征; 冗余特征分支提升特征多样性与尺度交互能力; 增强分支 (iRMB) 在保持轻量化的同时引入注意力机制, 有效改善特征选择性^[21]。这种多路径设计不仅增强了不同尺度缺陷的局部表征能力, 而且有利于裂纹连续性与点蚀聚集特征的建模分析。

1.3.2 iRMB 模块及其特征一致性建模机制

为弥补传统卷积在建模长距离依赖性方面的不足, iMANet 在关键分支中引入了 iRMB 模块。iRMB 将高效算子 $F(\cdot)$ 实例化为深度可分离卷积 (DW-Conv) 与基于窗口的多头自注意力机制 (Window-based MHSA) 的级联结构^[22], 以平衡局部感受野建模与长距离依赖建模能力。其核心运算形式为:

$$F(\cdot) = \text{DW-Conv}(\text{EW-MHSA}(\cdot)) \quad (5)$$

该方法遵循扩展-增强-收缩的逆残差逻辑: 在通道扩展阶段, 通过 MLP 将输入通道维度扩展 λ 倍; 在特征增强阶段, 采用改进的扩展窗口 MHSA (EW-MHSA) 和 3×3 深度可分离卷积 (DW-Conv) 来增强

局部结构感知；最后通过通道压缩和残差连接实现高效特征融合。

该设计使 iRMB 能够在低计算成本下协同优化局部细节建模与中远程语义一致性。因此，反射噪声干扰在金属表面缺陷边界判定过程中得到有效抑制。

1.4 FDPN 网络结构

针对钢材表面缺陷大规模跨度的检测挑战，以及细节与高层次语义平衡的困难，本文设计了聚焦扩散金字塔网络 (FDPN)。如图 4 所示，该模块采用类似于 Inception^[23] 的并行多分支架构，通过聚焦-扩散的两阶段循环机制，构建具有高语义一致性和多尺度感知能力的特征金字塔表征。

1.4.1 两阶段特征聚焦机制

为了精确定义 FDPN 中的特征流转，设输入为多尺度特征组 $P = \{P_3, P_4, P_5\}$ ，其中 $P_i \in R^{H_i \times W_i \times C}$ 。该算子首先通过上采样、 1×1 卷积或 ADown 降采样将所有特征在空间维度上对齐至 P_4 的分辨率，并进行通道拼接得到对齐特征 P_{cat} 。随后，利用一组具有分化感受野的深度可分离卷积 $k \in \{5, 7, 9, 11\}$ 捕捉多尺度空间模式：




图 4 FDPN 网络结构

Fig.4 Network structure of FDPN

1.4.2 双向特征扩散与深度融合策略

FDPN 的整体架构中，中间尺度的 FocusFeature 模块充当了跨尺度信息交互的枢纽。为了将聚焦后的多尺度上下文高效传递至各检测尺度，本文设计了自上而下与自下而上的双向特征传递路径。

在第一阶段的初始扩散中，FocusFeature_1 生成的多尺度融合特征 f_1 沿着两个方向进行尺度变换与语义分发。自下而上的下采样路径：特征 f_1 经过步长为 2 的卷积操作 (Conv) 下采样后，与最底层深层特征 (富含全局上下文) 进行拼接。自上而下的上采样路径：特征 f_1 通过上采样 (Up) 操作放大空间分辨率后，与最浅层特征 (富含局部细粒度细节) 进行拼接。随后

$$F_{spatial} = \sum_{k \in K} DWConv_k(P_{cat}) + P_{cat} \quad (6)$$

最后，通过逐点卷积与残差连接输出聚焦特征：

$$F_{out} = Conv_{1 \times 1}(P_{cat} + PWConv(F_{spatial})) \quad (7)$$

在第一阶段 (FocusFeature_1)，网络对对齐后的骨干多尺度特征进行初级聚焦。该阶段接收原始特征，核心目标是多尺度空间对齐与粗粒度定位。通过多尺度响应的加权融合，FocusFeature_1 明确强化了对关键空间结构 (如边缘、轮廓) 的关注，弥合了层级间的几何间距，并在完成第一尺度对齐后输出跨尺度融合特征 f_1 。

在第二阶段 (FocusFeature_2)，尽管特征 f_1 整合了多尺度空间信息，但在多尺度叠加后，语义冗余与判别能力不一致性极易残留。为此，在经历第一次双向特征扩散后，网络引入 FocusFeature_2 进行语义一致性精炼。该阶段接收经过扩散与深度增强的混合特征，充当跨尺度信息的语义枢纽，通过二次特征重组消除叠加引入的语义冗余。这一过程能有效避免弱缺陷 (如细微裂纹) 响应在多尺度融合中被复杂背景信息稀释。

的多尺度特征随后送入深度特征增强模块 (即 C2f 模块) 进行统一的特征提取，形成初步的多尺度特征表示。此过程有效弥合了传统特征金字塔中因尺度差异导致的信息断层。

在第二阶段的深度扩散中，网络以 FocusFeature_2 生成的二次聚焦特征 f_2 为核心，执行第二轮的双向扩散。为了在提升跨尺度语义交互能力的同时避免引入额外的计算负担，本文在扩散路径末端采用了轻量级深度增强模块 (LC2f)。LC2f 由两个级联卷积操作构成，其特征变换过程可表示为：

$$X_{out} = Conv_{1 \times 1}(Conv_{3 \times 3}(X_{in})) \quad (8)$$

最终，FDPN 输出增强型三尺度特征表示 $[p3_2, f_2, p5_2]$ 用于解码器 (Decoder)。相较于传统 FPN

架构, FDPN 构建了包含两阶段聚焦与双向扩散的循环迭代机制。该架构通过多轮尺度对齐与语义重组迭代计算, 缩小深层特征与浅层特征的语义差异, 对应特征提取过程如图 5 所示。该结构可同步完成局部结构特征提取与大尺度区域全局语义建模, 提升模型在复杂工业场景下的检测稳定性与特征区分性能。




图 5 FDPN 特征提取

Fig.5 FDPN feature extraction

2 实验结果与分析

2.1 数据集

本研究采用两个公开数据集 GC10-DET^[24]和 NEU-DET 进行分析。如图 6、图 7 所示。




图 6 NEU-DET 数据集

Fig.6 NEU-DET dataset

NEU-DET 是由东北大学发布的金属表面缺陷数据集, 包含 1800 张 200×200 像素的图像。缺陷类型包括内卷鳞片 (RS)、斑块 (Pa)、裂纹 (Cr)、凹坑表面 (PS)、夹杂物 (In) 及划痕 (Sc)。根据 8:1:1 的比例, 训练集被随机划分为 1440 张图像, 验证集 180 张图像, 测试集 180 张图像。

GC10-DET 数据集包含 10 种真实工业钢材缺陷类型, 包括油渍斑点(os)、腰带褶皱(wf)、焊接线(wl)、新月形间隙(cg)、轧制凹坑(rp)、折痕(cr)、丝纹斑点(ss)、冲孔痕迹(ph)、夹杂物(in)、水渍斑点(ws)。经过人工去噪与预处理后, 最终保留 2294 张高分辨率图像。实验采用 8:1:1 的比例将数据集随机划分为训练集 (1836 张)、验证集 (229 张) 和测试集 (229 张)。




图 7 GC10-DET 数据集

Fig.7 GC10-DET dataset

2.2 实验环境与参数设置

表 1 和表 2 分别提供了主要的环境配置和训练参数设置。

表 1 环境配置

Table 1 Environment configuration	
名称	配置
操作系统	Ubuntu 20.04.1 LTS
CPU	Intel(R) Xeon(R) CPU E7-4809 v3 @ 2.00 GHz
GPU	NVIDIA GeForce RTX 4090
CUDA	12.8
Python	3.10
Pytorch	2.2.1

表 2 参数设置

Table 2 Parameter settings	
名称	设置
输入尺寸	640×640
初始学习率	0.002
批次大小	12
轮数	200
优化器	AdamW

2.3 评估指标

本文选取参数量(Parameters)、十亿浮点运算次数(Giga Floating Point Operations, GFLOPs)、作为轻量化的评价指标, 选取精确率(Precision, P)、召回率(Recall, R)和平均精度均值(mean Average Precision, mAP)作为检

测精度指标。计算公式如下：

$$P = \frac{TP}{TP + FP} \quad (9)$$

$$R = \frac{TP}{TP + FN} \quad (10)$$

$$AP = \int_0^1 P(R) dR \quad (11)$$

$$mAP = \frac{1}{n} \sum_{i=1}^n AP(i) \quad (12)$$

其中，AP 表示单类别平均精度，TP 表示模型正确识别的正例样本数量，FP 表示被识别为正例的负例

样本数量，FN 表示被识别为负例的正例样本数量，n 为类别总数。

2.4 消融实验与分析

为定量评估各核心模块（FEG-LStem、iMANet、FDPN）在 LMF-DETR 模型中对检测性能的贡献，分别在 GC10-DET 和 NEU-DET 两个基准数据集上进行了消融实验。另外为了全面评估模型对不同尺度缺陷的检测能力，本文遵循 COCO 评估标准中的多尺度平均精度指标，即 AP_S（小目标）、AP_M（中等目标）、AP_L（大目标）。实验结果如表 3 和表 4 所示。

表 3 GC10-DET 数据集上的消融实验结果

Table 3 Ablation experiment results on GC10-DET dataset

DEIM	FDPN	iMANet	FEG-LStem	AP	mAP ₅₀	mAP ₇₅	AP _S	AP _M	AP _L	Parameters/M	GFLOPs
√				36.1	68.0	37.8	24.6	20.6	39.2	10.2	24.8
√	√			39.1	71.0	38.7	27.5	22.2	42.7	10.1	24.6
√		√		40.6	72.4	44.2	25.4	28.6	42.1	10.2	25.2
√			√	40.1	73.4	37.9	20.0	21.2	40.7	8.6	21.6
√	√	√		41.7	76.8	44.9	27.8	27.8	43.2	11.0	29.5
√	√		√	41.5	76.0	42.2	26.9	28.3	43.7	10.5	26.8
√		√	√	41.9	76.5	42.1	27.4	28.9	42.9	9.8	25.4
√	√	√	√	42.6	78.2	43.5	28.7	29.3	44.2	10.3	28.9

表 4 NEU-DET 数据集上的消融实验结果

Table 4 Ablation experiment results on NEU-DET dataset

DEIM	FDPN	iMANet	FEG-LStem	AP	mAP ₅₀	mAP ₇₅	AP _S	AP _M	AP _L	Parameters/M	GFLOPs
√				40.7	66.5	42.2	22.5	35.2	49.1	10.2	24.8
√	√			39.5	70.6	38.8	45.5	33.8	46.9	10.1	24.6
√		√		38.8	68.9	37.1	42.5	33.6	49.4	10.2	25.2
√			√	38.1	67.4	37.1	38.9	33.8	45.7	8.6	21.6
√	√	√		39.7	69.8	43.2	45.8	35.8	49.2	11.0	29.5
√	√		√	41.5	71.5	44.2	44.9	36.3	49.7	10.5	26.8
√		√	√	40.9	70.5	43.6	46.4	36.9	49.9	9.8	25.4
√	√	√	√	42.5	72.8	45.1	47.6	38.7	51.0	10.3	28.9

表 4 结果显示，基线模型（DEIM）在复杂背景下的特征捕捉能力有限，mAP₅₀ 和 mAP₇₅ 值分别为 68.0% 和 37.8%。单独引入 FDPN 后，mAP₅₀ 提升至 71.0%，AP_S 和 AP_M 分别提高 2.9% 和 1.6%。这表明聚焦-扩散机制能有效提升多尺度特征的传输效率，在处理中小尺度缺陷时展现出更优的语义一致性。

集成 FDPN、iMANet 后，mAP₇₅ 指标提升至 44.9%（+7.1%），在所有增强方案中对高 IoU 阈值的贡献最为突出。这归因于 iMANet 内置的 iRMB 模块，该模块实现了局部细节与长程依赖关系的协同建模，进一步提升了特征判别能力。

引入 FEG-LStem 后，平均绝对精度（mAP₅₀）提升至 73.4%，模型参数量由 1020 万降至 860 万，计算量下降

12.9%。实验表明，该模块借助 LoG 算子引入边缘先验信息，既强化大规模缺陷轮廓表征能力（AP_L 达到 40.7%），也实现了检测精度与运行效率的兼顾优化。

当所有模块协同运作时，该模型在各项指标上均达到最优表现，mAP₅₀ 值高达 78.2%——较基线模型提升 10.2%。这表明底层特征增强、阶段内信息交换与跨尺度金字塔融合之间存在协同作用关系。

在 NEU-DET 数据集上，所提出的模块展现出良好的性能稳定性与泛化能力。实验结果表明：FDPN 模型在小目标检测方面表现良好，AP_S 从 22.5% 进一步提升至 45.5%；而 iMANet 模型在多尺度权衡中保持性能平衡，增强了模型对复杂纹理缺陷的鲁棒性。完整版模型达到 45.1% 的 mAP₇₅ 值，同时 AP_S、AP_M

和 AP_L 指标分别达到 47.6%、38.7%和 51.0%。实验结果表明,相较于基线模型,LMF-DETR 实现了全范围检测精度的提升,充分验证了其在金属表面极端条件下的检测鲁棒性。

mAP_{50} 、 mAP_{75} 、 AP_S 及 AP_M 同步性指标的提升,充分展现了该模型在精确定位精度方面的核心优势,尽管引入特征增强与多尺度融合机制带来了微小的计算开销,但其对检测精度的增益是决定性的。与基线模型相比,所提方法在参数规模基本不变、计算复杂度增加了 4.1GFLOPs 的情况,在 GC10-DET 数据集上取得了 10.2%的精度提升。这充分证明了模型设计的合理性。

2.5 训练损失收敛性与稳定性分析

针对端到端网络中复杂特征交互结构(如串联与双路径设计)可能引发的梯度回传问题,本文对比了所提出的 LMF-DETR 模型与基线 DEIM 模型在训练阶段的 Loss 收敛曲线(如图 8 所示)。




图 8 LMF-DETR 与 DEIM 收敛曲线对比

Fig.8 Comparison of the convergence curves between LMF-DETR and DEIM

从曲线的整体走势来看,两者的损失函数均呈现出连续且平稳的下降态势,并最终达到收敛。在整个训练周期内,LMF-DETR 并未出现梯度消失或梯度爆炸的现象。在收敛效率方面,基线模型 DEIM 需要约 13,390 次迭代才完全趋于平缓,而 LMF-DETR 在约 10,710 次迭代时便已进入稳定的收敛区间,收敛速度提升了约 20%,且最终的损失绝对值与基线模型处于同一稳定水平。

曲线中观察到的高频轻微震荡是 DETR 系列架构的典型特征。这主要源于网络在端到端训练中,匈牙利匹配(Hungarian Matching)机制在不同批次间动态分配正负样本所带来的固有梯度方差。这种局部的正常波动完全处于可控范围内,并未影响损失函数的宏观下降趋势,且在训练中后期逐渐收窄。

2.6 错误诊断与分析

为了深入分析所提改进模块对检测性能的增益机理,本文引入 TIDE^[25]评估框架,即 Loc(Localization, 定位误差)、Both(Loc+Sim, 定位+相似混淆)、

Dupe(Duplicate, 重复检测)、Bkg(Background, 背景混淆)、Cls(Classification, 分类误差)、Miss(Missed, 漏检)。对基线模型 DEIM 与 LMF-DETR 在 GC10-DET 数据集上的误差分布进行了精细化分析。实验结果如表 5 和图 9 所示。

表 5 改进前后 dAP 对比

Table 5 dAP Comparison Before and After Modification

错误类型	DEIM	LMF-DETR	幅度变化
Loc (定位)	4.41	3.77	↓0.64
Both (混合)	0.19	0.21	↑0.02
Bkg (背景)	3.29	2.13	↓1.16
Dupe (重复)	4.1	1.49	↓2.61
Cls (分类)	1.88	1.48	↓0.40
Miss (漏检)	0.62	0.30	↓0.32




图 9 改进前后 dAP 对比

Fig.9 Comparison of dAP before and after improvement

实验表明,改进后的模型在大部分的误差上实现了性能提升,其中 Dupe 误差降幅最大,从 4.10 骤降至 1.49(下降约 63.7%)。这验证了本文提出的 iMANet 与 FDPN 模块在特征聚合方面的优越性。通过强化阶段内特征交互与低损耗的多尺度传播,实现了更准确的语义归一化,有效消除了冗余预测。

Bkg 误差从 3.29 降低至 2.13(下降 35.3%)。得益于本文模型 LMF-DETR 在前端阶段 FEG-LStem 模块中引入的 LoG 滤波器,增强了缺陷边缘与背景纹理的判别性。这种对底层高频信息的显式建模,使得网络能够更清晰地辨识真实缺陷与相似背景噪声。

图 10 展示了基线模型 DEIM 与本文提出的 LMF-DETR 在 TIDE 评估标准下的主误差分布对比。




图 10 误差分布对比

Fig.10 Error Range Comparison

首先, 最明显的变化体现在重复预测误差 (Dupe) 的比例上, 基线模型的 Dupe 占比高达 28.3%, 是仅次于定位误差的主要瓶颈; 而在 LMF-DETR 中, 该比例被大幅压缩至 15.9%。

其次, 观察定位误差 (Loc) 的占比迁移可以发现,

其比例从 30.4% 上升至 40.2%。需要明确的是, 尽管其占比上升, 但由于总 dAP 数值的下降, Loc 实际上已得到优化。这种占比的提升反映了高性能检测器的一个普遍特征: 即在解决掉分类混乱和冗余预测等误差后, 如何进一步提升边界框回归的精度成为了模型持续进步的核心挑战。

最后, 在工业场景最为关注的漏检误差 (Miss) 方面, LMF-DETR 将其占比从 4.3% 进一步降低至 3.2%。极低的漏检比例结合提升的检测精度, 验证了所提模型在复杂工业环境下拦截微小、低对比度缺陷的可靠性, 满足了钢铁生产中的高安全性需求。

2.7 各类缺陷类型的 mAP50/% 指标分析

为分析各模块对不同缺陷的贡献度, 图 11 对比了各改进方案在 GC10-DET 分类数据集上的 mAP₅₀ 指标表现。




图 11 不同改进措施下各类缺陷类型的 mAP50/% 指标

Fig.11 mAP50/% indicators of each defect type under different improvements

实验结果表明, 完整模型在多数分类类别中取得最优性能。特别是在打孔 (ph)、焊缝线 (wl)、轧制凹坑 (rp) 及腰带褶皱 (wf) 等类别中, 改进效果相比基线方法有较大的改善, 尽管在油渍 (os) 和褶皱 (cr) 类别中, 单独引入 FDPN 的效果略优于完整模型, 这源于此类缺陷通常呈现大尺度特征且与背景高

度耦合。FDPN 的聚焦-扩散机制通过增强全局语义对齐能力, 在此类宏观特征建模中展现出较高的适应性。但通过引入 FEG-LStem 和 iMANet, 其对细微复杂缺陷 (如 rp、wf) 的捕捉能力有明显改善。这种权衡使得 LMF-DETR 在全面工业工况下展现出更稳健的平均检测准确率。

2.8 比较实验与分析

2.8.1 σ 参数对比实验

为验证 σ 参数的合理性, 本文在 GC10-DET 数据集上进行对比分析。本文 σ 参数固定多尺度 (0.7/1.0/1.3) 与可学习 σ 、固定单尺度 σ (1.0) 展开对比。实验结果见表 6。

表 6 GC10-DET 上的对比实验结果

策略	σ 取值	mAP50	AP	GFLOPs
A	可学习	71.5	39.9	23.9
B	(1.0)	67.4	38.6	15.6
C (本文)	(0.7/1.0/1.3)	73.4	40.1	21.6

相比之下, 本文提出的固定多尺度 $\sigma=(0.7,1.0,1.3)$ 策略 (C) 取得了最佳综合性能, mAP50 达到 73.4%, AP 达到 40.1%, 分别较可学习 σ 提升 1.9% 和 0.2%, 同时计算量控制在 21.6 GFLOPs, 低于可学习策略。该结果表明, 多尺度固定 σ 设计能够有效覆盖不同尺

寸缺陷的响应范围, 在保留 LoG 先验边缘增强能力的同时, 兼顾检测精度与计算效率, 验证了本文参数设置的合理性与有效性。

2.8.2 主流算法对比实验

为验证所提模型的有效性与可行性, 本文采用两个数据集进行对比分析。该模型与 YOLOv7^[26]、FasterRCNN、YOLOv8s^[27]、FasterRCNN、SSD、DINO^[28]、RT-DETR^[29] 及 D-FINE^[30] 等主流目标检测算法展开对比。实验结果见表 7 和表 8。

实验结果表明, 所提出的 LMF-DETR 模型在两个数据集上均展现出了稳定性能。与传统检测算法相比, LMF-DETR 在准确性方面表现更优。如表 7 和表 8 所示, 综合对比实验证明了 LMF-DETR 模型在金属表面缺陷检测中的有效性与优越性。该模型在公开数据集上展现出良好性能与适应性, 展现出广阔的应用前景。

表 7 GC10-DET 上的对比实验结果

Table 7 Comparative experiment results on GC10-DET

Model	Image Size	R%	mAP ₅₀₋₉₅ %	mAP ₅₀ %	Parameters/M	GFLOPs
YOLOv7	640×640	62.1	40.8	69.4	37.2	104.8
YOLOv8s	640×640	61.7	41.4	63.7	11.1	28.8
FasterRCNN	640×640	61.5	40.2	64.1	41.4	134
SSD	640×640	61.6	40.7	65.4	24.4	62.7
DINO	640×640	64.7	41.5	74.3	29.6	75.3
RT-DETR	640×640	63.4	41.2	73.2	39.0	57.0
D-FINE	640×640	64.2	40.9	68.3	10.2	25.2
DEIM	640×640	65.1	40.7	68.0	10.2	24.8
Ours	640×640	65.2	42.8	78.2	10.3	28.9

表 8 NEU-DET 上的对比实验结果

Table 8 Comparative experiment results on NEU-DET

Model	Image Size	R%	mAP ₅₀₋₉₅ %	mAP ₅₀ %	Parameters/M	GFLOPs
YOLOv7	640×640	70.4	41.6	70.1	37.2	104.8
YOLOv8s	640×640	70.9	42.3	72.8	11.1	28.8
FasterRCNN	640×640	68.1	40.8	71.3	41.4	134
SSD	640×640	67.4	40.9	67.9	24.4	62.7
DINO	640×640	68.7	41.5	70.2	29.6	75.3
RT-DETR	640×640	69.9	41.8	72.7	39.0	57.0
D-FINE	640×640	70.2	42.6	67.7	10.2	25.2
DEIM	640×640	68.4	42.7	66.4	10.2	24.8
Ours	640×640	73.1	43.4	72.8	10.3	28.9

2.9 热力图检测结果对比与特征图分析

为了进一步从定性角度探究所提 LMF-DETR 模型的特征提取与定位机理, 本文引入了热力图对检测过程进行可视化。如图 12 和图 13 所示。通过对比原图、基线模型 (DEIM) 以及本文模型 (LMF-DETR) 的特征响应分布, 可以观察到以下特征: 基线模型 DEIM 的热力图激活区域呈现破碎化趋势, 导致对同一物理区域输出了多个相互重叠的预测框。相比之下, LMF-DETR 的热力图激活区域更为连贯且集中, 能够将分布散乱的缺陷特征有效聚合。实现了更强的全局

建模能力, 从特征层面抑制了重复预测 (Dupe Error) 的产生, 确保了检测结果的语义一致性。

为验证所提方法的有效性, 本文对 LMF-DETR 的特征响应进行了可视化分析。如图 14 所示, 相较于基线模型 DEIM, LMF-DETR 模型展现出更强的背景噪声抑制能力和特征聚焦精度。在复杂纹理与低对比度场景中, LMF-DETR 的激活区域与缺陷几何形态高度吻合, 响应强度呈现更集中连续的分布特征, 且未出现基线模型中常见的响应扩散或断裂现象。这直观印证了该模型在提升语义判别能力与定位鲁棒性方面的有效性。




图 12 GC10-DET 热力图对比
Fig.12 Comparison of GC10-DET thermograms




图 13 NEU-DET 热力图对比
Fig.13 Comparison of NEU-DET thermal maps




图 14 特征提取对比

Fig.14 Feature extraction comparison

3 结束语

本文针对钢材表面缺陷检测中结构模糊、对比度低及缺陷尺寸高度不均衡等问题,提出多特征增强型端到端检测模型 LMF-DETR,从特征提取初始阶段、阶段内特征融合、多尺度特征扩散三个层次实现系统性优化,在保持端到端优势的同时提升了检测精度与鲁棒性。

实验结果表明,LMF-DETR 在两个公开数据集 GC10-DET 和 NEU-DET 上均取得稳定且明显的性能提升,其改进并非依靠简单的模块堆叠,而是基于钢材表面缺陷成像特点与工程约束进行针对性建模。FEG-LStem 模块通过 LoG 边缘增强与轻量级特征映

射,强化了微小与细粒度缺陷检测能力,在提升 AP_s 、 mAP_{75} 的同时降低参数量与计算量,验证了底层特征质量对检测效果的关键作用。iMANet 模块依托多分支特征聚合与局部上下文建模,有效提升中尺度缺陷检测性能与整体 mAP ,在增强感受野互补性的同时抑制复杂纹理与镜面反射噪声,实现高召回率与低误报率的兼顾。FDPN 模块采用两阶段迭代聚焦-扩散机制,缓解多尺度融合中的信息稀释问题,使大尺度缺陷检测 AP_L 与多尺度检测一致性提升,在复杂背景下表现出更强的结构连续性与定位稳定性。

三模块协同作用,使模型在 mAP_{50} 与 mAP_{75} 下实现各类 AP 指标同步提升,形成特征初始化、阶段内融合、跨尺度扩散的多级协同增益。模型在计算开销

可控的前提下,实现了精度、稳定性与工程适用性的综合提升,有效解决了钢材缺陷对比度极低、边界模糊、噪声干扰强等工程难点。

未来工作将围绕复杂成像环境下的鲁棒性提升、轻量化与边缘部署优化,以及缺陷检测与等级评估一体化建模展开,进一步增强模型在实际工业场景中的应用价值。

参考文献:

- [1] ZHOU X, SONG K, FU J, et al. A review of surface defect detection of steel strip based on deep learning[J]. IEEE Transactions on Instrumentation and Measurement, 2022, 71: 1-16.
- [2] LIU Y, WANG H, ZHANG L. Review of surface defect detection of steel products based on machine vision[J]. IET Image Processing, 2023, 17(1): 1-22.
- [3] WU S, MA S. A Review of Metal Surface Defect Detection Technologies in Industrial Applications [J]. Applied Sciences, 2025, 15 (4): 2186.
- [4] 伍麟, 郝鸿宇, 宋友. 基于计算机视觉的工业金属表面缺陷检测综述 [J]. 自动化学报, 2024, 50 (7): 1261-1283.
Wu L, Hao H Y, Song Y. Review of industrial metal surface defect detection based on computer vision[J]. Acta Automatica Sinica, 2024, 50(7): 1261-1283.
- [5] TABERNIK D, SELA S, SKVARC J, et al. Segmentation-based deep-learning approach for surface-defect detection[J]. Journal of Intelligent Manufacturing, 2020, 31(3): 759-776.
- [6] 向宽, 李松松, 栾明慧, 等. 基于改进 Faster RCNN 的铝材表面缺陷检测方法 [J]. 仪器仪表学报, 2021, 42 (1): 191-198. Xiang K, Li S S, Luan M H, et al. Aluminum surface defect detection method based on improved Faster RCNN[J]. Chinese Journal of Scientific Instrument, 2021, 42(1): 191-198.
- [7] CHU Y, YU X, RONG X. A Lightweight Strip Steel Surface Defect Detection Network Based on Improved YOLOv8 [J]. Sensors, 2024, 24: 6495.
- [8] 高春艳, 秦荣, 李满宏, 等. 改进 YOLOv7 算法的钢材表面缺陷检测研究 [J]. 计算机工程与应用, 2024, 60 (7): 282-291. Gao C Y, Qin S, Li M H, et al. Research on steel surface defect detection based on improved YOLOv7 algorithm[J]. Computer Engineering and Applications, 2024, 60(7): 282-291.
- [9] 陶友凤, 姜麟, 大妹. 基于 RCD-YOLO 的钢材表面缺陷检测算法 [J/OL]. 控制工程, 2024: 1-9 [2026-05-26].
Tao Y F, Jiang L, Da M. Steel surface defect detection algorithm based on RCD-YOLO[J/OL]. Control Engineering of China, 2024: 1-9[2026-05-26].
- [10] HE Y, SONG K, MENG Q, et al. An end-to-end steel surface defect detection approach via improved Faster R-CNN[J]. IEEE Transactions on Instrumentation and Measurement, 2019, 69(5): 2641-2650.
- [11] LI W, YE X, ZHAO Y, et al. Strip steel surface defect detection based on improved yolov3 algorithm[J]. Acta Electronica Sinica, 2020, 48(7): 1284-1292.
- [12] WANG X, GIRSHICK R, GUPTA A, et al. Non-local neural networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Salt Lake City: IEEE, 2018: 7794-7803.
- [13] CARION N, MASSA F, SYNNAEVE G, et al. End-to-end object detection with transformers[C]//Proceedings of the European Conference on Computer Vision (ECCV). Glasgow: Springer, 2020: 213-229.
- [14] HUANG S H, LU Z C, CUN X D, et al. DEIM: DETR with improved matching for fast convergence [C]//2025 IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2025: 15162-15171.
- [15] RAO Y, ZHAO W, ZHU Z, et al. HorNet: Efficient high-order spatial interactions with recursive gated convolutions[C]//Advances in Neural Information Processing Systems (NeurIPS). New Orleans: Curran Associates, 2022: 10353-10366.
- [16] CAO S, et al. Legnet: lightweight edge-gaussian driven network for low-quality remote sensing image object detection[J]. IEEE Geoscience and Remote Sensing Letters, 2025, 22: 6000305.
- [17] GONZALEZ R C, WOODS R E, EDDINS S L. Digital Image Processing Using MATLAB[M]. 3rd ed. Gatesmark Publishing, 2020: 186-194.
- [18] SZELISKI R. Computer vision: algorithms and applications[M]. 2nd ed. Cham: Springer Nature, 2022: 156-160.
- [19] HAN K, WANG Y, TIAN Q, et al. Ghostnet: more features from cheap operations[C]//Proceedings of the IEEE/CVF

- Conference on Computer Vision and Pattern Recognition (CVPR). Seattle: IEEE, 2020: 1580-1589.
- [20] LI X, WANG W, HU X, et al. Selective kernel networks[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Long Beach: IEEE, 2019: 510-519.
- [21] ZHANG J, LI X, LI J, et al. Rethinking mobile block for efficient attention-based models[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). Paris: IEEE, 2023: 1389-1400.
- [22] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[C]//International Conference on Learning Representations (ICLR). Virtual: OpenReview, 2021.
- [23] SZEGEDY C, VANHOUCKE V, IOFFE S, et al. Rethinking the inception architecture for computer vision[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Las Vegas: IEEE, 2016: 2818-2826.
- [24] WANG C Y, BOCHKOVSKIY A, LIAO H Y M, et al. Csp-net: a new backbone that can enhance learning capability of cnn[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) Workshops. Seattle: IEEE, 2020: 390-391.
- [25] BOLYA D, FOLEY S, HAYS J, et al. Tide: A general toolbox for identifying object detection errors[C]//Proceedings of the European Conference on Computer Vision (ECCV). Glasgow: Springer, 2020: 558-573.
- [26] HENDERSON P, FERRARI V. End-to-end training of object class detectors for mean average precision[C] //Proceedings of the Asian Conference on Computer Vision (ACCV). Taipei: Springer, 2017: 198-213.
- [27] WANG C Y, BOCHKOVSKIY A, LIAO H Y M, et al. YOLOv7: trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Vancouver: IEEE, 2023: 7462-7471.
- [28] ZHANG H, LI F, LIU S, et al. Dino: detr with improved denoising anchor boxes for end-to-end object detection[C]// Proceedings of the International Conference on Learning Representations (ICLR). Kigali: OpenReview, 2023.
- [29] LV W, ZHAO Y, XU S, et al. Detrs beat yolos on real-time object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle: IEEE, 2024: 16965-16974.
- [30] PENG Z, HUANG Z, LI Y, et al. D-fine: redefining regression task for real-time object detection[R/OL]. (2024-10-15)[2026-04-09].<https://arxiv.org/abs/2410.11893>.