



计算机工程与应用
Computer Engineering and Applications
ISSN 1002-8331, CN 11-2127/TP

《计算机工程与应用》网络首发论文

题目: MDWF-YOLO:多尺度双路加权融合的航拍小目标检测网络
作者: 李方方, 雷鸣, 郭森海
网络首发日期: 2026-07-09
引用格式: 李方方, 雷鸣, 郭森海. MDWF-YOLO:多尺度双路加权融合的航拍小目标检测网络[J/OL]. 计算机工程与应用.
<https://link.cnki.net/urlid/11.2127.TP.20260709.0934.012>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

MDWF-YOLO:多尺度双路加权融合的航拍小目标检测网络

李方方^{1,2}, 雷鸣^{1,2+}, 郭森海³

1.长江大学 计算机科学学院, 湖北 荆州 434023

2.长江大学 人工智能科研平台, 湖北 荆州 434023

3.武汉华润燃气有限公司, 武汉 430000

+ 通信作者 E-mail: 6611972@qq.com

摘要: 针对无人机航拍图像中目标尺度微小、遮挡密集、背景复杂以及光照不均等固有挑战所导致的YOLOv26模型小目标检测精度受限、深层语义特征易丢失的问题, 提出一种多尺度双路加权融合航拍小目标检测模型MDWF-YOLO。首先, 在骨干网络中构建双路径下采样骨干网络, 于原生卷积下采样分支之外增设Haar小波下采样路径, 以缓解深层网络中小目标特征的流失。其次, 设计轻量级混合局部与全局注意力(Mixed Local and Global Attention, MLGA)模块以重构C3k2单元, 强化对关键区域的特征响应。再次, 提出自适应快速空间金字塔池化(Adaptive Spatial Pyramid Pooling-Fast, ASPPF)模块, 通过可学习权重动态融合最大池化与平均池化, 有效保留小目标细节表征。在此基础上构建加权路径聚合网络, 增设极小目标检测头并设计加权拼接模块, 实现骨干双路下采样各层级与颈部网络对应层级特征的加权融合, 使网络能够自主学习不同来源特征的最优贡献系数。此外, 引入余弦衰减调度策略优化端到端损失函数中一对多分支权重的衰减轨迹。为满足无人机机载平台对计算资源与存储空间的严苛限制, 进一步对MDWF-YOLO实施递进式轻量化处理, 综合利用网络结构剪枝、可分离卷积下采样及幽灵瓶颈模块, 设计四个轻量化变体版本(v1-v4), 以在检测精度与推理效率之间获取灵活可选的平衡。在VisDrone2019数据集上的实验结果表明, 与基线YOLOv26n相比, v1模型在参数量降低51.8%、计算量仅为7.2 GFLOPs的条件下, mAP50与mAP50:95分别提升4.3与3.6个百分点; v4模型则在保持mAP50:95与基线持平的同时, 参数量、计算量与模型大小分别大幅削减88.4%、29.3%与76.6%, 计算量低至4.1 GFLOPs。所提方法在显著提升航拍小目标检测精度的同时, 为资源受限条件下的高效部署提供了多档位可选解决方案。

关键词: 无人机航拍图像; 小目标检测; YOLOv26; 双路加权融合; 混合注意力; 轻量化模型

文献标志码:A 中图分类号:TP391.41 doi: 10.3778/j.issn.1002-8331.2604-0240

MDWF-YOLO: A Multi-scale Dual-path Weighted Fusion Network for Aerial Small Object Detection

LI Fangfang^{1,2}, LEI Ming^{1,2+}, GUO Senhai³

1. School of Computer Science, Yangtze University, Jingzhou, Hubei 434023, China

2. Artificial Intelligence Research Platform, Yangtze University, Jingzhou, Hubei 434023, China

3. Wuhan China Resources Gas Company Limited, Wuhan 430000, China

Abstract: To address the challenges of tiny scales, dense occlusions, complex backgrounds, and uneven illumination in UAV aerial images, which limit small-object detection accuracy and cause deep feature loss in YOLOv26, MDWF-YOLO, a multi-scale dual-path weighted fusion detection model, is proposed. First, a dual-path downsampling backbone is constructed by adding a Haar wavelet downsampling path alongside the standard convolution downsampling path to mitigate small-object feature loss in deep networks. Second, a lightweight Mixed Local and

基金项目: 国家自然科学基金面上项目(62276032)。

作者简介: 李方方(2001—), 男, 硕士研究生, 研究方向为机器学习与人工智能、目标检测; 雷鸣(1979—), 男, 硕士研究生, 副教授, 研究方向为计算机检测与控制、信号处理、智能系统、油气田软件开发; 郭森海(1973—), 男, 工程师, 研究方向为工业自动化、数控技术。

Global Attention (MLGA) module is designed to reconstruct the C3k2 unit, enhancing feature responses in critical regions. Third, an Adaptive Spatial Pyramid Pooling-Fast (ASPPF) module is proposed, which dynamically fuses max-pooling and average-pooling outputs with learnable weights to preserve fine-grained small-object details. Then, a Weighted Path Aggregation Network is built, incorporating a tiny-object detection head and a weighted concatenation module. This module enables weighted fusion of features at corresponding levels between the dual-path downsampling backbone and the neck network, allowing adaptive learning of optimal contribution coefficients for different sources. Furthermore, a cosine decay schedule is introduced to optimize the decay trajectory of the one-to-many branch weights in the end-to-end loss function. To satisfy the strict computational and storage constraints of UAV onboard platforms, MDWF-YOLO is progressively lightened through network pruning, separable convolution downsampling, and ghost bottleneck modules, resulting in four lightweight variants (v1–v4) that offer flexible trade-offs between detection accuracy and inference efficiency. Experiments on the VisDrone2019 dataset demonstrate that, with a 51.8% parameter reduction and only 7.2 GFLOPs, the v1 variant improves mAP50 and mAP50:95 by 4.3 and 3.6 percentage points over the baseline YOLOv26n, respectively. The v4 variant maintains the baseline mAP50:95 while reducing the parameter count, computational cost, and model size by 88.4%, 29.3%, and 76.6%, respectively, achieving a computational cost of merely 4.1 GFLOPs. The proposed method significantly enhances small-object detection accuracy in aerial images and provides a family of selectable solutions for efficient deployment under resource-constrained conditions.

Key words: UAV aerial imagery; small object detection; YOLOv26; dual-path weighted fusion; hybrid attention; lightweight model

近年来,无人机应用已从农业植保、公共安全延伸至紧急物流、军事安防等诸多领域。然而,其特有的俯拍视角也带来了相应的技术挑战:一方面,图像中充斥大量难以辨识的小与极小目标;另一方面,严重的遮挡、复杂的背景及不稳定的光照条件,共同导致了检测精度的显著下降。此外,无人机有限的硬件资源进一步要求检测模型必须轻量化,以确保在实际部署中能达到最佳效果。

传统的目标检测方法通常遵循一个区域提议、特征提取和分类器的多阶段流水线,其流程复杂且分离、特征表示能力有限、检测速度与精度难以兼得和泛化能力较弱等局限性,使得其不能在如今实时性要求较高的无人机场景中应用。

随着深度卷积神经网络(DCNN)^[1]的强大特征学习能力被揭示,目标检测^[2]领域进入了以数据驱动和端到端学习为标志的深度学习时代。与传统方法相比,基于深度学习的方法在精度和速度上实现了质的飞跃。当前的主流方法根据其检测流程,大致可分为两大类:两阶段(two-stage)检测器和单阶段(one-stage)检测器。两阶段检测器将检测分为两步:首先生成区

域提议,即可能包含物体的候选区域,然后对这些候选区域进行分类和精确边界框回归,其通常检测精度较高,但是推理速度相对较慢,如:R-CNN^[3]、Fast R-CNN^[4]、Faster R-CNN^[5]、Mask R-CNN^[6]等。单阶段检测器摒弃了生成区域提议的步骤,直接在图像上密集采样,预测物体的类别和边界框,其检测速度较快,检测精度也很高,更适合实时应用,如:YOLO系列^[7]、SSD^[8]、RetinaNet系列^[9]、EfficientDet^[10]、DETR等^[11]。

人工智能技术的飞速发展,正推动无人机应用进入前所未有的广阔领域。然而,无人机航拍图像中小目标占比高的特点,与其带来的检测难度极大的挑战形成了尖锐矛盾。这一矛盾,使得针对无人机的小目标检测模型研究成为当前备受关注的的前沿焦点。为应对无人机小目标检测的挑战,现有研究主要从网络结构优化、注意力机制引入和模型轻量化设计等路径展开,但普遍面临精度与效率的平衡难题。

在结构优化方面,李等人^[12]通过引入Bi-PAN-FPN与GhostBlockV2来增强特征融合并削减参数量,然其小目标检测精度未达预期。王等人^[13]设计的

CS-FPN 与位置重校准模块 (FRM) 虽有效缓解了特征丢失, 却以计算量激增 279.4% 为代价, 部署成本过高。翟等人^[14]与张^[15]则分别通过增减检测头、集成三明治融合模块等方式针对性优化, 但前者推理耗时增加, 后者结构复杂性依然显著。

在注意力机制应用方面, Neeraj Battish 等人^[16]提出的 SDMMNet 与 MEECA 机制虽提升了精度, 但导致参数量与计算量同步大幅上涨。胡等人^[17]基于多注意力机制生成注意力图, 有效聚焦密集小目标, 但其图像裁剪策略会破坏大目标结构, 存在检测盲区。

在轻量化与剪枝策略方面, 李等人^[18]通过 RFCBAMConv 与 STCMSP 结构强化小目标特征提取, 但模型体积仍超出 YOLOv11n 基准 50%。相较之下, 李等人^[19]采用可变形卷积与 LAMP 剪枝, 在提升精度的同时实现了模型压缩, 展现出更优的工程潜力。惠等人^[20]跨界引入 Swin Transformer 等组件, 创新性显著, 然其整体计算开销未明确, 部署可行性存疑。

综上所述, 当前针对航拍小目标检测的相关研究, 仍难以在严格控制模型参数量与计算量、保障推理实时性的同时, 实现检测精度的大幅提升, 检测精度与部署效率的权衡优化, 始终是该领域待解决的核心挑战。

1 YOLOv26

YOLOv26 是 Ultralytics 团队于 2026 年初开源的新一代实时目标检测模型, 定位为兼顾边缘端实时部署效率与高精度, 延续系列易用、高效、多场景适配的特点, 在目标检测、实例分割、旋转框检测、姿态估计等任务上均实现了性能与落地性的双重升级。其网络架构由骨干网络、颈部网络和检测头三部分组成, 核心改进集中在端到端推理架构重构、检测头轻量化设计和训练范式优化三大维度。其结构如图 1 所示。

YOLOv26 最核心的架构革新是原生无 NMS 端到端推理。传统 YOLO 模型依赖 NMS 后处理去除冗余检测框, 该环节不仅引入固定推理延迟, 还存在超参数敏感、密集遮挡场景易漏检、边缘设备算子适配难等问题。YOLOv26 首次在 YOLO 系列中实现端到端无 NMS 设计, 通过一对一标签分配与端到端去重学

习机制, 使模型直接输出无冗余的检测结果, 彻底消除独立后处理环节, 在无损精度的前提下简化了推理全链路, 降低了边缘部署的延迟波动与工程复杂度。

轻量化回归分支重构是 YOLOv26 面向边缘部署的关键设计。自 YOLOv8 起引入的 DFL 模块通过对边界框坐标分布建模提升了回归精度, 但也带来计算图复杂度提升和低算力设备适配性差等问题。YOLOv26 彻底移除 DFL 模块, 以轻量化直接坐标回归替代分布建模, 并通过配套训练策略保障回归精度无损失, 简化了计算图结构, 减少内存占用, CPU 端单帧推理速度较前代模型最高提升 43%。

训练范式全链路优化是 YOLOv26 性能提升的核心支撑。引入 ProgLoss 渐进式损失平衡策略, 根据训练进度动态调整各损失项权重, 强化小目标和遮挡目标的特征学习; 设计 STAL 小目标感知标签分配机制, 优化小目标样本匹配规则, 提升学习效率; 配套 MuSGD 混合优化器, 融合 SGD 的强泛化能力与先进优化思路, 提升训练稳定性与收敛速度。

总之, YOLOv26 通过端到端架构革新、轻量化设计和训练范式升级三大维度的协同改进, 进一步拉近了边缘场景下实时性与高精度的平衡边界, 降低了开发者算法落地门槛, 是当前从实验室创新到工业级边缘部署的优选端到端实时视觉方案之一。




图1 YOLOv26模型结构图

Fig.1 YOLOv26 model structure

2 MDWF-YOLO

尽管YOLOv26n在通用数据集COCO上表现出色, 但其在无人机专用数据集VisDrone2019上的性能却显著下降 (mAP50:95 仅为 19.2%)。这一性能落差主要源于VisDrone2019图像中含有大量小目标, 且普遍存在遮挡与光照不均等复杂场景, 对模型的泛化能力提出了更大挑战。为了提高其精确度, 提出一种基于YOLOv26的多尺度双路加权融合网络: MDWF-YOLO。其结构如图2所示。




图2 MDWF-YOLO模型结构图

Fig.2 MDWF-YOLO model structure

其一, 构建双路径下采样骨干网络 (Dual-Path Downsampling Backbone Network, DPDBN), 在原生卷积下采样分支基础上新增 Haar 小波下采样路径, 缓解深层网络中小目标特征丢失问题; 其二, 设计轻量级混合局部与全局注意力 (Mixed Local and Global Attention, MLGA) 模块改进 C3k2 结构, 增强网络特征提取能力; 其三, 提出自适应快速空间金字塔池化 (Adaptive Spatial Pyramid Pooling-Fast, ASPPF) 模块替换原生 SPPF 模块, 通过自适应加权融合平均池化与最大池化操作, 充分保留小目标细节特征; 其四, 构建加权路径聚合网络 (Weighted Path Aggregation Network, WPA-Net), 新增极小目标检测头并设计加权拼接模块, 实现骨干双路径下采样各层级与颈部网络各层级特征的加权融合, 使网络可自主学习不同层级特征的贡献权重; 其五, 引入余弦衰减策略优化一对多损失的衰减权重, 进一步提升模型对小目标的学习能力与检测精度; 最后, 为了在检测精度与推理效率之间获取灵活可选的平衡, 综合利用网络结构剪枝、可分离卷积下采样及幽灵瓶颈模块实施递进式轻量化

处理, 设计了四个轻量化变体版本 (v1-v4)。

2.1 双路径下采样骨干网络

YOLOv26 在无人机航拍图像检测任务中的主要瓶颈在于对小目标及极小目标的检测能力不足。由于无人机高空视角导致小目标在图像中占据绝对主导地位, 而原始网络缺乏针对此类极端尺度分布的专门设计。随着步长为 2 的卷积下采样层数加深, 小目标的空间特征逐级丢失, 检测精度显著下降。为此, 在原始下采样路径基础上, 引入一条基于 Haar 小波变换的无损下采样支路, 最大限度保留小目标的原始特征信息, 构建双路径下采样骨干网络 (DPDBN)。

2.1.1 Haar 小波下采样模块

为缓解传统卷积下采样导致的空间信息丢失问题, 引入基于 Haar 小波变换的下采样模块 (Haar Wavelet Downsampling, HWD)。该模块能够在降低特征图分辨率的同时, 无损保留所有原始信息, 并将其显式分解为结构化的频率子带, 从而增强网络对细节特征的捕获能力, 尤其适用于小目标检测任务。其结构如图 3 所示。




图3 HWD模块结构图

Fig.3 HWD module structure

先是无损特征编码, 输入特征图 $X \in \mathbb{R}^{B \times C \times H \times W}$ (其中 H, W 为偶数), HWD 应用二维 Haar 小波变换。该变换将每个 2×2 的局部邻域分解为四个系数: 低频近似 (LL)、水平高频 (LH)、垂直高频 (HL) 和对角高频 (HH), LL 表示局部区域的平均强度, 保留了轮廓信息; LH 表示响应水平方向的边缘变化; HL 表示响应垂直方向的边缘变化; HH 表示响应对角线方向的纹理或角点。其变换公式如下:

$$LL = \frac{a + b + c + d}{2} \quad (1)$$

$$LH = \frac{a + b - c - d}{2} \quad (2)$$

$$HL = \frac{a - b + c - d}{2} \quad (3)$$

$$HH = \frac{a - b - c + d}{2} \quad (4)$$

其中 $\{a, b, c, d\}$ 为 2×2 块内按行主序排列的像素值。上述变换完全可逆, 且不引入任何信息损失。通过将四个子带沿通道维度拼接成 $X_{\text{haar}} \in \mathbb{R}^{B \times 4C \times H/2 \times W/2}$, 实现了空间到通道的无损信息重排。

其次是进行可学习的特征融合, 虽然 Haar 变换保留了完整信息, 但通道数膨胀至 4 倍。为了控制计算开销并提取高判别性特征, HWD 采用一个 1×1 卷积层对 X_{haar} 进行跨通道融合:

$$X_{\text{out}} = \text{Conv}_{1 \times 1}(X_{\text{haar}}) \in \mathbb{R}^{B \times C_{\text{out}} \times H/2 \times W/2} \quad (5)$$

其中 C_{out} 为期望的输出通道数。该卷积层不仅将通道数压缩至合理范围, 还能通过可学习参数自适应地筛选和组合不同频率分量, 增强对任务有益的特征 (如小目标的边缘高频信息), 同时抑制噪声。

在复杂度上, 相比步长为 2 的 3×3 卷积, HWD 的计算量显著降低, 仅为卷积的 44.4%。此外, HWD 的参数量为 $4C_{\text{in}}C_{\text{out}}$, 而卷积的参数量为 $9C_{\text{in}}C_{\text{out}}$, HWD 减少约 55.6%。

2.1.2 与主流下采样模块比较

与 YOLOv5^[21] 的 Focus 模块相比, HWD 不仅实现了无损下采样, 更通过小波变换显式分离了低频轮廓与多方向高频细节, 为后续网络提供了结构化、物理意义明确的特征表示。而与空间到深度卷积 (SPD-Conv) 相比, HWD 的拼接方式具有频率解释性, 可视为一种硬编码的注意力机制, 引导网络关注边缘纹理等关键信息。大量实验证明, HWD 能有效提升小目标检测性能, 且易于集成到现有 CNN 架构中。

2.1.3 双路径下采样空间对齐方式

在双路径下采样结构中, 两条路径输出特征图的空间对齐是实现有效融合的前提。卷积下采样路径采用步长为 2 的标准卷积操作, 输出特征图的空间分辨率逐级减半, 特征位置坐标通过卷积核的滑动窗口与 padding 补偿实现映射。Haar 小波下采样路径采用离散 Haar 小波变换, 将输入特征图中每个 2×2 局部邻域分解为四个频率子带, 再沿通道维度拼接后, 经 1×1

卷积进行跨通道融合并恢复至目标通道数。上述过程中,由于 Haar 小波变换的分解与重组以 2×2 邻域为基本单元,其输出特征图的空间分辨率同样减半,空间坐标映射关系与步长为 2 的卷积下采样天然一致,二者均以输入特征图中 2×2 局部邻域为单位映射至输出特征图中单个空间位置,且坐标原点对齐方式相同。因此,两条路径在同一层级输出的特征图具有完全一致的空间分辨率与坐标映射关系,可直接沿通道维度进行拼接融合。这一特性保证了双路径特征在后续处理中的空间一致性,为构建加权路径聚合网络提供了结构基础。

2.2 混合局部与全局注意力模块

无人机航拍图像中广泛存在的复杂背景结构与不均匀光照分布会严重削弱小尺度目标的信噪比,导致标准卷积特征提取过程中目标区域响应被杂波淹没。YOLOv26 虽凭借 C3k2 模块的高效跨阶段部分连接实现了良好的速度与精度权衡,但其对空间上下文信息的利用仍局限于固定感受野的卷积堆叠,缺乏对全局场景与局部细节的显式自适应增强机制。

为此,本文提出一种混合局部与全局注意力模块 (MLGA),并据此构建增强型骨干单元 MLGA_C3k2,以在不显著增加计算开销的前提下强化网络对复杂背景下小目标的感知能力。

2.2.1 MLGA 模块

MLGA 模块的核心思想是并行地建模局部显著性响应与全局场景上下文,并通过可微分的特征加权机制将二者融合至原始特征图中。其结构如图 4 所示。




图4 MLGA模块结构图

Fig.4 MLGA module structure

前向传播过程可形式化描述为:首先进行通道压缩,输入特征图 $x \in \mathbb{R}^{C \times H \times W}$ 首先经过由 1×1 卷积、批归一化与 SiLU 激活函数构成的投影层,将通道数

降至原来的一半,以降低后续运算的时空复杂度。

其次进行局部注意力生成,对压缩后的特征图分别施加核尺寸为 5×5 、步长为 1 的最大池化与平均池化。最大池化用于突出局部显著特征并抑制噪声干扰,平均池化则保留纹理细节与区域平滑信息。特别地,平均池化设置不包括填充计算以排除填充区域对统计量的贡献,从而减轻小目标特征被稀释的风险。二者输出经逐元素相加得到局部注意力描述子:

$$A_{\text{local}} = \text{MaxPool}_{5 \times 5}(x') + \text{AvgPool}_{5 \times 5}(x') \quad (6)$$

接着进行全局注意力生成,采用自适应全局平均池化将压缩特征图压缩至 $C' \times 1 \times 1$,捕获通道维度的全局上下文信息:

$$A_{\text{global}} = \text{GlobalAvgPool}(x') \quad (7)$$

最后进行注意力融合与重标定,局部与全局描述子经逐元素相加后,通过另一 1×1 卷积将通道数恢复至原始维度 C ,并经由 Sigmoid 函数将响应值归一化至 $(0,1)$ 区间,得到最终的空间-通道混合注意力图:

$$M = \sigma(\text{Conv}_{1 \times 1}(A_{\text{local}} + A_{\text{global}})) \quad (8)$$

模块输出为原始特征图与注意力图的残差加权结果:

$$\text{MLGA}(x) = x + x \odot M \quad (9)$$

该残差形式既保留了原始特征的完整性,又通过逐元素乘法实现了对非目标区域的软性抑制与对目标区域的定向增强。

2.2.2 局部池化核尺寸选择机理分析

局部注意力分支采用 5×5 池化核尺寸,其选择依据与无人机航拍图像中小目标的尺度特性密切相关。以 VisDrone2019 数据集为例,经 640×640 输入分辨率下采样至 P3 特征图层级后,尺寸小于 32×32 像素的小目标在该层仅占据不超过 4×4 的感受野范围。若采用 3×3 池化核,其有效感受野约为 3×3 像素,对于最大边长接近 32 像素的目标而言,仅能覆盖目标局部区域,难以充分聚合邻域上下文信息,易导致注意力响应碎片化。若采用 7×7 或更大池化核,感受野过大,在高分辨率特征层上会过度引入背景信息,导致小目标特征被周围无关区域稀释,注意力响应的空间定位

精度下降。5×5 池化核在 P3 层对应于约 40×40 像素的输入图像感受野, 与小目标的典型尺寸 (32×32 像素) 较为匹配, 能够在保留邻域上下文的同时维持较高的空间定位精度。此外, 5×5 池化核在 P4、P5 等更深层级对应的感受野逐步增大, 可自适应地捕获更大尺度的上下文信息。为验证核尺寸选择的合理性, 本文在 VisDrone2019 验证集上对 3×3、5×5 和 7×7 三种池化核尺寸进行了消融实验。结果表明 (详见第 3.4.1 节), 5×5 核尺寸的检测精度均优于 3×3 和 7×7, 验证了上述理论分析的正确性。

2.2.3 局部与全局注意力融合方式理论分析

采用直接相加的方式融合局部注意力描述子 A_{local} 与全局注意力描述子 A_{global} , 其合理性可从以下两个角度论证。从信息互补性角度, A_{local} 由 5×5 窗口内的最大池化与平均池化生成, 编码了局部邻域内的显著响应与纹理分布, 空间分辨率与输入特征图一致, 具有精细的空间定位能力; A_{global} 由全局平均池化生成, 将整个空间压缩为单一标量, 编码了通道维度的全局上下文信息, 经广播机制扩展至与 A_{local} 相同的空间维度。两者在信息粒度上形成互补, 局部注意力提供“何处值得关注”的空间定位, 全局注意力提供“何种特征值得关注”的通道先验。从梯度传播角度, 相加操作对两个分支的梯度权重相等 (梯度均为 1), 避免了乘法融合或可学习加权融合可能引入的梯度偏置或额外参数, 保证了训练初期两个分支被均等优化, 有利于稳定收敛。若采用加权融合策略, 需引入额外的可学习参数, 增加了过拟合风险与计算开销。为验证该设计的有效性, 本文在 VisDrone2019 验证集上对比了三种融合策略: 直接相加、可学习加权融合 ($\alpha A_{local} + (1-\alpha)A_{global}$, α 为可学习标量) 以及拼接后卷积融合。结果表明 (详见第 3.4.1 节), 直接相加的检测精度均优于可学习加权融合和拼接后卷积融合, 验证了该设计的合理性。

2.2.4 MLGA_C3k2 模块

基于上述 MLGA 模块, 对 YOLOv26 中的 C3k2 模块进行改进, 其模块结构图如图 5 所示。




图5 MLGA_C3k2模块结构图

Fig.5 MLGA_C3k2 module structure

先构建 MLGA_Bottleneck, 在标准 Bottleneck 单元的输入端口插入 MLGA 模块, 使得输入特征图在进入两个 3×3 卷积变换之前已完成注意力引导的特征提纯, 从而保证后续卷积核聚焦于关键语义区域; 其次构建 MLGA_C3k, 将 C3 结构内部的 Bottleneck 替换为 MLGA_Bottleneck, 实现从单层到多层的注意力强化; 最后构建 MLGA_C3k2, 继承自 C2f 框架, 将瓶颈列表替换为 MLGA_C3k。最终得到的 MLGA_C3k2 模块保持了与原版 C3k2 完全一致的外部接口与通道变换逻辑, 因而可作为即插即用的替代组件无缝部署于现有检测网络中。

2.3 自适应快速空间金字塔池化

空间金字塔池化 (Spatial Pyramid Pooling, SPP) 及其快速实现 (SPPF) 已被广泛用于视觉目标检测任务中, 其通过聚合多尺度上下文信息以增强网络对尺度变化的鲁棒性。然而, SPPF 结构中固定采用最大池化操作, 这存在两方面局限: 其一, 最大池化虽能突出局部显著响应并抑制噪声, 却不可避免地丢弃了部分细节信息, 这对小目标的表征尤为不利; 其二, 池化核尺寸与融合权重为预设常量, 缺乏针对数据特性与任务需求的动态自适应能力。

为克服上述局限, 本文提出一种自适应快速空间金字塔池化 (ASPPF)。ASPPF 在保留 SPPF 高效并行

计算框架的基础上,创新性地引入可学习的通道级自适应池化融合机制,赋予模型动态调整多尺度特征表达的能力。其结构如图6所示。




图6 ASPPF模块结构图

Fig.6 ASPPF module structure

ASPPF 模块的核心组件自适应池化融合 (AdaptivePoolFusion), 其设计如下:

$$y = \sigma(w) \cdot f_{\text{avg}}(x) + (1 - \sigma(w)) \cdot f_{\text{max}}(x) \quad (10)$$

其中, $x \in \mathbb{R}^{C \times H \times W}$ 为输入特征图, f_{avg} 与 f_{max} 分别表示具有相同核尺寸、步长及填充配置的平均池化与最大池化操作; $w \in \mathbb{R}^{C \times 1 \times 1}$ 为可学习通道级权重参数; $\sigma(\cdot)$ 为 Sigmoid 激活函数, 将权重值约束至区间 (0,1)。该机制使得每个通道均能自主学习其在保留纹理平滑性与突出局部显著性之间的最优平衡点。

权重参数 w 的初始化对模块训练的稳定性 and 收敛速度具有重要影响。本文采用常数初始化策略, 将所有权重初始值设为 0.5, 使得 $\sigma(0.5) \approx 0.622$, 即训练初期平均池化与最大池化的加权系数分别约为 0.622 和 0.378。这一设计赋予平均池化略高的初始权重, 确保训练初期能够充分保留细节信息, 有利于小目标特征的提取; 随着训练推进, 网络可根据各通道的实际需求通过反向传播自适应调整该比例。若采用 0 均值随机初始化, Sigmoid 输出集中在 0.5 附近, 虽无偏但缺乏对小目标细节保护的前期偏向; 若初始化为较大正值或负值, 则会导致训练初期某一池化分支被过度

抑制, 影响梯度流动与收敛速度。

权重参数 w 在网络训练过程中与卷积层权重等参数一同参与反向传播更新, 其梯度由两项因子共同决定: 一是平均池化与最大池化输出的差值, 反映了两种池化在当前特征上的响应差异; 二是 Sigmoid 函数的导数, 在 w 接近 0 时梯度趋于 0, 天然形成软性边界约束, 防止权重更新幅度过大。更新过程中不施加额外的正则化约束或手动调整, 完全由优化器根据损失函数的梯度信号自主调节。这种端到端的自适应更新机制, 使得各通道的融合比例能够根据数据分布与任务需求动态收敛至最优解。

基于此, ASPPF 的整体结构为: 首先, 输入特征图经一个不带激活函数 1×1 卷积将通道数压缩至 $C/2$, 以降低后续运算负担; 随后, 该降维特征图依次通过三次 AdaptivePoolFusion 操作, 其等效感受野随级联次数增加而逐步扩大, 形成从局部细节到全局上下文的多尺度表征序列; 接着, 将三次池化输出与首层降维特征沿通道维度拼接后, 再由一个 1×1 卷积将通道数恢复至目标维度 C_{out} ; 最后, 若输入与输出通道数相同, 则附加恒等残差连接以优化梯度传播。

与标准 SPPF 相比, ASPPF 在计算开销基本持平的前提下引入了极少量可学习参数 (仅与通道数成正比), 却显著提升了特征表达的灵活性与判别力。该模块的轻量化设计与即插即用特性使其能够无缝嵌入现有主干网络, 在无人机航拍图像、小目标检测等背景复杂、信噪比受限的任务中展现出突出的增益效果。

2.4 加权路径聚合网络

无人机航拍图像中包含大量小目标和极小目标, 以 VisDrone2019 数据集为例, 标注框尺寸小于 32×32 像素的目标数量占比高达 41.29%, 且尺寸小于 64×64 像素的目标占比则达到 70%。然而, YOLOv26 原始网络结构中并未设置面向极小目标的 P2 检测头, 这一设计缺陷严重削弱了对小尺度目标的感知与定位能力, 所以应增设了 P2 检测头。同时, 为进一步提升多尺度特征融合的灵活性与鲁棒性, 本文设计了一种自适应加权拼接模块, 并将其应用于骨干网络双路径下采样各层级与颈部网络对应层级特征

之间的融合过程,使得网络能够在训练过程中自主学习不同来源特征的贡献权重,进而构建出加权路径聚合网络(WPA-Net),其网络结构如图7所示。




图7 加权路径聚合网络结构图

Fig.7 Weighted path aggregation network structure

2.4.1 加权拼接模块

在卷积神经网络中,将多源特征图沿通道维度拼接是构建多尺度、多分支架构的基础操作。然而,传统拼接操作隐含假定所有输入特征对后续任务的贡献等权,这一假设在实际中往往不成立,不同层次特征携带的噪声与冗余程度各异,不同模式或感受野下的特征在不同任务中的重要性也存在差异。强制等权不仅引入冗余计算,还可能导致低质量特征对最终表征产生负面影响。

为此,本文提出自适应加权拼接模块(Weighted Concat),通过在拼接前引入一组可学习的通道级缩放因子,赋予网络动态调整各分支贡献度的能力。设 $X = \{x_1, x_2, \dots, x_n\}$ 为待融合特征张量,其中 $x_i \in \mathbb{R}^{C_i \times H_i \times W_i}$, $w_i \in \mathbb{R}$ 为可训练标量权重,前向过程定义为 $Y = \text{Concat}(w_1 \cdot x_1, w_2 \cdot x_2, \dots, w_n \cdot x_n)$,其中 $\text{Concat}(\cdot)$ 沿通道维度拼接。权重以原始浮点数存储,不施加 Softmax 等显式约束,保留各分支独立缩放自由度。

选择以原始浮点数形式存储权重且不施加 Softmax 归一化等显式约束,主要基于以下三方面考量:其一,从特征表达的灵活性角度,Softmax 归一化将各分支权重压缩至和为1的单纯形上,虽然便于解释各分支的相对重要性,但在某些场景下可能限制模型的表达能力。例如,当两条路径的特征质量均较

高且互补性强时,网络可能希望同时放大两者的贡献(即权重均大于1),而 Softmax 约束强制此消彼长,无法实现协同放大;反之,当两条路径的特征均受噪声污染时,网络可能希望同时抑制两者(即权重均小于1),Softmax 同样无法满足。不施加约束的设计允许各分支权重独立变化于整个实数域,赋予网络更充分的表达自由度。其二,从优化稳定性角度,Softmax 归一化在反向传播时引入交叉耦合项,某一支权重的梯度不仅依赖于自身的输出,还依赖于其他分支权重,这种耦合效应在训练初期可能导致梯度振荡。独立标量权重则避免了这种耦合,每个分支的梯度仅取决于该分支特征与损失函数的关系,优化轨迹更平滑。其三,从实际训练表现角度,通过对权重历史值的监测发现,经充分训练后各分支权重能够自发收敛至合理范围,且模值保持在1附近,未见发散或退化现象,表明网络能够自主学习到稳定的融合系数,无需额外的显式约束,并且原始的等权拼接模块也是没有任何显示约束。

相较于等权拼接,WeightedConcat 在多种场景中优势显著,在多尺度特征金字塔(如 FPN、PANet、BiFPN)中,可学习权重自动抑制浅层高频噪声或深层语义模糊,强化最有利于任务的特征层级;在多分支辅助任务集成中,自适应平衡主辅支路贡献,规避梯度冲突。实验表明,替换标准拼接后,模型的检测精度稳定提升,推理延迟与内存占用未见明显增加。

2.4.2 骨干与颈部特征加权融合的合理性分析

将 WeightedConcat 应用于骨干网络双路径下采样各层级与颈部网络对应层级特征之间的融合,构建 WPA-Net。该设计并非对任意层级特征的盲目加权,而是基于对无人机航拍小目标检测任务中多层级特征特性的深入分析。

从特征特性的互补性角度,颈部网络各层级输出的特征图经过骨干网络多层卷积与非线性变换,语义抽象程度较高,对目标类别的判别能力较强,但由于多次下采样操作,空间细节信息已部分丢失;骨干双路径下采样网络中各层级的 HWD 输出特征图通过 Haar 小波变换保留了更多的原始空间细节与高频边缘信息,对小目标的空间定位更为精确,但语义抽象

程度相对较低。两者在信息粒度上形成天然互补，颈部特征提供“是什么”的语义判别，骨干双路径特征提供“在哪里”的空间定位。将两者在同一层级进行加权融合，能够使网络根据具体任务需求动态调整语义与细节的贡献比例。

从噪声分布的差异性角度，颈部网络中深层特征图由于感受野较大，容易引入背景区域的干扰信息，尤其在大面积复杂背景的无人机航拍图像中更为突出；骨干双路径特征由于小波变换的局部性，噪声主要集中在高频子带，低频近似分量相对稳定。在融合过程中，可学习权重能够自动降低高噪声分支的贡献，提升低噪声分支的权重，从而实现自适应的噪声抑制。

从层级对应的必要性角度，同一层级的特征图具有相同的空间分辨率，融合时无需额外的上采样或下采样操作；不同层级的特征图空间分辨率不同，若进行跨层级融合，需引入额外的重采样操作，不仅增加了计算开销，还可能因插值引入伪影，对小目标检测尤为不利。因此，选择对应层级进行加权融合，既保证了空间分辨率的天然一致性，又避免了不必要的重采样误差。

2.5 衰减函数

在 YOLOv26 端到端检测框架中，损失函数 (E2ELoss) 采用双分支设计，同时维护一对多匹配分支 (one-to-many) 与一对一匹配分支 (one-to-one)，通过动态调整二者加权系数平衡训练收敛性与最终精度。原始实现中，一对多分支权重 w_{o2m} 随训练进程从 0.8 线性衰减至 0.1，一对一分支权重 w_{o2o} 同步由 0.2 升至 0.9。然而，线性衰减未充分考虑网络在不同训练阶段对密集与稀疏监督需求的非线性变化，可能导致前期收敛效率不足或后期一对一分支主导过快引发过拟合风险。

为此，对 E2ELoss 的权重衰减机制进行优化，引入线性、指数、余弦、多项式及指数-余弦混合五种调度策略（变化曲线如图 8 所示）。各衰减因子 $f(t)$ 定义如下，其中 $t = \min(x/T, 1.0)$ 为归一化训练进程：

线性衰减： $f(t) = 1 - t$

指数衰减： $f(t) = \exp(-\lambda t)$ ， λ 为衰减率超参数

余弦衰减： $f(t) = 0.5(1 + \cos(\pi t^\gamma))$ ， γ 为时间扭曲

因子。

多项式衰减： $f(t) = (1 - t)^p$ ， p 为幂次超参数

指数衰减和余弦衰减组成的混合衰减：

$$f(t) = \alpha \exp(-\lambda t) + (1 - \alpha) \cdot 0.5(1 + \cos(\pi t))$$

$$w_{o2m} \text{ 实时值为 } w_{o2m} = w_{\text{final}} + (w_{\text{init}} - w_{\text{final}}) \cdot f(t)$$




图8 衰减函数变化曲线对比图

Fig.8 Comparison of decay function curves

2.5.1 余弦衰减策略

从训练阶段需求与曲线形状特性的匹配关系出发，对余弦衰减的优越性进行分析。训练初期网络需要充分的密集监督信号以快速学习基础特征，由图 8 可见，余弦衰减曲线在该阶段下降极为平缓，权重保持在初始值 0.8 附近，密集监督的有效作用时间显著长于其他衰减策略；训练中期网络应逐步过渡至稀疏监督，余弦衰减的下降速率逐渐加快，实现平滑切换，而线性衰减保持匀速、指数衰减已进入缓慢区，均不及余弦衰减贴合学习进程的实际需求。

训练后期，余弦衰减曲线快速下降至终值 0.1 附近，使一对一稀疏监督迅速占据主导地位以进行精细调优。时间扭曲因子 $\gamma=0.9$ 的引入进一步增强了曲线灵活性， $\gamma < 1$ 使初期更平缓、后期加速更明显，恰好契合“前期充分学习、后期快速切换”的训练需求。综上，余弦衰减“先缓后急”的非线性特性精准匹配了端到端检测从密集监督到稀疏监督的最优切换节奏，无需修改网络结构或增加额外计算开销，仅通过优化损失权重的动态调度即可实现稳定的精度增益。消融实验表明（详见第 3.4.2 节），余弦衰减策略 ($\gamma=0.9$) 在所有指标上均取得最优性能，极小目标检测精度提升尤为显著。

2.6 轻量化网络

尽管以上五项改进策略均针对无人机航拍图像中背景复杂、目标尺度悬殊、信噪比低等挑战进行了定向优化，且消融实验一致表明各改进点对检测精度具有正向贡献，其中 MLGA、ASPPF 与 Cosine-0.9 策略引入的额外参数量与计算开销可忽略不计，但双路径下采样网络与加权路径聚合网络在带来显著精度增益的同时，使模型大小、参数量和计算量都有所增加，对资源受限的无人机机载嵌入式平台而言部署友好性有所折损。

为在精度与效率间寻求更优平衡，对 MDWF-YOLO 实施系统性轻量化设计，综合运用网络结构剪枝、可分离卷积下采样（SCDown）与幽灵瓶颈模块（GhostBottleneck）三种技术对模型进行针对性压缩重构。其中，结构剪枝剔除冗余层和通道以降低参数冗余度；SCDown 以逐深度可分离卷积替代标准下采样，压缩计算量与参数量；GhostBottleneck 利用廉价线性变换生成冗余特征图，以极低计算代价扩充特征维度。基于上述技术，设计四个递进式轻量化变体，各版本在前一版本基础上进一步压缩，构成从精度优先到效率优先的平滑过渡谱系，为实际无人机视觉任务提供可根据资源约束灵活选用的高性价比检测方案。轻量化后的网络结构如图 9 所示。




图9 轻量化的网络结构图

Fig.9 Lightweight network structure

2.6.1 网络结构剪枝

鉴于无人机航拍图像中目标尺度分布呈现显著的长尾特征,即小尺度目标在数量上占据绝对主导地位,深层网络所提取的高语义和大感受野特征对于此类目

标的检测贡献极为有限。因此，可针对性地对网络深层通道配置进行裁剪，即适当缩减深层特征图的通道维度，以剔除对最终检测性能贡献甚微的冗余参数与计算单元，从而有效降低模型参数量与计算量。与此同时，进一步移除专用于大尺度目标检测的 P5 检测头。相应地，在 Haar 小波下采样路径中，与该检测头对应的 P5 层级下采样操作亦一并删除，以避免无效计算。然而，为保障网络整体结构的完整性与感受野的层级分布，原卷积下采样路径中的 P5 层级予以保留。若强行去除该层，将导致网络拓扑的严重断裂，显著压缩模型的有效感受野范围，进而对检测精度造成较大幅度的负面冲击。

移除 P5 检测头而不影响中等尺度目标检测性能，主要基于以下考量。从感受野与目标尺度的匹配关系看，P5 层特征图的空间分辨率为输入图像的 1/32，其单个特征点对应的输入图像感受野约为数百像素，主要响应大尺度目标（如占据画面 1/3 以上的大型车辆等）。以 VisDrone2019 数据集为例，标注框尺寸大于 96×96 像素的大目标数量占比不足 5%，而中等尺度目标（32×32 至 96×96 像素）在 P4 层特征图（分辨率 1/16）上的感受野匹配度更高。因此，移除 P5 检测头对大尺度目标检测有影响，但对该数据集中数量稀少的大目标而言代价可控；中等尺度目标的检测主要由 P3 和 P4 检测头承担，P5 头的移除对其无直接影响。从 YOLOv26 多检测头的分工与补偿机制看，YOLO 系列模型的多个检测头通过网格划分在不同空间分辨率上并行预测，各层检测头之间存在天然的尺度分工，浅层高分辨率特征图负责小目标，深层低分辨率特征图负责大目标。移除 P5 头后，P4 检测头可通过 anchor-free 机制覆盖原 P5 头负责的部分中等偏大目标。从数据驱动的实验验证看，实验结果显示（详见第 3.5 节），v1 仅移除 P5 检测头及对应 HWD 层后，精度没有下降，印证了 P5 检测头在该数据集上的冗余性。上述剪枝策略在压缩模型规模的同时，力求最大限度地维持小目标检测性能，为后续轻量化设计奠定基础。

2.6.2 可分离卷积下采样

可分离卷积下采样 (SCDown) 模块是一种基于

可分离卷积的高效下采样算子,旨在以较低的计算与参数代价实现空间分辨率的压缩与通道维度的变换。该模块由两个顺序连接的卷积层构成:首先利用一个逐点卷积(1x1卷积)将输入通道数由 c_1 映射至目标通道数 c_2 ,完成通道信息的线性重组与维度调整;随后,通过一个分组数等于输出通道数的深度卷积(即逐通道卷积),以给定的卷积核尺寸 $k \times k$ 与步长 s 执行空间域的下采样操作。其前向传播过程可形式化表示为:

$$\text{SCDown}(X) = \text{DepthwiseConv}_{k,s}(\text{PointwiseConv}_{1,1}(X)) \quad (11)$$

其中 $X \in \mathbb{R}^{c_1 \times H \times W}$ 为输入特征图,PointwiseConv为标准逐点卷积,DepthwiseConv为逐通道卷积。相比于同等配置的标准卷积下采样模块,SCDown在参数量与计算量方面均具备显著优势。当输入输出通道数较大时,SCDown可将参数规模与运算负担削减至标准卷积的数十分之一,且信息损失被控制在极低水平。

SCDown的性能表现并非在所有网络层级均一致,其适用性与特征图的空间分辨率和通道配置密切相关。在骨干浅层,特征图空间分辨率极高,逐深度卷积在此高分辨率下的计算量占总运算量的主导比例。若输入输出通道数较大,SCDown的逐点卷积部分将引入显著的 $c_1 \times c_2 \times H \times W$ 次乘法运算,可能反超标准卷积的总计算量。因此,轻量化版本中都保留了首层标准卷积下采样,仅将SCDown应用于首层之后的层级。在骨干中层(如P3到P4,分辨率80×80或更低),空间分辨率已减半,输入输出通道数通常为256到512量级,此时SCDown的计算优势开始明显突出,参数量从标准卷积的 $256 \times 512 \times 9 \approx 1.18\text{M}$ 以8.5倍的压缩比降至 $256 \times 512 + 512 \times 9 \approx 0.14\text{M}$,并且信息损失可控。在骨干深层及颈部层(如P4到P5),分辨率进一步降低至40×40及以下,通道数进一步增大,SCDown的压缩效益更为显著。此外,由于深层特征已高度抽象,空间冗余度较高,逐通道卷积的局部运算已足以完成下采样任务,对精度的影响极小。实验结果表明(详见第3.5节),将骨干中层及颈部对应层级的标准卷积下采样替换为SCDown后,参数量与计算量显著降低,而mAP50仅小幅度下降。而将首层下采样替换为SCDown时,计算量反增,验证了SCDown在浅层

高分辨率层级的不适用性。上述分析表明,SCDown的适用性与层级位置密切相关,其优势在中低分辨率、大通道数的层级最为显著,本文据此制定了针对性的逐层替换策略。

2.6.3 幽灵瓶颈模块

幽灵瓶颈模块(GhostBottleneck)是一种基于幽灵卷积(GhostConv)的高效瓶颈模块,旨在以极低的参数与计算代价实现特征变换与通道扩展。该模块源于华为诺亚方舟实验室提出的GhostNet^[22]架构思想,其核心假设在于深度神经网络的特征图中存在大量冗余,部分特征图可通过廉价线性变换由少量本特征图生成。GhostBottleneck将这一思想封装为标准残差瓶颈结构,在保持表征能力的前提下显著压缩模型规模。

模块内部由主路径与捷径分支(shortcut)两部分构成。主路径依次包含三个操作:首先,一个核尺寸为1x1的幽灵卷积将输入通道数 c_1 压缩至中间通道数 $c_2/2$,完成通道间的信息交互与降维;其次,根据步长 s 的取值决定是否插入深度卷积:当 $s=2$ 时,执行逐通道卷积以实现空间下采样;当 $s=1$ 时,该位置以恒等映射替代;最后,第二个核尺寸为1x1的幽灵卷积将中间通道数扩展至目标输出通道数 c_2 ,且该卷积未附加非线性激活函数,以保持线性变换的特性。主路径的数学表达为:

$$Y_{\text{main}} = \text{GhostConv}_{1 \times 1}^{c_2}(\mathcal{D}(\text{GhostConv}_{1 \times 1}^{c_2/2}(X))) \quad (12)$$

其中, $X \in \mathbb{R}^{c_1 \times H \times W}$ 为输入特征图;GhostConv表示幽灵卷积操作; $\mathcal{D}$ 在 $s=2$ 时为深度卷积,在 $s=1$ 时退化为恒等映射。

捷径分支的设计与主路径相呼应,以保证残差连接在维度上的严格匹配。当步长 $s=2$ 时,捷径分支由深度卷积与标准1x1卷积串联构成,深度卷积以相同的步长与核尺寸完成空间降采样,随后标准卷积将通道数由 c_1 调整至 c_2 ,二者均不含激活函数;当步长 $s=1$ 时,捷径分支退化为恒等映射。最终,模块输出为主路径与捷径分支输出之和:

$$\text{GhostBottleneck}(X) = Y_{\text{main}} + Y_{\text{shortcut}} \quad (13)$$

与标准瓶颈模块相比,GhostBottleneck在参数效

率方面具有显著优势。GhostBottleneck 通过幽灵卷积将普通卷积的参数量削减近半, 再结合深度卷积进一步压缩空间维度的参数开销。具体而言, 幽灵卷积将标准卷积拆分为少量本征卷积与廉价线性运算的组合, 使得生成相同数量特征图所需参数大幅降低。因此, 在同等输入输出通道配置下, GhostBottleneck 可将参数量与计算量压缩至标准瓶颈模块的 50% 以下。

因此, 将 GhostBottleneck 嵌入 MLGA_C3k2 模块以替代标准瓶颈单元, 构成 MAGhostC3k2 模块, 能够在几乎不损害特征表达质量的前提下, 有效降低模型存储占用与推理延迟。这对于计算资源与能耗预算均极度受限的机载嵌入式平台具有重要的工程价值。

2.6.4 递进式轻量化

为实现检测精度与推理效率的灵活折衷, 本文基于结构剪枝、SCDown 与 GhostBottleneck 三种轻量化技术, 设计了四个递进式变体版本, 构成从精度优先到效率优先的平滑过渡谱系。各版本的核心结构差异与适用场景如下。

MDWF-YOLO 标准版作为精度基准, 参数量 2.86M, 计算量 8.5 GFLOPs, 检测精度最高, 适用于对检测精度要求较高的地面端离线分析或中高性能机载平台。v1 在此基础上仅实施结构剪枝, 移除 P5 检测头及对应 HWD 层, 将骨干 P5 层级后通道数由 1024 降至 512, 颈部与检测头通道同步压缩。该版本参数量锐减 57.7% 至 1.21M, 计算量降至 7.2 GFLOPs (与 YOLOv5n 持平, 而检测精度却远高于 YOLOv5n), 检测精度保持不变。v1 以无损压缩实现了轻量化与精度的较好平衡, 适用于精度敏感但对模型规模有初步限制的无人机机载场景。

v2 在 v1 基础上谨慎引入少量轻量化算子替换, 将骨干 P3 到 P4、P4 到 P5、P5 到 P6 三层标准卷积下采样替换为 SCDown, 将骨干 P5 层 MLGA_C3k2 替换为 MAGhostC3k2, 同时将 HWD 路径 P4 层通道数由 512 降至 256。该版本参数量进一步降至 0.86M, 计算量 6.5 GFLOPs (与 YOLOv11n 和 YOLOv12n 持平, 而检测精度却远高于这两个模型), 检测精度仅下降 0.1 个百分点, 以极小的精度代价换取了显著的效率提升, 是轻量化与精度的最优平衡, 适用于中低端无人

机机载处理器等对功耗与实时性有明确要求的场景。

v3 大幅扩展轻量化替换范围, 除首层下采样保留标准卷积外, 其余骨干及颈部下采样全部替换为 SCDown; 除 P2、P3、P4 检测头处 MLGA_C3k2 保留外, 骨干与颈部其余 MLGA_C3k2 全部替换为 MAGhostC3k2。该版本参数量降至 0.72M, 计算量 5.8 GFLOPs, 已与基线 YOLOv26n 持平, 检测精度有一定下降, 仍显著高于基线 YOLOv26n。v3 在计算资源严格受限的条件下保持了较强的竞争力, 适用于低成本嵌入式设备。

v4 实施极致轻量化, 将骨干 P4 层及以后通道数由 512 进一步压缩至 256, 并降检测头处 MLGA_C3k2 全部替换为 MAGhostC3k2, 颈部与检测头所有 MAGhostC3k2 通道数同步压缩, HWD 路径 P3、P4 层通道数由 256 统一降至 128。该版本参数量仅 0.29M (降低 88.4%), 计算量 4.1 GFLOPs (降低 29.3%), mAP50:95 与基线持平, 以约十分之一的参数量实现了同等精度。v4 适用于内存与算力极度受限的超轻量级无人机平台, 是边缘实时检测场景的理想选择。

四个变体的递进式设计遵循三条核心原则。其一为**精度优先原则**: 以 MDWF-YOLO 标准版精度为基准, 优先采用对精度影响最小的结构剪枝 (v1), 随后谨慎引入轻量化算子 (v2), 再逐步扩大替换范围 (v3-v4), 确保每一阶段的精度损失可控。其二为**关键路径保护原则**: 面向检测头的 MLGA_C3k2 模块对最终精度贡献最大, v1-v3 均予以保留, 仅在 v4 中替换; 首层下采样分辨率极高, SCDown 替换后计算量反增且精度损失明显, 故在所有版本中均保留标准卷积。其三为**渐进式压缩原则**: v1 验证结构剪枝的无损性, v2 验证少量算子替换的可行性, v3 验证大面积替换的精度代价, v4 验证极致压缩的精度底线。各版本从前一版本验证有效的基础上进一步扩展压缩范围, 保证了每一步压缩的可控性与可解释性。

实验结果表明 (详见第 3.5 节), 四个版本在精度与效率间取得了优良的梯次平衡, 为不同资源约束条件下的实际部署提供了灵活可选的模型配置。

3 实验结果与分析

3.1 数据集

为了验证 MDWF-YOLO 模型在无人机航拍图像中有较好的检测效果, 本文选取由天津大学机器学习与数据挖掘实验室的 AISKEYEYE 团队收集和发布的 VisDrone2019 数据集进行实验。该数据集使用了多种无人机平台在中国 14 个不同城市的多种不同天气、角度和光照下拍摄, 耗时接近半年。该数据集中, 训练集有 6471 张图像, 总共包含 343205 个标注, 每张图像约含 53 个标注实例。验证集和测试集分别有 548 张和 1610 张图像。数据集包含 10 种类别: 行人、人、自行车、汽车、厢式货车、卡车、三轮车、遮阳三轮车、公交车和摩托车。

3.2 实验环境与训练策略

本文使用操作系统为 Ubuntu20.04.5, Python3.8, 深度学习框架为 PyTorch2.0.0, CPU 为 Intel(R) Xeon(R) Platinum 8474C, 系统内存为 80GB, 显卡为 Nvidia GeForce RTX 4090D, 显存为 24GB, 并使用 CUDA 11.8 加速。训练参数配置如表 1 所示。

表1 训练参数配置

参数名称	参数值
Epochs	300
Imgsz	640x640
Batch	16
Patience	50
Optimizer	MuSGD
Workers	8
Close_mosaic	10
lr0	0.01
lrf	0.01
Momentum	0.937

3.3 评估指标

为系统评估模型在解决无人机图像小目标漏检与误检问题上的性能, 本文采用了一系列公认的评估指标。在检测精度方面, 选用 mAP50 与 mAP50:95 作为核心评价标准, 因其综合考量了精确率与召回率, 能够全面衡量模型的整体性能。同时, 针对无人机平台计算资源有限的特点, 模型的计算效率同样至关重要。因此, 本文还将模型大小、参数量 (params)、每秒帧数 (frames per second, FPS) 及每秒十亿次浮点运算 (floating point operations per second, GFLOPS) 纳入

评估体系, 以综合评判其部署可行性。

(1) 精确率 (precision, P), 表示所有检测到的目标中, 正确预测的目标所占的比例。精确率越高, 说明模型的误检越少。公式为:

$$P = \frac{TP}{TP + FP} \quad (14)$$

其中, TP 表示真正例 (模型正确预测的目标数), 而 FP 表示假正例 (模型错误预测的目标数)。

(2) 召回率 (recall, R), 表示所有真实目标中, 正确预测的目标所占的比例。召回率越高, 说明模型的漏检越少。公式为:

$$R = \frac{TP}{TP + FN} \quad (15)$$

其中, FN 表示假负例 (真实目标未被检测到的目标数)。

(3) 平均精度 (average precision, AP), 精确率和召回率之间存在权衡关系, 然而 AP 则是通过计算 Precision-Recall 曲线 (PR 曲线) 下的面积, 综合反映模型在单类别上的检测性能。某类别的 AP 值越高, 证明该模型在该类别上的检测性能越好。公式为:

$$AP = \int_0^1 P(R) dR \quad (16)$$

其中, P 代表精确率, R 代表召回率。

(4) 平均精度均值 (mean of average precision, mAP), mAP 是所有类别的 AP 的平均值。mAP50 指的是在 IoU 阈值为 0.5 时计算得到的 mAP 值, 表示只有当预测框和真实框的 IoU 大于等于 0.5 时, 该预测才被认为是正确的, 同理, mAP50:95 指的是在 IoU 阈值范围为 0.5 到 0.95 之间 10 个 mAP 值的平均值。mAP 值越高, 说明模型检测效果越好。公式为:

$$mAP = \frac{1}{n} \sum_{i=0}^n AP_i \quad (17)$$

3.4 消融实验

3.4.1 MLGA 模块消融实验

为确定 MLGA 模块中局部池化核的最优尺寸, 在 VisDrone2019 验证集上对 3×3、5×5 和 7×7 三种池化核配置进行了消融对比, 结果如表 2 所示。实验表明, 5×5 核尺寸在 mAP50 和 mAP50:95 两项指标上均取得最优值, 分别达 33.7% 和 19.3%。因此, 本文选用 5×5 作为 MLGA 局部池化核的默认配置。

表2 局部池化核不同尺寸对比

模块名称	局部池化核尺寸	mAP50/%	mAP50:95/%
------	---------	---------	------------

MLGA	3x3	33.1	18.9
MLGA	5x5	33.7	19.3
MLGA	7x7	33.3	19.1

为验证 MLGA 模块中局部与全局注意力融合方式的有效性,在 VisDrone2019 验证集上对直接相加、可学习加权融合和拼接后卷积融合三种策略进行了消融对比,结果如表 3 所示。直接相加策略以 33.7%的 mAP50 和 19.3%的 mAP50:95 取得最优性能。实验结果表明,简单相加能有效融合局部细节与全局上下文信息,更复杂的融合方式并未带来精度增益,验证了直接相加作为 MLGA 融合策略的高效性与合理性。

表3 局部与全局注意力融合方式对比

Table 3 Comparison diagram of fusion modes for local and global attention

模块名称	局部与全局注意力融合方式	mAP50/%	mAP50:95/%
MLGA	直接相加	33.7	19.3
MLGA	可学习加权融合	33.4	19.2
MLGA	拼接后融合	33.1	19.1

3.4.2 衰减函数消融实验

为验证端到端损失函数中一对多分支权重衰减调度策略对模型检测性能的影响,以 MDWF-YOLO 为基线框架,在 VisDrone2019 验证集上对原始线性衰减、指数衰减、多项式衰减、混合衰减及不同时间扭曲因子下的余弦衰减策略进行了系统消融对比,实验结果如表 4 所示。

表4 不同衰减函数策略对比

Table 4 Comparison diagram of different decay function strategies

基线	衰减函数	mAP50/%	mAP50:95/%
MDWF-YOLO	原始线性衰减	37.2	22.4
MDWF-YOLO	指数衰减	37.0	22.3
MDWF-YOLO	多项式衰减	37.1	22.5
MDWF-YOLO	混合衰减	37.2	22.3
MDWF-YOLO	余弦衰减 $\gamma=1.0$	37.3	22.3
MDWF-YOLO	余弦衰减$\gamma=0.9$	37.6	22.7
MDWF-YOLO	余弦衰减 $\gamma=0.8$	37.3	22.6
MDWF-YOLO	余弦衰减 $\gamma=0.7$	37.4	22.5

从衰减函数类型的横向对比来看,原始线性衰减的 mAP50 与 mAP50:95 分别为 37.2%和 22.4%;指数衰减精度略有下降 (mAP50 37.0%),多项式衰减在 mAP50:95 上微升至 22.5%;混合衰减与线性衰减精度持平。余弦衰减 ($\gamma=1.0$) 在 mAP50 上提升至 37.3%,初步展现了余弦调度相对线性及其他策略的优势。这一优势源于余弦衰减“先缓后急”的非线性特性精准匹配了端到端检测从密集监督到稀疏监督的最优切换节奏,而线性衰减全程匀速变化难以匹配网络在不同训练阶段对监督信号的非线性需求。

从时间扭曲因子 γ 的纵向对比来看, $\gamma=0.9$ 时模型取得最优性能, mAP50 与 mAP50:95 分别达 37.6%和 22.7%,较原始线性衰减分别提升 0.4 和 0.3 个百分点; $\gamma=0.8$ 与 $\gamma=1.0$ 精度相近, mAP50 均为 37.3%; $\gamma=0.7$ 时 mAP50 回升至 37.4%,但 mAP50:95 回落至 22.5%。分析认为, $\gamma<1$ 使余弦曲线在训练初期更为平缓、后期加速更为明显, $\gamma=0.9$ 恰好实现了“前期充分保留密集监督信号、后期快速切换至稀疏监督”的最优节奏; $\gamma=0.8$ 及 $\gamma=1.0$ 因曲率调整幅度不足或过度,未能达到同等平衡; $\gamma=0.7$ 初期过于平缓,后期切换过于仓促,导致泛化能力 (mAP50:95) 略有下降。该消融实验充分表明,余弦衰减策略有效提升了端到端检测的训练质量,且在 $\gamma=0.9$ 时性能达到最优。

3.4.3 综合消融实验

为系统验证各改进点的有效性及其协同作用,以 YOLOv26n 为基线,在 VisDrone2019 数据集上进行综合消融实验,涉及混合局部与全局注意力增强的 C3k2 模块 (MLGA_C3k2)、自适应快速空间金字塔池化模块 (ASPPF)、双路径下采样骨干网络 (DPDBN)、加权路径聚合网络 (WPA-Net) 以及端到端损失函数中的余弦衰减调度策略 (Cosine-0.9) 五项策略,结果如表 5 所示。

单模块增益方面, WPA-Net 提升最为显著: mAP50 从 33.3%升至 36.7%, mAP50:95 从 19.2%升至 22.0%, 分别提升 3.4 和 2.8 个百分点,表明加权路径聚合网络通过自适应学习不同层级融合权重,有效强

化了多尺度特征表达能力。MLGA_C3k2 以仅 1.2% 的参数量与计算量增幅使 mAP50 提升 0.4 个百分点,验证了其以极小代价换取背景干扰抑制能力。ASPPF 在不增加参数与计算量的前提下,使 mAP50:95 从 19.2% 提至 19.4%。DPDBN 引入双路径下采样后, mAP50 与 mAP50:95 分别提至 34.3% 与 19.7%, 参数量仅增 0.44M。Cosine-0.9 未引入任何额外开销, 使 mAP50 与 mAP50:95 分别提升 0.6 和 0.3 个百分点。

模块组合方面, 精度随改进点叠加持续上升。集成 MLGA_C3k2 与 ASPPF 时, mAP50 和 mAP50:95 分别达 33.8% 和 19.6%; 进一步引入 DPDBN 后分别提至 34.7% 和 20.1%。四个结构性模块全部启用时, mAP50 与 mAP50:95 分别达 37.2% 与 22.4%, 召回率从 32.8% 升至 37.0%, 参数量仅由 2.51M 增至 2.86M。最终引入 Cosine-0.9 后达最优水平, mAP50 为 37.6%, mAP50:95 为 22.7%, 精确率 48.5%, 各项指标显著领先基线及其他配置。

消融实验表明, 各改进策略在保持轻量化的前提下均有效提升小目标检测精度, 模块间具有良好的协同互补性。

3.5 递进式轻量化试验

为系统评估递进式轻量化策略对模型复杂度与性能的影响, 以 MDWF-YOLO 为基准, 依次引入结构剪枝、SCDown 与 MAGhostC3k2, 构建 v1-v4 四个变体, 在 VisDrone2019 上的实验结果如表 6 所示。

v1 仅实施结构剪枝, 移除 P5 检测头及对应 Haar 小波下采样层, 压缩深层通道数, 参数量锐减 57.7% 至 1.21M, 计算量降至 7.2 GFLOPs, 模型缩至 2.87MB。精度未降反升, mAP50 维持 37.6%, mAP50:95 微升至 22.8%, 有力印证了深层网络在无人机小目标检测中的冗余性, 针对性剪枝可在不损精度前提下实现可观压缩。

v2 谨慎引入少量 SCDown 与 MAGhostC3k2, 将骨干 P3 到 P5 下采样替换为 SCDown、骨干 P5 层 MLGA_C3k2 替换为 MAGhostC3k2。参数量降至 0.86M, 计算量 6.5 GFLOPs, 模型大小 2.21MB; mAP50 小幅回落至 37.5%, mAP50:95 为 22.6%, 精度损失远小于压缩比例, 在关键位置适度轻量化即可取得最优

平衡。

v3 大幅扩展替换范围, 除首层下采样外全部换为 SCDown, 除检测头外全部换为 MAGhostC3k2。参数量降至 0.72M, 计算量 5.8 GFLOPs (与基线持平), 模型大小 2.00MB; mAP50 降至 36.7%, mAP50:95 为 21.8%, 仍显著高于基线, 表明检测头中保留的高质量注意力模块对精度起决定性支撑作用。

v4 实施最激进策略, 将检测头 MLGA_C3k2 全部替换, 削减 P4 层及 Haar 小波下采样路径通道数。参数量压缩至 0.29M (降低 88.4%), 计算量 4.1 GFLOPs (降低 29.3%), 模型大小仅 1.20MB (降低 76.6%); mAP50 回落至 32.7%, mAP50:95 与基线持平 (19.2%), 以约十分之一参数量实现同等精度, 在极端资源受限场景下性价比优势突出。

综合四个版本, 结构剪枝在降复杂度同时未造成精度损失, 是轻量化首选; SCDown 与 MAGhostC3k2 大量替换会逐步侵蚀表征能力, 但效率增益显著, 通过控制替换范围可实现精度与速度的灵活折衷。递进式轻量化方案为无人机航拍小目标检测模型在多样化硬件平台上的部署提供了丰富可靠的选项。

3.6 对比试验

为全面评估 MDWF-YOLO 的综合性能, 在 VisDrone2019 数据集上将其及轻量化变体与 YOLOv5n-v12n、YOLOv26n、RT-DETR-R18 及近期文献算法 (文献 [18]、SCE-YOLO [23]、DMF-YOLOv11 [24]、文献 [25]、文献 [26]) 进行系统对比, 结果如表 7 所示。

因 YOLOv26 于 2026 年初开源, 目前尚无已发表的基于 YOLOv26 改进的航拍小目标检测算法, 本文将文献 [18、23-26] 等针对 YOLOv8/v11/v12 的改进算法迁移至 YOLOv26 框架下公平复现, 其改进路径 (注意力增强、特征金字塔优化、轻量化算子替换) 与 MDWF-YOLO 设计维度直接可比且与 YOLOv26 原生 STAL/ProgLoss 互补, 能有效验证本文方法的增量贡献。

基线 YOLOv26n 以 2.51M 参数量、5.8 GFLOPs 取得 33.3% mAP50 和 19.2% mAP50:95, FPS 达 174。YOLOv5n 到 v12n 等主流模型 FPS 普遍超 150, 但 mAP50 多徘徊于 32% 到 34%, 小目标精度存在瓶颈。

RT-DETR-R18 虽 mAP50 达 39.7%,但参数量 19.8M、计算量 57 GFLOPs, FPS 仅 71, 难以实时。MDWF-YOLO 标准版以 2.86M 参数量、8.5 GFLOPs 取得 37.6% mAP50 和 22.7% mAP50:95, 较基线分别提升 4.3 和 3.5 个百分点, FPS 保持 159, 以极低额外开销换取显著精度增益。

表 5 综合消融实验

Table 5 Comprehensive ablation experiments

基线	MLGA _C3k2	ASPPF	DPDB N	WPA _Net	Cosine -0.9	Params/M	GFLOPs	Size/MB	P/%	R/%	mAP50 /%	mAP50 :95/%
26n						2.51	5.8	5.15	44.3	32.8	33.3	19.2
26n	√					2.54	5.9	5.28	45.3	33.5	33.7	19.3
26n		√				2.51	5.8	5.15	44.0	33.2	33.6	19.4
26n			√			2.95	6.6	6.02	45.5	33.7	34.3	19.7
26n				√		2.54	7.7	5.39	46.4	35.6	36.7	22.0
26n					√	2.51	5.8	5.16	46.0	33.5	33.9	19.5
26n	√	√				2.54	5.9	5.27	45.8	33.4	33.8	19.6
26n	√	√	√			2.99	6.6	6.15	46.9	33.4	34.7	20.1
26n	√	√	√	√		2.86	8.5	6.08	46.6	37.0	37.2	22.4
26n	√	√	√	√	√	2.86	8.5	6.08	48.5	36.3	37.6	22.7

表 6 轻量化实验

Table 6 Lightweighting experiments

模型	网络结 构剪枝	SCDown	MAGhost C3k2	Params/M	GFLOPs	Size/MB	P/%	R/%	mAP50/ %	mAP50:95 /%
YOLO v26				2.51	5.8	5.15	44.3	32.8	33.3	19.2
MDWF- YOLO				2.86	8.5	6.08	48.5	36.3	37.6	22.7
MDWF- YOLOv1	√			1.21	7.2	2.87	47.3	36.7	37.6	22.8
MDWF- YOLOv2	√	少量	少量	0.86	6.5	2.21	46.4	37.2	37.5	22.6
MDWF- YOLOv3	√	较多	较多	0.72	5.8	2.00	47.0	35.3	36.7	21.8
MDWF- YOLOv4	√	全部	全部	0.29	4.1	1.20	42.7	33.1	32.7	19.2

表 7 对比实验

Table 7 Comparison experiments

模型	Params/M	GFLOPs	Size/MB	P/%	R/%	mAP50/%	mAP50:95/%	FPS
YOLOv5n	2.51	7.2	5.0	43.6	33.2	33.0	18.8	165
YOLOv8n	3.01	8.2	6.0	45.6	34.4	34.6	19.8	170
YOLOv9t	2.01	7.9	4.4	45.7	33.9	34.3	20.0	143
YOLOv10n	2.71	8.4	5.5	45.1	33.4	33.8	19.6	158
YOLOv11n	2.59	6.5	5.2	43.1	34.2	33.6	19.4	164
YOLOv12n	2.57	6.5	5.3	42.9	33.9	33.1	19.2	160
YOLOv26n	2.51	5.8	5.2	44.3	32.8	33.3	19.2	174
RT-DETR-R18	19.8	57	63.2	51.8	40.5	39.7	22.8	71
文献[18]	3.87	14.7	7.6	49.9	38.5	38.9	23.5	116
SCE-YOLO[23]	1.11	13.9	3.00	47.4	37.6	38.0	22.4	131
DMF-YOLOv11[24]	5.60	34.7	12.6	53.8	43.1	45.4	27.0	98
文献[25]	3.01	10.5	6.9	47.0	37.2	37.8	22.3	132
文献[26]	3.79	14.6	7.5	47.3	37.5	38.1	22.1	119
MDWF-YOLO	2.86	8.5	6.08	48.5	36.3	37.6	22.7	159

MDWF-YOLOv2	0.86	6.5	2.21	46.4	37.2	37.5	22.6	164
MDWF-YOLOv4	0.29	4.1	1.20	42.7	33.1	32.7	19.2	179

表 8 泛化实验

Table 8 Generalization experiments							
数据集	模型	Params/M	GFLOPs	P/%	R/%	mAP50/%	mAP50:95/%
UAVDT	YOLOv5n	2.51	7.2	33.1	20.9	25.8	15.2
	YOLOv8n	3.01	8.2	35.3	23.5	27.6	16.0
	YOLOv9t	2.01	7.9	34.9	23.1	27.2	15.7
	YOLOv10n	2.71	8.4	33.6	22.4	26.3	15.6
	YOLOv11n	2.59	6.5	34.9	22.8	26.6	15.8
	YOLOv12n	2.57	6.5	33.9	21.9	26.1	15.2
	YOLOv26n	2.51	5.8	34.8	22.5	26.2	15.7
	MDWF-YOLO	2.86	8.5	34.7	36.1	31.3	19.5
	MDWF-YOLOv4	0.29	4.1	32.9	35.5	28.6	17.2
TinyPerson	YOLOv5n	2.51	7.2	34.3	23.9	20.1	6.39
	YOLOv8n	3.01	8.2	36.4	24.6	21.3	6.55
	YOLOv9t	2.01	7.9	34.3	23.8	19.8	6.16
	YOLOv10n	2.71	8.4	36.1	22.3	19.1	5.87
	YOLOv11n	2.59	6.5	35.6	24.9	21.0	6.81
	YOLOv12n	2.57	6.5	33.5	23.6	19.6	6.14
	YOLOv26n	2.51	5.8	36.1	25.2	21.2	6.68
	MDWF-YOLO	2.86	8.5	36.0	29.4	23.4	7.72
	MDWF-YOLOv4	0.29	4.1	33.3	27.3	21.5	7.06

与先进算法相比, 文献[25] (3.01M, 10.5 GFLOPs, mAP50 37.8%)、文献[26] (3.79M, 14.6 GFLOPs, mAP50 38.1%)、SCE-YOLO (1.11M, 13.9 GFLOPs, mAP50 38.0%)的 mAP50 与 MDWF-YOLO 基本持平, 但其计算量分别为本模型的 1.24 到 1.72 倍, FPS (119 到 132)明显落后。DMF-YOLOv11 虽精度最高(mAP50 45.4%, mAP50:95 27.0%), 但计算量 34.7 GFLOPs 为本模型的 4.08 倍, FPS 仅 98。MDWF-YOLO 在精度与效率间实现更优权衡。

轻量化变体方面, v2 以 0.86M 参数量、6.5 GFLOPs、2.21MB 取得 37.5% mAP50 和 22.6% mAP50:95, FPS164, 以相当于基线 34.3%的参数量达到与文献[25]、SCE-YOLO 相当甚至更优的 mAP50:95。v4 参数量仅 0.29M (降低了 88.4%), 计算量 4.1 GFLOPs (降低了 29.3%), 模型大小 1.20MB (降低了

76.6%), mAP50:95 与基线持平(19.2%), FPS 达 179, 为表中速度最快, 在极端资源受限场景下价值突出。

综上, MDWF-YOLO 系列在精度与效率间实现多档均衡, 标准版以极低开销换显著精度增益, 处于 Pareto 前沿领先地位; v2 以极低参数量实现与先进算法相当精度; v4 在保持基线精度的同时大幅压缩模型规模。该系列为无人机实时视觉感知提供了高精度与高效率兼备的可靠解决方案。

3.7 泛化实验

为进一步验证 MDWF-YOLO 和极致轻量化版本 MDWF-YOLOv4 模型的泛化能力, 在 UAVDT 和 TinyPerson 两个公开数据集上进行了泛化实验, 与 YOLOv5n 到 v12n 及 YOLOv26n 进行对比, 结果如表 8 所示。

UAVDT 数据集是面向无人机航拍场景的车辆检测与跟踪基准数据集, 包含约 8 万帧图像, 涵盖不同

飞行高度、视角及光照条件下的车辆目标,目标尺度普遍较小且存在密集遮挡。TinyPerson 数据集则专注于极小尺度行人检测,图像采集自远距离监控与航拍场景,目标尺寸大多小于 20×20 像素,是评估极小目标检测性能的典型基准。

在 UAVDT 数据集上,MDWF-YOLO 标准版以 2.86M 参数量和 8.5 GFLOPs 计算量取得 31.3% 的 mAP50 和 19.5% 的 mAP50:95,较基线 YOLOv26n 分别提升 5.1 和 3.8 个百分点。值得注意的是,MDWF-YOLO 的召回率高达 36.1%,较 YOLOv26n 的 22.5% 提升 13.6 个百分点,表明双路径下采样与加权融合机制有效改善了密集遮挡场景下的小目标覆盖能力。MDWF-YOLOv4 以仅 0.29M 的参数量和 4.1 GFLOPs 的计算量取得 28.6% 的 mAP50 和 17.2% 的 mAP50:95,各项指标均超越所有同类轻量级基线模型。

在 TinyPerson 数据集上,目标尺寸的极度微小进一步考验了模型的极限检测能力。MDWF-YOLO 取得 23.4% 的 mAP50 和 7.72% 的 mAP50:95,较基线 YOLOv26n 分别提升 2.2 和 1.04 个百分点,召回率由 25.2% 提升至 29.4%。在该数据集上各模型 mAP50:95 绝对值普遍较低,反映出极小目标检测任务自身的艰巨性,但 MDWF-YOLO 的相对提升幅度仍保持稳定。MDWF-YOLOv4 以 0.29M 参数量取得 21.5% 的 mAP50 和 7.06% 的 mAP50:95,同样优于参数量为其数倍的多数基线模型。

上述泛化实验结果一致表明,MDWF-YOLO 所提各改进模块对不同场景、不同目标尺度分布具有稳定的适应能力,模型性能增益不局限于单一数据集,展现出良好的鲁棒性与泛化性。轻量化版本 MDWF-YOLOv4 在保持极低计算开销的同时,跨域性能仍超越多数主流轻量级基线模型,进一步印证了递进式轻量化策略的实用性。

3.8 可视化分析

为全面验证本文提出的 MDWF-YOLO 系列模型在无人机航拍小目标检测任务中的有效性,本节从特征提取能力可视化、检测结果可视化、训练收敛性能、轻量化部署性能三个核心维度,与基线模型 YOLO26n 进行系统性可视化对比分析。

特征热力图能够直观反映模型对图像不同区域的特征关注度,其中暖色调代表高特征响应区域,冷色调代表低特征响应区域。结果如图 10 所示。

从图 10 可以清晰观察到,基线 YOLOv26n 的特征响应整体分散,对道路边缘、建筑物等背景区域产生大量无效激活,而对密集小目标区域的特征激活严重不足,尤其在遮挡、远距离及复杂背景场景下响应值急剧下降。相比之下,MDWF-YOLO 能有效抑制背景干扰,将注意力高度集中于目标区域,热力图暖色调区域与目标分布高度重合,对密集小目标集群、部分遮挡及远距离目标均能产生强烈且连续的特征响应。这表明本文设计的多尺度双路加权融合网络能有效提取小目标高频细节特征,从特征提取层面解决了“背景干扰强、小目标特征弱”的核心难题。

为直观验证模型在实际场景中的检测性能,选取包含小目标密集分布、目标遮挡、夜间低光照、复杂背景干扰等典型挑战场景的无人机航拍图像进行检测结果可视化对比,结果如图 11 所示,图中框出的结果为 YOLO26n 漏检和误检,而 MDWF-YOLO 能正确检测的情况。




图10 检测热力图对比

Fig.10 Comparison of detection heatmaps




图11 检测结果可视化对比图

Fig.11 Visual comparison of test results

从图 11 对比可见, 基线模型 YOLO26n 存在显著检测缺陷, 对篮球场、夜间道路等场景中的远距离微小目标漏检严重, 在夜间停车场等密集场景下误检频发, 且夜间低光照条件下检测置信度普遍偏低, 鲁棒性不足; 而本文提出的 MDWF-YOLO 则展现出全面的性能提升, 不仅对远距离密集小目标实现了近乎完整的检测、漏检率大幅降低, 还有效抑制了背景误检, 在目标遮挡与复杂背景下仍能精准定位, 同时在夜间低光照场景中保持高置信度的稳定检测, 检测精度与召回率均显著优于基线模型。上述结果直观验证了 MDWF-YOLO 在无人机航拍小目标检测任务中的实际应用价值, 表明多尺度双路加权融合网络能够有效增强模型对小目标特征的提取与表征能力, 显著提升复杂场景下的检测鲁棒性。

为评估模型的训练效率与最终检测精度, 记录所有模型在 300 个 epoch 内验证集的 mAP50 与 mAP50-95 指标变化, 收敛曲线分别如图 12 与图 13 所示。




图12 mAP50对比图

Fig.12 Comparison of mAP50

从图 12 的 mAP50 收敛曲线可以看出, 所有模型在训练初期 (0-50epoch) 均呈现快速收敛趋势, mAP50 指标迅速上升。其中, MDWF-YOLO 及其轻量化变体的收敛速度始终显著快于基线模型 YOLO26n, 在训练至 50epoch 时, MDWF-YOLO 的 mAP50 已达到 34%, 而 YOLO26n 仅为 31%。在训练后期 (150-300epoch), 所有模型的收敛曲线逐渐趋于平稳, MDWF-YOLO 最终达到的 mAP50 峰值为 37.6%, 较 YOLO26n 的 33.3% 提升了 4.3 个百分点。

进一步观察图 13 的 mAP50-95 收敛曲线, 该指标对小目标的定位误差更为敏感。可以看出, MDWF-YOLO 的 mAP50-95 指标在整个训练过程中均保持对 YOLO26n 的显著优势, 最终峰值达到 22.7%, 较 YOLO26n 的 19.2% 提升了 3.5 个百分点。这表明, 多尺度双路加权融合网络不仅能够加快模型的收敛速度, 还能有效提升模型对小目标的精准定位能力。同时, MDWF-YOLOv1 到 v4 系列轻量化模型在精度略有下降的情况下, 仍保持了优于或持平于 YOLO26n 的检测性能, 验证了本文递进式轻量化设计策略的有效性。




图13 mAP50:95对比图

Fig.13 Comparison of mAP50:95

为评估模型在边缘计算设备上的部署可行性,对比了各模型的参数量(Params)、浮点运算量(GFLOPs)与模型文件大小(Size),结果如图14所示。




图14 递进式轻量化指标对比图

Fig.14 Comparison of progressive weight reduction targets

基线模型 YOLO26n 的参数量为 2.51M, GFLOPs 为 5.8, 模型大小为 5.15MB。本文提出的基础改进模型 MDWF-YOLO 的参数量为 2.86M, GFLOPs 为 8.5, 模型大小为 6.08MB, 虽然参数量和计算量略有增加, 但带来了显著的精度提升, 实现了精度与复杂度的较好平衡, 适用于对检测精度要求较高的场景。

为满足边缘设备的资源限制, 本文通过递进式轻量化得到了 MDWF-YOLOv1 到 v4 系列模型。其中, 极致轻量化版本 MDWF-YOLOv4 的性能最为突出, 其参数量仅为 0.29M, 较 YOLO26n 降低了 88.4%; GFLOPs 为 4.1, 较 YOLO26n 降低了 29.3%; 模型大小仅为 1.20MB, 较 YOLO26n 降低了 76.7%。同时, MDWF-YOLOv4 的 mAP50 指标仍达到 32.7%, mAP50-95 指标达到 19.2%, 与 YOLO26n 基本持平。这一结果表明, 本文的轻量化改进策略能够在大幅压缩模型参数量和计算量的同时, 最大限度地保留模型的检测精度, 使得改进后的模型能够完美适配无人机、嵌入式设备等资源受限平台的实时检测需求。

综上所述, 通过特征热力图、收敛曲线与轻量化性能的多维度可视化对比分析, 充分验证了本文提出的 MDWF-YOLO 系列模型在无人机航拍小目标检测任务中的综合优越性。多尺度双路加权融合网络有效解决了小目标特征提取困难的问题, 而递进式轻量化设计则为模型的边缘部署提供了坚实基础。

4 结束语

针对无人机航拍图像中小目标检测面临的尺度微小、遮挡密集、背景复杂及光照不均等固有挑战, 提出了一种多尺度双路加权融合航拍小目标检测模型 MDWF-YOLO。在 YOLOv26n 基础框架之上, 构建的双路径下采样骨干网络有效缓解了深层网络中小目标特征的流失问题; 设计的轻量级混合局部与全局注意力模块 (MLGA) 增强了网络对关键区域的特征响应; 提出的自适应快速空间金字塔池化模块 (ASPPF) 更好地保留了小目标细节表征; 构建的加权路径聚合网络 (WPA-Net) 实现了多层次特征的自主加权融合; 并引入余弦衰减调度策略优化了端到端损失函数中对多分支权重的衰减进程。在此基础上, 通过网络结

构剪枝、可分离卷积下采样与幽灵瓶颈模块的递进式轻量化设计, 构建了四个轻量化变体版本, 在检测精度与推理效率之间提供了多档位可选方案。

在 VisDrone2019 数据集上的系统实验表明, MDWF-YOLO 标准版在参数量仅小幅增加至 2.86M、计算量为 8.5 GFLOPs 的条件下, mAP50 与 mAP50:95 分别达 37.6%与 22.7%, 较基线 YOLOv26n 分别提升 4.3 与 3.5 个百分点, 推理速度保持 159 FPS。轻量化变体 MDWF-YOLOv2 以 0.86M 参数量和 6.5 GFLOPs 计算量取得 37.5%的 mAP50 与 22.6%的 mAP50:95, 在几乎无损精度的前提下将模型规模压缩至基线的 34.3%; 极致轻量化版本 MDWF-YOLOv4 参数量仅 0.29M (降低 88.4%), 计算量降至 4.1 GFLOPs (降低 29.3%), mAP50:95 仍与基线持平, 推理速度提升至 179 FPS, 成为对比模型中速度最快者。与基于 YOLOv8、YOLOv11 及 YOLOv12 改进的复现算法对比结果表明, MDWF-YOLO 在精度-效率 Pareto 前沿上处于领先地位, 各改进模块在 YOLOv26 基线之上的增量贡献得到有效验证。跨数据集泛化实验进一步

证实, MDWF-YOLO 在 UAVDT 和 TinyPerson 两个差异显著的公开数据集上均取得稳定的性能提升, 在 UAVDT 上 mAP50 达 31.3%, 较基线提升 5.1 个百分点, 召回率大幅提升 13.6 个百分点; 在 TinyPerson 极小目标数据集上 mAP50 达 23.4%, 较基线提升 2.2 个百分点。轻量化版本 MDWF-YOLOv4 的检测精度在泛化实验中以极低计算开销持续超越多数主流轻量级基线, 展现出良好的鲁棒性与泛化能力。

尽管 MDWF-YOLO 在上述实验中取得了优良性能, 但模型在极端密集遮挡场景下的小目标召回率仍有提升空间。当前轻量化设计主要基于经验性结构剪枝与算子替换, 未来可进一步探索基于神经架构搜索的自适应轻量化策略, 以实现更优的精度-效率自动权衡; 同时, 可引入时序信息的多帧融合检测机制, 利用无人机视频流的帧间关联进一步提升检测稳定性与极小目标捕获能力。为无人机航拍小目标检测提供了一套兼具高精度与高效率的完整解决方案, 对推动无人机视觉感知任务的实用化进程具有积极意义。

参考文献:

- [1] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25.
- [2] LIU L, OUYANG W, WANG X, et al. Deep learning for generic object detection: A survey[J]. International journal of computer vision, 2020, 128(2): 261-318.
- [3] GIRSHICK R, DONAHUE J, DARRELL T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]//Proceedings of the 2014 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2014: 580-587.
- [4] GIRSHICK R. Fast R-CNN[C]//Proceedings of the 2015 IEEE International Conference on Computer Vision. Piscataway: IEEE, 2015: 1440-1448.
- [5] REN S, He K, GIRSHICK R, et al. Faster r-cnn: towards real-time object detection with region proposal networks[J]. Advances in neural information processing systems, 2015, 28.
- [6] HE K, GKIOXARI G, DOLLAR P, et al. Maskr-cnn[C] //Proceedings of the IEEE international conference on computer vision. 2017: 2961-2969.
- [7] REDMON J, DIVVALA S, GIRSHICK R, et al. You only look once: unified, real-time object detection[C]//Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2016: 779-788.
- [8] LIU W, ANGUELOV D, ERHAN D, et al. SSD: single shot multibox detector[C]//Proceedings of the IEEE Conference on Computer Vision. Cham: Springer, 2016: 21-37.
- [9] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection[C]//Proceedings of the 2017 IEEE International Conference on Computer Vision. Piscataway: IEEE, 2017: 2999-3007.
- [10] TAN M, PANG R, Le Q V. Efficientdet: scalable and efficient object detection[C]//Proceedings of the IEEE/CVF conference on

- computer vision and pattern recognition. 2020: 10781-10790.
- [11] CARION N, MASSA F, SYNNAEVE G, et al. End-to-end object detection with transformers[C]//European conference on computer vision. Cham: Springer International Publishing, 2020: 213-229.
- [12] LI Y, FAN Q, HUANG H, et al. A modified YOLOv8 detection network for UAV aerial image recognition[J]. Drones, 2023, 7(5): 304.
- [13] WANG C, HAN Y, YANG C, et al. CF-YOLO for small target detection in drone imagery based on YOLOv11 algorithm[J]. Scientific Reports, 2025, 15(1): 16741.
- [14] ZHAI X, HUANG Z, LI T, et al. YOLO-Drone: an optimized YOLOv8 network for tiny UAV object detection[J]. Electronics, 2023, 12(17): 3664.
- [15] ZHANG Z. Drone-YOLO: An efficient neural network method for target detection in drone images[J]. Drones, 2023, 7(8): 526.
- [16] BATTISH N, KAUR D, CHUGH M, et al. SDNet: Spatially dilated multi-scale network for object detection for drone aerial imagery[J]. Image and Vision Computing, 2024, 150: 105232.
- [17] HU J, PANG T, PENG B, et al. A small object detection model for drone images based on multi-attention fusion network[J]. Image and Vision Computing, 2025, 155: 105436.
- [18] 李彬, 李生林. 改进 YOLOv11n 的无人机小目标检测算法[J]. 计算机工程与应用, 2025, 61(7): 96-104.
- LI B, LI S L. Improved YOLOv11n small object detection algorithm in UAV view[J]. Computer Engineering and Applications, 2025, 61(7): 96-104.
- [19] 李学威, 毛小坤, 孙滨, 等. 基于 YOLOv11n 的无人机航拍小目标检测算法[J/OL]. 光通信研究, 1-8[2025-10-09]. <https://link.cnki.net/urlid/42.1266.TN.20250210.1015.002>.
- LI X W, MAO X K, SUN B, et al. UAV aerial small object detection algorithm based on YOLOv11n[J/OL]. Study on Optical Communications, 1-8[2025-10-09]. <https://link.cnki.net/urlid/42.1266.TN.20250210.1015.002>.
- [20] HUI Y, WANG J, LI B. STF-YOLO: a small target detection algorithm for UAV remote sensing images based on improved Swin Transformer and class weighted classification decoupling head[J]. Measurement, 2024, 224: 113936.
- [21] OLORUNSHOLA O E, IRHEBHUDE M E, EVWIEKPAAFE A E. A comparative study of YOLOv5 and YOLOv7 object detection algorithms[J]. Journal of Computing and Social Informatics, 2023, 2(1): 1-12.
- [22] HAN K, WANG Y, TIAN Q, et al. Ghostnet: more features from cheap operations[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2020: 1580-9.
- [23] 张帅, 王波涛, 涂嘉怡, 等. SCE-YOLO: 改进 YOLOv8 的轻量级无人机视觉检测算法[J]. 计算机工程与应用, 2025, 61(13): 100-112.
- ZHANG S, WANG B T, TU J Y, et al. SCE-YOLO: improved lightweight YOLOv8 algorithm for UAV visual detection[J]. Computer Engineering and Applications, 2025, 61(13): 100-112.
- [24] 贺智轩, 陈里里, 王翔, 等. DMF-YOLOv11: 基于改进 YOLOv11n 的无人机航拍图像目标检测算法[J]. 计算机工程与应用, 2025, 61(14): 88-100.
- HE Z X, CHEN L L, WANG X, et al. DMF-YOLOv11: target detection algorithm for UAV images based on improved YOLOv11n[J]. Computer Engineering and Applications, 2025, 61(14): 88-100.
- [25] 刘玉萍, 尚翠娟, 李明明. 改进 YOLOv11 的无人机小目标检测算法[J]. 计算机工程与应用, 2025, 61(15): 124-131.
- LIU Y P, SHANG C J, LI M M. Improved YOLOv11 algorithm for small target detection in UAVs[J]. Computer Engineering and Applications, 2025, 61(15): 124-131.

- [26] 任洪娥,张佳源,王金聪,等.基于改进 YOLOv12 的无人机图像小目标检测方法[J/OL].辽宁工程技术大学学报(自然科学

版),1-10[2026-05-11].<https://link.cnki.net/urlid/21.1379.N.20260507.1640.002>.

REN H E, ZHANG J Y, WANG J C, et al. Small target detection method of UAV image based on improved YOLOv 12 [J/OL]. Journal of Liaoning Technical University (Natural Science) , 1-10[2026-05-11].<https://link.cnki.net/urlid/21.1379.N.20260507.1640.002>.