



计算机工程与应用  
Computer Engineering and Applications  
ISSN 1002-8331, CN 11-2127/TP

## 《计算机工程与应用》网络首发论文

题目: MPCE-YOLO: 基于多维特征增强的密集行人检测方法研究  
作者: 朱玉华, 王佳波  
网络首发日期: 2026-08-21  
引用格式: 朱玉华, 王佳波. MPCE-YOLO: 基于多维特征增强的密集行人检测方法研究 [J/OL]. 计算机工程与应用.  
<https://link.cnki.net/urlid/11.2127.tp.20260821.1056.004>



**网络首发:** 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式 (包括网络呈现版式) 排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

**出版确认:** 纸质期刊编辑部通过与《中国学术期刊 (光盘版)》电子杂志社有限公司签约, 在《中国学术期刊 (网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊 (网络版)》是国家新闻出版广电总局批准的网络连续型出版物 (ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

# MPCE-YOLO: 基于多维特征增强的密集行人检测方法研究

朱玉华<sup>+</sup>, 王佳波

沈阳工业大学 化工过程自动化学院, 辽阳 111003

<sup>+</sup> 通信作者 E-mail: zhuyuhua@sut.edu.cn

**摘要:** 针对密集场景下行人检测面临的目标尺度差异大、遮挡严重以及精度与效率难以平衡等问题, 提出一种改进的密集行人检测模型 MPCE-YOLO (MobileMamba-P2-CGAFusion-ESGECD-YOLO)。该模型以 YOLO11n 为基准框架, 从特征建模、多尺度表征、特征融合及检测头设计四个方面进行优化。首先, 首次将轻量化状态空间模型 MobileMamba 引入 YOLO11 网络, 设计 C3k2\_MobileMamba 模块替代原有 C3k2 结构, 利用状态空间模型的长程依赖建模能力和局部特征建模优势, 增强复杂遮挡场景下的行人特征表征能力。其次, 引入 P2 检测层构建 P2-P5 四尺度检测结构, 利用高分辨率特征层保留更多空间细节, 提高小尺度行人的定位精度。然后, 在特征融合网络中引入内容引导注意力融合模块 (Content-guided Attention Fusion, CGAFusion), 并构建内容引导式跨层特征重融合策略, 通过通道、空间与像素三重注意力机制实现深浅层特征的自适应加权融合, 增强深浅层特征交互能力, 提高模型对小尺度及遮挡目标的检测性能。最后, 首次提出高效共享细粒度增强卷积检测头 (Efficient Shared Granularity-Enhanced Convolutional Detection Head, ESGECD), 通过组归一化共享卷积与双级细粒度增强卷积协同设计, 在降低参数量与计算开销的同时增强邻域特征聚合能力, 提高遮挡目标的分类与定位性能。在 CrowdHuman 数据集上的实验结果表明, MPCE-YOLO 较基线模型在 mAP@0.5 和 mAP@0.5:0.95 上分别提升 3.4 和 4.2 个百分点, 参数量仅为 2.7M。消融实验与可视化分析进一步验证了各改进模块的有效性, 表明所提出的方法能够有效提升密集遮挡场景下的行人检测性能, 实现了检测精度与模型轻量化的协同优化。

**关键词:** 密集行人检测; YOLO11n; 状态空间模型; 四尺度检测; 轻量化检测头

文献标志码:A 中图分类号:TP391.4 doi: 10.3778/j.issn.1002-8331.2604-0216

## MPCE-YOLO: Research on Dense Pedestrian Detection Method Based on Multi-Dimensional Feature Enhancement

ZHU Yuhua<sup>+</sup>, WANG Jiabo

College of Chemical Process Automation, Shenyang University of Technology, Liaoyang, Liaoning 111003, China

**Abstract:** To address the challenges of large target scale variations, severe mutual occlusions, and the difficulty of balancing accuracy and efficiency in dense pedestrian detection scenarios, MPCE-YOLO (MobileMamba-P2-CGAFusion-ESGECD YOLO) is proposed which is an improved dense pedestrian detection model. This model is based on the YOLO11n framework and is optimized in four aspects: feature modeling, multi-scale representation, feature fusion, and detection head design. Firstly, the lightweight state-space model MobileMamba is introduced into the

**基金项目:** 辽宁省自然科学基金项目(2024-BSLH-210); 辽宁省教育厅基本科研项目(JYTMS20231250)。

**作者简介:** 朱玉华(1971—), 女, 硕士, 教授, 研究方向为过程在线检测与智能控制、机器人导航与定位等; 王佳波(2002—), 女, 硕士研究生, 研究方向为计算机视觉与目标检测。

YOLO11 network for the first time, and the C3k2\_MobileMamba module is designed to replace the original C3k2 block. By leveraging the long-range dependency modeling ability and local feature modeling advantages of the state-space model, the pedestrian feature representation ability in complex occlusion scenarios is enhanced. Secondly, the P2 detection layer is introduced to construct a P2-P5 four-scale detection structure, which retains more spatial details in the high-resolution feature layer and improves the positioning accuracy of small-scale pedestrians. Then, the Content-guided Attention Fusion module (CGAFusion) is incorporated into the feature fusion network, and a content-guided cross-layer feature refusion strategy is constructed. Through the triple attention mechanism of channel, space and pixel, the adaptive weighted fusion of deep and shallow layer features is achieved, enhancing the interaction ability between deep and shallow layer features and improving the detection performance of small-scale and occluded targets. Finally, an Efficient Shared Granularity-Enhanced Convolutional Detection Head (ESGECD) is proposed for the first time. Through group normalization sharing convolution and the collaborative design of dual-level fine-grained enhanced convolution, the neighborhood feature aggregation ability is enhanced while reducing the parameter quantity and computational cost, and the classification and positioning performance of occluded targets is improved. Experimental results on the CrowdHuman dataset show that MPCE-YOLO improves mAP@0.5 and mAP@0.5:0.95 by 3.4 and 4.2 percentage points respectively compared to the baseline model, with only 2.7M parameters. Ablation experiments and visual analysis further verify the effectiveness of each improvement module, indicating that the proposed method can effectively improve the pedestrian detection performance in dense occlusion scenarios and achieve the collaborative optimization of detection accuracy and model lightweighting.

**Key words:** Dense pedestrian detection ; YOLO11n; State space model; Four-scale detection; Lightweight detection head

随着全球城市化进程的迅猛发展,大型公共活动、交通枢纽及商业中心等场景下的密集人群管理已成为公共安全领域面临的严峻挑战。密集行人小目标检测作为计算机视觉与智能安防交叉领域的关键技术。在复杂的实际应用环境中,受背景杂波干扰、人群高度密集、目标相互遮挡等多种不利因素的影响,现有目标检测方法往往难以兼顾检测精度与算法运行效率,这一短板严重制约了其在实际场景中的应用效能<sup>[1]</sup>。

早期研究主要基于手工设计特征(如 HOG<sup>[2]</sup>、SIFT<sup>[3]</sup>)与分类器(如 SVM)的组合。深度学习的兴起彻底革新了这一领域,催生了以 R-CNN<sup>[4]</sup>、Fast R-CNN<sup>[5]</sup>、Faster R-CNN<sup>[6]</sup>为代表的两阶段检测算法。此类算法有效提升了检测精度,但复杂的候选区域生成过程限制了实时性能。相比之下,以 SSD<sup>[7]</sup>、YOLO<sup>[8]</sup>系列为代表的一阶段检测算法摒弃了区域建议步骤,实现了“端到端”的检测框架,在速度上取得了压倒性优势<sup>[9]</sup>。

然而,通用检测模型直接应用于密集行人场景时性能显著衰减,国内外学者围绕 YOLO 系列从三个维度开展改进:特征增强方面,2025 年,王丽黎等人<sup>[10]</sup>引入残差注意力机制提升遮挡场景下的特征响应,但其对长距离依赖建模能力有限;结构优化方面,2024 年汤静雯等人<sup>[11]</sup>提出了 ME-YOLO 轻量化设计,但其轻量化策略更多关注网络压缩,对密集遮挡场景下的细粒度特征挖掘不足;损失设计方面,Hua 等人<sup>[12]</sup>提

出 YOLO-ABD 模型,采用小目标检测层和基于相似度的激活模块(similarity-aware activation module, SimAM)<sup>[13]</sup>注意力机制,并使用分组重排卷积(Group Shuffle Convolution, GSConv)<sup>[14]</sup>模块来提高感知能力,改进后的模型为行人异常检测提供了一个轻量的解决方法,然而该方法对全局上下文利用不充分。

近两年,状态空间模型(State Space Model, SSM)尤其是 Mamba 系列在目标检测中快速发展,为解决密集场景下的全局建模与遮挡问题提供了新思路。2024 年,Zhu 等人提出 Vision Mamba (Vim)模型<sup>[15]</sup>,首次将 SSM 引入视觉编码,在保持线性计算复杂度的同时实现了与 Transformer 相当的全局建模能力。但其在密集行人场景下对目标检测中关键的局部纹理与边缘细节特征关注不足。2024 年,Liu 等人提出 VMamba 模型<sup>[16]</sup>,通过二维选择性扫描(2D Selective Scan, SS2D)机制将 SSM 扩展至二维视觉空间,构建了全局感受野并增强了长距离依赖建模能力,但对局部空间结构和细粒度纹理信息的刻画相对较弱。2025 年,Wang 等人提出 Mamba-YOLO 模型<sup>[17]</sup>,将 SSM 引入 YOLO 检测框架,发挥了线性复杂度下全局建模的优势,但在遮挡场景下对目标轮廓和边缘纹理细节利用仍不充分。因此,如何在保持轻量化特性的同时实现全局上下文信息与局部细节特征的协同建模,仍是当前密集行人检测研究中的重要问题。

与此同时,轻量化特征融合的研究也日益广泛。

2023 年, Yang 等人提出渐进式特征金字塔网络 AFPN (Asymptotic Feature Pyramid Network) [18], 通过渐进式跨层融合策略缓解不同尺度特征之间的语义鸿沟, 增强了多尺度目标的特征表达能力, 但其特征传递路径依赖预定义结构, 难以根据目标尺度变化动态调整融合权重。2023 年, Tang 等人提出的 HA-FPN (Hierarchical Attention Feature Pyramid Network) [19] 利用层次化特征选择策略实现不同尺度特征的重要性分配, 但对空间区域和通道语义信息的联合建模能力仍有不足。现有特征融合方法虽然在跨尺度信息交互和语义表达能力方面取得了进展, 但仍存在全局语义与局部细节协同不足、融合权重动态调节能力有限以及融合性能与计算开销难以兼顾等问题。

尽管如此, 现有研究仍存在一定的局限性。一方面, 许多改进方案为提升精度引入了可观的计算复杂度与参数量, 与 YOLO 系列追求高效、轻量的初衷有所背离。另一方面, 随着 YOLO 版本快速迭代, 大量现有工作仍基于较旧的 v5、v8 版本进行改进, 未能充分利用最新版本在架构设计与训练范式上的先天优势。YOLO11 作为 Ultralytics 公司推出的最新系列, 在其轻量化版本 YOLO11n [20] 上平衡了前沿性能与部署效率, 为密集行人检测研究提供了一个更强大的现代基线。

鉴于上述背景, 本文首次提出一种改进的行人检测模型 MPCE-YOLO, 以 YOLO11n 为基线模型, 针对密集行人检测的核心痛点, 开展针对性的结构改进与算法优化, 本文的主要贡献如下:

(1) 首次将轻量化状态空间模型 MobileMamba [21] 引入 YOLO11 目标检测框架, 设计 C3k2\_MobileMamba 模块替代原有 C3k2 结构, 在保持网络拓扑结构基本不变的情况下, 利用状态空间模型的长程依赖建模能力增强复杂遮挡场景下的行人特征表征能力。

(2) 针对密集场景中中小尺度行人占比较高的问题, 引入 P2 检测层, 构建 P2-P5 四尺度检测结构, 利用高分辨率检测层增强小目标感知能力, 并将内容引导注意力融合机制 (CGAFusion) [22] 引入特征融合网络, 提出一种内容引导式跨层特征重融合策略, 实现 Neck (颈部网络) 多尺度语义特征与 Backbone (骨干网络) 细节特征的自适应交互, 提升密集场景下小尺度及遮挡行人的检测性能。

(3) 首次提出了一种新型的高效共享粒度增强卷积检测头 ESGECD, 构建“细节增强—特征共享—任务解耦”的渐进式检测头架构。通过基于组归一化的共享卷积模块实现跨通道信息交互, 并设计双级细粒度增强卷积模块, 通过两个级联的细粒度增强卷积 (Granularity-Enhanced Convolution Based On Group Normalization, GEConv\_GN) 模块强化邻域特征聚合能力, 通过双分支结构分别进行目标分类与边界框回归预测。在降低参数量与计算复杂度的同时提高了模

型对遮挡目标的分类与定位能力, 有效降低了行人漏检率。

## 1 MPCE-YOLO 算法

在复杂场景下, 行人目标常因尺度差异显著及相互遮挡而导致特征表达模糊, 从而引发漏检和误检现象。针对这一问题, 原始 YOLO11n 模型的检测性能难以满足实际需求。虽然增大模型规模有助于提升精度, 但也会带来参数量和计算负担的大幅增加, 不利于部署应用 [23]。因此, 本文在兼顾检测效果与模型轻量化的前提下, 选取 YOLO11n 作为基础框架进行改进, 在保证网络轻量化结构的同时, 显著增强了对小目标与密集遮挡行人的检测精度与鲁棒性, 优化后的网络结构如图 1 所示。




图 1 MPCE-YOLO 网络结构图

Fig.1 MPCE-YOLO network structure diagram

首先, 对原来的 C3k2 模块进行改进, 引入 MobileMamba 结构, 形成 C3k2\_MobileMamba 模块, 替换了位于 Backbone 和 Neck 部分的 C3k2 模块。该模块利用 Mamba 的状态空间模型高效捕获长距离依赖, 增强了特征提取能力, 提升了模型对复杂场景下

行人特征的表达能力。其次,在 Head 部分增加浅层特征 P2 检测头,进一步提高对小目标检测性能,提升定位精度。然后,在特征融合阶段引入了 CGAFusion 融合模块。该模块在 P2、P3、P4、P5 四个尺度上分别对来自骨干网络和特征金字塔的特征进行自适应融合,通过内容引导的注意力机制突出目标区域的关键特征,有效增强了多尺度特征的语义一致性,提升了模型对尺度变化和遮挡目标的检测性能。最后,设计轻量化共享卷积检测头 ESGECD。该检测头采用共享卷积核实现多层特征图的统一编码,大幅减少了检测头的参数量和计算冗余,同时保持了检测精度,有效平衡了模型性能与部署效率。

### 1.1 C3k2\_MobileMamba 模块

YOLO11 原骨干网络中的 C3k2 模块通过跨阶段特征融合与轻量化卷积设计,在检测精度与计算效率之间实现了较好平衡。然而,对于密集行人检测场景,传统卷积受限于局部感受野,难以建立长距离依赖关系,同时对小目标边缘、纹理等高频细节信息的表征能力不足,容易造成特征丢失和目标漏检。针对上述问题,本文首次将轻量化状态空间模型 MobileMamba 引入 YOLO11 骨干网络,构建特征提取模块 C3k2\_MobileMamba,在不改变原有网络拓扑结构的基础上,仅将核心特征提取单元替换为 MobileMambaBlock,从而增强全局上下文建模能力和复杂场景下行人细粒度特征表达能力,同时保持轻量化特性,实现精度与效率的平衡。其结构如图 2 所示。




图 2 C3k2\_MobileMamba 模块结构图

Fig.2 Structure diagram of C3k2\_MobileMamba module

C3k2\_MobileMamba 模块的核心是 MobileMambaBlock,其内部结构如图 3 所示。该模块采用"DWConv-MRFFI-FFN"的残差设计,每个组件都包

裹在残差连接中。通过深度卷积 (Depthwise Convolution, DWConv) 提取基础特征,通过多感受野特征融合模块 (Multi-Receptive Field Feature Interaction, MRFFI) 融合多感受野信息,通过前馈网络 (Feed-Forward Network, FFN) 进行特征变换。其中核心模块为多感受野特征交互模块 MRFFI,其输入特征沿着通道维度分为三部分,这三个分支并行执行如下差异化算法:

第一部分特征进行了长距离小波变换增强 Mamba (Long-Range Wavelet Transform-Enhanced Mamba, WTE-Mamba),该分支为全局分支,总通道数为  $c$ ,该分支通道数为  $\xi c$ ,其中  $0 \leq \xi \leq 1$ 。全局分支包含两条并行的路径,分别为 Mamba 全局建模  $x_m^o$  和小波变换增强  $x_w^o$ ,最终两条路径的输出相加:

$$x_G^o = x_m^o + x_w^o, x_G^o \in R^{h \times w \times \xi c} \quad (1)$$

其中,小波变换是基于 Haar 小波基的二维离散小波变换 (2D-DWT)。密集人群场景中,行人目标的头部轮廓、肢体边缘以及人体与背景之间的边界通常表现为强烈的阶跃高频灰度突变。Haar 小波基作为典型的阶跃函数,其基函数形态与行人的边缘突变信号具有极高的互相关性,提升高频响应能力。另外,行人的站立姿态使得其几何特征主要集中在垂直和特定对角方向。Haar 小波通过  $x_{HL}$  (垂直细节) 和  $x_{HH}$  (对角细节) 将这些湮灭在复杂背景中的行人细粒度边缘和肢体轮廓解耦并提取出来,有效增强了遮挡场景下的行人边界鉴别力。同时,Haar 小波变换只需要通过简单的加减运算和移位运算实现,不引入复杂的浮点乘法开销,从而实现了轻量化的需求。

第二部分通过多核深度卷积 (Multi-Kernel Depthwise Convolution, MK-DeConv) 运算进行处理,增强不同感受野的感知能力,该分支为局部分支,通道数为  $\mu c$ ,其中  $\mu \leq 1 - \xi$ ,其输出特征表示为:

$$x_{Li}^o = \text{Conv}(x_{Li}^l, k = (2i + 1)), i \in \{1, \dots, n\} \quad (2)$$

$$x_L^o = \text{Concat}([x_{L1}^o, x_{L2}^o, \dots, x_{Ln}^o]) \quad (3)$$

其中  $x_{Li}^o$  表示:将通道划分为  $n$  个子部分之后,每个子部分  $x_{Li}^l$  采用不同尺寸的卷积核进行深度卷积之后的结果,其中卷积核尺寸以 3 为起始奇数,以步长为 2 逐级递增。最后将所有子部分的输出进行拼接得到  $x_L^o$ 。依据空间几何中心对齐原则,采用奇数尺寸是为了保证多分支特征在通道维度拼接时空间几何对齐,确保卷积操作具有明确的中心像素对齐,避免特征图发生空间偏移。步长设为 2 是为了以最小的计算代价实现感受野的非线性阶梯式扩展。

从多尺度感知能力角度来看,卷积核数量  $n$  决定了局部分支可覆盖的感受野层次。当  $n$  较小时,仅能建模有限尺度的局部信息;适当增加卷积核数量能够覆盖由细粒度纹理到局部结构的不同空间范围,增强多尺度特征表征能力。然而,当  $n$  继续增加时,局部

分支总通道数固定为 $\mu c$ ，每个卷积分支可分配的通道数将由 $\frac{\mu c}{n}$ 进一步降低为 $\frac{\mu c}{n+k}$ ，导致单个分支的特征表达能力减弱，容易产生特征碎片化，不利于局部感受野内有效信息的聚合。同时，更多并行卷积分支会增加 GPU 访存开销，降低轻量化网络的实际推理效率，这与 ShuffleNet V2<sup>[24]</sup>提出的减少网络碎片化设计原则一致。此外，随着卷积核尺寸进一步增大（如  $7 \times 7$  及以上），其感受野逐渐接近全局分支 WTE-Mamba 的建模范围，新增尺度与全局语义信息存在较大的功能重叠，多尺度感知能力提升趋于饱和，而计算开销持续增加，呈现收益递减趋势。因此，本文最终采用两个递增卷积核（ $3 \times 3$  和  $5 \times 5$ ）构建局部分支，在覆盖细粒度纹理与局部结构信息的同时，与全局分支形成互补，实现了多尺度特征表达能力与计算效率之间的较好平衡。

第三部分对剩余特征进行恒等映射，减少高维空间中的特征冗余，降低计算复杂度，该分支为恒等映射分支，通道数为 $(1 - \xi - \mu)c$ ，输入特征为 $x^l$ 。因此，对剩余的通道直接应用恒等映射：

$$x_l^o = x^l[(1 - \xi - \mu)c:] \quad (4)$$

三个部分的输出在通道维度拼接，得到 MRFFI 的最终输出：




图3 MobileMamba 结构图

Fig.3 Structure diagram of MobileMamba Block

## 1.2 跨粒度注意力机制 CGAFusion

在 YOLO11 网络中，Neck 通过多次上采样、下采样及特征拼接实现不同尺度特征之间的信息交互。然而，在连续特征聚合过程中，浅层特征中的边缘纹理和局部细节信息容易被高层语义信息弱化，而不同层级特征之间仍然存在一定的语义鸿沟。尤其是在密集行人检测场景下，小尺度目标和遮挡目标更加依赖浅层细节特征。因此，直接将 Neck 输出特征送入检测头，会导致部分细粒度信息丢失，不利于密集遮挡场景下小尺度行人的检测。另外，在多尺度目标检测网络中，传统的特征融合方式存在问题，例如，不

$$x^o = \text{Concat}(x_G^o, x_L^o, x_I^o) \quad (5)$$

本文所述的跨尺度融合并非传统特征金字塔网络中不同分辨率特征图之间的跨层融合，而是针对同一输入特征图内部不同感受野信息的多尺度特征交互与融合。MRFFI 模块通过通道划分策略，将输入特征映射至全局分支、局部分支和恒等映射分支。其中，全局分支利用 WTE-Mamba 建立长距离依赖关系，获得大感受野的全局语义信息；局部分支通过  $3 \times 3$  和  $5 \times 5$  深度卷积提取不同局部感受野下的边缘纹理和邻域结构信息；恒等映射分支则保留原始特征表达和低层细节信息。

三个分支的感受野由小到大依次覆盖细粒度纹理、局部结构以及全局上下文信息，其特征表达具有明显的尺度互补性。因此，本文采用通道拼接操作对三类特征进行融合，由于三个分支输出保持相同的空间分辨率，仅在通道维度上存在差异，因此通道拼接操作不会引入额外的空间信息损失，同时进一步充分保留不同尺度感受野下的特征表达，使不同尺度感受野的信息在后续卷积过程中进行充分交互，实现不同感受野特征之间的跨尺度融合，使网络可同时利用全局上下文信息和局部细节信息，从而增强网络对尺度变化目标和密集遮挡目标的特征表征能力。

同尺度语义冲突未被显示建模、通道与空间关系耦合不足、语义信息和细节信息融合不充分等。

针对这些问题，本文提出在 P2、P3、P4 和 P5 四个检测尺度前引入 CGAFusion 模块，在不改变该模块结构的基础上，针对密集行人检测场景提出一种基于 CGAFusion 的内容引导式跨层特征重融合策略。如图 4 所示，本文中的多尺度融合并非直接对不同分辨率特征图进行再次聚合，而是利用 Neck 已经完成多尺度信息交互的特性，将包含多尺度语义信息的融合特征与 Backbone 输出的原始细节特征进行再次交互。其中，Neck 输出特征已经通过自顶向下和自底向上的路

径聚合了不同尺度的信息, 具有丰富的全局语义表征能力; 而 Backbone 输出特征保留了更多边缘纹理和空间细节信息。将 Neck 输出的多尺度融合特征与 Backbone 对应层级的原始特征共同输入 CGAFusion 模块, 使两者进行再次交互, 通过动态生成融合权重, 实现两类特征的自适应信息交互, 形成“多尺度聚合—内容引导融合—目标检测”的特征处理流程。具体而言, 对于 P2、P3、P4 和 P5 四个尺度, 分别构建如下融合过程:

$$P_i^{out} = \text{CGAFusion}(P_i^{neck}, P_i^{backbone}), i \in \{2, 3, 4, 5\} \quad (6)$$

$P_i^{neck}$  示经过 Neck 多尺度聚合后获得的融合特征, 包含较丰富的语义信息;  $P_i^{backbone}$  表示 Backbone 对应层输出的原始特征, 保留了更多边缘纹理和局部细节信息;  $P_i^{out}$  表示 CGAFusion 输出特征。

CGAFusion 是一种融合通道注意力、空间注意力和像素注意力的跨粒度特征交互模块, 通过多层次注意力协同建模实现对融合特征的动态增强与抑制。

(1) 通道注意力模块通过全局平均池化聚合空间信息, 并利用 Bottleneck 结构生成通道权重, 实现关键语义通道增强与冗余通道抑制。

(2) 空间注意力模块借鉴卷积块注意力模块 (Convolutional Block Attention Module, CBAM) [25] 设计思想, 通过平均池化和最大池化提取空间响应信息, 生成空间注意力图以突出目标区域。

(3) 像素注意力模块进一步在像素级建立通道与空间信息之间的关联关系, 为不同位置动态分配融合权重, 实现细粒度特征重加权 [26]。

从特征融合的角度来看, 通道、空间与像素注意力三者的协同交互及串联顺序遵循自宏观至微观、自解耦至深度耦合的特征清洗逻辑。在多尺度特征融合过程中, 高层语义特征与低层细节特征存在显著的语义差异。高层特征侧重语义表达, 低层特征侧重纹理细节, 直接融合容易引起语义冲突和背景噪声干扰。

CGAFusion 本质上是一种内容感知的语义对齐机制。CGAFusion 采用“通道注意力与空间注意力并行建模、像素注意力串联细化”的设计策略。对于同一尺度下的 Neck 特征和 Backbone 特征, 两者虽然通过上采样实现空间尺寸对齐, 但其语义层级仍存在较大差异。为缓解这种语义鸿沟, CGAFusion 首先通过通道注意力筛选关键语义信息, 增强具有判别能力的语义响应; 随后, 通过空间注意力定位目标区域, 抑制背景噪声; 最后通过像素注意力完成细粒度特征重加权, 对不同位置的融合权重进行动态分配, 实现高层语义信息与低层细节信息的逐像素自适应匹配。因此, CGAFusion 不仅实现了特征融合, 更完成了跨层特征之间的语义对齐, 从根本上解决了多尺度检测结构中浅层空间细

节与深层全局语义无法有机统一的情况。

CGAFusion 结构图如图 5 所示。CGAFusion 模块的内部工作原理如下:

首先, 将 Neck 输出的高层特征  $F_h$  和 Backbone 输出的低层特征  $F_l$  经过通道对齐后进行通道拼接得到初始融合特征  $X$ , 其中  $F_h \in R^{C_h \times H \times W}$ ,  $F_l \in R^{C_l \times H \times W}$ ,  $X \in R^{C \times H \times W}$ :

$$X = F_h + F_l \quad (7)$$

$$C = C_h + C_l \quad (8)$$

其次, 分别计算通道注意力  $W_c$  和空间注意力  $W_s$ , 并通过加权融合得到联合注意力特征  $W_{cos}$ , 随后, 将初始融合特征  $X$  与  $W_{cos}$  进行通道交错 (Channel Shuffle) 和卷积映射操作, 以进一步建立通道与空间信息之间的关联关系, 最终生成像素级注意力权重图  $W$ :

$$W_c = c_{1 \times 1}(\delta(c_{1 \times 1}(X_{GAP}^c))) \quad (9)$$

$$W_s = c_{7 \times 7}([X_{GAP}^s, X_{GMP}^s]) \quad (10)$$

$$W_{cos} = W_c + W_s \quad (11)$$

$$W = \sigma(Gc_{7 \times 7}(\text{Shuffle}([X, W_{cos}]))) \quad (12)$$

其中  $c_{k \times k}$  表示卷积核大小为  $k \times k$  的卷积层,  $\delta(\cdot)$  表示 ReLU 激活函数,  $X_{GAP}^c$ 、 $X_{GAP}^s$  和  $X_{GMP}^s$  表示通过跨空间维度的全局平均池化操作、跨通道维度的全局平均池化和跨通道维度的全局最大池化操作,  $\text{Shuffle}(\cdot)$  表示通道交错,  $Gc_{k \times k}$  表示卷积核大小为  $k \times k$  的分组卷积层,  $\sigma(\cdot)$  表示 Sigmoid 激活函数,  $W \in R^{C \times H \times W}$ 。

最后, 利用生成的动态权重融合图  $W$ , 对高层语义特征和低层细节特征进行自适应加权融合。再通过  $1 \times 1$  卷积对融合结果进行进一步整合, 输出最终融合特征。其融合策略表示为:

$$\text{result} = X + W \cdot F_h + (1 - W) \cdot F_l \quad (13)$$

$$Y = c_{1 \times 1}(\text{result}) \quad (14)$$

其中,  $Y$  是 CGAFusion 最终输出特征,  $W$  的取值范围为  $[0, 1]$ 。与传统固定权重融合方式不同,  $W$  同时包含通道维度与空间维度的信息, 可以针对不同位置 and 不同语义响应动态调整两类特征的贡献比例, 根据输入特征的空间分布与通道响应自适应调整高层语义特征  $F_h$  与低层细节特征  $F_l$  的融合比例。由式 (13) 可知, 当某一区域的语义响应较强时, 动态权重  $W$  趋近于 1, 网络更加关注高层语义信息; 当目标边缘和纹理信息更加重要时,  $W$  趋近于 0, 网络更加关注低层细节特征。这种互补的机制, 正是本文解决跨层融合时分辨率与语义层级不匹配的核心所在。因此, CGAFusion 根据目标尺度、遮挡程度以及场景复杂度自适应调整两类特征的贡献比例, 从而实现更加有效的跨层特征融合。




图4 特征层结构图

Fig.4 Structure diagram of feature layer




图5 CGAFusion 内部结构图

Fig.5 Internal structure diagram of CGAFusion

### 1.3 构建四尺度检测结构

在标准的 YOLO11 目标检测框架中,检测头仅在 P3、P4、P5 三个尺度特征图上进行预测,其对应的下采样倍率分别为 8、16 和 32。随着网络层数的加深,特征图分辨率逐渐降低,虽然深层特征包含更加丰富的语义信息,但空间细节信息会不断丢失,这种现象在检测小尺度目标时尤为明显<sup>[27]</sup>。

设输入图像中目标尺寸为  $h \times w$ , 经过下采样倍率为  $s$  的特征层后,目标在特征图上的尺寸可表示为:

$$h_s = \frac{h}{s}, \quad w_s = \frac{w}{s} \quad (15)$$

则目标在特征图上的有效像素面积为:

$$A_s = \frac{hw}{s^2} \quad (16)$$

由公式 (16) 可知,有效像素面积随着下采样倍率呈平方衰减。当小尺度行人经过多次下采样后,其有效特征像素数量将急剧减少。例如,对于尺寸为  $20 \times 40$  pixels 的行人目标,在 P3 特征层 ( $s=8$ ) 上的有效面积仅为:

$$A_{P3} = \frac{20 \times 40}{8^2} = 12.5 \quad (17)$$

而在 P2 特征层 ( $s=4$ ) 上的有效像素面积为:

$$A_{P2} = \frac{20 \times 40}{4^2} = 50 \quad (18)$$

由式 (17) 和 (18) 可知, P2 层保留的有效特征像素数量约为 P3 层的 4 倍,因此,在密集行人场景中, P2 层可有效缓解目标经过多次下采样后出现的特征退化和信息丢失问题,为小尺度目标提供更加充分的细粒度表征能力。

针对上述问题,本文在 YOLO11 原始结构的基础上引入 P2 检测层,构建 P2-P5 四尺度检测结构,如图 5 所示。其中, P2 特征层的下采样倍率为 4,通过增加高分辨率检测分支,使网络在更早的阶段利用高分辨率特征进行目标检测,从而增强模型对密集场景中小尺度行人的感知能力。

为了同时利用浅层特征的空间细节信息和深层特征的语义信息,本文将 Backbone 输出的 P2 浅层特征与 Neck 上采样后的深层特征进行融合,其过程可表示为:

$$F_{P2} = \text{Conv}(\text{CGAFusion}(\text{Up}(F_{P3}), F_{B2})) \quad (19)$$

其中,  $F_{B2}$  表示 Backbone 输出的浅层特征;  $F_{P3}$  表示 Neck 中的深层语义特征;  $\text{Up}(\cdot)$  表示上采样操作;  $\text{CGAFusion}(\cdot)$  表示语义对齐;  $\text{Conv}(\cdot)$  表示卷积融合操作。

但由于  $F_{P2}$  与  $F_{P3}$  在空间分辨率上相差一倍,因此本文在特征融合时利用上采样操作将  $F_{P3}$  映射到与  $F_{P2}$  特征相同的空间分辨率,实现空间尺度对齐。随后,

利用前文所述 CGAFusion 模块对融合后的高层语义特征与浅层细节特征进行内容引导式重融合, 通过动态调整两类特征的贡献比例, 实现跨层特征之间的语义对齐与信息互补, 从而在机制上解决了四尺度检测结构中浅层空间细节与深层全局语义无法有机对齐的难题。最终生成的 P2 特征图被送入检测头进行预测。

由于 P2 特征图具有更高的空间分辨率, 其计算开销也会相应增加。设输入特征图尺寸为  $H \times W$ , 卷积核大小为  $K \times K$ , 输入和输出通道数分别为  $C_{in}$  和  $C_{out}$ , 对于二维卷积运算, 其理论计算量可表示为:

$$FLOPS_{P2} = 2H_2W_2K^2C_{in}C_{out} \quad (20)$$

由于 P2 特征图尺寸为:  $H_2 = \frac{H}{4}$ ,  $W_2 = \frac{W}{4}$ , 而 P3 特征图尺寸为:  $H_3 = \frac{H}{8}$ ,  $W_3 = \frac{W}{8}$ , 在相同卷积配置下, 其计算量满足:

$$\frac{FLOPS_{P2}}{FLOPS_{P3}} = \frac{H_2W_2}{H_3W_3} = 4 \quad (21)$$

由式 (21) 可知, 在相同通道配置下, P2 层的理论计算量约为 P3 层的 4 倍。因此, 引入 P2 检测层会增加一定的计算开销。然而, 由于 P2 层可以有效提升小尺度目标的有效表征能力, 其带来的性能增益远大于额外增加的计算代价。

## 1.4 ESGECD 检测头

在传统目标检测模型中, 检测头的分类与回归分支从输入起完全独立, 底层特征不共享, 这不仅带来了极高的计算开销和参数冗余, 也缺乏底层特征的共享机制。此外, 常规卷积在面对密集遮挡和模糊场景时, 对相互遮挡边界、重叠高频细节的捕获能力弱, 无针对细节的增强设计, 仅有简单的单级单向注意力机制。

为此, 本文提出了一种面向密集行人检测的轻量化检测头 ESGECD, 并首次构建了“细节增强—特征共享—任务解耦”的渐进式检测头架构。(1) 在检测头前端引入基于组归一化的卷积模块 (Convolution Based On Group Normalization, Conv\_GN) [28], 提高特征表达稳定性; (2) 与原单级结构不同, 针对密集场景首次设计双级细粒度增强卷积 (Granularity-Enhanced Convolution Based On Group Normalization, GEConv\_GN) 串联结构, 实现由局部纹理信息到高阶结构信息的渐进式增强; (3) 采用共享卷积架构替代传统分类与回归分支中的独立卷积结构, 在保持检测性能的同时降低参数量与计算开销。其整体结构如图 6 所示。




图 6 ESGECD 结构图

Fig.6 Structure diagram of ESGECD

首先, 输入特征图经过 Conv\_GN 模块进行通道压缩与特征重组。该模块采用  $1 \times 1$  卷积操作对输入特征图进行降维处理, 实现跨通道信息交互, 也减少后续计算量。设输入特征图为  $F_{in}$ , 经过  $1 \times 1$  卷积后得到压缩特征图:

$$F_c = \text{Conv}_{1 \times 1}(F_{in}) \quad (22)$$

本文在卷积操作后引入组归一化 (Group Normalization, GN)。GN 通过将特征通道划分为若干组, 在每个样本内部对每组特征独立计算均值和方差, 从而

实现特征归一化。假设将通道划分为  $G$  个组, 则每组包含  $C/G$  个通道。对于某一组特征, 其归一化过程可以表示为:

$$\hat{x}_i = \frac{x_i - \mu_g}{\sqrt{\sigma_g^2 + \epsilon}} \quad (23)$$

其中  $x_i$  为该组内的特征值,  $\mu_g$  为该组特征的均值,  $\sigma_g^2$  为该组特征的方差,  $\epsilon$  为防止除零的常数。最终归一化后的输出为:

$$F_{gn} = \gamma \hat{x}_i + \beta \quad (24)$$

其中 $\gamma$ 和 $\beta$ 为可学习参数。GN 通过组内归一化进一步缓解不同通道间的分布差异,提高模型在小批量训练条件下的稳定性,为后续 GEConv 模块的细粒度特征增强提供更加紧凑且稳定的输入特征表示。

随后,将归一化后的特征输入双级 GEConv\_GN 模块进行细粒度增强。GEConv\_GN 来源于细节增强卷积(Detail-Enhanced Convolution, DEConv)<sup>[29]</sup>的设计思想,由标准卷积(Vanilla Convolution, VC)以及中心差分卷积(Central Difference Convolution, CDC)、角度差分卷积(Angular Difference Convolution, ADC)、水平差分卷积(Horizontal Difference Convolution, HDC)和垂直差分卷积(Vertical Difference Convolution, VDC)五条分支组成,通过重参数化技术融合为单个标准卷积进行推理,给定一个输入特征图,GEConv 的输出特征可以表示为:

$$F_{out} = \text{GEConv}(F_{in}) = \sum_{i=1}^5 F_{in} * K_i = F_{in} * K_{cvt} \quad (25)$$

式中: $F_{in}$ 为输入特征; $F_{out}$ 为经过 GEConv 增强后的多尺度特征图; $K_i$ 分别表示 CDC、ADC、HDC、VDC 和 VC 的卷积核;\*表示卷积运算; $K_{cvt}$ 表示变换后的卷积核,它集成了并行卷积。

由于单级 GEConv 在密集行人检测场景下仅依靠一次细粒度增强难以充分建模复杂目标结构,而双级串联结构能够逐步扩大有效感受野,实现由低层纹理信息向高层结构信息的渐进式传递,因此本文采用双级 GEConv 串联结构。

第一级 GEConv 主要负责提取原始特征中的局部边缘、纹理以及梯度变化信息,实现基础细节增强;同时,在两级 GEConv 之间引入 GN 层,对增强后的特征进行标准化处理,缓解特征值漂移导致的梯度消失问题,加速模型收敛。第二级 GEConv 在标准化后进一步建模目标轮廓与高阶结构信息,使网络能感知更加复杂的轮廓形状与目标边界信息,实现由局部细节到结构化目标表示的渐进式增强。

在完成细粒度增强后,特征图进入共享卷积模块。由于目标分类与边界框回归两项任务在底层对行人的边缘和纹理具有强烈的特征共性需求,ESGCD 采用共享卷积层来提取通用语义表示,从而替代了传统检测头中分类与回归分支各自独立的卷积,大幅消除了参数冗余。此外,双级 GEConv 与共享卷积在功能上具有较强互补性。GEConv 侧重于通过多方向差分卷积增强目标边缘、纹理等细粒度结构信息,而共享卷积则进一步对增强后的特征进行语义整合与跨通道融合,构建分类与回归任务共同使用的特征表示。因此,首先利用 GEConv 充分挖掘目标的局部细节特征,再通过共享卷积对增强后的特征进行统一建模与跨通道融合,可避免共享卷积过早压缩特征所造成的细节信息损失。二者形成“细节增强—特征共享—任务解耦”的渐进式特征处理流程,在保证轻量化的同时提高检

测头对复杂场景目标的表征能力。

最后共享特征分别输入分类分支与回归分支。分类分支采用  $1 \times 1$  卷积与 Sigmoid 激活函数输出目标类别置信度;回归分支采用  $1 \times 1$  卷积预测边界框位置参数,并利用缩放因子(Scale)参数自适应调整不同尺度特征图的回归范围。

$$F_{cls} = \text{Sigmoid}(\text{Conv}_{1 \times 1}(F_{shared})) \in R^{H \times W \times 1} \quad (26)$$

$$F_{reg} = \text{Scale} \cdot \text{Conv}_{1 \times 1}(F_{shared}) \in R^{H \times W \times (4 \times 16)} \quad (27)$$

分类分支与回归分支的输出在通道维度进行拼接,得到各尺度特征图的检测结果。随后,对 P2-P5 四个尺度的检测结果进行汇总,通过非极大值抑制(Non-Maximum Suppression, NMS)去除冗余预测框,得到最终的图像检测输出。

下文的消融实验证明,本文提出的 ESGCD 模块降低了计算复杂度,有效增强网络对细节边界、纹理结构等高频信息的感知能力,从而增强网络对复杂场景中遮挡、模糊目标的识别能力。

## 2 实验环境与评价指标

### 2.1 数据集

本文采用公开的数据集 CrowdHuman<sup>[30]</sup>、CityPersons<sup>[31]</sup>和 WiderPerson<sup>[32]</sup>对算法进行训练和验证,以评估其在行人检测任务中的性能和有效性。

CrowdHuman 数据集是一个专注于密集场景下的行人检测任务的大规模人群图像数据集。数据集总共包含约 24000 张高分辨率图像,这些图像来源于真实的街道场景、公共活动区域、交通枢纽以及城市人群密集区域等多种环境。该数据集中,15000 张用于训练,5000 张用于测试,另有 4370 张构成验证集,总计标注了超过 47 万个行人实例。平均每张图像包含约 20 个以上的行人目标。该数据集的核心目标是推动目标检测算法在复杂环境下的性能提升,并且更加关注目标密度高、遮挡严重的真实场景,因此在检测难度和研究价值方面具有重要意义。

WiderPerson 数据集是面向拥挤场景行人检测任务构建的专用数据集,此数据集包含多种场景(如商场、街道和车站等),以及不同密度不同姿态的行人。整体包含 13382 张图像,累计标注行人相关实例约 40 万个。其中训练集 8000 张图像,验证集 1000 张图像、测试集 4382 张图像。

CityPersons 数据集是面向城市街景密集行人检测的经典基准数据集,由城市道路监控场景下采集的图像构成,该数据集共包含 2975 张训练图片、500 张验证图片和 1575 张测试图片,每幅图平均标注 7 名行人,其标注体系细致区分了可见行人、部分遮挡行人、重度遮挡行人等不同状态,该数据集被广泛用于验证密集行人检测算法在遮挡鲁棒性、小目标检测精度、复杂环境泛化能力等核心维度的表现。

## 2.2 实验环境及参数配置

本实验用的操作系统为 Ubuntu 20.04, GPU 型号为 NVIDIA GeForce RTX 4090, CPU 为 13th Gen Intel(R) Core(TM) i7-13700KF, 主机内存大小为 62GB, 显存大小为 24GB, 使用 Python3.10 作为编程语言, 使用 Pytorch 2.2.2 作为深度学习框架, CUDA 版本为 12.1。实验中不采用预训练权重, 采用 SGD 优化器 (Stochastic Gradient Descent), 实验的具体参数如表 1 所示。

表 1 模型训练参数

| Table 1 Model training parameters |        |
|-----------------------------------|--------|
| Parameters                        | Setup  |
| Epochs                            | 300    |
| Batch size                        | 16     |
| Image size                        | 640    |
| Optimizer                         | SGD    |
| Initial learning rate             | 0.01   |
| Workers                           | 4      |
| Weight decay                      | 0.0005 |
| Momentum                          | 0.937  |
| Warmup epoch                      | 3      |
| Warmup momentum                   | 0.8    |

## 2.3 评价指标

为了验证本文算法的性能, 选择准确率 P (Precision)、召回率 R (Recall)、平均精度 AP (Average Precision)、平均精度 mAP (mean Average Precision)、参数量 (Parameters)、浮点运算量 (GFLOPs) 和帧率 (Frames Per Second, FPS) 作为评价指标。其中, P 用于衡量检测结果的准确性, 表示被正确识别的行人在所有检测到的目标中的比例; R 则反映检测的完整性, 表示成功检测出的行人在实际存在行人中的比例。mAP@0.5 指交并比 (Intersection over Union, IoU) 为 0.5 时的平均精确度均值, mAP@0.5:0.95 为 IoU ∈ (0.5, 0.95)、以 0.05 为步长的平均精度均值。其中 P, R, mAP 的计算公式如下:

$$P = \frac{TP}{TP + FP} \quad (28)$$

表 2 C3k2\_MobileMamba 模块不同位置对比

Table 2 Comparison of Different Positions of the C3k2\_MobileMamba Module

| Model                     | P/%         | R/%         | mAP50/%     | mAP50:95/%  | Parameter/M | Size/M     |
|---------------------------|-------------|-------------|-------------|-------------|-------------|------------|
| YOLO11n                   | 85.7        | 70.9        | 82.4        | 52.0        | 2.6         | 5.2        |
| C3k2_MobileMamba-backbone | 85.5        | 71.1        | 82.5        | 52.1        | 2.5         | 5.0        |
| C3k2_MobileMamba-neck     | 85.5        | 71.2        | 82.6        | 52.2        | 2.5         | 5.2        |
| C3k2_MobileMamba-all      | <b>85.7</b> | <b>71.3</b> | <b>83.0</b> | <b>52.5</b> | <b>2.3</b>  | <b>4.9</b> |

## 3.2 C3k2\_MobileMamba 模块通道比例分析

为验证 C3k2\_MobileMamba 模块中 MRFFI 的全局分支与局部分支通道划分策略的合理性, 本文对全

$$R = \frac{TP}{TP + FN} \quad (29)$$

$$AP = \int_0^1 P(R) dR \quad (30)$$

$$mAP = \frac{1}{N} \sum_{i=1}^N AP(i) \quad (31)$$

式 (18)~(21) 中,  $N$  表示检测的类别综述;  $TP$ ,  $FP$  和  $FN$  分别表示真阳性 (True Positive)、假阳性 (False Positive) 和假阴性 (False Negative) 的数量。

## 3 实验结果与分析

### 3.1 C3k2\_MobileMamba 模块有效性

为了验证所提出的 C3k2\_MobileMamba 模块在不同网络位置对模型性能的影响, 本文设计了在 CrowdHuman 数据集上的对比实验, 如表 2 所示。由表 2 中的数据可知, 当仅在 Backbone 或 Neck 部分引入 C3k2\_MobileMamba 模块时, 模型在保持检测精度基本稳定的情况下, 整体参数量和计算复杂度均有所降低。而当 Backbone 与 Neck 同时引入 C3k2-MobileMamba 模块 (all) 时, 模型整体性能达到最佳状态。在该配置下, 虽然 Precision 没有发生变化, 但是模型的 Recall 提升至 71.3%, mAP50 提升至 83.0%, mAP50-95 提升至 52.5%, 相比于基线模型有明显提升, 同时参数量下降至 2.3M, 模型大小减少至 4.9M, 在保持轻量化优势的同时进一步提升了检测性能。产生上述效果的主要原因在于, C3k2-MobileMamba 模块在原有卷积特征提取结构的基础上引入了 MobileMamba 轻量化序列建模机制。该机制可以在较低计算开销下有效建模长距离依赖关系, 使网络在提取局部空间特征的同时具备更强的全局上下文感知能力。当该模块同时应用于 Backbone 与 Neck 时, 网络在不同层级的特征表达过程中均能够充分利用其全局建模优势, 从而实现更加有效的多尺度特征融合。

局分支比例  $\xi$  进行了参数敏感性分析。参考 MobileMamba 原始网络中全局分支占主导地位 ( $\xi=0.6\sim0.8$ ), 局部分支比例  $\mu$  固定在 0.2~0.3 范围内

的设计思想,同时考虑性能主要受全局分支比例影响以及 YOLO11 轻量化检测框架对计算效率的要求,本文设置  $\zeta$  分别为 0.25、0.40、0.60 和 0.70 进行对比实验,并保持局部分支比例  $\mu=0.25$  不变。实验结果如表 3 所示,实验结果表明,当  $\zeta=0.6$ ,  $\mu=0.25$  时模型取得

最佳检测性能,说明适当增加全局建模通道有助于增强密集场景下行人特征表达能力,但过大的全局分支比例会压缩局部细节建模空间,从而影响检测效果。因此,本文所有实验均在通道比例为  $\zeta=0.6$ ,  $\mu=0.25$  的情况下进行。

表 3 全局分支与局部分支通道划分

Table 3 Global branch and local branch channel partitioning

| Channel ratio             | P/%         | R/%         | mAP50/%     | mAP50:95/%  | Parameter/M | Size/M     |
|---------------------------|-------------|-------------|-------------|-------------|-------------|------------|
| $\zeta=0.25$ , $\mu=0.25$ | 85.3        | 71.0        | 82.6        | 52.3        | 2.3         | <u>4.8</u> |
| $\zeta=0.4$ , $\mu=0.25$  | 85.3        | <u>71.5</u> | 82.8        | 52.4        | 2.3         | 4.9        |
| $\zeta=0.6$ , $\mu=0.25$  | <b>85.7</b> | <b>71.3</b> | <b>83.0</b> | <b>52.5</b> | <b>2.3</b>  | <b>4.9</b> |
| $\zeta=0.7$ , $\mu=0.25$  | 85.6        | 71.3        | 82.8        | 52.4        | 2.4         | 5.1        |

### 3.3 双级 GEConv 结构有效性验证

为了验证 ESGECD 检测头中双级 GEConv 串联结构设计的合理性,本文进一步进行了针对性消融实验。实验分别设置三种检测头结构:无 GEConv 结构,仅保留共享卷积检测头;单级 GEConv 结构,在共享卷积前引入一层 GEConv 模块;双级 GEConv 结构(本文提出方法),采用两层 GEConv 串联并在中间引入 GN 归一化层。实验如表 4 所示。

由表 4 可以看出,引入单级 GEConv 后,模型的 mAP50 由 82.0%提升至 82.4%,mAP50:95 由 51.5%提

升至 51.8%,说明 GEConv 能够有效增强边缘、纹理等细粒度信息的表达能力。在此基础上,采用双级 GEConv 串联结构后,mAP50 进一步提升至 82.7%,mAP50:95 提升至 52.2%。这表明第二级 GEConv 在一级细节增强的基础上进一步挖掘高阶结构特征,增强目标轮廓与遮挡边界信息的表达能力,从而提升复杂场景下的检测性能。同时,双级 GEConv 仅增加约 0.1M 参数量,却获得了 0.3%的 mAP50 提升,说明所提出的双级细粒度增强策略具有较高的性能收益与参数效率。

表 4 双级 GEConv 串联结构有效性验证实验

Table 4 Validation study on the effectiveness of the cascaded dual-stage GEConv structure

| Structure     | P/%         | R/%         | mAP50/%     | mAP50:95/%  | Parameter/M | Size/M     |
|---------------|-------------|-------------|-------------|-------------|-------------|------------|
| YOLO11n       | 85.7        | 70.9        | 82.4        | 52.0        | 2.6         | 5.2        |
| No GEConv     | 85.2        | 71.0        | 82.0        | 51.5        | <u>1.9</u>  | <u>4.2</u> |
| Single GEConv | 85.5        | 71.8        | 82.4        | 51.8        | 1.9         | 4.5        |
| Double GEConv | <b>85.8</b> | <b>72.0</b> | <b>82.7</b> | <b>52.2</b> | <b>2.0</b>  | <b>4.8</b> |

### 3.4 消融实验

为了验证本文中提出的改进算法,本文将 YOLO11n 作为基线模型,使用 C3k2\_MMA (C3k2\_MobileMamba-all)、CGA (CGAFusion 特征融

合网络)、P2 (P2 检测头)和 ESGECD (ESGECD 轻量化检测头)在 CrowdHuman 数据集上开展了系统性的消融实验,在验证集上对各个训练输出的最佳权重文件进行验证,具体结果如表 5 所示,每组实验均在相同的环境配置和参数设置下进行。

表 5 消融实验结果

Table 5 Results of ablation experiments

| Baseline | C3k2_MMA | CGA | P2 | ESGECD | P/%         | R/%         | mAP50/%     | mAP50:95/%  | Parameter/M | Size/M     | GFLOPS      |
|----------|----------|-----|----|--------|-------------|-------------|-------------|-------------|-------------|------------|-------------|
| √        |          |     |    |        | 85.7        | 70.9        | 82.4        | 52.0        | 2.6         | 5.2        | 6.3         |
| √        | √        |     |    |        | 85.7        | 71.3        | 83.0        | 52.5        | 2.3         | 4.9        | 6.2         |
| √        |          | √   |    |        | <u>86.3</u> | 71.9        | 83.2        | 52.9        | 3.0         | 6.0        | 8.7         |
| √        |          |     | √  |        | 86.0        | 74.0        | 84.9        | 55.0        | 3.3         | 6.7        | 13.5        |
| √        |          |     |    | √      | 85.8        | 72.0        | 82.7        | 52.2        | 2.0         | 4.8        | <u>5.7</u>  |
| √        | √        | √   |    |        | 85.9        | 72.6        | 83.5        | 53.4        | 2.8         | 5.8        | 8.6         |
| √        | √        | √   | √  |        | 86.0        | <u>74.5</u> | <u>85.5</u> | <u>55.8</u> | 3.3         | 7.0        | 14.1        |
| √        | √        | √   | √  | √      | <b>86.3</b> | <b>75.7</b> | <b>85.8</b> | <b>56.2</b> | <b>2.7</b>  | <b>5.5</b> | <b>10.2</b> |

表 5 的消融实验结果表明,引入

C3k2\_MobileMamba-all 模块之后,模型的 mAP50 从

82.4%提升至83.0%, mAP50:95从52.0%提升至52.5%,更为关键的是,得益于C3k2\_MobileMamba高效的架构设计,模型的参数量从2.6M显著降低至2.3M,降幅约为11.5%,模型大小也从5.2M缩减至4.9M,计算量GFLOPS下降0.1M,在降低计算开销的同时增强了网络对全局信息的感知能力,因此模型能够更加准确地识别密集人群场景中的目标结果,提高检测稳定性。

引入CGAFusion模块后,相较于基线模型,其在准确率方面表现更优,提升至86.3%,召回率提升了1%, mAP50和mAP50:95分别提升0.8%和0.9%,验证了其在上下文信息融合中的有效性,CGAFusion模块使高层语义信息和低层细节信息实现更加充分的交互,提高模型对目标边界和细节特征的识别能力。

引入P2检测头之后,相较于基线模型,模型性能获得了最显著提升。mAP50和mAP50:95分别提升2.5%和3%,召回率提升了3.1%,说明增加P2检测层之后,模型利用更高分辨率的特征图保留更多细粒度空间信息,从而增强对小尺度行人的检测能力。但是不可避免,由于新增了高分辨率特征分支,模型参数量由2.6M增加至3.3M,模型大小由5.2M增加至6.7M,计算量由6.3增加至13.5,分别增长26.9%、28.8%和114.3%。虽然引入P2层带来了一定计算开销,但其带来的检测性能增益在所有改进中最为显著。因此,相比于适度增加的模型开销,P2层带来的检测性能提升具有更高的实际应用价值。从精度提升与模型复杂度变化的综合角度来看,引入P2检测层是合理且必要的。

此外,本文设计的ESGECD检测头替换原模型检测头,相较于基线模型, mAP50提升了0.3%,参数量减少了23.1%,模型大小减少了7.7%,计算量减少了9.5%,在保持检测精度的同时实现了更好的轻量化效果。最后,将四种改进方法进行结合,最终结果表明,相比原模型 mAP50提升了3.4%, mAP50:95提升了4.2%,参数量、模型大小和计算量虽有提升,但是相较于C3k2\_MobileMamba-all、CGAFusion和P2共同组合时,参数量、模型大小和计算量分别降低了18.2%、21.4%和27.7%,这说明,尽管C3k2\_MobileMamba-all、CGAFusion和P2模块带来了性能提升,但是轻量化检测头ESGECD有效缓解了P2检测层及特征增强模块引入后的参数增长问题,使得最终模型在实现最高精度的同时,有效兼顾了检测精度与计算开销需求,验证了改进策略的合理性与有效性。为密集行人检测任务提供了更优的检测性能与部署适应性。

### 3.5 对比实验

为了进一步验证所提出MPCE-YOLO模型在密集场景行人检测任务中的有效性,本文选取两阶段检测器SSD、Faster R-CNN,以及单阶段检测器YOLOv5<sup>[33]</sup>、YOLOv8<sup>[34]</sup>、YOLOv10<sup>[35]</sup>、YOLO11、YOLO12<sup>[36]</sup>和YOLO13<sup>[37]</sup>等主流目标检测模型进行对比,同时与近年来面向密集场景提出的改进模型

YOLO11n-GSConv、YOLO11n-AFPN<sup>[38]</sup>、YOLO11n-WTConv<sup>[39]</sup>、LDD-YOLO-n<sup>[40]</sup>、MCAP-YOLO<sup>[41]</sup>、改进YOLOv10-n<sup>[42]</sup>和MSD-YOLO<sup>[43]</sup>等进行比较,所有实验均在CrowdHuman数据集上采用相同训练策略和实验环境完成,实验结果如表6所示。

由表6可知,与经典目标检测模型相比,MPCE-YOLO在检测精度方面具有明显优势。与基线模型YOLO11n相比,MPCE-YOLO的Precision、Recall、mAP50和mAP50:95分别提高了0.6%、4.8%、3.4%和4.2%。其中,Recall指标提升最为显著,说明所提出的方法进一步有效缓解密集遮挡场景下目标漏检问题,提高对被遮挡行人的检测能力。

与最新的YOLO系列模型相比,MPCE-YOLO同样表现出较强的竞争力。相较于YOLO13, Precision、Recall、mAP50和mAP50:95分别提升1.2%、6.1%、4.2%和5.0%;相较于YOLO12,上述指标分别提升0.7%、5.3%、3.9%和4.6%。这表明本文提出的特征建模、多尺度特征融合以及检测头优化策略可以更加充分地挖掘密集场景中的目标特征,提高模型对遮挡目标和小尺度目标的检测能力。

与近年来的改进模型相比,MPCE-YOLO的综合性性能同样表现突出。虽然MCAP-YOLO的mAP50达到85.3%,与本文方法较为接近,但MPCE-YOLO进一步将mAP50提升至85.8%,提高了0.5%;同时mAP50:95由55.2%提升至56.2%,提高了1.0%。此外,MPCE-YOLO的Recall达到75.7%,高于MCAP-YOLO的74.4%,说明本文方法在保证检测精度的同时,能够有效减少漏检现象。

值得注意的是,YOLO11n-AFPN的mAP50:95达到57.4%,略高于本文方法的56.2%,但其参数量和计算量分别达到7.1M和16.0 GFLOPs,分别是MPCE-YOLO的2.63倍和1.57倍。相比之下,MPCE-YOLO仅使用2.7M参数和10.2 GFLOPs即取得了接近的检测性能,体现出更优的精度与复杂度平衡能力。

为了全面评估模型复杂度和推理效率,进一步对模型参数量(Params)、计算量(GFLOPs)和推理速度(FPS)进行了比较。与基线模型YOLO11n相比,MPCE-YOLO的参数量仅由2.6M增加至2.7M,增长约3.8%,而GFLOPs由6.3增加至10.2,增长约61.9%。虽然带来了一定的计算开销,但模型仍保持较轻量化的网络规模。

为保证不同模型之间对比的公平性,FPS仅统计模型前向传播(Forward)时间,不包含数据预处理和后处理过程。所有模型均在RTX4090 GPU、输入尺寸为640×640、batch size为16以及FP32精度的统一设置下进行测试,表中的FPS表示模型的平均吞吐率(images/s)。实验结果表明,MPCE-YOLO的推理速度达到274 images/s,虽然低于基线模型YOLO11n的570 images/s,但仍高于YOLO11n-AFPN的238 images/s。与YOLO11n-WTConv

的 452 images/s 相比, 本文方法虽然牺牲了一部分推理速度, 但在 mAP50 和 mAP50:95 指标上分别提升了 2.2% 和 0.4%, 说明所提出的方法在检测精度与推理效率之间取得了较好的平衡, 适用于对检测精度与定位质量要求更高的应用场景。

综合来看, 在仅增加少量参数的情况下, 实现了

表 6 不同检测模型对比实验

Table 6 Comparative experiment of different detection models

| Model             | P/%         | R/%         | mAP50/%     | mAP50:95/%  | Parameter/M | Size/M     | GFLOPs      | FPS<br>(images/s) |
|-------------------|-------------|-------------|-------------|-------------|-------------|------------|-------------|-------------------|
| SSD               | 69.2        | 38.4        | 70.3        | 33.5        | 33.2        | 113.5      | 41          | 290               |
| Faster R-CNN      | 72.6        | 45.7        | 72.6        | 39.3        | 41.1        | 158.1      | 207.1       | 135               |
| YOLOv5n           | 82.8        | 67.4        | 79.4        | 45.9        | <u>1.8</u>  | <u>3.6</u> | 4.1         | <u>760</u>        |
| YOLOv5s           | <u>86.8</u> | 71.6        | 83.6        | 52.7        | 7.0         | 13.7       | 15.8        | 420               |
| YOLOv8n           | 85.9        | 71.6        | 82.8        | 52.6        | 3.0         | 5.9        | 8.1         | 770               |
| YOLOv10n          | 83.1        | 69.2        | 79.7        | 46.8        | 2.7         | 5.5        | 8.2         | 618               |
| YOLO11n(baseline) | 85.7        | 70.9        | 82.4        | 52.0        | 2.6         | 5.2        | 6.3         | 570               |
| YOLOv12           | 85.6        | 70.4        | 81.9        | 51.6        | 2.5         | 5.2        | 5.8         | 502               |
| YOLOv13           | 85.1        | 69.6        | 81.6        | 51.2        | 2.4         | 5.2        | 6.2         | 563               |
| YOLO11n-GSConv    | 83.4        | <u>79.3</u> | 81.3        | 50.5        | 2.3         | 4.6        | 8.2         | 473               |
| YOLO11n-AFPN      | 83.6        | 73.7        | 85          | <u>57.4</u> | 7.1         | 15.1       | 16.0        | 238               |
| YOLO11n-WTConv    | 84.2        | 73.4        | 83.6        | 55.8        | 2.8         | 6.1        | 7.5         | 452               |
| LDD-YOLO-n        | 81.1        | 65.5        | 77.4        | 46.6        | 4.7         | —          | <u>1.8</u>  | —                 |
| MCAP-YOLO         | 86.0        | 74.4        | <u>85.3</u> | 55.2        | —           | —          | —           | —                 |
| 文献[43]            | —           | 70.8        | 82.7        | 51.2        | —           | —          | —           | —                 |
| MSD-YOLO          | —           | —           | 81.1        | 52.9        | 3.0         | —          | 10.6        | —                 |
| MPCE-YOLO(Ours)   | <b>86.3</b> | <b>75.7</b> | <b>85.8</b> | <b>56.2</b> | <b>2.7</b>  | <b>5.5</b> | <b>10.2</b> | <b>274</b>        |

### 3.6 泛化实验

为全面评估所提出模型在跨数据集场景中的适应能力与稳定表现, 本文进一步设计了泛化性能对比实验, 并选取了 CityPersons 和 WiderPerson 两个具有代表性的行人检测数据集进行验证, 分别模拟城市街道密集行人场景与复杂环境下的多尺度行人检测场景, 实验环境、训练策略及超参数设置均与主实验保持一致。

在 CityPersons 数据集上的实验结果如表 7 所示。相较于基线模型 YOLO11n, MPCE-YOLO 在 P 和 R 方面分别提升了 0.4% 和 5.6%, 说明改进模型有效降低了密集场景下的行人漏检率, 提升了对遮挡、小尺度行人目标的捕获能力。MPCE-YOLO 在 mAP50 指标上达到 65.4%, 相较基线模型的 59.2% 提升了 6.2%; 而在更为严格的 mAP50:95 指标上, 也由 36.2% 提升至 40.8%, 增幅达到 4.6%。这体现出模型具有更高的定位准确性。MPCE-YOLO 的参数量为 2.8M, 相较于基线模型的 2.6M 略有增加, 同时模型大小由 5.2MB 增加至 5.5MB。这种轻微的增长换来了检测性能的大

幅提升, 说明所引入的结构改进在计算成本与性能收益之间取得了较好的平衡。

为进一步评估模型在更复杂环境、多尺度行人分布场景下的适应能力, 本文在 WiderPerson 数据集上开展泛化性测试, 实验结果如表 8 所示。相较于基线模型 YOLO11n, MPCE-YOLO 在 P、R、mAP50 和 mAP50:95 上分别提升了 0.9%、1%、1.2% 和 1.3%, 虽然整体提升幅度相较 CityPersons 数据集略小, 但考虑到 WiderPerson 数据集本身已经具有较高的检测基准, 这种稳定的性能增长依然具有重要意义, 说明模型在不同难度级别的数据集上均具备良好的适应能力。在参数量和模型大小方面, MPCE-YOLO 与在 CityPersons 上的表现一致, 参数量为 2.7M, 模型大小为 5.5MB, 未因数据集场景变化而产生额外开销, 进一步证明了模型改进策略的通用性与稳定性。

综合两个数据集的实验结果可以看出, MPCE-YOLO 在跨场景泛化能力方面表现出较强的稳定性与一致性。

表 7 泛化性对比实验 (CityPersons)

Table 7 Generalization Comparison Experiment (CityPersons)

| Model             | P/%         | R/%         | mAP <sub>50</sub> /% | mAP <sub>50:95</sub> /% | Parameter/M | Size/M     |
|-------------------|-------------|-------------|----------------------|-------------------------|-------------|------------|
| YOLO11n(baseline) | 77.5        | 50.9        | 59.2                 | 36.2                    | 2.6         | 5.2        |
| MPCE-YOLO(Ours)   | <b>77.9</b> | <b>56.5</b> | <b>65.4</b>          | <b>40.8</b>             | <b>2.7</b>  | <b>5.5</b> |

表 8 泛化性对比实验 (WiderPerson)  
Table 8 Generalization Comparison Experiment (WiderPerson)

| Model             | P/%         | R/%         | mAP <sub>50</sub> /% | mAP <sub>50:95</sub> /% | Parameter/M | Size/M     |
|-------------------|-------------|-------------|----------------------|-------------------------|-------------|------------|
| YOLO11n(baseline) | 85.9        | 80.3        | 88.8                 | 63.2                    | 2.6         | 5.2        |
| MPCE-YOLO(Ours)   | <b>86.8</b> | <b>81.3</b> | <b>90.0</b>          | <b>64.5</b>             | <b>2.7</b>  | <b>5.5</b> |

3.7 可视化实验

为了更直观地比较 MPCE-YOLO 算法与基准模型 YOLO11n 算法的检测效果,本文在 CrowdHuman、CityPersons 和 WiderPerson 的测试集上分别对两种算法进行测试,选取具有典型特征的图片进行检测结果和热力图可视化,其可视化结果如图 7、图 8 和图 9 所示。通过对比分析,原始 YOLO11n 在一些复杂场景下存在漏检和边界框定位不准确等问题。在暗光场景下,MPCE-YOLO 算法可以更多地检测出后方的行人;在街头拥挤人群场景中,MPCE-YOLO 算法准确识别出后方遮挡的行人,并且在小目标场景下,精准识别

出远处的小目标,而原始 YOLO11n 在复杂场景和暗光条件下存在若干明显的检测缺陷。在暗光条件下,模型对目标的检测精度大幅下降,部分目标未被检测出。在远距离小目标检测方面存在显著的漏检现象,部分小目标未被有效识别。

总体而言,通过对比不用场景下的检测结果,改进算法在多目标检测、遮挡场景的识别、边缘目标感知以及小目标检测等方面均优于基准模型,具有更高的精度、更广的检测范围以及更强的鲁棒性,这充分验证了改进算法在特征增强、注意力引导和检测头设计方面的有效性。




图 7 检测结果对比图 (CrowdHuman)  
Fig.7 Comparison of test results




图8 检测结果对比图 (CityPersons)

Fig.8 Comparison of test results (CityPersons)



图9 检测结果对比图 (WiderPerson)

Fig.9 Comparison of test results (WiderPerson)

#### 4 结论

本文围绕密集行人检测任务中普遍存在的小目标识别精度不足、目标间严重遮挡以及检测精度与模型轻量化难以兼顾等关键问题,提出一种基于 YOLO11n 改进的密集行人检测算法——MPCE-YOLO。该算法在 YOLO11n 框架基础上,首先,对 C3k2 模块进行改进,引入 MobileMamba 结构以增强主干网络对行人特征建模能力,从而提升复杂场景下的特征表达效果。其次,构建 P2-P5 四尺度检测结构,引入高分辨率特征层以强化小目标检测能力,减少多尺度信息损失。然后,基于内容引导注意力的特征融合模块,实现多层特征的自适应加权融合,提升模型对关键区域的关

注能力。最后,设计轻量化检测头 ESGECD,通过共享卷积与细粒度增强机制降低参数量与计算复杂度,同时提升检测精度与模型效率。在 CrowdHuman、CityPersons 和 WiderPerson 三个数据集上进行了系统评估,实验结果表明,MPCE-YOLO 在参数量和模型大小上控制在较低水平,在性能上显著超越基线模型。这些结果证明了 MPCE-YOLO 在密集行人检测任务中取得了较好的检测性能,并且在不同场景、不同数据分布条件下均能保持稳定性能提升。

未来研究将集中进一步降低模型计算复杂度、探索更高效的注意力机制、优化网络结构以及结合多任务学习,以进一步提升模型在实际复杂场景中的应用效果与泛化能力。

## 参考文献:

- [1] 陈胜宝, 施隆照. YOLO-PD: 轻量级实时行人检测算法[J]. 计算机工程与应用, 2026, 62(06): 122-133.
- CHEN S B, SHI L Z. YOLO-PD: lightweight real-time pedestrian detection algorithm[J]. Computer Engineering and Applications, 2026, 62(06): 122-133.
- [2] DALAL N, TRIGGS B. Histograms of oriented gradients for human detection[C]//2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05). Piscataway: IEEE, 2005: 886-893.
- [3] ZHU D X. SIFT algorithm analysis and optimization[C]//2010 International Conference on Image Analysis and Signal Processing. Piscataway: IEEE, 2010: 415-419.
- [4] CAI Z, VASCONCELOS N. Cascade r-cnn: Delving into high quality object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 6154-6162.
- [5] GIRSHICK R. Fast R-CNN. Computer science[C]//Proceedings of the 2015 IEEE International Conference on Computer Vision (ICCV). 2015: 1440-1448.
- [6] REN S, HE K, GIRSHICK R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. IEEE transactions on pattern analysis and machine intelligence, 2016, 39(6): 1137-1149.
- [7] LIU W, ANGUELOV D, ERHAN D, et al. Ssd: single shot multibox detector[C]//European conference on computer vision. Cham: Springer International Publishing, 2016: 21-37.
- [8] Redmon J, DIVVALA S, GIRSHICK R, et al. You only look once: unified, real-time object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 779-788.
- [9] 陈海秀, 陈子昂, 宁馨, 等. 改进 YOLOv10n 的密集行人小目标检测方法[J/OL]. 小型微型计算机系统, 1-10[2026-04-01].
- CHEN H X, CHEN Z A, NING X, et al. Improved YOLOv10n dense pedestrian small target detection method[J/OL]. Journal of Chinese Computer Systems, 1-10[2026-04-01].
- [10] 王丽黎, 樊盼盼, 张诗雨. 面向密集行人场景的 YOLOv8n 改进算法[J]. 电子技术应用, 2025, 51(02): 15-20.
- Wang L L, FAN P P, ZHANG S Y. An improved YOLOv8n algorithm for dense pedestrian scenarios[J]. Application of Electronic Technique, 2025, 51(2): 15-20.
- [11] 汤静雯, 赖惠成, 王同官. 远距离情形下的改进 YOLOv8 行人检测算法[J]. 计算机工程, 2025, 51(04): 303.
- TANG J W, LAI H C, WANG T G. Improved YOLOv8 pedestrian detection algorithm for long-distance situations[J]. Computer Engineering, 2025, 51(04): 303.
- [12] HUA C J, LUO K, WU Y D, et al. YOLO-ABD: A multi-scale detection model for pedestrian anomaly behavior detection[J]. Symmetry, 2024.
- [13] YANG L, ZHANG R Y, LI L, et al. Simam: A simple, parameter-free attention module for convolutional neural networks[C]//International conference on machine learning. PMLR, 2021: 11863-11874.
- [14] LI H, LI J, WEI H, et al. Slim-neck by GSConv: A lightweight-design for real-time detector architectures[J]. Journal of Real-Time

Image Processing, 2024, 21(3): 62.

- [15] ZHU L H, LIAO B C, ZHANG Q, et al. Vision mamba: Efficient visual representation learning with bidirectional state space model[J]. arXiv preprint arXiv:2401.09417, 2024.
- [16] LIU Y, TIAN Y, ZHAO Y, et al. Vmamba: Visual state space model[J]. Advances in neural information processing systems, 2024, 37: 103031-103063.
- [17] WANG Z, LI C, XU H, et al. Mamba yolo: A simple baseline for object detection with state space model[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2025, 39(8): 8205-8213.
- [18] YANG G, LEI J, ZHU Z, et al. AFPN: Asymptotic feature pyramid network for object detection[J]. arXiv preprint arXiv:2306.15988, 2023.
- [19] DANG J, TANG X, LI S. HA-FPN: hierarchical attention feature pyramid network for object detection[J]. Sensors, 2023, 23(9): 4508.
- [20] SAPKOTA R, FLORES-CALERO M, QURESHI R, et al. YOLO advances to its genesis: a decadal and comprehensive review of the you only look once (YOLO) series[J]. Artificial Intelligence Review, 2025, 58(9): 274.
- [21] HE H, ZHANG J, CAI Y, et al. Mobilemamba: Lightweight multi-receptive visual mamba network[C]//Proceedings of the computer vision and pattern recognition conference. 2025: 4497-4507.
- [22] CHEN C, YU C, CAI S. Advancing landslide recognition through multi-dimensional feature fusion and transformer architectures[J]. The Visual Computer, 2025, 41(13): 11311-11325.
- [23] YUAN T, LAI H, TANG J, et al. LMFE-Net: A lightweight multi-scale pedestrian feature enhancement network for complex scenarios[J]. Optics & Laser Technology, 2025, 192: 113860.
- [24] MA N, ZHANG X, ZHENG H T, et al. Shufflenet v2: Practical guidelines for efficient cnn architecture design[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 116-131.
- [25] WOO S, PARK J, LEE J Y, et al. CBAM: convolutional block attention module[C]//Computer Vision-ECCV 2018, 2018: 3-19.
- [26] ZHANG Y, LI S, YAO T, et al. A drone detection network based on multi-scale feature fusion and content-guided attention mechanism[C]//2025 8th International Conference on Artificial Intelligence and Big Data (ICAIBD). IEEE, 2025: 219-224.
- [27] 薛光辉, 闫朝阳, 吴冕. PCSED-YOLO: 复杂环境下跨尺度多目标穿戴检测算法研究[J]. 计算机工程与应用, 2026, 62(05): 88-105.
- XUE G H, YAN C Y, WU M. PCSED-YOLO: Study on cross-scale multi-object wearable detection algorithm in complex environments[J]. Computer Engineering and Applications, 2026, 62(05): 88-105.
- [28] WU Y, HE K. Group normalization[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 3-19.
- [29] CHEN Z X, HE Z W, LU Z M. DEA-Net: Single image dehazing based on detail-enhanced convolution and content-guided attention[J]. IEEE transactions on image processing, 2024, 33: 1002-1015.
- [30] SHAO S, ZHAO Z J, LI B X, et al. CrowdHuman: A benchmark for detecting human in a crowd [EB/OL]. [2024-10-29]. <http://arxiv.org/abs/1805.00123>.

- [31] ZHANG S, BENENSON R, SCHIELE B. Citypersons: A diverse dataset for pedestrian detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 3213-3221.
- [32] ZHANG S, XIE Y, WAN J, et al. Widerperson: A diverse dataset for dense pedestrian detection in the wild[J]. IEEE Transactions on Multimedia, 2019, 22(2): 380-393.
- [33] KHANAM R, HUSSAIN M. What is YOLOv5: A deep look into the internal features of the popular object detector [EB/OL]. [2024-07-30]. <https://arxiv.org/abs/2407.20892>.
- [34] VASANTHI P, MOHAN L. Efficient YOLOv8 algorithm for extreme small-scale object detection[J]. Digital Signal Processing, 2024, 154: 104682.
- [35] WANG A, CHEN H, LIU L, et al. Yolov10: Real-time end-to-end object detection[J]. Advances in neural information processing systems, 2024, 37: 107984-108011.
- [36] KHANAM R, HUSSAIN M. A review of YOLOv12: attention-based enhancements vs. previous versions [EB/OL]. [2025-10-24]. <https://arxiv.org/abs/2504.11995>.
- [37] LEI M, LI S, WU Y, et al. YOLOv13: Real-Time object detection with hypergraph-enhanced adaptive visual perception[J]. arXiv preprint arXiv:2506.17733, 2025.
- [38] YANG G, LEI J, ZHU Z, et al. AFPN: Asymptotic feature pyramid network for object detection[C]//2023 IEEE International Conference on Systems, Man, and Cybernetics (SMC). IEEE, 2023: 2184-2189.
- [39] FINDER S E, AMOVAL R, TREISTER E, et al. Wavelet convolutions for large receptive fields[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2024: 363-380.
- [40] 杨迪, 张喜龙, 王鹏. LDD-YOLO: 改进 YOLOv8 的轻量级密集行人检测算法[J]. 计算机科学与探索, 2026, 20(1): 251-265.
- YANG D, ZHANG X L, WANG P. LDD-YOLO: Improved Lightweight Dense Pedestrian Detection Algorithm Based on YOLOv8[J]. Journal of Frontiers of Computer Science and Technology, 2026, 20(1): 251-265.
- [41] 周亚罗, 韩宁, 尹彪彪, 等. 针对密集场景的 MCAP-YOLO 和 Byte Track 行人跟踪算法研究[J]. 小型微型计算机系统, 2026, 47(6): 1449-1456.
- ZHOU Y L, HAN N, YIN B B, et al. Research on MCAP-YOLO and Byte Track Pedestrian Tracking Algorithms for Dense Scenes[J]. Journal of Chinese Computer Systems, 2026, 47(6): 1449-1456.
- [42] 王丽黎, 樊盼盼, 张诗雨. 面向密集行人场景的 YOLOv8n 改进算法[J]. 电子技术应用, 2025, 51(2): 15-20.
- WANG L L, F P P, ZHANG S Y. An improved YOLOv8n algorithm for dense pedestrian scenarios[J]. Application of Electronic Technique, 2025, 51(2): 15-20.
- [43] 陈海秀, 陈子昂, 陈丁熊, 等. 改进 YOLOv10-n 的密集行人检测模型[J/OL]. 红外技术, 1-10[2026-06-29].
- CHEN H X, CHEN Z A, CHEN D X, et al. Improved YOLOv10-n Dense Pedestrian Detection Model[J/OL]. Infrared Technology, 1-10[2026-06-29].