

YOLO-FLCSW:一种无人机视角下的小目标检测算法

宋丽丽^{1,2}, 徐子涵^{1,2}, 韩建峰^{1,2*}, 房建东^{1,2}, 南汝君^{1,2}, 李丽^{1,2}

¹内蒙古工业大学信息工程学院, 内蒙古 呼和浩特 010080;

²内蒙古自治区智能感知与系统工程重点实验室, 内蒙古 呼和浩特 010080

摘要 针对无人机巡检航拍图像中存在的小目标漏检、背景干扰及模型难以高效部署于嵌入式平台等挑战,提出一种基于 YOLOv8n 改进的轻量化小目标检测算法(YOLO-FLCSW)。首先,基于 FasterNet 和选择性注意力 LSK 模块构建轻量化特征提取模块 C2f_FLK,增强网络对小目标区域的感知能力;其次,提出一种跨尺度特征融合模块 UAV-CCFM,在提升网络对不同尺度特征融合能力的同时,有效控制整体参数量;再次,引入 SPPELAN 模块增强模型对不同尺度目标的适应性,进而提升小目标的检测精度;最后,采用 WIoUv3 损失函数以降低网络对低质量锚框的关注度。在 VisDrone2019 数据集上的消融与对比实验表明,相较于 YOLOv8n,所提算法在平均精度均值($P_{mAP@0.5}$ 和 $P_{mAP@0.5:0.95}$)指标上分别提升了 8.0 个百分点和 5.4 个百分点,同时模型大小与参数量分别减少了 33.3% 和 37.5%,在实现模型轻量化的同时有效提升了小目标检测性能。在自制公路巡检数据集上的实验进一步验证了模型的泛化能力。部署到 NVIDIA Jetson Xavier NX 平台的实验结果表明,与 YOLOv8n 相比,所提算法在满足实时性检测要求的前提下,能够获得更高的检测精度。

关键词 无人机; 小目标检测; 轻量化; YOLOv8n; NVIDIA Jetson Xavier NX

中图分类号 TP391 **文献标志码** A

DOI: 10.3788/LOP251524

1 引言

近年来,无人机在智能巡检领域发展迅速。其低空视野优势能够突破地形限制,在复杂环境中实现大范围实时数据采集,并通过高空视角获取更丰富的地面信息。这一技术特性使其成为建筑、交通和电力^[1-3]等领域的重要巡检工具。目标检测技术作为无人机智能巡检的核心,直接影响着无人机在复杂场景下对小目标的识别精度与效率。

在无人机目标检测的实际应用场景中,模型设计需平衡轻量化、检测精度和部署效率等 3 大核心需求。现有目标检测算法主要分为两大类:一是双阶段检测算法(如 Faster-RCNN 等),其通常包含候选区域生成和精细分类两个步骤,训练与推理过程需要较多的计算资源,导致速度较慢;二是单阶段检测方法(如 YOLO^[4]系列),因其端到端的架构优势,可通过单一网络直接输出目标位置和类别,避免了候选框生成环节,在推理速度方面具有显著优势。然而,针对无人机

场景中普遍存在的小目标检测难题,现有改进方法仍面临挑战。例如,Wang 等^[5]提出 Focal 快速网块(FFNB)并引入 BiFormer 注意力机制以提升小目标检测精度,但增加了两个检测层,模型结构变得复杂,导致计算量和推理时间均有不同程度的增加。Yue 等^[6]提出的轻量级 LE-YOLO 算法,通过深度可分离卷积强化特征融合能力,并配合颈部 LGS 瓶颈和 LGSCSP 模块以实现模型效率与精度的平衡。Wang 等^[7]提出的 YOLOX-X 目标检测算法 YOLOX_w,引入路径聚合网络、轻量级子空间注意力模块及优化后的损失函数,提升了检测精度,但也带来了参数量变大、运行速度较慢的问题。Li 等^[8]提出的 SOD-YOLO 模型,通过 RFCBAM 模块优化特征提取,并结合 BSSI-FPN 架构平衡空间与语义信息融合,在无人机图像小目标检测中实现了精度提升与模型轻量化,但该网络缺乏头部组件,且未包含主流注意力机制,难以应对特定任务。Zhang 等^[9]提出的 HSP-YOLOv8 算法,通过微小预测头增强小目标识别效果,并结合 SPD-Conv 模块实现

收稿日期: 2025-06-20; 修回日期: 2025-08-06; 录用日期: 2025-08-25; 网络首发日期: 2025-08-26

基金项目: 内蒙古自治区自然科学基金项目(2025LHMS06009)、内蒙古自治区科技计划项目(2023YFJM0002, 2025YF-HH0156)

通信作者: *hanjianfeng@imut.edu.cn

多尺度特征保留,有效解决了无人机航拍中小物体聚集与遮挡问题,显著降低了误检漏检率,但因其增加了 160×160 的预测头,模型复杂度较高,难以在嵌入式机载平台上部署。

尽管已有方法在无人机小目标检测中取得了一定进展,但航拍图像的复杂背景仍导致漏检与误检频发,且模型在嵌入式平台上的部署受到限制。以公路巡检为例,当前目标检测技术主要面临以下问题:其一,无人机智能公路巡检中的小目标在图像中像素占比低,特征图上对应的占用点数有限,这限制了检测网络对这些目标特征的感知能力,导致模型难以获得足够的区分信息;其二,航拍图像中目标尺度跨度大(从几像素到数百像素),且多尺度目标密集共存;其三,无人机公路巡检图像中,道路纹理、车道标线、植被阴影等复杂背景与目标特征相似,加之光照变化大,易产生大量背景干扰,从而增加误检与漏检的风险。针对上述无人机视角下小目标的本质特性,本文提出一种轻量化检测算法 YOLO-FLCSW,采用特征增强、多尺度融合、上下文增强和损失优化的改进策略,每个模块均针对无人机小目标检测的特定问题而设计。本文的主要贡献如下:

1) 针对无人机视角下小目标像素占比低、特征稀疏的核心挑战,结合 FasterNet 和 LSKNet 的选择性注意力机制(LSK 模块),对主干网络中的 C2f 模块进行改进,提出了新的特征提取结构 C2f_FLK。该结构有效提升了模型的特征提取与抗干扰能力,并在保持检测性能的同时实现了模型的轻量化。

2) 针对无人机航拍中多尺度目标共存且浅层细节特征易丢失的特点,结合轻量级跨尺度特征融合模块(CCFM),提出了 UAV-CCFM 结构,高效融合多尺度特征并降低参数量。该结构通过 1×1 卷积实现通道对齐与跨通道信息整合,促进多尺度特征融合,并增设了 P2 小目标检测头,在增强模型多尺度感知与小目标检测能力的同时,有效控制了整体参数量。

3) 针对无人机场景中目标尺度变化大、上下文信息复杂的特性,引入了基于高效层聚集网络的空间金字塔池化结构(SPPELAN)。该模块通过金字塔池化和局部信息聚合来增强模型对不同尺度目标的适应性,有效处理多尺度目标的特征,从而提升了模型对小目标的检测性能。

4) 针对复杂背景与目标密集带来的低质量样本问题,采用了 Wise-IoUv3(WIoUv3)损失函数。该方法通过动态调控梯度分配,有效抑制了低质量样本对模型训练的干扰,同时强化了对中高质量样本的优化权重,提升了模型在复杂场景下的检测鲁棒性和精度。

2 改进 YOLO-FLCSW 目标检测算法

Ultralytics 于 2023 年发布的 YOLOv8 采用 C2f 与空间金字塔快速池化(SPPF)主干、PAN-FPN 颈部结

构、多尺度模型及解耦型 anchor-free 预测头,实现了速度、精度与应用场景适应性的良好平衡。近年来,尽管 YOLO 系列(如 YOLO11)和非 YOLO 系列(如 RT-DETR)等新模型不断涌现,结构创新日益丰富,但 YOLOv8 凭借其成熟的技术生态,仍是航拍小目标场景下进行结构改进与性能验证的理想基础模型。然而,受限特征表达能力,YOLOv8n 在应对航拍图像中目标尺寸微小、背景复杂等挑战时,易出现漏检与误检。为此,本文提出了改进模型 YOLO-FLCSW,其在满足实时性要求的前提下,有效提升了对小目标的表征能力。其整体架构如图 1 所示。

YOLO-FLCSW 针对无人机视角下小目标检测的特殊挑战,基于 YOLOv8 在 4 个方面进行了改进:1)采用 C2f_FLK 模块提升小目标特征表达能力,以解决小尺寸目标的特征提取难题。2)引入 UAV-CCFM 模块以强化跨尺度特征融合,适应无人机场景中多尺度目标共存的特点。3)使用 SPPELAN 模块扩展空间感知范围,增强对小目标上下文信息的获取。4)采用 WIoUv3 损失函数以改善小目标边界回归精度,提升定位准确性。

2.1 改进主干特征提取网络

在无人机航拍视角下,小目标检测是任务中的主要挑战之一。YOLOv8 通过 C2f 模块来提取航拍图像中的目标特征。然而,C2f 模块虽然通过残差连接和瓶颈结构提取高级特征,但随着提取层数的增加,会带来额外的计算成本和参数量,并且其对空间重点背景信息的感知能力可能减弱。针对上述问题,提出了 C2f_FLK 模块,其结构如图 2 所示。

该模块引入 Faster Block 替代原有的 bottleneck 结构,在保持高效特征提取能力的同时,降低了模型计算开销。此外,在网络中添加了选择性注意力机制 LSK 模块,通过引入多尺度感受野,增强了模型对目标空间重点背景信息的感知能力。

2.1.1 改进 FasterNet

Chen 等^[10]提出的 PConv 算子通过通道分组与跨层内存复用优化了计算流程,在保证特征表达能力的同时,显著降低了计算量和内存访问次数。PConv 仅对部分输入通道进行卷积,其余通道则保持恒等映射,从而实现了高效的特征提取与推理。假设输入特征尺寸为 $h \times w \times c$,经过 $k \times k \times c$ 的卷积后输出特征尺寸为 $h \times w \times c$,其中, h 和 w 分别是图像的高和宽, c 是通道数。那么,常规卷积(Conv)的浮点运算数(FLOPs)如式(1)所示,其内存访问量(MAC)如式(2)所示。

$$F_{\text{FLOPs}} = h \times w \times k^2 \times c^2 \quad (1)$$

$$M_{\text{MAC}} = 2 \times h \times w \times c \quad (2)$$

PConv 的 FLOPs 如式(3)所示,其 MAC 如式(4)所示。

$$F_{\text{FLOPs}} = h \times w \times k^2 \times c_p^2 \quad (3)$$

$$M_{\text{MAC}} = 2 \times h \times w \times c_p \quad (4)$$




图1 YOLO-FLCSW 结构图

Fig. 1 YOLO-FLCSW structure diagram




图2 C2f_FLK 模块结构

Fig. 2 C2f_FLK module structure

部分卷积与普通卷积的结构对比如图3所示。假设 $c_p = \frac{c}{4}$, 则 PConv 的 FLOPs 仅为常规 Conv 的 $\frac{1}{16}$, 而其内存访问量仅为 Conv 的 $\frac{1}{4}$ 。因此, PConv 通过减少计算冗余和内存访问次数, 显著提高了计算效率。

Faster Block 是 FasterNet 中的一种轻量化特征提取模块。输入特征首先经过一个 PConv 层, 然后经过两个 1×1 卷积层, 最后与残差连接拼接得到输出。在第一个 1×1 卷积后添加了批归一化(BN)层和激活层。其结构如图4(a)所示。Faster Block 可以有效减少计算冗余和内存访问, 从而提高神经网络的运行速度和精度。

在小目标检测任务中, YOLOv8 主干的 C2f 模块通过残差连接和瓶颈结构带来了额外的计算成本。而 Faster Block 结构简单、参数量少、操作速度快。因此,




图3 Conv和PConv结构图

Fig. 3 Structure diagrams of Conv and PConv




图4 Faster Block与C2f_FasterNet结构图。(a)Faster Block结构图;(b)C2f_FasterNet结构图

Fig. 4 Faster Block and C2f_FasterNet structure diagram.

(a) Faster Block structure diagram; (b) C2f_FasterNet structure diagram

本文使用Faster Block来替换C2f中的bottleneck,从而得到C2f_FasterNet结构,如图4(b)所示。此举旨在减少模型参数数量和计算量,更有效地提取空间特征,并

提高模型的推理速度。

2.1.2 选择性注意力

局部空间信息选择性核(LSK)模块^[11]具备根据输入动态调节空间感受野的能力,从而能够高效捕获丰富的上下文信息,提升空间关注精度。针对无人机航拍中背景复杂、干扰强的实际问题,LSK模块通过并行多尺度大卷积核处理,增强了模型对关键区域的感知能力。具体而言,LSK包含两条并行分支:一条采用 5×5 深度可分离卷积与 1×1 卷积,用于提取局部空间特征;另一条采用膨胀率为3的 7×7 深度可分离卷积与 1×1 卷积,以采集更大感受野的上下文信息。两分支获得的特征经通道维度的全局平均池化和最大池化后,在 7×7 卷积层进行空间特征信息的融合与交互,充分整合了不同尺度的空间描述符。此后,通过Sigmoid激活函数生成动态权重,并与大卷积核序列特征进行逐通道相乘,实现对特征的自适应加权。加权后的特征再经过卷积层进一步融合,得到最终的注意力特征,最后与输入特征逐元素点乘后输出结果。LSK模块结构如图5所示。




图5 LSK模块结构图

Fig. 5 LSK module structure diagram

LSK模块结构不仅提升了对多尺度信息的捕获能力,还能自动调节对不同复杂度目标及背景的关注程度,从而有效适应无人机航拍图像中目标尺度与背景的变化,提升检测精度和场景适应性,为无人机智能巡检提供有力支持。

通过在C2f_FasterNet中集成LSK模块,可以利用LSK模块的大感受野特性捕获小目标周围更丰富的上下文信息,弥补特征稀疏的不足,同时抑制背景噪声,突出目标区域特征。同时,通过FasterNet架构保证了在特征增强的同时控制计算复杂度,以满足嵌入

式部署的需求。

对LSK模块在C2f_FasterNet中的添加位置进行了对比分析,共考察了4个候选位置,如图4(a)中的a和b位置(即Faster Block中最后一层卷积合并的前后位置),以及图4(b)中的c和d位置(即C2f_FasterNet最后一层卷积的前后位置)。根据实验结果,最终选择将LSK模块添加到d位置。由此构成的C2f_FLK模块能够在实现模型轻量化的同时,更有效地提升对小目标空间信息的捕获能力,减少复杂背景信息对小目标检测的干扰,从而提高模型的整体性能。

2.2 改进跨尺度特征融合模块

YOLOv8的颈部结构基于PAN-FPN机制,通过自顶向下和自底向上的多尺度特征融合增强了语义信息的传递。然而,该结构在捕获浅层细节特征方面存在不足,且多次采样过程中不可避免地会导致部分细粒度特征丢失,限制了底层信息的充分利用。为此,受跨尺度特征融合模块^[12]的启发,结合通道与空间注意力机制,在每条融合路径中进行了优化。首先,利用 1×1 卷积(无激活函数)对输入特征进行线性变换,统一不同尺度特征的通道维度至256,实现维度匹配。其次,在上采样前加入 1×1 卷积(带激活函数),通过引入非线性激活来增强模型的表达能力。最后,将C2f与 3×3 卷积的输出通道数均设计为256,在保证模型表达能力的同时有效控制了参数量。该结构采用元素级相加和拼接的方式融合多尺度特征,在兼顾计

算效率的同时,优化了细粒度细节与全局语义的融合效果,从而增强了模型在多尺度目标,特别是小目标检测任务中的表现能力。

针对无人机视角下目标小、分布密集等挑战,在CCFM基础上提出了UAV-CCFM融合结构。该结构通过优化颈部区域,降低了模型参数量,并进一步提升了多尺度特征融合效率及对密集小目标的检测能力。在检测头设计上,传统模型通常输出3层特征图(P3~P5,分辨率分别为 80×80 、 40×40 、 20×20),但 80×80 特征图对极小目标的表达能力有限。因此,UAV-CCFM额外引入了下采样率为4的P2检测头(160×160 特征图),使其更适应以小目标为主的无人机场景,从而进一步提升检测精度,并通过 1×1 卷积有效控制了参数规模。UAV-CCFM结构如图6所示。




图6 UAV-CCFM结构图

Fig. 6 UAV-CCFM structure diagram

2.3 改进快速空间金字塔池化层

SPPF 是 YOLOv8 的组成部分,它对传统的空间金字塔池化(SPP)结构进行了改进。SPPF 通过串行最大池化结构提升了推理效率并简化了计算过程,但其串行结构限制了并行性,导致多尺度特征表达的独立性较弱,难以充分满足无人机场景下对小目标检测与复杂背景判别的更高要求。

SPPELAN^[13]是一种结合了 SPP 和高效层聚合网络(ELAN)^[14]结构的目标检测模块。该模块通过多分

支特征传递与局部信息聚合,实现了多层次空间特征的高效提取。具体而言,SPPELAN 首先利用 1×1 卷积对输入特征进行通道降维,随后通过多个并行的最大池化层提取不同尺度的空间上下文信息,最终通过通道拼接与融合卷积整合多尺度特征,从而增强特征表达能力及上下文感知能力。在无人机航拍场景下,SPPELAN 能有效提升模型对小目标和复杂背景的检测精度与鲁棒性。SPPF 和 SPPELAN 的结构对比如图 7 所示。




图 7 SPPF 和 SPPELAN 结构图

Fig. 7 SPPF and SPPELAN structure diagrams

2.4 优化损失函数

对 YOLOv8 中 CIoU^[15] 损失函数在无人机检测任务中的局限性进行分析可知:其线性宽高比约束在目标发生非线性变化时可能引发梯度偏移,且静态的调焦策略仅关注重叠区域而忽略了空间分布,导致几何偏差。在航拍场景中,复杂背景与目标密集性加剧了低质量样本的干扰,而 CIoU 的上述缺陷进一步削弱了模型对空间信息的感知能力,限制了检测精度的提升。为此,引入了基于动态聚焦机制的 WIoUv3^[16] 损失函数。其构建了梯度增益分配策略,通过动态权重系数抑制低质量样本的异常梯度干扰,从而提升了模型在复杂场景下的检测鲁棒性。WIoUv3 有效缓解了因预测框与真实框宽高比呈线性依赖关系而导致的几何失真问题,并通过重构梯度传播路径提升了模型的收敛稳定性。

WIoUv3 利用离群度 β 来衡量锚框质量,并基于 β 构造一个非单调聚焦系数 r ,将其应用于 WIoUv1。WIoUv1 的计算公式如下:

$$L_{\text{WIoUv1}} = R_{\text{WIoU}} \times L_{R_{\text{IoU}}} \quad (5)$$

$$R_{\text{WIoU}} = \exp\left(\frac{(b_{c_x}^{\text{gt}} - b_{c_x})^2 + (b_{c_y}^{\text{gt}} - b_{c_y})^2}{(c_w^2 + c_h^2)}\right) \quad (6)$$

$$L_{R_{\text{IoU}}} = 1 - R_{\text{IoU}} \quad (7)$$

式中: c_w 和 c_h 代表检测框的最小外接矩形的宽和高; $(b_{c_x}^{\text{gt}}, b_{c_y}^{\text{gt}})$ 代表真实框的中心点坐标; (b_{c_x}, b_{c_y}) 代表预测框的中心点坐标。 β 值越小,表示锚框质量越高,为其分配较小的 r 值,以降低高质量锚框在较大损失函数中的权重。 β 值越大,表示锚框质量越低,则分配较小的梯度增益,以减少低质量锚框产生的有害梯度。WIoUv3 通过这种梯度增益分配策略获得了优越的性能,其公式如下:

$$L_{\text{WIoUv3}} = r \times L_{\text{WIoUv1}} \quad (8)$$

$$r = \frac{\beta}{\delta \alpha^{\beta - \delta}} \quad (9)$$

$$\beta = \frac{L_{R_{\text{IoU}}}^*}{L_{R_{\text{IoU}}}} \in [0, +\infty) \quad (10)$$

式中: δ 和 α 是超参数; $L_{R_{\text{IoU}}}^*$ 是当前 IoU 损失; $\overline{L_{R_{\text{IoU}}}}$ 是 IoU 损失的滑动平均值。WIoUv3 通过动态调整的锚框质量评估策略,采用非单调机制引导模型聚焦于中等质量的候选区域,有效增强了小尺度目标的定位精度。该改进方案适用于无人机视角下的密集小目标检测场景,通过自适应损失函数加权机制,针对性地强化了模型对微小目标的优化权重,从而在复杂背景及目标尺度分布不均衡的场景中实现了更稳定的检测效果。

3 实验环境及评价指标

3.1 数据集

由于巡检领域公开数据集稀缺,采用双重验证策略:选取 VisDrone2019 数据集作为通用小目标检测性能评估基准,以验证所提算法在复杂环境下的基础检测性能;同时构建无人机公路智能巡检数据集,以评估算法在实际巡检应用场景中的有效性和实用性。

VisDrone2019^[17]是由天津大学与 AISKYEYE 团队联合开发的大规模无人机航拍数据集,涵盖 10209 张高分辨率静态图像与 288 段视频(共计 261908 帧),采集自中国多种类型的城乡场景,覆盖多种天气与光照条件。该数据集包含约 260 万个经人工标注的边界框,目标以行人、车辆、非机动车为主,具有小目标主导、密度极化与动态尺度变化等特性。VisDrone2019 被广泛应用于小目标检测、多目标跟踪和密集人群计数等任务,并被严格划分为训练集(6471 张)、验证集(548 张)和测试集(1610 张)。

在无人机公路智能巡检应用中,准确的道路标线检测是实现自主导航的关键技术环节。通过对标线位置的精确识别,可为无人机飞行控制系统提供实时的航迹修正信息,从而实现沿道路中心线的自主巡检飞行,保障巡检任务的安全性和有效性。因此,构建高质量的标线检测数据集对于提升无人机智能巡检系统的整体性能具有重要意义。针对无人机公路智能巡检任

务的特殊需求,本研究采用 M300 RTK 无人机与禅思云台相机(H20、P1)构建了道路标线检测数据集。该数据集主要涵盖校园内部道路场景,同时也包括高速公路、一级公路和二级公路的相关场景。拍摄区域集中在校园、高速公路,以及国道,确保了场景涵盖阴影、杂物及遮挡等复杂环境,以增强数据集的多样性。最终构建的数据集包含 4 种类型的路面标线:白实线、黄虚线、白虚线,以及黄实线。该数据集共计包含 8519 张图像,其中,训练集 7502 张,验证集 1017 张。部分样例图像如图 8(a)所示。

图 8(b)展示了自制数据集的手动标注相关信息。左上角的子图显示了数据集中每种类别的实例数量,该数据集以黄虚线为主。右上子图展示了数据集中对象边界框的大小分布,所有对象框的中心点被归一化至同一点以便比较。左下图是目标中心点的空间位置分布热力图,深蓝色区域表示目标密度最高的区域。目标中心点主要集中在图像中央偏下位置,形成一个十字形分布:在 $y \approx 0.5$ 和 $x \approx 0.5$ 附近,形成两条交叉的高密度带,而图像左右边缘的目标分布相对稀疏。右下角的散点图展示了物体边界框的相对宽度与高度。由图可知,绝大多数目标集中分布于图形的左下角小尺寸区域,其中,高密度区域主要位于宽度小于 0.02、高度小于 0.2 的范围内。根据相对面积标准(小于图像面积的 0.12%),高密度区域目标可被认定为小目标。同时,这些目标的宽高比普遍小于 0.1,也满足小目标的判定条件。




图 8 无人机航拍公路标线数据集示例图和信息图。(a)示例图;(b)信息图

Fig. 8 UAV aerial road marking dataset example diagrams and infographic. (a) Example diagrams; (b) infographic

3.2 实验环境及训练参数

实验的训练平台为 Windows 系统, GPU 为 NVIDIA 3090TI(24 GB 显存),深度学习框架为 PyTorch 2.1.0, Python 版本为 3.8, CUDA 版本为 11.8。具体实验设置如表 1 所示。

实验中所有模型的输入图像尺寸均统一为 640×640 。在相同的实验环境下,采用相同的训练参数,所有模型均训练 300 个周期(epoch)。详细的训练参数配置见表 1。

模型的验证、推理及实时性能测试在 NVIDIA

表 1 实验参数设置表

Table 1 Experimental parameter setting table

Parameter	Numeric
Epoch	300
Batch size	8
Image size	640×640
Initial learning rate	0.01
Momentum	0.937
Weight decay	0.0005
Worker	4
Optimizer	SGD

Jetson Xavier NX 嵌入式平台上进行。该平台实验环境为 Pytorch 1.11、TensorRT 8.5、Python 3.8、Jetpack 5.1.2。嵌入式平台的具体设备参数如表 2 所示,其中, TOPS 表示每秒万亿次操作。

3.3 评价指标

本实验采用的评价指标包括平均精度均值(P_{mAP}),

表 2 嵌入式设备参数

Table 2 Embedded device parameters

Name	Configuration
CPU	6-core ARM Cortex-A57
GPU	NVIDIA Volta™ GPU
Memory	8 GB
Computility	21 TOPS
Operating system	Ubuntu 20.04 focal

表 3 消融实验

Table 3 Ablation experiments

Model	Scheme	C2f_FLK	UAV-CCFM	SPPELAN	WIoUv3	$P_{\text{mAP}0.5}$ %	$P_{\text{mAP}0.5;0.95}$ %	P %	R %	Model size /MB	Param s / 10^6	FPS / (frame·s ⁻¹)
YOLOv8n	1					33.0	19.2	43.7	33.8	6.3	3.01	145
	2	✓				34.0	19.8	43.8	34	5.9	2.81	143
	3		✓			39.9	23.8	49.6	38.7	4.8	2.23	110
	4			✓		33.6	19.6	44.6	33.4	5.9	2.85	150
	5				✓	34.0	19.8	46.4	33.5	6.3	3.01	145
	6	✓	✓			40.5	24.4	50.9	38.8	4.5	2.03	108
	7	✓	✓	✓		40.6	24.3	49.7	38.8	4.2	1.88	115
	8	✓	✓	✓	✓	41.0	24.6	51.0	39.5	4.2	1.88	116

方案 2 使用 C2f_FLK 替换 YOLOv8 主干部分的 C2f 模块,其 $P_{\text{mAP}0.5}$ 和 $P_{\text{mAP}0.5;0.95}$ 分别提升了 1.0 个百分点和 0.6 个百分点,同时模型参数量降低了 0.2×10^6 。这证明 C2f_FLK 模块能够捕获更多的小目标空间信息,减少复杂背景的干扰,在提升模型检测性能的同时实现了模型的轻量化。

方案 3 仅将 UAV-CCFM 替换原 YOLOv8 的颈部网络。虽然 FPS 有所降低,但网络性能得到显著提升: $P_{\text{mAP}0.5}$ 、 $P_{\text{mAP}0.5;0.95}$ 、 P 和 R 分别提升了 6.9 个百分点、4.6 个百分点、5.9 个百分点和 4.9 个百分点,同时模型大小减少了 1.5 MB,参数量减少了 0.78×10^6 。这充

具体为 $P_{\text{mAP}0.5}$ 和 $P_{\text{mAP}0.5;0.95}$ 、精确率(P)、召回率(R)、参数量(Params)、浮点运算数(FLOPs)、模型大小和帧率(FPS)。

P_{mAP} 综合考虑了不同 IoU 阈值下的所有精确率和召回率情况,是一个综合性指标。 $P_{\text{mAP}0.5}$ 代表了 IoU 阈值为 0.5 时的 P_{mAP} 值, $P_{\text{mAP}0.5;0.95}$ 则为 IoU 从 0.5 开始,以步长 0.05 递增至 0.95 时,各阈值下 P_{mAP} 的平均值。 $P_{\text{mAP}0.5}$ 和 $P_{\text{mAP}0.5;0.95}$ 的值越大,表明模型的整体精度越高。 mAP 的计算公式如式(11)所示。

$$P_{\text{mAP}} = \frac{1}{n} \sum_{k=1}^n P_{\text{AP},k} \quad (11)$$

精确率的计算公式如式(12)所示。

$$P = \frac{N_{\text{TP}}}{N_{\text{TP}} + N_{\text{FP}}} \quad (12)$$

召回率的计算公式如式(13)所示。

$$R = \frac{N_{\text{TP}}}{N_{\text{TP}} + N_{\text{FN}}} \quad (13)$$

式中: N_{TP} 、 N_{FP} 、 N_{FN} 分别代表真阳性、假阳性和假阴性的数量。

4 实验结果与分析

4.1 消融实验

为了深入分析和验证各个改进模块对无人机航拍图像目标检测性能的影响,以 YOLOv8n 为基准模型,进行了一系列消融实验,实验结果如表 3 所示。

分说明 UAV-CCFM 有效提升了模型的多尺度特征融合能力,并显著减小了模型参数量。

方案 4 引入了快速空间金字塔池化层 SPPELAN。在降低参数量和模型大小的同时, $P_{\text{mAP}0.5}$ 、 $P_{\text{mAP}0.5;0.95}$ 和 P 分别提升了 0.6 个百分点、0.4 个百分点和 0.9 个百分点,FPS 达到 150 frame/s,表明 SPPELAN 能使模型更有效地处理多尺度目标的特征,从而增强模型的整体性能。

方案 5 采用了 WIoUv3 损失函数。在参数量和模型大小不变的情况下, $P_{\text{mAP}0.5}$ 、 $P_{\text{mAP}0.5;0.95}$ 和 P 分别提升了 1.0 个百分点、0.6 个百分点和 2.7 个百分点。

方案 6 在方案 2 的基础上引入了 UAV-CCFM, 使得 $P_{\text{mAP}@0.5}$ 、 $P_{\text{mAP}@0.5:0.95}$ 和 P 分别提升了 6.5 个百分点、4.6 个百分点和 7.1 个百分点。

方案 7 在方案 6 的基础上进一步引入了 SPPELAN, 在 $P_{\text{mAP}@0.5}$ 提升 0.1 个百分点且 FPS 提升 7 frame/s 的情况下, 参数量下降了 0.15×10^6 。

方案 8 整合了所有改进模块。与基线模型相比, $P_{\text{mAP}@0.5}$ 、 $P_{\text{mAP}@0.5:0.95}$ 、 P 和 R 分别提升了 8.0 个百分点、5.4 个百分点、7.3 个百分点和 5.7 个百分点, 参数量和模型大小分别减少了 37.5% 和 33.3%。虽然 FPS 有

所降低, 但仍能保持在 116 frame/s。综合来看, 改进后的网络结构在满足实时性要求的前提下, 有效提升了检测性能。

4.2 LSK 模块位置对比实验

为了系统评估 LSK 模块的布局策略, 在 C2f_FLK 模块中对 LSK 模块的不同添加位置进行了对比实验 (位置如图 4(a) 中的 a 和 b, 以及图 4(b) 中的 c 和 d 所示)。在保持相同训练参数的条件下, 分别在 YOLOv8n 和 YOLO-FLCSW 模型中进行实验, 结果如表 4 所示。

表 4 LSK 模块不同位置对比表

Table 4 Comparison table of different positions of LSK module

Model	Position	$P_{\text{mAP}@0.5} / \%$	$P_{\text{mAP}@0.5:0.95} / \%$	$P / \%$	$R / \%$	Params / 10^6	FLOPs / 10^9	Model size / MB
YOLOv8n	a	33.5	19.2	44.3	33.6	2.71	7.4	5.7
	b	33.6	19.4	44.1	33.6	2.71	7.4	5.7
	c	34.4	19.8	46	34.7	3.06	8.5	6.3
	d	34	19.8	43.8	34	2.81	7.7	5.9
YOLO-FLCSW	a	40.1	24.0	49.3	39.2	1.78	16.4	4.0
	b	40.9	24.5	49.2	39.5	1.78	16.4	4.0
	c	41.1	24.6	51.7	39.7	2.12	17.5	4.5
	d	41.0	24.6	51.0	39.5	1.88	16.6	4.2

观察表 4 可以发现, 将 LSK 模块添加到 d 位置效果最为均衡。虽然添加到 a 和 b 位置能使模型得到明显的轻量化, 但在网络提取小目标特征时会牺牲部分信息, 导致模型的平均精度较低。将 LSK 模块添加到 c 位置时, 虽然模型的性能得到提升, 但模型的参数量、浮点运算数和模型大小显著增加, 导致计算复杂度提升。相比之下, 将 LSK 模块添加到 d 位置, 既能保持模型的轻量化, 又能兼顾模型的性能。综上所述, 最终

选择将 LSK 模块添加到 d 位置。

4.3 注意力机制对比实验

为验证 LSK 模块与 Faster Block 融合的有效性, 设计了对比实验。以 YOLOv8n 为基准架构, 分别将 C2f_FasterNet 与不同注意力机制 (SE、ECA、TA、LSK) 相结合, 评估各注意力机制对模型性能的影响。实验结果如表 5 所示, 为所提出方法的有效性提供了定量分析依据。

表 5 注意力机制对比实验

Table 5 Attention comparison experiments

Model	Attention mechanism	$P_{\text{mAP}@0.5} / \%$	$P_{\text{mAP}@0.5:0.95} / \%$	$P / \%$	$R / \%$	Params / 10^6	FLOPs / 10^9	Model size / MB
C2f_FasterNet	No	32.6	18.8	43.8	32.9	2.65	7.1	5.5
	+SE	32.6	18.8	42	33	2.66	7.1	5.5
	+ECA	33.0	18.9	43.9	32.8	2.65	7.1	5.5
	+TA	33.0	19.3	43.4	32.3	2.65	7.3	5.6
	+LSK	34.0	19.8	43.8	34	2.81	7.7	5.9
YOLOv8n	No	33.0	19.2	43.7	33.8	3.01	8.2	6.3
	+LSK	34.6	20.3	45.7	34.3	3.18	8.7	6.6

由表 5 结果可以看出, LSK 模块在 C2f_FasterNet 和 YOLOv8n 上分别使 $P_{\text{mAP}@0.5}$ 提升了 1.4 个百分点和 1.6 个百分点, 验证了选择性注意力机制的有效性。C2f_FasterNet+LSK 模块组合以 2.81×10^6 的参数量达到了 34.0% 的 $P_{\text{mAP}@0.5}$, 相比原 YOLOv8n 实现了轻量化与性能的双重优化。LSK 作为选择性注意力机制在小目标检测中表现优异, 其召回率显著提升, 有效减少了漏检问题, 为模块协同机制提供了实验支撑。

4.4 损失函数对比实验

为了验证 WIoUv3 损失函数的优越性, 在相同训练参数的条件下, 对常见损失函数进行了对比实验, 结果如表 6 所示。

结果显示, WIoUv3 损失函数在小目标检测上的效果更好。相较于原始的 CIoU, $P_{\text{mAP}@0.5}$ 、 $P_{\text{mAP}@0.5:0.95}$ 和 P 分别提升了 1.0 个百分点、0.6 个百分点和 2.7 个百分点。与其他损失函数相比, WIoUv3 的各项性能

表 6 不同损失函数对比实验

Table 6 Comparison experiments of different loss functions

Loss function	$P_{\text{mAP}0.5} / \%$	$P_{\text{mAP}0.5:0.95} / \%$	$P / \%$	$R / \%$	Params / 10^6	FLOPs / 10^9	Model size / MB
YOLOv8+CIoU	33	19.2	43.7	33.8	3.01	8.2	6.3
YOLOv8+EIoU ^[18]	33.6	19.8	45.1	33.6	3.01	8.2	6.3
YOLOv8+WIoUv1	33.5	19.5	45.8	32.8	3.01	8.2	6.3
YOLOv8+WIoUv3	34.0	19.8	46.4	33.5	3.01	8.2	6.3

指标均高于 EIoU 和 WIoUv1。综上所述, WIoUv3 能够动态优化损失函数并对小目标进行加权,从而更有效地提高模型在复杂小目标场景中的检测性能。

4.5 不同模型对比实验

为了进一步展现所提算法的优势,除 YOLOv8n 外,还选取了 YOLOv8s、YOLOv9t、YOLOv10n、YOLOv10s、YOLOv11n 和 YOLOv11s 等模型在 VisDrone2019 数据集上进行对比实验,相关结果如表 7 所示。

从表 7 结果来看,虽然 YOLOv8n、YOLOv9t、YOLOv10n 和 YOLOv11n 与所提模型属于同一量级,具有参数量少、部署速度快的优点,且 FPS 高于所提模型,但在特征表达方面存在欠缺,易出现误检和漏检问题,其性能显著低于所提模型。例如,相较于 YOLOv8n,所提模型在 $P_{\text{mAP}0.5}$ 、 $P_{\text{mAP}0.5:0.95}$ 、 P 和 R 上分别提升了 8.0 个百分点、5.4 个百分点、7.3 个百分点和 5.7 个百分点,同时参数量和模型大小分别减少了 37.5% 和 33.3%。

YOLOv8s 和 YOLOv11s 等模型的量级大于所提模型,其模型大小和复杂度大幅度增加,这可能导致这些模型难以在无人机嵌入式机载设备上平稳运行。此外,这些模型的性能均低于所提模型,且 FPS 也低于所提模型。例如,所提模型的 $P_{\text{mAP}0.5}$ 、 $P_{\text{mAP}0.5:0.95}$ 、 P 和 R 分别比 YOLOv8s 高 1.3 个百分点、0.8 个百分点、1.4 个百分点和 0.8 个百分点,并且所提模型的复杂度远低于 YOLOv8s,更易于在嵌入式平台部署。

与 PECS-YOLO 模型相比,所提模型的计算量虽然更大,但 $P_{\text{mAP}0.5}$ 、 $P_{\text{mAP}0.5:0.95}$ 、 P 和 R 分别高出 5.0 个百分点、2.4 个百分点、4.6 个百分点和 3.9 个百分点,且参数量比 PECS-YOLO 少 0.75×10^6 。

相较于 LEFE-YOLOv8 模型,所提检测框架在检测性能上呈现轻微劣势,但在模型复杂度方面实现了显著优化。MFFSODNet 设计了多尺度特征提取模块 (MSFEM),显著提升了模型的性能,但其较高的计算开销导致模型实时性不佳。

与基于 Transformer 的模型相比,RT-DETR 是在 DETR 基础上发展而来的端到端实时目标检测器,显

表 7 不同模型在 VisDrone2019 数据集上对比实验表

Table 7 Comparative experimental table of different models on the VisDrone 2019 dataset

Model	$P_{\text{mAP}0.5} / \%$	$P_{\text{mAP}0.5:0.95} / \%$	$P / \%$	$R / \%$	FLOPs / 10^9	Params / 10^6	Model size / MB	FPS / (frame·s ⁻¹)
YOLOv8n	33.0	19.2	43.7	33.8	8.2	3.01	6.3	145
YOLOv9t	33.0	19.3	43.8	33.1	6.4	1.73	4.2	100
YOLOv10n	33.1	19.2	43.4	33.1	8.4	2.69	5.8	135
YOLOv11n	33.9	19.7	44.2	34.2	6.3	2.58	5.5	141
YOLOv8s	39.7	23.8	50.3	38.7	28.6	11.13	22.5	112
YOLOv10s	39.2	23.7	49.6	37.8	24.5	8.04	16.5	109
YOLOv11s	39.5	23.7	52	37.7	21.3	9.41	19.2	106
LEFE-YOLOv8 ^[19]	42.3	25.2			21.9	8.77		
PECS-YOLO ^[20]	36.0	21.2	46.4	35.6	11.1	2.63	5.6	126
MFFSODNet ^[21]	46.3	26.9	55.8	44.3	55.8	4.54	9.8	82
RT-DETR-L	47.8	29.2	61.7	46.5	88.9	30.3	57.9	74
WDFS-DETR ^[22]	44.5	26.9	58	44.1	52.0	19.7	40.7	78
Deformable DETR	42.1	25.2			196.0	39.8		12
TAM-TR ^[23]	55.3	38.2	66.8	43.5	246.3	41.9	64.8	40
DEIM ^[24]	39.1	22.2			7.1	3.7	14.7	110
SSD	17.6	9.0	30.9	17.7	22.8	14.2	49.8	32
Faster-RCNN	21.6	9.8	35.5	31.4	134.2	41.7	108	21
RetinaNet	12.1	7.6	39.2	15.4	20.5	36.7	139	20
YOLO-FLCSW	41.0	24.6	51.0	39.5	16.6	1.88	4.2	116

传统的Faster-RCNN作为典型的双阶段算法,模型相对复杂且对小目标检测能力较弱。一阶段算法

图9展示了不同检测模型的计算复杂度与检测精度之间的权衡关系。图中红色虚线表示高性能阈值线($P_{\text{mAP}} \geq 40\%$),绿色虚线表示效率阈值线($\text{FLOPs} \leq 20 \times 10^9$)。从图9可以直观看出,YOLO-FLCSW模型位于双阈值线划定的最优性能区域内,同时满足了高精度($P_{\text{mAP}} \geq 40\%$)和高效率($\text{FLOPs} \leq 20 \times 10^9$)的要求。相较于其他检测模型,YOLO-FLCSW实现了精度和效率的平衡,在保证低计算开销的同时获得了更高的检测精度,验证了改进算法的有效性,为资源受限环境下的实时检测提供了优化的解决方案。



4.6 实验效果可视化分析

结果显示,在密集小目标分布场景(图 10(a))中,YOLOv8n 模型存在明显的漏检现象(如绿框所示),PECS-YOLO 模型在一定程度上改善了识别能力,但仍存在一定的漏检。相比之下,YOLO-FLCSW 模型显著降低了小目标的漏检率,基本实现了对绿框中所有车辆的识别,展现了对远距离密集分布小尺度目标更强的检出能力。

为了进一步探究本文的改进效果,采用梯度加权




图 10 检测效果对比图。(a)密集小目标分布场景;(b)复杂背景场景;(c)低光照分布小目标场景

Fig. 10 Comparison of detection effects. (a) Dense small target distribution scene; (b) complex background scene; (c) low-light distribution small target scene

类激活映射(Grad-CAM^[25])技术对YOLOv8n的P3检测头与YOLO-FLCSW的P2检测头进行了可视化分析。Grad-CAM通过热力图显示网络关注的区域,有助于理解模型的决策过程。在生成的热力图中,颜色深度反映了模型对相应区域的关注程度:冷色调区域(蓝色)表示较低的激活响应,对应模型关注度较弱的背景区域;暖色调区域(红色)则表示较高的激活响应,对应模型高度关注的目标特征区域。可视化结果如图11所示,从左至右依次为原始图像、YOLOv8n的P3检测头和YOLO-FLCSW的P2检测头的特征激活热力图。其中:图11(a)展示复杂背景下密集车辆与人群的

混合场景;图11(b)为高密度车辆场景;图11(c)为密集人群场景。

在图11(a)中,YOLOv8n的P3检测头更多关注于近距离中等尺度车辆,对远距离车辆及行人的小目标特征表征能力不足,漏检率较高。而YOLO-FLCSW的P2检测头在小目标特征提取方面展现出更强的敏感性,对行人和远距离车辆的激活响应更为充分,有效降低了小目标的漏检率。

在图11(b)中,YOLOv8n的P3检测头对小尺度汽车的关注呈现广泛扩散的特征,且容易受复杂环境干扰。YOLO-FLCSW的P2检测头则表现出更精确




图 11 热力图对比图。(a)复杂背景下密集车辆与人群混合场景;(b)高密度车辆场景;(c)密集人群场景

Fig. 11 Heat map comparison diagrams. (a) Mixed scene of dense vehicles and crowds under complex background; (b) high-density vehicle scene; (c) dense crowd scene

的车辆边界定位和更集中的目标关注能力,提升了模型在复杂背景下的目标区分能力。

在图 11(c)中,YOLOv8n 的 P3 检测头关注的行人数量较多但相对分散,边界定位精度有限。而 YOLO-FLCSW 的 P2 检测头对行人的关注更加集中,激活区域边界更加清晰,有效改善了密集目标场景下的检测性能。

综上所述,YOLO-FLCSW 模型在小目标检测能力、注意力集中度,以及抗复杂背景干扰性能等关键指标上均显著优于基线 YOLOv8n 模型。

表 8 自制数据集对比实验

Table 8 Self-made dataset comparison experiment

Model	$P_{AP} / \%$				$P_{mAP0.5} / \%$	Params / 10^6	Model size / MB
	white solid line	yellow dotted line	white dotted line	yellow solid line			
YOLOv8n	99.3	96.1	91.1	96.1	95.6	3.01	6.3
YOLO-FLCSW	99.3	97.9	93.3	98.9	97.3	1.88	4.2

为了更直观地验证模型的性能,选取了一张复杂背景下的低照度小尺度图片(使用 M300RTK 无人机和禅思云台相机 P1 在碧弘峰拍摄)进行推理测试,结果如图 12 所示。对比两种目标检测模型的表现可以

4.7 泛化性实验

在自建的公路智能巡检数据集上进行了实验分析,最终训练结果如表 8 所示。根据表 8 结果,与基线模型相比,YOLO-FLCSW 模型在 $P_{mAP@0.5}$ 指标上实现了 1.7 个百分点的提升。具体来看,黄虚线的平均精度(P_{AP})提高了 1.8 个百分点,白虚线的 P_{AP} 增加了 2.2 个百分点,黄实线的 P_{AP} 增加了 2.7 个百分点,白实线的 P_{AP} 保持不变。这表明所提模型更容易提取小目标特征,同时显著降低了参数量和模型大小,验证了其在自制数据集上具有良好的泛化能力。

看出,YOLOv8n 模型在检测树影下的黄色虚线时发生了漏检,而 YOLO-FLCSW 模型则成功实现了识别。这表明 YOLO-FLCSW 模型的抗背景干扰能力强于 YOLOv8n。




图 12 推理路标对比图。(a) YOLOv8n 推理结果;(b) YOLO-FLCSW 推理结果

Fig. 12 Inference landmark comparison diagram. (a) YOLOv8n inference result; (b) YOLO-FLCSW inference result

4.8 模型部署实验

为客观评估所提算法在无人机嵌入式平台的实际部署效能,实验基于 NVIDIA Jetson Xavier NX 平台,并采用 VisDrone2019 验证集进行基准测试。对比指标包括 $P_{mAP@0.5}$ 、 $P_{mAP@0.5; 0.95}$ 、 P 、 R 、推理时间、FPS 和 GPU 显存占用,同时评估了 TensorRT 精度校准策略

对模型推理性能的优化效果。测试环境配置如下:批处理大小为 1,输入图像尺寸为 640×640 。具体对比结果如表 9 所示。

根据表 9 结果,在时间复杂度方面,改进算法(YOLO-FLCSW)在未优化状态下的推理时间为 60.2 ms,相较于 YOLOv8n 增加了 39.4%,这主要归因

表 9 NVIDIA Jetson Xavier NX 平台实验结果

Table 9 NVIDIA Jetson Xavier NX platform experimental results

Model	Precision calibration	$P_{mAP0.5} / \%$	$P_{mAP0.5; 0.95} / \%$	$P / \%$	$R / \%$	Model size / MB	Inference / ms	FPS / ($\text{frame} \cdot \text{s}^{-1}$)	GPU
YOLOv8n	No	33.4	19.3	44.2	34.4	6.3	43.2	23.1	1.1 GB
	FP32	33.5	19.3	44.3	34.1	18.1	27.1	35.1	930 MB
	FP16	33.5	19.3	44.3	34.2	7.8	22.3	40.2	773 MB
YOLO-FLCSW	No	42.1	24.7	51.5	40.7	4.2	60.2	17.3	1.1 GB
	FP32	41.9	24.6	51.0	40.8	11.2	39.4	23.8	1010 MB
	FP16	41.9	24.5	51.1	40.7	6.1	24.5	33.2	986 MB

于 YOLO-FLCSW 模块的特征增强计算。通过 TensorRT 优化,在 FP16 精度模式下,推理时间优化至 24.5 ms,在精度基本无损的情况下获得了 2.46 倍的加速,证明了算法对硬件加速具有良好的适配性。

在空间复杂度方面,FP16 配置下 YOLO-FLCSW 的模型大小为 6.1 MB,GPU 显存占用为 986 MB(平台总显存为 6854 MB),资源利用率仅为 14.4%,为系统并发处理预留了充分的余量。

性能评估显示,改进算法在 FP16 优化后能达到 33.2 frame/s,满足实时检测要求,且其检测性能相较于 YOLOv8n 有显著提升。综合分析表明,YOLO-FLCSW 在 640×640 输入、FP16 精度配置下实现了计算效率与检测精度的最优权衡,验证了改进算法在无人机嵌入式平台部署的有效性。

5 结 论

针对无人机智能巡检中小目标占比高、背景干扰强及硬件资源受限等挑战,提出一种基于 YOLOv8n 改进的轻量化模型——YOLO-FLCSW。采用 FasterNet 主干与 LSK 注意力机制构建了 C2f_FLK 模块,以动态调整感受野来增强小目标的表达能力;提出 UAV-CCFM 跨尺度特征融合模块,通过高效整合多尺度信息并控制参数量;利用 SPPELAN 结构优化了金字塔特征表示,提升了模型的多尺度适应性。在损失函数方面,结合 WIoUv3 以抑制低质量锚框的影响,从而提升检测精度。实验表明,YOLO-FLCSW 在 VisDrone2019 数据集上的 $P_{mAP@0.5}$ 、 $P_{mAP@0.5:0.95}$ 、 P 、 R 等指标均优于原模型,同时参数量与模型体积显著降低,并成功实现了在 NVIDIA Jetson Xavier NX 平台上的网络量化与嵌入式部署,具备了实时性和高准确率。为进一步增强小目标检测能力,引入了 P2 检测头以提升多尺度感知,但这使得 FLOPs 增至 16.6×10^9 。尽管如此,对于极小目标的检测,所提模型仍存在漏检及鲁棒性不足的问题。未来工作将聚焦于轻量化与特征增强的协同优化,以推动模型在无人机巡检中的实际工程应用。

参 考 文 献

- [1] Liu Z, Hu X N, Li J Q, et al. Graph relation network for person counting in construction site using UAV[J]. Applied Soft Computing, 2021, 110: 107562.
- [2] Wang K, Wu Q Q, He X T, et al. Optimizing UAV traffic monitoring routes during rush hours considering spatiotemporal variation of monitoring demand[J]. International Journal of Geographical Information Science, 2022, 36 (10): 2086-2111.
- [3] 罗潇, 於锋, 彭勇. 基于深度学习的无人机电网巡检缺陷检测研究[J]. 电力系统保护与控制, 2022, 50(10): 132-139.
Luo X, Yu F, Peng Y. UAV power grid inspection defect detection based on deep learning[J]. Power System Protection and Control, 2022, 50(10): 132-139.
- [4] Redmon J, Divvala S, Girshick R, et al. You only look once: unified, real-time object detection[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), June 27-30, 2016, Las Vegas, NV, USA. New York: IEEE Press, 2016: 779-788.
- [5] Wang G, Chen Y F, An P, et al. UAV-YOLOv8: a small-object-detection model based on improved YOLOv8 for UAV aerial photography scenarios[J]. Sensors, 2023, 23(16): 7190.
- [6] Yue M, Zhang L Q, Huang J, et al. Lightweight and efficient tiny-object detection based on improved YOLOv8n for UAV aerial images[J]. Drones, 2024, 8(7): 276.
- [7] Wang X, He N, Hong C, et al. Improved YOLOX-X based UAV aerial photography object detection algorithm [J]. Image and Vision Computing, 2023, 135: 104697.
- [8] Li Y G, Li Q, Pan J, et al. SOD-YOLO: small-object-detection algorithm based on improved YOLOv8 for UAV images[J]. Remote Sensing, 2024, 16(16): 3057.
- [9] Zhang H, Sun W, Sun C H, et al. HSP-YOLOv8: UAV aerial photography small target detection algorithm [J]. Drones, 2024, 8(9): 453.
- [10] Chen J R, Kao S H, He H, et al. Run, don't walk: chasing higher FLOPS for faster neural networks[C]//2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), June 17-24, 2023, Vancouver, BC, Canada. New York: IEEE Press, 2023: 12021-12031.
- [11] Li Y X, Hou Q B, Zheng Z H, et al. Large selective kernel network for remote sensing object detection[C]//2023 IEEE/CVF International Conference on Computer Vision (ICCV), October 1-6, 2023, Paris, France. New York: IEEE Press, 2024: 16748-16759.
- [12] Zhao Y A, Lv W Y, Xu S L, et al. DETRs beat YOLOs on real-time object detection[C]//2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), June 16-22, 2024, Seattle, WA, USA. New York: IEEE Press, 2024: 16965-16974.
- [13] Wang C Y, Yeh I H, Liao H Y M. YOLOv9: learning what you want to learn using programmable gradient information[M]//Leonardis A, Ricci E, Roth S, et al. Computer vision-ECCV 2024. Lecture notes in computer science. Cham: Springer, 2025, 15089: 1-21.
- [14] Wang C Y, Bochkovskiy A, Liao H M. YOLOv7: trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]//2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), June 17-24, 2023, Vancouver, BC, Canada. New York: IEEE Press, 2023: 7464-7475.
- [15] Zheng Z H, Wang P, Ren D W, et al. Enhancing geometric factors in model learning and inference for object detection and instance segmentation[J]. IEEE Transactions on Cybernetics, 2022, 52(8): 8574-8586. [PubMed]
- [16] Tong Z J, Chen Y H, Xu Z W, et al. Wise-IoU: bounding box regression loss with dynamic focusing mechanism[EB/OL]. (2023-01-24)[2025-10-12]. <https://arxiv.org/abs/2301.10051>.

- [17] Du D W, Zhu P F, Wen L Y, et al. VisDrone-DET2019: the vision meets drone object detection in image challenge results[C]//2019 IEEE/CVF International Conference on Computer Vision Workshop (ICCVW), October 27-28, 2019, Seoul, Republic of Korea. New York: IEEE Press, 2019: 213-226.
- [18] Zhang Y F, Ren W Q, Zhang Z, et al. Focal and efficient IOU loss for accurate bounding box regression [J]. *Neurocomputing*, 2022, 506: 146-157.
- [19] 赵向阳, 史再峰, 王云峰, 等. 高精度轻量级的无人机航摄图像目标检测模型研究[J]. *激光与光电子学进展*, 2024, 61(24): 2437010.
Zhao X Y, Shi Z F, Wang Y F, et al. High-precision and lightweight object detection model for drone aerial photography images[J]. *Laser & Optoelectronics Progress*, 2024, 61(24): 2437010.
- [20] 王舒梦, 徐慧英, 朱信忠, 等. 基于改进YOLOv8n的航拍轻量化小目标检测算法: PECS-YOLO[J]. *计算机工程*, 2025, 51(9): 280-293.
Wang S M, Xu H Y, Zhu X Z, et al. Lightweight small object detection algorithm for aerial photography based on improved YOLOv8n: PECS-YOLO[J]. *Computer Engineering*, 2025, 51(9): 280-293.
- [21] Jiang L J, Yuan B X, Du J W, et al. MFFSODNet: multiscale feature fusion small object detection network for UAV aerial images[J]. *IEEE Transactions on Instrumentation and Measurement*, 2024, 73: 5015214.
- [22] Liu J J, Xie Y H. WDFS-DETR: a Transformer-based framework with multi-scale attention for small object detection in UAV Engineering Tasks[J]. *Results in Engineering*, 2025, 27: 105930.
- [23] Xu J H, Fan X T, Jian H D, et al. TAM-TR: Text-guided attention multi-modal transformer for object detection in UAV images[J]. *ISPRS Journal of Photogrammetry and Remote Sensing*, 2025, 227: 170-184.
- [24] Huang S H, Lu Z C, Cun X D, et al. DEIM: DETR with improved matching for fast convergence[C]//2025 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), June 10-17, 2025, Nashville, TN, USA. New York: IEEE Press, 2025: 15162-15171.
- [25] Selvaraju R R, Cogswell M, Das A, et al. Grad-CAM: visual explanations from deep networks via gradient-based localization[J]. *International Journal of Computer Vision*, 2020, 128(2): 336-359.

YOLO-FLCSW: A Small Target Detection Algorithm for UAV Inspection

Song Lili^{1,2}, Xu Zihan^{1,2}, Han Jianfeng^{1,2*}, Fang Jiandong^{1,2}, Nan Rujun^{1,2}, Li Li^{1,2}

¹*School of Information Engineering, Inner Mongolia University of Technology, Hohhot 010080, Inner Mongolia, China;*

²*Inner Mongolia Autonomous Region Key Laboratory of Intelligent Perception and System Engineering, Hohhot 010080, Inner Mongolia, China*

Abstract

Objective Accurate identification and localization of small targets in drone aerial imagery is crucial for highway inspection. However, small targets are characterized by their limited size, irregular shapes, complex backgrounds, and significant lighting variations, which often challenge conventional detection methods. Therefore, in-depth research into small-target detection is urgently needed. This study not only aims to enhance the accuracy and efficiency of drone image analysis but also strives to provide more reliable data support for decision-making across various domains, thereby holding significant theoretical and practical value.

Methods To address the specific challenges of small-target detection from a drone's perspective, this paper proposes a lightweight detection algorithm named YOLO-FLCSW. Building upon YOLOv8, the algorithm incorporates integrated improvements across four key areas. 1) A feature enhancement layer: the C2f_FLK module is designed to enhance feature representation for small targets with sparse features. 2) A multi-scale fusion layer: the UAV-CCFM module strengthens cross-scale feature fusion to handle coexisting multi-scale targets. 3) A context enhancement layer: the SPPELAN module extends the spatial perception range to capture richer contextual information for small targets. 4) loss function optimization: the WIoUv3 loss function is adopted to improve bounding box regression accuracy and suppress interference from low-quality samples.

Results and Discussions Comprehensive experiments were conducted on the VisDrone2019 dataset. Ablation studies confirmed the effectiveness of each proposed module. Comparative experiments with various attention mechanisms and loss functions demonstrated the superiority of the LSK module and WIoUv3. Furthermore, comparisons with state-of-the-art models, including YOLO series variants and Transformer-based detectors, showed that YOLO-FLCSW achieves a superior balance between detection accuracy and computational efficiency. Additional experiments on a custom highway inspection dataset validated the model's strong generalization capability. Deployment tests on an NVIDIA Jetson Xavier NX embedded platform confirmed that the optimized model maintains real-time performance while achieving higher accuracy.

Conclusions To tackle the challenges of high small-target ratios, complex background interference, and limited hardware resources in drone-based inspection, this paper proposes YOLO-FLCSW, a lightweight improved model based on YOLOv8n. The model

employs a FasterNet backbone integrated with an LSK attention mechanism to form the C2f_FLK module, dynamically adjusting the receptive field. The UAV-CCFM module facilitates efficient multi-scale feature fusion with controlled parameters. The SPPELAN structure enhances multi-scale adaptability, and the WIoUv3 loss function improves detection accuracy. Experiments demonstrate that YOLO-FLCSW outperforms the baseline in terms of $P_{mAP@0.5}$, $P_{mAP@0.5:0.95}$, precision, and recall, while significantly reducing parameters and model size. Successful deployment and quantization on the NVIDIA Jetson Xavier NX platform verify its practicality for real-time, accurate embedded drone inspection.

Key words UAV; small target detection; lightweight; YOLOv8n; NVIDIA Jetson Xavier NX