



计算机工程与应用
Computer Engineering and Applications
ISSN 1002-8331,CN 11-2127/TP

《计算机工程与应用》网络首发论文

题目：基于 DSDN-YOLO 的 PCB 表面缺陷检测算法
作者：杜利明，胡景旺，王凤英，张明亮，李君科
网络首发日期：2026-07-03
引用格式：杜利明，胡景旺，王凤英，张明亮，李君科. 基于 DSDN-YOLO 的 PCB 表面缺陷检测算法[J/OL]. 计算机工程与应用.
<https://link.cnki.net/urlid/11.2127.tp.20260702.1916.008>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于 DSDN-YOLO 的 PCB 表面缺陷检测算法

杜利明^{1,2}, 胡景旺¹⁺, 王凤英², 张明亮¹, 李君科²

1.沈阳建筑大学 计算机科学与工程学院, 沈阳 110168

2.宿迁学院 信息工程学院, 江苏 宿迁 223800

+ 通信作者 E-mail: 1905736667@qq.com

摘要: 针对印刷电路板 (Printed Circuit Board, PCB) 表面缺陷检测中微小目标特征弱、背景纹理干扰强、边界定位易波动等问题, 提出一种改进 YOLOv11n 的轻量化缺陷检测模型 DSDN-YOLO。提出可变形注意力动态卷积模块 (Deformable-Attentive Dynamic Convolution, DADC), 融合可变形注意力的自适应空间采样与动态卷积的多专家加权机制, 用于重构 C3k2 单元, 强化对缺陷形态与位置变化的特征表征。引入空间-通道全局自注意力聚合模块 (Spatial-Channel Global Self-attention Fusion Module, SCGSFM) 并创新性地前置部署于多尺度融合通路的源头节点, 对最高语义特征实施跨层融合前的协同重标定, 提供高判别性的语义先验。设计动态结构感知邻域插值 (Dynamic Structure-Aware Neighborhood Interpolation, DNI) 替代最近邻上采样, 通过邻域几何感知动态生成插值权重, 缓解边界锯齿与特征混叠, 提升细长缺陷的定位稳定性。构建尺寸感知回归损失 (Size-Aware Loss, SA-Loss), 依据目标尺寸自适应调节回归梯度, 强化小目标的学习贡献。实验结果表明, 模型在 PKU-Market-PCB 增强数据集上的 mAP@0.5 和 mAP@0.5:0.95 分别达到 95.4% 和 53.4%, 较基准模型提升 2.7% 和 5.1%, 召回率提升 6.5%; 在 DeepPCB 数据集上亦验证其良好的泛化能力。该方法在保持轻量化的同时有效提升检测精度, 可为 PCB 产线实时自动质检提供可靠方案。

关键词: PCB 缺陷检测; YOLOv11; DADC; SCGSFM;

文献标志码:A 中图分类号: TP391.4 doi: 10.3778/j.issn.1002-8331.2603-0257

PCB Surface Defect Detection Algorithm Based on DSDN-YOLO

DU Liming^{1,2}, HU Jingwang¹⁺, WANG Fengying², ZHANG Mingliang¹, LI Junke²

1. School of Computer Science and Engineering, Shenyang Jianzhu University, Shenyang 110168, China

2. School of Information Engineering, Suqian University, Suqian, Jiangsu 223800, China

Abstract: To address the challenges in Printed Circuit Board (PCB) surface defect detection, such as weak features of small targets, strong background texture interference, and unstable boundary localization, this paper proposes an improved YOLOv11n defect detection model, DSDN-YOLO. A Deformable-Attentive Dynamic Convolution (DADC) module is proposed to reconstruct the C3k2 unit by fusing the adaptive spatial sampling of deformable attention with the multi-expert weighting mechanism of dynamic convolution, thereby enhancing the feature representation for defect morphology and position variations. The Spatial-Channel Global Self-attention Fusion Module

基金项目: 国家自然科学基金(62262055); 江苏省产学研合作项目(BY20251032、BY20251033); 宿迁市科技计划指导性项目(Z2025040); 宿迁学院人才引进科研启动基金项目(校 2022XRC091); 宿迁学院联培研究生创新基金(2024LPCX03、2024LPCX05)。

作者简介: 杜利明(1976—), 男, 博士, 副教授, CCF 会员, 研究方向为机器视觉、智能软件测试; 胡景旺(2001—), 男, 硕士研究生, 研究方向为深度学习、工业缺陷检测等; 王凤英(1976—), 女, 硕士, 副教授, CCF 会员, 研究方向为深度学习、智能软件测试等; 张明亮(2000—), 男, 硕士研究生, CCF 会员, 研究方向为深度学习、工业缺陷检测等; 李君科(1986—), 男, 博士, 教授, CCF 会员, 研究方向为绿色计算、高性能计算等。

(SCGSFM) is introduced and innovatively deployed at the head of the multi-scale fusion pathway to perform collaborative recalibration on the highest-level semantic features before they enter cross-scale fusion, providing highly discriminative semantic priors. A Dynamic Structure-Aware Neighborhood Interpolation (DNI) module is designed to replace nearest-neighbor upsampling. It mitigates boundary aliasing and feature distortion by dynamically generating interpolation weights through neighborhood geometry perception, improving the localization stability of elongated defects. Furthermore, a Size-Aware Loss (SA-Loss) is constructed, which adaptively adjusts regression gradients according to the target size to enhance the learning contribution of small targets. Experimental results show that the proposed model achieves 95.4% and 53.4% on mAP@0.5 and mAP@0.5:0.95, respectively, on the enhanced PKU-Market-PCB dataset, representing improvements of 2.7% and 5.1% over the baseline model, with a 6.5% increase in recall. Its excellent generalization ability is also verified on the DeepPCB dataset. The proposed method effectively improves detection accuracy while maintaining a lightweight design, providing a reliable solution for real-time automated quality inspection on PCB production lines.

Key words: PCB defect detection; YOLOv11; deformable-attentive dynamic convolution; spatial-channel global self-attention fusion module

印刷电路板 (Printed Circuit Board, PCB) 作为电子元器件互连的核心载体, 其制造质量直接决定了现代电子系统的可靠性与稳定性^[1]。然而, 在蚀刻、显影及层压等复杂的制造工艺中, 受环境微尘及工艺非线性影响, PCB 表面极易产生短路、开路、鼠咬、余铜等微小缺陷。随着电子产品向高密度化与微型化发展, 线宽与线距持续缩小至微米级别, 传统的人工目视检测方法受主观疲劳与效率限制, 已难以满足高精度与高复杂度的在线检测需求^[2]。因此, 研发兼具检测与推理的自动化检测算法, 已成为提升 PCB 产线良率与智能化水平的迫切任务。

在实际工业场景中, PCB 表面缺陷检测仍面临多重挑战: 其一, 缺陷多呈小尺度、细长或不规则形态, 有效像素占比低且对比度不足, 特征响应弱, 定位易波动; 其二, 基板走线、焊盘与丝印等强纹理结构带来高频背景干扰, 缺陷与背景易发生混叠, 从而诱发误检; 其三, 部分缺陷与正常结构边缘在局部外观上相近, 对模型的细粒度判别与上下文建模提出更高要求; 其四, 在边缘侧算力受限条件下, 需要在保证帧率的同时维持稳定的漏检与误报控制能力。

近年来, 基于深度学习的目标检测算法凭借较强的特征表征与泛化能力, 已成为工业质检领域的重要技术路线^[3]。现有方法大体分为两类: 以 Faster R-CNN^[4]为代表的二阶段检测方法通常具有较高精度, 例如耿朝晖等^[5]针对 PCB 样本不均衡问题, 结合 ResNet50 主干、特征金字塔 (Feature Pyramid Network,

FPN) 与 Focal Loss 改善分类学习, 从而提升微小缺陷的检出能力; 但其候选区域生成与逐级回归过程带来较高推理开销, 难以满足产线实时性要求。相比之下, 以 YOLO (You Only Look Once) 系列为代表的单阶段检测采用端到端回归范式, 在速度与精度之间具有更优的综合权衡, 更适合工业在线部署。

围绕 PCB 场景的小目标与复杂纹理干扰, 研究者对 YOLO 框架进行了持续改进: 吕秀丽等^[6]在 YOLOv8 主干中引入多尺度混合卷积 (multi-scale mixed convolution, MSMC), 并改进 BiFPN (Bidirectional Feature Pyramid Network) 融合策略以强化多尺度语义交互, 从而提升细微缺陷表征; Zhang 等^[7]通过鲁棒特征下采样 (Robust Feature Downsampling, RFD) 与动态上采样器 (Dynamic Upsampler, DySample) 重构特征金字塔, 缓解特征传递过程中的细节模糊并改善复杂纹理背景下的检测完整性。随着 YOLOv11 的提出, 相关研究进一步聚焦于高效特征聚合与回归优化: Zhao 等^[8]结合双向特征金字塔与 WIoU (Wise Intersection over Union) 动态聚焦损失, 改善回归学习的关注分配; 黄文杰等^[9]利用部分卷积 (Partial Convolution, PConv) 策略重构骨干网络的核心残差单元以提升特征提取效率, 并集成轻量化共享检测头 (Lightweight Shared Convolutional Detection, LSCD) 实现回归参数的深度解耦与冗余压缩, 在降低计算开销的同时保持了检测精度。

然而, 尽管上述基于 YOLO 架构的改进在检测性

能与效率权衡方面取得进展,但在实际 PCB 产线场景中仍存在不足:一方面,现有特征聚合与注意增强机制在强化缺陷响应的同时,往往难以有效抑制走线、焊盘等高频纹理带来的干扰,导致非结构化微小缺陷的判别特征易被背景响应稀释,误检风险增加;另一方面,部分方法对解码端的空间结构保真与小目标回归不平衡问题关注不足,使细长缺陷在上采样重建过程中易出现边界模糊或几何失真,同时小尺寸目标因梯度贡献偏弱而影响定位优化效果。针对上述问题,本文提出一种改进 YOLOv11n 的 PCB 表面缺陷检测方法 DSDN-YOLO。主要贡献如下:

(1) 针对骨干网络中固定采样方式对微小缺陷与形变缺陷建模不足、特征响应较弱且定位易波动的问题,提出可变形注意力动态卷积模块(Deformable-Attentive Dynamic Convolution, DADC),并用于重构 C3k2 单元。该模块将可变形注意力的自适应空间采样与动态卷积的专家核特征聚合深度耦合,实现对非规则边缘的精准贴合与细粒度缺陷表征增强,从而提升网络对微小目标及几何形变的感知能力。

(2) 针对颈部网络多尺度融合过程中跨层特征对齐不足以及高频走线等规律性背景易导致缺陷语义稀释的问题,引入空间-通道全局自注意力聚合模块(Spatial-Channel Global Self-attention Fusion Module, SCGSFM)。该模块通过跨维度的特征耦合机制,将空间局部异常捕获与通道语义特异性筛选深度协同,在引导跨层特征精准对齐的同时,实现高频规律背景噪声的有效剥离与缺陷敏感语义的自适应增强,从而显著提升复杂场景下融合特征的纯度与可分性。

(3) 针对传统最近邻上采样易导致细长缺陷边界锯齿化、细节失真及结构一致性退化的问题,设计动态结构感知插值策略(Dynamic Structure-Aware Neighborhood Interpolation, DNI)。该策略依托局部邻域几何特征的自适应感知与插值权重的动态生成,实现缺陷边界的亚像素级平滑重构,显著增强上采样过程的拓扑保真度,从而优化细长缺陷的边缘表达并提升定位精度。

(4) 针对回归优化过程中目标尺度不平衡造成的小目标样本梯度贡献不足问题,构建尺寸感知损失(Size-Aware Loss, SA-Loss)。该损失通过引入尺度自适应调节因子对回归梯度流进行动态重加权,在保

障全局寻优过程平滑稳定的同时,定向强化小目标样本的回归学习,从而显著提升微小缺陷的边界定位精度与模型收敛质量。

1 基线模型与问题分析

YOLOv11n 是 Ultralytics 团队在 YOLOv8^[10]基础上提出的轻量化单阶段目标检测模型,延续 CSPNet 的部分连接思想,并对特征提取与多尺度融合结构进行优化。其网络由骨干(Backbone)、颈部(Neck)与检测头(Head)组成^[11]:骨干以 C3k2 模块替代 C2f,并通过可配置卷积核实现 1×1 与 3×3 卷积协同以降低冗余,同时在 SPPF 后引入 C2PSA 强化关键区域表征;颈部沿用 PANet 进行跨尺度双向融合,输出 P3、P4、P5 三层特征图以适应不同尺寸目标的检测需求;检测头采用 Anchor-Free 解耦设计并结合深度可分离卷积,实现参数与计算开销可控下的高效推理与定位。

尽管 YOLOv11n 在通用目标检测中性能优异,但在面对 PCB 强纹理背景与微小形变缺陷并存的复杂工业场景时,仍暴露出显著局限:在特征提取层面,骨干网络对非结构化缺陷的几何感知受限。其标准卷积的固定感受野在提取鼠咬、毛刺等形态多变缺陷时,易丢失边缘高频细节,难以实现精确的空间形态对齐。在跨尺度融合阶段,颈部网络在复杂背景下的特征聚焦能力较弱。面对 PCB 中密集的走线与焊盘噪声,现有的跨尺度拼接缺乏空间与通道的深度协同建模,高频背景易形成主导性激活,导致微弱缺陷语义在融合中被稀释与混淆。在细节重构环节,传统上采样机制易导致边界失真与结构伪影。最近邻插值未显式建模局部语义连续性,极易引发特征混叠与边缘锯齿,削弱开路、短路等细长缺陷的边界定位精度。而在模型优化端,微小目标的回归学习易陷入梯度瓶颈。在缺陷尺度极端失衡时,常规回归损失未能赋予微小样本动态优化偏置,其微弱的回归梯度易被中大型目标损失淹没,导致模型收敛于次优拟合状态。

2 DSDN-YOLO 模型设计

基于前述对基线模型局限性的剖析,本文在 YOLOv11n 的基础上构建 DSDN-YOLO 总体框架,如图 1 所示。




图1 DSDN-YOLO 网络结构

Fig.1 DSDN-YOLO network structure

模型围绕特征提取重构、多尺度融合增强、细节恢复优化、回归目标优化四个关键环节进行改进：首先，在骨干网络中重构 C3k2 单元形成 C3k2_DADC，以提升微小、形变及非结构化缺陷的特征表征能力；其次，在颈部融合路径中引入 SCGSFM，以增强缺陷相关响应并抑制强纹理干扰；然后，在上采样阶段引入 DNI 策略，以提升特征重建的结构保真度与边界稳定性；最后，在回归优化中采用 SA-Loss，以强化小目标样本的回归贡献并提升定位精度。

2.1 可变形注意力增强的 C3k2 重构

PCB 表面缺陷不仅表现出显著的形态多样性与非

结构化特征，鼠咬等微小缺陷呈现出不规则的几何突变，更存在极大的目标尺寸跨度，大面积的余铜与极微小的毛刺往往并存。基线 YOLOv11n 的 C3k2 主要依赖固定网格采样与相对刚性的感受野形态进行特征聚合，当缺陷呈现非结构化边界突变、局部形变以及剧烈的尺度变化时，采样点难以对齐关键轮廓，导致高频细节在层间传递中被稀释并伴随冗余纹理响应。针对上述问题，本文提出可变形注意力动态卷积（Deformable-Attentive Dynamic Convolution, DADC）以突破传统静态卷积在空间自适应感知上的刚性局限。重构后的 C3k2_DADC 模块及其核心 DADC 算子结构如图 2 所示。




图2 C3k2_DADC模块与DADC算子结构: (a) C3k2_DADC; (b) DADC

Fig.2 Structure of the C3k2_DADC module and the DADC operator: (a) C3k2_DADC (b) DADC

具体而言,如图2(a)所示,在保留C3k2原有CSP分流框架与信息流路径不变的前提下,本文对主分支表征单元进行结构级重构:将原Bottleneck替换为本文提出的DADC单元,使主分支由固定卷积堆叠转变为具备动态采样与自适应聚合能力的表征路径,从而构建C3k2_DADC模块,并提升骨干网络对非结构化缺陷的建模能力与定位稳定性。图2(b)展示了DADC

单元的内部计算流程。该单元以动态卷积^[12](Dynamic Convolution, DyConv)为基础完成动态核组合,其结构如图3所示;然后在权重生成与特征聚合过程中耦合可变形注意力机制(Deformable Attention, Def-Attn),提供可学习的空间对齐约束与关键区域的定向聚合能力,从而在复杂纹理背景下强化缺陷区域响应并抑制冗余纹理干扰。




图3 DyConv模块

Fig.3 DyConv module

其中,DyConv旨在通过引入多专家网络动态调整卷积权重,以增强模型对复杂特征的表达能。对于输入特征 x ,该模块首先利用路由机制预测出 k 个专家核(Expert Kernels, W_k)的归一化聚合权重 α_k ,并将其线性加权组合以生成动态卷积核 W_{dyn} ;随后,利用该动态核对输入特征执行卷积提取。其核心计算过程可由公式(1)与公式(2)所示:

$$W_{dyn} = \sum_{k=1}^K \alpha_k(x) \cdot W_k \quad (1)$$

$$Y = \text{Conv}(x, W_{dyn}) \quad (2)$$

尽管DyConv通过多专家核增强了特征表达,但其权重生成高度依赖全局平均池化,对局部微小目标缺乏显式感知。在PCB检测的目标与背景强失衡场景下,基于空间均值的汇聚易使权重估计偏向大面积基

板纹理响应,导致鼠咬等微小缺陷的高频细节被稀释,从而削弱动态权重对缺陷区域的有效调制。此外,DyConv 缺少显式的空间几何对齐机制,难以精确贴合非结构化缺陷的不规则边缘。

针对上述局限,本文引入 Def-Attn 作为特征的全局空间校准环节,并将其置于 DyConv 的全局平均池

化之前。不同于常规的固定网格采样,Def-Attn 通过可学习的空间采样偏移与注意力权重自适应调整聚合位置,使特征聚合位置能够自适应对齐缺陷边缘等判别区域,从而减弱背景纹理对权重估计的主导地位。其结构原理如图 4 所示。




图 4 Def-Attn 模块
Fig.4 Def-Attn module

设输入特征值为 $x \in \mathbb{R}^{C \times H \times W}$, 对于查询位置 q 对应的查询特征向量 z_q , Def-Attn 通过两条并行的线性映射分支分别预测空间采样偏移与注意力权重。其中, **Offset Linear** 分支输出第 m 个注意力头在第 k 个采样点处的二维空间偏移量 Δp_{mqk} , **Weight Linear** 分支生成对应的注意力权重 A_{mqk} , 并通过 Softmax 函数进行归一化, 以保证同一注意力头内各采样点权重之和为 1。

在此基础上, 以查询位置的参考点 p_q 为中心, 结合预测偏移得到最终的特征采样位置 $p_q + \Delta p_{mqk}$ 。随后, 在值特征图上采用双线性插值方式提取对应位置的特征响应, 并依据注意力权重 A_{mqk} 对各采样点特征进行加权聚合, 从而得到第 m 个注意力头的输出, 并将各头输出经线性映射后融合, Def-Attn 的整体输出可表示为式 (3), M 与 K 分别表示注意力头数与采样点数, W_m 与 W'_m 为可学习的线性变换矩阵。为兼顾模型性能与计算效率, 本文设定 $M=4$, $K=4$ 。

$$y_q = \sum_{m=1}^M W_m \left[\sum_{k=1}^K A_{mqk} \cdot W'_m x(p_q + \Delta p_{mqk}) \right] \quad (3)$$

DADC 的核心创新并不在于引入单一现有算子, 而在于两者构建的深度融合机制。Def-Attn 在空间维度输出已被缺陷区域主导的校准特征, DyConv 则在权重维度以该特征为路由依据, 动态生成输入相关的卷积核。两者通过“空间校准、权重路由、卷积重构”的链式耦合, 共同产生出空间采样与内容加权的联合自适应能力, 从而在底层特征图内对不同尺寸的缺陷实现微观跨尺度融合。为清晰阐明该融合过程的数据流, 设模块初始输入特征为 x , 其整体耦合过程可形式化如下:

首先, 进行空间尺度的自适应校准。输入特征 x 经过初始卷积投影后, 送入可变形注意力机制 Def-Attn 提取空间采样偏移并进行特征对齐。由于采样点能够根据缺陷的实际物理大小动态扩张或收聚, 该步骤打

破了固定感受野的限制, 输出空间对齐特征 $X_{def} = \text{Def-Attn}(\text{Conv}(x))$ 。

然后, 执行跨尺度特征引导的专家加权。如图 2(b) 的权重流所示, 为突破常规 DyConv 依赖原始特征汇聚易受干扰的局限, DADC 将高质量对齐特征 X_{def} 送入路由机制。通过全局平均池化与多层感知机 (FC-ReLU-FC), 动态生成 k 个专家核的归一化权重 α_k , 如下式 (4) 所示:

$$\alpha_k = \text{Softmax}(\text{MLP}(\text{GAP}(X_{def}))) \quad (4)$$

最后, 完成微观跨尺度特征的聚合输出。将生成的权重与多专家核进行线性组合, 得到动态卷积核 $W_{dyn} = \sum_{k=1}^K \alpha_k W_k$ 。如图 2(b) 的主干数据流所示, 利用该动态核对 X_{def} 执行二维卷积, 并依次通过批量归一化与 SiLU 激活函数, 得到最终输出:

$$Y = \text{SiLU}(\text{BN}(\text{Conv2d}(X_{def}, W_{dyn}))) \quad (5)$$

综上, 通过内嵌 DADC 算子, 重构后的 C3k2_DADC 将可学习的空间对齐约束与动态聚合过程协同建模, 使骨干输出在结构一致性与缺陷响应强度上得到同步增强; 该输出在进入颈部融合前已完成关键区域对齐与纹理抑制, 为 SCGSFM 的空间-通道协同重标定提供稳定的高层语义先验, 从而提升整体框架在复杂背景下的可判别性。

2.2 颈部多尺度特征融合优化

在 YOLOv11n 的颈部网络中, 跨尺度信息的对齐与融合质量直接决定微小缺陷的可分性与响应强度。尽管 C3k2_DADC 已在骨干阶段增强了非结构化缺陷的对齐建模并抑制部分纹理干扰, 但在上采样与拼接驱动的跨层融合过程中, PCB 中高频走线与焊盘结构仍易形成主导性的空间激活与通道响应, 使缺陷语义在融合链路中被稀释, 进而影响检测稳定性。

为解决这一问题, 本文沿用 FPN-PAN 双向融合范式, 并在原架构基础上嵌入两项针对性优化: 其一, 在 FPN 自顶向下路径的入口部署 SCGSFM 模块, 对最高语义层进行语义重标定, 为跨尺度融合提供具有高判别性的语义先验; 其二, 将跨层拼接前的近邻上采样替换为 DNI 模块, 以增强跨尺度特征对齐时的结构感知能力。改进后的多尺度特征融合网络整体拓扑如图 5 所示。设骨干网络输出的三尺度特征分别为 $P_3 \in \mathbb{R}^{C_3 \times 80 \times 80}$ 、 $P_4 \in \mathbb{R}^{C_4 \times 40 \times 40}$ 和 $P_5 \in \mathbb{R}^{C_5 \times 20 \times 20}$ 。在 FPN 自顶向下传递的源头, 最高语义层 P_5 并不直接参与拼接, 而是首先经 SCGSFM 模块完成语义特征重标定, 输出净化特征 $P'_5 = \text{SCGSFM}(P_5)$ 。随后, 为实现跨尺度融合, 网络依次通过本文提出的 DNI 模块进行结构感知上采样与通道拼接, 分别得到中层融合特征 $F_4 = \text{C3k2}(\text{Concat}(\text{DNI}(P'_5), P_4))$, 以及最终的小目标特征 $F_3 = \text{C3k2}(\text{Concat}(\text{DNI}(F_4), P_3))$ 。




图 5 颈部多尺度融合图

Fig.5 Multi-scale feature fusion in the neck network

在 PAN 自底向上路径中, 网络进一步通过步长为 2 的卷积下采样与拼接操作, 依次计算得到最终的中

目标特征 $N_4 = \text{C3k2}(\text{Concat}(\text{Conv}(F_3), F_4))$ 以及大目标特征 $N_5 = \text{C3k2}(\text{Concat}(\text{Conv}(N_4), P'_5))$ 这三个尺度

的最终输出 (F_3, N_4, N_5) 将分别送入解耦检测头进行预测。

2.2.1 SCGSFM 语义重标定模块

针对上述跨尺度融合中的语义稀释问题, 本文借鉴文献[13]中池化与全局特征聚合自注意力机制 (Pooling and Global feature Fusion Self-attention Mechanism, PGFSM) 的设计思想, 引入其核心的空间-通道全局自注意力聚合模块 (Spatial-Channel Global Self-attention Fusion Module, SCGSFM), 并创新性地将其前置于 FPN 自顶向下路径的源头节点, 即最高语义层进入融合链路之前, 使其提供具有高区分度的语义引导先验, 并完成一次全局重标定。结合 PCB 缺陷检测的任务特性, 本文对原模块进行了如下适应性调整: (1) 舍弃原 PGFSM 中针对通用目标检测场景设计的空间池化聚合分支与通道池化聚合分支, 专注于 SCGSFM 提供的全局自注意力机制, 使模块设计更契合 PCB 缺陷检测中全局规律性纹理与局部异常性缺陷并存的特征分布; (2) 优化空间视图与通道视图构造时的维度变换流程, 移除原结构中冗余的特征转置环节, 在保留全局自注意力建模能力的同时减少不必要

的内存访问与张量重排开销。该部署策略与上述结构调整协同作用, 使 SCGSFM 从通用特征增强单元转化为专用于跨尺度融合质量提升的语义重标定模块。

重构后的 SCGSFM 内部处理逻辑如图 6 所示, 不同于卷积块注意力模块 (Convolutional Block Attention Module, CBAM) 等传统注意力模块在空间与通道域独立生成权重, SCGSFM 将空间与通道建模视为相互耦合的协同过程, 通过多视图投影与跨维度交互建模空间与通道的协同关系, 以增强缺陷相关区域的显著性并抑制纹理背景干扰。首先对输入特征 $x \in \mathbb{R}^{C \times H \times W}$ 执行特征解耦与正交视图投影。模块通过 1×1 卷积将通道维度压缩至 N , 得到中间特征 $F \in \mathbb{R}^{N \times H \times W}$ 。随后, F 被分流处理以构建多视图表征: 一条支路将 F 通过 Reshape 与转置操作构造空间视图 $M \in \mathbb{R}^{(HW) \times N}$ 与值视图 $T \in \mathbb{R}^{(HW) \times N}$; 另一条支路对 F 施加两组独立的 1×1 卷积映射, 并经 Reshape 得到通道视图 $G \in \mathbb{R}^{N \times (HW)}$ 与值视图 $R \in \mathbb{R}^{N \times (HW)}$ 。该非对称投影在保留空间拓扑的同时, 引入通道维语义变换的灵活度。在此基础上, 模块利用矩阵乘法显式挖掘空间与通道的联合依赖关系, 并行生成两张协同注意力图, 如式(6)所示:




图 6 SCGSFM 模块

Fig.6 SCGSFM module

$$\begin{cases} Z_s = \text{Softmax}(M \times G) \in \mathbb{R}^{(HW) \times (HW)} \\ Z_c = \text{Softmax}(G \times M) \in \mathbb{R}^{N \times N} \end{cases} \quad (6)$$

其中, Z_s 基于全图像素间的内积关系构建空间亲和矩阵, 用于刻画长距离空间依赖并引入全局一致性约束, 从而在一定程度上减弱基板纹理对局部响应的

干扰; Z_c 则建模通道维度的语义相关性, 促进对缺陷判别更敏感的特征通道被筛选与增强。随后, 将上述构建的空间与通道亲和矩阵 Z_s 和 Z_c 作为自适应的注意力权重, 分别与输入特征经线性投影得到的值视图 T 和 R 进行矩阵相乘, 以此驱动特征的双流自适应增强。具体而言, 空间流增强特征 $P_s = Z_s \times T$ 旨在强化

缺陷区域的显著性,而通道流增强特征 $P_c = Z_c \times R$ 用于过滤冗余背景通道。最终,两个分支的输出经 Reshape 恢复为维度 $\mathbb{R}^{N \times H \times W}$ 后进行逐元素叠加,并通过末端的 1×1 卷积层将通道数恢复至 C , 输出最终特征 Y 如式 (7):

$$Y = \text{Conv}_{1 \times 1}(\text{Reshape}(P_s) \oplus \text{Reshape}(P_c)) \quad (7)$$

综上,SCGSFM 在最高语义层进入 FPN 融合链路之前,对空间与通道响应进行协同重标定,缓解跨层拼接过程中纹理主导激活导致的缺陷语义稀释问题;在 C3k2_DADC 已完成边缘对齐与缺陷敏感表征的基础上,该模块进一步提升高层语义的融合可分性与稳定性,并为后续上采样阶段的结构化细节恢复提供更干净、更一致的语义引导,从而降低误激活与融合噪声对检测结果的累积影响。

2.2.2 动态结构感知插值的上采样机制

传统特征图上采样通常采用最近邻插值 (Nearest Neighbor Interpolation, Nearest), 其通过空间位置索引映射对特征值进行复制,以恢复空间分辨率。然而,该类刚性上采样策略未显式建模局部结构与语义连续性,极易在高频纹理与细粒度目标并存的场景中引发特征混叠与结构性伪影。对于 PCB 缺陷检测而言,最近邻插值在细小缺陷边界处易产生锯齿效应与空间不连续,同时会放大大面积平坦铜箔基板上的高频纹理与噪声干扰,进而削弱微小缺陷的特征表征精度与定位稳定性。

针对上述由刚性插值引发的局部拓扑失真问题,

受内容感知特征重组 CARAFE^[14] (Content-Aware ReAssembly of Features) 启发,本文设计动态结构感知邻域插值模块 DNI (Dynamic Structure-Aware Neighborhood Interpolation),其结构如图 7 所示。该模块以 CARAFE 中的自适应特征重组机制为底层架构,但摒弃了其面向通用视觉任务的冗余结构。针对 PCB 缺陷检测场景的物理先验与 YOLOv11n 轻量化骨架的算力约束,DNI 对原始框架进行了两项关键的结构性重构。其一,剥离了冗余的前置通道压缩模块。原始设计动机是在高维特征(典型 $C=256 \sim 512$)下平衡核预测开销,但在 YOLOv11n 颈部特征通道数本就不高(典型 $C=64 \sim 128$)的条件下,该压缩层不仅难以发挥降维收益,反而引入了多余的中间张量。为此,DNI 将权重生成路径精简为单层卷积直通预测,这不仅消除了特征降维过程中的高频信息损耗,更大幅降低了前向推理时的访存开销。其二,核预测头输出维度的重构。原版重组机制的预测头输出 $25\sigma^2$ 的通道特征(对应 5×5 重组邻域)。本文将该预测头的输出维度重构为 $9\sigma^2$ 维。这一结构性降维是基于 PCB 缺陷判别尺度的物理回归——PCB 上的鼠咬、毛刺、缺孔等微小缺陷在颈部特征图上往往仅占据 $1 \sim 3$ 像素的过渡带宽度, 3×3 邻域恰好能完整覆盖边缘像素-过渡像素-背景像素的三阶判别窗口,既保证对边缘几何的完整表征,又规避了 5×5 宽泛邻域引入的 16 个外圈同质化基板像素对核心边缘信号的稀释。




图 7 DNI 模块

Fig.7 DNI module

设低分辨率输入特征为 $x \in \mathbb{R}^{C \times H \times W}$ 。得益于前置通道压缩与降维结构的剥离,DNI 以最简路径构建特征重组的数据流,避免了任何冗余的中间张量与额外参数开销。在动态权重生成阶段,模块直接以单层 3×3 卷积对输入特征的局部结构线索进行编码,刻画缺陷边缘的几何突变走向;随后在 9 个邻域位置维度上执行 Softmax 归一化,从而得到跨通道共享的结构权重

张量 W ,以显式表征邻域像素对目标亚像素的相对贡献。如式(8):

$$W = \text{Softmax}(\text{Conv}_{3 \times 3}(x)) \in \mathbb{R}^{r^2 \times 9 \times H \times W} \quad (8)$$

其中, r 表示上采样倍率,9 对应针对性收紧的 3×3 局部邻域。这一约束式权重生成在大幅压缩参数开销的同时,从物理底层切断了前述大面积平坦铜箔背景的远端噪声摄入,迫使有限的插值注意力自适应

聚焦于核心的缺陷几何突变地带。

在领域聚合与亚像素重构阶段, DNI 通过邻域展开算子 $\text{Unfold}(\bullet)$ 提取输入特征在每个空间位置上的 3×3 局部邻域块, 将其与跨通道共享的结构权重张量 $\mathbf{W}$ 进行逐领域加权聚合; 聚合后的张量经亚像素重排算子 PixelShuffle 将通道维度的细节信息周期性映射至空间维度, 输出高保真的上采样特征 $\mathbf{Y}$ 如下 (9) 所示。式中, $\mathbf{W}_k$ 与 $\text{Unfold}(\mathbf{x})_k$ 分别表示权重张量与邻域特征张量在邻域索引 k 上的分量。

$$\mathbf{Y} = \mathcal{PS} \left(\sum_{k=1}^9 \mathbf{W}_k \cdot \text{Unfold}(\mathbf{x})_k \right) \in \mathbb{R}^{C \times rH \times rW} \quad (9)$$

由此, DNI 通过精简的局部邻域结构建模与自适应的插值权重生成, 在保持极低计算开销的同时, 有效切断了平坦铜箔背景的噪声摄入。该机制使上采样特征在细节恢复阶段保持了极高的结构保真度, 显著减少了边界模糊与几何失真对特征解码的累积影响, 从而为后续检测头提供了更为一致的几何表征基础, 进一步支撑了小尺度缺陷定位的稳定优化。

2.3 面向小目标的尺寸感知损失函数设计

YOLOv11n 基线模型采用 CIOU 作为边界框回归损失, 在 IoU 项之外引入中心距离与长宽比一致性约束, 以兼顾定位误差与形状回归。此类损失函数在通用场景下表现均衡, 但在 PCB 表面缺陷检测中, 目标尺度普遍偏小且分布密集, 暴露出严峻的梯度主导偏置问题。具体而言, 尽管 CIOU 本身具备空间尺度不变性, 但在反向传播过程中, 中大尺度样本因其锚点映射多、回归绝对误差大, 其产生的梯度幅值往往以压倒性优势主导整个网络的优化方向, 致使极微小缺陷的回传梯度被严重稀释与淹没, 模型对其定位学习明显不足。

为缓解尺度失衡引发的优化偏置, 现有的尺度自适应机制多通过对损失项进行硬阈值切换或分量重分

配的方式实现, 但这类机制在反向传播中容易引发数值附近的梯度突变与优化震荡, 难以从根本上缓解小目标全局梯度幅值微弱的问题。基于上述分析, 本文构建尺寸感知回归损失 SA-Loss (Size-Aware Loss)。SA-Loss 不修改 CIOU 自身的几何度量内核, 而是通过引入由目标尺度直接驱动的非线性尺度重加权算子, 对整体回归项施加平滑、连续的乘法增益, 使反向传播过程中流向小目标样本的梯度强度获得定向放大, 同时让中大尺度样本的梯度贡献保持与基线相当。其整体形式如式 (10) 所示:

$$L_{SA} = s(A^{gt}) \cdot L_{CIOU}, \quad A^{gt} = \frac{W^{gt} \cdot h^{gt}}{W \cdot H} \quad (10)$$

其中, L_{SA} 表示本文提出的尺寸感知回归损失, L_{CIOU} 为基线回归项; A^{gt} 为真实框的归一化面积, 由真实框宽高 W^{gt} , h^{gt} 与输入分辨率 W , H 计算得到。核心函数 $s(A^{gt})$ 即为本文设计的非线性尺度重加权算子, 用于对不同尺度样本的回归梯度贡献进行平滑调节, 其定义如式 (11) 所示:

$$s(A^{gt}) = 1 + \lambda \cdot \sigma \left(\frac{A_0 - A^{gt}}{\tau} \right) \quad (11)$$

式中, $\sigma(\cdot)$ 表示 Sigmoid 函数, A_0 为小目标面积阈值, τ 控制权重变化的过渡带宽, λ 为最大增益系数。为直观刻画尺度重加权因子 $s(A^{gt})$ 的非线性调制规律, 图 8 展示了本文典型参数设置 ($A_0 = 0.1, \tau = 0.02$) 下, 不同增益系数 λ 对应的权重响应曲线。

如图 8 所示, 尺度重加权因子 $s(A^{gt})$ 随真实框归一化面积 A^{gt} 的增大呈单调衰减, 并在判别阈值 A_0 附近完成非线性过渡。该响应曲线在数学拓扑上实现了针对不同尺度样本回归梯度的三阶自适应重分配。




图8 尺度重加权因子的响应曲线

Fig.8 Response curves of the scale-aware re-weighting function

首先, 在微小目标强增益区间 ($A^{gt} \ll A_0$), Sigmoid 函数输出趋近于 1, 该算子渐进趋于 $s(A^{gt}) \approx 1 + \lambda$, 从而对小尺度样本的回归误差施加更高权重, 强化其学习强度。随着目标尺度增加并进入阈值自适应平滑区间 ($A^{gt} \approx A_0$), 权重在 τ 的控制下实现平滑且连续的衰减, 避免阈值附近的突变加权以保持优化过程稳定。最终, 在常规目标渐进回落区间 ($A^{gt} > A_0$) 后, $s(A^{gt})$ 逐步衰减并收敛至基准常数 1, 使中/大尺寸样本的回归项保持与基线 CIoU 相近的梯度增幅, 从而降低其对整体优化方向的主导效应。由此, SA-Loss 通过对损失函数局部优化曲面的尺度敏感重塑, 在定向强化小目标回归梯度贡献的同时保障了全局寻优过程的平滑稳定。

最终, 整体训练目标由分类损失 L_{cls} 、分布式回归项 L_{DFL} 与本文提出的尺寸感知回归损失 L_{SA} 加权组成, 如式 (12) 所示, 其中 β 与 γ 为损失权重系数。该设计在保持网络前向结构不变的前提下, 通过对回归梯度进行尺度自适应调制, 进一步提升了微小缺陷的定位优化效率与收敛稳定性。

$$L = L_{cls} + \beta L_{DFL} + \gamma L_{SA} \quad (12)$$

3 实验及结果分析

3.1 数据集介绍

本文使用 PKU-Market-PCB 数据集^[15]作为主要实

验数据, 并引入公开数据集 DeepPCB^[16]作为泛化性验证。PKU-Market-PCB 数据集包含 6 种常见的 PCB 缺陷: 开路 (open_circuit)、短路 (short)、鼠咬 (mouse_bite)、毛刺 (spur)、余铜 (spurious_copper) 和缺孔 (missing_hole), 共 693 张图像, 一张图片中只包含一个缺陷类别。同样覆盖开路、短路、鼠咬、毛刺、余铜和缺孔 6 类缺陷, 如图 9 所示。由于原始数据集样本规模有限, 小样本训练条件下模型易出现过拟合与参数估计偏差, 导致泛化能力不足; 同时, 实际 PCB 产线检测还会受到光照不均、设备抖动、成像噪声及背景纹理干扰等因素影响, 进一步增加微小缺陷检测难度。因此, 本文在原始数据基础上对图像进行增强与污染退化处理, 生成污染增强版本。具体而言, 增强策略包括随机旋转、镜像翻转与平移等几何变换, 以及亮度/色彩扰动、噪声注入与模糊退化等污染操作, 以模拟产线中常见的成像干扰。通过上述处理, 最终获得 5614 张用于 PCB 缺陷检测的图像, 本文实验按照 8:1:1 划分为训练集、验证集和测试集。

DeepPCB 数据集如图 10 所示, 同样覆盖开路、短路、鼠咬、毛刺、余铜和缺孔 6 类缺陷, 共 1500 张图像, 每张图像包含 3–12 个缺陷实例。为保证实验评估的客观性与可比性, 同样按照 8:1:1 的比例对数据集进行随机划分, 分别构建训练集、验证集与测试集。




图9 PKU-Market-PCB 增强数据集六种缺陷图

Fig.9 Six Types of Defects in the PKU-Market-PCB Enhanced Dataset




图 10 DeepPCB 数据集六种缺陷图

Fig.10 Six Types of Defects in the DeepPCB Dataset

3.2 实验环境和评价指标

所有实验均在配备 AMD Ryzen 9 7940HX 处理器和 NVIDIA GeForce RTX 4070 Laptop GPU (8GB 显存) 的计算平台上完成。实验在 Python 3.12.3 环境下, 基于 PyTorch 2.7.1 框架实现, 并利用 CUDA 12.6 进行加速计算。输入图像尺寸统一调整为 640×640 。模型训练轮数为 300, 批量大小为 32, 采用 SGD 优化器; 初始学习率为 0.01, 动量为 0.937, 权重衰减为 0.0005, 并采用 3 个 epoch 的 warmup 策略。

实验评价指标有准确率 (precision, P)、召回率 (recall, R)、平均精度均值 (mean Average Precision, mAP)、浮点运算量 (FLOPs) 和模型参数量 (model parameters, Params) 等。计算公式如 (13)、(14) 和 (15) 所示。

$$P = \frac{TP}{TP + FP} \quad (13)$$

$$R = \frac{TP}{TP + FN} \quad (14)$$

$$mAP = \frac{1}{N} \sum_{i=1}^N \left(\int_0^1 P(R) dR \right)_i \quad (15)$$

式 (13)、(14) 和 (15) 中: TP 为真正例, FP 为假正例, FN 为假反例; $\int_0^1 P(R) dR$ 表示单类别下 Precision-Recall 曲线与坐标轴围成的面积; N 表示类别总数; i 表示第 i 个类别。此外, 采用 Params 与 FLOPs 衡量模型的理论计算复杂度, 并结合 FPS 评估模型在实际硬件端的前向推理速度, 以全面衡量算法在检测精度、部署开销与工业实时性之间的综合平衡。

3.3 消融实验

本节在 PKU-Market-PCB 增强数据集上开展消融实验, 旨在剖析 DSDN-YOLO 各核心模块的功能属性及其对复杂背景下微小缺陷检测的性能贡献。实验遵

循严格的变量控制原则, 在保持超参数与训练策略完全一致的前提下, 系统评估了不同组件组合在精度、召回率及计算效率等维度的表现, 从而验证模型设计的合理性与有效性。

3.3.1 核心改进模块消融实验

实验以 YOLOv11n 为基线 (Baseline), 依次集成 C3k2_DADC、SCGSFM、DNI 以及 SA-Loss 模块, 并分别记为 A、B、C 和 D。其中“✓”表示使用了相应的方法对模型进行改进。各组实验的具体配置与对应结果如表 1 所示。由表 1 的消融实验结果表明可知, 基线模型在面对 PCB 复杂背景时, $mAP@0.5$ 为 92.7%, 且召回率 R 仅为 87.3%, 暴露出明显的漏检瓶颈; 将原始 C3k2 单元替换为 C3k2_DADC(A)后, 模型通过结构级重构实现了对非结构化缺陷几何变化的自适应对齐, 有效克服了固定网格采样对细微轮廓捕获能力的不足, 使召回率 R 显著提升至 91.5%, 为后续模块提供了更高质量的特征先验; 在此基础上进一步加入 SCGSFM(B)后, 模型利用跨维协同重标定机制, 精准抑制了 PCB 走线及焊盘纹理产生的高频冗余响应, 准确率 P 提升至 95.0%, 展现出与模块 A 在特征捕获与背景抑制层面的强互补性, 二者协同作用使 $mAP@0.5$ 跃升至 95.0%; 再叠加引入 DNI(C)后, 模型凭借结构感知权重替代了刚性的最近邻插值, 在保持细长缺陷边界连续性的同时显著缓解了上采样阶段的语义漂移, 使 $mAP@0.5$ 进一步稳步优化; 最终集成 SA-Loss(D)后, DSDN-YOLO 达到了最优检测效能。

整合 A、B、C 和 D 四个模块后, 尽管改进模型的参数量与计算开销小幅增加, 但其准确率、召回率和 mAP 的综合表现更好, DSDN-YOLO 的 P 、 R 和

mAP@0.5 分别较基线模型提升了 1.5%、6.5%和 2.7%，这说明本文模型能较好地平衡 PCB 表面缺陷检测场景下实时性和检测准确性的要求。


表 1 消融实验
Table 1 Ablation study

基线	A	B	C	D	P/%	R/%	mAP@0.5/%	Params(M)	GFLOPs
✓					94.0	87.3	92.7	2.58	6.3
✓	✓				94.6	91.5	94.3	2.78	6.8
✓		✓			95.0	88.0	93.9	2.62	6.4
✓			✓		94.2	87.8	93.0	2.66	6.5
✓	✓	✓			95.2	93.0	95.0	2.82	6.9
✓	✓	✓	✓		95.3	93.3	95.2	2.86	7.0
✓	✓	✓	✓	✓	95.5	93.8	95.4	2.86	7.0

3.3.2 DNI 上采样机制有效性分析

为验证 DNI 的有效性，本文采用 Grad-CAM++算法对不同上采样方式驱动下的特征响应分布进行可视化对比，结果如图 11 所示。由图可知，DNI 驱动下的特征图高响应区域能够更精准地拟合缺陷目标的空间分布与局部形态，其激活区域呈现出更高的集中度与语义连续性，且边缘过渡平滑，内部关联更为紧密。在特征分布的均衡性方面，DNI 通过对邻域像素响应的自适应聚合与归一化重构，有效规避了 Nearest 插值因像素刚性复制导致的局部响应剧烈波动现象，使

目标区域的激活强度更加均匀，并表现出对走线纹理与焊盘等背景噪声的优异抑制能力。在结构一致性层面，DNI 能够更完整地保留微小缺陷的边缘细节与局部拓扑连续性；反观 Nearest 上采样，其热力图边缘存在明显的量化锯齿效应，且响应区域易发生破碎，导致目标结构不连续及形态失真，语义映射关系相对薄弱。因此，DNI 上采样更有利于保持细粒度结构信息并提升微小缺陷的定位稳定性与检测鲁棒性。



(a) 原图 (b) Nearest上采样 (c) DNI上采样

图 11 不同上采样方式的特征响应分布可视化对比

Fig.11 Visualization comparison of feature response distributions under different upsampling methods

3.4 对比实验

3.4.1 不同 C3K2 结构对比

为深度剖析并验证 C3k2_DADC 模块的有效性，本实验选取了近年来主流特征表征算子 ODConv^[17]、DEConv^[18]、AKConv^[19]、以及 DCNv4^[20]。我们将这些算子与本文的 DADC 分别用于重构 C3k2 单元，并嵌入 YOLOv11n 模型中，在 PKU-Market-PCB 增强数据集上开展对比实验，实验遵循严格的变量控制原则，在保持超参数与训练策略完全一致的前提下，最终对

比结果如表 2 所示。由实验结果分析可知，引入不同设计范式的卷积模块对 C3k2 进行重构，均能在一定程度上增强模型的特征表征能力。

其中，全维度动态卷积 ODConv 利用多维注意力机制实现了通道及空间等维度的动态权重分配，有效提升了特征响应的精准度；细节增强卷积 DEConv 通过多尺度特征融合与残差学习机制，强化了模型对缺陷边缘等高频纹理信息的提取与恢复能力；可变核卷积 AKConv 则凭借对采样坐标偏移量的灵活定义，通

过生成任意形状的卷积核来适配缺陷目标复杂的几何拓扑形变；可变形卷积 DCNv4 通过引入动态调制的空间偏移，实现了对特征采样位置的自适应对齐，在处理几何形变特征时展现出强大的建模能力。实验表明，相较于基线 C3k2 及其他改进方法，C3k2_DADC 在关键指标上取得最优表现，mAP@0.5 提升至 94.3%、召回率 Recall 提升至 91.5%，同时将计算量与参数量控制在合理范围内，在精度提升与复杂度开销之间取得更优平衡。为直观展示 C3k2_DADC 模块在 PCB 表面缺陷检测中的表征优势，本文选取极具代表性的鼠咬微小缺陷作为测试样本，对比分析了基线 C3k2、C3k2_AKConv、C3k2_DCNv4 以及本文 C3k2_DADC 的实际检测表现。由图 12(a)可知，基线 C3k2 模块在

面对走线纹理复杂、边界对比度微弱的区域时，由于特征提取能力受限，存在显著的漏检风险；如图 12(b)-(c)所示，替换为 C3k2_AKConv 与 C3k2_DCNv4 后，模型对不规则局部特征的感知力有所增强，成功检出了部分基线遗漏的目标，但其在密集高频背景下易受全局冗余信息干扰，对极微小缺陷的聚焦能力依然不足，导致检测置信度偏低。相比之下，如图 12(d)所示，本文 C3k2_DADC 模块对该类弱特征目标的语义响应最为充分，漏检情况得到明显缓解。此外，目标缺陷的置信度由 0.77 提升至 0.83，反映出该结构在强化特征表达能力的同时，显著增强了模型对极小缺陷的检出稳定性。上述可视化对比结果进一步验证了 C3k2_DADC 在复杂背景下对细粒度缺陷的检测优势。

表 2 不同 C3k2 结构对比
Table 2 Comparison of different C3K2 structures

模型	mAP@0.5/%	P/%	R/%	Params(M)	GFLOPs
C3k2 (Base)	92.7	94.0	87.3	2.58	6.3
C3k2_ODConv	94.0	94.9	91.2	3.35	8.1
C3k2_DEConv	93.5	94.3	90.2	2.75	7.2
C3k2_AKConv	93.9	94.1	91.0	2.95	7.5
C3k2_DCNv4	94.1	94.4	91.2	2.85	7.4
C3k2_DADC	94.3	94.6	91.5	2.78	6.8




图 12 PCB 缺陷场景下检测效果对比图

Fig.12 Qualitative comparison of detection results in PCB defect scenarios

3.4.2 不同注意力模块对比

为评估本文设计的 SCGSFM 模块在 PCB 缺陷检测任务中的有效性，本节选取几组当前主流的注意力

机制进行替换对比实验，实验结果如表 3 所示。

表3 不同注意力机制对比

Table 3 Comparison of different attention mechanisms.

注意力机制	AP/%						mAP@0.5/%
	缺孔	鼠咬	短路	毛刺	余铜	开路	
YOLOv11n	99.0	91.5	98.9	89.3	91.8	86.0	92.7
+SimAM	99.0	91.8	99.0	89.8	92.2	86.2	93.0
+CBAM	99.1	91.6	99.1	90.5	92.6	86.5	93.3
+MLCA	99.3	92.4	99.1	91.0	93.0	86.6	93.5
+SCGSFM	99.5	92.8	99.2	91.4	94.0	87.0	93.9

由表3实验数据分析可知,相较于其他改进策略,SCGSFM在各项精度指标上均展现出显著的竞争优势。具体而言,SimAM^[21]虽然利用能量函数实现了无参化的3D注意力权值推断,但因缺乏对空间与通道依赖关系的深度耦合建模,导致其对毛刺等高频细微特征的增强效果有限;CBAM^[22]虽通过串联空间与通道模块提升了特征筛选能力,但在面对PCB复杂的走线纹理时,其解耦式的处理策略易造成跨维度交互语义的缺失,导致在鼠咬等非结构化缺陷的定位上出现偏差;而MLCA^[23]在应对极微小且边界模糊的缺陷时,其动态适应性仍逊色于本文模块。相比之下,引入SCGSFM后的模型mAP@0.5较基线提升了1.2%,特别是在最具挑战性的鼠咬和毛刺类别上,分别实现了1.3%和2.1%的显著增长。上述结果充分证明,SCGSFM的全局协同重标定机制能够有效抑制复杂背景纹理的干扰,在难检微小目标的精细化识别与精准定位方面具备显著优越性。

为直观验证SCGSFM模块在特征跨层流转中的语义纯化机理,本文提取了最高级语义特征进入多尺

度融合路径前节点的响应热力图进行定性对比。如图13的可视化结果所示,由于基线YOLOv11n在此交汇处缺乏前置降噪机制,其输出特征极易受高频背景干扰,导致低能响应广泛弥散于远端正常走线上。在引入经典双维度算子CBAM后,正如前文定量分析所述,其解耦串联策略引发了显著的“特征混叠”效应,高能激活区域向周边健康结构发生了明显的溢出。进一步观察引入MLCA算子的热力图分布,尽管能量扩散现象有所收敛,但缺陷周边仍残留明显的局部伪影,表明其对规律性背景纹理的剥离仍不够充分。相比之下,本文设计的SCGSFM模块部署于特征流转的核心节点,经该模块处理后,特征图的能量分布呈现出显著的结构性重构。其空间与通道协同机制实现了精确的背景去噪:不仅将高能异常响应峰值高度收敛并紧密锚定于微小缺陷核心,同时对周边的规律性走线产生了显著的响应抑制作用,呈现出高对比度的低能量背景分布。上述可视化证据表明,SCGSFM具备优异的特征纯化与语义解耦能力,能够有效阻断高频背景噪声在多尺度融合网络中的跨层传递扩散。




图13 复杂走线背景下不同注意力机制的特征响应热力图

Fig.13 Feature response heatmaps of different attention mechanisms under complex trace backgrounds

3.4.3 不同损失函数对比

为评估尺寸感知损失函数SA-Loss对模型训练及回归精度的影响,本文将基线CIoU与经典损失函数GIoU^[24]、SIoU^[25]、辅助框损失Inner-IoU^[26]、以及前沿的尺度动态损失SD Loss^[27]进行横向对比实验。所有损失函数均分别应用于YOLOv11n模型训练,训练

过程中严格遵循控制变量原则,性能对比结果如表4所示。

由表4的定量分析可知,不同损失函数对PCB缺陷回归优化的效能呈现显著差异。基线模型采用CIoU时,因缺乏针对极小目标的显式优化机制,其mAP@0.5与召回率R分别受限于92.7%与87.3%。在

引入经典损失函数 GIoU 与 SIoU 后, 尽管模型通过增加重叠面积与角度惩罚等复杂的几何度量缓解了定位误差, 但整体精度提升受限, 且微小缺陷的漏检问题仍未得到改善; 而 Inner-IoU 通过引入辅助边框的尺度比例控制, 在回归精细度上取得了一定突破, 将 mAP 提升至 93.0%, 但其召回率的改善幅度依然有限。进一步引入前沿的尺度动态损失 SD Loss 后, 模型 mAP 提升至 93.2%, 表明动态分配损失分量权重的策略具有一定积极意义; 然而, 其召回率的提升仍遭遇显著的性能瓶颈。这一现象从实证层面印证了前文的理论剖析: 在目标尺度极度失衡的场景中, 无论是堆叠复杂的几何度量、引入辅助框约束, 还是调整损失内部的“度量权衡”, 均无法有效的消除微小目标“跨样本梯度被淹没”的优化困境, 从而导致大量弱特征缺陷持续漏检。

表 4 不同损失函数对比

Table 4 Comparison of different loss functions			
损失函数	mAP@0.5/%	P/%	R/%
CIoU	92.7	94.0	87.3
GIoU	92.9	94.0	87.5
SIoU	92.8	94.1	87.6
Inner-IoU	93.0	94.2	87.8
SD Loss	93.2	94.3	88.5
SA-LOSS	93.4	94.4	90.8

相比之下, 本文提出的 SA-Loss 在各项评估指标

表 5 不同算法实验结果对比

Table 5 Comparison of experimental results for different algorithms							
算法	P/%	R/%	GFLOPs	Params(M)	mAP@0.5/%	mAP@0.5:0.95/%	FPS
Faster-R-CNN	93.0	92.8	205.1	46.76	94.2	48.2	35
SSD	91.2	82.5	85.7	25.57	88.9	39.2	95
YOLOv5n	95.4	88.3	5.8	2.18	92.3	48.6	217
YOLOv6n	94.9	87.4	11.5	4.16	91.8	47.0	185
YOLOv8n	95.1	88.4	6.8	2.70	93.5	49.3	164
YOLOv10n	94.7	90.8	8.2	2.69	93.8	49.7	112
RT-DETR-R18	95.8	91.0	57.0	20.2	94.8	50.2	105
YOLOv11n	94.0	87.3	6.3	2.58	92.7	48.3	238
HDH-YOLO	94.2	92.1	5.5	2.42	94.5	51.5	225
GESC-YOLO	94.8	91.5	6.0	2.15	94.6	51.2	142
Ours	95.5	93.8	7.0	2.86	95.4	53.4	212

实验结果表明, DSDN-YOLO 在各项评估指标上均展现出良好的综合性能。相较于 Faster R-CNN 和

中均展现出最优的回归性能, 其 mAP@0.5 达到对比组最高的 93.4%。尤为关键的是, SA-Loss 在召回率指标上实现了突破性增长, 从基线的 87.3%显著提升至 90.8%。这一客观数据验证了 SA-Loss 的核心机制的科学性: 该损失依托非线性的尺度自适应调节因子, 实现了对反向传播中回归梯度流的“动态重塑”。通过定向放大微小缺陷样本在全局梯度更新中的贡献占比, 该机制有效克服了回归优化过程中极易由大中型目标主导的“梯度偏置”现象, 进而显著强化了模型对极小且非结构化缺陷的检出能力, 精准契合了 PCB 表面缺陷检测的严苛要求。

3.4.4 目标检测算法对比

为全面评估 DSDN-YOLO 在 PCB 表面缺陷检测任务中的综合性能, 本文选取具有代表性的两阶段检测器 Faster R-CNN^[4]、单阶段检测器 SSD^[28]、主流轻量化 YOLO 系列 (YOLOv5n^[29]、YOLOv6n^[30]、YOLOv8n^[10]、YOLOv10n^[31]、YOLOv11n^[32]) 以及基于 Transformer 架构的 RT-DETR-R18^[33]。为进一步验证算法的前沿优势, 本文还引入了近两年发表的 PCB 改进算法 HDH-YOLO^[34]与 GESC-YOLO^[35]作为核心对比基准。所有模型均在相同的 PKU-Market-PCB 增强数据集下开展训练与测试, 并严格控制实验超参数与硬件环境的一致性。实验采用准确率 P、召回率 R、mAP@0.5、参数量 Params 与计算量 GFLOPs 以及 FPS 等作为核心评价指标, 详尽对比结果如表 5 所示。

SSD, 本文方法在大幅压缩计算开销并实现高效推理的同时, 在检测精度上实现了全面超越。与 YOLO 系

列同量级算法相比, DSDN-YOLO 在 mAP@0.5 与召回率等关键指标上表现更佳。较基准模型 YOLOv11n, DSDN-YOLO 的准确率提高了 1.5%, 召回率提升了 6.5%, mAP@0.5 提升了 2.7%; 特别是在评估边界框贴合度的严苛指标 mAP@0.5:0.95 上, 本文模型达到 53.4%, 较基准提升了 5.1%, 有效验证了改进算法对细长及微小缺陷的高精度回归能力。此外, 与具备较高精度的 RT-DETR-R18 相比, 尽管 DSDN-YOLO 在准确率上略低 0.3%, 但在反映漏检控制能力的召回率指标上高出 2.8%, 同时 mAP@0.5:0.95 指标亦优于后者的 50.2%, 且参数量与计算量显著降低。

在与同领域最新研究成果 HDH-YOLO 与 GESC-YOLO 的深度对比中, DSDN-YOLO 同样展现出显著优势。实验结果表明, 上述两种轻量化算法在参数量压缩方面表现优异; 但在应对真实的复杂工业检测背景时, 其微小缺陷的漏检控制能力存在一定局限, 召回率均未超过 93%, 表明常规的轻量化策略在抑制背景干扰时面临表征瓶颈。此外, GESC-YOLO 因网络分支结构的增加导致显存访存开销增大, 其实际推理速度下降至 142FPS。相比之下, DSDN-YOLO 在仅引入极少量参数增量的前提下, 将推理速度稳固在 212FPS 的高帧率水准, 同时在召回率与 mAP 等核心指标上取得了全场最优表现。最终, DSDN-YOLO 的准确率与召回率分别达到 95.5%和 93.8%, 在计算成本、定位精度与推理速度之间达成了极其理想的权

衡, 能够较好地满足 PCB 缺陷检测场景对实时性和准确性的双重要求, 具备工业产线部署的应用潜力。

3.5 泛化性验证

为进一步评估 DSDN-YOLO 模型的泛化能力, 本文引入 DeepPCB 数据集进行跨数据集验证。相较于 PKU-Market-PCB 数据集, DeepPCB 数据集具有更为复杂的样本特征: 其单张图像中包含多种不同类别的缺陷, 且图像采集自高分辨率线性扫描电荷耦合器件 (CCD), 能够更加贴近实际工业场景中微小且密集的缺陷细节。鉴于两个数据集在数据分布与采集方式上的显著差异, 该实验能够有效检验模型在不同域下的适应能力。本节实验环境及参数设置与 3.2 节保持一致, 具体实验结果如表 6 所示。由表 6 可知, 在 DeepPCB 数据集上, 本文方法在检测精度与计算效率之间达成了良好的综合平衡。与基准模型 YOLOv11n 相比, 本文方法的准确率 P 和召回率 R 分别由 95.7%、96.2%提升至 97.8%和 98.5%, mAP@0.5 由 98.5%提升至 99.2%。更为关键的是, 在常规检测指标已趋于饱和的背景下, 本文模型在评估边界框定位精度的严苛指标 mAP@0.5:0.95 上由 77.6%提升至 82.3%, 增幅达 4.7%, 有效验证了在复杂纹理干扰下对微小缺陷边界的高精度回归能力。与同量级 YOLO 系列模型及近期前沿的 HDH-YOLO、GESC-YOLO 相比, 本文方法不仅在 mAP@0.5 指标上稳居全场最优, 更在反映漏检控制的召回率上展现出较大优势, 表明本文模型面对多缺陷共存场景并未因过度压缩参数而面临表征瓶颈, 具有更强的跨域适应性。综上所述, 本文模型在 DeepPCB 数据集上依然维持了稳定且高精度的检测效能, 证实了算法应对跨域数据与缺陷分布差异时的良好泛化能力。

表 6 DeepPCB 数据集实验结果对比

Table 6 Comparison of DeepPCB dataset experimental results

算法	P/%	R/%	GFLOPs	Params(M)	mAP@0.5/%	mAP@0.5:0.95/%	FPS
YOLOv5n	96.8	95.2	5.8	2.18	98.4	80.2	217
YOLOv6n	96.0	93.3	11.5	4.16	98.0	77.2	185
YOLOv8n	95.9	93.4	6.8	2.70	97.9	75.3	164
YOLOv10n	97.7	94.8	8.2	2.69	98.3	78.5	112
YOLOv11n	95.7	96.2	6.3	2.58	98.5	77.6	238
HDH-YOLO	97.7	95.4	5.5	2.42	98.6	80.4	225
GESC-YOLO	97.2	95.8	6.0	2.15	98.9	80.8	142
Ours	97.8	98.5	7.0	2.86	99.2	82.3	212

3.6 检测结果可视化分析

为直观评估 DSDN-YOLO 模型在 PCB 表面缺陷检测任务中的实际效果, 本节分别从 PKU-Market-PCB 增强数据集和 DeepPCB 数据集的测试集中随机选取部分具有代表性的样本进行可视化对比, 检测结果可视化如图 14 和图 15 所示。通过与基线模型 YOLOv11n、HDH-YOLO 以及 GESC-YOLO 的检测结果进行对照, 可以较为直观地分析改进模型在缺陷响应完整性、检测置信度以及边界框定位精度等方面的性能差异。

从图 14 所示的 PKU-Market-PCB 增强数据集检测结果可以看出, YOLOv11n 容易受背景结构干扰, 存在漏检及置信度偏低问题; 而 HDH-YOLO 与 GESC-YOLO 在复杂背景下依然存在定位框松散及部分极微弱特征响应缺失的现象。相比之下, DSDN-YOLO 能够对目标缺陷形成更完整的检测响应, 部分基线模型未能有效识别的缺陷在改进模型中得到

了正确检出, 同时检测框与真实缺陷区域之间的贴合程度更高, 预测结果也表现出更好的稳定性。这说明所提模型在微小缺陷特征提取、非结构化边界建模以及缺陷区域定位方面具有更强的表征能力。

从图 15 所示的 DeepPCB 数据集检测结果可以看出, 基线模型与 HDH-YOLO 以及 GESC-YOLO, 虽然能够完成多数明显缺陷的识别, 但在复杂线路分布和密集背景干扰条件下, 仍存在检测框偏移以及相邻微小目标区分能力不足等现象。相较之下, DSDN-YOLO 在短路、缺口、鼠咬等缺陷类型上均表现出更为稳定的检测效果, 不仅边界框定位更加准确, 而且对邻近目标和细粒度缺陷区域的区分能力也更强。该结果表明, 改进模型在跨尺度特征融合、局部细节恢复以及小目标回归优化等方面发挥了积极作用, 使模型能够在复杂背景条件下保持较高的检测稳定性和定位准确性。上述可视化结果与前文定量实验结论相一致, 进一步说明 DSDN-YOLO 在 PCB 表面微小缺陷检测任务中具有较好的应用潜力。




图 14 PKU-Market-PCB 增强数据集缺陷检测结果对比

Fig.14 Comparison of Defect Detection Results on the PKU-Market-PCB Enhanced Dataset




图 15 DeepPCB 数据集缺陷检测结果对比

Fig.15 Comparison of Defect Detection Results on the DeepPCB Dataset

4 结束语

针对 PCB 表面微小缺陷定位难及背景纹理干扰等挑战,本文提出一种改进 YOLOv11n 的检测模型 DSDN-YOLO,该模型通过在骨干网络中构建 C3k2_DADC 结构增强了对非结构化缺陷的几何感知能力,并利用颈部的 SCGSFM 模块协同抑制复杂基板的高频纹理噪声,同时结合 DNI 动态结构感知插值与 SA-Loss 尺寸感知损失优化了细长微小目标的边界重构质量与回归稳定性;实验结果表明,DSDN-YOLO

在 PKU-Market-PCB 增强数据集上具有良好的检测性能,在参数量与计算量微增的前提下,其 $mAP@0.5$ 与 $mAP@0.5:0.95$ 分别达到 95.4%和 53.4%,较基准模型提升了 2.7%和 5.1%;同时,准确率与召回率也分别实现了 1.5%和 6.5%的增长。此外在 DeepPCB 数据集上也证明了模型具有较好的泛化能力。未来研究将侧重于模型的量化剪枝与端侧推理加速,旨在进一步提升算法在实际工业流水线中的部署效率与实时响应能力。

参考文献:

- [1] 姜媛媛,蔡梦南.轻量化的印刷电路板缺陷检测网络 Multi-CR YOLO[J].电子测量与仪器学报,2023,37(11):217-224.
JIANG Y Y, CAI M N. Lightweight PCB defect detection network Multi-CR YOLO[J]. Journal of Electronic Measurement and Instrumentation, 2023, 37(11): 217-24.
- [2] 陈锦妮,拜晓桦,李云红,等.基于 PA-YOLO v5 的印制电路板缺陷检测[J].红外技术,2024,46(06):654-62.
CHEN J N, BAI X H, LI Y H, et al. PCB defect detection based on PA-YOLO v5[J]. Infrared Technology 2024,46(06): 654-62.
- [3] 孙铁强,于洪健,张灿,等.基于 YOLO 提示与 ICT-ViT 的印刷电路板缺陷高效分割技术研究[J].激光与光电子学进展,2025,62(12):195-205.

- SUN T Q, YU H J, ZHANG C, et al. Efficient Printed Circuit Board Defect Segmentation Technology Based on YOLO Prompts and ICT-ViT[J]. *Laser & Optoelectronics Progress*, 2025, 62(12): 195-205.
- [4] Ren SH Q, He K M, Ross Girshick, et al. FasterR-CNN: Towards real-time object detection with region proposal networks[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2016, 39(6): 1137-1149.
- [5] 耿朝晖, 龚涛. 基于改进 Faster R-CNN 的 PCB 板表面缺陷检测[J]. *现代计算机*, 2021, (19): 89-93.
- GENG Zhaohui, GONG Tao. PCB Surface Defect Detection Based on Improved Faster R-CNN[J]. *Modern Computer*, 2021, (19): 89-93.
- [6] 吕秀丽, 杨昕升, 曹志民. 改进 YOLOv8 的 PCB 表面缺陷检测算法[J]. *电子测量技术*, 2024, 47(12): 100-108.
- LV X L, YANG X S, CAO Z M. Improved PCB surface defect detection algorithm for YOLOv8[J]. *Electronic Measurement Technology*, 2024, 47(12): 100-108.
- [7] ZHANG T, ZHANG J, PAN P, ZHANG X. YOLO-RRL: A Lightweight Algorithm for PCB Surface Defect Detection[J]. *Applied Sciences*, 2024, 14(17): 7460.
- [8] ZHAO Y, JIANG Z D. YOLO-WWBi: An Optimized YOLO11 Algorithm for PCB Defect Detection[J]. *IEEE Access*, 2025, 13: 74288-74297.
- [9] 黄文杰, 罗维平, 陈镇南, 等. 基于 YOLO11 的轻量化 PCB 缺陷检测算法研究[J]. *广西师范大学学报(自然科学版)*, 2026, 44(01): 56-67.
- HUANG Wenjie, LUO Weiping, CHEN Zhennan, et al. Research on lightweight PCB defect detection algorithm based on YOLO11[J]. *Journal of Guangxi Normal University (Natural Science Edition)*, 2026, 44(1): 56-67.
- [10] JOCHER G, CHAURASIA A, QIU I. Ultralytics YOLOv8[EB/OL]. (2023-1-10)[2025-04-15]. <https://github.com/ultralytics/ultralytics>.
- [11] ALI M L, ZHANG Z. The YOLO framework: A comprehensive review of evolution, applications, and benchmarks in object detection[J]. *Computers*, 2024, 13(12): 336.
- [12] CHEN Y, DAI X, LIU M, et al. Dynamic Convolution: Attention over Convolution Kernels[C]//*Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. Seattle, WA, USA: IEEE, 2020: 11030-11039.
- [13] WANG C X, WANG H R. Cascaded feature fusion with multi-level self-attention mechanism for object detection[J]. *Pattern Recognition*, 2023, 138: 109377.
- [14] WANG J Q, CHEN K, XU R, et al. CARAFE: Content-Aware ReAssembly of FEatures[C]//*Proceedings of the IEEE/CVF International Conference on Computer Vision*. Seoul, Korea (South): IEEE, 2019: 3007-3015.
- [15] Huang Weibo, Wei Peng. A PCB dataset for defects detection and classification[EB/OL]. [2024-11-21]. <https://doi.org/10.48550/arXiv.1901.08204>.
- [16] TANG S, HE F, HUANG X, et al. Online PCB defect detector on a new PCB defect dataset[J]. *arXiv preprint arXiv:1902.06197*, 2019.
- [17] LI C, ZHOU A J, YAO A B. Omni-dimensional dynamic convolution[C]//*International Conference on Learning Representations (ICLR)*. 2022.
- [18] CHEN Z X, HE Z W, LU Z M. DEA-Net: Single image dehazing based on detail-enhanced convolution and content-guided attention[J]. *IEEE Transactions on Image Processing*, 2024, 33: 1002-1015.
- [19] ZHANG X, SONG Y, SONG T, YANG D, YE Y, ZHOU J, ZHANG L. LDConv: Linear deformable convolution for improving convolutional neural networks[J]. *Image and Vision Computing*, 2024, 149: 105151.
- [20] XIONG Y, LI Z, CHEN Y, et al. Efficient deformable convnets: rethinking dynamic and sparse operator for vision applications[C]//*Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. Piscataway, NJ: IEEE, 2024: 5652-5661.

- [21] QIN X Y, LI N, WENG C, et al. Simple attention module based speaker verification with iterative noisy label detection[C]. IEEE International Conference on Acoustics, Speech and Signal Processing, 2022: 6722-6726.
- [22] WOO S, PARK J, LEE J Y, KWEON I S. CBAM: Convolutional block attention module[C]//Proceedings of the European conference on computer vision. Cham: Springer, 2018: 3-19.
- [23] WAN D H, LU R SH, SHEN S Y, et al. Mixed local channel attention for object detection[J]. Engineering Applications of Artificial Intelligence, 2023, 123: 106442.
- [24] REZATOFIGHI H, TSOI N, GWAK J Y, et al. Generalized intersection over union: A metric and a loss for bounding box regression[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Long Beach: IEEE, 2019: 658-666.
- [25] GEVORGYAN Z. SIOU Loss: More Powerful Learning for Bounding Box Regression[Z]. arXiv:2205.12740, 2022.
- [26] ZHANG H, XU C, ZHANG S. Inner-IoU: More Effective Intersection over Union Loss with Auxiliary Bounding Box[Z]. arXiv:2311.02877, 2023.
- [27] Yang J, Liu S, Wu J, Su X, Hai N, Huang X. Pinwheel-shaped Convolution and Scale-based Dynamic Loss for Infrared Small Target Detection[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2025, 39(9): 9202-9210.
- [28] LIU W, ANGUELOV D, ERHAN D, et al. Ssd: Single shot multibox detector[C]//European conference on computer vision. Cham: Springer International Publishing, 2016: 21-37.
- [29] JOCHER G. YOLOv5 by Ultralytics[CP/OL]. 2020[2026-06-08]. <https://doi.org/10.5281/zenodo.3908559>.
- [30] LI C, LI L, JIANG H, et al. YOLOv6: A single-stage object detection framework for industrial applications[Z]. arXiv:2209.02976, 2022.
- [31] WANG A, CHEN H, LIU L, et al. Yolov10: Real-time end-to-end object detection[J]. Advances in Neural Information Processing Systems, 2024, 37: 107984-108011.
- [32] JOCHER G, QIU I. Ultralytics YOLO11[EB/OL]. (2024-09-30)[2025-04-15]. <https://github.com/ultralytics/ultralytics>.
- [33] ZHAO Y, LV W, XU S, et al. DETRs beat YOLOs on real-time object detection [C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2024: 16959-16968.
- [34] 吴葛, 朱宇凡, 贾泽宁. 改进 YOLO11 的 PCB 表面缺陷检测方法[J]. 电子测量技术, 2025, 48(14): 136-145.
WU G, ZHU Y F, JIA Z N. Method for detecting PCB surface defects with improved YOLO11[J]. Electronic Measurement Technology, 2025, 48(14): 136-145.
- [35] WEI M, JI H, WEI J. GESC-YOLO: Improved lightweight printed circuit board defect detection based algorithm[J]. Sensors, 2025, 25(3): 839.