

基于 Transformer 的生产线预测性维护方法

傅朝斌, 马 杰*, 刘 爽, 陈文波, 夏思远, 胡绍雄, 张红波, 罗望丹

(湖北中烟工业有限责任公司 襄阳卷烟厂, 湖北 襄阳 441004)

(* 通信作者电子邮箱 602492259@qq.com)

摘 要: 生产线预测性维护(PM)是一种以设备工作状态为依据的维护决策方式。传统方法依赖规则和人工经验, 预测效率和精度较低; 而机器学习的方法可以从历史数据中学习, 并自动捕捉设备在出现问题前的细微变化。然而, PM 数据通常具有长时间序列和长尾分布等特性, 导致现有的机器学习方法面临精度低和训练效率差的挑战。此外, 现有模型通常只能预测单一的故障类型, 难以处理多种故障和故障之间的关联, 进而限制了预测的准确性。针对以上问题, 提出一种基于 Transformer 多标签分类的故障分类预测模型。首先, 使用 Transformer 编码处理生产线不同设备的数据(如受力、振动等信号), 以捕捉序列中的长期依赖关系, 并提升计算效率; 其次, 通过分类模型分析提取到的特征, 从而识别不同设备的故障类型; 此外, 引入新的标签机制, 以应对设备可能同时存在多种故障的问题; 最后, 基于不同故障类型的维护需求, 使用层次分析法(AHP)进行维护优先级排序, 并最终提供适应性维护方案。针对电机驱动不平衡的问题, 将所提模型与常用的循环神经网络(RNN)、长短期记忆(LSTM)网络和时序卷积网络(TCN)模型进行对比。实验结果表明, 基于 Transformer 多标签分类的故障分类预测模型与上述常用模型相比, 在处理生产线设备故障预测任务时, 具有更高的准确性和更低的分类错误率。

关键词: 预测性维护; 故障预测; Transformer; 深度学习; 层次分析法

中图分类号: TP315 **文献标志码:** A

Transformer-based predictive maintenance method for production lines

FU Chaobin, MA Jie*, LIU Shuang, CHEN Wenbo, XIA Siyuan, HU Shaoxiong,

ZHANG Hongbo, LUO Wangdan

(Xiangyang Cigarette Factory, China Tobacco Hubei Industrial Company Limited, Xiangyang Hubei 441004, China)

Abstract: Predictive Maintenance (PM) in production lines is a maintenance decision-making method based on the equipment operating conditions. The traditional methods rely on rules and human experience, which results in low prediction efficiency and accuracy. At the same time, the machine learning methods can learn from historical data and capture subtle equipment changes before issues arise automatically. However, PM data often have characteristics such as long time series and long-tailed distributions, which poses challenges in terms of prediction accuracy and training efficiency to the existing machine learning methods. Moreover, existing models typically predict a single fault type, making it difficult to handle multiple faults and their correlations, thus limiting prediction accuracy. To address these issues, a fault classification prediction model based on Transformer multi-label classification was proposed. Firstly, Transformer encoding was applied to process data from different production line equipment (e. g., force, vibration signals) to capture long-term dependencies in the sequences and improve computational efficiency. Then, a classification model was used to analyze the extracted features, so as to identify fault types in different equipment. Additionally, a new label mechanism was introduced to address the issue of possible simultaneously-existed multiple faults in pieces of equipment. Finally, maintenance priority sorting was conducted using the Analytic Hierarchy Process (AHP) based on the maintenance requirements for different fault types, and an adaptive maintenance solution was provided ultimately. The proposed model was compared with commonly used Recurrent Neural Network (RNN), Long Short-Term Memory (LSTM) network, and Temporal Convolutional Network (TCN) models for the motor drive imbalance problem. Experimental results show that the Transformer-based multi-label classification fault prediction model has higher accuracies and lower classification error rates when handling production line equipment fault prediction tasks compared to the above mentioned commonly used models.

Key words: Predictive Maintenance (PM); fault prediction; Transformer; deep learning; Analytic Hierarchy Process (AHP)

0 引言

生产线运行过程中面临内部机械设备逐步劣化的情况, 为保证生产线长周期、可靠的运行, 企业一般采用预测性维护(Predictive Maintenance, PM)的方法, 以降低生产线维护成本的同时提高设备乃至生产系统的运作效率^[1]。

生产线的 PM 是一种基于设备状态的事先维护方法^[2]。进行生产线的 PM 的前提是找到设备发生的故障, 因此故障预测是 PM 体系中非常重要的组成部分^[3]。目前, 研究人员提出了多种故障预测方法, 主要分为传统基于物理模型预测和机器学习预测方法。对于传统基于物理模型方法, 阳贤文^[4]、张猛^[5]构建了设

备混合故障演化模型, 实现了对橡胶吸盘生产系统的 PM, 但该方法依赖规则和人工经验, 预测效率和精度较低; 而机器学习的方法可以从历史数据中学习, 自动捕捉设备在出现问题前的细微变化, 故许多研究人员多考虑采用机器学习(如支持向量机(Support Vector Machine, SVM))的方法预测故障, 如戴邵武等^[6]提出了一种滚动轴承整个寿命故障周期退化趋势预测方法, 结合时域特征和 SVM 算法, 实现了轴承退化预测。传统的机器学习方法在面对小规模、结构化数据时表现良好, 但面对具有多设备和大量数据的生产线环境时, 因为这种方法依赖手动特征工程, 无法有效捕捉设备数据的潜在特征且耗时较高, 具有一定的

收稿日期: 2024-10-25; 修回日期: 2025-04-10; 录用日期: 2025-04-16。

作者简介: 傅朝斌(1975—), 男, 广西桂林人, 工程师, 主要研究方向: 智能制造; 马杰(1995—), 男, 河北沧州人, 助理工程师, 主要研究方向: 智能制造; 刘爽(1992—), 女, 湖北随州人, 助理工程师, 硕士, 主要研究方向: 智能制造; 陈文波(1997—), 男, 湖北襄阳人, 助理工程师, 主要研究方向: 智能制造; 夏思远(1995—), 男, 湖北襄阳人, 助理工程师, 主要研究方向: 智能制造; 胡绍雄(1994—), 男, 湖北宜城人, 助理工程师, 主要研究方向: 智能制造; 张红波(1975—), 男, 陕西西安人, 工程师, 主要研究方向: 智能制造; 罗望丹(1978—), 女, 湖北襄阳人, 助理工程师, 主要研究方向: 智能制造。

局限性。因此,一些研究人员提出使用深度学习的方法,能够自动从大量数据中提取复杂的特征和信息。Yan等^[7]提出了一种考虑模型间非线性关系的综合预测方法,并通过铣刀寿命实验进行验证。Liu等^[8]基于采用CNN-LSTM扩大感受野,提高了故障预测精度。虽然循环神经网络(Recurrent Neural Network, RNN)及其变体长短期记忆(Long Short-Term Memory, LSTM)网络已经在时序数据处理中展现了较好的效果,但PM数据通常具有长时间序列和长尾分布等特性,这种序列化处理机制导致模型在长序列数据处理上效率较低,且在面对长尾分布数据时,难以捕捉远距离依赖,可能存在梯度消失等问题。此外,该方法大多只能预测一种故障类别,而生产线中的设备大多存在多种安全隐患,并不符合实际。

结合上述研究的不足,本文面向生产线安全隐患预测,采用Transformer编码器算法架构,以打破传统方法的局限性。Transformer编码器能够通过全局自注意力机制自适应地分配注意力权重,更擅长捕捉长距离依赖和重要性更高的特征,并实现并行化处理,提高效率。此外,本文通过引入新的标签机制,使模型可以预测设备可能同时存在的多种故障。Transformer网络的引入使用户能够更准确、更高效地预测设备可能的故障,避免生产线停机,降低成本,并提高生产效率。生产线设备众多必然会出现不同设备、不同类型的故障,设备维护人员仅依靠自身经验确定维护时机、维护顺序是缺乏依据的,因此引入基于层次分析法(Analytic Hierarchy Process, AHP)的优先级排序,为维护时机的决策提供指导性建议。

1 问题描述

1.1 问题分析

PM的核心任务是通过实时分析生产设备的时序数据,提前预测可能发生的故障,避免设备突发停机或损坏^[9]。在设备运行过程中,故障通常通过综合分析历史数据和实时监控数据,捕捉设备性能的微小变化和异常波动,从而识别潜在的故障风险。通过深度分析设备时序数据,故障预测能够显著提高设备维护的准确性和及时性,降低传统定期检测方法未能及时发现设备亚健康状态的风险,并大幅减少因突发故障引起的生产停滞。

PM数据通常具有长时间序列和长尾分布的特性。其中,长时间序列特性源于工业设备的持续运行和故障发生过程的渐进性变化,需要长期监控和分析设备的历史数据。而长尾分布则是由于正常运行数据占据绝大多数,故障数据稀少且种类多样,导致数据集呈明显的不平衡性。这些特性给传统机器学习模型带来了较大的挑战^[10]。相比之下,Transformer模型通过全局自注意力机制能够同时关注长序列中的重要信息,具备更好的并行处理能力,且它不依赖序列化的处理方式,能够更高效地捕捉设备故障的远距离依赖特征。此外,在应对长尾分布问题时,自注意力机制可以自适应地赋予稀有故障信号更多的关注权重,提升故障预测的敏感性和准确性。

综上,采用Transformer编码器的模型对生产线产生的时间序列数据进行故障预测,去除Transformer解码器在时间序列分类中有助于简化模型结构、减少计算成本和防止过拟合,为PM提供诊断依据。

1.2 时间序列数据

在自动化生产线运行过程中时间序列数据无处不在,但在实际生产过程中,现有研究缺乏对所有设备全生命周期的监控、数据标记,因此想要使用机器学习方法对设备故障预测受到了极大的阻碍。为此,本文针对Transformer模型所需要的时间序列数据,获取了多设备多元时间序列(Multivariate Time Series, MTS)数据,通过维护记录、数据模拟,进行数据收集、建模和标记,实现高效的设备故障预测、分类等功能。

1) 生产线时序数据格式。

自动化生产线生产过程的时序数据包括:度量(Metric)即所监测的设备/零件ID、时间戳(Timestamp)形成数据点的时刻、数据点(Data point)即某时刻所有监测指标的值与监测指标字段

(Filed)即所监测的传感器等的数量值、标签(Tag)等。对于生产线所在环境数据包括温度、湿度等,所有传感器数据包括压力值、振动幅度、频率等,属于监测指标,存储格式为浮点型。

设备状态字段包括正常运行、异常运行,可以使用one-hot编码为0、1整数值,此外剩余使用寿命(Remaining Useful Life, RUL)一般表示为设备距离下一次故障的时间,计算公式如下:

$$V_{RUL} = \frac{t - t_0}{\bar{t}} \quad (1)$$

其中: t 为当前设备/零件使用时间点; t_0 为设备/零件开始使用时间点; $\bar{t}$ 为该设备/零件平均使用时间。

设备维护记录字段一般可以准确地表达该设备/零件真实的使用状态、损害程度。根据维修专家知识、维修所用时间、大修、小修和是否更换零部件,可以为每次记录提供真实有效的设备状态,为设备状态评级。根据级别使用类别标签,为后续预测故障做准备,再得到优先级决策,以期实现自动化生产的高效性。

2) 多元时间序列数据标准化。

多元时间序列是将某个设备所有关联数据按照发生时间的先后顺序,按照记录的值排列成以观测变量轴和时间轴2个维度的矩阵表示,这些变量在时间上相关。某个设备/零件的数据表示形式如图1所示。




图1 生产线某零件/设备状态时间序列

图1中,横轴(时间轴)每个点代表设备/零件监测时间点,纵轴(观测数据轴)分字段表示为设备/零件属性字段、传感器数据字段、环境数据字段、设备状态字段和维护记录字段。随着时间的推移,设备/零件的观测数据形成了多元时间序列,根据设备记录数据,运用深度学习算法可将上述字段分为原始数据与标签。生产线某个设备/零件的多元时序数据定义线性空间表达式如下:

$$X = (x_0, x_1, \dots, x_{N-1})^T \in \mathbb{R}^{N \times D_s} \quad (2)$$

$$S = (s_0, s_1, \dots, s_{N-1})^T \in \mathbb{R}^{N \times D_s} \quad (3)$$

$$R = (r_0, r_1, \dots, r_{N-1})^T \in \mathbb{R}^{N \times D_r} \quad (4)$$

$$H = \{X, S, R\} \in \mathbb{R}^{N \times D} \quad (5)$$

其中: X 表示该设备/零件所有关联值; D_s 表示每个关联值的维度; S 表示该设备/零件状态值; D_s 表示状态值维度; R 表示该设备维护记录值; N 表示时间维度基数; D_r 表示维护记录值维度; $D = D_s + D_s + D_r$ 。因为在深度学习Transformer的输入端为编码器结构,模型训练阶段使用自监督的方法。

输入矩阵如下:

$$\begin{bmatrix} x_i^0 & x_i^1 & \dots & x_i^{D_s-1} \\ x_{i+1}^0 & x_{i+1}^1 & \dots & x_{i+1}^{D_s-1} \\ \vdots & \vdots & & \vdots \\ x_{i+seq-1}^0 & x_{i+seq-1}^1 & \dots & x_{i+seq-1}^{D_s-1} \end{bmatrix}$$

输出矩阵如下:

$$\begin{bmatrix} s_{i+1}^0 & s_{i+1}^1 & \dots & s_{i+1}^{D_s-1} & r_{i+1}^0 & r_{i+1}^1 & \dots & r_{i+1}^{D_r-1} \\ s_{i+2}^0 & s_{i+2}^1 & \dots & s_{i+2}^{D_s-1} & r_{i+2}^0 & r_{i+2}^1 & \dots & r_{i+2}^{D_r-1} \\ \vdots & \vdots & & \vdots & \vdots & \vdots & & \vdots \\ s_{i+seq2}^0 & s_{i+seq2}^1 & \dots & s_{i+seq2}^{D_s-1} & r_{i+seq2}^0 & r_{i+seq2}^1 & \dots & r_{i+seq2}^{D_r-1} \end{bmatrix}$$

其中:输入矩阵为设备或零件在多个时间步上的多元时序数据,输出矩阵为模型基于输入数据生成的预测或重构结果。

向量序列Input($x_i, x_{i+1}, \dots, x_{i+seq-1}$)是从向量 S 中使用采样长 seq 得到,预测向量Output($s_{i+1}, r_{i+1}, s_{i+2}, r_{i+2}, \dots, s_{i+seq2}, r_{i+seq2}$)为运行状态编码, $seq2$ 表示输出矩阵的时间窗口长度。

1.3 时序数据预处理

对于生产线的不同种类的数据采集过程中,因来源不同、持续时间较长、数据量较大等原因,常出现一系列的数据质量问题,例如传感器故障、网络传输问题和人为记录错误等,这些情况常导致数据集中产生零散和明确的数据值缺失。而时间序列数据的数值缺失会对预测和模型产生严重的不利影响。对于这类数据,一般有删除和填充两类处理方法。由于本文采用的数据集是设备振动数据,且同一类型设备存在多个振动传感器,相互之间具有相似性,因此采用相邻传感器的数据值进行填充。

在生产设备振动数据的采集过程中,存在传感器采样频率不一致、网络传输延迟和时钟偏差等问题,常导致时间序列的时间戳不同步。这种时间对齐问题会破坏数据的时序关联性,进而影响模型的预测性能。为解决这一问题,本文采用动态时间规整(Dynamic Time Warping, DTW)方法进行时间对齐。DTW通过动态规划计算多条时间序列的最优匹配路径,从而在非线性时间轴上实现序列间的对齐。本文以主传感器数据作为基准序列,对其他传感器数据分别计算局部距离矩阵,并通过累积距离最小化原则找到匹配路径。对齐过程中,为提升计算效率,采用Sakoe-Chiba约束限制路径搜索范围,并对长序列进行分段处理。通过该方法,有效解决了多传感器时间序列的不同步问题,确保了输入模型的数据具有一致的时序结构,从而为预测性能的提升提供了保障。

此外,在使用深度学习算法过程中,数据标准化是预处理的重要环节。它可以消除不同特征之间的尺度差异,提高模型在训练过程中的稳定性和收敛效果。其次,通过对输入数据进行合适的标准化,深度神经网络能够更好地适应数据的敏感性,加速模型的收敛,防范梯度相关问题,并能够提高模型对未见数据的泛化性能。目前,这一步骤常使用Z-Score标准化和Min-Max缩放标准化。

Z-Score标准化的主要目的是将不同量级下的数据统一到同一量级,保证数据之间的可比性。数据将转化为均值为0、标准差为1的标准正态分布。为了避免标准化数据与原始数据差距过大,该处理过程要求数据分布在近似正态分布下,公式如下:

$$x_{\text{nom}} = \frac{x - \mu}{\sigma} \quad (6)$$

其中: x_{nom} 为经过标准化的值; x 为原始数据值; μ 为原始数据值的平均值; σ 为原始数据值的标准差。

Min-Max缩放标准化是通过线性变化的方式,将所有数据缩放到给定的最大值和最小值之间。对数据进行简单的缩放处理不会改变数据点之间的分布,通常将数据归一到0~1,以适应深度学习数据运算。公式如下:

$$x_{\text{nom}} = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (7)$$

其中: $x_{\max}$ 为原始数据值的最大值; $x_{\min}$ 为原始数据值的最小值。

1.4 基于Transformer编码器的电机故障多分类模型

本文采用Transformer的自注意力机制深度捕捉生产线运行过程中周期性参数的内在时间依赖性。引入位置编码以保持过程数据中的时间顺序信息,从而拥有处理序列顺序的内在机制。通过调整层数或头数适应数据量和复杂度,Transformer解决了LSTM无法利用GPU并行计算的问题,提高了时间序列数据的预测准确性和实时性。在生产线维护过程中,无需停机或在基本不拆卸设备的情况下,能够及时发现潜在的失效模式或趋势,以便快速制定符合条件的维护措施,消除生产线运行中的潜在风险。

本文所提网络架构如图2所示,其中包括了输入层、4层Transformer编码器、全连接层、Softmax层和输出层。Transformer编码器通过自注意力机制提取特征。自注意力机制允许模型在处理序列数据时动态地关注序列中不同位置的信息,从而更好地捕捉序列中的长距离依赖关系。特征提取可以将某一时刻设备的多维属性监测信息转化为自然语言处理领域的词向量。该方法的特点是通过词嵌入的方式将原始数据转化为向量形式,以最大限度地保留原始信息,能适应不同长度的时间序列。因为监测信息会被转化为固定长度的词向量,而不需要预先定义

固定的时间窗口或序列长度。




图2 Transformer编码器多分类模型

1.4.1 输入编码

将时间序列作为输入,其中每个时间点的所有观测数据作为一个特征向量,为了使用自注意力机制,并提取更深层次的特征,使用嵌入层,将特征向量映射到更高维度的表示。

1.4.2 位置编码

由于Transformer模型没有内置对序列的位置信息进行建模的机制,为了保证时间序列的时序性,Transformer模型引入了绝对位置编码,每个位置都会有一个唯一的位置编码向量,而不同维度的位置编码向量则包含不同频率的正弦和余弦函数,这使得模型可以学习到输入序列中元素的位置信息。计算公式如下:

$$PE_{(pos, 2i)} = \sin\left(\frac{pos}{1000^{2i/d_m}}\right) \quad (8)$$

$$PE_{(pos, 2i+1)} = \cos\left(\frac{pos}{1000^{2i/d_m}}\right) \quad (9)$$

其中: pos 代表位置; i 代表维度; d_m 是模型参数。上述公式的含义是将 pos 位置的信息映射成为一个 d_m 维的位置向量。

1.4.3 多头自注意力机制

注意力机制如式(10)所示,因为 Q, K, V 分别通过 X 经过不同参数矩阵的线性变化得到,所以称作自注意力机制。由于 X 通过不同变化,可以增加学习参数,使得自注意力机制能够关注输入序列的不同部分,增强了模型的表达能力,进而使模型能够在处理序列数据时更灵活地学习和表达不同位置之间的关系。为了更全面、灵活地捕捉序列中的信息,提高模型性能和泛化能力。源于多通道图像卷积思想,多头自注意力模块如图3所示,对 X 进行多次自注意力计算,从而得到多个注意力头。然后,对输出 W 进行多头合并,再经过线性变化 W 得到最终输出结果:

$$\text{Multi}(Q, K, V) = \text{Concat}(\text{head}_1, \text{head}_2, \dots, \text{head}_n)W \quad (10)$$

$$\text{head}_i = \text{Attention}(XW_i^Q, XW_i^K, XW_i^V) =$$

$$\text{Attention}(Q_i, K_i, V_i) = \text{Softmax}\left(\frac{Q_i K_i^T}{\sqrt{d_k}}\right)V_i \quad (11)$$

其中: head_i 表示第 i 个注意力头; d_k 为注意力头维度; k 明确关联到“键(Key)”; W 是多头自注意力机制输出矩阵的权重参数矩阵; Q_i, K_i, V_i 分别为查询矩阵、键矩阵、值矩阵; W_i^Q, W_i^K, W_i^V 分别为输

入序列的不同注意力头的参数矩阵。




图3 多头自注意力结构

1.4.4 残差连接和层归一化

使用残差连接和层归一化增强模型的训练稳定性。在深层神经网络训练过程中,常出现梯度爆炸和梯度消失。为了解决这一问题,He等^[11]在处理图像分类问题中创造性地提出了使用残差连接的ResNet。如式(12)所示,在残差连接中,每个残差块包含了一个主要的路径和一个捷径或跳跃连接。主要的路径执行了一系列的变换,捷径直接将输入或经过轻量级的变换后的输入叠加到主要路径的输出上。这种连接方式使网络可以学习残差,即学习将输入映射到与它对应的输出之间的差异。

$$y=f(x,\{w_i\})+x$$
 (12)

其中: x 为输入; $f(x,\{w_i\})$ 为经过主要路径变换, $\{w_i\}$ 是主要路径中的权重参数; y 为输出。

1.4.5 前馈神经网络

前馈神经网络是一种由全连接层组成的常见神经网络结构,它通过自注意力机制层的特征进行非线性变换,通过一系列的线性和非线性变换,整合和处理输入信息。式(13)表示输入到输出的映射过程,其中通过矩阵相乘和激活函数的运算完成了特征的变换和非线性映射。在实际应用中,通过调整权重和偏置,网络可以学习逼近复杂的非线性函数关系。假设输入层有 n 个特征,隐藏层有 p 个神经元,输出层有 k 个神经元,激活函数为 σ_i ; x 为输入向量,维度为 n 。 r 为输出,维度为 p 。

$$r=\sigma_1(W_{hidout}\cdot\sigma_0(W_{hidin}\cdot x+b_{hid})+b_{out})$$
 (13)

其中: W_{hidin} 是输入层到隐藏层的权重矩阵,维度为 $p\times n$; b_{hid} 是隐藏层的偏置向量,维度为 p ; σ_0 是隐藏层的激活函数; W_{hidout} 是隐藏层到输出层的权重矩阵,维度为 $k\times p$; b_{out} 是输出层的偏置向量,维度为 k ; σ_1 是输出层的激活函数。

1.4.6 叠加多个编码器

堆叠更多的编码层有助于模型学习更复杂的特征表示。如图2所示,首先,某时刻多元数据 x_i 通过位置编码叠加位置信息。其次,将得到的多元数据 x_i 输入多头自注意力机制层,对多元时序数据 $(x_0,x_1,\cdots,x_{N-1})$ 所表示的信息进行自注意力机制运算,得到表征向量 z_i ,使得 $(z_0,z_1,\cdots,z_{N-1})$ 成为具有位置特征、语义特征的序列。为避免自注意力运算过程中出现梯度消失和梯度爆炸,对后向序列与前向序列进行残差连接,并进行层归一化,得到后续序列 $(z_0,z_1,\cdots,z_{N-1})$ 。再次,使用前馈神经网络对序列数据进行非线性变化激活处理,得到 $(r_0,r_1,\cdots,r_{N-1})$ 。最后,经过

数次Transformer编码器结构,对数据进行深层次处理,其中 N 表示序列中第 N 个时间步的数据。

1.4.7 池化层

采用全局最大池化(Global Max Pooling, GMP),取每个特征维度上的最大值,进一步将序列特征压缩为固定长度的向量表示,方便后续分类任务。

1.4.8 全连接层和Softmax层

全连接层是用于从Transformer编码器模型的高级特征生成原始预测分数,使用Softmax层则将这些分数映射为类别概率分布,使得模型输出更易解释且适应多分类损失函数。

1.5 基于AHP的优先级排序的维护时机决策方法

对于检查出故障的设备,可以考虑使用AHP对多设备维修任务进行优先级评价。综合考虑设备故障评级rank、设备重要性指数key、历史维修频率f、设备价值value,建立判断矩阵 u 如下:

$$u=\begin{matrix} & \begin{matrix} \text{rank} & \text{key} & f & \text{value} \end{matrix} \\ \begin{matrix} \text{rank} \\ \text{key} \\ f \\ \text{value} \end{matrix} & \begin{bmatrix} 1 & a_{1,2} & a_{1,3} & a_{1,4} \\ & 1 & a_{2,3} & a_{2,4} \\ & & 1 & a_{3,4} \\ & & & 1 \end{bmatrix} \end{matrix}$$
 (14)

准则因素行列所对应的值表示两者之间的重要程度,一般由专家打分、问卷调查、实验等方式获取,大于1则表述此列对应元素重要性强于此行对应元素。通过计算矩阵 u 的最大特征根 $\lambda_{\max}$,得到它对应的特征向量 $w=(w_1,w_2,\cdots,w_m)$,即为优先级评定的各因素权重系数,其中 m 表示判断矩阵 u 的阶数。为保证各评价指标次序无误,需要对特征根进行一致性检验,通过一致性检验的权重参数,才更具科学性、可靠性。

2 实验与结果分析

2.1 实验设置与结果

电机驱动在工业生产线中扮演着至关重要的角色,几乎所有驱动都涉及旋转驱动。然而,旋转轴上的不平衡可能导致轴承或其他机械部件的寿命缩短。因此,及早发现不平衡问题对于降低维护成本、避免不必要的生产停滞,并提高设备寿命具有重要意义^[12]。通过对旋转轴上振动的分析,可以有效检测不平衡或发现对其他被连接设备的潜在损害,这已经被证明是一种前景广阔的方法^[13]。

本文采用了在CHIST-ERA SOON项目的框架^[14]内获得的电机振动数据集,该数据集包含振动传感器提供的数据,这些数据可用于设计和测试一般分类问题或更具体问题(如PM)的深度学习算法。

Gligor等^[14]开发了一种基于ESP32 SoC的实验传感器装置,用于电机主轴监测振动等参数。每个文件名都编码如何获得数据,并隐式地编码数据标签。在本文实验中,使用2个电机,分别命名为m1和m2,其中m1是被测试的电机,m2是环境电机,用于获得更复杂的测试环境(如补充噪声源)。数据集的组织方式如表1所示。

表1 CHIST-ERA SOON 电机振动数据集

类别	数据描述	数据量	占比/%	类别标签
无负载正常运行	无机械负载,设置在最大轴转速的一半	107 336	9.06	0
负载正常运行	机械负载扭矩为0.5 N·m,设置为最大轴转速的一半	102 909	8.69	1
负载轴错位	机械负载扭矩为0.5 N·m,设置为最大轴转速的一半,在轴处存在机械不平衡	151 093	12.75	2
电气故障	无机械负载运行,设置为最大轴转速的一半,100 Ω电阻模拟电气故障	101 854	8.60	3
带负载的电气故障	机械负载扭矩为0.5 N·m,设置为最大轴转速的一半,100 Ω电阻模拟故障	103 376	8.73	4
轴错位和电气故障	扭矩为0.5 N·m,轴错位,设置为最大轴转速的一半,50 Ω电阻模拟故障	150 463	12.70	5
正常运行、高噪声	无机械负荷运行,设置在最大轴转速的一半,m2接近运行	102 111	8.62	6
正常运行、负荷、高噪声	机械负载扭矩为0.5 N·m,设置为最大轴转速的一半,m2接近运行	104 468	8.82	7
轴错位、高噪声	扭矩为0.5 N·m,轴错位,设置为最大轴转速的一半,m2接近运行	151 017	12.75	8
轴错位、电气故障、高噪声	轴错位,设置在最大轴转速的一半,100 Ω电阻模拟故障,m2振动接近运行	110 081	9.29	9

表1为持续运行电机的状态数据,其中每类数据在100 000条以上,包括无负载正常运行、正常运行、轴错位故障、电气故障和存在高噪声影响等正常与非正常运行样本。将所有样本按照

时间序列提取,并按照6:2:2划分训练集、测试集和验证集,统计故障预测结果。

本节故障分类任务为多类别分类问题,其中每个样本只属

于一个类别。为了引导模型学习准确的分类决策,提高模型在复杂任务上的性能,采用多元交叉熵损失函数:

$$loss = - \sum_{i=1}^c y_i \log y_{i_pre} \tag{15}$$

其中: c 为分类总数; y_i 为某分类的标签值,只能为0或1; y_{i_pre} 是在Softmax层前面输出的概率值, i_pre 表示模型对第*i*个类别的预测概率。使用单热编码,对于每个样本,使用一个长度*k*的二进制向量,其中只有一个元素为1,表示该样本属于相应的类别。

此外,为评估模型分类性能,计算准确率、精确度、召回率和F1分数等评估指标,建立混淆矩阵,展示模型在测试集上的预测结果与实际标签之间的关系,以了解模型在各类别上的性能表现。

本文模型是在一台配备了GTX 3060显卡的服务器上运行的,在PyCharm上配置Python 3. 9. 16+PyTorch 2. 0. 0+CUDA 11. 8版本的深度学习框架,并使用scikit-learn 1. 2. 2、numpy 1. 24. 3、matplotlib 3. 7. 1、pandas 1. 5. 3等版本的机器学习数据处理库。

根据上述对数据集划分方法,对模型进行调优实验,Transformer编码器模型参数优化结果如表2所示。

表2 Transformer编码器模型参数优化

窗口大小	迭代次数	学习率	优化算法	准确率
50	50	0.000 01	AdamW	0.992
50	50	0.000 10	AdamW	0.997
100	50	0.000 01	AdamW	0.991
100	50	0.000 10	AdamW	0.996
200	50	0.000 01	AdamW	0.997
200	50	0.000 10	AdamW	0.999
200	150	0.000 10	SGD	0.982

由表2可得出结论,在相同学习率和相同优化算法下,窗口大小为200的条件下准确率最高。相同学习率下,对比随机梯度下降优化(Stochastic Gradient Descent, SGD)算法使用AdamW(Adam with decoupled Weight decay)优化算法所得模型的准确率更高,且使用SGD需要迭代次数更多。对比不同窗口下的准确率,均超过了0.990,该预测过程对数据窗口的敏感度较低,适合不同时间内的故障预测。

因此,最终使用叠加了4层的Transformer编码器结构和8头注意力机制。训练过程中使用优化器AdamW,最终使用学习率为0.000 10。批处理batchsize大小选用128,数据采样步长为10,采样窗口大小为200,迭代50个epoch。

为了对比,同样使用RNN、LSTM网络和时序卷积网络(Temporal Convolutional Network, TCN)模型分别进行训练解决该多目标分类任务,考虑训练成本等因素经调试对比后分别取得最优参数如表3所示。

表3 对比实验参数优化

模型	窗口大小	迭代次数	batchsize	学习率	优化器	准确率
RNN	200	50	128	0.000 1	Adam	0.934
LSTM	200	50	128	0.000 1	Adam	0.976
TCN	200	50	128	0.000 1	Adam	0.974

2.2 结果分析

在实验过程中划分轴的10个不同状态类,在训练阶段的训练准确率接近100%。Transformer编码器模型使用优化器AdamW时,训练集总损失逐步趋近于0.000 8,验证集总损失逐步趋近于0.000 8;在使用优化器SGD时,训练集总损失逐步趋近于3.413 9,验证集总损失逐步趋近于0.711 8。对于验证测试过程中的准确率,Transformer编码器模型使用优化器AdamW相较于使用优化器SGD时提升了1个百分点。使用优化器AdamW和优化器SGD损失函数和准确率函数如图4~5所示,在开始阶段,2种优化器的损失均有较大的波动,但随着训练的进行,损失逐渐趋于稳定,并最终收敛到一个较小的值。与损失函数相反,准确率的增加意味着模型在训练数据上的性能不断提升。在开始阶段,准确率较低,但随着训练的进行,准确率逐渐提高,并最终趋

于稳定。




图4 Transformer编码器模型优化器AdamW损失与准确率




图5 Transformer编码器模型优化器SGD损失与准确率

RNN模型、LSTM网络模型和TCN模型的损失和准确率如图6~8所示。三者的训练准确率均在90%以上,但与RNN相比,LSTM网络模型和TCN模型的准确率高5个百分点。




图6 RNN模型损失与准确率




图7 LSTM网络模型损失与准确率




图8 TCN模型损失与准确率

针对本文实验中长时序数据的处理,LSTM网络模型因它的长记忆的特性表现,明显优于RNN,但由于数据长尾分布的特点,LSTM和RNN的表现都明显次于Transformer编码模型。此外,TCN模型虽然能够处理长时序数据,但在处理长尾分布特征时,表现仍不如Transformer模型。

如图9所示,在轴运动状态10个类别的分类过程中,Transformer编码器结构模型分类效果达到了理想水平。




图9 Transformer编码器模型混淆矩阵

图9中,纵轴为电机实际运行状态,横轴为预测电机运行状态,数值0~9分别表示10种运行状态,位于对角线的深色块表示分类正确类别数,其余方块为预测错误的样本数。通过图9可见,无负载正常运行标签为0的运行状态的1569个样本全部预测正确,负载正常运行标签为1的运行状态的1536个样本全部预测正确,其余样本同上。大多数情况下可对所选的样本得到正确分类,使用Transformer编码器模型对故障分类的混淆率较低。

图10~12分别为RNN、LSTM网络模型和TCN模型的混淆矩阵效果图,可以看出因为训练数据长尾分布的特点,对比模型或多或少都出现了对于高频数据类别过于敏感而忽视相对低频数据类别的问题。




图10 RNN模型混淆矩阵




图11 LSTM网络模型混淆矩阵




图12 TCN模型混淆矩阵

综合实验结果,Transformer编码器模型能够更好地实现生产线状态实时预测,该模型可以更有效完成生产线设备故障预测任务。

Transformer模型通过全局注意力机制实现特征提取,其中注意力权重的分布直接反映了模型对不同时间步(或位置)特征的关注程度^[15]。因此本文通过提取自注意力权重分布的方法,判断模型是否能够有效捕获长时间序列中的远距离依赖关系。

绘制Transformer模型注意力矩阵的热力图,如图13所示。

可以看出,query对不同的key具有不同的关注度(即不同的活跃度,活跃度越高,自注意力得分越高)。每个点的颜色深浅表示在某个查询位置上对输入序列中各个位置的注意力权重。从图13中可以看出,注意力分布不是局限于局部(如仅靠近对角线),而是散布在整个序列范围内,这表明模型能够捕获全局的远距离依赖信息。




图13 自注意力权重分布热力图

2.3 优先级排序的维护决策

为进行维护优先级排序的决策分析,将表1中的10种电机运行状态类别作为评估对象,并为每一项设定了故障等级(Rank)、重要性指数(Key)等评估参数,以此构建层次分析法所需的判断数据,具体数值如表4所示。

表4 各运行状态的维护优先级评估参数

设备序号	Rank	Key	f/年	Value/万元
1	1	3	1	1.0
2	2	4	1	1.2
3	4	6	3	0.8
4	3	7	4	1.5
5	5	8	5	1.8
6	6	9	6	2.0
7	7	5	2	0.9
8	8	6	3	1.1
9	9	7	4	0.7
10	10	10	5	2.5

根据专家经验,建立判断矩阵如下:

$$\begin{matrix} & \text{rank} & \text{key} & f & \text{value} \\ \text{rank} & & & & \\ \text{key} & & & & \\ f & & & & \\ \text{value} & & & & \end{matrix} u = \begin{bmatrix} 1 & 4 & 3 & 2 \\ & 1 & 2 & 1 \\ & & 1 & 0.5 \\ & & & 1 \end{bmatrix}$$

根据判断矩阵得到最大特征值 $\lambda_{\max}$ 为4.10,则各指标的权重向量为:

$$w = \begin{bmatrix} w_{\text{rank}} \\ w_{\text{key}} \\ w_f \\ w_{\text{value}} \end{bmatrix} = \begin{bmatrix} 0.4872 \\ 0.1833 \\ 0.1164 \\ 0.2131 \end{bmatrix}$$

代入权重向量计算每个设备的评分并排序得到优先维护顺序为:设备10(7.81975)→设备9(6.28207)→设备6(5.69750)→设备8(5.58001)→设备5(4.86898)→设备7(4.75149)→设备3(3.56828)→设备4(3.52935)→设备2(2.07932)→设备1(1.36660)。

3 结语

针对现有生产线PM数据所存在的长序列、长尾分布的特性,本文提出一种基于Transformer编码器的故障分类预测模型。使用Transformer编码能够更好地捕捉序列中的长期依赖关系,而且由于可以并行处理整个序列,具有更高的计算效率的优势。对生产线的不同设备数据(受力、振动等信号)进行特征提取,通过分类模型得出不同设备的故障类型。然后结合不同类型故障

维护需求,使用层次分析法进行维护优先级排序,并最终提供适应性维护方案。通过实验结果验证了模型的可行性和有效性,实现生产线状态预测实时性和维护方案自适应性。该方法在提高维护效率和降低成本方面具有实际应用潜力。

然而,尽管本文模型取得了较好的成果,但在实际应用中仍然需要进一步探索。首先,尽管Transformer模型在处理长时间序列数据方面表现优异,但它的计算复杂度较高,未来可以考虑进一步优化模型结构,降低计算成本,提升在大规模生产线环境中的实时性和资源利用率。其次,本文主要针对单一场景下的设备故障预测,未来可以扩展到多场景或跨领域的预测任务中,探索模型的迁移学习能力,提升它的泛化性能。此外,随着工业物联网和5G技术的发展,设备传感器数据的获取和传输将更多样化和实时化,如何有效融合多源异构数据,提高模型的预测能力和决策支持能力将是未来研究的一个重要方向。

参考文献 (References)

- [1] 高晗. 基于深度学习的复杂工况下机械设备预测性维护方法研究[D]. 杭州:浙江大学, 2022.
- [2] 廖志伟. 基于机器学习的机电设备运行状态预测[J]. 煤炭技术, 2024, 43(5): 288-291.
- [3] 陈金马. 机械专业设备维护中的预测性维护策略与技术进展[C]// 教育发展与科学研究论坛论文集. 北京:中国自动化学会智慧教育专业委员会, 2024:1-5.
- [4] 阳贤文. 汽车空调橡胶吸盘生产线预测性维护系统研究[D]. 杭州:浙江大学, 2021.
- [5] 张猛. 面向焊接自动化生产线的动态预防性维护方法设计与实现[D]. 成都:电子科技大学, 2016.
- [6] 戴邵武,陈强强,丁宇. 基于时域特征的滚动轴承寿命预测[J]. 计算机测量与控制, 2019, 27(10): 60-63.
- [7] YAN T, LEI Y, LI N, et al. Online joint replacement-order optimization driven by a nonlinear ensemble remaining useful life prediction method [J]. Mechanical Systems and Signal Processing, 2022, 173: No. 109053.
- [8] LIU C, ZHU H, TANG D, et al. Probing an intelligent predictive maintenance approach with deep learning and augmented reality for machine tools in IoT-enabled manufacturing [J]. Robotics and Computer-Integrated Manufacturing, 2022, 77: No. 102357.
- [9] PECH M, VRCHOTA J, BEDNÁŘ J. Predictive maintenance and intelligent sensors in smart factory [J]. Sensors, 2021, 21 (4) : No. 1470.
- [10] ZHANG X, FANG Z, WEN Y, et al. Range loss for deep face recognition with long-tailed training data[C]// Proceedings of the 2017 IEEE International Conference on Computer Vision. Piscataway: IEEE, 2017: 5419-5428.
- [11] HE K, ZHANG X, REN S, et al. Identity mappings in deep residual networks [C]// Proceedings of the 2016 European Conference on Computer Vision, LNCS 9908. Cham: Springer, 2016: 630-645.
- [12] CHIN J W, KIM D J, PARK S, et al. Comprehensive experimental study on shaft voltage of traction motor with ceramic bearing for electric vehicles [C]// Proceedings of the 2023 IEEE Vehicle Power and Propulsion Conference. Piscataway: IEEE, 2023:1-6.
- [13] WANG G D, FENG A D, XIE C L, et al. Vibration and stability analysis of a spinning shaft with arbitrary boundaries subjected to partial load [J]. Journal of Vibration and Control, 2024, 30 (5/6) : 1378-1390.
- [14] GLIGOR A, IANTOVICS L B, TURC A. Electric motor vibrations dataset[DS/OL]. [2024-09-10]. <https://zenodo.org/records/6473455>.
- [15] 房佳姝,刘崇茹,苏晨博,等. 基于自注意力Transformer编码器的多阶段电力系统暂态稳定评估方法[J]. 中国电机工程学报, 2023, 43(15): 5745-5758.