

基于 YOLO11n 的非机动车辆轻量化目标检测模型

汪立远¹, 罗亚波¹, 张 峰^{1*}, 黄 随²

(1. 武汉理工大学 机电工程学院, 武汉 430070; 2. 湖北天威汽车有限公司, 湖北 随州 441300)

摘 要: 针对洒水车智能喷洒中非机动车辆检测算法复杂度高、多尺度目标检测困难等问题,提出一种基于 YOLO11n 的轻量化目标检测模型。基于 YOLO11n 模型,设计了轻量化多尺度骨干网络,将传统下采样模块替换为轻量级自适应提取模块。提出多尺度卷积模块 C3k2-MSCB,并引入大核注意力机制改进 C2PSA,以减少模型的参数量,提升模型对多尺度信息的检测能力。使用基于卷积神经网络的跨尺度特征融合模块替换原模型颈部网络,进一步缩小模型大小,提高检测效率。实验结果表明,在自建的非机动车辆数据集上,相较于基准模型,改进的 YOLO11n 模型的参数量、GFLOPs 和模型大小分别降低了 46.3%, 20.3% 和 42.9%, 同时 mAP@50 提升了 0.3%, 为洒水车智能喷洒系统提供了可靠的支持。

关键词: YOLO11n; 主干网络; 轻量化; 多尺度; 洒水车; 非机动车辆

中图分类号: TP183; TP391.41 **文章编号:** 1001-5868(2026)01-0131-09

Lightweight Object Detection Model for Non-Motor Vehicles Based on YOLO11n

WANG Liyuan¹, LUO Yabo¹, ZHANG Feng¹, HUANG Sui²

(1. School of Mechanical and Electrical Engineering, Wuhan University of Technology, Wuhan 430070, CHN;

2. Hube Tianwei Automobile Co., Ltd., Suizhou 441300, CHN)

Abstract: A lightweight object detection model based on an improved YOLO11n is proposed to address the high computational complexity and the difficulty of detecting multiscale objects in the intelligent spraying of non-motor vehicles by sprinkler trucks. Building on the YOLO11n framework, a lightweight multiscale backbone network, termed lightweight multiscale backbone, is introduced, in which the conventional downsampling module is replaced with a lightweight adaptive ext module. The C3k2-multiscale convolution block incorporates a large-kernel attention mechanism, and a large separable kernel attention module is further proposed to enhance channel-and-spatial self-attention, thereby reducing model parameters and improving multiscale feature representation. In addition, convolutional neural network-based cross-scale feature fusion is employed to further reduce model size and improve detection efficiency. Experimental results demonstrate that, on a self-built non-motor vehicle dataset, the improved YOLO11n model reduces the number of parameters, GFLOPs, and model size by 46.3%, 20.3%, and 42.9%, respectively. Compared with the baseline model, mAP@50 increases by 0.3 percentage points, providing accurate and reliable support for intelligent spraying systems for sprinkler trucks.

Key words: YOLO11n; backbone; lightweight; multiscale; sprinkler truck; non-motor vehicle

收稿日期: 2025-07-17.

基金项目: 校企合作攻关项目([2023]58, 2023DJC082, 20231h0215).

* 通信作者: 张 峰

0 引言

在城市环境中,洒水车作为维护城市清洁和绿化的重要组成部分,其日常作业对于保持城市卫生和生态环境平衡至关重要^[1]。然而,传统洒水车在执行任务时,常采用固定作业模式进行洒水,这种做法在一定程度上会对非机动车辆造成不便,进而形成潜在的交通安全隐患^[2-3]。因此,实现洒水车智能化,其核心在于能够快速、准确地识别非机动车辆,从而为智能喷洒决策系统提供关键信息。

目前,洒水车智能化喷洒的研究主要集中在行人检测与建立防喷溅系统两方面。张谦^[4]提出一种基于多传感器信息融合的洒水车行人防喷溅系统,基于改进的YOLOv4检测行人,并与毫米波雷达进行特征融合,从而感知行人目标信息,同时该研究建立了洒水车行人防喷溅系统模型,实现洒水车行人防喷溅控制。熊文军等^[5]提出一种智能监测和控制系统,该系统集成多种技术实现清洁车的智能化控制,采用超声测距模块避免碰撞,运用YOLOv4算法检测行人和减速带,使用VGG16网络进行垃圾量化进而调节清扫功率,通过CAN通信模块实现对清洁车设备的实时控制,采用多线程实现多任务算法之间的协调与通信。陈增志^[6]设计一种洒水车定量喷洒控制系统,采用车载控制器闭环控制柱塞变量泵的比例阀,并结合PID算法实现洒水车的定量喷洒控制,对喷洒量及喷洒范围进行定量调节,但该系统仍需要人工操作,效率较低。

然而,洒水车在行进过程中不仅会对行人造成影响,还会对路边的非机动车辆造成影响。当前非机动车辆检测领域的研究主要集中于违规行为识别及安全头盔佩戴检测等衍生应用,而针对非机动车辆本体检测的研究仍显不足。Jing等^[7]通过构建混合注意力机制增强局部特征响应,同时结合Transformer模块实现跨尺度上下文建模,提出一种用于非机动车头盔佩戴检测的目标检测网络YOLO-HD,实现对非机动车辆是否佩戴头盔的检测。Li等^[8]通过改进YOLOv4-Tiny,提出一种轻量化模型D-YOLO,通过剪枝减少冗余模型参数量,在CSPNet中融合膨胀卷积与深度可分离卷积,引入CA注意力机制,有效压缩了模型大小,但模型精确性仍有待提升。王博等^[9]结合定位损失、训练策略以及特征网络优化算法三个方面,改进了Faster R-CNN,提升非机动车辆检测与识别的准确率及可

靠性。王林等^[10]针对道路监控下因监控探头高度和角度不同,融合VovNet网络和可变形卷积优化YOLOv5网络,缓解了非机动车辆漏检误检现象。

在以往针对非机动车辆的研究中,虽然在提升检测精度方面取得了显著进展,但这些技术往往需要复杂的计算资源和昂贵的硬件支持,难以在资源有限的嵌入式设备上实现有效部署。而洒水车作为一种经济型商用车辆,其设备预算相对有限。同时,洒水车在动态行驶工况下对非机动车辆进行实时检测时,由于相对位置的变化,目标物体会呈现出显著的多尺度特征变化。鉴于此,本文提出一种基于YOLO11n的非机动车辆轻量化目标检测模型。该模型在YOLO11n骨干网络的基础上,设计了轻量化多尺度骨干网络(LMBNet),引入轻量级自适应提取(LAE)模块,采用多尺度卷积模块(MSCB)模块改进C3k2,引入大核注意力机制(LSKA)改进C2PSA,提出C2PSA-LSKA特征提取模块,替换原有颈部网络为基于卷积神经网络的跨尺度特征融合(CCFM)模块。通过这些改进,模型的参数量和计算量得到了显著减少,使其在计算资源有限的嵌入式设备中也能正常运行,同时增强了模型对多尺度物体的检测精度。

1 YOLO11n模型概述

2024年美国公司Ultralytics提出的单阶段目标检测模型YOLO11有五个版本:YOLO11n, YOLO11s, YOLO11m, YOLO11l和YOLO11x,其模型复杂度按照n到x依次递增。与之前的版本相比,YOLO11模型特别擅长小物体检测,并且在保持高精度的同时,能维持实时检测的速度^[11-12]。类似地,YOLO11也由骨干网络(Backbone)、颈部网络(Neck)和检测头(Head)三部分组成。

YOLO11的骨干网络由Conv, C3k2, SPPF和C2PSA四个模块组成。YOLO11将C2f模块替换为C3k2模块,使用两个较小的卷积操作代替单一大卷积,减少了计算负担,加快了处理速度。同时在C2机制内部嵌入了一个多头注意力机制,即C2PSA机制,增强了YOLO11的特征提取能力。

YOLO11的颈部网络负责连接骨干网络和检测头,进行特征融合和增强。与骨干网络一样,采用C3k2模块替换了C2f模块,通过上采样和下采样操作,将不同层级的特征图进行有效融合,最终输

出到检测头。

YOLO11的检测头将从颈部网络传递过来的多尺寸特征图转换成最终的检测结果, YOLO11的检测头加入了两个深度可分离卷积DWConv, 减少了参数数量和计算量。

2 YOLO11n模型改进

2.1 轻量化多尺度骨干网络LMBNet设计

尽管YOLO11n的骨干网络采用C3k2模块替换C2f, 并引入C2PSA模块, 增强了特征提取能力, 但在减轻模型负担方面并未有显著的提升。同时, 在洒水车对非机动车辆的实时感知过程中, 由于洒水车与目标间相对位置的动态变化, 目标物体在视觉传感器中呈现出显著的多尺度特征变化现象, 对算法的鲁棒性提出了更高要求。

针对上述问题, 本文提出一种轻量化多尺度骨干网络LMBNet, 其创新性改进主要体现在以下几方面: 首先, 设计多尺度卷积模块C3k2-MSCB, 通过异构卷积分支构建, 强化多尺度特征表征能力; 其次, 采用轻量级自适应增强模块LAE^[13]重构下采

样过程, 在保持特征完整性的同时降低了计算负载; 最后, 引入大核空间注意力机制LSKA^[14]优化C2PSA模块, 实现更精准的空间-通道协同注意力计算。结果表明, 该骨干网络不仅有效减少了模型参数数量和计算量, 同时检测精度也有小幅度提升, 对于提升模型的鲁棒性和轻量化都有正向作用。

2.1.1 轻量化自适应特征提取LAE

在YOLO11中, 采用 3×3 标准卷积进行空间下采样操作, 实现扩大特征感受野和特征图空间维度压缩的目标。然而, 在复杂背景与噪声干扰环境下, 该卷积采样机制存在对多尺度目标特征信息捕捉能力不足的问题, 导致目标检测任务的性能下降。

LAE模块是一种多尺度特征提取方法, 如图1所示, 它采用两个并行分支实现多尺度特征的高效提取。在轻量化特征提取分支中, LAE采用深度可分离分组卷积替代标准卷积操作。通过将输入特征图进行通道分组并实施深度卷积, 将参数数量压缩至传统卷积的 $1/16$ 。自适应提取分支则专注于在多尺度特征图中保留更多的上下文信息和高分辨率细节, 通过自适应权重结合不同位置的全局信息。




图1 LAE模块结构图

采用LAE模块替换骨干网络中的下采样模块, 在保留特征图分辨率的同时保持了图像边缘轮廓与角点结构的完整性, 从而增强模型对感兴趣区域的检测性能。该模块通过参数优化设计与自适应特征融合策略, 设计了两个共享参数的并行分支, 将参数数量减少至传统卷积的 $1/16$, 在保证检测精度的前提下, 还有效减少了模型的大小, 对于模型轻量化有正向作用。

2.1.2 C3k2-MSCB模块

MSCB^[15]模块是一种结合了深度可分离卷积与

多尺度卷积的模块, 其核心机制是多尺度深度卷积(MSDC)。如图2所示, MSDC采用并行分支架构实现特征表征, 通过异构多个不同尺寸卷积核组, 在通道维度进行空间域特征解耦。在每个尺度的分支中, 应用深度可分离卷积将标准卷积分解为深度卷积和逐点卷积, 其中深度卷积在每个输入通道上独立进行卷积操作, 逐点卷积则通过 1×1 卷积核进行通道间的特征融合, 从而实现跨通道信息交互。每个深度可分离卷积后连接批量归一化层(BN)和激活函数ReLU6, 以加速模型收敛。最后, 通过通

道混洗操作,混合不同分支输出的通道信息,从而增强特征多样性与表达能力。




图2 MSCB结构图

基于MSCB模块对多尺寸目标的检测优势,本文将其与C3k2结合,提出一种动态配置的混合模块C3k2-MSCB,如图3所示。当 $c3k=True$ 时,保留标准C3k模块的残差连接特性,当 $c3k=False$ 时,通过MSCB模块替代传统的Bottleneck结构。替换后的C3k2-MSCB不仅保留了原始C3k2架构的计算效率,而且未增加模型负担。采用C3k2-MSCB这种分层-聚合的拓扑结构,通过建立尺度感知特征金字塔,有效捕捉多尺度和多分辨率的上下文信息。通过多尺度卷积,该模块能从不同尺度对图像特征进行提取,使得模型可以更好地感知图像中不同大小的目标,尤其在多视角场景下对尺度变化较大的非机动车的检测精度上取得了显著提升。




图3 C3k2-MSCB结构图

2.1.3 使用LSKA注意力机制改进C2PSA

本文提出的新型混合架构C2PSA-LSKA是一种融合了大核可分离卷积注意力LSKA改进C2PSA的特征提取结构。如图4所示,该架构采用双路特征交互策略:主路保持特征完整性直接传

递,辅路径通过多个堆叠的PSABlock进行深度特征挖掘,每个PSABlock都融入了一个LSKA注意力机制,通过解耦式大核卷积实现高效空间注意力建模。




图4 C2PSA-LSKA结构图

如图5所示为不同大核注意力机制对比。图5(a)为改进前的传统大核注意力LKA-t;图5(b)为改进前大核可分离卷积注意力LSKA-t;图5(c)为改进后的传统大核注意力LKA;改进后的LSKA结构如图5(d)所示,其核心是将传统二维大核卷积解耦为一个水平方向 $1 \times (2d-1)$ 和一个垂直方向 $(2d-1) \times 1$ 的深度可分离卷积序列,同时引入扩张深度可分离卷积DW-D-Conv,通过超参数 d 动态调整卷积核的扩张率,结合核覆盖系数 k 实现多尺度特征捕获,采用串联执行,从而实现了与原始大尺寸2D核类似的效果。




图5 不同大核注意力机制对比

在降低计算复杂度上,LSKA将LKA模块中2D深度卷积核分解为级联的水平和垂直1D卷积核,有效减少了因核尺寸增大导致的参数数量和计算量的二次增长,使得模型在使用大核时仍能保持较低的

计算复杂度,提升了计算效率。该结构保持了原始LKA的注意力建模能力,通过增大感受野更有效地挖掘更多特征以提升对多尺寸目标的检测精度。

2.2 颈部网络改进

本文采用CCFM^[16]重构YOLO11n的颈部网络。CCFM是一个轻量级特征融合网络,通过跨尺寸融合不同分辨率的特征图来增强模型对小尺寸对象的检测能力,同时保持计算效率。与YOLO11颈部网络相比,CCFM增加了三个 1×1 卷积,并加入了一个空间-通道分离下采样SCDown^[17]。

CCFM通过轻量级的卷积操作实现特征的横向融合,并利用 1×1 卷积层进一步传递和增强特征表示,通过解耦尺度内交互和跨尺度融合,避免了不必要的计算冗余。与此同时,CCFM专注于跨尺度特征之间的融合,而不是在整个多尺度特征序列上进行复杂的计算。因此在保持必要计算的同时,

显著减少了不必要的计算开销,从而有效融合不同层级的信息,减少计算负担,增强对模型尺度变换的适应性与小尺寸目标的检测能力。

2.3 改进后模型结构

如图6所示为改进后模型的网络结构图。本文在YOLO11n骨干网络基础上提出一种轻量化多尺度骨干网络LMBNet,引入LAE模块代替原下采样,提出了C3k2-MSCB和C2PSA-LSKA模块。利用该骨干网络重构YOLO11n骨干网络,既减少了模型的计算负担,又提升了模型对多尺度目标的检测能力,有效增强了模型的鲁棒性。在加入CCFM颈部网络后,进一步减少模型的参数量和计算量,同时增强了对小尺寸目标检测能力。LMBNet与CCFM的协同架构不仅显著降低模型参数量,同时在复杂场景下保持了对多尺度目标的检测优势,有效平衡了模型的检测效率与检测性能。




图6 改进后模型整体网络结构图

3 实验结果与分析

3.1 数据集制作及实验环境配置

为实现对非机动车辆的检测,采用自制数据集进行训练。自制数据集中包含部分从coco, voc等公共数据集提取的非机动车辆图片,部分网络的图像资源,以及线下采用相机拍摄的真实道路图片,包含电动车、自行车和三轮车三类检测对象,共计5 736张图片,样本数量分别为4 621、3 963和521,统一采用LabelImg标注为.txt格式,通过随机抽样抽取部分图片计算平均IoU为0.85,满足标注一致性。整个数据集按照7:2:1的比例分为训练集、测试集和验证集。由于洒水车常主要工作时间为道

路行人与车辆较少的时间段,本数据集场景包括无遮挡的白天,也有部分车辆密集场景与夜晚等多个场景。实验平台为Windows11操作系统,CPU是12th Gen Intel(R) Core(TM) i7-12650H, GPU是NVIDIA GeForce RTX 4060 Laptop GPU,深度学习框架为PyTorch, cuda版本为12.1, python版本为3.9.18。研究设定的样本训练过程选用SGD优化器,总共训练200个epoch, batch_size为16, workers为4,初始学习率为0.01,动量因子为0.937。

3.2 评价指标

考虑到本模型需要集成至嵌入式设备中,实验采用mAP@50、mAP@50-95、模型参数量(Params)、每秒浮点数运算次数(GFLOPs)、模型大小(M)、每秒

传输帧数(FPS)作为评价指标来衡量模型性能:

1)mAP@50:一种用于多类别目标检测的性能度量,指在 50% 的 IoU 阈值下,计算模型的平均精度。

2)mAP@50-95:一种更全面的 mAP 衡量方式,指在 50%~95% 的 IoU 阈值范围内,计算模型的平均精度。

3)模型参数量:模型中参数的总数,影响模型的学习能力和计算资源消耗。

4)FLOPs:每秒浮点数运算次数。GFLOPs 表示每秒十亿次浮点运算,代表模型的计算复杂度。

5)模型大小 M :指训练好的深度学习模型所占用的存储空间。

6)每秒传输帧数 FPS :表示模型的推理速度和

实时性能。

3.3 消融实验

3.3.1 骨干消融实验

为验证每个改进对骨干网络性能的贡献,对骨干网络模块进行消融实验,实验结果如表 1 所示。由表可知,将 YOLO11n 的下采样替换为 LAE 模块后, mAP@50 由 92.7% 提升到 93.0%,模型参数量、GFLOPs 和模型大小分别降低了 11.6%、3.1% 和 13.4%。加入 C3k2-MSCB 后,模型的 mAP@50、参数量、GFLOPs 和大小基本保持不变, mAP@50-95 由 73.2% 提升至 75.0%。加入了融合 LSKA 注意力机制的 C2PSA, mAP@50 进一步提升至 93.0%, mAP@50-95 提升为 74.6%,模型的参数量、GFLOPs 和模型大小分别降低了 16.2%、3.1% 和 14.5%。

表 1 骨干消融实验结果

模型	参数					
	mAP@50/%	mAP@50-95/%	Params/($\times 10^6$)	GFLOPs	M/MB	FPS
无	92.7	73.2	2.59	6.4	5.22	242.5
LAE	93.0	74.1	2.20	6.2	4.52	216.6
C3k2-MSCB	92.8	74.4	2.58	6.4	5.24	223.4
C2PSA-LSKA	92.8	74.7	2.55	6.4	5.16	248.6
LAE+C3k2-MSCB	93.0	74.6	2.20	6.2	4.53	195.3
LAE+C3k2-MSCB+C2PSA-LSKA	93.0	74.6	2.17	6.2	4.46	191.5

骨干消融实验结果表明,本文提出的 LMBNet 骨干网络,不仅有效降低了模型的参数量与模型大小,减少了模型的计算成本,同时对模型的检测精度有一定的提升,有效提升了模型的检测效率。

3.3.2 网络消融实验

为验证各个网络结构对模型性能的功效,对骨干网络和颈部网络进行消融实验。实验结果如表 2 所示。将 YOLO11n 的颈部网络替换为 CCFM 网络后,模型参数量、GFLOPs 和大小分别降低了

30.5%、15.6% 和 28.3%,而模型的 mAP@50 保持不变, mAP@50-95 由 73.2% 提升至 73.6%,在保证检测精度的前提下有效减少了模型复杂度。结合 LMBNet 骨干网络后, mAP@50 提升至 93.0%,模型参数量、GFLOPs 和模型大小分别降低了 46.3%、20.3% 和 42.9%。

结果表明,结合 LMBNet 骨干网络和 CCFM 颈部网络,不仅显著减小了模型的参数量与模型大小,模型的检测精度还略有提升,使得该模型更加适配性能较低的嵌入式设备中。

表 2 网络消融实验结果

模型	参数					
	mAP@50/%	mAP@50-95/%	Params/($\times 10^6$)	GFLOPs	M/MB	FPS
无	92.7	73.2	2.59	6.4	5.22	242.5
CCFM	92.7	73.6	1.80	5.4	3.74	231.4
CCFM+LMBNet	93.0	73.4	1.39	5.1	2.98	194.8

3.4 对比实验

3.4.1 骨干网络不同卷积对比实验

为使模型轻量化,本模型采用 LAE 模块替换骨干网络中下采样卷积模块,为验证其有效性,将其

与 ODCnv,SPDCnv 和 ADown 卷积进行对比,实验结果如表 3 所示。由表 3 可知,相较于其他轻量化卷积, LAE 模块在参数量上基本持平,但 mAP@50 提升了 0.3%,为所有卷积中最高。

表 3 骨干网络中不同卷积对比结果

卷积	参数		
	mAP@50/%	Params/($\times 10^6$)	GFLOPs
3 $\times$ 3Conv	92.7	2.59	6.4
ODConv	92.7	4.62	4.8
SPDConv	92.8	2.20	5.5
ADown	92.9	2.21	5.5
LAE	93.0	2.20	6.2

3.4.2 改进的 C3k2-MSCB 数量和位置对比实验

本文提出 C3k2-MSCB 模块采用 MSCB 改进 C3k2 中的 Bottleneck, 理论上改进后的 C3k2-MSCB 模块特征提取能力更强, 且参数量更低。但由于在 YOLO11n 中, 深层(P3,P4)和浅层(P1,P2)的 C3k2 的 c3k 设定不同, 针对深层和浅层, 对比是否采用 C3k2-MSCB 替换 C3k2 验证模型性能。

如表 4 所示, 只替换浅层 C3k2 模型的 mAP@50 提升了 0.1%, 只替换深层 C3k2 模型的 mAP@50 下降了 0.3%, 全部替换后确实可以大幅降低模型的参数量和模型大小, 但模型的 mAP@50 也下降了 0.2%, 综合考虑只替换掉浅层的 C3k2, 即 c3k=False 时采用 C3k2-MSCB, c3k=True 时采用 C3k2。

表 4 C3k2-MSCB 数量和位置对比结果

位置	mAP@50/%	Params/($\times 10^6$)	GFLOPs
P1,P2	92.8	2.58	6.4
P3,P4	92.4	2.48	6.4
P1,P2,P3,P4	92.5	2.35	6.2

3.4.3 不同骨干网络对比实验

为保证模型的实时性, 本模型提出一种轻量化多尺度骨干网络 LMBNet, 为验证该骨干网络的有效性, 将其与轻量化骨干网络 RepVit、FasterNet 和 HGNetV2 进行对比, 实验结果如表 5 所示。

从对比结果中发现, 替换不同的轻量化骨干网络都可以减少模型参数量, 使模型轻量化, 但检测精度都有一定幅度的下降, 而本文提出的 LMBNet

不仅参数量有较大幅度下降, 检测精度也有提升。

表 5 骨干网络对比结果

主干网络	mAP@50/%	Params/($\times 10^6$)	GFLOPs
Darknet	92.7	2.59	6.4
RepVit	91.9	2.11	5.4
FasterNet	91.7	2.38	5.6
HGNetV2	92.9	2.38	5.6
LMBNet	93.0	2.17	6.2

3.4.4 不同颈部网络对比实验

为保证模型的轻量化和准确性, 本模型采用 CCFM 替换 YOLO11n 原本的颈部网络。为验证该颈部网络的有效性, 将其与 BiFPN, SlimNeck, HSGFPN 进行对比, 实验结果如表 6 所示。

表 6 颈部网络对比结果

颈部网络	mAP@50/%	Params/($\times 10^6$)	GFLOPs
PANet	92.7	2.59	6.4
SlimNeck	92.2	2.48	5.9
HSGFPN	92.1	1.85	5.8
BiFPN	91.8	2.61	7.1
CCFM	92.7	1.80	5.4

从对比结果中发现, 替换颈部网络可以减少模型参数量, 使模型轻量化, 本文所采用的 CCFM 不仅在参数量、GFLOPs 和模型大小大幅下降, 还能保持模型精度不变。

3.4.5 与其他模型对比试验

为进一步验证本研究算法的有效性, 将本研究模型的各项评价指标与一些经典的目标检测模型以及其他学者提出的轻量化模型进行对比实验, 实验结果如表 7 所示。

由表 7 可知, 相较于 Faster-RCNN, YOLOv3-tiny, YOLOv5n, YOLOv8n, YOLOv10n 和 RT-DETR, 本文模型的 mAP@50 分别提升了 6.9%、2.2%、1.3%、1.5%、1.5% 和 1.7%, 模型的参数量、GFLOPs 和模型大小分也有一定程度下降。与

表 7 与其他模型对比实验结果

模型	参数					
	mAP@50/%	mAP@50-95/%	Params/($\times 10^6$)	GFLOPs	M/MB	FPS
Faster-RCNN	86.1	63.1	138.7	380	108.2	43
YOLOv3-tiny	90.8	68.6	9.52	14.5	18.29	238.2
YOLOv5n	91.7	72.2	2.18	5.9	4.44	200.5
YOLOv8n	91.5	73.4	2.69	6.9	5.37	250.1
YOLOv10n	91.5	73.4	2.70	8.4	5.50	247.1
RT-DETR	91.3	72.9	40.4	143.6	432.1	71
YOLO11n	92.7	73.2	2.59	6.4	5.22	240.2
本文	93.0	73.4	1.39	5.1	2.98	194.8

改进前的 YOLO11n 模型相比,改进后模型的 mAP@50 提升了 0.3%,模型的参数量、GFLOPs 和模型大小分别降低了 6.3%、20.3% 和 42.9%。综合对比可知,所提出的模型不仅仅在精确度优于以上这些目标检测模型,更是在模型参数量、GFLOPs 和模型大小上具有一定的优势,兼顾了模型的检测性能和模型的轻量化,可以更加快速、准确、高效地识别非机动车辆。

3.5 结果可视化对比与嵌入式部署验证

为验证改进后模型的检测效果,从测试集中选取两组不同场景图像进行对比。图 7(a)和图 7(b)对比了多尺度场景下 YOLO11n 和本文模型检测效果,图 8(a)和图 8(b)对比了在夜晚场景下 YOLO11n 和本文模型的检测效果。结果显示,无论是非机动车辆较多的多尺度场景还是夜晚场景,本文模型较原始的 YOLO11n 模型都能识别出更多的非机动车辆,在置信度上也高于原始模型。




图 7 多尺度场景



图 8 夜晚场景

为进一步验证模型在嵌入式设备上的有效性,本文将所提模型部署至洒水车上的 Jetson Nano 嵌入式设备上实验。Jetson Nano 是由英伟达公司设计的小型人工智能计算机,搭载四核 64 位 ARM 的 CPU, GPU 为 128 核集成 NVIDIA Maxwell, 显存为 4 GB LPDDR4。在相同环境下运行 10 次推理任务,分别测试了 YOLOv8n, YOLO11n 和本模型,以评估检测精度、检测速度及模型大小,结果如表 8 所示。

表 8 不同模型在 Jetson Nano 上对比结果

模型	参数			
	mAP@50/%	M/MB	FPS 波动范围	平均 FPS
YOLOv8n	91.7	4.44	12.5~13.4	13.1
YOLO11n	92.7	5.22	12.1~12.9	12.4
本模型	93.0	2.98	11.2~12.1	11.7

由表 8 可知,部署在 Jetson Nano 设备上的模型检测速度较 Windows 系统差距较大。但本文提出的模型检测速度的波动范围为 0.9 FPS,具有一定的推理稳定性,同时检测速度较 YOLOv8n 和 YOLO11n 差距不大,仅为 1.4 FPS 和 0.7 FPS,基本满足实际使用需求。本文模型的 mAP@50 和模型大小较 YOLOv8n、YOLO11n 有较大优势,更加适用于计算资源受限的嵌入式设备中。

4 结语

针对洒水车智能喷洒中非机动车辆检测实时性差,模型复杂度高、多尺度目标检测困难等问题,基于 YOLO11n 提出一种轻量化多尺度骨干网络 LMB,并与 CCFM 颈部网络结合,实现了对非机动车辆的低成本、高效率的检测。本文构建的 LMB 骨干网络,将传统下采样替换为 LAE 模块,提出 C3k2-MSCB 模块,引入 LSKA 大核注意力机制改进 C2PSA,相较于 YOLO 模型的骨干网络更加轻量化和高效。实验结果表明,在自建的非机动车辆数据集上,所提出的模型较原始的 YOLO11n 模型的 mAP@50 提升了 0.3%,模型的参数量、GFLOPs 和模型大小分别降低了 46.3%、20.3% 和 42.9%。这一优化不仅满足洒水车智能喷洒系统的实时性的需求,同时保证了检测精度,为洒水车智能喷洒系统提供了可靠的支持。

参考文献:

- [1] 李红燕. 对新型智能洒水车的研究探讨[J]. 南方农机, 2018, 49(7): 140, 143.
Li Hongyan. Research and discussion on new intelligent sprinkler [J]. South Agricultural Machinery, 2018, 49(7): 140, 143.
- [2] 韩惠, 刘娜, 朱俊文, 等. 基于百度地图的洒水车智能预警系统研究[J]. 地理空间信息, 2018, 16(11): 29-31, 10.
Han Hui, Liu Na, Zhu Junwen, et al. Research on sprinkler intelligent alarming system based on Baidu map [J]. Geospatial Information, 2018, 16(11): 29-31, 10.
- [3] Qian Y, Sun Q, Fei G, et al. Riding behavior and electric bike traffic crashes: a Chinese case-control study [J]. Traffic Injury

- Prevention, 2020, 21(1): 24-28.
- [4] 张 谦. 基于多传感器信息融合的洒水车行人防喷溅系统研究[D]. 淄博: 山东理工大学, 2022.
- Zhang Qian. Research on pedestrian splash prevention system of sprinkler based on multi-sensor information fusion [D]. Zibo: Shandong University of Technology, 2022.
- [5] 熊文军, 赵山虎, 李世博, 等. 清洁车智能监测与控制系统研究[J]. 计算机测量与控制, 2022, 30(5): 109-114.
- Xiong Wenjun, Zhao Shanhu, Li Shibo, et al. Research on intelligent monitoring and control system of cleaning vehicle[J]. Computer Measurement & Control, 2022, 30(5): 109-114.
- [6] 陈增志. 洒水车定量喷洒控制系统[J]. 专用汽车, 2019(2): 92-95.
- Chen Zengzhi. Water spraying vehicle quantitative spraying control system[J]. Special Purpose Vehicle, 2019(2): 92-95.
- [7] Jing W, Zhu Z, Chen H, et al. Toward large-scale non-motorized vehicle helmet wearing detection: a new benchmark and beyond[J]. IEEE Transactions on Consumer Electronics, 2025, 71(1): 594-607.
- [8] Li Y, Ding H, Hu P, et al. Real-time detection algorithm for non-motorized vehicles based on D-YOLO model [J]. Multimedia Tools and Applications, 2024, 83(22): 61673-61696.
- [9] 王 博. 基于深度学习的非机动车辆检测与识别[D]. 西安: 西安电子科技大学, 2021.
- Wang Bo. Non-motor vehicle detection and recognition based on deep learning[D]. Xi'an: Xidian University, 2021.
- [10] 王 林, 翁友虎. 融合VovNet网络和可变形卷积的非机动车辆检测[J]. 计算机系统应用, 2023, 32(5): 132-140.
- Wang Lin, Weng Youhu. Non-motor vehicle detection based on VovNet network and deformable convolution [J]. Computer Systems & Applications, 2023, 32(5): 132-140.
- [11] Wang Z, Su Y, Kang F, et al. PC-YOLO11s: a lightweight and effective feature extraction method for small target image detection[J]. Sensors, 2025, 25(2): 348.
- [12] Huang J, Wang K, Hou Y, et al. LW-YOLO11: a lightweight arbitrary-oriented ship detection method based on improved YOLO11[J]. Sensors, 2025, 25(1): 65.
- [13] Yu Z, Guan Q, Yang J, et al. LSM-YOLO: a compact and Effective roi detector for Medical detection [C]//International Conference on Neural Information Processing, 2025: 30-44.
- [14] Lau K W, Po L M, Rehman Y A U. Large separable kernel attention: rethinking the large kernel attention design in CNN[J]. Expert Systems with Applications, 2024, 236: 121352.
- [15] Rahman M M, Munir M, Marculescu R. EMCAD: efficient multi-scale convolutional attention decoding for medical image segmentation [C]//2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2024: 11769-11779.
- [16] Zhao Y, Lv W, Xu S, et al. DETRs beat YOLOs on real-time object detection[EB/OL]. 2023; arXiv: 2304.08069.
- [17] Wang A, Chen H, Liu L, et al. YOLOv10: real-time end-to-end object detection[EB/OL]. 2024; arXiv: 2405.14458.

作者简介:

汪立远(2001—),男,湖北省鄂州市人,硕士研究生,主要研究领域为机器视觉;

张 峰(1986—),男,河南省信阳市人,博士,讲师,主要研究领域为生产调度。