

基于YOLOv8n的轻量化改进算法

范崇阳, 林 昌*, 李文芳, 张敏

(莆田学院 机电与信息工程学院, 福建 莆田 351100)

(*通信作者电子邮箱linchanpt@163.com)

摘 要:以卷积神经网络(CNN)为特征提取内核的YOLOv8n通常对嵌入式目标检测系统硬件要求较高,难以实现低配置下的有效检测。针对此问题,提出一种YOLOv8n轻量化改进算法。首先,引入双卷积核DualConv构建轻量级深度神经网络,即利用3×3和1×1卷积核同时处理输入特征图,并利用组卷积技术高效地排列卷积滤波器,从而减少模型参数量与计算量;其次,利用轻量型自适应下采样模块(LADM)替换普通卷积,以保证在降低参数量与计算量的同时,适应性地权衡不同通道的特征,从而更好地保留重要的特征信息;再次,引入大核分离卷积注意力(LSKA)机制改进特征融合层,以增强该层的多尺度特征提取能力;最后,利用轻量型参数共享与细节增强检测头(LPSDED)参数共享的优势高效地预测图像中不同大小和形状目标的位置和类别,从而有效降低网络的计算量与参数量。实验结果表明,相较于原始YOLOv8n模型,改进后的YOLOv8n目标检测模型在VOC2007+VOC2012联合数据集上的参数总量减少了43.3%,计算量降低了37.0%,而检测精度仅下降2个百分点。可见,所提算法成功地实现了模型轻量化,并在模型精度和计算效率之间取得了最佳平衡。

关键词:YOLOv8n;轻量化改进;目标检测;特征提取;组卷积

中图分类号:TP181 **文献标志码:**A

Lightweight improved algorithm based on YOLOv8n

FAN Chongyang, LIN Chang*, LI Wenfang, ZHANG Min

(School of Electromechanical and Information Engineering, Putian College, Putian Fujian 351100, China)

Abstract: A Convolutional Neural Network (CNN) is employed as the core for feature extraction in the YOLOv8n model, which imposes significant hardware demands on embedded target detection systems and hinders effective detection under low-configuration conditions. To address this issue, a lightweight improved algorithm based on YOLOv8n was proposed. Firstly, DualConv, which employs both 3×3 and 1×1 convolutional kernels to process input feature maps simultaneously, was introduced to construct a lightweight deep neural network. Group convolution techniques were applied to arrange convolutional filters efficiently, thereby minimizing model parameters and computational cost. Secondly, standard convolution was replaced by the Lightweight Adaptive Downsampling Module (LADM) to reduce parameters and computational cost while balancing features of different channels adaptively, thereby preserving critical feature information better. Thirdly, the Large Separable Kernel Attention (LSKA) mechanism was integrated to refine the feature fusion layer, thereby enhancing its multi-scale feature extraction capabilities. Finally, the advantages of parameter sharing were utilized by the Lightweight Parameter Sharing and Detail Enhancement Detection Head (LPSDED) to predict the locations and categories of targets with varying sizes and shapes in images efficiently, thereby decreasing computational cost and parameters of the network effectively. Experimental results demonstrate that compared with the original YOLOv8n model, the improved YOLOv8n object detection model has a 43.3% reduction in total parameters and a 37.0% decrease in computational cost on the VOC2007+VOC2012 combined dataset, with only a 2 percentage points decline in detection precision. It can be seen that by the proposed algorithm, model lightweighting is successfully achieved, with an optimal balance between detection accuracy and computational efficiency.

Key words: YOLOv8n; lightweight improvement; target detection; feature extraction; group convolution

0 引言

在计算机视觉技术与深度学习快速发展的推动下,目标检测算法已成为智能监控、自动驾驶、医疗影像分析等领域的核心技术支撑^[1-2]。作为该领域代表性成果,基于单阶段检测框架的YOLO(You Only Look Once)系列算法^[3]凭借高效的实时检测特性与简洁的网络架构持续受到学术界关注。目前,YOLOv8在检测精度上较前代模型^[4-6]取得突破性进展,但伴随模型复杂度提升产生的计算资源需求严重制约了YOLO算法在边缘计算设备中的部署。特别是在移动终端算力持续升级的产业背景下,如何构建兼顾YOLOv8^[7]检测效能与模型轻量化的平衡架构,已成为推动算法落地应用的关键突破口。

YOLO算法作为目标检测领域的经典算法,凭借简洁的网络结构、高效的信息处理能力和广泛的适用性,在视觉任务中取得了显著成效;然而该算法在实际应用中仍存在计算复杂度高、内

存占用大、GPU依赖性较强等问题,这些局限性在一定程度上制约了YOLO算法在资源受限场景下的部署与应用。尽管轻量化YOLO算法的研究已取得一定进展,但仍面临诸多挑战:首先是如何有效平衡检测精度与模型复杂度;其次是如何针对不同应用场景选择最优的轻量化策略。因此,在确保目标检测性能的前提下实现算法的轻量化改进,已成为当前计算机视觉领域及目标检测领域亟待解决的关键问题。

目前,国内外研究人员针对YOLO算法已做出许多的轻量化研究。刘子洋等^[8]引入注意力机制BRA(Bi-level Routing Attention)提升对小目标的检测性能,引入GSConv(Generalized Sparse ConVolution)模块平衡BiFormer带来的计算量和参数量的增加,不但有一定的精度提升,计算量相对基线也没有变化。赵翠芳等^[9]在主干利用级联扩张残差模块(Cascade Dilation-wise Residual, CDR)的多速率扩张卷积和残差结构,实现基本特征提取;在颈部引入加权双向特征金字塔网络(Bidirectional Feature

收稿日期:2025-02-26;修回日期:2025-03-18;录用日期:2025-03-24。

基金项目:福建省中央引导地方科技发展资金资助项目(2024L3020065);福建省自然科学基金资助项目(2022J05257)。

作者简介:范崇阳(2000—),男,河南郑州人,硕士研究生,CCF会员,主要研究方向:深度学习、机器视觉; 林昌(1989—),男,福建莆田人,副教授,博士,主要研究方向:机器人技术、目标智能检测与识别; 李文芳(1964—),男,福建莆田人,教授,硕士,主要研究方向:机械设计、机电一体化技术; 张敏(2004—),女,福建南平人,主要研究方向:机器视觉。

Pyramid Network, BiFPN), 利用跨尺度连接和加权融合输入特征; 利用内容引导卷积和自注意力(Content Guided Convolution and self-Attention, CGCA)融合模块融合深浅层特征图, 缓解了梯度消失问题, 增强了细节特征; 引入动态检测头, 实现检测头和注意力的统一, 提高检测能力。汤子旋等^[10]采用FasterNet作为主干网络, 在提升模型对陨石坑和月面岩石特征提取能力的同时减少模型参数量和计算量, 提高检测速度; 然后引入SimAM注意力机制模块, 提升特征融合能力; 最后将广义交并比(Generalized Intersection over Union, GIoU)作为损失函数。这种做法对于月面场景比较有效。王舒梦等^[11]在Neck部分增加P2小目标检测层, 将深浅层特征图进行拼接, 以更好捕捉小目标的细节信息; 利用轻量化卷积PartialConv改进C2f(Convolutional to feature), 进行模型轻量化; 结合空间金字塔池化(Spatial Pyramid Pooling, SPP)和特征提取增强模块(Efficient Layer Attention Network, ELAN)对空间金字塔池化结构进行改造, 使模型能更有效地捕捉小目标特征; 利用通道注意力机制SE(Squeeze and Excitation)改进检测头使网络更好地关注重要的通道, 减少复杂环境中背景噪声对小目标检测任务的干扰; 最后使用EfficientIoULoss作为边界框损失函数, 提升模型对小目标的检测能力。王泽宇等^[12]将FasterNet主干作为特征提取网络, 采用局部卷积(Partial Convolution, PConv)减少了冗余计算和内存访问; 在特征融合中引入深度可分离卷积(Depth Wise Convolution, DWConv), 进一步降低了模型的复杂性和计算资源消耗; 使用Focal-EIoU作为模型损失函数, 提高了检测精度, 使得模型更具鲁棒性。张丽娟等^[13]通过将骨干网络替换为条件参数化卷积实现特征自适应调节, 在颈部网络将GSconv+轻量化跨阶段特征融合模块(Visual object-aware and Void Generalized Slim Cross Stage Partial, VoVGSCSP)瓶颈组合降低模型复杂度, 并融合坐标注意力机制强化特征表征, 虽有效提升了检测精度, 但模型轻量化程度仍存在优化空间。

上述研究成果从不同场景、不同技术对YOLOv8进行轻量化改进, 但各有优劣之处。针对YOLOv8在边缘计算场景中面临的

模型复杂度与部署效能失衡问题, 本文以YOLOv8n为基准模型提出DLLL-YOLO算法, 通过构建多维度轻量化协同优化框架, 重点解决特征提取冗余度控制、跨层参数共享效率提升及注意力机制计算开销压缩等关键技术挑战, 在保持模型精度损失可控的前提下实现算法部署适应性突破。核心算法如下:

1) 采用分组卷积与点卷积的并行异构架构重构特征融合单元; 在保持跨阶段部分(Cross Stage Partial, CSP)模块轻量化优势的同时, 利用分组卷积的局部稀疏连接捕获细粒度空间特征, 并借助点卷积的全局稠密交互建立跨通道长程依赖, 二者通过参数共享与特征叠加实现局部-全局感知的互补性增强, 从而在单一模块内突破传统CSP结构的特征表达能力瓶颈, 为多尺度目标检测任务提供更高效率的特征融合范式。

2) 通过构建动态权重分配机制, 将分组卷积的通道解耦特性与空间特征软选择策略深度融合, 以像素级自适应加权实现多尺度特征的高效压缩与跨通道交互增强, 在显著降低计算冗余的同时, 有效缓解传统下采样中的高频信息丢失问题, 为轻量化目标检测模型的层次化特征表达优化提供了新思路。

3) 检测头通过异构特征融合与动态参数共享的协同架构, 重构目标检测任务中分类与定位的特征优化范式。设计共享双路径细节增强卷积模块, 结合组归一化约束的膨胀卷积层强化高频特征捕获能力, 利用跨检测层的参数复用策略降低计算冗余; 同时引入可学习缩放因子动态平衡分类与回归分支的特征贡献权重, 通过梯度反向传播自适应缓解任务冲突问题。在维持单阶段检测器端到端效率优势的基础上, 实现了细粒度特征表达与轻量化计算的统一。

1 DLLL-YOLO 算法

本文针对YOLOv8n存在的一些缺点, 对原模型进行了一定程度的优化, 实现了算法的计算量与性能的平衡, 改进后模型结构如图1所示。




图1 DLLL-YOLO模型整体结构

1.1 双卷积核模块

标准卷积在提取特征图信息的过程中, 参数量和计算量不断增加, 导致模型计算量增大而精度提升有限。针对以上问题,

本文引入双卷积核DualConv^[14]改进CSP模块, 将3×3与1×1卷积核集成以同时处理相同的输入特征图通道。由于DualConv使用1×1卷积保留输入特征图的原始信息, 因此较深层卷积层的3×3

卷积核仍然可以从输入特征图的原始信息中学习。双卷积核模块的结构如图2所示。

在DualConv中,超参数 G 决定核权重矩阵的分组数量,每组包含 $1/G$ 个 $K \times K$ 卷积核。对于给定的 G ,尺寸为 $(K \times K + 1 \times 1)$ 的组合卷积核的比例为所有通道的 $1/G$,其余 1×1 卷积核的比例为 $(1 - 1/G)$ 。因此,在由 G 个卷积滤波器组成的双卷积层中,组合卷积核的浮点运算数为:

$$FL_{cc} = \frac{D_o^2 \times K^2 \times M \times N + D_o^2 \times M \times N}{G} \quad (1)$$




图2 双卷积核模块结构

鉴于DualConv对CSP模块的改进不会干扰正常的下采样过程,本文将原始C2f模块进行全面替换,模块伪代码如下所示。

算法1 CSP-Dual。

输入 tensor x (shape: $[B, c_1, H, W]$);

输出 tensor $output$ (shape: $[B, c_2, H, W]$)。

- 1) $feature_mAP \leftarrow Conv2D(x)$;
//通过cv1卷积层,输出通道数为 $2 \times c_{hidden}$
- 2) $split_features \leftarrow Split(feature_mAP, num_parts=2, axis=1)$;
//输出形状: $[B, c_{hidden}, H, W] \times 2$
- 3) $y \leftarrow [split_features[0], split_features[1]]$;
//储存在 y
- 4) for m in self. m do
- 5) $current_feature \leftarrow y[-1]$;
//取列表最后一个元素
- 6) $processed_feature \leftarrow m(current_feature)$;
//self. m 处理后输出
- 7) $y.append(processed_feature)$;
//填入 y 列表
- 8) $concatenated_features \leftarrow Concatenate(y, axis=1)$;
//沿通道维度拼接所有特征
- 9) $output \leftarrow Conv2D(concatenated_features$;
 $kernel=1 \times 1, out_channels=c_2)$;
//通过卷积层cv2降维
- 10) return $output$

实验结果表明,该优化策略可显著降低模型的参数量和计算量,同时对精度的影响微乎其微,实现了模型效率与性能的有效平衡。

1.2 轻量型自适应下采样模块

在池化方面,大多数模型的思路是使用最大池化或平均池化,最大池化会直接损害某些特征信息,而平均池化会柔化所有特征信息,同样对特征信息造成一定的损伤。本文基于自适应池化权重想法,结合组卷积思路,提出轻量型自适应下采样模块(Lightweight Adaptive Downsampling Module, LADM),该模块在池化时进行自适应的权重计算,从而更好地保存特征信息。

具体地,一路输入张量 x 传递给注意力机制模块,注意力模块首先进行平均池化操作,然后进行卷积从而得到输出张量。

其中 D_o 表示输出特征图的宽度和高度。

其余 1×1 逐点卷积核的浮点运算数为:

$$FL_{pc} = (D_o^2 \times M \times N) \times (1 - 1/G) \quad (2)$$

浮点运算总数为:

$$FL_{dc} = FL_{cc} + FL_{pc} = D_o^2 \times K^2 \times M \times N/G + D_o^2 \times M \times N \quad (3)$$

其中: M 是输入通道数(输入特征图的深度); N 是卷积滤波器的数量; D_i 是输入特征图的宽、高维度; $K \times K$ 是卷积核大小; G 是组卷积和双卷积中的组数; $1/P$ 是异构卷积中 3×3 卷积核的比率。

使用rearrange函数将输出张量的维度重新排列为 $(bs, ch, h, w, s_1 \times s_2)$,其中: bs 是批次大小, ch 是通道数, h 和 w 是空间维度, $s_1 \times s_2$ 是注意力权重的维度,即在维度重排的同时将池化信息整合到最后一维,最后对最后一维进行Softmax操作从而得到池化权重。

另一路将输入张量 x 传递给下采样组卷积层,基于组卷积的思路,将输入张量按通道数进行分组,每组独立地进行卷积运算,从而减少参数量和计算量,同时保持模型的表达能力。得到输出张量后,使用rearrange函数将输出张量的维度重新排列为 (bs, ch, h, w, s) ,其中 s 是下采样因子, $s_1 \times s_2$ 与 s 最终相等。考虑到Focus切片操作开销较大,在组卷积这一路上暂不采用。最后将池化权重与下采样输出张量进行element-wise乘法,使用torch.sum函数在最后一个维度上求和,得到最终输出张量。LADM结构如图3所示。

1.3 特征融合模块

卷积核尺寸的增加会导致模型整体计算量和内存占用量呈指数级增加,为缓解此问题,引入大核分离卷积注意力(Large Separable Kernel Attention, LSKA)^[15]模块改进特征融合层,结构如图4所示。

将深度卷积和深度膨胀卷积的二维核分裂成2个一维可分的级联核,即为LSKA构型。其中:DW-Conv代表标准深度卷积;DW-D-Conv代表扩展深度卷积; $\otimes$ 代表哈达玛积; k 代表最大感受野; d 代表膨胀率。LSKA模块的输出如下所示:

$$\bar{Z}^C = \sum_{H,W} W_{(2d-1) \times 1}^C * \left(\sum_{H,W} W_{1 \times (2d-1)}^C * F^C \right) \quad (4)$$

$$Z^C = \sum_{H,W} W_{\lfloor k/d \rfloor \times 1}^C * \left(\sum_{H,W} W_{1 \times \lfloor k/d \rfloor}^C * \bar{Z}^C \right) \quad (5)$$

$$A^C = W_{1 \times 1} * Z^C \quad (6)$$

$$\bar{F}^C = A^C \otimes F^C \quad (7)$$

其中: C 是输入通道数; H 和 W 分别表示特征图的高度和宽度; d

是膨胀率。式(4)中的 $\bar{Z}^c$ 表示核大小为 $(2d-1) \times 1$ 和 $1 \times (2d-1)$ 的卷积核与输入特征图深度卷积的输出,它捕获局部的空间信息并补偿核大小 $(k/d) \times 1$ 和 $1 \times (k/d)$ 的深度扩展卷积的网格效应, $\lfloor \cdot \rfloor$ 表示向下取整。式(5)为扩展的深度卷积,负责捕获深度卷积输

出的全局空间信息。式(6)是将深度卷积的输出与 1×1 卷积核进行卷积,得到注意力图 A^c ,其中 $*$ 和 $\otimes$ 分别表示卷积和Hadamard积。式(7)将注意力图特征信息和输入特征图特征信息进行Hadamard相乘,从而得到最终输出。




图3 轻量型自适应下采样模块结构




图4 不同大核注意力模块的比较

本文引用LKSA改进快速空间金字塔池化(Spatial Pyramid Pooling Fast, SPPF)层,旨在提升YOLO多尺度特征的提取与融合能力,并阶段性平衡精度与计算量。具体地,第一阶段,首先对输入特征图 x_1 进行卷积操作,得到一个新的特征图 x_2 ;然后将此特征图进行连续最大池化操作,从而得到3种不同尺度的特征图 y_1 、 y_2 和 y_3 (y_3 在concat时进行计算),将这3种不同尺度的特征图与原始特征图进行concat操作得到新的特征图。

第二阶段将特征图输入LKSA模块计算特征图的注意力权重,并使用这些权重加权输入特征图。具体地,输入特征图 x 通过一个卷积层conv_h,得到一个水平方向的注意力权重;水平方向的注意力权重通过一个卷积层conv_v,得到一个垂直方向的注意力权重;垂直方向的注意力权重通过一个卷积层conv_spatial_v,得到一个空间方向的注意力权重(垂直);空间方向的注意力权重(垂直)通过一个卷积层conv1,得到最终的注意力权重;最后将最终的注意力权重与原始特征图 x_1 相乘,得到加权后的特征图。

1.4 轻量型参数共享与细节增强检测头

YOLOv8的检测头针对不同特征图进行不同尺寸物体的预测。首先,各部分独立进行多次卷积操作,给参数量和计算量带来了沉重负担;其次,在进行预测时也没有考虑其他尺寸特征信息的重复利用。针对以上两点,提出轻量型参数共享与细节增强检测头(Lightweight Parameter Sharing and Detail Enhancement Detection Head, LPSDED),以高效地预测图像中不同大小与形状目标的位置和类别,并进一步降低网络的计算量与参数量。LPSDED的结构如图5所示。

首先,将前排卷积层的归一化算法替换为组归一化(Group Normalization, GN)算法^[16],GN示意图如图6所示,其中深色方块

是各个算法计算均值和方差的区域, C 代表通道数, N 是批量大小, H 、 W 是高度和宽度,第3个维度的大小是 $H \times W$,表示输入尺寸。从图6中可以看出只有批次归一化(Batch Normalization, BN)的计算与批次大小 N 有关,层归一化(Layer Normalization, LN)、实例归一化(Instance Normalization, IN)和GN的计算都在单个样本上进行。考虑到本实验所用数据集与批次大小,且GN的性能在文献[17]中已得到充分的验证,故选用GN进行适配,意在提升检测头定位和分类的性能,同时避免过分轻量化带来的严重失准问题。其次在中间卷积层使用共享卷积,将不同尺度的特征图信息进行整合,以大幅减少参数量与计算量,从而实现轻量化的目的。再者,利用细节增强卷积(Detail Enhanced Convolution, DEConv)^[18],它由5个并行部署的卷积层组成,包括1个普通卷积(Vanilla Convolution, VC)、1个中心差分卷积(Central Difference Convolution, CDC)、1个角度差分(Angular Difference Convolution, ADC)、1个水平差分卷积(Horizontal Difference Convolution, HDC)和1个垂直差分卷积(Vertical Difference Convolution, VDC),借此提高检测头的细节捕获能力,进一步提升模型检测精度。




图5 LPSDED模块结构

具体地,DEConv通过将先验信息整合至标准卷积层中,有效增强了特征表征能力和模型泛化性能。在此基础上,采用重参数化技术将DEConv等效转换为标准卷积,这一转换过程无需引入额外的参数和计算开销。随后,模型利用共享和增强后的特征信息进行目标回归与分类任务。然而,在共享卷积层整合的特征信息中,各检测头所处理的目标尺度不一致。为此,本文引入Scale层对特征进行自适应缩放,以解决多尺度目标检测的适配问题。

综上所述,LPSDED检测头在显著降低参数量和计算复杂度的同时,可以有效控制目标检测精度损失,实现检测效率与性能的优化平衡。




图6 不同归一化算法比较

2 实验与结果分析

2.1 数据集与实验环境

本文使用 VOC2007+VOC2012 公开数据集^[19]进行模型训练和性能验证。将 VOC2007 的测试集与 VOC2012 的训练集进行整合,训练集、训练集和测试集按 7:1:2 的比例进行数据集的划分,划分后训练集图片数为 15 052,验证集图片数为 2 150,测试集图片数为 4 301。输入的图像尺寸统一为 640×480。

该数据集包含人、动物、交通工具、家具在内的 20 个类别,每幅图像平均包含 2.4 个目标,在实际训练时发现有些纯背景图片,也有画框但未标注的图片,但作者认为此类干扰有利于模型的学习,故保留。

实验的操作环境为 Windows 11, CPU 为 Intel Core i7-13650HX @2.60 GHz,内存 32 GB,显卡为 NVIDIA GeForce RTX 4060,显存 8 GB。深度学习框架使用 PyTorch-GPU 2.2.2,使用的 CUDA 版本为 12.1,使用 8.8.1 版本的 cuDNN 进行 GPU 加速,其他常规训练参数如表 1 所示,训练伪代码如下所示:

算法 2 DLLL-YOLO。

输入 yolov8n-DLLL.yaml;

输出 last.pt, best。

- 1) model ← yolov8n-DLLL.yaml;
- 2) data ← COV07+12.yaml;
- 3) cache ← False;
- 4) imsz ← 640;
- 5) Epochs ← 300;
- 6) Batch ← 32;
- 7) close_mosaic ← 0;
- 8) Workers ← 8;
- 9) Device ← 0;
- 10) Optimizer ← SGD;
- 11) Project ← runs/train/;
- 12) Name ← exp;
- 13) END

表 1 参数配置表

参数名	参数值	参数名	参数值
优化器	SGD	图片尺寸	640 (正方形)
批次大小	32	学习率	0.01
循环次数	300		

2.2 评价指标

在主流目标检测算法中,评价网络性能的指标主要有:精确率 P (Precision)、召回率 R (Recall)、平均精度 (Average Precision, AP) 和平均精度均值 (mean Average Precision, mAP)。本实验选取 mAP@0.5 和 mAP@0.5:0.95 这 2 项指标作为性能参考依据,其中, mAP@0.5 代表 IoU 阈值为 0.5 时的 mAP 值; mAP@0.5:0.95 表示 IoU 值从 0.5 开始,以步长为 0.05 递增至 0.95 时所计算得到的 mAP 值。mAP 值越大,表示模型的整体精度越高。上述指标计算公式如下所示:

$$P = \frac{TP}{TP + FP} \quad (8)$$

$$R = \frac{TP}{TP + FN} \quad (9)$$

$$V_{AP} = \int_0^1 P(R) dR \quad (10)$$

$$V_{mAP} = \frac{1}{N} \sum_{i=1}^N AP_i \quad (11)$$

其中: TP 为预测正确的正样本数, FN 为预测错误的负样本数, FP 为预测错误的正样本数; AP_i 为第 i 类平均精度; N 表示类别数。

在轻量化的工作中,模型的参数量 (Params) 与计算量 (以十亿次浮点运算次数 (Giga FLOat Operations, GFLOPs) 衡量) 也必须考虑。

2.3 检测效果分析

2.3.1 实际检测效果分析

图 7 是基准模型 YOLOv8n 与本文模型的检测效果对比。从第 1 张图中部靠右区域可以看出,本文模型的小目标检测能力得到提升,尽管由于精度限制,将目标误识别为“椅子”,但仍成功检测到了目标物体。值得注意的是,在原图中部区域,基准模型未能检测到门外行人,而本文模型不仅成功检测到该目标,且实现了正确分类,这一结果进一步验证了本文模型在小目标检测性能上的改进。此外,仔细观察还可以发现,在图片右侧存在遮挡的情况下,本文模型仍能准确检测并正确识别被遮挡目标,这表明本文模型在应对目标遮挡问题方面具有更好的鲁棒性。

在第 2 张图片的测试结果中,2 个模型在简单场景下的表现差异较小,均未能有效检测到后方严重遮挡的桌子和椅子。对于较明显的目标,2 个模型的检测效果和检测框的定位能力差距不大,这表明模型在处理严重遮挡场景的能力仍需进一步提升,同时对于结构简单目标的识别性能也有待改进。

第 3 张图片的结果显示,基准模型将沙发一角误识别为独立物体,而本文模型避免了这一错误。通过分析图片右侧 3 人检测框的定位精度可以发现,本文模型的预测框与真实目标的贴合度显著优于基准模型。



图7 检测效果对比

上述实验结果表明,本文模型在实现轻量化的同时,在实际检测任务中同样展现出优越的目标检测性能,有效平衡了模型检测能耗与检测精度。

2.3.2 热力图分析

图 8 是基准模型 YOLOv8n 与本文模型的热力图效果对比。通过分析第 1 幅图可以看出,基准模型的热力点大多集中在目标身体的中心部位,而本文模型在聚焦物体身体的基础上,增强了模型捕捉物体边缘轮廓的能力,且从画面中部 3 只羊中右上角的那一只分析来看,基准模型的精确率为 0.34,而本文模型的精确

率为 0.84,可见本文模型对于遮挡问题也有相当程度的应对能力。这一结果同样也表明本文模型在物体边缘轮廓检测方面的能力也优于基准模型。

在第 2 幅和第 3 幅图中同样体现本文模型擅长聚焦于物体的边缘,而且在第 3 幅图中,基准模型漏检左侧的车辆,而本文模型能检测并正确识别。这辆车的情形也可认为是遮挡问题,这也表明本文模型对于遮挡问题处理的有效性。




图 8 热力效果对比

2.4 定量实验结果与分析

2.4.1 消融实验分析

以 YOLOv8n 作为基准模型 (baseline),在 VOC2007+VOC2012 数据集上进行训练与评估。首先在特征融合层的优化实验中对比跨像素跨通道注意力 (Cross-Pixel Cross-Channel Attention, CPCA) 机制^[20]、卷积块注意力模块 (Convolutional Block Attention Module, CBAM)^[21]、动态注意力 (Dynamic Attention, DA) 机制^[22]和大核分离卷积注意力模块 (Large Separable Kernel

Attention, LSKA) 的性能表现。如表 2 所示,在相同实验条件下,LSKA 相较于 DA 在参数量与计算量上分别减少 6.6% 和 1.3%,并在 mAP@0.5 上增长 0.2 个百分点。LSKA 机制在保持最低参数量和计算成本的同时,实现了最优的检测精度。因此,本文采用 LSKA 机制对 SPPF 层进行改进。

表 2 注意力机制对比

注意力机制	mAP@0.5/%	mAP@0.5:0.95/%	Params/10 ⁶	计算量/GFLOPs
CPCA	39.9	23.9	3.08	14.7
CBAM	39.5	23.8	3.02	14.5
LSKA	40.1	23.9	3.02	14.5
DA	39.9	24.1	3.22	14.7

实验整体消融数据如表 3 所示。在利用 DC 模块对下采样模块进行改进后,模型参数量和计算量分别降低了 20.0% 和 18.5%,而 mAP@0.5 指标仅下降 1.8 个百分点,实现了较好的性能平衡。进一步将普通卷积层替换为 LADM 后,参数量与计算量分别减少了 13.75% 和 3.03%,同时精确率损失控制在 0.9 个百分点以内,验证了该模块在模型轻量化方面的有效性。再之后利用 LSKA 模块对 SPPF 层进行优化,改进模型在精确率保持不变的情况下,mAP@0.5、mAP@0.5:0.95 和 R 指标分别增长 0.6、0.7 和 0.6 个百分点,表明 LSKA 模块有效增强了模型对目标检测框的定位能力。最后,将检测头替换为 LPSDED,使模型参数量和计算量分别进一步降低 17.87% 和 20.31%,模型能耗进一步降低。综合所有改进措施,本文模型相较于基准模型参数量和计算量分别减少了 43.3% 和 37.0%,而精确率损失仅为 2 个百分点,并且 mAP@0.5 与 mAP@0.5:0.95 指标相较于基准模型分别下降 3.4 和 4.1 个百分点,在实际场景的检测效果也要优于基准模型。

上述实验结果验证了本文提出的轻量化改进方案的有效性,成功实现了计算效率与算法性能的优化平衡。

表 3 消融实验结果

算法	P/%	R/%	mAP@0.5/%	mAP@0.5:0.95/%	Params/10 ⁶	计算量/GFLOPs
baseline	79.0	63.8	72.3	53.0	3.00	8.1
baseline+DC ^[14]	78.6	61.8	70.5	50.7	2.40	6.6
baseline+DC+LADM	77.7	60.8	69.3	49.3	2.07	6.4
baseline+DC+LADM+LSKA	77.7	61.4	69.9	50.0	2.34	6.7
baseline+DC+LADM+LSKA+LPSDED	77.0	61.0	68.9	48.9	1.70	5.1

2.4.2 轻量化对比

在相同数据集和训练条件下,将本文模型与当前主流目标检测模型如 YOLOv8s^[7]、单次多框检测器 (Single Shot MultiBox Detector, SSD)^[23]、YOLOv5s、YOLOv7-tiny^[5] 在 mAP@0.5、mAP@0.5:0.95、参数量和计算量等关键指标上进行对比,同时与若干改进的轻量化算法进行了性能评估,具体对比结果如表 4 所示。

与基于轻量化主干网络改进的 YOLOv8n-FasterNet^[24] 和 YOLOv8n-MobileNet 相比,本文模型展现出显著优势。具体地,在参数量和计算量相当的情况下,本文模型相较于 YOLOv8n-FasterNet 在 mAP@0.5 和 mAP@0.5:0.95 指标上分别提升了 3.8 和 5.8 个百分点,这一结果充分验证了本文模型在检测精度和多尺度目标适应能力方面的优越性。

此外,与 YOLOv8n-MobileNet 相比,本文模型在参数量和计算量分别减少 32.00% 和 10.53% 的同时,mAP@0.5 和 mAP@0.5:0.95 指标分别提升 3.2 和 3.5 个百分点,进一步验证了本文模型的有效性。相较于 YOLOv8s、SSD、YOLOv5s 模型,尽管在参数量和计算量方面存在显著差异,但从单位计算成本下的性能表现来看,YOLOv8s 单位计算成本的性能表现值为 2.735,YOLOv5s 单位计算成本的性能表现值为 4.905,SSD 单位计算成本的性能表现值为 1.226,而本文模型单位计算成本的性能表现值为 13.509,这一结果充分说明本文模型在单位计算成本下的性能表现更优异。同时也表明在同等计算资源约束下,本文模型有望实现更优越的目标检测性能,为轻量化目标检测算法的设计与优化提供了新的思路。

表 4 轻量化模型对比

模型	mAP@0.5/%	mAP@0.5:0.95/%	Params/10 ⁶	计算量/GFLOPs
YOLOv8s	78.5	57.7	11.1	28.7
SSD	76.9	46.9	26.3	62.7
YOLOv5s	78.0	54.2	7.0	15.9
YOLOv7-tiny	76.4	50.3	5.8	13.3
YOLOv8n-FasterNet	65.1	43.1	1.7	5.1
YOLOv8n-MobileNet	65.7	45.4	2.5	5.7
DLLL-YOLO(本文模型)	68.9	48.9	1.7	5.1

2.4.3 有效感受野对比

为进一步验证实验的有效性,进行有效感受野(Effective Receptive Field, ERF)^[25]对比实验,结果如表5所示。有效感受野指输入图像中对神经元激活有显著影响的区域,即实际起作用的区域,不同于理论感受野,它通常呈高斯分布,中心区域贡献更大,可能因为网络深度和卷积操作的影响而缩小,通过反向传播或梯度分析发现,实际影响神经元输出的区域可能远小于理论值。

表5展示了给定阈值 t 的贡献评分,即最小矩形的高分子贡献面积比 r , t 越大, r 越大,即有效感受野越大,说明高贡献像素的分布越平滑,意味着大多数像素有助于最终预测。分析表5数据可知,在相同层的情况下,本文模型有效感受野范围几乎全部优于基准模型。具体地,从小目标检测图P3(第15层)来看,本文模型相较于基准模型,在 $t=20\%$, $t=30\%$, $t=50\%$, $t=99\%$ 时,实际起作用的像素面积分别增长33.3%、35.7%、36.5%和16.9%;从大目标检测图P5(第9层)来看,实际起作用的像素面积分别增长5.5%、3.2%、0.7%和16.4%。这些数据表明,无论从大目标检测还是小目标检测的角度,本文模型相较于基准模型都有更优越的检测性能,并且小目标检测的能力提升更多,佐证了本文模型在高轻量化程度下检测能力不弱于基准模型,也验证了本文模型在物体边缘检测上的能力来源。

表5 有效感受野对比

模型	层号 n	t 值/%			
		20%	30%	50%	99%
YOLOv8n	5	0.1	0.1	0.2	1.7
	7	0.3	0.5	1.1	8.7
	9	3.6	6.1	13.1	75.2
	15	0.6	1.4	5.2	71.4
	18	1.9	3.4	8.1	81.4
DLLL-YOLO	5	0.1	0.1	0.2	2.5
	7	0.3	0.5	1.1	31.4
	9	3.8	6.3	13.2	87.6
	15	0.8	1.9	7.1	83.5
	18	2.1	3.7	9.1	85.3

3 结语

针对 YOLOv8n 在硬件能力不足的设备上难部署的问题,本文基于 YOLOv8n 提出轻量化目标检测算法 DLLL-YOLO,通过引入双卷积核结合组卷积技术,降低计算成本;利用轻量型自适应下采样模块(LADM),在降低参数量与计算量的同时,更好地保留重要的特征信息;引入 LSKA 机制增强特征融合层的多尺度特征提取能力;此外,利用轻量型参数共享与细节增强检测头(LPSDED)实现不同尺度特征信息的共享,增强检测效果并且进一步降低网络的计算量与参数量。实验结果表明,本文模型以整体较小的精度牺牲带来模型计算成本的大幅降低,成功实现了模型轻量化与模型性能的平衡。在后续工作中,将更深入地考虑模型整体结构的优化,以提升模型对小目标的检测能力。

参考文献(References)

- [1] 郭庆梅,刘宁波,王中训,等. 基于深度学习的目标检测算法综述[J]. 探测与控制学报, 2023, 45(6): 10-20, 26.
- [2] 张阳婷,黄德启,王东伟,等. 基于深度学习的目标检测算法研究与应用综述[J]. 计算机工程与应用, 2023, 59(18): 1-13.
- [3] TERVEN J, CORDOVA-ESPARZA D M, ROMERO-GONZÁLEZ J A. A comprehensive review of YOLO architectures in computer vision: from YOLOv1 to YOLOv8 and YOLO-NAS [J]. Machine Learning and Knowledge Extraction, 2023, 5(4): 1680-1716.
- [4] WEI J, QU Y, GONG M, et al. VE-YOLOv6: a lightweight small target detection algorithm[C]// Proceedings of the 4th International Conference on Neural Networks, Information and Communication. Piscataway: IEEE, 2024: 873-876.
- [5] WANG C Y, BOCHKOVSKIY A, MARK LIAO H Y. YOLOv7: trainable bag-of-freebies sets new state-of-the-art for real-time object detectors [C]// Proceedings of the 2023 IEEE/CVF Conference on

- Computer Vision and Pattern Recognition. Piscataway: IEEE, 2023: 7464-7475.
- [6] CHARY P S. Real time object detection using YOLOv4 [J]. International Journal for Research in Applied Science and Engineering Technology, 2023, 11(XII): 1375-1379.
- [7] SOHAN M, SAI RAM T, RAMI REDDY C V, et al. A review on YOLOv8 and its advancements [C]// Proceedings of the 2023 International Conference on Data Intelligence and Cognitive Informatics, AIS. Singapore: Springer, 2024: 529-545.
- [8] 刘子洋,徐慧英,朱信忠,等. Bi-YOLO:一种基于 YOLOv8n 改进的轻量化目标检测算法[J]. 计算机工程与科学, 2024, 46(8): 1444-1454.
- [9] 赵翠芳,唐启恒,徐慧英,等. DCD-YOLO:基于改进 YOLOv8n 无人机小目标轻量化检测算法[J/OL]. 浙江师范大学学报(自然科学版) [2024-12-18]. <https://doi.org/10.16218/j.issn.1001-5051.2025.024>.
- [10] 汤子旋,张伟,李俊麟,等. FSG-YOLO:基于 YOLOv8 改进的轻量化月面障碍物检测算法[J]. 载人航天, 2024, 30(5): 666-675.
- [11] 王舒梦,徐慧英,朱信忠,等. 基于改进 YOLOv8n 航拍轻量化小目标检测算法: PECS-YOLO [J/OL]. 计算机工程 [2024-12-18]. <https://doi.org/10.19678/j.issn.1000-3428.0069353>.
- [12] 王泽宇,徐慧英,朱信忠,等. 基于改进 YOLOv8 的轻量化鱼苗检测算法: FD-YOLO[J]. 计算机工程, 2025, 51(4): 327-338.
- [13] 张丽娟,游浩海,李芝贻,等. 基于改进 YOLOv8n 轻量化的人参外观质量精准识别[J]. 农业工程学报, 2024, 40(24): 274-282.
- [14] ZHONG J, CHEN J, MIAN A. DualConv: dual convolutional kernels for lightweight deep neural networks[J]. IEEE Transactions on Neural Networks and Learning Systems, 2023, 34(11): 9528-9535.
- [15] LI M, LIU W, KANG Z, et al. Single image dehazing via multi-scale large kernel convolutional neural networks [C]// Proceedings of the 2024 International Joint Conference on Neural Networks. Piscataway: IEEE, 2024: 1-8.
- [16] WU Y, HE K. Group normalization [C]// Proceedings of the 2018 European Conference on Computer Vision, LNCS 11217. Cham: Springer, 2018: 3-19.
- [17] ZHOU K, HUANG X, LI Y, et al. Towards deeper graph neural networks with differentiable group normalization [C]// Proceedings of the 34th International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2020: 4917-4928.
- [18] LI F, BAI H, ZHAO Y. Detail-preserving image super-resolution via recursively dilated residual network[J]. Neurocomputing, 2019, 358: 285-293.
- [19] EVERINGHAM M, VAN GOOL L, WILLIAMS C K I, et al. The PASCAL Visual Object Classes (VOC) challenge [J]. International Journal of Computer Vision, 2010, 88(2): 303-338.
- [20] CHEN C, ZHANG H, CHEN X, et al. MSCB-YOLOv8: multi-scale cigarette butt small object detection model with channel prior convolutional attention [C]// Proceedings of the 4th International Conference on New Energy and Power Engineering. Piscataway: IEEE, 2024: 593-597.
- [21] WOO S, PARK J, LEE J Y, et al. CBAM: convolutional block attention module[C]// Proceedings of the 2018 European Conference on Computer Vision, LNCS 11211. Cham: Springer, 2018: 3-19.
- [22] XIA Z, PAN X, SONG S, et al. Vision Transformer with deformable attention [C]// Proceedings of the 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2022: 4784-4793.
- [23] LIU W, ANGUELOV D, ERHAN D, et al. SSD: single shot MultiBox detector [C]// Proceedings of the 2016 European Conference on Computer Vision, LNCS 9905. Cham: Springer, 2016: 21-37.
- [24] CHEN J, KAO S H, HE H, et al. Run, don't walk: chasing higher FLOPS for faster neural networks[C]// Proceedings of the 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2023: 12021-12031.
- [25] DING X, ZHANG X, HAN J, et al. Scaling up your kernels to 31×31: revisiting large kernel design in CNNs [C]// Proceedings of the 2022 IEEE/CVF Conference on computer Vision and Pattern Recognition. Piscataway: IEEE, 2022: 11953-11965.