

基于YOLOv11-Pose的轻量化人体姿态估计模型

刘玉成^{1,2}, 王甜甜^{1,2}, 刘美^{1*}

(1. 广东石油化工学院 自动化学院, 广东 茂名 525000; 2. 吉林化工大学 电气与控制工程学院, 吉林 吉林 132022)

(* 通信作者电子邮箱 879643579@qq.com)

摘要:在人体姿态估计(HPE)领域,当前的深度学习架构面临检测精度不足、模型参数复杂以及计算成本高昂的问题,极大地限制了它在实际应用中的推广。为了解决上述难题,提出一种轻量化HPE模型LSPM-YOLO (Lightweight Shared convolution and Progressive Multi-scale YOLO)。首先,针对检测精度不足的问题,引入风车形状卷积(PSConv)替代传统下采样模块,并将大型可分离核注意力(LSKA)模块与快速空间金字塔池化(SPPF)模块融合,强化模型的特征提取能力;其次,为了解决肢体遮挡导致的特征丢失问题,设计渐进多尺度特征提取(EPMF)模块,以深度可分离卷积(DWConv)为基础构建特征拆分与逐级传递通道,并结合残差连接实现浅层姿态细节特征与深层语义特征的融合,从而通过多尺度特征互补减少遮挡区域的特征歧义;最后,针对模型参数复杂和计算成本高昂的问题,在检测头部分设计一种轻量级共享卷积姿态检测头,从而利用共享卷积机制进行参数共享,同时对关键点分支的卷积核尺寸进行优化,从而在保证关键点检测完整性的前提下减少冗余参数与计算操作。在COCO-Pose2017和MPII数据集上的实验结果表明,与基准模型YOLOv11-Pose相比,LSPM-YOLO模型的参数量减少了17%,平均精度AP50分别提升了1.3和1.2个百分点。可见,LSPM-YOLO模型在轻量化设计的同时,实现了更高的检测精度。

关键词:人体姿态估计;风车形状卷积;大型可分离核注意力;共享卷积;轻量化模型

中图分类号:TP391.4 **文献标志码:**A

Lightweight human pose estimation model based on YOLOv11-Pose

LIU Yucheng^{1,2}, WANG Tiantian^{1,2}, LIU Mei^{1*}

(1. School of Automation, Guangdong University of Petrochemical Technology, Maoming Guangdong 525000, China;

2. College of Information and Control Engineering, Jilin University of Chemical Technology, Jilin Jilin 132022, China)

Abstract: In the field of Human Pose Estimation (HPE), current deep learning architecture faces challenges such as insufficient detection accuracy, complex model parameters, and high computational cost, which greatly limit its promotion in practical applications. To overcome the above challenges, a lightweight HPE model LSPM-YOLO (Lightweight Shared convolution and Progressive Multi-scale YOLO) was proposed. Firstly, to address the issue of insufficient detection accuracy, the Pinwheel-Shape Convolution (PSConv) was introduced to replace the traditional downsampling module, and the Large Separable Kernel Attention (LSKA) module was fused with the Spatial Pyramid Pooling-Fast (SPPF) module to enhance the model's feature extraction capability. Secondly, to solve the problem of feature loss caused by limb occlusion, an Extraction of Progressive Multi-scale Features (EPMF) module was designed to construct a feature splitting and hierarchical transmission channel based on DepthWise separable Convolution (DWConv), and combine with residual connections to achieve the fusion of shallow pose detail features and deep semantic features, thereby reducing feature ambiguity in occluded areas through multi-scale feature complementarity. Finally, to address the issues of complex model parameters and high computational cost, a lightweight shared convolution pose detection head was designed in the detection head part for parameter sharing using the shared convolutions, and the convolution kernel size of the keypoint branch was optimized to reduce redundant parameters and computational operations while ensuring the integrity of keypoint detection. Experimental results on the COCO-Pose2017 and MPII datasets show that compared with the baseline model YOLOv11-Pose, LSPM-YOLO model reduces the parameter count by 17% and increases the Average Precision AP50 by 1.3 and 1.2 percentage points, respectively. It can be seen that LSPM-YOLO model achieves higher detection accuracy with lightweight design.

Key words: Human Pose Estimation (HPE); Pinwheel-Shaped Convolution (PSConv); Large Separable Kernel Attention (LSKA); shared convolution; lightweight model

0 引言

人体姿态估计(Human Pose Estimation, HPE)是行为识别的关键前置技术,通过精准定位图像或视频中人体关节、头部、肩部等关键部位并构建姿态的数字表征,为动作识别、人机交互、安防监控等应用提供核心支撑^[1];然而,主流基于深度学习的HPE模型通常参数量大、计算复杂度高,导致推理慢,难以满足实时性或资源受限设备的部署要求。对此,模型轻量化成为关键优化方向,它能显著降低计算资源需求,提升效率,促进HPE技术在边缘端的应用。因此,轻量化和优化HPE模型,对于推动这一技术的广泛应用至关重要。持续优化模型的效率与性能,将推动姿态估计技术普及至更多领域,并加速计算机视觉的发展。

传统HPE模型以图结构模型为基础,依赖人工设计的关节

拓扑关系与图像特征描述方式,缺乏自适应学习机制,在模型精度和跨场景泛化能力上存在明显短板^[2]。随着深度学习技术与神经网络模型的不断发展,HPE逐渐从图像处理过渡到使用神经网络迭代推理,并取得了显著进展。目前,基于深度学习的HPE模型主要分为自底向上和自顶向下这2种技术方法^[3]。自底向上方法优先识别图像中的所有关键点,随后按照个体完成姿态模型的组合构建。以Cao等^[4]开发的OpenPose模型为代表,该模型通过PAF(Part Affinity Fields)技术实现关键点的跨个体关联,能够满足多人实时姿态估计需求。Cheng等^[5]提出HigherHRNet模型,采用多分支结构并行处理多分辨率特征图,基于迭代优化机制提升关键点检测的精度,在多人场景下有卓越的性能;但该方法对关键点匹配算法的准确性要求极高,易出现关联误差。自顶向下方法则先定位图像中的人体目标,再对

收稿日期:2025-07-18;修回日期:2025-09-08;录用日期:2025-09-15。 基金项目:国家自然科学基金资助项目(62073091)。

作者简介:刘玉成(2000—),男,安徽合肥人,硕士研究生,主要研究方向:图像处理、计算机视觉; 王甜甜(2000—),女,河南南阳人,硕士研究生,主要研究方向:毫米波雷达、手势识别; 刘美(1967—),女,广东湛江人,教授,博士,主要研究方向:人工智能、控制工程。

每个目标独立进行姿态估计。以 Xiao 等^[6]提出的 SimpleBaseline 为代表,该模型结构由骨干网络和简单的反卷积模块组成,没有复杂的跳层连接或多分支结构,易于理解和实现,计算量相对较小,在速度和准确度之间取得了较好的平衡;Sun 等^[7]提出的 HRNet(High Resolution Network)模型通过并行多分辨率子网架构有效保留图像细节信息,规避了传统下采样操作导致的特征损失问题。不过,这类方法在复杂背景环境下,为确保检测精度需扩充模型规模,从而影响实时性表现;并且在多人交互场景中,容易受到目标遮挡和边界框定位误差的干扰。除以上模型外,Shotton 等^[8]提出了基于深度图的实时人体姿态检测模型。该模型通过 Kinect 深度摄像头将人体划分为 32 类身体部件(例如头部、肩部、肘部等),运用深度随机决策森林对深度图像素实施逐像素分类,生成关节候选位置,结合 Mean Shift 聚类方法对最终关节点进行定位,并依据解剖学原理进行分组,构建动态骨架;但是受限于硬件设备,该模型的部署成本高并且无法通过算法进一步优化提升,难以适应通用场景。

针对以上问题,2022 年,Maji 等^[9]提出了基于 YOLO(You Only Look Once)框架的 YOLOv5-Pose 单阶段 HPE 模型。其核心设计摒弃了热力图生成与解析流程,通过端到端坐标预测优化实时性与精度平衡。2023 年,Zhao 等^[10]基于 YOLOv5-Pose 模型,通过将跳跃注意力模块和 Transformer 相结合,提升拥挤场景下的多人姿态估计精度;2024 年,Lu 等^[11]提出了基于 YOLOv8-Pose 的 KSL-POSE 模型,通过引入非线性激活函数并结合 KAN 卷积,增强模型的特征提取能力;2025 年,Tu 等^[12]基于 YOLOv8-Pose 框架提出 HP-YOLO 模型,通过在主干网络集成 ELSKA 机制并在探测头引入 RepNCSPELAN4 模块,提升关键点和目标检测精度并加快推理速度;同年 2 月,Tian 等^[13]提出了 YOLOv12-Pose 模型,利用区域注意力降低计算复杂度,并通过 R-ELAN(Residual

Efficient Layer Aggregation Network)增强特征聚合;6 月,Lei 等^[14]在 YOLOv12-Pose 模型的基础上提出 YOLOv13-Pose,引入了 HyperACE(Hypergraph-based Adaptive Correlation Enhancement)机制,用于捕捉全局高阶多对多语义关系,提出 FullPAD(Full-Pipeline Aggregation-and-Distribution)架构,将增强特征贯穿于模型的全流程。

综上,在 HPE 任务里,基于 YOLO 框架的模型已经取得显著进展。然而,模型复杂度和检测精度之间的平衡问题仍然存在,这极大地限制了 YOLO 系列模型的实际运用。为此,本研究提出一种优化的 YOLOv11n-Pose HPE 模型。通过构建新型特征融合结构与轻量化的卷积模块,在减少模型参数和计算量的情况下,增强模型对人体姿态的估计能力。

1 本文模型

1.1 YOLOv11-Pose

YOLOv11-Pose 是 Ultralytics 团队推出的姿态估计领域最先进的模型,它延续了之前 YOLO-Pose 版本的卓越成果,并在架构设计上进行了重要的革新:通过重新构建主干网络和颈部网络,引入了 C3K2 与 C2PSA 等创新模块,大幅增强了从图像中提取特征的能力以及目标检测的效果。C3K2 模块是基于传统 C2f 模块与 C3 模块的改进设计,通过融合可变卷积核(如 3×3、5×5 等)和通道分离策略,构建了核心组件 C3K。此外,C3K2 模块可以通过布尔变量 C3K 控制是否采用 C3K 结构,若为 False 则使用常规瓶颈结构。这种灵活设计让 C3K2 具备更高效的特征提取能力,尤其适合复杂场景及深层次特征提取任务。C2PSA 模块则是一个用于强化特征提取的高级模块,结合了 CSP(Cross Stage Partial)结构与 PSA(Pyramid Squeeze Attention)机制,进一步提升了多尺度特征提取性能。YOLOv11-Pose 模型结构如图 1 所示。




图1 YOLOv11-Pose模型结构

1.2 风车形状卷积

传统卷积进行下采样时,从输入层提取信息的过程中会涉及大量的卷积计算。它通过固定卷积核进行空间与通道特征提取,存在计算冗余、空间自适应性不足及语义聚焦能力弱等问题。与传统卷积不同,风车形状卷积(Pinwheel-Shaped Convolution, PSConv)^[15]采用非对称填充为图像的不同区域创建水平和垂直卷积核,它的结构原理如图 2 所示。同时,在每次卷积后应用批归一化(Batch Normalization, BN)和 SiLU(Sigmoid Linear Unit)激活函数,以提升训练的稳定性 and 速度。它的公式如式(1)所示:

$$\begin{cases} X_1^{(h',w',c')} = \text{SiLU}\left(\text{BN}\left(X_{P(1,0,0,3)}^{(h,w,c_1)} \otimes W_1^{(1,3,c')}\right)\right) \\ X_2^{(h',w',c')} = \text{SiLU}\left(\text{BN}\left(X_{P(0,3,0,1)}^{(h,w,c_1)} \otimes W_2^{(3,1,c')}\right)\right) \\ X_3^{(h',w',c')} = \text{SiLU}\left(\text{BN}\left(X_{P(0,1,3,0)}^{(h,w,c_1)} \otimes W_3^{(1,3,c')}\right)\right) \\ X_4^{(h',w',c')} = \text{SiLU}\left(\text{BN}\left(X_{P(3,0,1,0)}^{(h,w,c_1)} \otimes W_4^{(3,1,c')}\right)\right) \end{cases} \quad (1)$$

其中: h_1, w_1 和 c_1 分别表示输入张量 $X(h_1, w_1, c_1)$ 的高度、宽度和通道大小; $\otimes$ 是卷积运算符; $W_1^{(1,3,c')}$ 是输出通道为 c' 的 1×3 卷积

核,填充参数 $P(1,0,0,3)$ 分别表示左、右、上和下方方向上的填充像素数。 h' 、 w' 、 c' 分别表示每个分支输出张量的高度、宽度和通道数,它与输入张量的关系如式(2)所示:

$$\begin{cases} h' = h_1/s + 1 \\ w' = w_1/s + 1 \\ c' = c_2/4 \end{cases} \quad (2)$$

其中: c_2 是来自 PSConv 模块的最终输出特征图的通道数, s 是卷积步幅。拼接 4 个分支,将不同方向卷积提取到的特征融合在一起,丰富特征信息,形成一个新的张量 X' ,公式如式(3)所示:

$$X^{(h',w',4c')} = \text{Cat}(X_1^{(h',w',c')}, X_2^{(h',w',c')}, \dots, X_4^{(h',w',c')}) \quad (3)$$

拼接后的张量再经过一个卷积核大小为 2×2 的卷积进行卷积操作,该卷积过程不进行填充。通过这一步卷积,对拼接后的

特征进行归一化处理,调整输出特征图的通道数,使它符合后续网络的输入要求,最终得到输出特征图,输出最终张量 Y ,公式如式(4)所示:

$$Y^{(h_2,w_2,c_2)} = \text{SiLU}(\text{BN}(X^{(h',w',4c')} \otimes W^{(2,2,c_2)})) \quad (4)$$

其中 h_2 、 w_2 分别表示最终输出张量 Y 的高度和宽度,公式如式(5)所示:

$$\begin{cases} h_2 = h' - 1 = h_1/s \\ w_2 = w' - 1 = w_1/s \end{cases} \quad (5)$$

这种设计利用 PSConv 独特的风车状结构,能够在不显著增加参数数量的前提下,实现更大的感受野,有效地捕捉目标的上下文信息;尤其是在目标尺寸较小、背景复杂的情况下,能有效减少漏检,提高检测准确性和鲁棒性。




图2 风车形状卷积结构

1.3 大型可分离核注意力

在 YOLOv11-Pose 中,快速空间金字塔池化(Spatial Pyramid Pooling-Fast, SPPF)作为多尺度特征融合模块,虽然继承了高效计算的优势,但受限于设计初衷和结构特性,在复杂姿态尺度适应、细粒度特征保留和多尺度信息互补方面表现不足,尤其对高精度关节点定位的支持较弱。针对上述问题,提出了 SPPF_LSKA 模块,它的结构原理如图 3 所示。




图3 SPPF_LSKA 模块的结构

视觉注意力网络(Visual Attention Network, VAN)凭借它的大卷积核注意力(Large Kernel Attention, LKA)^[16]模块,在多种视觉任务上展现出卓越性能,甚至超越了视觉变换器(Vision Transformer, ViT);然而,LKA 模块中的深度卷积层随着卷积核增大,它的计算量和内存占用会呈二次方增长,这限制了超大卷积核的应用。为了突破这一计算瓶颈,Lau 等^[17]提出了大型可分离核注意力(Large Separable Kernel Attention, LSKA)模块。LSKA 的核心创新在于将深度卷积层的二维大卷积核分解为级联的水平和垂直一维核,结构原理如图 4 所示。与标准 LKA 相比,这种可分离分解策略使得 VAN 能够在它的注意力模块中直接高效地使用极大卷积核,而无须引入额外结构,在显著降低了计算复杂度和内存占用的同时,保持与标准 LKA 相当的性能。

SPPF_LSKA 模块在拼接操作后引入 LSKA 注意力机制,一方面借助可分离卷积的多尺寸核与注意力动态选择能力,突破了传统 SPPF 固定池化结构导致的感受野僵化问题,能根据目标尺度自适应匹配局部细节或全局上下文;另一方面,LSKA 的通道与空间注意力加权机制,替代了传统 SPPF 简单拼接多尺度特征的方式,有效过滤冗余信息并强化关键特征,同时可分离卷积的设计在避免池化导致的细节丢失的基础上降低了计算复杂度,提升了多尺度特征融合的有效性与定位精度。

1.4 渐进多尺度特征提取

C3K2 是 YOLOv11-Pose 中的创新模块,但随着模型深度的增加,特征图分辨率降低,小目标的细节易被丢失,对不同尺度目标的适应性有限,难以同时处理大目标和小目标。针对上述问题,提出了渐进多尺度特征提取(Extraction of Progressive Multi-scale Features, EPMF)模块,结构原理如图 5 所示。EPMF 模块不直接

对输入特征进行一次性多尺度操作,而是通过特征拆分、逐级传递的方式分步骤处理,结合不同尺寸的卷积核(如 3×3 、 5×5 、 7×7)捕获多尺度信息。其次,引入深度可分离卷积(DepthWise separable Convolution, DWConv)^[18]以减少因大尺寸卷积核带来的参数影响,在保持性能的同时提升推理速度。




图4 LKA 与 LSKA 模块的结构

EPMF 模块通过渐进式特征处理链路与多尺度信息融合策略,实现了高效的特征增强与冗余计算规避,它的核心逻辑体现在对不同尺度感受野的分层捕捉与精准整合。首先采用 3×3 DWConv 对输入原始特征进行初步处理,在保持特征提取能力的同时大幅降低计算量。随后,模块利用 chunk 函数将处理后的特征图按通道维度均匀拆分为两部分,分别记为 Feature_A、Feature_B,取其中 Feature_A 进入下一级处理,通过 5×5 DWConv 进一步扩大感受野,捕捉比 3×3 卷积更广泛的空间关联,处理后再次按通道均匀拆分为两部分,记为 Feature_C、Feature_D。接着,再取其中 Feature_C 通过 7×7 DWConv 处理得到 Feature_E,该卷积的超大感受野能够有效捕捉深层语义信息。以上每一步处理都建立在对上一阶段特征的拆分基础上,形成递进链条,避免一次性处理全尺度信息导致的冗余计算。最终将各阶段输出拼接整合,既保留了浅层细节,又融入了深层语义。此外,通过残差连接将原始输入特征与最终整合特征相加,有效缓解了深层网

络中的梯度消失问题,确保浅层细节信息能顺畅传递至后续网络层,进一步增强了信息流的完整性。




图5 EPMF模块结构

1.5 轻量化共享卷积姿态检测头

YOLOv11-Pose作为YOLO系列的最新姿态估计版本,它的检测头延续了以往“检测+姿态”的联合优化思路,侧重高效性和通用性。为了兼顾速度,通常采用较粗粒度的特征融合,且关键点预测与边界框检测共享大部分特征,可能导致小尺度关键点或被遮挡关节的定位精度下降。针对上述问题,提出轻量化共享卷积姿态检测头(Lightweight Shared Convolutional Pose detection head, LSCP),结构原理如图6所示。LSCP模块引入了共享卷积机制^[19]和分离BN计算。将3×3卷积与1×1卷积组成的核心特征提取设为共享模块,所有检测层均复用这组卷积的权重参数,通过共享特征提取层,避免了为每个检测层单独计算相同的特征,大幅减少了重复计算和存储开销。在此基础上,每个检测层都有独立的BN和SiLU激活函数,通过平滑的非线性变换进一步增强特征的非线性表达能力,能更精细地调整特征分布,提升检测分支对复杂特征的捕捉能力。

在关键点分支的网络结构设计上,YOLOv11-Pose采用了一种相对简洁的架构方案,它的核心由3×3 DWConv与3×3普通卷积构成,其中DWConv通过将通道与空间卷积分离实现轻量化,而3×3卷积则负责捕捉局部空间关联,两者串联后直接输出关键点坐标与可见性的预测结果。这种结构虽能在一定程度上平衡

精度与速度,但受限于单一卷积组合的特征表达能力,对复杂场景下的被遮挡关节、小尺度目标等捕捉能力有限,且缺乏针对性的维度调整机制,容易因特征通道冗余或不足影响预测精度。相比之下,LSCP模块则采用了更为精细化的卷积结构设计策略:第一个1×1卷积通过降维与通道整合,在保留核心信息的同时减少后续计算量;中间的3×3卷积则专注于空间特征提取,利用更大的感受野捕捉关键点间的空间关联,并通过SiLU激活函数增强特征的非线性表达能力;最后的1×1卷积则通过升维,将处理后的特征精准映射至关键点所需的输出维度。这种结构上的优化使得LSCP模块在保持较高关键点检测精度的同时,在关键点分支上通过两次1×1卷积的操作实现了独立降维处理,避免了3×3卷积在高通道数下的计算冗余,提升了特征提取效率。




图6 LSCP模块结构

1.6 LSPM-YOLO整体结构

本文提出的HPE改进模型LSPM-YOLO的整体结构如图7所示。以YOLOv11-Pose模型为基础,首先用PSConv取代原下采样模块,利用非对称填充为图像的不同区域创建水平和垂直卷积核,形成独特的风车状结构,在扩大感受野的同时参数量小幅减少,有效提升特征提取能力;其次,在SPPF模块中引入LSKA注意力机制,动态调整感受野、加权融合多尺度特征,保留细节信息的同时利用可分离卷积的设计在避免池化导致的细节丢失的基础上降低了计算复杂度;再次,在此基础上提出EPMF模块,利用渐进式特征处理,通过特征拆分、逐级传递的方式分步骤处理,结合不同尺寸的卷积核,在捕获多尺度信息的同时通过残差连接覆盖完整的人体尺度,实现跨层特征复用;最后,通过优化原检测头,实现轻量化共享卷积,利用独立BN和SiLU激活函数以及关键点分支的独立降维处理,使不同尺度的特征能被更精准地处理,提升关键点定位精度。




图7 LSPM-YOLO的整体结构

最终,这种设计使得 LSPM-YOLO 所采用的设计策略有效实现了模型精度与计算复杂度的协同优化。该方案显著降低了模型推理所需的计算资源需求,使它具备在移动终端及嵌入式设备等资源受限环境下高效部署的可行性,从而提升了模型在广泛实际应用场景中的实用性与竞争力。

2 实验及分析

2.1 实验数据集和环境

为验证 LSPM-YOLO 模型的性能,本文在 COCO-Pose2017^[20]和 MPII^[21]数据集上进行实验。COCO-Pose2017 数据集是 COCO-2017 数据集中专门用于人体关键点检测的子集,包含超过 250 000 个人类实例。其中训练集有 56 599 幅图像,验证集有 2 346 幅图像,测试集有 20 000 幅图像。数据集中包含单人与多人以及不同场景的图像,兼顾了遮挡处理、人群密集场景。MPII 数据集约 25 000 幅图像,涵盖了 410 种人类活动,为姿态估计模型在不同活动场景下的训练和评估提供了丰富的数据支持,其中训练集约 15 000 幅图像,验证集约 3 000 幅图像,测试集约 7 000 幅图像。

实验环境基于 Windows 10 系统,具体配置如表 1 所示。

表 1 实验环境配置

参数	配置
操作系统	Windows 10
CUDA 版本	12. 1
Epochs	200
GPU	NVIDIA GeForce RTX 4090
Python	3. 10
PyTorch	2. 1. 1

2.2 实验指标

在 HPE 任务中,预测关键点与真实关键点之间的相似度并非简单地用欧氏距离计算,而是引入了尺度归一化指标来计算两点之间的相似度。一般会将关键点位置偏差、大小因素及可见性的关键点相似度(Object Keypoint Similarity, OKS)视为重要指标,它的公式如式(6)所示:

$$V_{\text{OKS}} = \frac{\sum_i \exp\left(-\frac{d_i^2}{2s_k^2\sigma_i^2}\right) \cdot \delta(v_i > 0)}{\sum_i \delta(v_i > 0)} \quad (6)$$

表 2 COCO-Pose2017 与 MPII 数据集上的实验数据对比

数据集	模型名称	参数量/ 10^6	AP50/%	AP75/%	AP(0. 50:0. 95)/%	AR50/%	AR75/%	AR(0. 50:0. 95)/%
COCO-Pose2017	Lite-HRNet	1. 8	82. 5	62. 5	57. 6	86. 2	71. 8	62. 1
	SimCC	2. 3	84. 6	62. 9	57. 4	86. 4	72. 6	65. 9
	RTMPose	3. 3	83. 1	62. 6	56. 2	86. 1	72. 8	67. 1
	YOLOv5-Pose	2. 5	80. 9	61. 7	56. 1	88. 8	71. 7	65. 6
	YOLOv8-Pose	3. 0	83. 0	64. 5	58. 2	89. 4	73. 6	67. 3
	YOLOv11-Pose	2. 9	82. 8	64. 2	58. 5	90. 0	73. 4	67. 7
	YOLOv12-Pose	2. 8	83. 5	64. 7	58. 8	90. 4	73. 8	67. 9
	YOLOv13-Pose	2. 7	83. 8	64. 8	58. 7	90. 1	74. 2	67. 8
MPII	LSPM-YOLO	2. 4	84. 1	65. 7	59. 7	90. 8	74. 9	68. 7
	Lite-HRNet	1. 8	89. 2	80. 0	72. 7	90. 7	84. 5	80. 4
	SimCC	2. 3	91. 2	80. 5	72. 2	95. 5	86. 2	79. 8
	RTMPose	3. 3	88. 9	79. 7	70. 4	91. 7	87. 9	79. 6
	YOLOv5-Pose	2. 5	92. 4	81. 2	73. 3	97. 0	87. 8	80. 8
	YOLOv8-Pose	3. 0	91. 8	80. 8	73. 1	96. 3	88. 0	80. 6
	YOLOv11-Pose	2. 9	92. 2	81. 7	73. 9	96. 7	87. 6	80. 5
	YOLOv12-Pose	2. 8	92. 6	81. 1	72. 5	97. 3	87. 5	79. 8
	YOLOv13-Pose	2. 7	92. 0	79. 4	71. 2	97. 0	86. 8	78. 9
	LSPM-YOLO	2. 4	93. 4	82. 5	74. 6	97. 4	88. 7	81. 5

另外,本文在 MPII 数据集上进一步实验,可以看出,LSPM-YOLO 模型与基准模型 YOLOv11-Pose 相比:AP50 提高了 1. 2 个百分点,AP75 提高了 0. 8 个百分点,AP(0. 50:0. 95)提高了 0. 7 个百分点;AR50 提高了 0. 7 个百分点,AR75 提高了 0. 9 个百分点,AR(0. 50:0. 95)提高了 1. 0 个百分点。虽然 LSPM-YOLO 模型参

其中: i 是第*i*类关键点对应的关键点; d_i 是第*i*个关键点的预测位置与真实位置之间的欧几里得距离; s 是目标区域的尺度大小,一般用于尺度归一化; k_i 是第*i*个关键点的权重因子,是一个预定义的、针对不同关键点类型的常数,反映了该关键点标注的可重复性; v_i 表示第*i*个关键点的可见性标签, $v_i = 0$ 表示未标注,通常不在图像内, $v_i = 1$ 表示标注但不可见,通常指被遮挡, $v_i = 2$ 表示标注且可见,关键点在图像内清晰可见; δ 是指当关键点被标注,无论是否可见函数值为 1,未被标注函数值为 0。

OKS 的值介于 0~1,数值越接近 1,说明预测的人体关键点与数据集中标注的真实值吻合度越高,模型的预测效果越好;反之亦然。在实际应用中,OKS 常与精准度(Precision, P)、召回率(Recall, R)等指标结合,全面评估 HPE 模型的表现。本文选取平均精度(Average Precision, AP)的多个变体,包括 AP50、AP75 和 AP(0. 50:0. 95),以及平均召回率(Average Recall, AR)的对应指标 AR50、AR75 和 AR(0. 50:0. 95),作为评估模型性能的关键指标。其中,AP50 代表在设定阈值为 0. 5 时的平均精度;AP75 则对应阈值为 0. 75 时的平均精度;AP(0. 50:0. 95)则涵盖了阈值范围从 0. 5 至 0. 95 的所有平均精度值。AR 衡量的是模型在所有真实目标中能够正确识别出的目标比例。其中,AR50 和 AR75 分别对应阈值为 0. 5 和 0. 75 时的平均召回率;而 AR(0. 50:0. 95)则表示阈值从 0. 5 至 0. 95 的整个范围内的平均召回率。此外,还选取参数量和浮点运算数(FLOating Point operations)作为对比模型大小和计算复杂度的关键指标。

2.3 对比实验结果

LSPM-YOLO 模型在 COCO-Pose2017 数据集上与 Lite-HRNet (Lightweight High-Resolution Network)^[22]、SimCC (Simple Coordinate Classification)^[23]、RTMPose (Real-Time Multi-person Pose)^[24]、YOLOv5-Pose、YOLOv8-Pose、YOLOv11-Pose、YOLOv12-Pose、YOLOv13-Pose 等主流模型的实验对比结果如表 2 所示。

从 COCO-Pose2017 数据集上的实验结果可以看出,LSPM-YOLO 模型与基准模型 YOLOv11-Pose 相比,模型的参数量减少了 17%,AP50 增加 1. 3 个百分点,AP75 增加 1. 5 个百分点,AP(0. 50:0. 95)增加 1. 2 个百分点,AR50 增加 0. 8 个百分点,AR75 增加 1. 5 个百分点,AR(0. 50:0. 95)增加 1. 0 个百分点。

数量比 Lite-HRNet 多,但是在 AP50 和 AR50 上分别提高了 4. 2 个百分点和 6. 7 个百分点,其余指标也有不同程度的增长。

上述结果表明,LSPM-YOLO 模型比基准模型 YOLOv11-Pose 检测准确率更高,效果更好,参数量也得到了明显下降。与 Lite-HRNet、SimCC、RTMPose、YOLOv5-Pose、YOLOv8-Pose、YOLOv12-

Pose、YOLOv13-Pose 等主流模型相比,LSPM-YOLO 模型在精度上有着明显优势。通过分析上述实验结果可以得出相同结论,LSPM-YOLO 模型比基准模型 YOLOv11-Pose 更加高效,更适合在计算资源有限的设备上部署。

2.4 消融实验

在 COCO-Pose2017 数据集上,为测试 PSCnv、SPPF_LSKA、EPMF 和 LSCP 四个模块的有效性进行消融实验,训练设置保持不变,实验结果如表 3 所示。

从实验结果可以看出,原 YOLOv11-Pose 模型加入 LSCP 模块后参数量和 FLOPs 分别降低了 10% 和 9%,AP50 只是略微降低了 0.3 个百分点;引入 LSKA 注意力机制和 PSCnv 后,参数量和 FLOPs 略微上涨,AP50 提升了 1.1 个百分点;加入 EPMF 模块后,LSPM-YOLO 模型比原 YOLOv11-Pose 模型参数量降低了 17%,AP50 增加 1.3 个百分点,同时 FLOPs 降低了 7%。

为了评估改进后的模型性能,进行了检测结果的可视化对比分析,实际检测结果对比如图 8 所示。

从图 8(a) 可以得知,在肢体遮挡场景下,基准模型 YOLOv11-Pose 因对遮挡应对不足,关键点估计易出现较大误差,错误定位被遮挡肢体的关键点,导致检测关键点与实际位置偏差明显;在小目标检测场景中,YOLOv11-Pose 模型因小目标特征不显著,易出现关键点坐标偏移、部分关键点遗漏等问题,使得估计误差增大,影响整体检测精度。从图 8(b) 可以得知,LSPM-YOLO 模型凭借其针对遮挡场景的优化设计,能更精准地推断被遮挡部位,关节点的连线更贴合人体实际姿态,在遮挡区域的关节点处理上,估计误差有所减小,同时置信度下降幅度小,仅降低

0.01;在小目标检测场景中,LSPM-YOLO 模型从其较高的置信度 0.83、0.81 与 0.89 可知,对比基准模型 YOLOv11-Pose 分别提高了 0.12、0.03 和 0.01,说明估计误差得到了有效降低,充分体现出在小目标检测时的低误差特性,进一步证明了该模型在复杂场景下处理关键点估计任务的可靠性。

表 3 消融实验数据对比

实验	LSCP	SPPF_LSKA	PSCnv	EPMF	参数量/ 10 ⁶	FLOPs/ 10 ¹⁰	AP50/%
1	—	—	—	—	2.9	7.4	82.8
2	√	—	—	—	2.6	6.7	82.5
3	—	√	—	—	3.1	7.6	83.4
4	—	—	√	—	2.7	7.4	83.1
5	—	—	—	√	2.5	7.5	83.9
6	√	√	—	—	2.8	6.9	82.7
7	√	—	√	—	2.4	6.7	82.8
8	√	—	—	√	2.2	6.7	83.5
9	—	√	√	—	3.0	7.6	83.4
10	—	√	—	√	2.8	7.7	83.7
11	—	—	√	√	2.4	7.5	83.6
12	√	√	√	—	2.7	7.0	83.6
13	√	√	—	√	2.5	6.9	84.0
14	√	—	√	√	2.0	6.7	83.7
15	—	√	√	√	2.7	7.7	83.8
16	√	√	√	√	2.4	6.9	84.1

注:“—”代表未使用。



(a) YOLOv11-Pose 模型检测图

(b) LSPM-YOLO 模型检测图

图 8 YOLOv11-Pose 与 LSPM-YOLO 模型结果对比示例

3 结语

本文以 YOLOv11-Pose 模型为基础,提出了一种轻量化改进模型 LSPM-YOLO。通过引入 PSCnv 替代原有的下采样模块,显著增强了特征提取能力;同时,将大型可分离核注意力(LSKA)模块与 SPPF 模块相结合,有效提升了模型在处理复杂姿态时的性能。此外,还提出了一种 EPMF 模块,该模块通过渐进式多尺度特征融合和 DWConv 的运用,不仅实现模型轻量化,而且在保留浅层细节的同时融合了深层语义信息,并通过残差连接加强了信息流的完整性,从而更有效地处理肢体遮挡问题。在检测头的设计上,创新性地提出了一种轻量化共享卷积姿态检测头 LSCP,进一步减少了模型的参数量和 FLOPs。在 COCO-Pose2017 数据集和 MPII 数据集上的实验结果表明,相较于原 YOLOv11-Pose 模型,LSPM-YOLO 模型在保持轻量化特性的同时,更适用于计算能力受限的设备,并在 HPE 任务中提高了准确率,尤其是在人体遮挡等复杂环境下。未来将致力于进一步提高模型的精确度和减小模型尺寸,并在实际应用中优化该模型。

参考文献 (References)

- [1] 李卓然,李华,王桐,等. 基于融合特征状态空间模型的轻量化人体姿态估计[J]. 计算机应用, 2025, 45(10): 3179-3186.
- [2] 李佳宁,王东凯,张史梁. 基于深度学习的二维人体姿态估计:现状及展望[J]. 计算机学报, 2024, 47(1): 231-250.
- [3] 孙瑞阳,杨慧馨,赵蓝飞. 一种具有尺度不变性的人体姿态估计算法[J]. 哈尔滨理工大学学报, 2024, 29(4): 59-68.
- [4] CAO Z, SIMON T, WEI S E, et al. Realtime multi-person 2D pose estimation using part affinity fields [C]// Proceedings of the 2017 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway:

IEEE, 2017: 1302-1310.

- [5] CHENG B, XIAO B, WANG J, et al. HigherHRNet: scale-aware representation learning for bottom-up human pose estimation [C]// Proceedings of the 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2020: 5385-5394.
- [6] XIAO B, WU H, WEI Y. Simple baselines for human pose estimation and tracking [C]// Proceedings of the 2018 European Conference on Computer Vision, LNCS 11210. Cham: Springer, 2018: 472-487.
- [7] SUN K, XIAO B, LIU D, et al. Deep high-resolution representation learning for human pose estimation [C]// Proceedings of the 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2019: 5686-5696.
- [8] SHOTTON J, FITZGIBBON A, COOK M, et al. Real-time human pose recognition in parts from single depth images [C]// Proceedings of the 2011 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2011: 1297-1304.
- [9] MAJI D, NAGORI S, MATHEW M, et al. YOLO-Pose: enhancing YOLO for multi person pose estimation using object keypoint similarity loss [C]// Proceedings of the 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops. Piscataway: IEEE, 2022: 2636-2645.
- [10] ZHAO J, JIA D, WANG Q. Correction algorithm of multi-person pose estimation based on improved YOLOv5 [C]// Proceedings of the 2023 International Conference on Networking and Network Applications. Piscataway: IEEE, 2023: 631-636.
- [11] LU T, CHENG K, HUA X, et al. KSL-POSE: a real-time 2D human pose estimation method based on modified YOLOv8-Pose framework [J]. Sensors, 2024, 24(19): No. 6249.

- [12] TU H, QIU Z, YANG K, et al. HP-YOLO: a lightweight real-time human pose estimation method [J]. *Applied Sciences*, 2025, 15(6): No. 3025.
- [13] TIAN Y, YE Q, DOERMANN D. YOLOv12: attention-centric real-time object detectors [EB/OL]. [2025-04-11]. <https://arxiv.org/pdf/2502.12524>.
- [14] LEI M, LI S, WU Y, et al. YOLOv13: real-time object detection with hypergraph-enhanced adaptive visual perception [EB/OL]. [2025-04-15]. <https://arxiv.org/pdf/2506.17733>.
- [15] YANG J, LIU S, WU J, et al. Pinwheel-shaped convolution and scale-based dynamic loss for infrared small target detection [C]// *Proceedings of the 39th AAAI Conference on Artificial Intelligence*. Palo Alto: AAAI Press, 2025: 9202-9210.
- [16] GUO M H, LU C Z, LIU Z N, et al. Visual attention network [J]. *Computational Visual Media*, 2023, 9(4): 733-752.
- [17] LAU K W, PO L M, REHMAN Y A U. Large separable kernel attention: rethinking the large kernel attention design in CNN [J]. *Expert Systems with Applications*, 2024, 236: No. 121352.
- [18] CHOLLET F. Xception: deep learning with depthwise separable convolutions [C]// *Proceedings of the 2017 IEEE Conference on Computer Vision and Pattern Recognition*. Piscataway: IEEE, 2017: 1800-1807.
- [19] WANG X, YU S X. Tied block convolution: leaner and better CNNs with shared thinner filters [C]// *Proceedings of the 35th AAAI Conference on Artificial Intelligence*. Palo Alto: AAAI Press, 2021: 10227-10235.
- [20] LIN T Y, MAIRE M, BELONGIE S, et al. Microsoft COCO: common objects in context [C]// *Proceedings of the 2014 European Conference on Computer Vision*, LNCS 8693. Cham: Springer, 2014: 740-755.
- [21] ANDRILUKA M, PISHCHULIN L, GEHLER P, et al. 2D human pose estimation: new benchmark and state of the art analysis [C]// *Proceedings of the 2014 IEEE Conference on Computer Vision and Pattern Recognition*. Piscataway: IEEE, 2014: 3686-3693.
- [22] YU C, XIAO B, GAO C, et al. Lite-HRNet: a lightweight high-resolution network [C]// *Proceedings of the 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition*. Piscataway: IEEE, 2021: 10435-10445.
- [23] LI Y, YANG S, LIU P, et al. SimCC: a simple coordinate classification perspective for human pose estimation [C]// *Proceedings of the 2022 European Conference on Computer Vision*, LNCS 13666. Cham: Springer, 2022: 89-106.
- [24] JIANG T, LU P, ZHANG L, et al. RTMPose: real-time multi-person pose estimation based on MMPose [EB/OL]. [2025-04-24]. <https://arxiv.org/pdf/2303.07399>.