



计算机应用
Journal of Computer Applications
ISSN 1001-9081, CN 51-1307/TP

《计算机应用》网络首发论文

题目：基于分层动态记忆与注意力压缩的视觉目标跟踪
作者：鲍孙飞，王军
收稿日期：2026-06-03
网络首发日期：2026-08-06
引用格式：鲍孙飞，王军. 基于分层动态记忆与注意力压缩的视觉目标跟踪[J/OL]. 计算机应用. <https://link.cnki.net/urlid/51.1307.TP.20260805.1703.007>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于分层动态记忆与注意力压缩的视觉目标跟踪

鲍孙飞^{1,2}, 王军^{1,2*}

(1.江西水利电力大学 信息工程学院, 江西 南昌 330099; 2.智慧水利江西省重点实验室, 江西 南昌 330099)

(*通讯作者电子邮箱 wangjun012778@126.com)

摘要: 视觉目标跟踪的目的是结合目标初始标注对视频序列中的目标进行持续定位。尽管基于 Transformer 的跟踪方法已取得显著进展, 但现有方法大多依赖固定的初始模板, 缺乏对目标长期外观演变的有效建模机制, 在目标发生形变、遮挡或外观剧变时容易出现跟踪漂移。为此, 本文提出一种基于分层动态记忆与注意力压缩的视觉目标跟踪 (HDMTrack) 算法。该算法引入由初始模板表示、长期聚合记忆与短期动态特征构成的三级分层记忆结构, 对目标外观的长期一致性与短期动态变化进行统一建模。其次, 构建了基于注意力聚合的模板压缩模块, 将完整模板特征序列压缩为紧凑的全局表示, 在有效保留判别信息的同时降低序列冗余。同时还提出自适应三阶段记忆更新策略, 根据记忆库饱和状态在追加、衰减压缩与滑动更新三种模式间动态切换, 实现对长时序历史信息的持续积累。实验结果表明, 本文 HDMTrack 算法在 GOT-10k 上平均重叠率达到 75.2%, 在 TrackingNet 和 UAV123 上的成功率曲线下面积分别达到 83.0% 和 67.4%, 并在 LaSOT 的 9 类挑战属性中取得 8 项最优、1 项次优结果。本文方法能够有效缓解长时跟踪中的模板漂移问题, 提升了复杂场景下跟踪的准确性与鲁棒性。

关键词: 视觉目标跟踪; Transformer; 动态模板; 分层记忆; 注意力机制

中图分类号: TP391 **文献标志码:** A

Hierarchical dynamic memory with attention-based compression for visual object tracking

BAO Sunfei^{1,2}, WANG Jun^{1,2*}

(1. School of Information Engineering, Jiangxi University of Water Resources and Electric Power, Nanchang, Jiangxi 330099, China;

2. Jiangxi Province Key Laboratory of Smart Water Conservancy, Nanchang, Jiangxi 330099, China)

Abstract: Visual object tracking aims to continuously localize a target in video sequences based on its initial annotation. Although Transformer-based tracking methods have achieved remarkable progress, most existing approaches rely heavily on fixed initial templates and lack effective mechanisms for modeling long-term appearance variations in targets, making them prone to tracking drift when targets undergo deformation, occlusion, or drastic appearance changes. To address this issue, a Hierarchical Dynamic Memory with attention-based compression for visual object Tracking (HDMTrack) algorithm was proposed. In this algorithm, a three-level hierarchical memory structure composed of an initial template representation, long-term aggregated memory, and short-term dynamic features was introduced to achieve unified modeling of both long-term appearance consistency and short-term dynamic variations of the target. Then, an attention-aggregation-based template compression module was constructed to compress the full template feature sequence into a compact global representation, effectively reducing sequence redundancy while preserving discriminative information. Meanwhile, an adaptive three-stage memory update strategy was proposed. This strategy dynamically switches among appending, decay compression, and sliding update modes based on the saturation state of the memory bank, thereby enabling continuous accumulation of long-term historical information. Experimental results showed that the proposed algorithm achieved an Average Overlap of 75.2% on GOT-10k, and obtained an area under the curve score of 83.0% and 67.4% on TrackingNet and UAV123, respectively. It also achieved the best results in eight of the nine challenge attributes on LaSOT and the second-best result in the remaining attribute. The proposed method can effectively alleviate template drift in long-term tracking and improve the tracking accuracy and robustness in complex scenarios.

Keywords: visual object tracking; transformer; dynamic template; hierarchical memory; attention mechanism

0 引言

视觉目标跟踪是计算机视觉领域的重要研究方向, 其目标是在已知初始帧目标位置的条件下, 对后续视频帧中的目

收稿日期: 2026-06-03; 修回日期: 2026-07-18; 录用日期: 2026-07-20。

基金项目: 江西省自然科学基金重点项目 (20252BAC250017)。

作者简介: 鲍孙飞(2001—), 男, 安徽芜湖人, 硕士研究生, 主要研究方向: 计算机视觉、目标跟踪; 王军(1978—), 男, 江西九江人, 教授, 博士, CCF 会员, 主要研究方向: 计算机视觉、目标跟踪。

标进行持续定位与状态估计^[1]。该技术在智能监控、自动驾驶、人机交互以及无人机导航等场景中具有广泛应用价值^[2]。

复杂场景中的目标跟踪任务常伴随着目标形变、快速运动、光照变化、背景干扰以及长时间遮挡等问题，这些因素容易导致目标外观发生显著变化，从而降低跟踪器的鲁棒性与稳定性^[3]。早期基于相关滤波与孪生网络的跟踪方法虽然具有较高的运行效率，但由于特征表达能力有限，难以充分建模复杂场景中的目标变化。近年来，Transformer 结构凭借全局特征建模能力，在视觉目标跟踪领域取得了显著进展。以单流跟踪（One-Stream Tracking, OSTrack）^[4]为代表的单流 Transformer 跟踪器通过联合建模模板区域与搜索区域，实现了目标特征的深度交互，在多个公开数据集上表现出较好的跟踪性能。

现有 Transformer 跟踪方法大多依赖固定的初始模板作为目标外观参考，缺乏对目标外观动态变化的有效建模。当目标经历长时间姿态变化、尺度变化或遮挡干扰时，初始模板与当前目标之间的外观差异会逐渐增大，从而导致跟踪漂移甚至跟踪失败。部分研究尝试引入动态模板更新机制以缓解模板退化问题，但现有方法在历史信息利用、模板质量控制以及长时序建模等方面仍存在不足，难以同时兼顾目标外观的长期稳定性与短期动态变化。

针对上述问题，本文提出一种基于分层动态记忆与注意力压缩的视觉目标跟踪（Hierarchical Dynamic Memory with attention-based compression for visual object Tracking, HDMTrack）算法。在单流 Transformer 跟踪框架的基础上，引入动态模板记忆机制，通过历史外观信息的分层建模增强目标表示能力。本文主要工作包括：1）设计基于注意力聚合的模板压缩模块，对模板特征进行全局聚合，在降低序列冗余的同时保留关键判别信息；2）构建包含稳定模板、长期聚合记忆以及短期动态特征的三级分层记忆结构，实现对目标外观长期一致性与短期变化的联合建模；3）提出自适应三阶段记忆更新策略，根据记忆状态动态调整更新方式，以提升长时序场景下的记忆利用效率。在 4 个公开数据集 GOT-10k^[5]、TrackingNet^[6]、LaSOT^[7]和 UAV123^[8]上的实验结果表明，本文方法在复杂场景下具有较好的跟踪性能与鲁棒性。

1 相关工作

1.1 基于深度学习的目标跟踪方法

早期基于深度学习的目标跟踪方法主要沿两条技术路线发展：孪生匹配范式与在线更新的判别式范式。在孪生网络方向，全卷积孪生网络（Siamese Fully-Convolutional network, SiamFC）^[9]首次将孪生结构引入单目标跟踪任务，通过离线学习得到可泛化的相似度度量函数，并在模板帧与搜索区域之间执行互相关匹配，从而构建了高效的端到端跟踪框架。随后孪生区域候选网络（Siamese Region Proposal Network,

SiamRPN）^[10]将区域候选生成与边界框回归纳入统一网络，显著提升了目标定位精度；SiamRPN 的改进版本（Siamese Region Proposal Network++, SiamRPN++）^[11]进一步引入更深的骨干网络与多层特征聚合以缓解深层特征的空间信息退化问题。为简化锚框设计并增强泛化能力，孪生框自适应网络（Siamese Box Adaptive Network, SiamBAN）^[12]、孪生分类与回归网络（Siamese Classification And Regression, SiamCAR）^[13]等方法以无锚框范式重构分类与回归分支，提升了在复杂场景中的适用性。与此同时，孪生跟踪器在结构层面仍持续演进，例如非对称孪生跟踪器（Asymmetric siamese Tracker, AsymTrack）^[14]通过非对称双流结构增强模板分支与搜索分支的互补表达能力，在保持匹配框架高效性的同时改善了外观建模能力。

与离线匹配不同，基于在线更新的方法通过在跟踪过程中动态调整模型参数以适应目标外观变化。多域网络（Multi-Domain Network, MDNet）^[15]采用多域预训练结合在线微调构建判别式外观模型；重叠最大化精确跟踪（Accurate Tracking by Overlap Maximization, ATOM）^[16]通过“分类—状态估计”解耦的两阶段框架提升定位精度；判别模型预测（Discriminative Model Prediction, DiMP）^[17]则引入可微分的判别模型预测机制并借助元学习实现更高效的在线更新。这类方法在面对遮挡、背景干扰等情况下容易引入噪声导致模型漂移或退化。上述局限促使研究者进一步探索能够同时兼顾全局建模以及端到端训练的 Transformer 架构。

1.2 基于 Transformer 的目标跟踪方法

Transformer 凭借自注意力机制对长程依赖的建模能力以及交叉注意力对跨特征对齐的优势，在视觉目标跟踪中展现出良好的表示与匹配能力。Transformer 跟踪（Transformer Tracking, TransT）^[18]是较早将 Transformer 引入目标跟踪的代表性工作之一，其通过注意力特征融合模块实现模板与搜索特征的交互建模，在一定程度上替代了传统互相关操作。时空 Transformer 跟踪网络（Spatio-Temporal trAnsfoRmer network for visual tracKing, STARK）^[19]进一步将历史信息纳入建模，通过编码与解码器结构实现端到端的目标状态估计，使跟踪器在长时序场景下具有更强鲁棒性。随后，研究者围绕更简洁的统一建模框架与更高效的交互机制持续推进，例如 OSTrack^[4]采用单流联合建模策略，将模板与搜索区域的图像块共同输入视觉 Transformer 骨干，并通过候选消除等设计降低冗余计算；MixFormer^[20]通过混合注意力机制进一步增强模板—搜索联合表示能力；自回归跟踪器（AutoRegressive visual Tracking, ARTrack）^[21]将跟踪问题建模为自回归序列预测任务，通过对历史轨迹的显式建模指导当前帧定位。

在注意力机制方面，部分方法通过结构改造增强目标表征与抗干扰能力。例如 ATrans^[22]通过双注意力机制提升特征

交互效果; GdaTFT^[23]引入全局膨胀注意力与目标聚焦网络以提升复杂场景下的定位稳定性; 非对称选择性注意力Transformer (Asymmetric Selective Attention transFormer, ASAFFormer)^[24]则结合卷积视觉Transformer与非对称选择性注意力以兼顾局部细节与全局语义。与此同时, 面向实时应用与端侧部署需求, 研究者进行轻量化与高效Transformer跟踪器的设计, 如HiT^[25]探索轻量层级视觉Transformer以降低计算成本; 紧凑Transformer跟踪器 (Compact Transformer Tracker, CTTrack)^[26]通过紧凑结构与相关建模提升效率与表示能力; 动态Transformer高效跟踪框架 (Dynamic transformer framework for efficient Tracking, DyTrack)^[27]则从动态Transformer角度探索在保证精度的同时实现更高效的计算路径选择与适应性。此外, 针对视频序列固有的时序连续性, 一些方法强调跨帧信息融合与时空联合建模, 例如时空联合建模跟踪器 (Spatio-Temporal joint-modeling Tracker, STTrack)^[28]通过联合时空建模提升跨帧一致性; 连续时序信息融合跟踪器 (Continuous Temporal Information Fusion Tracker, CTIFTrack)^[29]聚焦连续时序信息融合以增强对外观变化和短时遮挡的鲁棒性。上述研究表明, Transformer架构已成为目标跟踪的重要范式, 但其在长时序外观演化建模与历史信息利用方式上仍存在进一步提升空间。

1.3 目标跟踪中的模板更新策略

尽管Transformer跟踪器能够通过注意力机制实现强特征交互与全局建模, 现有多数方法仍以初始模板为主要外观参照, 对目标外观随时间的持续演化缺乏显式建模。当目标发生形变、旋转或遭遇遮挡时, 静态模板与当前外观差异逐步累积, 易引发模板失配与跟踪漂移。为缓解该问题, 早期模板更新策略多采用线性插值等启发式方法, 以固定频率与更新系数对模板进行替换, 但在遮挡或定位偏移情况下容易将低质量样本引入模板并造成噪声累积, UpdateNet^[30]通过学习方式融合初始模板、累积模板与当前模板以估计更优的更新结果, 从而在一定程度上提高更新可靠性。另一方面, 基于记忆网络的工作通过显式读写历史外观信息提升长时序鲁棒性, 例如动态记忆网络跟踪器 (dynamic Memory

networks for Tracking, MemTrack)^[31]利用动态记忆模块以注意力机制对历史外观进行检索与更新; STMTrack^[32]进一步构建时空记忆网络并通过交叉注意力从记忆中读取与当前搜索区域最相关的历史特征。然而, 上述记忆方法均采用平坦式存储结构, 以相同粒度统一维护历史特征, 无法区分目标外观的长期稳定趋势与短期变化; 且随跟踪序列增长, 记忆库容量持续扩张, 难以在有限计算资源下支撑长时序的记忆积累。

综上, 现有模板更新与记忆方法仍存在以下不足: 1) 记忆结构单一, 无法在有限序列长度内同时兼顾短时外观细节与长时变化趋势; 2) 缺乏对记忆库容量的动态管理, 难以支撑长时序场景下的历史信息持续积累。针对上述问题, 本文提出了一种面向Transformer跟踪框架的分层动态模板记忆更新策略, 通过构建三级记忆结构与自适应更新机制, 实现对目标外观变化的高效建模与快速推理。

与上述方法相比, 本文在以下3个方面实现了显著改进: 1) 通过注意力聚合压缩模块自适应地突出目标区域的判别性贡献、抑制背景噪声, 从特征层面实现对低质量信息的隐式过滤; 2) 以分层方式存储历史信息, 初始模板、长期聚合记忆与短期动态特征分别以不同粒度建模目标外观的稳定参考、长期趋势与近期细节, 形成跨时间尺度的互补表征; 3) 通过三阶段自适应更新策略将短期动态特征渐进压缩为长期聚合记忆, 在严格控制序列长度恒定的前提下实现对长时序历史信息的持续积累。

2 基于分层动态记忆与注意力压缩的跟踪算法

2.1 整体框架

本文的基于分层动态记忆与注意力压缩的目标跟踪 (HDMTrack) 算法在Transformer跟踪框架的基础上引入动态模板记忆结构和注意力聚合的模板压缩机制, 缓解现有方法过度依赖单一初始模板、难以持续适配目标外观变化, 从而在遮挡、形变与背景干扰等场景下易发生表征失配与定位漂移的问题。HDMTrack的整体框架如图1所示。




图1 HDMTrack 的整体结构框架

Fig. 1 Overall framework of HDMTrack

给定视频序列, 以初始模板帧与当前搜索帧作为输入。对于模板帧, 首先通过图像分块与线性嵌入操作将其转化为 patch 特征序列, 再经由基于注意力聚合的模板压缩模块将完整 patch 序列压缩为紧凑的全局模板表示。在跟踪初始阶段, 记忆库由若干重复的全局模板表示构成, 为后续动态更新提供稳定的初始状态。对于搜索帧, 同样经图像分块与线性嵌入后, 将位置编码后的 patch 特征与记忆库中的模板序列拼接, 共同送入视觉 Transformer (Vision Transformer, ViT) 骨干网络进行特征提取与交互。骨干网络输出的搜索区域特征经预测头生成当前帧的目标位置与置信度估计。

在每一搜索帧完成目标预测后, 模型根据预测头输出的目标置信度对当前帧跟踪质量进行初步评估。当前帧置信度高于预设阈值时, 将对应搜索区域特征作为候选动态模板进行暂存; 为降低瞬时噪声与偶然漂移带来的干扰, 本文进一步在局部时间窗口内对候选特征进行质量筛选, 仅保留置信度较高的候选特征用于后续记忆更新。

对筛选后的候选特征进行基于注意力聚合的模板压缩, 将完整 patch 特征序列压缩为紧凑的全局模板表示, 并根据当前记忆库状态自适应执行对应的记忆更新操作。由于长期聚合记忆并非直接由单帧特征写入, 而是经过短期动态特征缓冲与注意力聚合后逐步形成, 能够在一定程度上降低遮挡帧、错误定位帧以及背景干扰帧对长期历史表征的污染风险。

2.2 基于注意力聚合的模板压缩

为了解决模板分支中特征序列冗余高且易引入噪声的问题, 提出一种基于注意力聚合的模板压缩模块。该模块通过自适应加权融合, 将完整的模板序列压缩为单一的全局紧凑表示, 显著保留与目标相关的核心判别信息, 从而为后续匹配与记忆更新提供更稳定的模板表征。

设模板图像经图像分块与线性嵌入后得到 patch 特征序列 $\mathbf{X} \in \mathbb{R}^{N \times C}$, 其中 patch 数量 N 设置为 256, 特征维度 C 设置为 768。为引入空间位置先验, 首先将二维正弦余弦位置编码 $\mathbf{P} \in \mathbb{R}^{N \times C}$ 叠加至 patch 特征, 得到位置感知特征:

$$\bar{\mathbf{X}} = \mathbf{X} + \mathbf{P} \quad (1)$$

将位置感知特征送入注意力预测网络, 为每个 patch 预测量注意力权重:

$$\mathbf{a} = \text{Softmax}\left(f_{\theta}(\bar{\mathbf{X}})\right) \quad (2)$$

其中 $f_{\theta}(\bullet)$ 表示多层感知机 (Multilayer Perceptron, MLP), Softmax 表示归一化函数, 其操作沿 patch 维度执行, 确保所有 patch 的注意力权重归一化, 且满足:

$$\sum_{i=1}^N a_i = 1 \quad (3)$$

最终, 以归一化注意力权重对原始 patch 特征进行加权求和, 得到压缩后的全局模板表示:

$$\mathbf{t} = \sum_{i=1}^N a_i \mathbf{x}_i \quad (4)$$

其中, $\mathbf{x}_i$ 为第 i 个 patch 的原始特征, a_i 为对应的归一化注意力权重。该操作将 N 个 patch 特征聚合为单一全局 token, 实现了从高维 patch 序列到紧凑全局表示的映射。相较于直接截断或平均池化等简单压缩方式, 基于注意力的加权聚合能够自适应增强判别性区域的贡献, 并在一定程度上抑制背景噪声干扰, 从而为后续记忆库构建提供更加稳定且紧凑的模板表示。本文进一步结合短期动态特征层保留完整 patch 序列, 以缓解全局压缩在小目标与复杂背景场景下可能带来的细粒度信息损失问题。

2.3 三级分层记忆结构

现有 Transformer 跟踪方法通常仅以初始帧的静态模板参与特征交互, 难以应对跟踪过程中目标外观的持续变化。为此, 本文构建一种三级分层记忆结构, 将历史信息划分为三个层级, 其结构如图 2 所示。




图2 三级分层记忆结构

Fig. 2 Structure of a three-level memory bank

初始模板表示是记忆库的第一层级, 由初始模板帧经注意力聚合压缩后的全局 token 重复若干次构成, 为跟踪器提供稳定可靠的初始外观参考。随着跟踪的持续进行, 该层级的重复数量将逐渐衰减, 为长期聚合记忆提供空间。

长期聚合记忆是记忆库的第二层级, 由历史动态特征块经注意力聚合压缩后的全局 token 序列构成, 以高度压缩的形式保存目标在较长时间跨度内的外观变化信息。

短期动态特征是记忆库的第三层级, 由最近若干帧的完整搜索区域特征块构成, 以完整 patch 序列的形式保留目标的近期细粒度外观信息。

三个层级按照上述顺序拼接后与搜索区域特征共同送入骨干网络, 在时间尺度与特征表示上形成互补, 使跟踪器能够在统一框架下同时建模目标外观的长期一致性与短期变化。

2.4 自适应三阶段记忆更新策略

在目标跟踪过程中, 记忆库需要在有限的序列长度约束下持续积累历史信息。为此, 本文提出了一种自适应三阶段记忆更新策略, 根据记忆库的饱和状态动态切换更新模式, 其记忆更新状态如图 3 所示。




图3 三阶段记忆更新状态

Fig. 3 Three-stage memory update process

第一阶段为追加阶段：跟踪初期，记忆库由大量初始模板表示与少量动态块构成。短期动态特征块数量未达上限时，将当前帧搜索区域特征块追加至记忆库末尾，记忆库序列长度随之增加。当动态特征块数量达到预设上限时，触发向第二阶段的转移。

第二阶段为衰减压缩阶段：动态块饱和后，记忆库进入衰减压缩阶段，初始模板表示逐渐减少，长期聚合记忆不断积累。具体操作为：将最旧的短期动态特征块送入注意力聚合模块，压缩为单一长期聚合记忆 token 并追加至长期聚合记忆序列；同时移除初始模板表示中最旧的 token，为新帧特征提供序列空间。经过上述操作，记忆库总序列长度保持不变。当初始模板表示衰减至预设下限且长期聚合记忆达到上限时，触发向第三阶段的转移。

第三阶段为滑动聚合更新阶段：记忆库进入全饱和状态后，采用滑动聚合更新机制，将最旧的短期动态特征块聚合为长期记忆序列并替换最旧的长期聚合记忆，同时以当前帧特征块替换最旧的短期动态特征块，记忆库序列长度严格保持不变。

2.5 损失函数

本文采用基于角点预测的边界框回归头作为预测模块。该模块以搜索区域的骨干网络输出特征图作为输入，通过两个并行的子网络分别回归目标边界框的左上角坐标 (x_1, y_1) 与右下角坐标 (x_2, y_2) ，并由独立的分类分支生成逐像素置信度得分图，以此实现目标的精确定位与可靠性评估。与传统方式相比，角点预测能够更细粒度地刻画边界变化，对目标尺度剧烈变化与长宽比显著波动的场景具有更好的适应性。

在训练目标设计方面，本文采用分类损失、交并比（Intersection over Union, IoU）回归损失与坐标回归损失三项联合优化的策略，总损失函数定义为：

$$\mathcal{L} = \lambda_{\text{cls}} \mathcal{L}_{\text{cls}} + \lambda_{\text{reg}} \mathcal{L}_{\text{reg}} + \lambda_{\text{L1}} \mathcal{L}_{\text{L1}} \quad (5)$$

其中， λ_{cls} 、 λ_{reg} 与 λ_{L1} 分别为分类损失与回归损失的平衡权重，分类损失 $\mathcal{L}_{\text{cls}}$ 采用加权焦点损失，IoU 回归损失 $\mathcal{L}_{\text{reg}}$ 采用广义 IoU 损失，坐标回归损失 $\mathcal{L}_{\text{L1}}$ 采用 L1 损失。

3 实验与结果分析

3.1 实验配置

3.1.1 数据集与评价指标

在 GOT-10k^[5]、TrackingNet^[6]、LaSOT^[7]和 UAV123^[8]4 个公开单目标跟踪数据集上进行实验验证。其中，GOT-10k 采用训练类别与测试类别严格隔离的协议，用于评估模型在未知类别上的跨类别泛化能力；TrackingNet 包含大规模真实场景视频序列，用于测试模型在复杂数据分布下的综合跟踪性能；UAV123 包含 123 个无人机视角视频序列，具有快速运动、目标尺度较小及视角变化显著等特点，用于评估模型在复杂运动和小目标场景中的适应能力；LaSOT 测试集包含 280 个长序列视频，并提供丰富的属性标注，用于分析模型在外观持续变化、遮挡累积及长时跟踪场景下的鲁棒性。

根据各数据集的官方评价协议，本文采用相应指标对跟踪性能进行评价。对于 GOT-10k，采用平均重叠率（Average Overlap, AO）以及成功率（Success Rate, SR）指标，其中 AO 表示预测框与真实框交并比在全部测试帧上的平均值，SR_{0.5} 和 SR_{0.75} 分别表示以交并比为 0.5 和 0.75 为判定阈值时的跟踪成功率，即满足相应交并比条件的帧数占全部测试帧的比例。对于 TrackingNet，采用成功率曲线下面积（Area Under the Curve, AUC）、精度（Precision, P）和归一化精度（Normalized Precision, P_{Norm}）作为评价指标，P 用于衡量预测目标中心与真实目标中心之间的位置误差，P_{Norm} 则表示对不同目标尺度下的位置误差进行归一化后所得精度曲线下面积。对于 UAV123^[8]和 LaSOT^[7]，按照一次性评估（One-Pass Evaluation, OPE）协议报告 AUC 和等指标，并结合 LaSOT^[7]的属性标注进一步分析算法在遮挡、形变、尺度变化和相似背景等困难场景下的跟踪性能。

3.1.2 实现细节

本文采用预训练的 ViT 作为骨干网络，模板分支输入分辨率设置为 256×256，搜索分支输入分辨率设置为 256×256。训练阶段采用自适应矩估计解耦权重衰减优化器，初始学习率设为 4×10^{-5} ，权重衰减设为 1×10^{-4} ，批大小设置为 8，共训练 300 个轮次。训练数据采用 GOT-10k^[5]、LaSOT^[7]和 TrackingNet^[6]的混合训练集。所有实验均在单张 NVIDIA RTX 5060 Ti 16 GB 图形处理器上完成。

记忆库相关超参数设置如下：初始模板重复次数设置为 20，短期动态特征块数量上限设置为 2 帧，长期聚合记忆数量上限设置为 5 个 token。模板压缩模块采用 4 层多层感知机，隐藏层维度与骨干网络保持一致。本文所提算法的运行速度能够达到 87 帧每秒，能够满足实时跟踪需求。

3.2 实验对比

为全面评估本文算法的性能，与近年来具有代表性的算

法,包括 CEATrack^[33]、DyTrack^[27]、ATrans^[22]、CTIFTrack^[29]、高效外观提示跟踪器 (Efficient Appearance Prompt Tracker, EAPTrack)^[34]、MCAT-swin^[35]、STTrack^[28]、ASAFormer^[24]、AsymTrack^[14]、CTTrack^[26]、GdaTFT^[23]、HiT^[25]在 GOT-10k^[5]、TrackingNet^[6]、UAV123^[8]及 LaSOT^[7]四个公开基准数据集上进行对比分析。

首先在 GOT-10k^[5]与 TrackingNet^[6]上检验跨类别泛化与大规模真实场景下的整体鲁棒性,其次在 UAV123^[8]上评估面向无人机视角的复杂运动与小目标场景适配能力。在 LaSOT^[7]上进一步讨论长序列条件下外观演变与模板漂移问

题,以突出分层动态记忆结构在长期稳定跟踪中的作用机制。

在 GOT-10k^[5]上,由于测试类别与训练类别完全隔离,算法性能在很大程度上取决于是否能够摆脱类别先验并形成具有普适性的目标表征。如表 1 所示,本文算法在 AO 上达到 75.2%, SR_{0.5} 和 SR_{0.75} 分别达到 85.1%和 72.2%。相较于 CTTrack^[26]在 AO 上提升了 1.7 个百分点,优于 DyTrack^[27]达到的 72.4%,说明在未知类别目标上依然能够维持稳定的定位精度。模型能够在外观变化发生时保留判别性强且稳定的历史表征,从而减少由噪声更新引起的漂移风险,最终体现为更强的跨类别泛化性能。

表1 在 GOT-10k 和 TrackingNet 数据集上与主流跟踪器的性能比较

Tab. 1 Performance comparison with mainstream trackers on the GOT-10k and TrackingNet datasets

算法	GOT-10k			TrackingNet		
	AO/%	SR _{0.5} /%	SR _{0.75} /%	AUC/%	P _{Norm} /%	P/%
本文算法	75.2	85.1	72.2	83.0	87.4	81.3
CEATrack ^[33]	72.1	82.0	67.6	81.8	86.8	79.7
DyTrack ^[27]	72.4	80.2	68.5	<u>82.9</u>	<u>87.3</u>	81.2
ATrans ^[22]	71.2	72.3	68.6	82.7	86.8	81.4
CTIFTrack ^[29]	71.3	81.5	66.7	82.3	87.2	80.4
EAPTrack ^[34]	71.0	80.9	65.6	81.5	86.5	79.5
MCAT-swin ^[35]	70.0	80.0	63.4	81.2	85.6	79.1
STTrack ^[28]	70.8	80.6	66.8	82.3	86.8	80.1
ASAFormer ^[24]	71.3	80.0	67.6	82.2	<u>87.3</u>	80.6
AsymTrack ^[14]	67.7	76.6	61.4	80.0	84.5	77.4
CTTrack ^[26]	<u>73.5</u>	<u>83.5</u>	<u>70.6</u>	82.5	87.1	80.3
GdaTFT ^[23]	65.0	77.8	53.7	77.8	83.5	75.4
HiT ^[25]	64.0	72.1	58.1	80.0	84.4	77.3

如表 1 所示,在 TrackingNet^[6]上,同样表现出较高的整体稳定性,AUC 与 P 分别取得 83.0%和 81.3%的效果。由于 TrackingNet^[6]涵盖了大量不同类型的野外视频序列,场景变化与干扰因素更加多样,这一结果表明本文算法的特征表达与记忆维护策略具有良好的可迁移性,能够在复杂数据分布下保持一致的跟踪质量。

为验证本文算法在小目标场景下的跟踪能力,在 UAV123^[8]数据集上进行对比评估。该数据集由无人机视角采集,通常伴随平台运动引起的剧烈视角变化与频繁快速运动,同时目标尺度较小、观测不确定性更强。在此类场景中,单点指标难以完整反映不同方法在不同阈值区间内的性能差异。图 4 展示了本文算法与目标感知无锚点跟踪 (Object-aware anchor-free network, Ocean)^[36]、Transformer 辅助判别模型预测跟踪器 (Transformer-assisted Discriminative Model Prediction tracker, TrDiMP)^[37]、AutoMatch^[38]、TCTrack^[39]、孪生图注意力跟踪 (Siamese Graph Attention Tracking, SiamGAT)^[40]、STMTrack^[32]、TransT^[18]、SiamCAR^[13]、孪生 Transformer 金字塔网络 (Siamese Transformer Pyramid

Network, SiamTPN)^[41]以及 SiamBAN^[12]10 种优秀算法在不同重叠率阈值和位置偏差阈值下对目标进行跟踪的成功率曲线下面积与精度比较结果。

如图 4 所示,本文算法与其他代表性算法在 UAV123 数据集^[8]上的成功率曲线和精度曲线。其中,图 4(a)图例中方括号内的数值表示成功率曲线下面积,图 4(b)图例中方括号内的数值表示中心位置偏差阈值为 20 像素时的精确率。从图 4 可以看出,本文算法的成功率曲线下面积和精度分别取得 67.4%和 87.6%的效果,表明其整体性能优于对比方法。这说明本文算法在快速运动与小目标场景中不仅能够提升目标的定位精度,更能在阈值变化时保持良好的区间连续性与一致性,体现出更强的鲁棒性。

为进一步验证该算法的长时跟踪能力,本文在 LaSOT^[7]上从属性维度展开分析。与短序列基准不同,LaSOT^[7]的长序列会显著放大误差累积效应,遮挡以及目标尺度变化等容易引发模板漂移并导致后续持续失配。为更细致地对比本文算法在不同挑战属性下的性能差异,将本文算法与现有具有代表性的跟踪器不同挑战属性下的进行性能对比,包括

STMTrack^[32]、TransT^[18]、AsymTrack^[14]、SiamTPN^[41]、SiamBAN^[12]、SiamCAR^[13]、SiamFC^[9]、SiamRPN++^[11]、稀疏Transformer跟踪器 (Sparse Transformer Tracker, SparseTT)^[42]、TrDiMP^[37]以及 ATOM^[16]。

如表 2 所示, 本文算法在九类典型困难属性下均取得最优或次优结果, 其中在尺度变化、低分辨率、光照变化、相机运动、部分遮挡、完全遮挡、视角变化和目標形变八类属性下取得最优结果, 在相似背景属性下取得次优结果。




图4 UAV123 数据集上的成功率曲线与精度曲线

Fig. 4 Success rate curves and precision plots on the UAV123 dataset

表2 LaSOT 数据集不同挑战属性下的 AUC 对比

Tab. 2 Comparison of success rate AUC under different challenge attributes on the LaSOT dataset

算法	AUC/%								
	尺度变化	低分辨率	光照变化	相机运动	部分遮挡	完全遮挡	视角变化	目标形变	相似背景
本文算法	67.8	60.9	68.7	69.6	65.8	58.3	68.2	69.5	<u>59.3</u>
TrDiMP ^[37]	63.6	<u>58.8</u>	<u>67.5</u>	<u>68.5</u>	61.5	<u>56.7</u>	62.6	64.7	59.9
SparseTT ^[42]	<u>66.0</u>	56.5	67.4	67.8	<u>63.4</u>	56.0	<u>67.3</u>	<u>68.5</u>	56.4
AsymTrack ^[14]	64.4	57.6	65.7	68.2	62.0	56.4	65.8	65.8	56.8
TransT ^[18]	64.0	56.2	64.9	66.5	61.0	54.6	62.6	66.3	57.0
STMTrack ^[32]	60.6	50.3	65.2	63.3	57.1	47.8	58.2	64.0	54.1
SiamTPN ^[41]	57.7	50.2	59.5	61.4	55.3	49.2	57.7	59.1	52.2
ATOM ^[16]	51.5	44.7	56.1	56.4	48.3	42.8	47.4	51.4	45.1
SiamCAR ^[13]	51.7	43.9	56.4	52.7	48.0	41.0	49.6	53.4	43.0
SiamBAN ^[12]	51.2	41.1	53.8	54.0	48.4	42.1	45.7	52.4	47.4
SiamRPN++ ^[11]	49.4	38.7	52.8	52.1	46.5	37.4	45.4	52.9	44.9
SiamFC ^[9]	33.2	25.2	34.6	33.3	30.6	24.5	28.6	35.1	30.8

在尺度变化和视角变化属性下, 本文算法的 AUC 分别达到 67.8%和 68.2%, 说明短期动态特征能够及时表征近期外观变化, 长期聚合记忆则保留跨时段的稳定外观线索, 二者协同提升了跟踪器对尺度和视角变化的适应能力。在光照变化和相机运动属性下, AUC 分别达到 68.7%和 69.6%, 表明动态更新机制能够持续补充近期目标信息, 而初始模板可提供相对稳定的外观参考, 从而减轻亮度波动、背景快速变化及运动干扰对目标表征的影响。在部分遮挡和完全遮挡属性下, AUC 分别达到 65.8%和 58.3%, 说明分层记忆能够保留遮挡前的历史外观信息, 有助于降低遮挡造成的模板退化; 其中, 完全遮挡下的性能相对较低, 表明模型对长时间严重遮挡以及遮挡后目标恢复的适应能力仍有提升空间。在目标形变属性下, 本文算法取得 69.5%的 AUC, 说明三级记忆结构通过联合建模不同时间尺度的外观信息, 能够缓解持续形

变造成的模板失配。在低分辨率属性下, 本文算法以 60.9%的 AUC 取得最优结果, 表明注意力聚合压缩能够在目标信息有限时保留较具判别性的特征; 在相似背景属性下, 本文算法取得 59.3%的 AUC, 略低于 TrDiMP^[37]的 59.9%, 说明强背景干扰仍可能影响动态特征筛选与记忆更新的可靠性。总体而言, 分层动态记忆结构在多类长时困难场景下表现出较好的适应能力, 但在相似背景和长时间完全遮挡等场景中仍存在改进空间。

3.3 消融实验

为验证本文提出的三级分层记忆结构对长时跟踪性能的贡献, 在 LaSOT^[7]数据集上设置了 4 组对比实验。实验通过控制变量法, 逐层引入记忆分支, 定量分析各层级特征对最终精度的影响。实验结果如表 3 所示。从表 3 可以看出, 当

仅使用初始聚合模板时, AUC 为 66.3%。随着序列推进, 目标外观会经历持续变化并叠加复杂干扰, 静态模板难以覆盖后续分布, 容易出现跟踪漂移, 从而限制长时跟踪性能。

在此基础上引入长期聚合记忆后, AUC 提升至 66.7%, 较基准提高 0.4 个百分点。该结果表明, 长期聚合记忆能够从历史高质量帧中压缩更稳定的全局外观信息, 在外观发生阶段性变化或出现间歇性失配时提供更可靠的参考, 从而提升长时跟踪的稳定性。

表3 三层分层记忆结构消融实验的 AUC 结果

Tab. 3 AUC of ablation experiment on three-layered memory structure

编号	初始聚合模板	长期聚合记忆	短期动态特征	AUC/%
1	√			66.3
2	√	√		66.7
3	√		√	67.2
4	√	√	√	67.6

相较于长期聚合记忆, 引入短期动态特征带来的性能提升更为明显, AUC 达到 67.2%, 较基准提高 0.9 个百分点。这表明短期动态特征有助于捕捉邻近帧中的快速外观变化, 从而提高跟踪器对瞬时姿态变化和局部形变的适应能力, 减少定位抖动。

当同时启用初始聚合模板、长期聚合记忆和短期动态特征时, AUC 达到 67.6%, 较基准提高 1.3 个百分点, 取得最优结果。不同层级的记忆信息具有互补作用: 初始聚合模板

提供稳定的外观参考, 长期聚合记忆保留目标的长期变化信息, 短期动态特征补充近期外观细节, 三者共同提高了复杂场景下的整体跟踪性能。

为验证注意力压缩模块与三阶段更新策略的独立贡献, 在 GOT-10k 上设置了 3 组消融实验, 结果如表 4 所示。


表4 各模块的消融实验的 AO 结果

Tab. 4 Ablation results for different modules


编号	模板表示	更新方式	AO/%
1	完整模板特征	无更新	71.5
2	压缩模板	无更新	73.0
3	压缩模板	三阶段更新	75.2

以完整模板特征配合无更新策略为基线, AO 为 71.5%。引入注意力聚合压缩模块后, AO 提升至 73.0%, 表明将冗余 patch 序列压缩为紧凑全局表示能够有效提升模板的判别质量。在此基础上进一步引入三阶段自适应更新策略后, AO 提升至 75.2%, 说明持续引入历史外观信息并对记忆库进行动态管理能够显著增强跟踪器对目标外观演变的适应能力。上述结果表明, 注意力聚合压缩模块能够提升模板表示质量, 三阶段自适应更新策略则在此基础上进一步增强模型对目标外观变化的适应能力。两者结合后取得最佳性能, 验证了整体设计的有效性。

为确定记忆库关键超参数的最优配置, 在 GOT-10k 上分别对初始模板重复数量与长期聚合记忆数量进行敏感性分析, 结果如图 5 所示。



(a) 初始模板重复数量的消融



(b) 长期聚合记忆数量的消融

图5 记忆库关键超参数消融分析

Fig. 5 Ablation study of key hyperparameters in the memory bank

对于初始模板重复数量, 当取值从 5 增大至 20 时, AO 由 74.0%持续提升至 75.2%; 继续增大至 30 和 40 时, 性能趋于平稳, 维持在 75.1%至 75.2%之间。这表明适量的初始模板重复能够为跟踪器提供稳定的外观锚点, 但过多重复并不带来额外收益, 综合性能与序列长度的平衡, 本文选取 20 作为最优配置。

对于长期聚合记忆数量, 当取值为 5 时 AO 达到最高的 75.2%, 取值过小时长期记忆容量不足以覆盖充分的历史外观变化, 取值过大时性能出现小幅下滑, 可能与训练时采用

的长期聚合记忆数量较小有关, 因此本文选取 5 作为最优配置。

3.4 可视化分析

选取 LaSOT^[7]测试集中的 goldfish-7 视频序列进行可视化分析。如图 6 所示, 该序列背景纹理复杂、目标尺度较小且存在光线变化等干扰, 易导致响应分散与定位漂移。图 6 中(a)、(b)、(c)、(d)分别展示了在 goldfish-7 视频序列上的第 #174、#643、#964、#1418 帧上的可视化结果, 该结果包括预测框、热力图以及响应得分图。每组结果从左至右依次为目

标预测结果、响应热力图叠加结果和响应得分图。响应得分图右侧的颜色标尺表示搜索区域各空间位置的响应得分，颜

色由冷色向暖色变化表示响应值逐渐增大，响应值越大说明该位置与目标中心的匹配程度越高。




图6 LaSOT 数据集中 goldfish-7 视频序列的可视化结果

Fig. 6 Visualization results of goldfish-7 video sequence in the LaSOT dataset

由图 6 可见，在复杂长时序上，本文算法仍能给出准确的目标定位框，同时响应热力图的高激活区域主要集中在目标本体附近，而非背景干扰区域。这说明本文算法能够在长时跟踪过程中持续感知目标外观变化，并通过分层记忆机制有效筛选高质量历史帧，抑制噪声模板的干扰。上述现象表明，分层动态记忆能够在外观退化时提供更稳定的判别线索，使模型在复杂背景下保持集中响应与可靠定位，从而降低漂移风险。

4 结语

本文针对 Transformer 目标跟踪方法在复杂场景下易受目标外观变化与干扰因素影响的问题，提出了一种基于分层动态记忆与注意力压缩的视觉目标跟踪方法 HDMTrack。该方法通过注意力模板压缩模块对模板特征进行全局聚合，在降低特征冗余的同时提升模板判别质量；构建由初始稳定模板、长期聚合记忆与短期动态特征组成的三级分层记忆结构，实现对目标外观长期稳定性与短期动态变化的联合建模；设计自适应三阶段记忆更新策略，根据记忆库饱和状态动态调整更新方式，在严格控制序列长度的前提下实现对长时序历史信息的持续积累。

在 GOT-10k、TrackingNet、UAV123 和 LaSOT 四个公开基准数据集上的实验结果表明，所提方法具有较好的跟踪性能与泛化能力，在 GOT-10k 上 AO 达到 75.2%，优于现有代表性方法。消融实验进一步验证了各模块的独立贡献与协同效应，证明了分层记忆结构设计的合理性。

本文方法也存在一定局限：当目标长时间被严重遮挡时，置信度门控机制可能导致记忆库更新停滞，影响遮挡后的重定位能力；当前方法以 ViT-Base 为骨干，在资源受限的边缘设备上存在一定的部署压力。未来研究将进一步探索更轻量化的记忆管理策略，以降低存储与计算开销，并尝试将该分

层动态记忆机制扩展至多目标跟踪、视频分割等相关时序视觉任务中，以验证其在更广泛场景中的应用潜力。

参考文献

- [1] 李玺,查宇飞,张天柱,等.深度学习的目标跟踪算法综述[J].中国图象图形学报,2019,24(12):2057-2080. (Li Xi, Zha Yufei, Zhang Tianzhu, et al. Survey of visual object tracking algorithms based on deep learning[J]. Journal of Image and Graphics, 2019, 24(12): 2057-2080.)
- [2] 柳培忠,汪鸿翔,骆炎民,等.一种结合时空上下文的在线卷积网络跟踪算法[J].计算机研究与发展,2018,55(12):2785-2793. (Liu Peizhong, Wang Hongxiang, Luo Yanmin, et al. Online convolutional network tracking via spatio-temporal context[J]. Journal of Computer Research and Development, 2018, 55(12): 2785-2793.)
- [3] Chen Zeshi, Peng Caiping, Liu Shuai, et al. Visual object tracking: review and challenges[J]. Applied Soft Computing, 2025, 177: 113140.
- [4] Ye Botao, Chang Hong, Ma Bingpeng, et al. Joint feature learning and relation modeling for tracking: a one-stream framework[C]// ECCV 2022. Cham: Springer, 2022: 341-357.
- [5] Huang Lianghua, Zhao Xin, Huang Kaiqi. GOT-10k: a large high-diversity benchmark for generic object tracking in the wild[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2021, 43(5): 1562-1577.
- [6] Müller M, Bibi A, Giancola S, et al. TrackingNet: a large-scale dataset and benchmark for object tracking in the wild[C]// ECCV 2018. Cham: Springer, 2018: 300-327.
- [7] Fan Heng, Lin Liting, Yang Fan, et al. LaSOT: a high-quality benchmark for large-scale single object tracking[C]// CVPR 2019. Piscataway: IEEE, 2019: 5374-5383.
- [8] Mueller M, Smith N, Ghanem B. A benchmark and simulator for UAV tracking[C]// ECCV 2016. Cham: Springer, 2016: 445-461.
- [9] Bertinetto L, Valmadre J, Henriques J F, et al. Fully-convolutional Siamese networks for object tracking[C]// ECCV 2016 Workshops. Cham: Springer, 2016: 850-865.
- [10] Li Bo, Yan Junjie, Wu Wei, et al. High performance visual tracking with Siamese region proposal network[C]// CVPR 2018. Piscataway: IEEE, 2018: 8971-8980.
- [11] Li Bo, Wu Wei, Wang Qiang, et al. SiamRPN++: evolution of Siamese visual tracking with very deep networks[C]// CVPR 2019. Piscataway: IEEE, 2019: 4282-4291.

- [12] Chen Zedu, Zhong Bineng, Li Guorong, et al. Siamese box adaptive network for visual tracking[C]// CVPR 2020. Piscataway: IEEE, 2020: 6668-6677.
- [13] Guo Dongyan, Wang Jun, Cui Ying, et al. SiamCAR: Siamese fully convolutional classification and regression for visual tracking[C]// CVPR 2020. Piscataway: IEEE, 2020: 6269-6277.
- [14] Zhu Jiawen, Tang Huayi, Chen Xin, et al. Two-stream beats one-stream: asymmetric Siamese network for efficient visual tracking[C]// AAAI 2025. Palo Alto, CA: AAAI Press, 2025: 10959-10967.
- [15] Nam H, Han B. Learning multi-domain convolutional neural networks for visual tracking[C]// CVPR 2016. Piscataway: IEEE, 2016: 4293-4302.
- [16] Danelljan M, Bhat G, Khan F S, et al. ATOM: accurate tracking by overlap maximization[C]// CVPR 2019. Piscataway: IEEE, 2019: 4660-4669.
- [17] Bhat G, Danelljan M, Van Gool L, et al. Learning discriminative model prediction for tracking[C]// ICCV 2019. Piscataway: IEEE, 2019: 6182-6191.
- [18] Chen Xin, Yan Bin, Zhu Jiawen, et al. Transformer tracking[C]// CVPR 2021. Piscataway: IEEE, 2021: 8126-8135.
- [19] Yan Bin, Peng Houwen, Fu Jianlong, et al. Learning spatio-temporal transformer for visual tracking[C]// ICCV 2021. Piscataway: IEEE, 2021: 10448-10457.
- [20] Cui Yutao, Jiang Cheng, Wang Limin, et al. MixFormer: end-to-end tracking with iterative mixed attention[C]// CVPR 2022. Piscataway: IEEE, 2022: 13608-13618.
- [21] Wei Xing, Bai Yifan, Zheng Yongchao, et al. Autoregressive visual tracking[C]// CVPR 2023. Piscataway: IEEE, 2023: 9697-9706.
- [22] Liu Haichao, Qin Jiangwei, Liang Haoyu, et al. ATrans: improving single object tracking based on dual attention[J]. Journal of Visual Communication and Image Representation, 2025, 111: 104553.
- [23] Liang Yun, Li Qiaoqiao, Long Fumian. Global dilated attention and target focusing network for robust tracking[C]// AAAI 2023. Palo Alto, CA: AAAI Press, 2023: 1549-1557.
- [24] Gong Xiaomei, Zhang Yi, Hu Shu. ASAFFormer: visual tracking with convolutional vision transformer and asymmetric selective attention[J]. Knowledge-Based Systems, 2024, 291: 111562.
- [25] Kang Ben, Chen Xin, Wang Dong, et al. Exploring lightweight hierarchical vision transformers for efficient visual tracking[C]// ICCV 2023. Piscataway: IEEE, 2023: 9612-9621.
- [26] Song Zikai, Luo Run, Yu Junqing, et al. Compact transformer tracker with correlative masked modeling[C]// AAAI 2023. Palo Alto, CA: AAAI Press, 2023: 2321-2329.
- [27] Zhu Jiawen, Chen Xin, Diao Haiwen, et al. Exploring dynamic transformer for efficient object tracking[J]. IEEE Transactions on Neural Networks and Learning Systems, 2025, 36(8): 15502-15514.
- [28] Sun Yumei, Tang Chuanming, Luo Hui, et al. Joint spatio-temporal modeling for visual tracking[J]. Knowledge-Based Systems, 2024, 283: 111206.
- [29] Zhang Zhiguo, Guo Zhiqing, Wang Liejun, et al. CTIFTrack: continuous temporal information fusion for object track[J]. Expert Systems with Applications, 2025, 262: 125654.
- [30] Zhang Lichao, Gonzalez-Garcia A, Van de Weijer J, et al. Learning the model update for Siamese trackers[C]// ICCV 2019. Piscataway: IEEE, 2019: 4010-4019.
- [31] Yang Tianyu, Chan A B. Learning dynamic memory networks for object tracking[C]// ECCV 2018. Cham: Springer, 2018: 153-169.
- [32] Fu Zhihong, Liu Qingjie, Fu Zehua, et al. STMTrack: template-free visual tracking with space-time memory networks[C]// CVPR 2021. Piscataway: IEEE, 2021: 13774-13783.
- [33] Wang Yuanyun, Gu Geng, Tang Chao, et al. Compact axial attention with detail enhancement for visual object tracking[J]. Engineering Applications of Artificial Intelligence, 2026, 169: 114121.
- [34] Wu Jinhui, Zhang Wenkang, Yang Wankou. Exploring efficient appearance prompts for light-weight object tracking[J]. Journal of Visual Communication and Image Representation, 2025, 113: 104608.
- [35] Wang Qinghui, Yang Peng, Dou Lei. Enhancing visual tracking with multi-scale cross-correlation and progressive attention[J]. Neurocomputing, 2025, 623: 129417.
- [36] Zhang Zhipeng, Peng Houwen, Fu Jianlong, et al. Ocean: object-aware anchor-free tracking[C]// ECCV 2020. Cham: Springer, 2020: 771-787.
- [37] Wang Ning, Zhou Wengang, Wang Jie, et al. Transformer meets tracker: exploiting temporal context for robust visual tracking[C]// CVPR 2021. Piscataway: IEEE, 2021: 1571-1580.
- [38] Zhang Zhipeng, Liu Yihao, Wang Xiao, et al. Learn to match: automatic matching network design for visual tracking[C]// ICCV 2021. Piscataway: IEEE, 2021: 13339-13348.
- [39] Cao Ziang, Huang Ziyuan, Pan Liang, et al. TCTrack: temporal contexts for aerial tracking[C]// CVPR 2022. Piscataway: IEEE, 2022: 14798-14808.
- [40] Guo Dongyan, Shao Yanyan, Cui Ying, et al. Graph attention tracking[C]// CVPR 2021. Piscataway: IEEE, 2021: 9543-9552.
- [41] Xing Daitao, Evangeliou N, Tsoukalas A, et al. Siamese transformer pyramid networks for real-time UAV tracking[C]// WACV 2022. Piscataway: IEEE, 2022: 2139-2148.
- [42] Fu Zhihong, Fu Zehua, Liu Qingjie, et al. SparseTT: visual tracking with sparse transformers[C]// IJCAI 2022. California: IJCAI, 2022: 905-912.

This work is partially supported by the Key Project of Jiangxi Provincial Natural Science Foundation (20252BAC250017).

BAO Sunfei, born in 2001, M. S. candidate. His research interests include computer vision and visual object tracking.

WANG Jun, born in 1978, Ph. D., professor. His research interests include computer vision and visual object tracking.