

基于多尺度知识蒸馏的工业异常分割方法

马东东^{1,2}, 何莲^{1,2,3*}, 成苗^{1,2,3}, 张绍兵^{1,2,3}, 郑志浩^{1,2}, 胡益龙^{1,2}

(1. 中国科学院成都计算机应用研究所, 成都 610213; 2. 中国科学院大学 计算机科学与技术学院, 北京 100049;

3. 深圳市中钞科信金融科技有限公司, 广东 深圳 518206)

(* 通信作者电子邮箱 helian@cbpm-kexin.com)

摘要:在工业异常检测中,一些异常分割方法通过结合记忆库作为辅助信息以提升异常分割的性能,然而这些方法采用近似查找的方式提升记忆库中目标特征块的检索速度,满足了实时性,却损失了一定的精度,从而达到了性能的瓶颈;此外,记忆库一旦过大,会导致计算成本的增加。为解决上述问题,提出一种基于多尺度知识蒸馏的工业异常分割方法 MKD-AD。在蒸馏网络训练阶段,通过正常样本训练知识蒸馏网络而不是构建记忆库;在分割网络训练阶段,将分割网络结合蒸馏网络的多尺度差值特征以更好地定位异常。实验结果表明,该方法在具有竞争力的 MVTEC AD 数据集上的图像级和像素级接受者操作特征曲线下面积(AUROC)分别达到了 99.5% 和 98.2%,优于大多数对比方法,验证了 MKD-AD 的有效性。

关键词:计算机视觉;机器视觉;工业异常检测;知识蒸馏;缺陷定位

中图分类号:TP391.4 **文献标志码:**A

Industrial anomaly segmentation method based on multi-scale knowledge distillation

MA Dongdong^{1,2}, HE Lian^{1,2,3*}, CHENG Miao^{1,2,3}, ZHANG Shaobing^{1,2,3}, ZHENG Zhihao^{1,2}, HU Yilong^{1,2}

(1. Chengdu Institute of Computer Application, Chinese Academy of Sciences, Chengdu Sichuan 610213, China;

2. School of Computer Science and Technology, University of Chinese Academy of Sciences, Beijing 100049, China;

3. Shenzhen CBPM-KEXIN Banking Technology Company Limited, Shenzhen Guangdong 518206, China)

Abstract: In industrial anomaly detection, some anomaly segmentation methods enhance the performance of anomaly segmentation by combining a memory bank as auxiliary information. However, these methods use an approximate search to improve the retrieval speed of target feature blocks in the memory bank, which meets real-time requirements but sacrifices certain accuracy, thus reaching a performance bottleneck. Additionally, if the memory bank becomes too large, the computational costs will increase. To address the aforementioned issues, an industrial anomaly segmentation method based on multi-scale knowledge distillation — MKD-AD was proposed. During the distillation network training phase, the knowledge distillation network was trained using normal samples instead of building a memory bank. During the segmentation network training phase, the segmentation network was combined with the multi-scale difference features of the distillation network to locate anomalies better. Experimental results show that this method achieves image-level and pixel-level AUROC (Area Under the Receiver Operating Characteristic curve) of 99.5% and 98.2%, respectively, on the competitive MVTEC AD dataset, outperforming most comparison methods, thereby confirming the effectiveness of MKD-AD.

Key words: computer vision; machine vision; industrial anomaly detection; knowledge distillation; defect location

0 引言

在现代工业生产中,产品质量的稳定性和可靠性是企业竞争力的关键因素。随着自动化和智能化技术的发展,工业生产线的自动化程度不断提高,对生产过程的监控和质量控制提出了更高的要求。异常检测作为质量控制的重要组成部分,旨在生产过程中及时发现和识别出不符合质量标准的异常产品,以减轻缺陷产品流入市场的风险,提高生产效率和产品质量。

传统的异常检测方法通常依赖人工检查或者基于规则的系统,这不仅效率低,而且容易受到人为因素的干扰,如疲劳、注意力不集中等,这些都可能导致检测结果的不准确。此外,人工检测通常耗时较长,尤其是在大批量生产时,检测速度通常成为生产流程的瓶颈。随着劳动力成本的不断上升,企业也在寻找更经济、高效的检测方法降低成本。随着机器学习技术的快速发展,基于数据驱动的异常检测方法逐渐成为研究的热点。

大多数现有的方法通过分析正常生产数据,再建立模型以识别和预测异常情况,处于分布内的视为正常样本,分布外的则视为异常样本。例如基于自编码器(AutoEncoder, AE)^[1-2]和生成对抗网络(Generative Adversarial Network, GAN)^[3-4]的方法,这些方法通过正确重建输入图像,在训练时不断缩小重建误差,在推

断时,在输入正常图像后,模型重建后的图像和输入图像误差较小,输入异常图像后,重建后的图像和原图像误差较大,误差的大小可以作为衡量正负样本的一个标准。然而,这一假设并非总是成立。重建网络同样能复原部分异常区域,致使这些负样本的重建误差较小,因而被误判为正样本。基于特征嵌入的方法通过计算待测样本中的局部特征与正常样本中相应的特征的距离或者相似度作为异常分数,但是这种方法大多数停留在 Patch 层面,对于像素级的异常定位存在不足。虽然也有结合上述两种方法的,例如 MemAE(Memory-augmented AutoEncoder)^[5],为了抑制异常区域的重建,引入记忆库(Memory Bank)约束自编码器的泛化能力。然而,该方法存在以下几方面局限:首先,记忆库需占用额外的存储资源,当正常样本数较大时,对计算和存储资源的需求显著增加,提高了硬件门槛;其次,在大规模记忆库中检索最近邻图像块(Patch)耗时较长,难以满足高实时性工业异常检测场景的要求;最后,在特征替换过程中,部分本无须替换的正常 Patch 特征可能被记忆库中的特征或加权特征所替代,这种过度替换易破坏原有正常特征的表征,反而导致异常定位性能下降。基于 U-Net^[6]架构的方法,如 MemAD^[7]在 U-Net^[6]的基础上加入了多尺度的 Memory Bank 为分割网络提供更多的异常定位信息;然而该方法涉及近似最近邻查找,虽然可以提升速度,但会损失

收稿日期:2024-09-27;修回日期:2024-11-21;录用日期:2024-12-02。

作者简介:马东东(1999—),男,山西长治人,硕士研究生,主要研究方向:人工智能、机器视觉;何莲(1983—),女,四川西充人,高级工程师,博士,主要研究方向:人工智能、机器视觉;成苗(1983—),男,四川成都人,高级工程师,硕士,主要研究方向:人工智能、机器视觉;张绍兵(1979—),男,四川成都人,研究员级高级工程师,硕士,主要研究方向:高速图像处理、缺陷检测、深度学习;郑志浩(1999—),男,河南周口人,硕士研究生,主要研究方向:人工智能、机器视觉;胡益龙(1995—),男,山西忻州人,硕士研究生,主要研究方向:因果推断、异常检测。

精度。

为了解决以上问题,本文提出一种基于多尺度知识蒸馏的工业异常分割方法 MKD-AD。首先,在类似 U-Net^[6] 的网络基础上,引入一个可学习的学生网络以学习编码器提取的正样本特征,该网络的编码器采用了 ResNet18^[8] 预训练模型作为教师模型,在训练阶段引入异常模拟策略进行自监督训练分割网络,仅使用正样本训练学生网络,教师网络和学生网络产生的多尺度特征图的差值特征可以为网络直接提供有效的异常定位信息,无须提前存储额外的特征记忆库和烦琐的检索过程,更有助于提升模型的检测性能。

1 相关工作

1.1 基于重建的方法

基于重建的方法通常采用 AE^[1-2] 网络,它的网络架构由编码器和解码器组成。编码器将输入的正常图像经过一系列卷积池化操作压缩至低维空间,以减少高维空间冗余的特征信息,而解码器则将低维特征进行上采样,从而还原为原输入图像的大小,通过比较重建前后输入和输出图像的像素级误差可以定位图像区域中的异常区域。例如 SMAI (Superpixel Masking And Inpainting)^[9] 采用图像修复网络,对输入的正常图像区域进行随机掩码(mask)操作,修复网络将随机掩码后的图像还原为原来的正常图像,通过比较还原后的图像与输入图像的异常分数图从而定位缺陷。InTra (Inpainting Transformer)^[10] 则采用 Transformer^[11] 架构作为编码器,以局部图像窗口为处理单元,对中心区域进行掩码操作,并通过重建该掩码区域还原图像内容;最后通过比较原始图像与重建结果的差异实现异常定位。然而,Transformer 模型通常参数数量较大,推理速度较低,难以用于实时性要求较高的工业场景。上述方法都有共同的缺点,即重构网络有时也能很好地恢复异常区域,这导致一些异常样本未能被检出。在 AE 的基础上引入 Memory Bank 的方法可以有效抑制 AE 在负样本数据上的强泛化性,如 MemAE (Memory-augmented AE)^[5]、TrustMAE (Trust Memory AE)^[12]、记忆去噪自编码器 (Memory Denoising Convolutional AE, MemDCAE)^[13] 等方法,这类方法虽然取得了一定的效果,但是需要额外的存储空间存

储正常样本的特征块,可能还涉及排序检索操作。若 Memory Bank 过大,检索延时也会提升,一些正常且无须替换的 Patch 特征可能也会因为被 Memory Bank 中的 Patch 块所替换,从而损坏原本的特征,最终导致性能达到瓶颈。

1.2 基于特征嵌入的方法

基于特征嵌入的方法的基本原理是直接利用在 ImageNet^[14] 数据集上的预训练模型提取正常样本的特征,通过对比待测样本的特征与预先提取完成的正样本的特征得到异常分数,从而定位异常。例如 SPADE (Semantic Pyramid Anomaly DEtection)^[15] 方法使用预训练过的特征提取器提取测试图像的特征向量,在训练集中找到与测试图像特征向量最近的 K 个正常图像,计算测试图像与这 K 个最近邻正常图像之间的平均距离;如果平均距离大于预设阈值,则判定该测试图像为异常。然而 SPADE 在进行像素级异常检测时,需要对每个像素进行最近邻搜索,这可能导致较高的计算成本和推理延迟。而 PatchCore^[16] 通过对 Memory Bank 先进行下采样,选择最具代表性的核心特征子集,极大地减小了存储空间,保留了原始记忆库的覆盖范围,然后利用近似最近邻方法检索最相关的样本,缩短了推理时间。但上述方法都停留在 Patch 块层面,对像素的定位仍不足。而 MemAD^[7] 在 U-Net^[6] 的基础上结合了多尺度的 Memory Bank 模块,从而实现了较高的像素级的异常定位。但是这种方法同时保存了 3 个层级的 Memory Bank,对记忆库下采样取核心集以及利用迭代贪婪近似方法寻找最近似的 Patch 特征,都可能会对精度造成一定的损失,若正常样本数过多也会极大地增加存储资源,因此可以通过知识蒸馏的手段缓解该问题,以提升精度。

2 MKD-AD

MKD-AD 由语义分割网络、知识蒸馏模块、多尺度特征融合 (Multi-Scale Feature Fusion, MSFF) 模块以及异常模拟模块组成,结构如图 1 所示。知识蒸馏模块为语义分割网络提供利于异常定位的差值特征信息,MSFF 模块有效地将不同层级的特征信息进行上下文融合,异常模拟模块为语义分割网络提供了自监督的标签信息,4 个模块相互结合,最终实现高效的异常分割。




图 1 MKD-AD 的结构

2.1 语义分割网络

语义分割网络采用类似 U-Net^[6] 的网络架构,它的结构如图 2 所示,其中编码器部分采用了在 ImageNet 数据集^[14] 上预训练过的 ResNet18^[8] 作为特征提取器,通过提取输入图像的不同尺度的特征,拼接中间 3 层特征与知识蒸馏模块提供的差值特征以更有效定位缺陷;编码器将原始图像压缩到紧凑的低维特征,以减少过多的冗余特征信息;解码器对低维特征进行上采样,将图像还原为原图大小,并计算每个像素位置正常和异常的可能性。ResNet18^[8] 的特征层越深,它的特征信息越偏向它所分类的语义信息;特征层越浅,它的特征信息又不够丰富,感受野也会减小,

捕捉不到抽象级别的信息。所以将 ResNet18^[8] 的中间 3 层与学生网络进行蒸馏得到差值特征,并再次拼接送入解码器部分完成缺陷的预测任务。定义训练集 $D_{\text{train}} = \{x_1, x_2, \dots, x_n\}$, 正常图像的标签记为 $y_x = 0$, 异常图像的标记为 $y_x = 1$, 测试集 D_{test} 的标签 $y_x \in \{0, 1\}$ 。

2.2 知识蒸馏模块

受 Wang 等^[17] 提出的 STFP (Student-Teacher Feature Pyramid Matching) 方法的启示,本文将知识蒸馏与语义分割网络有效地结合起来,以提供更多的异常的差值定位信息给分割网

络。教师和学生网络都采用了 ResNet18 的网络架构,其中教师网络采用在 ImageNet 数据集上预训练的 ResNet18 模型,同时也作为分割网络的编码器部分,学生网络架构与教师一样,但需要通过训练学习更新网络参数。知识蒸馏模块的训练只在正样本数据上进行,使得教师网络只将学习的正样本特征传递给学生网络,学生网络在训练期间只见过正样本,它对正样本所提取的特征和教师网络提取到的正样本特征高度相似,对于负样本的缺陷区域,教师网络和学生网络所提取的对应位置特征则有很大区别,从而产生异常的定位信息。




图2 语义分割网络的结构

教师网络和学生网络提取的 Patch 特征沿通道维度进行归一化后的结果由式(1)~(2)表示:

$$\hat{F}_t^k(i, j) = \frac{F_t^k(i, j)}{\|F_t^k(i, j)\|_2} \quad (1)$$

$$\hat{F}_s^k(i, j) = \frac{F_s^k(i, j)}{\|F_s^k(i, j)\|_2} \quad (2)$$

其中: $F_t^k(i, j)$ 和 $F_s^k(i, j)$ 分别表示教师网络和学生网络提取的 Patch 特征; $\hat{F}_t^k(i, j)$ 和 $\hat{F}_s^k(i, j)$ 分别表示教师和学生网络对各自 Patch 特征沿通道维度进行归一化; k 表示网络提取到的第 k 个特征层, $k \in \{2, 3, 4\}$; (i, j) 表示 Patch 特征位于特征图中的位置。

为了有效结合异常定位信息,对两个网络对应位置的 Patch 特征进行差值计算,值越大表示异常的可能性越大,反之越小。差值计算过程通过式(3)表示:

$$F_{\text{diff}}^k(i, j) = (\hat{F}_t^k(i, j) - \hat{F}_s^k(i, j))^2 \quad (3)$$

其中 $F_{\text{diff}}^k(i, j)$ 表示对 2 个网络在各自第 k 层特征图 (i, j) 位置处 Patch 特征沿通道维度进行均方差计算后得到的结果。

融合差值信息与教师网络提取的特征,既能包含异常定位信息,也可保留输入本身的特征,拼接后的特征如式(4)所示:

$$F_{\text{cat}}^k(i, j) = \text{concat}(\hat{F}_{\text{diff}}^k(i, j), \hat{F}_t^k(i, j)) \quad (4)$$

其中 concat 表示对差值特征和教师网络提取的特征沿通道维度拼接,拼接后的特征由 $F_{\text{cat}}^k(i, j)$ 表示。

知识蒸馏在异常检测中的原理如图3所示,对于正常区域(如图3中白色区域),教师网络 and 经训练后的学生网络对应的 Patch 块相似度非常高,对于异常区域(如图3中的深色区域),由于两者对应的 Patch 块的表征会有很大区别,所以相似度会非常低,异常分数就会很高。




图3 知识蒸馏的原理

2.3 多尺度特征融合

输入图像经过教师学生网络后,分别提取 2 个网络的中间 3 层特征,通过将 2 个网络的特征图对应位置做差求平方,便可得到 3 个不同尺寸的差值特征图,这些特征图包含了丰富的异常定位信息。然后拼接教师网络提取的 3 层特征,从而为解码器提供更多额外的辅助信息,且无须单独为不同层级存储 Memory Bank,减小了存储压力。多尺度特征融合(MSFF)借鉴了 MemSeg (Memory-based Segmentation network)^[18],结合通道注意力和多尺度特征融合,有效融合了差值特征和教师网络提取的特征,减少了差值特征与教师网络特征拼接后的冗余特征信息,以得到更有效的特征表示。MSFF 模块的网络结构如图4所示,来自拼接后的特征分别经过通道注意力和卷积块后进行点乘,随后又经过了 2 层卷积模块。为了融合小尺度的特征与大尺度的特征,需要经过上采样至大尺度特征的大小,随后又经过卷积和叠加操作实现融合,最终将通过 MSFF 模块得到的特征作为解码器的输入完成解码操作。




图4 MSFF模块的网络结构

2.4 异常模拟

由于工业异常检测中缺陷样本难以收集,且可能出现的缺陷类型难以穷举,为了模拟在异常检测中出现的一些情况,CutPaste 算法^[19]通过从一个图像中切割出一个区域,并将该区域粘贴到同一图像的另一个随机位置模拟异常,该区域保持了原始图像的结构和内容,模拟了图像中可能出现的缺陷或异常,但这些模拟的缺陷与真实缺陷在视觉上可能并不完全相同。为了模拟更生动的缺陷,CutPaste 也衍生出了类似 CutPaste-Scar 等变体,但是它采用矩形框直接复制粘贴的方式,边界处会出现明显不连续性,导致产生的异常区域边界不够真实自然。SimpleNet^[20]则在特征层面增加高斯噪声模拟异常,虽然这样可以避免在图像层面上设计逼真异常区域的问题,但是需要在特征层面很高的调参技巧才能达到很好的效果。

本文参考了 DRÆM (Discriminative joint Reconstruction Anomaly Embedding Method)^[21]所采用的异常模拟策略,它的异常模拟效果如图5所示。DRÆM 通过从 DTD 数据集^[22]中选取纹理样本融入正常图像中模拟异常图像,这些样本提供了丰富的异常纹理特征,有助于生成多样化的异常图像,从而提高模型对未知异常类型的泛化能力。该异常模拟策略主要分为以下步骤:

1) 首先使用 Perlin^[23]噪声生成二维噪声图像以生成异常形状,并通过随机均匀采样的阈值将它二值化,得到异常区域掩码 M_p 。

2) 其次,通过采样 DTD 中的纹理图像 M_t ,应用 RandAugment^[24]增强纹理图像后得到 $M_{t_{\text{aug}}}$,对掩码 $M_{t_{\text{aug}}}$ 和 M_p 执行逐元素乘积形成异常掩码 $M_{p_{\text{ano}}}$ 。对正常图像 I 和掩码 $M_{p_{\text{ano}}}$ 执行逐元素乘积形成掩码 M_l 。引入透明度因子 δ 平衡 M_l 图像与 $M_{p_{\text{ano}}}$ 图像的融合,得到 M_{ano} 。

$$M_{p_{\text{ano}}} = M_p \odot M_{t_{\text{aug}}} \quad (5)$$

$$M_l = M_p \odot I \quad (6)$$

$$M_{\text{ano}} = \delta M_{p_{\text{ano}}} + (1 - \delta) M_1 \quad (7)$$

3)对异常区域掩码进行取反操作得到 $\bar{M}_p$,将它与正常图像




图5 异常模拟效果

2.5 损失函数

本文方法使用了3种损失函数:均方误差(Mean Squared Error, MSE)损失、L1损失以及Focal损失^[25]。

1)MSE损失函数主要用于教师网络和学生网络进行知识蒸馏时。通过该损失函数,教师网络能够将在正常样本上学习到的知识蒸馏给学生网络,通过训练学生网络减小2个网络所提取的特征的差距,为分割网络提供有价值的分割信息。定义特征图的大小为 (w, h) ,则第 k 层特征图MSE损失为 L_{MSE}^k ,中间3层之和可表示为 $L_{\text{st_sum}}$ 。

$$L_{\text{MSE}}^k = \frac{1}{w \times h} \sum_{i=1}^h \sum_{j=1}^w F_{\text{diff}}^k(i, j) \quad (9)$$

$$L_{\text{st_sum}} = \sum_{k=2}^4 L_{\text{MSE}}^k \quad (10)$$

2)在分割网络中,L1损失计算预测值与真实值之间的绝对差值。通过计算该损失然后进行反向传播使损失值越来越小,使得网络对异常区域的预测越来越接近真实值。它的公式如下:

$$L_1 = \sum_{i=1}^h \sum_{j=1}^w |\hat{y}(w, h) - y(w, h)| \quad (11)$$

其中: $\hat{y}(w, h)$ 表示分割网络的在每个像素位置的预测值; $y(w, h)$ 表示真实值。

3)Focal损失^[25]旨在解决类别不平衡问题,特别是在异常检测中正负样本比例相差悬殊的情况下。Focal损失通过减少对易分类样本的关注,增加对难分类样本的关注,从而提高模型对少数类别的识别能力。Focal损失的公式为:

$$L_{\text{Focal}} = -\alpha(1 - \hat{y}(w, h))^{\beta} \log(\hat{y}(w, h)) \quad (12)$$

其中: α 是平衡正负样本的权重系数; β 是调节易分类样本权重的聚焦参数。Focal损失用于提高模型对异常区域分割的准确性,特别是在异常区域占比较小的情况下。

2.6 MKD-AD训练及推理

MKD-AD网络的训练分为两个阶段。

第一阶段为教师网络和学生网络的训练,它的过程如图6所示,这个阶段的输入只有正样本,目的是通过教师网络提取正样本的特征后传递给学生网络,使学生网络输出的特征逐渐和教师网络相似,该阶段的训练过程如算法1所示。




图6 蒸馏网络训练的过程

算法1 MKD-AD学生网络的训练。

输入 正样本 $\{x_i\}, i = 1, 2, \dots, N$ 。

输出 学生网络 θ_s 。

程序初始化 教师网络加载预训练权重并冻结,学生网络初始化参数 θ_s 。

for $i = 1$ to N do:

逐元素乘积后再与 M_{ano} 相加得到最终的异常模拟图。

$$I_a = \bar{M}_p \odot I + M_{\text{ano}} \quad (8)$$

利用教师网络提取 x_i 的特征得到 F_1^2, F_1^3, F_1^4 。

利用学生网络提取 x_i 的特征得到 F_s^2, F_s^3, F_s^4 。

根据式(1)~(3)和(9)~(10)可以得到蒸馏网络的损失 $L_{\text{st_sum}}$ 。

梯度下降更新参数 θ_s 。

end for

第二阶段为分割网络的训练,如图7所示,这一阶段为了能够自监督训练,除了正样本作为输入外,又引入了异常模拟策略生成负样本作为输入,然后分割网络会结合蒸馏网络的差值特征,经过融合模块后,送入解码器实现像素级的异常分割,该阶段的训练过程如算法2所示。




图7 分割网络训练的过程

算法2 MKD-AD分割网络的训练。

输入 训练完成的学生网络,训练集 $\{x_i\}, i = 1, 2, \dots, n$;

输出 分割网络 θ_g 。

程序初始化 分割网络初始化参数 θ_g 。

for $i = 1$ to N do:

x_i 经过蒸馏网络得到 F_1^2, F_1^3, F_1^4 和 F_s^2, F_s^3, F_s^4 。

经过式(3)得到差值特征 $F_{\text{diff}}^2, F_{\text{diff}}^3, F_{\text{diff}}^4$ 。

经过式(4),拼接分割网络特征提取器提取到的特征与插值特征,得到 $F_{\text{cat}}^2, F_{\text{cat}}^3, F_{\text{cat}}^4$,经过MSFF模块送入解码器。

计算分割网络的损失 L_1 和 L_{Focal} 。

梯度下降更新参数 θ_g 。

end for

MKD-AD经过蒸馏和分割训练后,冻结网络中所有参数,推理过程如图8所示。学生网络由于训练期间只见过正样本,推理期间,学生网络和分割网络中的主干网络(即教师网络)相互结合为分割网络提供了丰富的差值特征,当输入是正样本时,该差值特征包含的异常信息很少;当输入是负样本时,该差值特征包含的异常信息很多,以此辅助分割网络实现高效的异常定位。模型的推理过程如算法3所示。




图8 网络推理的过程

算法 3 MKD-AD 分割网络的推理。

输入 测试样本 x_{test} , 学生网络及其参数 θ_s 和分割网络及其参数 θ_g ;

输出 异常分割掩码结果。

程序初始化 分割网络初始化参数 θ_g 。

利用教师和学生网络提取特征 F_t^2, F_t^3, F_t^4 和 F_s^2, F_s^3, F_s^4 。

经过式(3)得到差值特征 $F_{\text{diff}}^2, F_{\text{diff}}^3, F_{\text{diff}}^4$ 。

经过式(4), 将差值特征与分割网络特征提取器提取到的特征拼接, 得到 $F_{\text{cat}}^2, F_{\text{cat}}^3, F_{\text{cat}}^4$ 。

经过 MSFF 模块送入解码器, 得到异常分割掩码结果。

3 实验与结果分析

3.1 实验设置

实验在 Ubuntu 20.04.4 LTS 上进行, 显卡为 NVIDIA GeForce RTX 4090, PyTorch 版本为 2.3.1, Python 版本为 3.8.19。

MKD-AD 的图像输入大小为 256×256 , 编码器模块采用了在 ImageNet^[14] 上进行的 ResNet18^[8] 预训练权重, batch 大小为 32。

对于每个类别进行 500 轮训练, 其中前 120 轮用于蒸馏训练, 以筛选出平均损失最小的学生网络的模型权重, 后 380 轮用于分割网络的训练。蒸馏网络的优化器采用了随机梯度下降 (Stochastic Gradient Descent, SGD), 学习率为 0.4, 权重衰减率为 0.0005, 动量值为 0.9。分割网络的优化器采用了 AdamW, 学习率为 0.003, 权重衰减率为 0.0005, L1 损失和 Focal 损失的权重分别为 0.6 和 0.4。

3.2 数据集

实验采用 MVTec AD 数据集^[26], 该数据集是工业异常检测领域广泛认可的基准数据集, 专为无监督异常检测任务设计, 它的特点在于高分辨率图像的多样性以及丰富的标注信息。数据集

包含超过 5 000 张图像, 该数据集分为正常图像和异常图像两类, 共计 3 629 张图像用于训练, 1 725 张图像用于测试, 分辨率为 700×700 或 $1\,024 \times 1\,024$, 包含 5 个不同的纹理类别和 10 个不同的物体类别。每个类别包含 60~320 张正常图像以及几十张带有异常区域的测试图像。训练集图像均为无缺陷样本, 而测试集则包含了各种类型的缺陷样本, 如划痕、凹陷、脏污、形变和缺料等, 共计 73 种不同的缺陷类型。对于测试集中的缺陷样本, 数据集提供了像素级的精确标注, 这为异常区域的检测和定位提供了可靠的参考。

3.3 评价指标

本文采用图像级和像素级接受者操作特征曲线下面积 (Area Under Receiver Operating Characteristic curve, AUROC) 作为评价指标, 以全面评价 MKD-AD 方法的工业异常检测性能。

图像级 AUROC 是一种经典的二分类评价指标, 它通过绘制 ROC (Receiver Operating Characteristic) 曲线并计算它的下面积衡量模型的整体分类能力, AUROC 值越高, 表示模型区分正负样本的能力越强。

像素级 AUROC 则是对模型在像素级异常检测能力的评价, 它不仅考虑了异常区域的检测准确性, 还考虑了定位的精确性。它通过比较模型预测的异常像素与真实标注之间的匹配程度计算, 能够更细致地反映模型在异常定位方面的表现。

在实验中, 首先利用图像级的 AUROC 评价模型对异常图像的分类效果, 其次通过像素级的 AUROC 进一步分析模型在异常区域定位上的准确性。

3.4 实验结果

在 MVTec AD 数据集上对不同方法进行图像级和像素级的 AUROC 对比, 实验结果如表 1 所示。可以看出, MKD-AD 优于大多数方法, 验证了该方法的有效性。

表 1 不同方法在 MVTec AD 数据集上的图像级和像素级 AUROC 单位: %

类别	SPADE ^[15]		PaDim ^[27]		CutPaste ^[19]		P-SVDD ^[28]		DR ^{EM} ^[21]		ProtoAD ^[29]		MemAD ^[7]		MKD-AD	
	图像级	像素级	图像级	像素级	图像级	像素级	图像级	像素级	图像级	像素级	图像级	像素级	图像级	像素级	图像级	像素级
bottle	97.2	98.4	99.8	98.3	98.3	97.6	98.6	98.1	99.2	99.1	99.9	98.3	100.0	98.8	100.0	99.0
capsule	89.7	99.0	91.5	98.5	96.2	97.4	76.7	95.8	98.5	94.3	93.1	98.2	96.4	97.4	98.5	98.1
carpet	92.8	97.5	99.9	99.1	93.1	98.3	92.9	92.6	97.0	95.5	99.5	99.2	87.4	96.9	99.5	98.0
grid	47.3	93.7	95.7	97.3	99.9	97.5	94.6	96.2	99.9	99.7	93.7	98.0	100.0	99.2	100.0	99.3
hazelnut	88.1	99.1	93.3	98.2	97.3	97.3	92.0	97.5	100.0	99.7	100.0	98.8	99.4	98.2	100.0	97.3
leather	95.4	97.6	100.0	99.2	100.0	99.5	90.9	97.4	100.0	98.6	100.0	99.4	100.0	96.7	100.0	99.5
metal nut	71.0	98.1	99.2	97.2	99.3	93.1	94.0	98.0	98.7	99.5	99.9	96.8	100.0	99.0	99.8	96.6
pill	80.1	96.5	94.4	95.7	92.4	95.7	86.1	95.1	98.9	97.6	95.8	94.2	94.8	97.7	99.1	97.2
screw	66.7	98.9	84.4	98.5	86.3	96.7	81.3	95.7	93.9	97.6	94.9	98.9	100.0	97.0	96.4	97.4
tile	96.5	87.4	97.4	94.1	93.4	90.5	97.8	91.4	99.6	99.2	99.2	95.2	100.0	99.2	99.9	99.4
toothbrush	88.9	97.9	97.2	98.8	98.3	98.1	100.0	98.1	100.0	98.1	99.7	98.8	100.0	97.6	100.0	99.2
wood	95.8	85.5	98.8	94.9	98.6	95.5	96.5	90.8	99.1	96.4	99.1	95.6	100.0	98.9	100.0	96.0
zipper	96.6	96.5	90.9	98.5	99.4	99.3	97.9	95.1	100.0	98.8	94.6	96.7	96.5	90.8	100.0	99.0
平均	85.1	95.9	95.6	97.6	96.3	96.7	92.3	95.5	98.8	98.0	97.6	97.5	98.0	97.5	99.5	98.2

在图像级的异常检测中, MKD-AD 在多个类别上达到了 100% 的 AUROC, 平均 AUROC 达到了 99.5%; 在像素级的异常分割任务中, 平均 AUROC 达到了 98.2%。实验结果表明, MKD-AD 性能优于大多数对比方法, 不仅在图像级上能够对异常进行高效判别, 也在像素级上实现了精确定位。

在图像级的异常检测任务中, MKD-AD 在 screw 类别上的表现相对较差, 可能的原因是螺丝本身材质表面光滑, 拍摄图像时有一些反光, 诱导了方法预测错误, 导致将正常螺丝图像识别为了异常图像。

在像素级异常检测任务中, MKD-AD 在 wood 和 metal nut 类别上的结果相对更差。对于 wood 类别, 可能是 MKD-AD 识别出了一些看起来异常但并不认为是异常的区域, 如图 9 所示, 原图中标记的部分相较于其他区域更像是一种异常, MKD-AD 也定位出了该区域, 但是真实标签并未标记这一处, 从而导致它在 wood 类别上 AUROC 较低。对于 metal nut 类别, 异常定位性能差的原因可能是异常模拟策略对 metal nut 类别构建的缺陷样本相较于于

真实缺陷样本的分布差异较大, 从而导致了在该类别上的异常定位性能较低。

MKD-AD 和 MemAD^[7] 都基于编码解码的分割网络实现高效的异常定位, 不同之处在于, MemAD 方法通过提前构造正常样本 3 种不同尺寸的特征记忆库, 并将记忆库融入分割网络中以达到良好的异常定位性能, 但这种基于记忆库的方法在推理过程中需要对特征记忆库进行向量相似度检索, 寻找最相似的特征。为了加速检索过程, 通常引入近似查询操作, 导致损失了一定的精度。而 MKD-AD 通过蒸馏的方式避免了记忆库的构建以及近似检索的过程, 从而提升了检测性能。相较于 MemAD, MKD-AD 的图像级和像素级 AUROC 分别提高了 1.5 和 0.7 个百分点, 验证了它结合了蒸馏方法定位异常的有效性。

图 10 为 MKD-AD 的预测结果, 通过观察预测出的 mask 图像可以发现, MKD-AD 预测的异常区域和真实标签的异常区域轮廓基本一致, 它能精准地定位较小的斑点缺陷, 同时能够定位裂纹缺陷等大缺陷。




图9 MKD-AD在 wood类别上的预测结果




图10 MKD-AD的预测结果

3.5 消融实验

为了探究蒸馏网络的不同尺度差值特征经过融合模块后对方法性能的影响,拼接 ResNet18^[8]的中间3层与蒸馏网络的差值特征后形成的3个不同尺度特征用 $F^k(k \in \{2, 3, 4\})$ 表示。 F^k 是由蒸馏网络的第 k 层差值特征图与教师网络的第 k 层特征图沿通道维度进行拼接后的结果。在图像级和像素级 AUROC 上进行消融实验,实验结果如表2所示。

表2 MSFF 模块不同尺度特征融合后的 AUROC 结果 单位: %

Stage	图像级	像素级
—	98.9	97.5
F^2, F^3	99.2	98.1
F^3, F^4	99.1	97.4
F^2, F^3, F^4	99.5	98.2

其中“—”表示3个尺度的特征不进行多尺度融合,可以看出,图像级和像素级的 AUROC 相较于 F^4 分别下降了0.6和0.7个百分点。当融合 F^2 和 F^3 后, AUROC 相较于不融合的情况有所提升,但相较于3层全部融合有所下降。当融合 F^3 和 F^4 时, AUROC 不如融合 F^2 和 F^3 ,因为越深层的特征越抽象,缺少了底层的细粒度特征, F^2 相较于 F^4 的细粒度特征更加丰富,从而导致了指标有所下降。最后将3个特征层融合的效果最好,图像级和像素级的 AUROC 指标分别达到了99.5%和98.2%。消融实验结果验证了充分融合3种尺度的差值特征能够使 MKD-AD 的检测性能达到最好。

4 结语

本文提出基于多尺度知识蒸馏的工业异常分割方法 MKD-AD,通过蒸馏网络为异常分割提供了丰富的异常定位信息,辅助分割更好地定位异常,无须像 MemAE、MemAD 等网络重新构造额外的内存记忆库,减少了存储压力和检索排序操作。MKD-AD

在 MVTEC AD 数据集上的结果优于大多数对比方法,更加符合工业实际场景。然而 MKD-AD 在某些类别表现依然欠缺,一部分原因可能是异常模拟策略在某些类上表现得不够真实,另一部分原因是模型对于一些光线干扰不够鲁棒。在未来的研究中,我们将探索更真实的异常模拟策略以及更鲁棒的算法框架进一步提升方法的性能。

参考文献 (References)

[1] BERGMANN P, LÖWE S, FAUSER M, et al. Improving unsupervised defect segmentation by applying structural similarity to autoencoders [C]// Proceedings of the 14th International Joint Conference on Computer Vision, Imaging and Computer Graphics Theory and Applications — Volume 5: VISAPP. Setúbal: SciTePress, 2019: 372-380.

[2] TANG T W, KUO W H, LAN J H, et al. Anomaly detection neural network with dual auto-encoders GAN and its industrial inspection applications [J]. Sensors, 2020, 20(12): No. 3336.

[3] AKCAY S, ATAPOUR-ABARGHOU EI A, BRECKON T P. GANomaly: semi-supervised anomaly detection via adversarial training [C]// Proceedings of the 2018 Asian Conference on Computer Vision, LNCS 11363. Cham: Springer, 2019: 622-637.

[4] SCHLEGL T, SEEBÖCK P, WALDSTEIN S M, et al. Unsupervised anomaly detection with generative adversarial networks to guide marker discovery [C]// Proceedings of the 2017 International Conference on Information Processing in Medical Imaging, LNCS 10265. Cham: Springer, 2017: 146-157.

[5] GONG D, LIU L, LE V, et al. Memorizing normality to detect anomaly: memory-augmented deep autoencoder for unsupervised anomaly detection [C]// Proceedings of the 2019 IEEE/CVF International Conference on Computer Vision. Piscataway: IEEE, 2019: 1705-1714.

[6] RÖNNEBERGER O, FISCHER P, BROX T. U-Net: convolutional networks for biomedical image segmentation [C]// Proceedings of the 2015 International Conference on Medical Image Computing and

- Computer-Assisted Intervention, LNCS 9351. Cham: Springer, 2015: 234-241.
- [7] 刘永江,陈斌. 基于多尺度记忆库的像素级无监督工业异常检测[J]. 计算机应用, 2024, 44(11): 3587-3594.
- [8] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition [C]// Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2016: 770-778.
- [9] LI Z, LI N, JIANG K, et al. Superpixel masking and inpainting for self-supervised anomaly detection [C]// Proceedings of the 2020 British Machine Vision Conference. Durham: BMVA Press, 2020: No. 275.
- [10] PIRNAY J, CHAI K. Inpainting Transformer for anomaly detection [C]// Proceedings of the 2022 International Conference on Image Analysis and Processing, LNCS 13232. Cham: Springer, 2022: 394-406.
- [11] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need [C]// Proceedings of the 31st International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2017: 6000-6010.
- [12] TAN D S, CHEN Y C, CHEN T P C, et al. TrustMAE: a noise-resilient defect classification framework using memory-augmented auto-encoders with trust regions [C]// Proceedings of the 2021 IEEE Winter Conference on Applications of Computer Vision. Piscataway: IEEE, 2021: 276-285.
- [13] 张宏伟,张伟伟,熊文博,等. 基于记忆去噪卷积自编码器的色织物缺陷检测[J]. 纺织高校基础科学学报, 2022, 35(2): 64-71.
- [14] DENG J, DONG W, SOCHER R, et al. ImageNet: a large-scale hierarchical image database [C]// Proceedings of the 2009 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2009: 248-255.
- [15] COHEN N, HOSHEN Y. Sub-image anomaly detection with deep pyramid correspondences [EB/OL]. [2024-08-20]. <https://arxiv.org/pdf/2005.02357>.
- [16] ROTH K, PEMULA L, ZEPEDA J, et al. Towards total recall in industrial anomaly detection [C]// Proceedings of the 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2022: 14298-14308.
- [17] WANG G, HAN S, DING E, et al. Student-teacher feature pyramid matching for unsupervised anomaly detection [C]// Proceedings of the 2021 British Machine Vision Conference. Durham: BMVA Press, 2021: No. 1273.
- [18] YANG M, WU P, FENG H. MemSeg: a semi-supervised method for image surface defect detection using differences and commonalities [J]. Engineering Applications of Artificial Intelligence, 2023, 119: No. 105835.
- [19] LI C L, SOHN K, YOON J, et al. CutPaste: self-supervised learning for anomaly detection and localization [C]// Proceedings of the 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2021: 9659-9669.
- [20] LIU Z, ZHOU Y, XU Y, et al. SimpleNet: a simple network for image anomaly detection and localization [C]// Proceedings of the 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2023: 20402-20411.
- [21] ZAVRTANIK V, KRISTAN M, SKOČAJ D. DRÆM — a discriminatively trained reconstruction embedding for surface anomaly detection [C]// Proceedings of the 2021 IEEE/CVF International Conference on Computer Vision. Piscataway: IEEE, 2021: 8310-8319.
- [22] CIMPOI M, MAJI S, KOKKINOS I, et al. Describing textures in the wild [C]// Proceedings of the 2014 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2014: 3606-3613.
- [23] PERLIN K. An image synthesizer [J]. ACM SIGGRAPH Computer Graphics, 1985, 19(3): 287-296.
- [24] CUBUK E D, ZOPH B, SHLENS J, et al. RandAugment: practical automated data augmentation with a reduced search space [C]// Proceedings of the 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops. Piscataway: IEEE, 2020: 702-703.
- [25] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection [C]// Proceedings of the 2017 IEEE International Conference on Computer Vision. Piscataway: IEEE, 2017: 2999-3007.
- [26] BERGMANN P, FAUSER M, SATTLEGGGER D, et al. MVTec AD — a comprehensive real-world dataset for unsupervised anomaly detection [C]// Proceedings of the 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2019: 9584-9592.
- [27] DEFARD T, SETKOV A, LOESCH A, et al. PaDiM: a patch distribution modeling framework for anomaly detection and localization [C]// Proceedings of the 2021 International Conference on Pattern Recognition, LNCS 12664. Cham: Springer, 2021: 475-489.
- [28] YI J, YOON S. Patch SVDD: patch-level SVDD for anomaly detection and segmentation [C]// Proceedings of the 2020 Asian Conference on Computer Vision, LNCS 12627. Cham: Springer, 2021: 375-390.
- [29] HUANG C, KANG Z, WU H. A prototype-based neural network for image anomaly detection and localization [J]. Neural Processing Letters, 2024, 56(3): No. 169.