

基于改进 YOLOv8 模型的交通信号灯检测算法

陈智^{1*}, 张晨骛¹, 李浩², 陈志涛², 陆艳铭², 孙涛³

(1. 北方工业大学 电气与控制工程学院, 北京 100144; 2. 云南省交通规划设计研究院股份有限公司, 昆明 650011;

3. 云南省交通投资建设集团有限公司, 昆明 650103)

(* 通信作者电子邮箱 cz86@ncut.edu.cn)

摘要:针对现有基于计算机视觉的交通信号灯检测算法在复杂环境下容易出现误检漏检等问题,提出一种基于改进 YOLOv8 模型的交通信号灯检测算法 DMW-YOLO (Deep adaptive weight Multi-scale information feature extraction Wise complete intersection over union-YOLO)。首先,利用迁移学习对交通信号灯的形状以及颜色进行权重共享,在保持计算复杂度不变的前提下降低复杂光源对算法的干扰;其次,设计一种深度自适应权重特征金字塔网络(DWFPN)特征融合模块代替 YOLOv8 中的路径聚合网络(PANet)模块,通过联合高维特征信息调整模块权重减少图像模糊引起的信号灯信息丢失;再次,提出一种多尺度信息特征提取(MFE)模块代替 YOLOv8 中的快速空间金字塔池化(SPPF)模块,在尽量不提升计算量的同时通过在特征提取时获得的不同感受野组合降低小目标信号灯带来的信息损失;最后,提出一种新型损失函数 Wise-CIoU (Wise-Complete Intersection over Union) 损失函数代替 Ciou (Complete Intersection over Union) 损失函数,实现对信号灯目标的精准定位。实验结果表明,相较于原 YOLOv8 算法,所提算法的精确率(Precision)提高了 2.3 个百分点,召回率(Recall)提高了 4.4 个百分点,平均精确率(mAP@0.5)和不同阈值下平均精确率(mAP@0.5:0.95)分别提高了 3.5 和 4.8 个百分点,同时每秒帧数(FPS)达到了 297.1,满足对于交通信号灯检测的实时性要求。

关键词: 信号灯检测; 特征融合; 迁移学习; 损失函数; 特征提取

中图分类号: TP391.4 **文献标志码:** A

Traffic light detection algorithm based on improved YOLOv8 model

CHEN Zhi^{1*}, ZHANG Chen'ao¹, LI Hao², CHEN Zhitao², LU Yanming², SUN Tao³

(1. School of Electrical and Control Engineering, North China University of Technology, Beijing 100144, China;

2. Broadvision Engineering Consultants Company Limited, Kunming Yunnan 650011, China;

3. Yunnan Communications Investment and Construction Group Company Limited, Kunming Yunnan 650103, China)

Abstract: To address the issues of false positives and false negatives that the existing computer vision-based traffic light detection algorithms often encounter in complex environments, a traffic light detection algorithm called DMW-YOLO (Deep adaptive weight Multi-scale information feature extraction Wise complete intersection over union-YOLO) was proposed on the basis of an improved YOLOv8 model. First, transfer learning was used to share weights for the shape and color of traffic lights, thereby reducing the interference of complex light source conditions on the algorithm while maintaining the same computational complexity. Second, a Deep adaptive Weight Feature Pyramid Network (DWFPN) feature fusion module was designed to replace the Path Aggregation Network (PANet) module in YOLOv8, so that the high-dimensional feature information was integrated to adjust the module weights for reducing the loss of traffic light information caused by image blurring. Third, a Multi-scale information Feature Extraction (MFE) module was proposed to replace the Spatial Pyramid Pooling Fast (SPPF) module in YOLOv8, so that the information loss caused by small-target traffic lights was reduced by obtaining different receptive field combinations during feature extraction while minimizing the increase in computational load. Finally, a novel loss function Wise-CIoU (Wise-Complete Intersection over Union) was proposed to replace the Ciou (Complete Intersection over Union) loss function, thereby realizing precise localization of traffic light targets. Experimental results show that compared to the original YOLOv8 algorithm, the proposed algorithm achieves an increase of 2.3 percentage points in Precision, an increase of 4.4 percentage points in Recall, with the average precision (mAP@0.5) and average precision at different thresholds (mAP@0.5:0.95) improved by 3.5 and 4.8 percentage points, respectively, while the Frames Per Second (FPS) reaches 297.1, meeting the real-time requirements for traffic light detection.

Key words: traffic light detection; feature fusion; transfer learning; loss function; feature extraction

0 引言

交通信号灯是城市交通管理系统的重要组成部分,它在防止交通事故、提升交通效率方面发挥着不可或缺的作用。随着城市化进程的推进,城市交通也面临越来越复杂的挑战,包括交通拥堵和事故频发等问题。通过对信号灯进行合理的规划和动态的调控,可以有效地协调行人与机动车之间的通行权,降低两者之间潜在冲突。

利用计算机视觉对信号灯检测的方法主要分为传统方法和深度学习方法。传统检测信号灯方法^[1]主要利用颜色分割和对比的方式检测信号灯。例如曾杨帆等^[2]提出一种融合 HSV (Hue, Saturation, Value) 颜色空间与灰度图像先验信息的交通信

号灯识别方法,通过倾斜校正、大小标准化预处理后,利用 HSV 空间初步识别信号灯颜色,结合霍夫直线检测提取感兴趣区域 (Region Of Interest, ROI);针对 HSV 失效场景,基于信号灯红黄绿分层结构先验,对灰度图像 ROI 像素沿垂直方向分区域求和,通过阈值判定颜色类别。李慧森等^[3]提出一种融合改进多尺度视网膜增强 (Multi-Scale Retinex with Color Restoration, MSRCR) 与最大稳定极值区域 (Maximally Stable Extremal Region, MSER) 的识别算法。首先通过高斯环绕函数联合伽马变换优化 MSRCR 算法,校正雾霾图像亮度并增强细节;再利用 MSER 算法提取信号灯候选区域,结合背板几何特征筛选目标区域;最后将定位区域转换至 HSV 空间,通过色调直方图统计区分红、黄、绿灯状态。

收稿日期: 2025-07-14; 修回日期: 2025-09-09; 录用日期: 2025-09-11。

基金项目: 云南省交通运输厅科技创新及示范项目(云交科教便[2023]147号)。

作者简介: 陈智(1986—), 男, 江西南昌人, 副研究员, 博士, 主要研究方向: 城市交通控制、交通仿真、交通组织与优化; 张晨骛(2001—), 男, 北京人, 硕士研究生, 主要研究方向: 图像处理; 李浩(1987—), 男, 陕西宝鸡人, 高级工程师, 博士, 主要研究方向: 智能交通; 陈志涛(1992—), 男, 内蒙古赤峰人, 工程师, 硕士, 主要研究方向: 交通仿真、计算机视觉; 陆艳铭(1990—), 男, 河南开封人, 高级工程师, 硕士, 主要研究方向: 智慧交通; 孙涛(1990—), 男, 云南宣威人, 工程师, 主要研究方向: 智能交通。

有效解决了图像亮度失真问题。Lin 等^[4]提出一种基于学习的两阶段框架以应对夜间驾驶场景,第一阶段采用图像强度编码和色调映射进行交通信号灯检测,随后结合对数极坐标变换的支持向量机(Support Vector Machine, SVM)分类器用于箭头信号灯识别,该技术在所有交通信号灯类别上的平均准确率达 97.5%。但是单纯使用颜色分割进行判断的方法在面对复杂场景以及面对不同光照程度的条件下往往表现不佳,无法达到预期效果。近年来,随着卷积神经网络的发展,研究人员开始研究利用深度学习检测信号灯的方法。相较于传统方法,利用深度学习的方法在检测精度、检测速度和鲁棒性方面有了显著提高。

基于深度学习的目标检测算法主要分成两类:即二阶段目标检测算法和一阶段目标检测算法。二阶段目标检测算法将目标检测分为 2 个步骤:首先通过区域提议网络或其他方法生成可能包含目标的候选区域,然后分类和精细化定位这些候选区域以确定目标的具体类别和位置。

二阶段检测算法检测精度较高,能够有效避免背景干扰,减少误检;但是相较于一阶段算法处理速度较慢,且训练时间较长。二阶段目标检测算法主要包括 RCNN (Region-Convolutional Neural Network)^[5]、Faster R-CNN (Faster Region-Convolutional Neural Network)^[6]、SPPNet (Spatial Pyramid Pooling Network)^[7]、DetectoRS (Detecting objects with Recursive feature pyramid and Switchable atrous convolution)^[8]和 R-FCN (Region-based Fully Convolutional Network)^[9]。李靖博^[10]提出基于 Faster R-CNN 深度学习算法构建交通信号灯检测识别模型。构建包含红、绿、黄三色灯及转向类别的标注数据集实施迁移学习,利用交叉熵损失与 Smooth L1 损失优化多任务学习。实验结果表明,模型在测试集上达到 93.49% 的整体准确率。李在润^[11]通过改进 CenterNet 算法,采用中心点定位替代传统候选框机制,结合 ResNet18 (Residual Network)主干网络优化通道数,构建多尺度特征融合层级网络以提升小目标检测能力,改进后的检测模型 mAP (mean Average Precision) 达 0.753,每秒帧数 (Frames Per Second, FPS) 达 20.8。

一阶段检测算法通过单次前向传播过程直接预测图像中目标的类别和位置,并在特征图上直接进行分类和回归,从而快速检测目标。由于简洁的计算流程,一阶段目标检测算法在实时性方面更突出。一阶段检测算法主要包括 YOLO 算法系列^[12-16]、SSD (Single Shot MultiBox Detector) 算法系列^[17-19]、RetinaNet^[20]和 EfficientDet^[21]。余杨等^[22]提出一种融合支持向量数据描述 (Support Vector Data Description, SVDD) 重识别与 YOLOv8 的交通信号灯检测模型,通过全局注意力机制增强特征提取、EIoU (Efficient-Intersection over Union) 损失函数优化定位,并引入异常信息反馈机制动态提升模型鲁棒性。实验表明该方法在检测精度和抗干扰能力上显著优于传统 YOLOv8。罗庆龄^[23]提出一种融合极化自注意力机制的交通信号灯检测算法,针对 YOLOv8 在低分辨率小目标检测中存在的精度不足、易漏检误检等问题,通过在颈部网络引入 SPDConv 压缩空间维度与增强通道扩展对低分辨率小目标的特征提取能力;设计 PSA (Pyramid Split Attention) 极化自注意力机制,强化模型对非线性细节语义信息的捕捉能力;采用 Focal-CIoU (Focal-Complete-Intersection over Union) 损失函数缓解样本类别不平衡问题并优化边界框回归精度。实验结果表明,改进算法相较于 YOLOv8s 的 mAP 和 FPS 均得到了提高。Yao 等^[24]提出一种由增强型超类检测器和细粒度分类器构成的交通信号灯识别框架,通过聚类算法确定最佳超类数量以减轻相似类别影响,为超类检测器增加额外预测层以利用阴影特征提升性能,基于深度可分离卷积和扩展层构建细粒度分类器以实现不同交通信号灯的优异识别;在 WPI 交通信号灯数据集上的实验结果显示,该方法精度达 99.04%、召回率 97.40%、每帧耗时 9.9 ms,与其他先进方法相比竞争力显著,对交通信号灯识别十分有效。Huang 等^[25]提出一种轻量级交通信号灯检测模型,采用精简骨干网络和 Low-GD (Low-Gather and Distribute mechanism) 颈部架构,能提升信息丰富度、位置感知和多尺度特征聚合整合能力,减少信息损失,还通过基于 Stable Diffusion 的数据增强策略扩展复杂天气下的数据集以提高泛化

性;该模型在 YCTL2024 数据集上 FPS 达到 135,准确率为 98.23%。Tang 等^[26]提出基于增强型 RT-DETR 的 GAD-DETR 网络,首先借鉴 GhostNet 减少计算冗余的思路并整合重参数化卷积,开发 GRELAN (Ghost RepConv Efficient Layer Aggregation Network) 模块重构骨干网络,大幅降低模型大小和参数量并提升检测速度,其次引入 ADown 替代标准卷积进行下采样以改善小目标识别,最后设计轻量级特征融合模块 DGSFM 进一步降低计算成本、提高效率;实验结果显示, GAD-DETR 检测精度达 95.9%,且效率优化显著,模型大小减小 50.3%,参数量和计算量分别降低 50.8% 和 51.2%,帧率从 76.7 提升至 117.8。

1 改进的 DMW-YOLO 算法

1.1 DMW-YOLO 算法的网络结构

针对当前检测算法在复杂场景中存在因灯色相近导致的误检、漏检等问题,本文构建了 DMW-YOLO (Deep adaptive weight Multi-scale information feature extraction Wise complete intersection over union-YOLO) 检测算法,可以快速准确地区分复杂环境下不同光源的信号来源,进而实现信号灯的精确检测。DMW-YOLO 采用迁移学习的方式,先将注意力聚焦于信号灯形状特征,再将形状信息迁移至信号灯种类筛选,最后集中识别信号灯颜色信息,从数据层面提升了检测基准精度。其次提出了深度自适应权重特征金字塔网络 (Deep adaptive Weight Feature Pyramid Network, DWFPN) 信息融合模块,通过在 Neck 层加权融合相邻层的数据与原始数据,有效减少特征丢失并提升图像特征提取能力;再次,采用多尺度信息特征提取 (Multi-scale information Feature Extraction, MFE) 模块代替原有的快速空间金字塔池化 (Spatial Pyramid Pooling Fast, SPPF) 结构,通过多次特征提取操作增大感受野;最后使用 Wise-CIoU (Wise-Complete Intersection over Union) 代替原有的 Ciou (Complete Intersection over Union),显著提高预测框的定位精度。DMW-YOLO 的结构如图 1 所示。

1.2 基于信号灯形状和颜色的迁移学习

在训练中,训练数据与检测算法本身具有同等重要的耦合关系。复杂道路环境中存在车灯、路灯等多光源干扰现象,这些干扰源的颜色、亮度和分布状况与信号灯存在显著相似性。这种相似性导致算法易混淆干扰源与信号灯颜色,无法准确区分信号灯的颜色,从而对检测过程造成干扰,最终降低检测精度。

本文采用迁移学习的方式实现信号灯精准识别。图 2 为迁移学习框架示意图。

首先通过识别信号灯的几何形态特征进行区域筛选,有效排除非信号灯目标的形态干扰,继而通过跨模态特征迁移技术提取信号灯颜色特征,显著降低复杂环境中无关因素带来的干扰,使检测算法能够更准确地聚焦于信号灯本身,从而提升识别的准确性。

经训练后的信号灯目标检测算法可基于信号灯的形态学特征,对颜色特征预测模块生成的候选信号灯实例进行自适应筛选,通过多维度特征匹配机制有效剔除场景中无关光源的误检干扰,从而实现信号灯目标的精准定位与状态判别。

1.3 深度自适应权重特征金字塔网络 DWFPN

YOLOv8 架构采用特征金字塔网络 (Feature Pyramid Network, FPN) 融合多尺度特征,但它只通过上下层级间特征数据的逐元素简单叠加实现融合。这种原始的融合策略未能考虑不同来源特征的重要性差异,缺乏可学习的自适应权重分配机制,这与特征融合需依据任务需求动态调整特征贡献度的基本原则相悖,容易导致特征表达能力冗余与损失。该问题在复杂交通场景中尤为突出:一方面,非检测源光源干扰和不同能见度下的光照变化会掩盖信号灯特征;另一方面,随着网络深度增加,FPN 对单一信号灯的差异性表征的关注程度逐渐降低,进而削弱信号灯颜色分类与检测的判别能力。因此,为了应对这一挑战,本文提出 DWFPN。图 3 为 FPN、双向特征金字塔网络 (Bidirectional Feature Pyramid Network, BiFPN)^[21]和 DWFPN 这 3 种颈部网络的结构。相较于图 3(b)单一 BiFPN^[21],DWFPN 对同一层级的局部特征提取分支与高维层级的跨尺度特征分支同时采

取基于特征重要性动态分配权重的融合策略整合多维度信息,提高对信号灯局部细节的感知能力。

DWFPN 架构的创新性体现在 2 个部分:

首先在同一尺度的特征信息融合输出阶段引入跨层特征跳跃连接,自适应融合主干网络中的原始信息,并使用可学习的动

态权重分配参数加权融合不同来源的特征,通过残差连接保留主干网络原始特征信息并进行自适应融合,结合可学习的动态权重参数,在保障计算效率的前提下,通过自适应权重实现不同来源特征的差异化贡献度分配,利用同维度层间的多层次特征交互以有效抑制复杂环境中的光源干扰。




图1 DMW-YOLO的网络结构




图2 迁移学习框架

其次构建高维特征抽取机制,提取关键高维数据并进行差异化自适应权重融合。针对FPN仅考虑同层级信息交互而忽略跨层级特征的问题,本文通过同层级多尺度特征融合架构进行困难场景信号灯检测。依据高维特征空间细节丰富与低维特征语义信息突出的特征,通过跨层级特征交互,一方面缓解因网络层数加深导致信号灯特征梯度消失现象,实现全局语义特征与局部细节特征的协同整合;另一方面在最大化融合信号灯信息的同时,有效抑制复杂环境中的干扰光源影响,提升了在困难场景下对信号灯的检测能力。本文分别对低维语义信息与高维细节信息进行实验,实验结果如图4所示。




图3 3种颈部网络连接方式

实验结果如表1所示,在高分辨率特征空间中,信号灯信息相较于复杂环境干扰光源能够保持更完整的特征表达,经差异化权重融合后算法准确率显著提升;在低层次特征空间中,图像分辨率下降导致颜色特征严重丢失,使得复杂环境中的干扰光源信息对信号灯颜色信息造成了显著干扰,致使误判干扰和检测精度下降。

由表1可知,相较于单一的高维信息融合的连接方式(DWFPN-up-link),单一的低维信息融合的连接方式(DWFPN-down-link)的 Precision、Recall、mAP@0.5 和 mAP@0.5:0.95 分别下降了 2.2、1.0、0.9 和 1.1 个百分点;相较于单一的高维信息融

合的连接方式,融合高维信息与低维信息的连接方式(DWFPN-all-link)的 Precision、Recall、mAP@0.5 和 mAP@0.5:0.95 分别下降了 0.8、1.0、0.5 和 1.1 个百分点。由此可见高维信息中包含着较多信号灯信息,低维信息中包含着较多干扰信息,因此本次实验采取单一的高维信息融合的连接方式。

1.4 多尺度信息特征提取 MFE

YOLOv8 采用 SPPF 结构增强多尺度目标特征感知能力,它通过串行三级下采样池化操作,并将每次池化结果通过残差连接融合。这种设计可以有效地捕捉到不同尺度物体的信息特征,在复杂场景中抑制环境光噪声干扰,同时通过串行操作降低

计算复杂度,满足实时性要求。然而,SPPF的串行处理在极端的尺度变化时会导致特征信息丢失和冗余信息问题,进而降低模

型算法的泛化性。为此,本文提出 MFE 模块替代 YOLOv8 中的 SPPF 对特征进行提取。




图4 3种DWFPN的结构

表1 3种DWFPN性能对比

单位: %

DWFPN	Precision	Recall	mAP@0.5	mAP@0.5:0.95
DWFPN-all-link	92.6	89.8	93.4	60.6
DWFPN-down-link	91.2	89.8	93.0	60.6
DWFPN-up-link	93.4	90.8	93.9	61.7

MFE 模块的提出基于并行多尺度感知,通过仿照 SPPCSPC 的多分支结构将特征分流到不同路径处理:一条路径通过简单的 CBS(Conv Batchnorm SiLU)结构保留特征更多的梯度信息和原始特征,保证梯度信息的完整;另一条路径通过多尺度增强扩大感受野的范围,增强模糊图像的细节捕捉能力,通过多尺寸的特征加权融合与通道维度对齐,提高目标检测的准确性。

MFE 模块将 CBS 模块更换为 CBR(Conv Batchnorm ReLU)模块, CBR 模块融合了 SimConv(Simplified Conv),并提出 RepPConv(Reparameterized Partial Convolution)结构对特征信息进行提取。首先采用 SimConv 作为 MFE 的基准组成模块,同时使用 RepPConv 作为特征提取中的通道注意力加强模块, SimConv 将 Conv 中的 SiLU 激活函数转换成 ReLU 激活函数,可以在不降低检测精度的情况下有效地提高检测速度。RepPConv 是对 PConv(Partial Convolution)进行的重参数化,在通道上对卷积进行切分重组,有效地提高卷积在通道中对信号灯信息权重的提升与关注,在降低计算量的同时提高检测精度,中间部分采用 SPP 结构,依据小卷积核对目标边缘等细节敏感、大卷积核擅长捕获目标轮廓等全局语义信息的特点,通过自适应权重、对不同尺度特征图加权求和,排除在复杂环境中对于无关光源的检测。

MFE 的结构如图 5 所示。

传统轻量化卷积存在对内存的频繁访问,在降低浮点运算数(Floating Point Operations, FLOPs)的同时存在降低每秒浮点运算数(Floating Point Operations per Second, FLOPS)的现象,针对这一矛盾, PConv 提出基于通道特征相似性的重参数化选择性卷积策略:利用输入特征通道间存在部分高度相似性的特性,仅对高相似性通道执行卷积操作,而跳过低相似性通道。通过引导卷积操作聚焦于空间特征提取,有效减少计算冗余量及内存访问频次。但是 PConv 存在因通道切分而导致的信号灯特征丢失现象,因此本文对 PConv 进行重参数化,提出 RepPConv,在训练时 RepPConv 对其中高相似度分支通道采取多分支特征提取结构,将原始一条支路分割为 1×1 卷积支路、3×3 卷积支路和原始支路,通过不同分支捕捉不同尺度的信号灯细粒度细节和全局语义信息。其中:1×1 卷积支路聚焦信号灯通道信息,3×3 卷积支路聚焦信号灯空间特征,原始支路保留信号灯原始特征,在测试时通过重参数化技术将训练时的多分支结构转化为单一的 3×3 卷积,减小模块的计算量,既保留了多分支带来的性能增益,又避免了推理时多分支的计算冗余,显著提升运行速度。RepPConv 能够显著提升 FLOPS,实现计算资源的高效利用。RepPConv 的结构如图 6 所示。




图5 MFE 的结构




图6 RepPConv 的结构

如式(1)~(2)所示, h, w 为图片化为向量后的高和宽, k 为卷积核的核数, C_p 为 PConv 选择的卷积通道数, 当部分比例 $r=C_p/C$ 为 1/4 时, 由于占用内存成平方关系, FLOPs 仅为普通卷积的 1/16。内存访问量(Memory Access Count, MAC)仅为普通卷积的 1/4, 实现计算资源的高效利用。

$$V_{FLOPs} = h \times w \times k^2 \times C_p^2 \quad (1)$$

$$V_{MAC} = h \times w \times 2C_p + k^2 \times C_p^2 \approx h \times w \times 2C_p \quad (2)$$

相较于传统卷积 Conv 操作, RepPConv 采用通道选择性部分卷积, 仅对低重复性卷积通道执行卷积运算, 通过抑制冗余信息的干扰, 在提升计算效率的同时实现精度的同步优化。

SimConv 将 YOLOv8 中的 SiLU 激活函数变为 ReLU, 有效地减少推理时的浮点运算量, 提高了运算速度。同时相较于 SiLU, 可能导致数值分布偏移和内存碎片化, ReLU 的非负输出更利于内存连续分配。

ReLU 结构如图 7 所示。

ReLU 是一种常用的激活函数, 它仅需通过比较和取最大值的简单计算即可完成运算, 只需完成一次运算, 而 SiLU 激活函数需要先经过 Sigmoid 计算后再与原函数相乘, 需要 5 次浮点数运

算,因此 ReLU 比 SiLU 激活函数效率更高。ReLU 激活函数和 SiLU 激活函数的公式如下:

$$f(x) = \max(0, x) \quad (3)$$

$$f_{\text{SiLU}}(x) = x \cdot \text{Sigmoid}(x) \quad (4)$$

更重要地,ReLU 的非负输出特性优化了内存访问模式。现代 GPU 的内存带宽利用率与数据连续性强相关,SiLU 的输出值为 $(-0.278, \infty)$,导致内存分布分散;而 ReLU 输出非负,内存布局更紧凑,有效地提高了运算速率。




图 7 ReLU 示意图

1.5 Wise-CIoU 损失函数

YOLOv8 使用 Ciou 作为边界框回归损失函数,公式如式(5)~(7)所示:

$$V_{\text{Ciou}} = V_{\text{IoU}} - \frac{p^2(b, b^{\text{gt}})}{c^2} - \alpha v \quad (5)$$

$$v = \frac{4}{\pi^2} \left(\arctan \frac{w^{\text{gt}}}{h^{\text{gt}}} - \arctan \frac{w}{h} \right)^2 \quad (6)$$

$$\alpha = \frac{v}{(1 - V_{\text{IoU}}) + v} \quad (7)$$

其中: V_{IoU} 表示预测物体框与真实物体框的交并比; p 表示预测框与真实框的中心点距离的归一化值; b, b^{gt} 表示预测物体检测框的位置和真实物体检测框的位置; c 表示预测框与真实框的最小外接矩形的对角线长度; α 用于平衡距离项和形状项的权重, v 用于对比目标框的宽高比的相似性; w, h 和 $w^{\text{gt}}, h^{\text{gt}}$ 分别是预测目标框和真实目标框的宽高。

Ciou 通过引入宽高比差异系数构建几何约束,但它的约束机制与目标尺度变化及检测置信度之间具有非单调关系,导致面对不均样本时难以准确标注少样本目标的边框。为此,参考 WIoU (Wise-Intersection over Union) 改进 Ciou,引入基于样本频率的加权融合策略,提升对小目标和不平衡样本的检测性能。

Wise-CIoU 的公式如下:

$$V_{\text{Wise-CIoU}} = r \times V_{\text{Ciou}} \quad (8)$$

$$r = \frac{V_{\beta}}{\delta \alpha^{\beta-\delta}} \quad (9)$$

$$V_{\beta} = (L_{\text{IoU}}^* / \overline{L_{\text{IoU}}})^{\gamma} \quad (10)$$

其中: r 为非单调剧增系数; V_{β} 为离群度,当 V_{β} 较小时表示锚框是高质量的,算法会为它分配较小的梯度增益,以使算法更关注普通质量的锚框, V_{β} 较大时表示锚框是低质量的,算法会为它分配较大的梯度增益,以减少低质量锚框的负面影响; $\overline{L_{\text{IoU}}}$ 表示动态分配运行平均值; L_{IoU}^* 为交并比 (Intersection over Union, IoU) 的值; γ, δ 是 2 个用于调节权重的超参数; V_{Ciou} 为原始 Ciou 损失函数。

Wise-CIoU 如图 8 所示。其中: C 表示预测框和真实框对角线距离; b_g 和 b_{gt} 表示预测框和真实框的中心点; $\rho^2(b_g, b_{gt})$ 表示中心点距离; H_g, H_{gt} 表示预测框和真实框的高度; W_g, W_{gt} 表示预测框和真实框的宽度。

相较于 Ciou, Wise-CIoU 利用深度学习算法自适应调整学习权重和引入高级几何变换构建空间关系,在复杂场景下能够精准判别信号灯类别。对比实验结果如表 2 所示。

由表 2 可知,在引入基于样本频率的加权融合策略后,相较于 WIoUv1, Wise-CIoU 的 Precision、Recall、mAP@0.5 和

mAP@0.5:0.95 分别提升了 2.3、3.2、1.5 和 0.1 个百分点;相较于 WIoUv2, Precision 降低了 0.2 个百分点, Recall 提升了 2.6 个百分点, mAP@0.5 提升了 1.2 个百分点, mAP@0.5:0.95 降低了 0.2 个百分点;相较于 WIoUv3, Precision 降低了 0.8 个百分点, Recall 提升了 2.9 个百分点, mAP@0.5 提升了 0.4 个百分点, mAP@0.5:0.95 降低了 0.8 个百分点,综合性能 Wise-CIoU 最优。




图 8 Wise-CIoU 示意图

表 2 不同 WIoU 性能对比

单位: %

损失函数	Precision	Recall	mAP@0.5	mAP@0.5:0.95
WIoUv1	90.8	88.7	92.5	61.0
WIoUv2	93.3	89.3	92.8	61.3
WIoUv3	93.9	89.0	93.6	61.9
Wise-CIoU	93.1	91.9	94.0	61.1

2 实验与结果分析

2.1 数据集

本实验采用 S2TLD 交通信号灯数据集,包含 5786 幅图像,分辨率主要为 1080 像素×1920 像素和 720 像素×1280 像素。数据集涵盖 5 类信号灯状态,分别为红灯(red)、黄灯(yellow)、绿灯(green)、熄灭(off)和等待(wait on),共计 14130 个实例。覆盖多样化的道路场景与天气条件。本实验按 6:2:2 划分训练集、测试集和验证集。

2.2 评价指标

本次实验采用 4 个评价指标: mAP、Recall、Precision、mAP@0.5:0.95。

1) mAP 与 mAP@0.5:0.95。mAP 用于评估算法在所有类别上的平均精度,综合反映算法的分类和定位准确率。mAP 的计算公式如式(11)~(12)所示:

$$V_{\text{AP}} = \int_0^1 V_{\text{P}} dV_{\text{R}} \quad (11)$$

$$V_{\text{mAP}} = \frac{1}{N} \sum_{n=1}^N V_{\text{AP}} \quad (12)$$

其中: $V_{\text{P}}, V_{\text{R}}$ 分别是召回率和准确率; mAP@0.5:0.95 指阈值为 50% 和 95% 时的 mAP; N 为样本总参数量。

2) Recall 和 Precision。Recall 反映正样本的覆盖能力,定义为所有真正样本被正确预测的比例, Precision 指预测为正样本中真实为正样本的比例。Recall 和 Precision 的计算公式如式(13)~(14)所示:

$$V_{\text{R}} = TP / (TP + FN) \quad (13)$$

$$V_{\text{P}} = TP / (TP + FP) \quad (14)$$

其中: TP 指实际为正样本且被预测为正样本的实例数; FN 指实际为正样本但被预测为负样本的实例数; FP 指实际为负样本但被预测为正样本的实例数。

2.3 实验环境

实验的软件环境为: 操作系统 Windows 11, Python3.9, PyTorch 2.3.0, CUDA 12.1.66; 硬件环境为: GPU 4070ti super, CPU 为 12th Gen Intel Core i5-12600KF。实验参数设置: 优化器使用随机梯度下降 SGD, 学习率为 10^{-2} , 最终学习率设置为 10^{-4} , 权重衰减为 5×10^{-4} , 动量设置为 0.937, batch size 的大小为 16, 每次训练的 epoch 为 200, workers 设置为默认值 8。

2.4 实验结果

2.4.1 消融实验

为验证算法的有效性,在S2TLD数据集上进行消融实验,以YOLOv8为基准,探究每一个模块添加产生的影响。表3展示了消融实验结果,其中A1代表数据迁移,A2代表DWFPN,A3代表MFE,A4代表Wise-CIoU。

表3 消融实验结果

单位:%

模块				Precision	Recall	mAP@0.5	mAP@0.5:0.95
A1	A2	A3	A4				
				92.7	86.7	91.2	57.9
√				93.0	88.2	92.2	59.8
√	√			92.5	89.7	93.0	61.9
√		√		92.6	91.1	93.5	61.4
√			√	93.1	91.9	94.0	61.1
√	√	√	√	95.0	91.1	94.7	62.7

从表3中可见:1)迁移学习方法在不增加参数量的情况下有效地提高了Precision、Recall、mAP@0.5和mAP@0.5:0.95;2)添加DWFPN后,虽然Precision下降了0.5个百分点,但是Recall和mAP分别提升了1.5和0.8个百分点;3)结合迁移学习和MFE模块后,Recall、mAP@0.5和mAP@0.5:0.95分别提升了4.4、2.3和3.5个百分点,Precision下降了0.1个百分点;4)在迁移学习基础上采用Wise-CIoU时,Precision、Recall、mAP@0.5和mAP@0.5:0.95分别提升了0.1、3.7、1.8和1.3个百分点;5)将4个改进点分别替换,Precision、Recall、mAP@0.5和mAP@0.5:0.95相较于基准YOLOv8分别提高了2.3、4.4、3.5和

4.8个百分点。

模块的参数量(Params)以及计算量如表4所示。

由表4可知,DMW-YOLO相较于原始YOLOv8的Params仅提升了 0.34×10^6 ,计算量在仅提升了0.2 GFLOPs的基础上性能得到大幅度提高,FPS相较于原始算法提升了77.1,在保证高精度的同时满足实时检测的要求。

表4 模块参数计算量

算法	Params/ 10^6	计算量/GFLOPs	FPS
YOLOv8	3.01	8.2	220.0
数据迁移	3.01	8.2	215.3
DWFPN	2.87	8.0	240.0
MFE	3.49	8.6	263.9
Wise-CIoU	3.01	8.2	223.4
DMW-YOLO	3.35	8.4	297.1

为验证模块有效性,本文从数据和结构这2个维度展示实验效果,图9为各模块实验效果热力图对比。图9(a)为数据维度的迁移学习效果对比。对比可见,YOLOv8对边缘模糊物体的识别存在明显误差,而经过数据迁移后能完全解决此类模糊目标的识别难题。从图9(b)可见,YOLOv8在存在遮挡现象时表现不佳,而添加DWFPN模块后可以有效地识别出被遮挡的信号灯。图9(c)结果显示,YOLOv8对于小型黑色信号灯的检测性能不佳,在引入MFE模块后,算法对于小型黑色信号灯的检测精度得到提升。图9(d)显示YOLOv8在光照条件过强的情况下对于箭头型信号灯识别不佳,而引入Wise-CIoU后得到显著改善。




图9 各模块实验效果热力图对比

2.4.2 对比实验

为了验证算法及各模块的优越性,对DWFPN、MFE、Wise-CIoU以及整体算法设计了对比实验。

1)DWFPN模块验证。

以YOLOv8为baseline,为了消除数据层面的干扰,只单纯地对算法效果进行评判,先对模型进行迁移学习消融实验,随后在迁移学习基础上仅替换FPN模块。选取YOLOv8中的路径聚合网络(Path Aggregation Network, PANet)、BiFPN、广义特征金字塔网络(Generalized Feature Pyramid Network, GFPN)^[27]、渐进特征金字塔网络(Asymptotic Feature Pyramid Network, AFPN)^[28]和FPN的weight、adaptive、concat的3种连接方式^[29]作对比,结果如表5所示。

根据表5数据,DWFPN的mAP@0.5:0.95和Recall在对比的所有FPN模块中最高,且mAP@0.5、Precision和最高的FPN(concat)只相差0.5个和0.3个百分点。在对比实验中BDFPN与FPN(concat)相较来说性能最佳,但是与FPN(concat)相比,BDFPN具有参数量更小和速度更快的优势,因此综合对比采用DWFPN作为FPN模块的替代。

2)MFE模块对比实验。

为验证MFE模块的优越性,实验采取YOLOv8n为baseline,通过数据迁移消除数据干扰,对不同SPPF特征提取部分进行替换,选择综合性能最高的模块,本次选取YOLOv8中的SPPF、

ASPP(Atrous Spatial Pyramid Pooling)^[30]、SPPCSPC、SPPFCSPC作对比,实验结果如表6所示。

表5 FPN模块对比实验结果

单位:%

FPN	Precision	Recall	mAP@0.5	mAP@0.5:0.95
PANet	93.0	88.2	92.2	59.8
BiFPN	91.9	89.0	92.0	60.5
GFPN	93.0	89.3	92.0	60.7
AFPN	93.7	88.4	91.8	59.3
FPN(weight)	92.2	89.1	92.7	60.7
FPN(adaptive)	93.4	89.1	93.2	60.9
FPN(concat)	93.8	89.2	93.5	61.1
DWFPN	92.5	89.7	93.0	61.9

表6 SPPF模块对比实验结果

单位:%

特征提取模块	Precision	Recall	mAP@0.5	mAP@0.5:0.95
SPPF	93.0	88.2	92.2	59.8
ASPP	93.4	89.5	93.2	60.1
SPPCSPC	92.2	87.9	92.4	61.5
SPPFCSPC	93.7	89.6	92.8	61.3
MFE	92.6	91.1	93.5	61.4

从表 6 中可以看出, MFE 的 $mAP@0.5$ 和 Recall 是所有模块中最高的, 即使 $mAP@0.5:0.95$ 与 SPPCSPC 相比降低了 0.1 个百分点, Precision 相较于 SPPCSPC 降低了 1.1 个百分点, 但是 MFE 与其他模块相比综合性能最优秀, 因此综合判断本次实验采用 MFE 模块。

3) Wise-CIoU 模块对比实验。

为了证明损失函数 Wise-CIoU 的优越性, 以 YOLOv8 为 baseline, 以数据迁移排除数据层面干扰的方式替换损失函数部分。选取 Ciou、GIoU (Generalized-Intersection over Union)^[31]、DIoU (Distance-Intersection over Union)^[32]、EIoU (Efficient-Intersection over Union)^[33]、SIoU (Soft-Intersection over Union)^[34]、MPDIoU (Minimum Point Distance-Intersection over Union)^[35]、NMD (Normalized Wasserstein Distance)^[36]、WIoUv1、WIoUv2 和 WIoUv3 作对比, 实验结果如表 7 所示。

表 7 损失函数对比实验结果

单位: %

损失函数	Precision	Recall	$mAP@0.5$	$mAP@0.5:0.95$
Ciou	93.0	88.2	92.2	59.8
GIoU	92.7	85.5	91.1	59.5
DIoU	91.9	90.0	92.8	60.4
EIoU	89.7	88.1	91.3	60.4
SIoU	94.0	89.8	93.2	61.1
MPDIoU	94.1	89.5	93.0	60.9
NMD	93.9	90.2	93.6	60.2
WIoUv1	90.8	88.7	92.5	61.0
WIoUv2	93.3	89.3	92.8	61.3
WIoUv3	93.9	89.0	93.6	61.9
Wise-Ciou	93.1	91.9	94.0	61.1

从表 7 中可见: Wise-CIoU 的 Recall、 $mAP@0.5$ 是所有损失函数中最高的; Precision 相较于最高的损失函数 MPDIoU 相差了 1.0 个百分点, 但是 Recall、 $mAP@0.5$ 和 $mAP@0.5:0.95$ 都远高于 MPDIoU; $mAP@0.5:0.95$ 相较于最高的损失函数 WIoUv3 仅相差了 0.8 个百分点。综合对比 Wise-CIoU 性能最为优秀, 因此选择 Wise-CIoU 作为损失函数。

4) 综合对比实验。

为了证明本文算法的优越性, 将改进后的算法与 ATSS (Adaptive Training Sample Selection)^[37]、Faster R-CNN、Grid

R-CNN (Grid Region-Convolutional Neural Network)^[38]、SSD 等算法进行综合对比, 结果如表 8 所示。

从表 8 中可见, DMW-YOLO 相较于其他算法在 Precision、Recall、 $mAP@0.5$ 和 $mAP@0.5:0.95$ 都取得了最好的结果, 综合对比所有评价指标, DMW-YOLO 具有最优越的性能。

表 8 各算法对比实验结果

单位: %

算法	Precision	Recall	$mAP@0.5$	$mAP@0.5:0.95$
ATSS	87.1	76.2	84.1	55.5
Faster R-CNN	92.7	85.5	91.1	59.5
Grid R-CNN	91.9	90.0	92.8	60.4
SSD	89.7	88.1	91.3	60.4
YOLOv6n	92.6	86.7	90.9	57.1
YOLOv7-T	91.7	82.8	88.9	50.0
YOLO9-T	92.2	89.0	92.8	60.4
YOLOv10n	91.0	88.5	92.6	61.5
YOLO11n	92.2	89.5	92.4	60.8
YOLO12n	92.2	89.6	92.6	59.6
YOLOv13n	92.2	87.9	92.7	60.0
DMW-YOLO	95.0	91.1	94.7	62.7

2.4.3 可视化结果验证

为验证实际应用场景的泛化能力, 在 S2TLD 数据集上对比了本文算法与 YOLOv8 的可视化结果。

图 10 为 YOLOv8 和 DMW-YOLO 的热力图对比。从图 10(a) 可见, YOLOv8 在信号灯遮挡不全的时候并不能准确识别, DMW-YOLO 有效地解决了这个问题。从图 10(b) 中可见, 在面对黑天等光照条件不足的情况下, YOLOv8 在对信号灯进行检测时存在重检现象, DMW-YOLO 则可以准确地光线昏暗的情况下识别信号灯。从图 10(c) 中可见, YOLOv8 并不能准确区分出复杂环境中干扰光源与信号灯光源, DMW-YOLO 则可以准确区分信号灯与干扰光源。从图 10(d) 中可见, YOLOv8 对小目标信号灯并不能够进行准确识别, DMW-YOLO 有效地解决了这个问题。从图 10(e) 中可见, 在面对多种信号灯光源的情况下, YOLOv8 对于边缘信号灯信息和小目标信号灯信息存在漏检, 而 DMW-YOLO 可以准确地检测所有的信号灯。

图 11 是在多种光源干扰场景下 DMW-YOLO 与 YOLOv8 的检测对比结果。




图 10 2 个算法的热力图对比




图 11 多种光源干扰场景检测

从图 11(a)可见,在雨雪等恶劣天气条件下,YOLOv8对微小目标的识别能力存在不足,而DMW-YOLO则能有效地提升检测性能。从图 11(b)可见,在夜间等复杂光照场景下,YOLOv8会出现单信号灯重复检测的情况,而DMW-YOLO则有效地规避了此类问题。从图 11(c)可见,在复杂多光源干扰场景下,YOLOv8存在信号灯漏检问题,而DMW-YOLO不仅有效降低漏检率,还展现出更强的环境鲁棒性与场景适应能力。

3 结语

针对复杂场景下信号灯颜色相近、模糊不清导致的漏检等问题,本文提出了DMW-YOLO算法,在保证实时性的同时显著提升信号灯检测精度。本文运用数据迁移的方式在不增加计算量的前提下提升精度,提出DWFPN替代PANet实现高维度信号灯颜色特征融合,抑制相近光源干扰;运用MFE代替SPPF通过增大感受野提高小目标的检测能力;最后使用Wise-CIoU代替Ciou提高少样本检测精度。对比实验结果验证了该算法的有效性。

参考文献 (References)

- [1] 谷明琴,蔡自兴,李仪. 应用圆形成和颜色直方图的交通信号灯识别[J]. 计算机工程与设计, 2012, 33(1): 243-247.
- [2] 曾杨帆,陈章勇,夏甫根,等. 基于先验信息的交通信号灯识别方法[J]. 汽车实用技术, 2022, 47(21): 37-42.
- [3] 李慧森,方振国. 雾霾天气下交通信号灯的识别[J]. 科技创新与应用, 2024, 14(19): 35-38, 42.
- [4] LIN H Y, TSAI M Y. Traffic light detection for nighttime driving with log-polar transform incorporated learning [J]. Results in Engineering, 2025, 25: No. 103783.
- [5] GIRSHICK R, DONAHUE J, DARRELL T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation [C]// Proceedings of the 2014 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2014: 580-587.
- [6] REN S, HE K, GIRSHICK R, et al. Faster R-CNN: towards real-time object detection with region proposal networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(6): 1137-1149.
- [7] HE K, ZHANG X, REN S, et al. Spatial pyramid pooling in deep convolutional networks for visual recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 37(9): 1904-1916.
- [8] QIAO S, CHEN L C, YUILLE A. DetectoRS: detecting objects with recursive feature pyramid and switchable atrous convolution [C]// Proceedings of the 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2021: 10208-10219.
- [9] DAI F, LI Y, HE K M, et al. R-FCN: object detection via region-based fully convolutional networks [C]// Proceedings of the 30th International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2016: 379-387.
- [10] 李靖博. 基于Faster R-CNN模型的交通信号灯检测识别研究[J]. 山西交通科技, 2024(3): 115-118.
- [11] 李在润. 基于卷积神经网络的交通信号灯检测和识别[D]. 成都: 四川大学, 2021: 28-31.
- [12] REDOM J, FARHADI A. YOLOv3: an incremental improvement [EB/OL]. [2024-07-18]. <https://arxiv.org/pdf/1804.02767>.
- [13] GEETHA A S. YOLOv4: a breakthrough in real-time object detection [EB/OL]. [2025-07-28]. <https://arxiv.org/pdf/2502.04161>.
- [14] WANG C Y, YEH I H, MARK LIAO H Y. YOLOv9: learning what you want to learn using programmable gradient information [C]// Proceedings of the 2024 European Conference on Computer Vision, LNCS 15089. Cham: Springer, 2025: 1-21.
- [15] LEI M, LI S, WU Y, et al. YOLOv13: real-time object detection with hypergraph-enhanced adaptive visual perception [EB/OL]. [2025-07-18]. <https://arxiv.org/pdf/2506.17733>.
- [16] WANG C Y, BOCHKOVSKIY A, LIAO H-Y M. YOLOv7: trainable bag-of-freebies sets new state-of-the-art for real-time object detectors [C]// Proceedings of the 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2023: 7464-7475.
- [17] LIU W, ANGUELOV D, ERHAN D, et al. SSD: single shot MultiBox detector [C]// Proceedings of the 2016 European Conference on Computer Vision, LNCS 9905. Cham: Springer, 2016: 21-37.
- [18] FU C Y, LIU W, RANGA A, et al. DSSD: deconvolutional single shot detector [EB/OL]. [2024-08-01]. <https://arxiv.org/pdf/1701.06659>.
- [19] LI Z, YANG L, ZHOU F. FSSD: feature fusion single shot multibox detector [EB/OL]. [2024-08-01]. <https://arxiv.org/pdf/1712.00960>.
- [20] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection [C]// Proceedings of the 2017 IEEE International Conference on Computer Vision. Piscataway: IEEE, 2017: 2999-3007.
- [21] TAN M, PANG R, LE Q V. EfficientDet: scalable and efficient object detection [C]// Proceedings of the 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2020: 10778-10787.
- [22] 余杨,何刘. 基于YOLOv8和SVDD重识别的交通信号灯检测方法[J]. 汽车实用技术, 2024, 49(23): 49-54.
- [23] 罗庆龄. 融合极化自注意力机制的交通信号灯检测算法[J]. 长江信息通信, 2024, 37(6): 40-43.
- [24] YAO Z, LIU Q, FU J, et al. A coarse-to-fine deep learning based framework for traffic light recognition [J]. IEEE Transactions on Intelligent Transportation Systems, 2024, 25(10): 13887-13899.
- [25] HUANG Y, WANG F. D-TLDDetector: advancing traffic light detection with a lightweight deep learning model [J]. IEEE Transactions on Intelligent Transportation Systems, 2025, 26(3): 3917-3933.
- [26] TANG C, LI Y, WANG L, et al. Real-time traffic light detection based on lightweight improved RT-DETR [J]. Journal of Real-Time Image Processing, 2025, 22(2): No. 82.
- [27] JIANG Y, TAN Z, WANG J, et al. GiraffeDet: a heavy-neck paradigm for object detection [EB/OL]. [2025-08-21]. <https://arxiv.org/pdf/2202.04256>.
- [28] YANG G, LEI J, ZHU Z K, et al. AFPN: asymptotic feature pyramid network for object detection [C]// Proceedings of the 2023 IEEE International Conference on Systems, Man, and Cybernetics. Piscataway: IEEE, 2023: 2184-2189.
- [29] XIAO J, ZHAO T, YAO Y, et al. Context augmentation and feature refinement network for tiny object detection [EB/OL]. [2025-08-21]. <https://openreview.net/pdf?id=q2ZaVU6bEsT>.
- [30] CHEN L C, PAPANDREOU G, SCHROFF F, et al. Rethinking atrous convolution for semantic image segmentation [EB/OL]. [2025-08-21]. <https://arxiv.org/pdf/1706.05587>.
- [31] REZATOFIGHI H, TSOI N, GWAK J, et al. Generalized intersection over union: a metric and a loss for bounding box regression [C]// Proceedings of the 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2019: 658-666.
- [32] ZHENG Z, WANG P, LIU W, et al. Distance-IoU loss: faster and better learning for bounding box regression [C]// Proceedings of the 34th AAAI Conference on Artificial Intelligence. Palo Alto: AAAI Press, 2020: 12993-13000.
- [33] ZHANG Y F, REN W, ZHANG Z, et al. Focal and efficient IoU loss for accurate bounding box regression [J]. Neurocomputing, 2022, 508: 146-157.
- [34] GEVORGYAN Z. Siou loss: more powerful learning for bounding box regression [EB/OL]. [2025-08-21]. <https://arxiv.org/pdf/2205.12740>.
- [35] MA S L, XU Y. MPDIoU: a loss for efficient and accurate bounding box regression [EB/OL]. [2025-08-12]. <https://arxiv.org/pdf/2307.07662>.
- [36] WANG J, XU C, YANG W, et al. A normalized Gaussian Wasserstein distance for tiny object detection [EB/OL]. [2025-08-21]. <https://arxiv.org/pdf/2110.13389>.
- [37] ZHANG S, CHI C, YAO Y, et al. Bridging the gap between anchor-based and anchor-free detection via adaptive training sample selection [C]// Proceedings of the 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2020: 9756-9765.
- [38] LU X, LI B, YUE Y, et al. Grid R-CNN [C]// Proceedings of the 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2019: 7355-7364.