



计算机工程与应用
Computer Engineering and Applications
ISSN 1002-8331, CN 11-2127/TP

《计算机工程与应用》网络首发论文

题目： 基于改进 YOLOv11n 的变电站设备目标检测算法
作者： 程焕，马帅旗，刘英博
网络首发日期： 2026-08-19
引用格式： 程焕，马帅旗，刘英博. 基于改进 YOLOv11n 的变电站设备目标检测算法
[J/OL]. 计算机工程与应用.
<https://link.cnki.net/urlid/11.2127.tp.20260818.1336.007>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于改进 YOLOv11n 的变电站设备目标检测算法

程焕, 马帅旗⁺, 刘英博

陕西理工大学, 电气工程学院, 陕西 汉中 723000

⁺ 通信作者 E-mail: msq0912@163.com

摘要: 针对变电站复杂环境下设备目标检测存在的背景干扰强、多尺度特征分布不均、小目标易漏检以及类别混淆导致误检等问题, 提出一种基于改进 YOLOv11n 的变电站设备目标检测算法。首先, 设计部分通道多感受野融合模块 (Partial-Channel Multi-Receptive Field Fusion, PC-MRF) 替换 C3k2, 通过部分卷积对多尺度特征渐进融合, 增强多尺度特征表达能力, 同时缓解类别混淆; 其次, 构建边界定位质量感知检测头 (Boundary Localization Quality Perceptron-Head, BLQP-Head), 利用边界框定位质量信息优化候选框置信度, 提高复杂背景下目标框筛选的可靠性; 然后, 在 C2PSA 结构中引入动态双曲正切模块 (Dynamic Tanh, DyT), 通过非线性特征调制聚焦有效目标、抑制背景干扰; 最后, 构建特征金字塔共享卷积模块 (Feature Pyramid Shared Convolution, FPSC) 替换 SPPF, 优化高低层特征融合效果, 改善多尺度目标的检测性能。实验结果表明, 改进模型的 mAP50 和 mAP50-95 较 YOLOv11n 分别提升 2.77% 和 2.63%, 验证了所提方法在变电站设备目标检测任务中的有效性。

关键词: 变电站; 深度学习; YOLOv11; 小目标检测

文献标志码:A 中图分类号:TP391.41 doi: 10.3778/j.issn.1002-8331.2604-0449

Substation Equipment Detection Algorithm Based on Improved YOLOv11n

CHENG Huan, MA Shuaiqi⁺, LIU Yingbo

Shaanxi University of Technology, School of Electrical Engineering, Hanzhong 723000, China

Abstract: A substation equipment object detection algorithm based on improved YOLOv11n is proposed to address issues such as strong background interference, uneven multi-scale feature distribution, missed detection of small objects, and misclassification caused by high inter-class similarity in complex substation environments. First, a Partial-Channel Multi-Receptive Field Fusion module (PC-MRF) is designed to replace C3k2, which progressively fuses multi-scale features through partial convolution to enhance multi-scale feature representation and alleviate category confusion. Second, a Boundary Localization Quality Perceptron-Head (BLQP-Head) is constructed to optimize candidate box confidence using bounding box localization quality information, thereby improving the reliability of object box selection under complex backgrounds. Third, a Dynamic Tanh module (DyT) is introduced into the C2PSA structure to focus on effective targets and suppress background interference through nonlinear feature modulation. Finally, a Feature Pyramid Shared Convolution module (FPSC) is built to replace SPPF, optimizing cross-layer feature fusion and improving multi-scale object detection performance. Experimental results show that the improved model achieves a 2.77 percentage point increase in mAP50 and a 2.63 percentage point increase in mAP50-95 over YOLOv11n, demonstrating the effectiveness of the proposed method for substation equipment object detection tasks.

基金项目: 陕西省自然科学基金项目 (2023-JC-YB-442); 陕西理工大学研究生创新基金项目 (SLGYCX2670)。

作者简介: 程焕(2000—), 男, 硕士研究生, CCF 学生会员, 研究方向为机器视觉; 马帅旗(1977—), 男, 硕士, 副教授, 研究方向为机器视觉、现代电力电子技术; 刘英博(2000—), 男, 硕士研究生, 研究方向为机器视觉。

Key words: substation; deep learning; YOLOv11; small object detection

变电站作为电力系统的关键枢纽,其设备运行状态直接关系到整个供电网络的安全性与可靠性^[1]。据统计,热故障在变电站设备故障中占比超过 30%,且常引发设备损坏、停电甚至火灾等严重后果^[2]。当前变电站巡检仍主要依赖于人工巡检,存在诸如检测效率低、成本高、结果主观性强、难以保障人身安全等不足。

随着计算机技术的迅速发展,目标检测算法应运而生,它凭借检测效率高、非接触式误差小等优势,逐步成为工业领域新兴的重要手段,并被广泛应用于工业场景中。目标检测算法的核心在于从图像或视频数据中精准识别并定位预设类别的目标对象,其可依据检测原理大致分类为传统目标检测算法和基于深度学习的目标检测算法。方向梯度直方图 (Histogram of Oriented Gradient, HOG)^[3]、尺度不变特征变换 (Scale Invariant Feature Transform, SIFT)^[4]等传统的算法过于依赖手动设计特征,预测框生成效率低、耗时长,逐步被性能更优的深度学习算法替代。

基于深度学习的目标检测算法依据是否存在候选框生成环节,分为两阶段算法与单阶段算法两大类。对于 R-CNN^[5]、Fast R-CNN^[6]、Faster R-CNN^[7]等两阶

段算法,He 等^[8]通过引入多尺度特征图,应用 Faster R-CNN 进行多尺度特征检测,展示了该算法的良好检测性能。此类算法虽然在精度上具备优势,但两阶段的运算框架使其运算速度受制。相比之下,SSD^[9]、YOLO^[10]系列等单阶段算法省去候选框提取步骤,将分类与预测框回归任务融入同一网络同步执行,实现了运算速度的大幅提升。在变电站设备检测场景中,YOLO 系列算法因其兼顾精度与速度要求,在工程领域得到了广泛应用。

近年来,YOLO 系列算法在电力巡检领域取得了显著进展。王磊等^[11]针对无人机电力巡检中关键部件检测精度不足的问题,提出改进 YOLOv5s 算法,通过引入 CBAM 注意力机制、BiFPN 特征融合结构及改进 SPP 模块,增强多尺度特征表达能力并提升复杂背景下的检测性能。为解决绝缘子尺寸差异大、背景干扰严重导致漏检率高的问题,张剑锐等^[12]基于 YOLOv7,融合 CBAM 注意力机制与 CFP 金字塔结构,并结合 k-means 优化先验框,有效降低漏检率并提高检测精度。面对多尺度变化不一、小目标特征易丢失的问题,Xu 等^[13]提出 IPE-YOLO 算法,通过 CSP_MSEIE 模块和 CGRFPN 结构增强多尺度特征提

取与融合,并采用 LSCD 检测头减少参数量,有效平衡了检测精度与速度。在更复杂的输电线路缺陷检测场景中,刘方轩等^[14]针对多尺度变化显著、目标遮挡严重等问题,提出改进 YOLOv11n 算法,通过设计 MANet-FC 模块实现多尺度语义融合,引入 GOLD-YOLO-ASF 结构强化跨层特征交互,并结合多目标注意力检测头与改进损失函数提升模型在小目标及遮挡场景下的检测能力。孙铁强等^[15]针对绝缘子缺陷检测中背景干扰和小目标漏检问题,基于 YOLOv8n 提出改进算法,引入 C2f-RE 模块与 FDPN 结构,结合 LSDECD 和 Inner-WIoU 分别提升多尺度捕获能力和小目标检测性能,提升了模型在面对复杂天气干扰时的鲁棒性。综上所述,现有研究虽然在电力设备目标检测领域取得了显著进展,但在实际应用场景中仍存在诸多问题。首先,设备常处于金属构件、密集线缆与光照变化交织的复杂背景中,易受干扰;其次,设备尺寸跨度大,导致多尺度特征分布不均,检测性能失衡;此外,小型部件像素占比低,深层特征提取过程中信息易衰减,漏检率较高;最后,电力设备类型多且外观相似性高,易引发类别混淆,增加误判与漏判风险。针对上述问题,本文提出了一种基于改进 YOLOv11n 的变电站设备目标检测算法,主要贡献如

下:

(1) 设计了 PC-MRF 模块替代骨干网络和颈部网络中的 C3k2 模块,通过对输入特征进行部分卷积,增强了模型对不同尺度设备结构特征的表达能力,缓解了变电站设备尺度差异大、局部细节易丢失和类别混淆的问题。

(2) 构建了适用于 YOLOv11n 的 BLQP-Head 检测头,通过优化检测框排序和非极大值抑制(Non-Maximum Suppression, NMS)阶段的候选框保留策略,从而缓解小目标高质量预测框因分类置信度偏低而被错误抑制的问题。

(3) 在 C2PSA 结构中引入 DyT,构建了 C2PSA-DyT 特征调制结构,通过动态激活调制增强目标区域响应、抑制背景干扰,从而提升复杂场景下的特征选择能力和检测稳定性。

(4) 构建了 FPSC 替代原 SPPF 结构,通过采用多膨胀率卷积分支模拟不同尺度感受野,使模型在扩大感受野的同时尽可能保留小目标和细粒度结构信息,从而改善变电站设备跨尺度检测的均衡性。

(5) 搭建了以智能车作为移动载体的双光相机图像采集装置,用于初步验证算法在边缘设备上的部署可行性。

1 改进后的 YOLOv11n 算法

1.1 改进后的 YOLOv11n 算法结构

在变电站设备目标检测场景中,存在背景干扰强、目标尺度差异显著、小目标易漏检、类别混淆易误检等问题,这对检测模型的特征表征能力、场景适应性均提出了较高要求。YOLOv11n^[16]在检测精度与推理

效率之间实现了良好平衡,其模块化的网络结构为针对性改进提供了便利,适合变电站巡检场景的实际应用需求。因此,本文选取 YOLOv11n 作为基础算法框架,提出一种面向变电站设备目标检测的改进模型,结构如图 1 所示。




图 1 改进前后的 YOLOv11n 算法结构

Fig.1 Structure of original and improved YOLOv11n algorithms

1.2 PC-MRF 模块

在变电站设备目标检测场景中,电力设备普遍具有形态多样、尺度差异显著等特点。YOLOv11 中的 C3k2 模块虽然通过深度可分离卷积降低了计算复杂度,但其固定的 3×3 卷积核限制了感受野范围,难以适应变电站场景下设备尺寸差异大的特性,无法同步有效捕获小型绝缘子的局部细节特征与大型变压器的全局结构信息,进而引发多尺度检测性能失衡问题^[17]。针对此问题,本文设计了 PC-MRF 模块,模块结构如图 2 所示,该模块在思路上汲取了 GhostNet^[18]的轻量

化思想与 FasterNet^[19]的特征重用思想,并结合变电站巡检场景下目标尺度差异显著、细节特征易丢失的问题进行了针对性优化。在通道维度上对输入特征进行部分卷积 (Partial Convolution, PConv) 操作,仅对一半通道进行特征变换,通过渐进式的卷积聚合构建多感受野卷积组合,其余通道通过旁路分支直接保留,以实现多尺度语义与细节信息的互补融合,原理如图 3 所示。

首先,对输入特征 $\mathbf{X} \in \mathbb{R}^{C \times H \times W}$ 分为两路操作,一路通过残差连接得到 $\mathbf{X}_r \in \mathbb{R}^{C \times H \times W}$ 以待后续使用,另一

路通过 3×3 进行初步特征提取, 然后沿通道均分为两路, 一路进入 5×5 卷积 (分组数为通道数的一半) 进一步提取中尺度特征, 另一路保留。接着, 将 5×5 卷积输出再次通道均分, 一路送入 7×7 卷积 (分组数为通道数的四分之一), 另一半继续保留。小卷积核提取局部细节, 大卷积核捕获上下文全局语义, 通道分割机制消除传统多分支结构的计算冗余, 以此完成多尺度特征渐进聚合, 过程可表示为:

$$[X_p, X_o] = \text{Split}(\text{Conv}_{3 \times 3}(X)) \quad (1)$$

$$[X_{p1}, X_{o1}] = \text{Split}(\text{Conv}_{5 \times 5}(X_p)) \quad (2)$$

$$X_{p2} = \text{Conv}_{7 \times 7}(X_{p1}) \quad (3)$$

式中: $X_p \in \mathbb{R}^{\frac{C}{2} \times H \times W}$ 表示输入特征经过 3×3 卷积特征提取和沿通道切分后继续参与部分卷积的中间特征; $X_o \in \mathbb{R}^{\frac{C}{2} \times H \times W}$ 表示经过 3×3 卷积特征提取和沿通道切分后保留的特征; $\text{Split}(\cdot)$ 表示沿通道维度切分; $\text{Conv}_{3 \times 3}(\cdot)$, $\text{Conv}_{5 \times 5}(\cdot)$, $\text{Conv}_{7 \times 7}(\cdot)$ 分别表示进行 3×3 、 5×5 、 7×7 的卷积操作; $X_{p1} \in \mathbb{R}^{\frac{C}{4} \times H \times W}$ 表示中间特征 X_p 经过 5×5 卷积特征提取和沿通道切分后继续参与部分卷积的中间聚合特征; $X_{o1} \in \mathbb{R}^{\frac{C}{4} \times H \times W}$ 表示中间特征 X_p 经过 5×5 卷积特征提取和沿通道切分后保留的特征; $X_{p2} \in \mathbb{R}^{\frac{C}{4} \times H \times W}$ 表示经过 7×7 卷积操作之后得到的聚合特征。




图2 PC-MRF 结构图

Fig.2 PC-MRF structure




图3 PConv 原理图

Fig.3 PConv structure

将多尺度聚合特征 X_{p2} 与保留特征 X_o 、 X_{o1} 进行拼接, 并通过 1×1 卷积完成融合与降维, 得到最终聚合特征:

$$X_{\text{fuse}} = \text{Conv}_{1 \times 1}(\text{Concat}(X_{p2}, X_o, X_{o1})) \quad (4)$$

式中: $X_{\text{fuse}} \in \mathbb{R}^{C \times H \times W}$ 表示多尺度聚合特征和保留特征

经过特征聚合后所得的中间特征; $\text{Concat}(\cdot)$ 表示沿通道维度的特征拼接。最后在融合特征的基础上, 引入残差连接以补充原始信息, 最终输出特征图:

$$Y = X_{\text{fuse}} + X_r \quad (5)$$

式中: Y 为模块输出特征图。与通常多尺度卷积的并行全通道提取特征的方式不同, PC-MRF 模块结合部

分卷积实现通道选择性计算, 并采用多感受野渐进聚合结构。该设计在参数量和计算量适度增长的前提下, 实现了跨尺度特征的充分融合, 增强了小目标局部细节与大目标全局语义的多尺度特征表达能力, 改善了变电站场景下相似设备的类别混淆问题。

1.3 BLQP-Head 检测头

绝缘子这类小型设备因像素少、边缘特征弱, 检测时易被变电站的复杂背景或大型设备干扰, 导致 YOLOv11n 原生的检测头出现分类置信度与定位质量严重脱节的问题。NMS 阶段仅依据分类分数进行排序筛选, 使得定位精确但分类分稍低的优质预测框, 极易被定位偏差大但分类分虚高的劣质框所抑制, 造成目标设备被错误滤除, 最终引发漏检问题^[20, 21]。为解决此类问题, 本文借鉴定位质量估计 (Localization Quality Estimation, LQE)^[22]对预测框定位质量进行显

式估计的思想, 并结合 YOLOv11n 检测头结构, 构建了 BLQP-Head 检测头, 结构如图 4 所示。传统的定位质量估计方法通常依赖回归 IoU 分数这类额外的监督信号实现定位质量的显式回归, 其准确性高度依赖人工标注框的精度。然而在变电站实际环境中, 盘形玻璃绝缘子和针式陶瓷绝缘子的真实标注框易存在边界定位偏差, 此时传统方法会因监督信号含噪而难以输出可靠的质量分数。BLQP-Head 可直接从回归分支的分布特征中提取定位置信度, 通过评估各边界方向概率分布的尖锐程度感知回归结果的不确定性。该特性使得检测头在复杂背景下, 对绝缘子等小型设备的高质量预测框保留与低质量框抑制过程更为稳定可靠。




图 4 BLQP-Head 结构图

Fig.4 BLQP-Head structure

回归分支对某一边界位置的预测结果可表示为离散概率分布, 该分布的形状直接反映模型的定位置信程度, 即分布越尖锐集中, 则定位质量越高; 分布越

平坦或呈多峰状, 则定位不确定性越大。基于此, BLQP 首先通过 Softmax 将回归分支输出的四个方向 (左、右、上、下) 边界的原始预测输出转换为离散概率分

布, 这一过程可表达为:

$$\mathbf{q}_d(j) = \text{Softmax}(\hat{\mathbf{z}}_d), d \in \{l, r, t, b\} \quad (6)$$

式中: $\mathbf{q}_d(j)$ 为在 d 方向上第 j 个区间的归一化概率值; d 为边界方向标记, l 、 r 、 t 、 b 分别对应左右上下方向; $\hat{\mathbf{z}}_d$ 为回归分支在 d 方向的原始预测输出。对每个方向的概率分布, 提取概率分布中数值最大的前 K 个值 (即 TopK 值) 及其均值, 并将其拼接构成统计特征向量:

$$\mathbf{v} = \text{Concat}(\text{TopK}(\mathbf{q}_d, K), \bar{q}_d), d \in \{l, r, t, b\} \quad (7)$$

式中: $\mathbf{v}$ 为拼接后的特征统计向量; $\text{TopK}(\mathbf{q}_d, K)$ 为在 d 方向上概率分布中按数值排序选取的前 K 个最大概率值构成的向量; $\bar{q}_d$ 为在 d 方向上概率分布的均值。在给定统计特征 $\mathbf{v}$ 后, 通过两层全连接网络预测定位质量分数:

$$s = \sigma(\mathbf{W}_2 \cdot \delta(\mathbf{W}_1 \cdot \mathbf{v})), s \in [0, 1] \quad (8)$$

式中: s 为预测的定位质量分数; $\sigma(\cdot)$ 为 Sigmoid 激活函数; $\delta(\cdot)$ 为 ReLU 激活函数; $\mathbf{W}_1$ 、 $\mathbf{W}_2$ 分别为两层全连接网络的权重矩阵。最后, 将 s 与分类分支输出的置信度分数 c 进行融合, 得到最终置信度 f 。

$$f = c \cdot s \quad (9)$$

式中: f 为最终融合置信度, c 为分类分支输出的置信度分数。 f 同时编码了分类语义信息与定位, 能够使高质量边界框在 NMS 阶段获得更高的保留优先级, 从而降低小目标的漏检率。

1.4 C2PSA-DyT 模块

变电站场景下待检测电力设备种类繁多, 背景区域广泛分布金属构架、密集线缆, 其视觉特征与绝缘子这类小目标设备的边缘、纹理特性重合, 易对目标检测造成背景干扰。YOLOv11n 的 C2PSA 模块依托多

头注意力机制实现全局特征依赖建模, 但其采用的静态激活函数对全图特征施加统一的非线性变换, 无法依据特征的信号强度与语义属性开展差异化调制, 难以对目标有效特征与背景干扰特征实现甄别式增强; 此外, 该模块仅通过空间权重完成特征选择性增强, 缺乏动态调控机制, 在复杂背景干扰下易出现注意力资源偏移, 进而制约变电站场景下的目标检测性能^[23]。针对这一问题, 本文在原有 PSABlock 的注意力分支与前馈分支前端分别嵌入一个 DyT^[24]单元, 以改进 C2PSA, 结构图如图 5 和图 6 所示。

通常的注意力改进的核心思路是对特征进行权重重标定, 其权重多基于特征统计量生成, 对输入特征的调制以线性缩放为主, 激活函数的映射形态固定, 不随输入特征内容动态变化。C2PSA-DyT 模块通过引入仿射变换, 以可学习的通道级缩放与仿射参数替代传统归一化层的统计依赖, 动态调控激活函数的非线性映射曲线, 使模型可根据特征语义自适应强化有效目标特征、抑制背景干扰, 更适用于存在复杂背景的变电站巡检场景。




图 5 C2PSA-DyT 结构图

Fig.5 C2PSA-DyT structure




图6 PSABlock_DYT 结构图

Fig.6 PSABlock_DYT structure

具体而言,输入特征先经过首节点 DyT 进行自适应非线性变换,使注意力机制更倾向于增强目标显著区域的权重;随后经残差连接与空间注意力计算后的特征,再通过第二节点 DyT 进行二次调制,进一步优化特征分布并抑制背景噪声后输入前馈网络。DyT 单元对输入特征矩阵 $\mathbf{X}$ 的变换过程可定义为:

$$\hat{\mathbf{X}} = \tanh(\alpha \odot \mathbf{X}), \alpha \in \mathbb{R}, \mathbf{X} \in \mathbb{R}^{C \times H \times W} \quad (10)$$

式中: $\hat{\mathbf{X}}$ 为 $\mathbf{X}$ 经过动态尺度调节后的非线性压缩中间表示; α 为全局可学习尺度因子,通过动态调节 $\tanh$ 函数的压缩斜率,使模块在背景平坦区域保持平缓响应以保留梯度信息,在目标突出区域增大非线性强度以放大判别特征; $(\alpha \odot \mathbf{X})$ 表示 α 和 $\mathbf{X}$ 按位相乘。最终输出特征可表示为:

$$F(\mathbf{X}) = \gamma \odot \hat{\mathbf{X}} + \beta, \gamma \in \mathbb{R}^C, \beta \in \mathbb{R}^C \quad (11)$$

式中: $F(\mathbf{X})$ 为输入特征经过 DyT 模块后的最终输出; γ 和 β 为逐通道仿射参数,分别对各通道特征进行幅度校正与均值对齐。上述双节点设计在保留 C2PSA 并行注意力结构与残差连接优势的基础上,增强了模块对复杂场景下多尺度目标的非线性建模能力,有效提升了模型的检测性能。

1.5 FPSC 模块

变电站巡检图像中通常包含绝缘子、断路器、隔

离开关等多种电力设备,目标尺度差异显著。同时,变电站场景中存在金属构架交错、线缆纵横的复杂背景,且现场光照条件多变;此外,设备常年暴露于户外环境,表面易出现锈蚀、污秽等细微纹理变化,上述特性对目标检测的多尺度特征提取能力与细粒度细节保留能力均提出了较高要求。YOLOv11n 中 SPPF 模块虽然通过多级池化操作实现了感受野的快速扩展,但其池化式特征聚合方式在融合过程中不可避免地引入空间信息损失,尤其在小尺度目标或细粒度结构特征提取时,易导致关键细节被平滑甚至丢失,从而削弱算法对多尺度目标的精细表征能力,影响复杂背景下的检测性能^[25]。为进一步提升算法的多尺度特征提取能力,受特征金字塔网络 (Feature Pyramid Network, FPN) 的多尺度特征表达思想^[26]启发,结合变电站设备尺度跨度大的场景特点,本文构建了 FPSC 模块替代 SPPF,结构图如图 7 所示。FPSC 模块与常规 FPN 侧重跨层特征融合不同,该模块主要通过共享权重的多膨胀率卷积分支进行局部多尺度上下文建模,以减少串联池化操作带来的空间细节损失,并在控制参数增长的同时增强跨尺度特征表达能力,从而更好地适应复杂变电站场景下的多尺度设备检测任务。相较于通常的 SPPF 改进方案,FPSC 通过权重共享避免了参

数随分支数线性增长问题,在提升计算效率的同时保留了完整的多尺度建模能力,更适用于存在边缘部署需求的变电站巡检场景。




图7 FPSC 结构图

Fig.7 FPSC structure

对于输入特征 $X \in \mathbb{R}^{C \times H \times W}$, 首先通过 1×1 卷积对输入特征完成通道压缩与初始语义抽象, 得到中间特征, 其过程可表示为:

$$Y_0 = \text{SiLU}(\text{BN}(\text{Conv}_{1 \times 1}(X))) \quad (12)$$

式中: Y_0 表示中间特征, $\text{Conv}_{1 \times 1}(\cdot)$ 表示 1×1 卷积操作, $\text{BN}(\cdot)$ 表示批量归一化, $\text{SiLU}(\cdot)$ 表示激活函数。该步骤一方面能够压缩通道维度、减少冗余计算, 另一方面也能对输入特征进行初步语义映射, 为后续多尺度特征提取提供更紧凑的特征表达。随后, FPSC 设置三层完全共享权重的 3×3 膨胀卷积, 膨胀率分别设置为 1、3、5, 用于提取多尺度特征。不同尺度分支的特征提取过程可表示为:

$$Y_1 = \text{SiLU}(\text{BN}(\text{Conv}_{3 \times 3}^{d=1}(Y_0))) \quad (13)$$

$$Y_2 = \text{SiLU}(\text{BN}(\text{Conv}_{3 \times 3}^{d=3}(Y_1))) \quad (14)$$

$$Y_3 = \text{SiLU}(\text{BN}(\text{Conv}_{3 \times 3}^{d=5}(Y_2))) \quad (15)$$

式中: Y_1, Y_2, Y_3 分别表示三个分支的特征提取结果。

$\text{Conv}_{3 \times 3}^{d=1}(\cdot)$, $\text{Conv}_{3 \times 3}^{d=3}(\cdot)$, $\text{Conv}_{3 \times 3}^{d=5}(\cdot)$ 分别表示膨胀率为 1、3、5 的 3×3 卷积操作。低膨胀率分支对应较小感受野, 主要提取局部精细结构; 高膨胀率分支对应较大感受野, 更适合感知场景上下文和设备整体结构, 从而较好地适应从近距离小型电力设备到远距离大型电力设备的多尺度分布。完成三条膨胀卷积分支提取后, 将初始特征 Y_0 与不同膨胀率下得到的特征 Y_1, Y_2, Y_3 沿通道维度进行拼接, 得到多尺度聚合特征 Y_{cat} :

$$Y_{\text{cat}} = \text{Concat}(Y_0, Y_1, Y_2, Y_3) \quad (16)$$

式中: $\text{Concat}(\cdot)$ 表示通道维度拼接操作。通过该方式, 模块能够同时保留输入特征中的基础语义信息、低膨胀率分支提取的局部细节信息, 以及高膨胀率分支获取的上下文信息, 使输出特征具有更丰富的尺度表达能力。最后, FPSC 再通过 1×1 卷积完成多尺度特征的融合与通道调整, 得到最终输出特征 Y_{out} :

$$Y_{\text{out}} = \text{SiLU}(\text{BN}(\text{Conv}(Y_{\text{cat}}))) \quad (17)$$

该设计通过权重共享的多尺度膨胀卷积替代 SPPF 的串联池化特征聚合机制, 在有效扩展感受野的同时保持空间细节信息, 并在控制多分支卷积参数适度增长的前提下, 提升了模型对不同尺度电力设备目标的特征表达能力。

2 实验与结果分析

2.1 实验环境与参数设置

本文所有实验均在配备 Intel Core i7-14700KF 处理器与 NVIDIA GeForce RTX 4070Ti GPU 的计算平台上完成。软件环境为 Windows 10 专业版操作系统, 深度学习框架采用 PyTorch 2.3.0, CUDA 版本为 12.6, 编程语言为 Python 3.10, 实验参数如表 1 所示。

表 1 实验超参数

Table 1 Experimental hyperparameters

参数名称	设置值
输入图像尺寸	640×640
训练批次	200
批次大小	16
优化器	SGD
初始学习率	0.01
学习率动量	0.937
权重衰减	0.0005
工作线程数	4
数据增强策略	mosaic

2.2 实验装置

为初步探索优化模型在模拟环境下的表现，搭建了如图 8 所示的实验装置。



图 8 实物装置


Fig.8 Experimental platform

装置以智能车作为移动载体，采用分层式硬件架构，主要由相机控制层、上位机层和运动控制层组成。其中，相机控制层由下位机和两台无刷伺服电机构成，主要用于云台姿态调节与目标区域对准；上位机层集成双光相机、激光雷达、超声波传感器及数传模块，承担环境感知、数据通信与图像采集功能；运动控制


层由下位机、巡线传感器、电机驱动模块和导航模块组成，用于实现车体运动控制、路径跟踪及障碍物预警。该装置可完成模拟环境下的变电站设备图像采集，并将采集图像上传至上位机，用于算法的初步部署验证，为研究提供了移动式实验平台支撑。

2.3 变电站设备数据集与评价指标

研究采用 Gomes 等^[27]公开发布的变电站设备数据集作为实验数据集，数据集示例如图 9 所示。该数据集由 7537 张图片构成，以 7:2:1 的比例分为训练集、验证集和测试集，其类别覆盖断路器、隔离开关、绝缘子、电力变压器、电流互感器等 15 种常见设备，该数据集来源于真实电气变电站现场，图像采集方式多样，涵盖不同光照、天气与拍摄角度，具有较高的场景多样性与代表性，适用于评估模型在真实变电站巡检环境下的检测性能。



(a) 部分数据集展示



(b) 数据集类别分布

图 9 数据集示例

Fig.9 Example images of dataset

(2) 评价指标

为全面衡量改进模型在变电站设备目标检测任务

中的实际性能,本研究选取以下指标进行测试:

$$P = \frac{TP}{TP + FP} \quad (18)$$

式中: P 为精确度 (Precision); TP 表示模型正确识别的正样本数量; FP 则表示模型错误识别的负样本数量。

$$R = \frac{TP}{TP + FN} \quad (19)$$

式中: R 为召回率 (Recall); FN 则表示模型漏检的负样本数量。

$$AP = \int_0^1 P(R) dR \quad (20)$$

式中: AP 为单一类别在精确率-召回率曲线下的平均精度,综合反映该类别的检测性能。

$$mAP = \frac{1}{N} \sum_{i=1}^N AP(i) \quad (21)$$

式中: N 代表数据集中所有类别总数; mAP 为计算所有类别 AP 值的平均值,用于衡量算法在多类别检测

任务中的综合表现。

$$FPS = \frac{1000}{t_{pre} + t_{infer} + t_{post}} \quad (22)$$

式中: FPS 表示模型每秒处理的图像帧数 (即推理速度)。 FPS 的计算包含前处理、模型推理和后处理三个阶段,单位为毫秒。 t_{pre} 表示前处理耗时,前处理负责图像解码、尺寸调整与归一化; t_{infer} 表示模型推理耗时,模型推理负责对处理后的张量执行前向计算,并输出任务对应的预测结果; t_{post} 表示后处理耗时,后处理负责对模型输出的结果进行 NMS 过滤和坐标映射,生成最终输出。本文在进行 FPS 测试前,先进行 5 轮预热操作,使 GPU 进入稳定运行状态;随后在同一验证集上连续执行 10 次完整的推理过程,分别记录每次推理的平均 FPS 值,最终以 10 次测试结果的算术平均值作为各模型的最终 FPS 性能指标。

除上述基于精度与速度的评估指标外,通常还会

从模型规模、计算复杂度以及最终训练权重三个维度进行补充评价,对应的指标分别为参数量 (Parameters, Params)、计算量 (Floating Point Operations, FLOPs) 和最优权重文件体积 (Size)。

2.4 消融实验

为验证本文模型中各改进模块的有效性,本文以

YOLOv11n 为基线模型,在变电站设备数据集上开展消融实验。实验依次引入 A 模块 (PC-MRF)、B 模块 (BLQP-Head)、C 模块 (C2PSA-DyT) 与 D 模块 (FPSC) 四个模块,逐步评估各模块对模型检测性能的独立贡献及其协同效果,表中“√”表示该模块已被添加至模型中,实验结果如表 2 所示。

表 2 消融实验对照表

Table 2 Comparison results of ablation experiment

	A	B	C	D	P/%	R/%	mAP50/%	mAP50-95/%	Params/M	FLOPs/G	Size/MB	FPS
1					83.17	78.09	83.16	53.33	2.59	6.3	5.2	228
2	√				84.17	79.69	84.61	54.57	2.63	7.7	5.3	210
3		√			83.57	79.17	84.47	54.13	2.59	6.4	5.2	213
4			√		84.80	78.39	84.55	54.27	2.59	6.3	5.2	214
5				√	83.69	78.81	84.51	54.23	2.73	6.3	5.5	193
6	√	√			84.54	79.19	85.03	54.83	2.64	7.7	5.3	204
7	√		√		83.55	79.96	85.17	54.98	2.63	7.7	5.3	207
8	√			√	85.06	79.51	85.20	55.06	2.78	7.7	5.6	208
9	√	√	√		83.61	80.82	85.49	54.99	2.64	7.7	5.3	205
10	√		√	√	83.80	80.18	85.46	55.26	2.78	7.7	5.6	206
11	√	√	√	√	84.68	80.40	85.93	55.96	2.78	7.7	5.6	204

表 3 COCO 指标

Table 3 COCO metrics

单位: %

	AP@0.5	AP@0.75	AP@[0.5:0.95]	AP@[0.5:0.95](L)	AP@[0.5:0.95](M)	AP@[0.5:0.95](S)
YOLOv11n	83.16	55.37	53.33	64.47	36.89	17.21
YOLO-Ours	85.93	57.89	55.96	66.23	39.76	19.15

实验结果表明,在仅引入 A 模块的条件下,改进后的算法 (Model-11) 虽然完整模型的参数 (Model-2),模型 mAP50 由 83.16%提升至 84.61%,提升幅度达 1.45%,表明部分通道参与结合多尺度感受野的协同提取策略能够有效强化算法的特征表征能力,并缓解类间高相似性所引发的混淆现象。在此基础上进一步引入 B 模块 (Model-6),召回率进一步提升至 79.19%,mAP50 达 85.03%,较单独引入 PC-MRF 时提升 0.42%,表明两模块在特征表征与定位质量优化方面形成有效互补,小目标检测质量得到进一步改善。继续引入 C 模块 (Model-9),模型召回率进一步提升至 80.82%,mAP50 与 mAP50-95 分别达到 85.49%与 54.99%,说明动态注意力调制机制与前两个模块协同作用,有效增强了模型对目标区域的响应能力,进一步抑制了复杂背景与光照变化带来的干扰。

改进后的算法 (Model-11) 虽然完整模型的参数量与计算量较基线有所增加,但在参数规模适度增长的前提下实现了检测精度的全面提升,mAP50 与 mAP50-95 较基线模型分别提升 2.77%与 2.63%,精确度与召回率分别达到 84.68%与 80.40%,各模块通过协同配合在性能全面提升的同时有效控制了参数增量,验证了各改进模块之间具有良好的兼容性与互补性,四个模块的组合改善了模型在变电站场景下的综合检测能力。

为进一步量化分析改进模型对不同尺度目标的检测适配性,本文采用 COCO 评价指标体系开展多尺度性能评估,结果如表 3 所示。改进模型在 AP@0.5、AP@[0.5:0.95]等核心精度指标上均优于基线模型,其

中 AP@0.5 与 AP@[0.5:0.95]分别提升 2.77%与 2.63%，表明改进模型具备更优的检测精度与鲁棒性。本文方法虽然在大 (Large, L)、中 (Medium, M)、小 (Small, S) 三类尺度目标的检测精度均实现不同程度提升，但小目标检测绝对值偏低，存在较大提升空间，小目标检测仍是未来优化的核心方向。

综上，本文提出的改进模型在综合检测性能上优于基线 YOLOv11n 模型。所设计的多模块协同优化方案既提升了多尺度目标的检测均衡性，也增强了复杂背景下的目标定位精度与特征判别能力，验证了改进

方法在变电站巡检场景下的有效性。

2.5 对比实验

为了更客观地评估本文模型的检测性能，本文选取两阶段检测模型 Faster R-CNN、单阶段检测模型 RT-DETR-l 以及 YOLO 系列轻量模型进行对比，在相同实验环境下进行比较。默认批次大小设置为 16，其中 RT-DETR-l 与 Faster R-CNN 的批次大小调整为 8，其余所有对比模型的超参数均保持统一设置，实验结果如表 4 所示。

表 4 对比实验结果

Table 4 Results of comparison experiment

	P/%	R/%	mAP50/%	mAP50-95/%	Params/M	FLOPs/G	Size/MB	FPS
RT-DETR-l ^[28]	71.44	61.07	63.30	28.92	32.01	103.5	63.2	66
Faster R-CNN	63.50	67.80	53.20	32.80	41.26	83.4	157.4	32
hyper-yolo ^[29]	83.44	81.17	85.60	55.95	3.62	9.5	7.3	198
文献[30]	83.62	78.76	84.45	53.09	2.05	5.9	4.6	229
YOLOv3-tiny ^[31]	79.53	69.02	73.75	43.33	12.14	18.9	23.3	226
YOLOv5n ^[32]	75.54	68.59	72.51	41.18	2.51	7.1	5.0	223
YOLOv6n ^[33]	76.06	69.32	73.00	41.98	4.24	11.7	8.3	229
YOLOv8n ^[34]	80.02	76.38	76.38	43.95	3.01	8.1	6.0	227
YOLOv10n ^[35]	75.75	70.11	74.43	43.15	2.27	6.5	5.5	283
YOLOv12n ^[36]	77.21	71.64	75.97	43.98	2.54	6.3	5.3	190
YOLOv13n ^[37]	80.99	72.29	78.06	46.54	2.45	6.2	5.2	190
YOLOv26n ^[38]	82.51	77.82	83.23	52.93	2.38	5.2	5.2	239
YOLOv11n	83.17	78.09	83.16	53.33	2.59	6.3	5.2	228
YOLO-Ours	84.68	80.40	85.93	55.96	2.78	7.7	5.6	204

实验结果表明，改进模型与 YOLOv5n、YOLOv8n、YOLOv10n 相比，mAP50 分别提升 13.42%、9.55%和 11.50%。与 YOLOv12n 和 YOLOv13n 相比，改进模型在 mAP50 上分别提升 9.96%和 7.87%。与 YOLOv26n 相比，改进模型在 mAP50 和 mAP50-95 上分别提升 2.70%和 3.03%。与 hyper-yolo 相比，在

参数量和计算量分别降低 0.84M 和 1.8G 的情况下，mAP50 实现了小幅提升。与文献[30]相比，改进模型在精度、mAP50 和 mAP50-95 上分别提升 1.06%、1.48%和 2.87%。

与非 YOLO 检测模型相比，改进模型相较于 Faster R-CNN 在 mAP50 上提升 32.73%；相较于

RT-DETR-l 在 mAP50 上提升 22.63%。综上,改进模型相较其他对比模型在检测精度上具备优势,更适用于变电站设备目标检测场景。

2.6 泛化实验

为进一步考查本文模型的鲁棒性与泛化能力,本文采用 InsPLAD 数据集^[39]开展泛化实验。该数据集来源于无人机对真实高压输电线路的巡检采集,与变电

站设备检测场景同属电力设备目标检测领域,具有较强的场景关联性,适用于评估本文模型的性能。实验结果表明,本文模型与基线相比,精度和 mAP50 分别提升了 2.41%和 1.59%,验证了改进模型在 InsPLAD 数据集上仍能保持稳定的检测性能。实验结果如表 5 所示。

表 5 InsPLAD 数据集泛化实验结果

Table 5 Generalization experiment results of the InsPLAD dataset

	P/%	R/%	mAP50/%	mAP50-95/%	Params/M	FLOPs/G	Size/MB	FPS
RT-DETR-l	80.28	81.03	72.61	53.72	31.98	103.4	63.1	105
Faster R-CNN	68.45	72.18	55.63	48.76	41.26	83.4	157.4	51
hyper-yolo	88.89	83.81	87.63	71.23	3.62	9.5	7.3	479
文献[30]	89.68	81.96	86.48	68.26	2.05	5.9	4.6	530
YOLOv3-tiny	84.42	70.03	74.21	54.32	12.14	18.9	23.3	501
YOLOv5n	85.29	70.89	76.56	57.66	2.51	7.1	5.0	607
YOLOv6n	75.23	73.30	75.83	59.15	4.24	11.7	8.3	572
YOLOv8n	81.57	71.13	74.76	56.54	3.01	8.1	6.0	564
YOLOv10n	83.63	82.72	83.65	65.71	2.27	6.5	5.5	787
YOLOv12n	81.61	70.22	74.47	57.75	2.51	5.8	5.2	519
YOLOv13n	88.66	82.48	86.02	68.75	2.45	6.2	5.2	492
YOLOv26n	90.21	78.88	85.03	68.48	2.38	5.2	5.1	535
YOLOv11n	86.64	83.76	86.68	69.46	2.59	6.3	5.2	549
YOLO-Ours	89.05	83.81	88.27	69.68	2.78	7.7	5.6	491

2.7 模型可视化分析

(1) 模型部署

为验证优化后模型在边缘设备上的实际表现,选用 Raspberry Pi 5 开发板(内存 8GB)作为上位机,实物如图 10 所示。该开发板不仅具备较高的计算性能和丰富的外设接口,而且具有较低的功耗,因此适用于变电站等场景下的边缘端部署。为提升树莓派检测性能,本文为树莓派开发板加装 Raspberry Pi AI HAT+扩展板,其搭载 Hailo-8 AI 加速器,INT8 精度下峰值算力达 26 TOPS。Hailo-8 AI 加速器仅支持加载 HEF 文件,实验首先将训练好的 PyTorch 模型导出为 ONNX 格式,随后借助 Hailo_model_zoo 中的编译工具转换为 INT8 量化的 HEF 文件,最后将 HEF 文件部

署至硬件平台。本文以 mAP50、单帧耗时、推理帧率与峰值功耗为核心指标,评估基线模型与优化模型在边缘设备上的部署性能,实验结果如表 6 所示。

表 6 模型部署性能

Table 6 Post-deployment performance of models

模型	文件类型	mAP50 /%	单帧耗时/ms	FPS	峰值功耗/W
YOLOv11n	PT	83.16	229	4	7.2
	HEF	82.21	33	30	7.3
YOLO-Ours	PT	85.93	251	4	7.1
	HEF	84.72	37	27	7.2

本文改进模型的单帧耗时达 37ms,帧率达 27FPS,峰值功耗为 7.2W。尽管精度改进策略使模型计算复杂度较基线有所提升,但其仍具有良好的实时检测能力,可满足变电站巡检场景下的边缘设备部署需求。后续研究将在维持检测精度优势的前提下,进一步探索高

效网络结构与轻量化优化方法，持续提升算法在边缘计算设备上的部署效能。

(2) 热力图

为了直观验证本文所提模型优化前后的检测效果，通过采用 XGrad-CAM 方法生成可视化热力图进行对比，热力对比图如图 11 所示。对比分析热力图结果可知，改进前模型容易受到背景干扰，容易出现注意力弥散现象，在无目标区域产生不必要的特征激活；改

进后的算法可聚焦目标区域，在目标位置形成高强度热区，有效弱化了无关背景的特征响应。



图 10 Raspberry Pi 5 开发板
Fig.10 Raspberry Pi 5




图 11 热力图可视化结果对比
Fig.11 Comparison of heat map visualization results

(3) 检测效果对比

为进一步验证所提改进模型的检测性能，本文选取五类典型场景进行对比，如图 12 所示。

第一组图像对应类别混淆场景。闭式刀闸隔离开关与熔断器式隔离开关（刀熔开关）整体结构与外观高度相近，基线模型无法有效提取二者的细粒度区分特征，出现同框重复标注与类别误判；而改进模型可准确识别出熔断器式隔离开关，表明 PC-MRF 模块有效增强了模型对相似设备的细粒度特征判别能力，缓

解了类别混淆问题。

第二、三、四组图像用于验证模型在复杂背景与低光照环境下对小目标的检测能力。在密集线缆、金属构件等背景干扰与多候选框重叠的影响下，基线模型对盘形玻璃绝缘子这类小目标出现了漏检现象，而改进模型可检测出目标；在低光照环境下，改进模型仍能检测出部分小目标绝缘子，验证了 BLQP-Head 与 C2PSA-DyT 模块对小目标检测性能与稳定性的提升作用。

第五组图像针对多尺度目标检测场景展开验证,画面同时涵盖大、中、小三类尺度的变电站设备。基线模型对其中小尺度盘形玻璃绝缘子存在漏检,而改进模型可实现多尺度目标的准确检出,说明 FPSC 模块有效优化了跨尺度特征融合效果,提升了模型对不同尺度设备的均衡检测能力。

综上所述,改进后的模型在目标检测和类别识别方面均表现出较高的准确性,相比改进前模型,置信度有所提升,验证了所提改进模型在目标检测方面的优良性能。

2.8 失败案例分析

尽管本文提出的改进算法在多数变电站设备目标检测场景中能够展现出较好的检测效果,但在极端工况下仍然存在一定局限性。图 13 给出了若干典型失败

案例:在第一组图像中,受金属架构与线缆的遮挡干扰,改进模型未能检测出盘形玻璃绝缘子;在第二组图像中,低光照环境导致图像对比度显著下降,模型无法有效识别部分的小尺度盘形玻璃绝缘子;在第三组图像中,金属构架的强遮挡背景造成严重干扰,导致模型不仅漏检了针式陶瓷绝缘子,同时因图像右下方区域像素信息不足,模型虽检测到目标,却将电流互感器错误分类为避雷器,出现类别混淆现象。上述案例表明,改进模型在强遮挡、低光照这类极端环境下,对于小目标仍存在漏检与误检等问题。

针对上述局限性,未来的研究工作将进一步探索更加有效的小目标检测增强策略与抗干扰注意力方法,以提升模型在遮挡、低光照等挑战性场景下的检测稳定性与鲁棒性。




图 12 检测效果对比

Fig.12 Comparison of detection results




图 13 失败案例分析

Fig.13 Analysis of typical failure cases of our model

3 结束语

本文针对变电站设备目标检测任务中存在的复杂背景干扰、多尺度检测失衡、小目标漏检及类别混淆等问题,提出了一种基于改进 YOLOv11n 的变电站设备目标检测算法。设计 PC-MRF 模块替换 C3k2,通过部分通道卷积与多感受野特征融合,增强模型对不同尺度目标特征表达能力,改善多尺度目标检测不均衡和相似特征混淆问题;构建 BLQP-Head 检测头,通过重构边界框定位质量感知机制对候选框置信度进行修正,降低了小目标高质量预测框在 NMS 阶段被错

误抑制的风险;引入 DyT 改进 C2PSA 模块,通过利用动态非线性调制增强目标区域特征响应,抑制复杂背景带来的干扰;构建 FPSC 模块替代 SPPF,通过权重共享的多尺度膨胀卷积实现跨尺度特征聚合,进一步改善了多尺度目标之间的检测均衡性。最后搭建了以智能车为移动载体的实验装置,为算法的初步部署验证提供了实验平台支撑。

实验结果表明,与基线模型 YOLOv11n 相比,本文所提模型的 mAP50 与 mAP50-95 分别提升 2.77%与 2.63%。在对比实验中,该模型在所有参与对比的

YOLO 系列模型中表现良好,泛化实验证明了本文所提方法具备良好的泛化能力与场景适应性。可视化检测结果显示,改进后的算法能够更准确地聚焦目标区域,并在目标检测和置信度表现方面优于基线模型,进一步验证了所提算法具有较好的检测性能。

虽然本文所提算法的轻量化指标相较基线有所增加,但与相应的检测精度增益相比总体可控,在精度优先的变电站设备巡检应用场景下仍具有工程合理性。本文所提改进方法在光照条件正常、目标无重度遮挡的常规变电站巡检场景中性能表现稳定,可有效支撑日常设备状态的定位任务;但复杂背景下的小目标检测是当前模型最核心的性能短板,面对强遮挡、极端光照、设备高度密集排布等极端工况时,小目标漏检与相似设备类别混淆的概率会有所升高,检测性能仍有较大提升空间。

面向边缘设备的实际部署需求,上述计算开销的增长与复杂场景下小目标检测的性能短板仍有进一步的优化空间。后续研究工作将从以下方向展开:一是在保持检测精度优势的基础上,继续探索高效结构设计,进一步提升算法在边缘计算设备上的部署效能;二是利用本文搭建的实验小车采集变电站现场真实图像,使用标注软件 LabelImg 完成数据标注,构建自建

数据集,对改进算法的实际工程性能开展更具针对性的验证与优化;三是围绕小目标检测这一性能短板,优化遮挡感知与低光照增强策略,研究小目标特征增强方法,提升绝缘子等小型设备在极端工况下的检测精度与鲁棒性,进一步增强算法的变电站场景适配能力。

参考文献:

- [1] 魏涛. 变电站自动化监测控制系统的研究[J]. 能源技术与管理, 2023,48(02):174-176.
WEI T. Research on automatic monitoring and control system for substation[J]. Energy Technology and Management, 2023,48(02):174-176.
- [2] 许媛. 变电站热故障诊断的数字孪生应用研究[D]. 成都: 电子科技大学, 2025.
XU Y. Research on the application of digital twin in thermal fault diagnosis of substations[D]. Chengdu: University of Electronic Science and Technology of China, 2025.
- [3] BOUCHENE M M. Bayesian optimization of histogram of oriented gradients (HOG) parameters for facial recognition[J]. The Journal of Supercomputing, 2024,80(14):20118-20149.
- [4] LOWE D G. Distinctive image features from scale-invariant keypoints[J]. International Journal of Computer Vision, 2004,60(2):91-110.
- [5] GIRSHICK R, DONAHUE J, DARRELL T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C].//Proceedings of 2014 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Piscataway: IEEE, 2014: 580-587.
- [6] GIRSHICK R. Fast R-CNN[C].//Proceedings of 2015 IEEE International Conference on Computer Vision (ICCV). Piscataway: IEEE, 2015: 1440-1448.
- [7] REN S, HE K, GIRSHICK R, et al. Faster R-CNN: towards real-time object detection with region proposal networks[J]. IEEE Transactions on Pattern Analysis and

- Machine Intelligence, 2017,39(6):1137-1149.
- [8] HE Y, SONG K C, MENG Q G, et al. An end-to-end steel surface defect detection approach via fusing multiple hierarchical features[J]. IEEE Transactions on Instrumentation and Measurement, 2020,69(4):1493-1504.
- [9] LIU W, ANGUELOV D, ERHAN D, et al. SSD: single shot multiBox detector[C].//Computer Vision – ECCV 2016: 14th European Conference. Berlin, Heidelberg: Springer, 2016: 21-37.
- [10] REDMON J, DIVVALA S, GIRSHICK R, et al. You only look once: unified, real-time object detection[C].//Proceedings of 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Piscataway: IEEE, 2016: 779-788.
- [11] 王磊, 郝涌汀, 潘明然, 等. 电力巡检中改进 YOLOv5s 的缺陷检测算法研究[J]. 计算机工程与应用, 2024, 60(10): 256-265.
- WANG L, HAO Y T, PAN M R. Improved defect detection algorithm in power inspection based on YOLOv5s[J]. Computer Engineering and Applications, 2024,60(10):256-265.
- [12] 张剑锐, 魏霞, 张林鎰, 等. 改进 YOLO v7 的绝缘子检测与定位[J]. 计算机工程与应用, 2024,60(04):183-191.
- ZHANG J R, WEI X, ZHANG L X. Improving detection and positioning of insulators in YOLO v7[J]. Computer Engineering and Applications, 2024,60(04):183-191.
- [13] XU M, CAI Z, CAI K, et al. IPE-YOLO: A Multi-Scale Defect Detection Method for Power Equipment Inspection[J]. Electronics,2025,14(19):3767-3767.
- [14] 刘方轩, 李为相, 肖迪, 等. 改进 YOLOv11n 的输电线路缺陷检测算法[J]. 计算机工程与应用, 2026,62(05):137-149.
- LIU F X, LI W X, XIAO D. Improved YOLOv11n algorithm for defect detection in transmission lines[J]. Computer Engineering and Applications, 2026,62(05):137-149.
- [15] 孙铁强, 洪兆志, 宋超, 等. 基于多尺度特征融合的轻量化绝缘子缺陷检测[J]. 激光与光电子学进展, 2025, 62(06): 136-147.
- SUN T Q, HONG Y Z, Song C, et al. Lightweight insulator defect detection based on multiscale feature fusion[J]. Laser & Optoelectronics Progress, 2025,62(06):136-147.
- [16] KHANAM R, HUSSAIN M. YOLOv11: an overview of the key architectural enhancements[EB/OL]. (2024-10-23) [2026-03-28] <https://arxiv.org/abs/2410.17725>.
- [17] 张博文, 刘国巍. 基于改进 YOLOV8 的钢材缺陷监测算法研究[J/OL]. 重庆工商大学学报(自然科学版). (2025-04-29) [2026-03-28]. <https://link.cnki.net/urlid/50.1155.N.20250428.1607.006>.
- ZHANG B W, LIU G W. Research on steel defect monitoring algorithm based on improved YOLOV8[J/OL]. Journal of Chongqing Technology and Business University (Natural Science Edition). (2024-04-29) [2026-03-28] <https://link.cnki.net/urlid/50.1155.N.20250428.1607.006>.
- [18] HAN K, WANG Y, TIAN Q, et al. GhostNet: more features from cheap operations[C].//Proceedings of 2020 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Piscataway: IEEE, 2020: 1577-1586.
- [19] CHEN J R, KAO S H, HE H, et al. Run, don't walk: chasing higher FLOPS for faster neural networks[C].//Proceedings of 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition(CVPR). Piscataway: IEEE, 2023: 12021-12031.
- [20] 刘志龙, 王成, 杜俊男, 等. 基于改进 YOLO11n 的电力高空作业安全防护装备检测算法[J/OL]. 电子测量技术. (2026-02-10)[2026-03-28] <https://link.cnki.net/urlid/11.2175.TN.20260210.1406.010>.
- LIU Z L, WANG C, DU J N, et al. Detection algorithm for electric power aerial work safety protective equipment based on improved YOLO11n. Electronic Measurement Technology. (2026-02-10) [2026-03-28] <https://link.cnki.net/urlid/11.2175.TN.20260210.1406.010>.
- [21] LI M Y, YAN N. IPD-YOLO: Person detection in infrared images from UAV perspective based on improved YOLO11[J/OL]. Digital Signal Processing, (2025-07-11)[2026-03-28]

- <https://doi.org/10.1016/j.dsp.2025.105469>.
- [22] LI X, WANG WH, HU X L, et al. Generalized focal loss V2: learning reliable localization quality estimation for dense object detection[C]//Proceedings of 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition(CVPR). Piscataway: IEEE, 2021: 11627-11636.
- [23] 钟长彬, 施建平, 祝孟洋, 等. CID-YOLO: 改进的 YOLOv11 PCB 缺陷检测算法[J/OL]. 电子测量技术. (2026-03-04) [2026-03-28]
<https://link.cnki.net/urlid/11.2175.tn.20260303.1311.030>.
ZHONG C B, SHI J P, ZHU M Y, et al. CID-YOLO: improved YOLOv11 PCB defect detection algorithm[J/OL]. Electronic Measurement Technology. (2026-03-04)[2026-03-28]
<https://link.cnki.net/urlid/11.2175.tn.20260303.1311.030>.
- [24] HOUKAN A, SAHOO K A. Dynamic tanh-enhanced transformer architecture for scalable and high-accuracy cyber threat detection in IoT environments[J]. Engineering Research Express, 2025, 7(3):035246-035246.
- [25] 徐盛, 山宏刚, 朱成, 等. FS-YOLO: 复杂环境下的液晶屏表面缺陷检测算法[J/OL]. 激光与光电子学进展. (2026-01-22)[2026-03-28]
<https://link.cnki.net/urlid/31.1690.TN.20260121.1807.086>.
XU S, SHAN H G, ZHU C, et al. FS-YOLO: an algorithm for detecting surface defects on LCD screens in complex environments. Laser & Optoelectronics Progress. (2026-01-22)[2026-03-28]
<https://link.cnki.net/urlid/31.1690.TN.20260121.1807.086>.
- [26] LIN T Y, DOLLAR P, GIRSHICK R, et al. Feature pyramid networks for object detection[C]//Proceedings of 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Piscataway: IEEE, 2017:936-944.
- [27] GOMES A A P, GANACIM F I S, MAGRIN F G S, et al. A semantically annotated 15-class ground truth dataset for substation equipment to train semantic segmentation models[J/OL]. Data. (2023-07-05) [2026-03-28]
<https://doi.org/10.3390/data8070118>.
- [28] ZHAO Y, LV W, XU S, et al. DETRs beat YOLOs on real-time object detection[C]//Proceedings of 2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Piscataway: IEEE, 2024: 16965-16974.
- [29] FENG Y, HUANG J, DU S, et al. Hyper-YOLO: when visual object detection meets hypergraph computation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2025,47(4):2388-2401.
- [30] 刘英博, 马帅旗, 程焕. 基于改进 YOLOv11n 的鸟类目标检测算法[J/OL]. 激光与光电子学进展. (2026-03-06) [2026-03-28]
<https://link.cnki.net/urlid/31.1690.TN.20260305.1610.062>.
LIU Y B, MA S Q, CHENG H. A bird target detection algorithm based on an improved YOLOv11n[J/OL]. Laser & Optoelectronics Progress. (2026-03-06) [2026-03-28]
<https://link.cnki.net/urlid/31.1690.TN.20260305.1610.062>.
- [31] ADARSH P, RATHI P, KUMAR M. YOLOv3-Tiny: object detection and recognition using one stage improved model[C]// Proceedings of 2020 6th International Conference on Advanced Computing and Communication Systems (ICACCS). Piscataway: IEEE, 2020: 687-694.
- [32] KHANAM R, MUHAMMAD H. What is YOLOv5: a deep look into the internal features of the popular object detector[EB/OL]. (2024-07-30)[2026-03-28]
<https://arxiv.org/abs/2407.20892>.
- [33] LI C, LI L, JIANG H, et al. YOLOv6: a single-stage object detection framework for industrial applications[EB/OL]. (2022-09-07)[2026-03-28]
<https://arxiv.org/abs/2209.02976>.
- [34] VARGHESE R, M S. YOLOv8: a novel object detection algorithm with enhanced performance and robustness[C]//Proceedings of 2024 International Conference on Advances in Data Engineering and Intelligent Computing Systems (ADICS). Piscataway: IEEE. 2024: 1-6.
- [35] WANG A, CHEN H, LIU L, et al. YOLOv10: real-time end-to-end object detection[EB/OL]. (2024-05-23)[2026-03-28]
<https://arxiv.org/abs/2405.14458>.

- [36] TIAN Y J, YE Q X, DOERMANN D. YOLOv12: attention-centric real-time object detectors[EB/OL]. (2025-02-18) [2026-03-28] <https://arxiv.org/abs/2502.12524>.
- [37] LEI M, LI S, WU Y, et al. YOLOv13: real-time object detection with hypergraph-enhanced adaptive visual perception[EB/OL]. (2025-06-21)[2026-03-28] <https://arxiv.org/abs/2506.17733>.
- [38] SAPKOTA R, CHEPPALLY R H, SHARDA A, et al. YOLO26: key architectural enhancements and performance benchmarking for real-time object detection[EB/OL]. (2025-09-29)[2026-03-28] <https://arxiv.org/abs/2509.25164>.
- [39] SILVA A L B V E, FELIX H D C, FRANCISCO M S, et al. InsPLAD: a dataset and benchmark for power line asset inspection in UAV images[J]. International journal of remote sensing, 2023, 44(23/24):7294-7320.