



计算机工程与应用
Computer Engineering and Applications
ISSN 1002-8331,CN 11-2127/TP

《计算机工程与应用》网络首发论文

题目： 基于数据增强与改进 YOLOv11 的无人机载荷检测方法
作者： 徐兆杰，侯博，李琳琳，韩思明，文僖越
网络首发日期： 2026-07-29
引用格式： 徐兆杰，侯博，李琳琳，韩思明，文僖越. 基于数据增强与改进 YOLOv11 的无人机载荷检测方法[J/OL]. 计算机工程与应用.
<https://link.cnki.net/urlid/11.2127.TP.20260729.1407.004>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于数据增强与改进 YOLOv11 的无人机载荷检测方法

徐兆杰, 侯博⁺, 李琳琳, 韩思明, 文僊越

火箭军工程大学, 西安 710025

+ 通信作者 E-mail: houbo@nwpu.edu.cn

摘要：在反无人机场景中，来袭无人机是否搭载载荷，是评估其威胁程度的重要依据。现有可见光无人机载荷检测面临公开数据集缺失、复杂场景覆盖不足以及检测精度偏低等诸多挑战。针对上述问题，本文构建了可见光无人机载荷检测数据集，并提出了一种生成式合成数据增强方法，用于低成本扩充训练数据并提升模型泛化能力。针对复杂背景下载荷目标特征表征不足的问题，本文对 YOLO 模型进行改进，模型对载荷目标、背景干扰及多尺度特征的建模能力。实验结果表明，所构建的数据集、生成式合成数据增强方法及改进 YOLO 模型能够有效提升无人机载荷检测性能，可为反无人机场景下的可见光载荷检测研究提供参考。

关键词：反无人机；载荷检测；数据增强；目标检测

文献标志码:A 中图分类号:TP391.4 doi: 10.3778/j.issn.1002-8331.2604-0190

UAV Payload Detection with Data Augmentation and Improved YOLOv11

XU Zhaojie, HOU Bo⁺, LI Linlin, HAN Siming, WEN Xiyue

Rocket Force University of Engineering, Xi'an 710025, China

Abstract: In counter-UAV scenarios, whether an incoming UAV carries a payload is an important basis for assessing its threat level. Existing visible-light UAV payload detection faces several challenges, including the lack of public datasets, insufficient coverage of complex scenarios, and limited detection accuracy. To address these issues, this paper constructs a visible-light UAV payload detection dataset and proposes a generative synthetic data augmentation method to expand training data at low cost and improve model generalization. To mitigate insufficient feature representation of payload targets under complex backgrounds, the YOLO model is improved to enhance its capability to model payload targets, background interference, and multi-scale features. Experimental results show that the constructed dataset, the generative synthetic data augmentation method, and the improved YOLO model can effectively improve UAV payload detection performance, providing a reference for visible-light payload detection research in counter-UAV scenarios.

Key words: Anti-UAV; payload detection; data augmentation; object detection

随着低空无人机应用的快速发展,无人机在巡检、物流配送、公共安全及侦察监控等民用、警用与军用

基金项目：国家自然科学基金青年项目 (62003363,62303485)、陕西省自然科学基金基础研究计划 (2022KJXX-99)、基础与前沿创新计划 (2025-QYCX-ZD-03-026)。

作者简介：徐兆杰(2002—), 男, 硕士研究生, 研究方向为计算机视觉; 侯博(1988—), 男, 博士, 副教授, 研究方向为反无人机、无人系统信息对抗; 李琳琳(1974—), 女, 博士, 副教授, 研究方向为无线自组网及数据链技术; 韩思明(1993—), 男, 硕士, 讲师, 研究方向为智能信息处理、对抗防御; 文僊越(2002—), 女, 硕士研究生, 研究方向为计算机视觉。

场景中得到广泛使用。然而,携带各类载荷的无人机侵入机场、军事基地等敏感区域的事件日益增多;同时,载荷类型的多样性与挂载能力的增强使得目标的威胁属性差异更加显著,并进一步压缩了可用于反制的时间窗口。因此,反无人机系统需要从无人机本体发现进一步扩展到对载荷携带状态与载荷类型的快速判定,以支撑威胁分级与反制决策。

无人机载荷感知研究主要包括非视觉模态、视觉模态和多传感器融合三类。雷达与声学方法利用微多普勒特征或声学变化判断有无载荷^[1-3],此类方法的输出多限于状态或重量信息,难以提供无人机载荷外观形态、空间位置和语义细节。视觉方法多将载荷识别建模为裁剪图像分类任务^[4-6],能够表征一定的细粒度外观差异,但通常依赖目标已被准确裁剪和居中的先验条件。多模态融合方法则结合雷达、红外和可见光信息开展无人机检测、跟踪与载荷识别^[7-9]。

上述方法虽然从不同模态出发推动了无人机载荷感知研究,但其任务形式多集中于载荷状态判断、重量估计或载荷分类,尚未充分关注广域视场下载荷目标的检测与定位问题。这也导致现有研究中面向载荷区域的检测级标注相对缺乏,统一的检测评测标准尚不完善。与此同时,现有公开无人机数据集也难以直接满足该任务需求:VisDrone、UAVDT等公开无人机数据集主要关注无人机平台视角下的地面目标检测与跟踪^[10,11],Anti-UAV、MMAUD和RCSD-UAV等数据集则更多关注无人机本体检测、多模态反无人机感知或复杂场景下的无人机目标检测^[12-14],缺乏面向载荷目标的精细化检测标注,使无人机载荷检测任务可利用的数据资源仍较为有限。

在数据匮乏条件下,数据增强是扩展训练分布、降低样本采集成本并提升跨场景泛化能力的重要手段。基于YOLOv5的无人机检测增强实验表明^[15],不同增强策略对检测性能影响显著,其中Mosaic增强在精确率和召回率方面取得了较好结果。相比图像扰动,合成数据增强能够生成原始数据中缺失的外观与场景变化。Jain等^[16]利用GAN生成合成缺陷样本,证明生成式增强可在小样本条件下补充传统增强难以表达的域内变化。Fang等^[17]提出基于可控扩散模型的数据增强方法,使生成样本在保持标注可继承性的同时

提升少样本检测性能。然而,面向无人机载荷检测任务,现有增强方法仍难以同时补充载荷外观与复杂背景变化。

需要进一步指出,数据增强虽可扩展训练样本覆盖范围和分布多样性,但载荷目标具有弱纹理、易受强背景干扰等特点,仍要求检测模型具备更强的特征表达、特征融合与定位能力。近年来,面向小目标、遥感目标及复杂场景检测的YOLO改进工作主要围绕轻量化卷积、特征金字塔重构、小目标检测头、注意力机制和结构重参数化展开。GCL-YOLO通过GhostConv和小目标检测头提升无人机目标检测能力^[18];Light-YOLO和Grain-YOLO通过轻量化模块降低计算开销并提升检测精度^[19,20];LMSD-YOLO、MCT-YOLO、MDQF-YOLO和RGE-YOLO则分别从多尺度融合、下采样优化、复杂环境特征增强和注意力机制等方面改善复杂场景检测性能^[21-24]。已有关于改进YOLOv11s的航拍小目标检测研究以及结构重参数化研究表明^[25,26],轻量卷积、注意力机制与重参数化设计有助于在有限计算资源下兼顾检测精度与推理效率。因此,面向无人机载荷检测任务,有必要在生成式合成样本扩展的基础上进一步优化检测模型结构,以增强模型对复杂背景下载荷目标的感知能力。

综上所述,当前无人机载荷检测仍存在三方面局限性:一是无人机载荷检测数据集与统一评测设置不足,难以支撑可复现的横向比较;二是现有数据增强方法对载荷外观和复杂场景变化的扩展能力有限,生成样本的语义与标注一致性仍需加强;三是现有YOLO改进方法对载荷目标的弱纹理、强背景干扰和轻量化部署需求考虑不足。围绕上述问题,主要贡献如下:

(1) 面向反无人机威胁评估需求,针对现有研究多聚焦无人机本体检测且载荷检测级标注数据稀缺的问题,构建并标注一个无人机载荷可见光检测数据集,提供统一的数据划分方案与评测设置;

(2) 提出一种生成式合成数据增强方法,通过生成与提取无人机载荷前景,并构建生成式背景库进行可控融合,实现训练样本的低成本扩增,从而提升模型对复杂背景与遮挡干扰的适应能力;

(3) 提出面向无人机载荷检测任务的 YOLOv11 改进模型。在骨干网络高层用 SimSPPF 替换 SPPF, 并在 C2f 中引入 RepConv 模块, 在不增加推理参数量且计算量仅略微增加的前提下, 增强特征表达与定位稳定性, 并提升检测性能。

1 数据增强与模型改进

1.1 数据集构建

本文所使用的原始图像数据主要来源于无人机飞行视频抽帧、网络图像搜集与公开数据集筛选, 以兼顾真实性与多样性。公开视频素材覆盖开阔天空、城市建筑群、山区林地及战场等场景, 并包含了不同高度、姿态及速度变化。网络图像以“无人机挂载”、“无人机载荷”等关键词搜索获取, 并按清晰度、机体完整性与载荷可辨识性剔除模糊与重复样本; 同时从 Anti-UAV 等公开数据集中补充样本。最终保留 5000 张图像, 按 8:1:1 并采用分层策略划分训练、验证与测试集, 其规模与目标尺寸分布统计见表 1。训练集、验证集与测试集分别包含 4000、500 与 500 张图像; 全数据集共标注载荷目标实例 4181 个。按统一的尺寸划分标准统计, 目标尺度分布以中目标为主, 共计 2451 个, 占比为 58.62%; 小目标与大目标分别为 992 个, 占比 23.73% 和 738 个, 占比 17.65%。表明本任务以中尺度目标为主, 同时包含一定比例的小目标与大目标, 为后续鲁棒性评估提供了必要覆盖。

表 1 目标尺寸分布表

Table 1 Target Size Distribution Table

	图像数	目标数	小目标	中目标	大目标
Train	4000	3363	800	1977	586
Val	500	396	87	231	78
Test	500	422	105	243	74
Total	5000	4181	992	2451	738

图 1 展示了数据集集中的部分样本图像, 涵盖开阔天空、城市建筑群、山区林地等多种拍摄场景, 以及不同型号无人机与各类载荷的形态。数据集中图像包含丰富的背景多样性与目标姿态变化, 能够为模型训练提供充足的场景覆盖与外观变化。




图 1 无人机载荷样本示例

Fig.1 Drone payload sample example

为反映真实反无人机场景中的主要检测难点, 进一步从数据层面对典型困难因素进行了保留与覆盖, 如图 2, 主要体现在以下三类挑战样本: (1) 极小目标: 载荷目标在图像中占比极低, 像素尺度接近或小于 32×32 , 细粒度纹理信息不足, 模型在特征下采样过程中更容易出现目标信息丢失, 导致漏检风险上升。

(2) 遮挡与重叠: 载荷被机身遮挡或与机体结构重叠, 导致可见区域不足, 目标边界与语义特征不完整, 易引发定位偏移或误检。(3) 低光照: 在低照度或逆光条件下, 载荷与背景对比度降低, 目标边缘弱化, 模型更易受到背景纹理干扰, 出现误检与漏检。



图 2 典型挑战性样本示例

Fig.2 Typical challenging sample example

为扩充训练样本规模并提升训练分布的丰富性, 在训练集上引入 Copy-Paste 增强、几何增强以及所

提出的生成式合成增强（具体原理见 1.2 节）三种增强方法进行扩充。为保证实验的客观性与可比性，增强样本仅用于训练集扩充，验证集与测试集均保持真实数据不变。同时，为降低生成样本噪声对模型训练的干扰，对合成数据实施严格的质量控制：首先通过规则过滤，剔除载荷不可辨识、前景结构异常、边界漂浮及存在明显生成伪影的样本；随后通过人工抽检，进一步清除尺度失调、光照方向矛盾等不符合物理一致性的样本。此外，对通过筛选的合成样本进行比例约束与随机混合，避免分布偏移。生成式合成增强样本示例如图 3 所示。



图 3 生成式合成增强样本示例

Fig.3 Generative synthetic augmented samples example

最终，通过三种增强方式的联合使用，数据集样本总量从原始的 5000 张扩充至 6179 张图像。其中，Copy-Paste 增强方法扩充样本 208 张，几何增强方法扩充样本 131 张，生成式合成数据增强方法扩充样本

840 张。该数据集共包含载荷样本 5322 个，按目标尺度划分：小目标 1090 个、中目标 3013 个、大目标 1219 个。为保证模型训练的有效性与数据分布的合理性，上述扩充得到的 1179 个增强样本全部纳入训练集，从而进一步丰富模型对复杂场景的适应能力。

1.2 生成式合成数据增强方法

生成式数据增强通过学习真实样本的数据分布，生成具有新场景背景或新成像条件的合成样本，以扩展训练数据分布并提升模型泛化能力。相比传统几何变换和颜色扰动等增强方式，生成式增强能够补充原始数据中缺失的目标形态和场景变化，更适用于样本数量有限和背景干扰强的检测任务。在无人机载荷检测中，载荷目标通常尺度较小、形态多样，并与无人机本体存在特定挂载关系；同时，检测场景受背景纹理、光照变化和成像条件影响较大，真实样本难以充分覆盖不同机型、载荷类型、飞行姿态和复杂环境组合。因此，引入生成式数据增强方法，有助于构建与真实样本互补的训练数据，为提升模型在复杂场景下的检测性能提供数据支撑。

本文提出一种生成式合成数据增强方法。该方法在无需额外人工采集数据的前提下，能够显著提升样本多样性，有效缓解真实数据在场景类型、光照条件及背景纹理等维度分布不均衡的问题，生成式合成数据增强框架见图 4。




图4 生成式合成数据增强框架

Fig.4 Generative Synthetic Data Augmentation Framework

该方法的增强流程整体可划分为前景生成、背景生成与融合标注三个连贯阶段。首先，前景生成以携带载荷无人机为核心，利用生成模型合成包含机体与载荷结构的前景图像，覆盖不同机型外观、载荷形态及俯仰、滚转、偏航等多姿态变化，同时剔除结构畸变、载荷辨识性差及语义不一致的样本，保证任务语义一致性；其次，背景生成则面向易干扰的复杂检测环境，构建城市建筑、山区林地及烟尘战场等多类型背景，并在纹理复杂度、明暗变化、逆光、色温和薄雾阴天等光照与天气条件上进行扩展，提升模型跨场景迁移鲁棒性；最后，在融合合成与标注阶段，将生成的前景目标按预设尺度与位置叠加至背景图像，通过边缘平滑、亮度色调匹配、适度模糊与噪声注入等约束弱化拼接痕迹，使合成图像更贴近真实成像效果，同时利用前景几何参数自动生成目标边界框，实现合成数据的闭环自动标注，避免额外人工标注开销。其合成图像的过程可表示为

$$I_{\text{syn}} = \alpha \cdot I_{\text{fg}} + (1 - \alpha) \cdot I_{\text{bg}} \quad (1)$$

其中， I_{fg} 为前景图像， I_{bg} 为背景图像， α 为用于边缘平滑融合的前景透明度。

1.3 YOLOv11 模型改进

针对无人机载荷目标纹理弱、尺度变化大及复杂背景干扰等问题，本文在保持 YOLOv11 主体架构不变的前提下，对骨干网络的高层上下文聚合与局部特征提取模块进行针对性改进，如图 5 所示。改进重点在于增强高层语义表达与局部细节刻画能力，同时兼顾端侧实时部署需求。

在高层上下文聚合部分，采用 SimSPPF 替换原始 SPPF 模块。SimSPPF 使用 CBR 结构 (Conv+BN+ReLU) 替代原 CBS 结构 (Conv+BN+SiLU)，以更简洁的计算实现多尺度语义信息聚合，在降低激活计算开销的同时增强特征响应的稀疏性，有助于模型在复杂背景中突出载荷相关特征，提升检测稳定性。在局部特征提取部分，将 C2f 模块中 Bottleneck 的 3×3 卷积替换为 RepConv，构建 C2f-Rep。RepConv 在训练阶段采用多分支结构增强特征学习，推理时通过结构重参数化融合为单分支卷积，不增加额外计算开销。该设计提升了模型对弱纹理载荷目标的局部细节建模能力和定位稳定性。




图5 改进模型结构图

Fig.5 The improved model structure diagram

1.3.1 SimSPPF 模块

YOLOv11 在骨干网络高层采用空间金字塔快速池化模块 SPPF 来扩大感受野、增强上下文建模能力。该模块通过串联最大池化近似获得多尺度响应,能够为检测头提供更丰富的全局信息。尽管 SPPF 多尺度聚合能力较好,但其 CBS 结构中的 SiLU 激活包含 sigmoid 运算,增加了计算负担,影响实时检测的部署效率与训练收敛稳定性。

本文引入简化空间金字塔快速池化模块 SimSPPF。该模块重新设计了 SPPF 内部的卷积单元,将原有的 CBS 结构替换为由卷积、批归一化和 ReLU 激活函数组成的 CBR 结构。与 SiLU 相比,ReLU 的计算形式更加简洁,能够减少激活函数的计算复杂度,并降低高频推理过程中由非线性函数带来的额外延迟。同时,ReLU 的单侧线性响应有助于增强有效梯度传递,使高层语义特征在训练阶段获得更稳定的优化过程。SPPF 与 SimSPPF 的结构对比如图 6 所示。

SimSPPF 对无人机载荷检测任务的适用性主要体现在特征表达效率与目标判别能力两个方面。一方面,CBR 结构降低了高层上下文聚合过程中的激活计算开销,使模型在处理可见光图像时能够以更轻量化的方式完成多尺度语义信息整合,有利于满足无人机载荷检测对实时性的要求。




图6 SPPF 与 SimSPPF 的结构对比图

Fig.6 Architectural Comparison between SPPF and SimSPPF

另一方面,ReLU 激活能够增强特征响应的稀疏性,使网络在复杂背景中更加突出与无人机机体和载荷区域相关的有效特征,减少建筑纹理、地物边缘和光照变化等背景因素对高层语义表达的干扰。对于载荷目标边界细节不明显且易与背景混淆的情况,SimSPPF 能够提供更稳定的上下文特征支持,从而提升模型对载荷区域的定位能力和类别判别能力。

1.3.2 RepConv 模块

C2f 是 YOLOv11 骨干网络中的关键特征提取模块。该模块将输入特征划分为不同分支,一部分直接参与融合,另一部分经 Bottleneck 进行深层变换,最终将不同层级的中间特征拼接融合,在较低计算开销

下提升特征表达效率。然而,原始 C2f 中 Bottleneck 主要依赖单分支 3×3 CBS 卷积 (Conv+BN+SiLU),其部署效率较高,但训练阶段的表征形式相对受限。对于无人机载荷检测任务,载荷目标占比小、局部纹理弱且边界细节不明显,单一 3×3 卷积难以充分刻画机体、挂载部位与载荷之间的局部结构差异,也容易受到复杂背景边缘和相似纹理的干扰,影响定位稳定性与误检抑制能力。




图7 RepConv 模块的结构图

Fig.7 Architectural Diagram of the RepConv Module

本方法将 Bottleneck 中的 3×3 CBS 卷积替换为 RepConv 模块,构建 C2f-Rep。RepConv 模块结构如图 7 所示。RepConv 在训练阶段构造多分支特征学习路径,包括 3×3 卷积分支、 1×1 卷积分支以及在维度匹配条件下的恒等映射分支,使网络获得更充分的特征表达能力。在推理阶段,RepConv 通过批归一化融合和卷积核等效变换将多分支参数合并为单一 3×3 卷积核,因此 C2f-Rep 部署时仍保持单分支形式,不增加推理计算开销。与原始 C2f 相比,C2f-Rep 的优势主要体现在三个方面。首先,多分支训练机制增强了 Bottleneck 对局部细节和边缘结构的刻画能力,提升了对弱纹理载荷区域的识别效果。其次, 1×1 卷积分支补充了通道间信息交互,使网络更有效地整合机体、挂载部位与载荷之间的关联特征。最后,结构重参数化保证了训练增强与部署简化的一致性,在提升检测精度的同时保持较低的推理开销。

2 实验与结果分析

2.1 实验设置

本节实验基于构建的无人机载荷检测数据集进行,数据集划分及统计信息已在 1.1 节详述。所有实验均在相同硬件环境下完成,具体配置如表 2 所示。实验具体的训练参数设置为:训练轮数(epochs)为 150,批大小(batch size)为 8,数据加载线程数(workers)为 4。采用 AdamW 优化器,基础学习率(lr)为 0.0001,权重衰减为 0.0001。

表 2 实验环境参数设置

Table 2 Experimental Environment Parameter Settings

配置项	参数
操作系统	Windows 11
Python 版本	3.8
深度学习框架	PyTorch 2.0.1
CUDA	11.8
CPU	Intel(R)Core(TM) i7-13650HX
GPU	NVIDIA GeForce RTX 4050
显存大小	6 GB
内存大小	16 GB

2.2 评估指标

为充分验证所提方法在载荷检测任务中的有效性,本文采用的评估指标包括:精确率 (Precision, P)、召回率 (Recall, R)、平均精度均值 ($mAP_{@0.5}$)、多阈值平均精度 ($mAP_{@0.5:0.95}$)、模型参数量 (Params)、计算复杂度 (GFLOPs) 以及推理帧率 (FPS)。其中,精确率用于衡量模型预测的准确程度,其定义为模型预测为正类的样本中实际为正类的比例。公式如下:

$$Precision = \frac{TP}{TP + FP} \quad (2)$$

其中, TP 表示正确预测为正类的样本数, FP 表示错误预测为正类的样本数。

召回率则反映模型对真正类样本的检出能力,即实际为正类的样本中被正确预测的比例。公式如下:

$$Recall = \frac{TP}{TP + FN} \quad (3)$$

其中, FN 表示未被检出的正类样本数。

平均精度 (AP) 用于评价模型在单个类别上的识别效果,通过对不同召回率下的精确率进行积分 (即

PR 曲线下的面积) 得到。平均精度均值 (mAP) 则是对所有类别 AP 值取平均。本文主要采用 $mAP_{@0.5}$ 作为评价指标, 即 IoU 阈值设为 0.5 时各类别 AP 的均值:

$$mAP_{@0.5} = \frac{1}{N} \sum_{i=1}^N AP_i^{IoU=0.5} \quad (4)$$

其中, N 为类别总数, $AP_i^{IoU=0.5}$ 表示第 i 类在 IoU 阈值为 0.5 条件下的平均精度。该指标在 VisDrone2019、UAVDT 等数据集中被广泛使用, 具有良好的可解释性。

此外, $mAP_{@0.5:0.95}$ 遵循 COCO 评估标准, 即在 IoU 阈值从 0.5 到 0.95 共 10 个阈值下分别计算 AP, 再对所有类别和阈值取均值, 定义为:

$$mAP_{@0.5:0.95} = \frac{1}{N} \sum_{i=1}^N \frac{1}{10} \sum_{t=1}^{10} AP_i^{IoU=\theta_t} \quad (5)$$

其中, θ_t 取值为 0.5, 0.55, ..., 0.95。该指标更为严格, 能够综合评估模型在不同定位精度要求下的表现。

2.3 对比实验

2.3.1 数据增强效果对比

为进一步验证本文生成式合成数据增强方法相较于现有数据增强方法的有效性, 本文在 YOLOv11 模型与相同训练参数设置下, 选取 Copy-Paste 增强、神经风格迁移增强、Sim2Air 合成增强以及本文生成式合成数据增强方法开展对比实验。为保证实验的客观性与可比性, 各方法均生成 200 张增强图像并与 230 张原始图像共同构成样本规模, 随后按 350 张用于训练、80 张用于验证进行划分, 除增强策略外其余训练与评估设置保持一致。表 3 给出了不同数据增强方法的对比结果。

表 3 不同数据增强方法效果对比

Table 3 Comparison of Different Data Augmentation Methods

	P(%)	R(%)	mAP _{@0.5} (%)
Copy-Paste ^[27]	62.0	59.0	57.9
神经风格迁移 ^[28]	74.8	56.4	71.6
Sim2Air 合成增强 ^[29]	79.5	70.3	78.6
Ours	83.3	78.6	84.0

由表 3 可知, 所提方法在 P、R、 $mAP_{@0.5}$ 指标上均取得最高结果。相比之下, Copy-Paste 增强虽然能够增加目标出现位置与局部组合变化, 但对载荷目标外观多样性和成像条件变化的扩展能力有限; 神经风格迁移增强主要改变图像整体外观域, 对载荷小目标边界、挂载关系和标注一致性的改善有限; Sim2Air 合成增强能够引入无人机姿态、尺度、视角、光照和背景等变化, 在一定程度上提升训练样本多样性, 但其数据构建目标主要面向无人机本体检测, 对载荷区域结构、挂载关系和局部边界一致性的表达仍不够充分。相比之下, 本文生成式合成数据增强方法通过前景与背景生成、可控融合和自动标注, 能够更有针对性地构造符合载荷检测任务需求的训练样本, 因此对载荷检测性能提升更为显著。

2.3.2 数据增强后模型性能对比

本节通过对比实验验证方法的有效性, 验证内容包括数据增强策略带来的性能提升以及模型结构改进带来的精度与效率收益。为保证结论具有代表性, 本文选取目标检测领域五类典型算法作为对比对象, 涵盖经典单阶段检测模型 SSD、经典两阶段检测模型 Faster R-CNN、轻量化单阶段检测模型 YOLOv8 与 YOLOv11, 以及基于 Transformer 的端到端检测模型 RT-DETR; 同时将改进后的 YOLOv11 模型纳入对比。

在实验设置上, 各模型分别在两种训练数据配置下训练, 并在同一测试集上统一评估: 首先仅使用原始训练集完成训练与验证, 测试结果见表 4; 随后在保持验证集与测试集不变的前提下, 将增强样本仅用于扩充训练集并重新训练, 测试结果见表 5。与此同时, 在相同训练数据配置与相同训练超参数条件下, 对比 YOLOv11 与所提模型的性能差异, 以刻画模型改进带来的增益。除训练数据配置或模型结构差异外, 其余训练流程与超参数保持一致, 从而保证对比的公平性与结论的可靠性。

表 4 给出了各模型在原始数据集上的测试结果。总体来看, 各模型在 $mAP_{@0.5}$ 上均达到较高水平, 但在更严格的 $mAP_{@0.5:0.95}$ 以及召回率 R 上的差异更为明显, 说明在本任务中不仅要成功检出目标, 还要在载荷这类目标上获得更稳定的定位精度。YOLOv11 作

为当前 YOLO 系列中性能较优的基线, $mAP_{@0.5}$ 达到 93.0%, $mAP_{@0.5:0.95}$ 为 63.8%, 召回率为 91.0%; 而改进后的模型在 $mAP_{@0.5}$ 上为 92.9%, 与 YOLOv11 基本持平, 但在更严格的 $mAP_{@0.5:0.95}$ 上达到 64.1%, 较 YOLOv11 提升 0.3 个百分点, 同时精确率和召回率分别提升 2.2 和 0.5 个百分点。在保持相近基础精度的前提下, 通过 SimSPPF 与 RepConv 模块的引入, 增强了模型对载荷目标的特征提取与定位能力。YOLOv8

表 4 对比实验结果

Table 4 Comparison of experimental results

	P(%)	R(%)	$mAP_{@0.5}(\%)$	$mAP_{@0.5:0.95}(\%)$	Params (M)	GFLOPs	FPS
SSD	88.3	82.7	89.4	55.6	23.9	137.0	25.18
FRCNN	87.1	89.1	82.1	47.5	28.3	253.8	10.48
YOLOv8	88.7	89.1	90.4	60.1	25.9	39.5	71.03
YOLOv11	90.4	91.0	93.0	63.8	2.59	6.44	71.31
RT-DETR	91.5	89.8	91.3	59.6	76.4	259.3	70.40
Ours	92.6	91.5	92.9	64.1	2.59	7.04	71.85

从效率指标看, 在参数量上保持与 YOLOv11 相同, 计算量仅为 7.04 GFLOPs, 较 YOLOv11 的 6.44 GFLOPs 略有增加; 推理帧率达到 71.85 FPS, 与 YOLOv11 的 71.31 FPS 基本持平, 仍能满足实时检测需求。这一结果表明, 引入的 SimSPPF 模块通过 CBR 结构替换 CBS, 在略微增加计算量的同时提升了推理效率; 而 RepConv 模块在训练时采用多分支结构、推理时融合为单分支卷积, 在不增加推理参数量和计算

的整体表现较均衡, 但 $mAP_{@0.5:0.95}$ 为 60.1%, 与所提模型存在明显差距。RT-DETR 精确率最高, $mAP_{@0.5}$ 为 91.3%, $mAP_{@0.5:0.95}$ 为 59.6%, 均低于改进模型。SSD 的 $mAP_{@0.5}$ 为 89.4%, 但召回率仅 82.7%, 漏检问题明显; Faster R-CNN 的 $mAP_{@0.5}$ 与 $mAP_{@0.5:0.95}$ 均偏低, 其在当前数据分布与目标尺度特征下适配性不足。

量的前提下增强了特征表达, 最终实现了精度的提升与速度的优化。YOLOv8 同样具有较高的实时性 (71.03 FPS) 且计算量较低 (39.5 GFLOPs), 但其参数量 (25.9M) 远高于改进模型。RT-DETR 虽然帧率接近, 但参数量与计算量显著更高。SSD 与 Faster R-CNN 在实时性上均不满足反无人机场景的快速响应需求。综合精度与效率, 改进模型在原始数据集上即展现出优于主流模型的目标定位精度与推理速度。

表 5 数据增强后各模型性能对比

Table 5 Comparison of model performance after data augmentation

	P(%)	R(%)	$mAP_{@0.5}(\%)$	$mAP_{@0.5:0.95}(\%)$
SSD	96.1	+7.8	87.6	+4.9
FRCNN	94.9	+7.8	91.8	+2.7
YOLOv8	94.7	+6.0	91.5	+2.4
YOLOv11	94.6	+4.2	91.7	+0.7
RT-DETR	93.6	+2.1	91.6	+1.8
Ours	95.8	+3.2	92.1	+0.6

在引入数据增强后, 表 5 展示了各模型在同一测试集上的性能变化。可以看到, 增强对所有模型均带来一致且显著的收益, 表明提出的生成式合成数据增强方法能够有效扩充训练样本的规模与场景多样性, 从而提升模型在复杂背景、光照变化及遮挡等困难条件下的泛化能力。

从各模型的提升幅度来看, SSD 的 P、R、 $mAP_{@0.5}$ 与 $mAP_{@0.5:0.95}$ 分别提升 7.8、4.9、5.0 与 8.8 个百分点;

Faster R-CNN 分别提升 7.8、2.7、4.7 与 8.6 个百分点; YOLOv8 分别提升 6.0、2.4、4.8 与 6.1 个百分点; YOLOv11 分别提升 4.2、0.7、2.5 与 1.0 个百分点; RT-DETR 分别提升 2.1、1.8、2.9 与 2.8 个百分点; 改进模型分别提升 3.2、0.6、2.4 与 1.6 个百分点。整体上, $mAP_{@0.5:0.95}$ 的提升幅度在 SSD 与 Faster R-CNN 上尤为显著, 表明生成式合成数据增强不仅改善了检出率, 还显著增强了模型对载荷目标的定位精度。

从增强后的性能来看,改进模型在 $mAP_{@0.5:0.95}$ 上达到 65.7%,为所有模型最高,较增强前的 64.1%提升 1.6 个百分点;同时精确率与召回率分别达到 95.8%和 92.1%,在保持高检出的前提下进一步降低了误检。此外,改进模型在参数量和计算量基本不变的前提下,通过数据增强获得了稳定的精度提升,充分体现了生成式合成增强方法的高效性,显著提升模型对困难样本的适应能力。增强后 SSD 与 Faster RCNN 的 $mAP_{@0.5}$ 与 $mAP_{@0.5:0.95}$ 均有提升;RT-DETR 增强后各项指标亦有提升,但其高参数量与高计算量决定了部署成本仍然较高。YOLOv8 在增强后同样表现出较强的定位能力,但其参数量明显高于改进模型;YOLOv11 的参数量与改进模型相同,但其 $mAP_{@0.5:0.95}$ 低于改进模型,说明本文结构改进在不增加参数量的前提下进一步提升了定位精度。

需要强调的是,对比仅改变训练数据,不改变模型结构,增强不会引入任何额外推理开销;在实际应用中,数据增强不会增加模型推理阶段的参数量和计算量,可在不改变部署开销的前提下提升检测精度。综合增强前后结果,提出的生成式合成数据增强方法能够稳定提升各模型的检测精度与定位稳定性,其中改进模型在精度与效率之间取得了最优平衡,适合反无人机场景下对实时性与可靠性要求较高的需求。

2.4 消融实验

为全面验证引入的 SimSPPF 与 RepConv 两项改

进模块的有效性及其对模型性能的具体贡献,在数据增强后的数据集上设计逐级消融实验。消融实验采用控制变量法,以 YOLOv11 为基线模型,依次单独引入 SimSPPF、单独引入 RepConv,并评估二者联合使用时的协同增益。通过这种逐级对比,可以清晰揭示每个模块的独立作用及两者组合的互补效果。本节从检测精度(精确率 P、召回率 R、 $mAP_{@0.5}$ 、 $mAP_{@0.5:0.95}$)以及模型复杂度与效率(参数量 Params、计算量 GFLOPs、推理帧率 FPS)三个方面进行评估。实验结果如表 6 所示。

单独引入 SimSPPF 之后,改进后的模型计算量由 6.44GFLOPs 略增至 7.04 GFLOPs,帧率基本保持不变,精确率与召回率分别达到 94.9%和 91.8%, $mAP_{@0.5:0.95}$ 达到 64.9%。这是由于 SimSPPF 在保留 SPPF 多尺度上下文聚合路径的前提下,将卷积块中的激活函数由 SiLU 替换为 ReLU,降低了非线性计算与访存开销,使模型在维持检测能力的同时获得更稳定的训练收敛与推理效率。

单独引入 RepConv 时,模型参数量与计算量均未增加,仍为 2.59 M 和 6.44 GFLOPs,帧率与基线持平。在推理开销完全不变的前提下,精确率与召回率分别达到 95.6%和 92.0%, $mAP_{@0.5:0.95}$ 达到 65.6%,较基线显著提高。这是由于 RepConv 在训练阶段采用并行多分支结构,增强了网络对载荷这类小尺度、弱纹理目标的特征学习能力,而推理时通过参数融合将多分支等价折叠为单分支卷积,从而实现训练增强表达、部署保持轻量的设计目标。

表 6 消融实验结果

Table 6 Ablation experiment results

SimSPPF	RepConv	P(%)	R(%)	$mAP_{@0.5}(\%)$	$mAP_{@0.5:0.95}(\%)$	Params (M)	GFLOPs	FPS
		94.6	91.7	95.5	64.8	2.59	6.44	71.85
√		94.9	91.8	95.5	64.9	2.59	7.04	71.90
	√	95.6	92.0	95.4	65.6	2.59	6.44	71.81
√	√	95.8	92.1	95.3	65.7	2.59	7.04	71.81

SimSPPF 与 RepConv 联合使用时,模型获得最佳综合性能。最终模型的精确率达到 95.8%,召回率达到 92.1%,严格定位指标 $mAP_{@0.5:0.95}$ 达到 65.7%,参数量维持 2.59 M 不变,计算量仅小幅增加至 7.04 GFLOPs,帧率保持在 71.81 FPS。上述结果表明,SimSPPF 与 RepConv 具有良好互补性:SimSPPF 以极

小的计算代价优化了训练效率与检测稳定性,RepConv 则在不增加任何推理开销的前提下显著提升了定位精度;二者联合使用可在几乎不牺牲部署效能的条件下实现更优的精度与效率的平衡。

2.5 可视化分析

为进一步直观分析数据增强及模型结构改进对载

荷检测的影响, 本节进行可视化对比分析。不同于仅展示单次检测结果的方式, 本节将增强前后两种训练设置下的预测结果进行对照, 并进一步给出 baseline 与改进模型的对比, 观察模型的变化趋势与改进来源。

如图 8 所示, 图中给出了多种检测模型在同一测试图像上的检测结果对比, 其中上排为增强前训练得到的结果, 下排为增强后训练得到的结果。数据增强带来的变化具有一致性: 多数模型在增强后对载荷目标的响应更加稳定, 原本易漏检的目标更容易被检出, 漏检现象减少; 预测框与目标轮廓的贴合程度提高, 边界偏移减轻; 对背景纹理、机体局部结构等干扰区域的误检也得到一定抑制。与此同时, 不同检测框架

的受益侧重点有所不同。SSD 和 Faster R-CNN 等在增强前更容易出现漏检或误检, 增强后改观更为直观。而 YOLO 系列在增强后主要体现为预测框更加紧致、目标置信度更加稳定。在相同数据设置下, 与基线相比, 改进后的模型在遮挡区域附近的预测框通常表现出更好的贴合度与一致性, 并且对复杂背景纹理的误检更少。结果与表 4、表 5 中改进模型在 $mAP_{@0.5:0.95}$ 和精确率上优于 YOLOv11 的结果相吻合, 说明引入的 SimSPPF 与 RepConv 模块并不只是提升粗检出层面的 $mAP_{@0.5}$, 而是更侧重于改善困难样本中的高 IoU 定位稳定性与误检抑制能力, 从而在复杂场景下获得更加可靠的检测输出。



图 8 数据增强前后不同模型载荷检测结果可视化对比

Fig.8 Visualization comparison of payload detection results of different models before and after data augmentation

图 9 进一步从模型关注区域的角度解释数据增强与结构改进带来的性能变化。热力图的高响应区域反映了模型在判别过程中更依赖的视觉线索。对比可见, 增强后模型在载荷目标附近的响应更为集中, 背景纹理区域的零散响应有所减弱, 说明数据增强在一定程度上提升了模型对目标与背景判别线索的稳定性, 使模型不再过度依赖易混淆的背景纹理, 而是转向更具

判别力的载荷局部结构。与此同时, 与基线相比, 改进模型在载荷本体及边缘轮廓处往往呈现出更连续、更集中的高响应区域, 而对机体结构与背景细碎纹理的响应更弱, 这表明结构改进有助于提升模型对载荷细粒度特征的捕获能力, 并降低由遮挡与弱纹理导致的关注偏移。




图9 不同模型热力图对比

Fig.9 Comparison of heatmaps across different models




图10 极端样本检测结果

Fig.10 Results of extreme samples

尽管生成式合成数据增强与模型改进均提升了整体鲁棒性,但在极端小尺度与弱纹理条件下仍可能出现漏检或定位不稳定。图10展示了增强后改进模型在典型挑战样本上的检测结果:在图10(a)、图10(b)中,载荷目标像素面积接近或小于 32×32 ,细节纹理信息不足且易在特征下采样过程中丢失,仍可能导致漏检,说明极端小目标依旧是当前方法的边界场景之一;而图10(c)为背光条件下样本,载荷与背景对比度降低,但模型仍能完成检出,表明其对一定程度光照变化具备鲁棒性。图10(d)为局部遮挡的测试样本,即便目标主体被轻微遮挡、有效特征区域不完整,模型仍可稳定识别并定位出载荷目标,体现出对轻度遮挡场景的良好适应能力。同时也说明,该方法在目标特征不完全可见的复杂场景下,仍能保持较为可靠的检测性能。

参考文献:

- [1] SAMARAS S, DIAMANTIDOU E, ATALOGLOU D, et al. Deep learning on multi-sensor data for counter UAV applications: a systematic review[J]. Sensors, 2019, 19(22): 4837. <https://doi.org/10.3390/s19224837>

3 结束语

本研究构建并标注了一个面向可见光无人机载荷检测的数据集,原始数据集包含5000张经过标注的图像,覆盖极小目标、遮挡及低光照等典型挑战场景。在此基础上,提出了一种生成式合成数据增强方法,通过前景与背景的生成、可控融合与自动标注,有效扩充了训练样本的规模与场景多样性。结合Copy-Paste与几何增强,数据集总量扩充至6179张,增强样本全部用于训练。同时,针对复杂背景下载荷目标特征表征不足的问题,通过引入SimSPPF模块和RepConv模块对YOLOv11进行改进。实验结果表明,改进后的模型在参数量和计算量基本不增加的前提下取得了更高的检测精度,尤其提升了对小尺度、弱纹理和背景相似载荷目标的识别能力,进一步验证了所提模型改进在精度提升与实时部署之间的有效性。使用多类代表性检测模型开展的对照实验表明,所提数据增强策略能够稳定提升各模型的检测精度与定位稳定性,验证了数据集与增强方法在缓解数据稀缺、提升跨场景泛化能力方面的有效性。

然而,本文方法在小尺度与弱纹理条件下载荷目标的检测仍存在一定局限。此类样本中,载荷目标在图像中的像素占比较低,经过多次特征下采样后有效细节容易被削弱;同时,弱纹理目标本身缺乏明显的边缘、颜色和结构差异,当其与无人机机体、复杂背景或低对比度环境相互叠加时,目标区域与背景区域之间的判别边界更加模糊,容易导致漏检或定位不稳定。针对上述问题,后续研究可从样本覆盖、特征表达和结构设计等方面开展进一步探索:在数据层面,补充极小尺度、弱纹理和低对比度条件下的载荷样本,并结合生成式增强方法进行困难样本定向扩充;在特征层面,关注弱纹理区域的细节保持与局部判别信息增强;在结构层面,探索更适合小目标感知的浅层特征融合和高分辨率检测分支。后续将围绕上述方向继续开展研究,以进一步缓解极端小尺度与弱纹理条件下载荷目标的漏检问题。

- [2] PALLOTTA L, CLEMENTE C, RADDI A, et al. A feature-based approach for loaded/unloaded drones classification exploiting micro-Doppler signatures[C]//2020 IEEE Radar Conference (RadarConf20). Piscataway: IEEE, 2020: 1-6. <https://doi.org/10.1109/Rada-Conf2043947.2020.9266458>
- [3] IBRAHIM O A, SCIANCALEPORE S, DI PIETRO R. Noise2Weight: on detecting payload weight from drones acoustic emissions[J]. Future Generation Computer Systems, 2022, 134: 319-333. <https://doi.org/10.1016/j.future.2022.03.041>
- [4] SEIDALIYEVA U, ALDURAIBI M, ILIPBAYEVA L, et al. Deep residual neural network-based classification of loaded and unloaded UAV images[C]//2020 Fourth IEEE International Conference on Robotic Computing (IRC). Piscataway: IEEE, 2020: 465-469. <https://doi.org/10.1109/IRC.2020.00088>
- [5] MÜLLER T, WIDAK H, KOLLMANN M, et al. Drone detection, recognition, and assistance system for counter-UAV with VIS, radar, and radio sensors[C]//Automatic Target Recognition XXXII. Bellingham: SPIE, 2022, 12096: 94-108. <https://doi.org/10.1117/12.2619086>
- [6] SOMMER L, SPRAUL R. Deep learning based UAV payload recognition[C]//2023 IEEE International Conference on Acoustics, Speech, and Signal Processing Workshops (ICASSPW). Piscataway: IEEE, 2023: 1-5. <https://doi.org/10.1109/ICASSPW59220.2023.10193235>
- [7] MEHTA V, AZAD H, DADBOUD F, et al. Real-time UAV and payload detection and classification system using radar and camera sensor fusion[C]//2023 IEEE/AIAA 42nd Digital Avionics Systems Conference (DASC). Piscataway: IEEE, 2023: 1-6. <https://doi.org/10.1109/DASC58513.2023.10311246>
- [8] KABIR S, RIFTI I A, TABIB H M S, et al. SpectraSentinel: lightweight dual-stream real-time drone detection, tracking and payload identification[OL]. arXiv, 2025: arXiv:2507.22650[2026-05-26].
- [9] ZHAO X F, ZHANG W W, XIA Y T, et al. G-YOLO: a lightweight infrared aerial remote sensing target detection model for UAVs based on YOLOv8[J]. Drones, 2024, 8(9): 495. <https://doi.org/10.3390/drones8090495>
- [10] DU D W, ZHU P F, WEN L Y, et al. VisDrone-DET2019: the vision meets drone object detection in image challenge results[C]//2019 IEEE/CVF International Conference on Computer Vision Workshop (ICCVW). Piscataway: IEEE, 2019: 213-226. <https://doi.org/10.1109/ICCVW.2019.00030>
- [11] DU D W, QI Y K, YU H Y, et al. The unmanned aerial vehicle benchmark: object detection and tracking[C]//Proceedings of the European Conference on Computer Vision (ECCV). Cham: Springer, 2018: 370-386. https://doi.org/10.1007/978-3-030-01249-6_23
- [12] JIANG N, WANG K R, PENG X K, et al. Anti-UAV: a large-scale benchmark for vision-based UAV tracking[J]. IEEE Transactions on Multimedia, 2023, 25: 486-500. <https://doi.org/10.1109/TMM.2021.3128047>
- [13] YUAN S H, YANG Y Z, NGUYEN T H, et al. MMAUD: a comprehensive multi-modal anti-UAV dataset for modern miniature drone threats[C]//2024 IEEE International Conference on Robotics and Automation (ICRA). Piscataway: IEEE, 2024: 2745-2751. <https://doi.org/10.1109/ICRA57147.2024.10610957>
- [14] GENG W X, YI J F, LI N, et al. RCSD-UAV: an object detection dataset for unmanned aerial vehicles in realistic complex scenarios[J]. Engineering Applications of Artificial Intelligence, 2025, 151: 110748. <https://doi.org/10.1016/j.engappai.2025.110748>
- [15] ALIN A Y, KUSRINI, YUANA K A. Data augmentation method on drone object detection with YOLOv5 algorithm[C]//2023 Eighth International Conference on Informatics and Computing (ICIC). Piscataway: IEEE, 2023: 1-6. <https://doi.org/10.1109/>

ICIC60109.2023.10382123

- [16] JAIN S, SETH G, PARUTHI A, et al. Synthetic data augmentation for surface defect detection and classification using deep learning[J]. *Journal of Intelligent Manufacturing*, 2022, 33(4): 1007-1020. <https://doi.org/10.1007/s10845-020-01710-x>
- [17] FANG H Y, HAN B, ZHANG S, et al. Data augmentation for object detection via controllable diffusion models[C]//*Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*. Piscataway: IEEE, 2024: 1257-1266.
- [18] CAO J S, BAO W S, SHANG H X, et al. GCL-YOLO: a GhostConv-based lightweight YOLO network for UAV small object detection[J]. *Remote Sensing*, 2023, 15(20): 4932. <https://doi.org/10.3390/rs15204932>
- [19] ZHONG Z Y, YUN L J, CHENG F Y, et al. Light-YOLO: a lightweight and efficient YOLO-based deep learning model for mango detection[J]. *Agriculture*, 2024, 14(1): 140. <https://doi.org/10.3390/agriculture14010140>
- [20] LIU C J, ZHONG L, WANG J, et al. Grain-YOLO: an improved lightweight YOLOv8 and its Android deployment for rice grains detection[J]. *Computers and Electronics in Agriculture*, 2025, 237: 110757. <https://doi.org/10.1016/j.compag.2025.110757>
- [21] GUO Y, CHEN S Q, ZHAN R H, et al. LMSD-YOLO: a lightweight YOLO algorithm for multi-scale SAR ship detection[J]. *Remote Sensing*, 2022, 14(19): 4801. <https://doi.org/10.3390/rs14194801>
- [22] 周忠锬, 张扬, 张宇, 等. MCT-YOLO: 航拍视角下小目标检测算法[J]. *计算机工程与应用*, 2026, 62(8): 130-141. (ZHOU Z K, ZHANG Y, ZHANG Y, et al. MCT-YOLO: small object detection algorithm from aerial perspective[J]. *Computer Engineering and Applications*, 2026, 62(8): 130-141.) <https://doi.org/10.3778/j.issn.1002-8331.2509-0032>
- [23] 牛宏侠, 李朔, 侯涛, 等. MDQF-YOLO: 面向复杂环境的铁路异物检测算法[J]. *计算机工程与应用*, 2026, 62(8): 116-129. (NIU H X, LI S, HOU T, et al. MDQF-YOLO: railway foreign object detection algorithm for complex environments[J]. *Computer Engineering and Applications*, 2026, 62(8): 116-129.) <https://doi.org/10.3778/j.issn.1002-8331.2507-0211>
- [24] 汪兴, 韩志科, 黄晓辉, 等. RGE-YOLO: 下采样与注意力机制融合的缺陷检测方法[J]. *计算机工程与应用*, 2026, 62(8): 105-115. (WANG X, HAN Z K, HUANG X H, et al. RGE-YOLO: defect detection method combining downsampling and attention mechanism[J]. *Computer Engineering and Applications*, 2026, 62(8): 105-115.) <https://doi.org/10.3778/j.issn.1002-8331.2505-0255>
- [25] 郭家林, 曹云峰. 改进 YOLOv11s 的航拍小目标检测方法研究[J]. *计算机工程与应用*, 2026, 62(8): 80-92. (GUO J L, CAO Y F. Research on aerial small target detection method based on improved YOLOv11s[J]. *Computer Engineering and Applications*, 2026, 62(8): 80-92.) <https://doi.org/10.3778/j.issn.1002-8331.2507-0111>
- [26] DING X H, ZHANG X Y, MA N N, et al. RepVGG: making VGG-style ConvNets great again[C]//*Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. Piscataway: IEEE, 2021: 13733-13742. <https://doi.org/10.1109/CVPR46437.2021.01352>
- [27] GHIASI G, CUI Y, SRINIVAS A, et al. Simple copy-paste is a strong data augmentation method for instance segmentation[C]//*Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. Piscataway: IEEE, 2021: 2918-2928. <https://doi.org/10.1109/CVPR46437.2021.00294>
- [28] GATYS L A, ECKER A S, BETHGE M. Image style transfer using convolutional neural networks[C]//*Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. Piscataway: IEEE, 2016: 2414-2423. <https://doi.org/10.1109/CVPR.2016.265>
- [29] BARISIC A, PETRIC F, BOGDAN S. Sim2Air: synthetic aerial dataset for UAV monitoring[J]. *IEEE Robotics and Automation*

Letters, 2022, 7(2): 3757-3764. <https://doi.org/10.1109/LRA.2022.3147337>

