

基于行人检测与闭环阈值的二维激光 SLAM 方法

冉莹莹^{1,2}, 徐孝彬^{1,2*}, 陈子恒^{1,2}, 杨坚³, 骆敏舟^{1,2}¹河海大学机电工程学院, 江苏 常州 213200;²河海大学江苏省特种机器人技术重点实验室, 江苏 常州 213200;³扬州大学机械工程学院, 江苏 扬州 225009

摘要 针对室内动态场景下移动机器人同时定位与建图(SLAM)的定位与建图质量退化问题,提出一种融合多模态激光特征的行人检测与地图优化方法。首先,基于改进的自适应聚类算法实现单帧二维点云的准确分割,并通过多分辨率降采样构建3种尺度的特征表达;其次,融合激光几何特征与回波强度信息,构建多模态特征输入;在此基础上,设计多支路卷积神经网络(CNN)实现行人检测,并在单帧点云中予以剔除;针对后端优化环节,采用闭环阈值的图优化方法,降低图优化的计算开销;最后,构建人腿数据集并进行模型训练,行人检测准确率达到96.38%,相比随机森林检测方法提高5.63个百分点。建图实验结果表明,所构建的地图能有效消除动态物体的残留,提升建图质量。

关键词 动态场景;点云;多尺度;激光强度;卷积神经网络;闭环阈值

中图分类号 TP242

文献标志码 A

DOI: 10.3788/LOP251336

1 引言

近年来,服务机器人在室内日常生活中得到广泛应用,如家庭服务、室内清扫、货物运送等^[1-3]。服务机器人实现室内导航的前提是获取环境地图并完成自身定位,即同时定位与建图(SLAM)^[4-5]。二维激光雷达具有视野大、精度高和环境适应性强等优点,常作为室内机器人SLAM中感知环境的传感器,用于测量周围环境并确定机器人位姿。然而,二维激光雷达仅通过单条激光线束旋转扫描获取环境信息,数据维度少,感知信息有限。尽管室内多为结构化环境,但仍存在一些复杂场景容易导致机器人定位失效,例如对称环境、长走廊和大尺度空间等。此外,动态物体的存在也会影响机器人的正常工作,过往行人、移动桌椅等可能引发SLAM系统不稳定,表现为建图中出现错误特征或残影、定位时局部地图匹配失败、回环检测中地图不闭合等问题。目前,基于动态环境的视觉SLAM已有较好的研究基础,例如通过剔除动态特征点,利用剩余的稳定静态特征点进行稠密地图构建^[6]。DS-SLAM(Dynamic Semantic SLAM)、Dyna-SLAM和DLD-SLAM(Deep Learning-based Dynamic SLAM)均表现出良好性能,但这些方法的建立均基于光照条件良好的假设,在光线不足甚至黑暗环境中难以稳定运行。激光雷达不受光线影响,因此在室内SLAM中应用广

泛^[7]。二维激光雷达还具有数据量小的优势,激光SLAM对硬件要求较低,可部署于资源有限的平台。

二维激光的行人检测主要基于人体几何特征,其中对腿部点云的研究较为充分。Xavier等^[8]、Arras等^[9]和Leigh等^[10]分别设计了多维几何特征,采用机器学习算法识别人腿。ROS(Robot Operating System)中开源了“leg_detector package”检测器,该检测器基于上述几何特征,使用随机森林分类器实现单个腿簇的检测^[11]。王天玺等^[12-13]提出一种多尺度自适应随机森林算法,以应对雷达点云噪声及特征多尺度问题。除腿部外,人体躯干也被视为有效的几何特征:采用躯干与手臂构成的三圆模型可降低个体差异的影响^[14],以腰部为观测对象有助于缓解遮挡问题^[15]。为弥补单层扫描的局限,学界提出了多层激光雷达融合方案。Hashimoto等^[16]在轮椅上安装3层二维激光雷达,3层雷达独立进行检测与跟踪,利用多雷达间的互补性降低遮挡影响。双层机器人采用胸部-腿部双雷达配置,通过关联2个高度的特征构建人物模型,并利用体积估计人物位置^[17]。Mozos等^[18]构建分层检测架构,分别对腿部、躯干和头部训练AdaBoost分类器,并通过概率框架集成分类器输出。

随着深度学习的发展,点云目标检测逐渐从基于手工特征的方法转向端到端的深度学习。其中一种常见方法是将激光点云转换为图像,利用图像深度学习

收稿日期: 2025-05-28; 修回日期: 2025-06-26; 录用日期: 2025-07-07; 网络首发日期: 2025-07-11

基金项目: 江苏省自然科学基金面上项目(BK20231187)、江苏省科协青年人才托举工程(JSTJ-2024-029)

通信作者: *xxbtc@hhu.edu.cn

模型进行检测。Beyer等^[19-20]提出DROW(Distance Robust Wheelchair/Walker)检测器,将特定角度和距离阈值内的点云转换为图像,经卷积神经网络(CNN)提取特征后,通过投票机制与极大值抑制实现人腿检测,并在后续工作中将检测对象扩展至人、步行者和轮椅。Jia等^[21]在DROW框架基础上引入自回归模型与空间注意力机制,提出DR-SPAAM(Distance Robust Spatial Attention and Auto-Regressive Model)行人检测方法。为快速标注人腿点云标签,借助基于视觉的人体检测方法,结合雷达-相机标定结果自动生成点云训练标签^[22-23]。为增强对行走过程中腿部运动时间动态的学习,Efstathiou等^[24]将人腿点云转换为图像,并结合CNN与长短期记忆(LSTM)网络,提升对腿部遮挡的处理能力。张陆峰等^[25-26]将改进的YOLOX应用于行人检测,引入坐标注意力(CA)机制与自适应空间特征融合(ASFF)网络,增强了网络对人腿特征的关注能力和对多尺度特征的融合性能。由于PointNet对点云顺序变化不敏感,Zheng等^[27]提出不再将点云转换为图像,而是直接将mini-PointNet语义分割应用于行人检测,其精度优于DROW。

基于二维激光的行人检测已有一定的研究基础,但在动态场景下,机器人SLAM对行人检测的精度与鲁棒性要求更高。本文聚焦于机器人SLAM中的行人干扰问题,优化Cartographer框架,融合强度与几何

特征,结合深度学习技术实现行人精准检测。通过为 Cartographer 提供更纯净的点云数据,有效降低行人移动引发的定位误差,同时优化地图构建过程,减少无关环境特征与残影,提升 SLAM 系统的整体性能与可靠性。

2 基本原理

2.1 基于融合多模态特征的行人检测

二维激光雷达仅能扫描单一平面,人体头部、颈部和臀部等部位因身高、体型差异存在显著个体差异,而腿部形状与高度相对稳定,因此选取腿部作为检测特征。所用机器人平台的二维雷达扫描平面距离地面 20 cm,对应人体腿部位置。基于检测精度和实时性要求,采用聚类算法与深度学习相结合的方法进行检测。

提出的基于行人检测与闭环阈值的二维激光SLAM方法框架如图1所示,分为前端和后端。前端提取行人对应的点云,将其剔除后再进行点云与局部地图匹配,后端进行优化和地图更新。算法具体流程如下:机器人采集二维激光雷达数据,首先对点云进行聚类,过滤部分噪声点,通过CNN识别人腿,并将其从初始点云中去除;随后通过相关性扫描匹配(CSM)算法实现点云与地图的匹配;最后对当前帧点云进行闭环检测,在检测过程中通过闭环阈值选取节点,降低闭环优化节点数量,实现闭环优化和地图更新,提升激光SLAM的实时性能。




图1 基于行人检测与闭环阈值的二维激光SLAM方法

Fig. 1 Two-dimensional laser SLAM method based on pedestrian detection and closed-loop threshold

2.2 基于自适应阈值的欧氏聚类方法

在激光雷达点云的采集过程中,系统会不可避免地捕获到离群点噪声,且存在邻近物体点云相互接近的现象。点云簇的准确聚类是实现行人检测的前提,因此在开展检测工作前,需对点云进行预处理,主要包括去除离散噪声点和优化聚类点云2个环节。激光雷达采集的点云如图2所示,采用极坐标形式表示,蓝色和红色点分别表示2类点云,黄色点表示离群点。

激光雷达的相邻点云具有相同的角分辨率,采用相邻点欧氏聚类方法,通过逐点判断实现点云的粗分割。如图2所示,点云坐标系的原点为 O ,点 A 和 B 的

极坐标分别为 $(\rho_{i+1}, \theta_{i+1})$ 和 (ρ_i, θ_i) , 三角形 $\triangle OAB$ 的斜边长 d 可通过 ρ_i 和 ρ_{i+1} 计算:

$$d = \sqrt{\rho_i^2 + \rho_{i+1}^2 - 2\rho_i\rho_{i+1}\cos\lambda} \quad (1)$$

式中: ρ_i 和 ρ_{i+1} 分别为第 i 个和第 $i+1$ 个点与原点之间的测量距离; $\lambda = \theta_{i+1} - \theta_i$, θ_i 和 θ_{i+1} 分别为第 i 个和第 $i+1$ 个点与 x 轴正方向的夹角。

构建欧氏聚类的判断准则为

$$d < d_{\text{th}} + \alpha \rho_{i+1} \sin \lambda \quad (2)$$

式中: d_{th} 为设定的距离阈值; α 为自适应系数。 d 值根据距离值 ρ_{i+1} 进行自适应调整:若满足式(2),则认为属于同一簇点云;若不满足,则新创建一簇点云,直至

遍历所有点云。图 3 展示了 1 帧点云的自适应阈值聚类效果。




图 2 基于自适应阈值的欧氏聚类方法

Fig. 2 Euclidean clustering method based on adaptive threshold




图 3 自适应阈值聚类效果

Fig. 3 Adaptive threshold clustering effect

2.3 多尺度点云输入

随着深度学习的发展, CNN 在一维信号处理中的应用日益广泛, 例如在振动故障诊断、音频识别等领域, 通过引入 CNN 提升识别准确率, 取得了良好的效果^[28-31]。在二维激光雷达的行人检测研究中, 单一模态的距离信息存在局限性。所提算法扩展了信号维度, 采用 CNN, 通过构建多层卷积结构实现对行人的高精度识别。由于真实 SLAM 场景中机器人位置的实时变化和室内环境的复杂多变, 激光雷达采集的回波信号具有较大的不确定性, 仅使用 CNN 提取单一尺度的隐含特征难以获得理想的识别效果。为充分挖掘复杂环境中回波波形所隐含的特征信息, 可通过多尺度方法提取点云特征, 从而提高识别性能。

将输入信号分别进行 1/2 和 1/3 下采样, 与原始信号构成 3 路输入, 图 4 展示了多尺度点云对比。其中, $S=1$ 对应原始输入点云, $S=1/2$ 为 1/2 下采样后的




图 4 多尺度点云示意图

Fig. 4 Schematic diagram of multi-scale point cloud

输入点云, $S=1/3$ 为 1/3 下采样后的输入点云。

2.4 多模态特征融合

典型激光雷达可同时获取目标物体的距离、角度和反射强度。激光 SLAM 常通过距离和角度信息构建环境的几何模型, 这种基于几何特征的方法在动态场景中易受行人运动等干扰源影响。激光雷达的反射强度指其发射的激光脉冲照射到目标物体后反射回来的信号强度, 其不仅受激光雷达到物体表面的距离和相对于表面法线的入射角所构成的空间位姿的影响, 而且与目标物体表面的材质、粗糙度和颜色等因素相关, 即目标物体直接影响反射强度。因此, 反射强度可作为区分不同物体的重要特征值。

为利用反射激光强度值, 反光板、反光条等反射率较高的人工信标常用于辅助定位。Kurz 等^[32]在走廊等无结构化区域增加反光条, 将反光条检测与基于几何的扫描匹配相融合, 实现基于激光雷达的无死角定位。Khan 等^[33]利用激光强度与反射率和外部参数(距离、入射角)强相关的特性, 通过激光强度获取姿态信息, 并将其应用于 Hector SLAM。Wang 等^[34]采用无人机搭载三维雷达, 利用激光点云的几何和强度信息检测车辆, 具有大规模、高精度的识别能力, 并可识别树下的车辆。Kataoka 等^[35]通过 16 线雷达的强度特征实现水坑的定位。Yoshitaka 等^[36]提出“Intensity-ICP (Iterative Closest Point with Laser Reflection Intensity)”算法, 利用激光雷达的反射强度提升扫描匹配性能, 即使在几何匹配失效时, 也能依据目标材质的差异实现匹配。Guivant 等^[37]结合几何和反射强度信息进行里程估计, 引入强度值优化现有仅依赖几何关系的里程计估计公式, 并将基于强度值的闭环检测与后端优化相结合, 进一步提升系统性能。Carballo 等^[38]使用多层激光测距仪(LRF)传感器, 融合激光反射强度与几何特征进行人员检测。综上所述, 反射强度信息与几何信息的融合可作为精准检测行人的多维输入特征。

激光的反射强度 I_r 与回波功率 P 成正比, 可通过回波功率获取反射强度:

$$I_r = \frac{P_r}{A_{\text{receiver}}} \quad (3)$$

式中: A_{receiver} 为接受孔径的有效面积。

对于激光雷达, 激光回波方程^[39]为

$$P_r(t) = \frac{\pi D^2}{4R_r^2} \eta_{\text{atm}}^2 \eta_{\text{sys}} \iint E(x, y, R_r) P_i(t') f_i(\beta) \cos \beta dx dy \quad (4)$$

式中: R_r 为激光发射系统与目标之间的距离; D 为接收系统直径; η_{atm} 为大气透过系数(单程大气传输系数); η_{sys} 为系统光学通过率; $E(x, y, R_r)$ 为高斯光束照度; P_i 为脉冲激光发射功率; β 为入射角; t 和 t' 分别为回波信号的接收时间和激光脉冲的发射时间; $f_i(\beta)$ 为单位面元的双向反射分布函数。

当光束发散角较小时,沿 Z 轴传播的轴向距离 z 约等于 R_r ,且目标的纵深线度与探测距离相比可忽略,可认为横向强度分布仅是 x 和 y 的函数,与 z 无关:

$$E(x, y, z) = \frac{2P_t}{\pi\omega^2} \exp\left(-2\left(\frac{x^2 + y^2}{\omega^2}\right)\right) \quad (5)$$

式中: ω 为高斯光束在离坐标原点距离为 z 处的光斑半径。在式(4)中,参数 D 、 η_{atm} 、 η_{sys} 、 P_t 与激光器自身及其周围环境直接相关,本文认为同一激光雷达在稳定环境中工作,因此可视为固定参数。 β 、 R_r 、 x 、 y 为激光与目标之间的角度和距离,是几何特征的直接体现。

若目标为具有理想漫反射表面的朗伯体,其可各向同性地反射入射光^[40], $f_r(\beta)$ 的计算公式为

$$f_r(\beta) = \frac{\rho_1}{\pi} \quad (6)$$

式中: ρ_1 为目标半球反射率。

若目标为非朗伯体,其展现出各向异性^[41], $f_r(\beta)$ 的计算公式为

$$f_r(\beta) = \frac{A}{\cos^6 \beta} \exp\left(-\frac{\tan^2 \beta}{s^2}\right) + B \cos^m \beta \quad (7)$$

式中: A 为镜面反射幅度; B 为漫反射幅度; s 为表面斜率; m 为漫反射系数。式(6)中,目标半球反射率与目标物体的表面材质、颜色、形状、环境和激光雷达自身参数有关。式(7)中,等号右边第一项和第二项分别为

入射角的镜面反射分量和漫反射分量。其中:镜面反射幅度主要与目标物体表面的粗糙程度和颜色相关,受目标物体的表面反射率、形状和尺寸、环境光照条件、激光雷达自身的参数等影响;漫反射系数主要受激光到物体的距离、光线与物体的入射角和物体的材料等因素影响。在这 2 个公式中,激光雷达自身参数和环境属于固定不变参数,不对行人检测产生影响,形状、距离、入射角等动态时变参数可作为几何特征的影响要素,但不能单独用于判断目标是否为行人,而目标物体表面材质这一参数直接影响回波功率。相较于白墙、玻璃和金属等高反射介质,行人衣物及皮肤的表面反射特性存在显著差异,这种差异化的回波强度特征为基于激光雷达的行人检测提供了有效判别依据。反射强度与单位面积激光回波功率呈线性正相关,因此可将强度特征用于行人检测。

为更准确地检测行人,将几何特征和强度特征融合成多模态特征。激光雷达发射出等角度分布的有序激光,激光点云的距离值序列是人腿显著的几何特征,因此选取距离信息作为输入的第一维度。然而,室内环境复杂多变,仅依靠单一的距离信息识别行人容易出现误判。所采用的 OLEI VB1-25 雷达提供了激光强度,因此将其作为第二维度的信息。与此同时,由式(4)可知,距离的平方乘以光强与 $f_r(\beta)$ 成正相关,可提取物体材质相关信息,故选取该乘积作为第三维度的信息。图 5 展示了点云优化的流程。




图 5 点云优化流程

Fig. 5 Flowchart of point cloud optimization

2.5 端对端行人检测

为使网络能够提取更全面的特征并具备更强的表达能力,采用并行的多支路网络结构。每层由 3 个相同的卷积块组成,每个卷积块包含卷积层、ReLU 激活函数和最大池化层,经过融合层、全连接层和激活函数实现任务的分类。大尺寸卷积核适用于提取全局信息,小尺寸卷积核则更适合提取局部信息。鉴于人腿对应的点云数量有限,所有卷积核的尺寸统一设为 3×1 。此外,选用 ReLU 作为激活函数以引入非线性,并结合最大池化层实现特征降维,从而有效减少网络参数量,提升模型的计算效率和泛化能力。所提行人检测算法的整体框架如图 6 所示,首先提取激光的光强、距离、距离的平方和光强的乘积 3 种模态的信号,随后通过降采样生成 3 尺度点云,最后将其分别输入多支路 CNN,确定行人位置并实现去除。

2.6 基于闭环阈值的图优化方法

提出一种基于闭环阈值的图优化方法,有效降低建图过程的复杂度与运算时间。在每帧建图过程中,后端优化时间主要取决于位姿图优化队列中匹配约束的数量。节点与子图之间的约束包括:新生成的节点与所有已完成的子图构建约束进行优化;新生成的子图与所有历史节点构建约束进行优化。当出现第二种情况时,匹配数量与历史节点数量呈线性关系。然而在实际条件下,建图未失效时,相距较远的相邻节点不可能存在关联,因此设置闭环阈值以减少匹配次数。子图的位姿节点集合为 $\mathbf{p} = (\mathbf{p}_1, \mathbf{p}_2, \dots, \mathbf{p}_n)$,在图优化阶段,这些节点位姿需要被优化,且每个节点位姿的计算公式为

$$\mathbf{p}_i = (x_i^p, y_i^p, \theta_i^p)^T = ((t_i^p)^T, \theta_i^p)^T \quad (8)$$




图6 多模态多尺度点云的CNN架构

Fig. 6 CNN architecture for multi-modal multi-scale point cloud

式中: $\mathbf{t}_i^p = (x_i^p, y_i^p)^T$ 为机器人在地图中的位置坐标(即平移向量); θ_i^p 为机器人在地图中的方向角。当插入新的第 $n+1$ 个位姿时, 遍历前面所有位姿, 当距离和角度均小于设定阈值时, 保留当前匹配位姿:

$$\mathbf{p}_i \text{ reserved if } |\mathbf{t}_{ij}^p| < d_{th}^p, |\theta_{ij}^p| < \theta_{th}^p \quad (9)$$

式中: $\mathbf{t}_{ij}^p$ 为节点坐标 $\mathbf{p}_i$ 与 $\mathbf{p}_j$ 的相对距离; θ_{ij}^p 为节点坐标 $\mathbf{p}_i$ 与 $\mathbf{p}_j$ 之间的相对角度; d_{th}^p 为设定的闭环距离阈值; θ_{th}^p 为设定的闭环角度阈值。在回环检测过程中, 通过匹配估算得到节点坐标 $\mathbf{p}_i$ 与 $\mathbf{p}_j$ 之间的相对位姿, 作为观测值 $\mathbf{z}_{ij}$:

$$\mathbf{z}_{ij}(\mathbf{p}_i, \mathbf{p}_j) = (dx^p, dy^p, d\theta^p)^T = ((\mathbf{t}_{ij}^p)^T, \theta_{ij}^p)^T \quad (10)$$

而节点坐标 $\mathbf{p}_i$ 与 $\mathbf{p}_j$ 又可由里程计测量得到, 将预测值 $\mathbf{z}_{ij}'$ 定义为

$$\mathbf{z}_{ij}'(\mathbf{p}_i, \mathbf{p}_j) = \mathbf{P}_i^{-1} \mathbf{P}_j \quad (11)$$

式中: $\mathbf{P}_i, \mathbf{P}_j$ 分别为节点坐标 $\mathbf{p}_i, \mathbf{p}_j$ 对应的转换矩阵。

将误差函数定义为

$$\mathbf{e}_{ij}(\mathbf{p}_i, \mathbf{p}_j) = \mathbf{t}2\mathbf{v}(\mathbf{Z}_{ij}^{-1} \mathbf{Z}_{ij}') \quad (12)$$

式中: $\mathbf{Z}_{ij}, \mathbf{Z}_{ij}'$ 分别为 $\mathbf{z}_{ij}, \mathbf{z}_{ij}'$ 对应的转换矩阵; $\mathbf{t}2\mathbf{v}(\cdot)$ 为将转换矩阵转换为对应位姿的函数。

3 分析与讨论

3.1 实验平台及环境

为验证所提算法的效果, 设计3组实验, 分别对行人检测、行人剔除及建图效果进行验证。采用自主研发的室内移动机器人实验平台, 如图7所示, 其配备1个二维激光雷达(OLEI VB1-25)、1个深度相机(Realsense D435)、6个超声波测距传感器和1个惯性测量单元(IMU)。激光雷达的角分辨率为 0.2° , 测距范围为 $0.2 \sim 25.0$ m。以典型建筑空间为实验对象, 选取公共大厅(图8)与室内房间2类场景, 利用带有二维

激光雷达的实验平台自动采集点云并制作数据集。数据集中共计72710帧样本, 其中, 37360帧为包含人腿的正样本, 35350帧为不含人腿的负样本, 按照7:2:1的数量比将数据集划分为训练集、验证集和测试集, 图9为建图过程中手动标记的人腿点云。




图7 实验平台

Fig. 7 Experimental platform

3.2 行人检测算法验证

研究以行人检测为核心, 其检测精度直接决定了滤除动态目标干扰的效果, 也是SLAM系统获取高精度点云数据的重要前提。为系统评估网络模型的综合性能, 设计3组消融实验, 分别检测特征通道、点云尺度和CNN支路数这3个维度对性能的影响。具体评估工作从2个方面展开: 首先基于训练过程的准确率曲线与损失函数曲线, 揭示模型的动态收敛特性及泛化能力差异; 其次构建包含准确率、精确度、召回率和F1值的量化评估体系, 对模型性能进行横向对比分析。通过动态过程和静态指标的双重验证, 全面评估分类任务中的判别能力。实验所用计算机的CPU为



图8 实验场景

Fig. 8 Experimental scenario

Intel(R) Core(TM) i7-14700HX, 内存为 32 GB, 显卡为 NVIDIA GeForce RTX 4070 8 GB 版, 采用的 Python 版本为 3.11, CUDA 和 cuDNN 版本分别为 11.8 和 8.9.7, PyTorch 版本为 2.0.1。

精确度 P 表示模型预测为正类的结果中, 真正为正类的比例, 其计算公式为

$$P = \frac{N_{TP}}{N_{TP} + N_{FP}} \quad (13)$$

式中: N_{TP} 为模型预测为正类的结果中真正为正类的数量; N_{FP} 为模型预测为正类的结果中实际是负类的数量。

准确率为模型预测正确的结果占总样本的比例, 其计算公式为

$$A_{\text{Accuracy}} = \frac{N_{TP} + N_{TN}}{N_{TP} + N_{TN} + N_{FP} + N_{FN}} \quad (14)$$




图9 数据集标注。(a)室内数据集;(b)房间数据集

Fig. 9 Dataset annotation. (a) Indoor dataset; (b) room dataset

表1 光强的消融实验参数设置

Table 1 Experimental parameter settings for light intensity ablation

Model	CNN branch	Input		Conv1		Conv2		Conv3	
		Channel	Scale of point cloud	Kernel size	Kernel number	Kernel size	Kernel number	Kernel size	Kernel number
1	1	1	1	3	32	3	64	3	128
2	1	3	1	3	32	3	64	3	128
3	3	1	1, 1, 1	3	32	3	64	3	128
4	3	3	1, 1, 1	3	32	3	64	3	128

式中: A_{Accuracy} 为准确率的值; N_{TN} 为模型预测为负类的结果中真正为负类的数量; N_{FN} 为模型预测为负类的结果中实际为正类的数量。

召回率 R 表示实际为正类的样本中, 被模型正确预测为正类的比例, 其计算公式为

$$R = \frac{N_{TP}}{N_{TP} + N_{FN}} \quad (15)$$

F1 值是综合评价分类模型性能的指标, 常用于衡量分类模型的精确度和召回率的平衡情况, 其计算公式为

$$F_{F1} = \frac{2PR}{P + R} \quad (16)$$

3.2.1 特征通道消融实验

为评估激光强度对行人识别的影响, 在网络架构完全相同的情况下, 设计 2 组不同输入通道的对比实验, 分别为单输入通道 CNN 与 3 输入通道 CNN。

在单通道 CNN 中, 输入数据仅为激光雷达获取的距离值。3 通道 CNN 扩充了输入维度, 3 个通道的输入数据分别为激光雷达获取的距离值、激光雷达获取的光强值、距离值平方与光强值的乘积。

设计 2 组消融实验, 设置 2 组不同的输入数据尺度和 CNN 支路结构, 验证光强对行人检测的影响。第一组是在单尺度单支路情况下, 将输入从单通道扩展到 3 通道进行验证, 分别为模型 1 和模型 2。第二组在单尺度 3 支路情况下, 将输入从单通道扩展到 3 通道进行验证, 分别为模型 3 和模型 4。具体网络参数配置如表 1 所示。

图 10(a)、(b)分别展示了基于单尺度单支路 CNN 的不同输入通道的训练准确率对比曲线、训练损失对比曲线。结果表明,具有 3 种维度特征的模型 2 的准确率始终高于单维度特征的模型 1,且模型 2 的损失曲线下下降速度明显快于模型 1,最终收敛损失值也更低。




图 11(a)、(b)分别展示了基于单尺度 3 支路 CNN 的不同输入通道的训练准确率对比曲线、训练损失对比曲线,结果表明,2 类曲线趋势与图 10 非常相似。这 2 组实验表明,引入光强特征能够使模型在训练集中学习到更多有效特征,显著提升预测能力,且优化目标的收敛表现更好。




图 10 基于单尺度点云和单支路 CNN 的光强消融实验结果。(a)训练集准确率;(b)训练集损失

Fig. 10 Intensity ablation experimental results based on single-scale point cloud and single-branch CNN. (a) Accuracy of training set; (b) loss of training set





图 11 基于单尺度点云和 3 支路 CNN 的光强消融实验结果。(a)训练集准确率;(b)训练集损失

Fig. 11 Light intensity ablation experimental results based on single-scale point cloud and three-branch CNN. (a) Accuracy of training set; (b) loss of training set

依据准确率、精确度、召回率及 F1 值 4 项关键指标,对模型性能进行综合评估,结果如表 2 所示。在单尺度与单支路条件下,相较于单输入通道的模型 1,3 输入通道的模型 2 在 4 项指标上均有显著提升,准确率、精确度、召回率、F1 值分别提升 0.1225、0.0681、0.1515、0.1117。与此类似,在单尺度和 3 支路条件下,与单输入通道的模型 3 相比,3 输入通道的模型 4 的准

确率、精确度、召回率、F1 值分别提升 0.1275、0.0820、0.1498、0.1173。2 组对比实验中,光强作为唯一变量,结果验证了光强及其相关联特征对模型性能具有显著的优化作用。

3.2.2 多尺度点云消融实验

为同时利用点云的全局和局部特征,检测网络输入融合了 3 种尺度的点云数据,分别为原始点云、1/2

表 2 多模态消融实验的评价指标

Table 2 Evaluation indexes for multimodal ablation experiments

Index	Single-branch CNN and single-scale point cloud			Three-branch CNN and single-scale point cloud		
	Model 1 (single-channel)	Model 2 (three-channel)	Difference	Model 3 (single-channel)	Model 4 (three-channel)	Difference
Accuracy	0.8317	0.9542	0.1225	0.8331	0.9606	0.1275
Precision	0.8830	0.9511	0.0681	0.8800	0.9620	0.0820
Recall	0.8079	0.9594	0.1515	0.8120	0.9618	0.1498
F1 value	0.8435	0.9552	0.1117	0.8445	0.9618	0.1173

降采样点云和 1/3 降采样点云。设计 2 组消融实验: 第一组在单通道、3 支路的情况下, 对比分析使用原始点云与多尺度点云的效果, 分别采用模型 3 和模型 5; 第

二组在 3 通道、3 支路的情况下, 对比分析使用原始点云与多尺度点云的效果, 分别采用模型 4 和模型 6。具体网络参数配置如表 3 所示。

表 3 点云尺度的消融实验参数

Table 3 Ablation experimental parameters for point cloud scale

Model	CNN branch	Input		Conv1		Conv2		Conv3	
		Channel	Scale of point cloud	Kernel size	Kernel number	Kernel size	Kernel number	Kernel size	Kernel number
3	3	1	1, 1, 1	3	32	3	64	3	128
5	3	1	1, 1/2, 1/3	3	32	3	64	3	128
4	3	3	1, 1, 1	3	32	3	64	3	128
6	3	3	1, 1/2, 1/3	3	32	3	64	3	128

图 12(a)、(b) 分别展示了训练过程中模型 3 和模型 5 的准确率对比曲线、损失对比曲线。2 个模型均采用单通道输入和 3 支路 CNN。在模型的性能表现上,

融合了 3 尺度输入点云的模型 5 展现出显著优势, 其训练集准确率明显高于单尺度输入点云的模型 3, 对应的训练集损失也持续低于模型 3。




图 12 基于单通道 3 分支 CNN 的点云尺度消融实验结果。(a) 训练集准确率; (b) 训练集损失

Fig. 12 Point cloud scale ablation experimental results based on single-channel and three-branch CNN. (a) Accuracy of training set; (b) loss of training set

图 13(a)、(b) 分别展示了训练过程中模型 4 和模型 6 的准确率对比曲线、损失对比曲线, 2 个模型均采用 3 通道输入和 3 支路 CNN, 2 组模型的准确率曲线和损失曲线趋势相近。这 2 组实验可证明, 在输入特征较少的情况下, 引入不同尺度的点云输入能够让模型学习到更多特征, 3 尺度点云通过多层次信息, 使 CNN 同时获得细节和整体特征, 从而提升了分类准确率。

表 4 详细展示了 2 组模型的评估结果。在单输入通

道与 3 支路 CNN 的条件下, 与单尺度点云的模型 3 相比, 采用 3 尺度点云的模型 5 在 4 项核心指标上均有提升, 准确率、精确度、召回率、F1 值分别提升 0.0096、0.0066、0.0087、0.0078。在 3 输入通道与 3 支路 CNN 的条件下, 对比单尺度点云的模型 4, 3 尺度点云的模型 6 虽在召回率上微降 0.0008, 但准确率、精确度和 F1 值仍分别提升 0.0032、0.0065 和 0.0029。这 2 组对比实验充分表明, 扩展点云尺度可增强特征捕获能力, 从而提升模型性能。




图 13 基于 3 通道 3 分支 CNN 的点云尺度消融实验结果。(a) 训练集准确率; (b) 训练集损失

Fig. 13 Point cloud scale ablation experimental results based on three-channel and three-branch CNN. (a) Accuracy of training set; (b) loss of training set

表 4 点云尺度消融实验的评价指标

Table 4 Evaluation indexes for point cloud scale ablation experiments

Index	Single-channel and three-branch CNN			Three-channel and three-branch CNN		
	Model 3 (single-scale point cloud)	Model 5 (three-scale point cloud)	Difference	Model 4 (single-scale point cloud)	Model 6 (three-scale point cloud)	Difference
Accuracy	0.8331	0.8427	0.0096	0.9606	0.9638	0.0032
Precision	0.8800	0.8866	0.0066	0.9620	0.9685	0.0065
Recall	0.8120	0.8207	0.0087	0.9618	0.9610	-0.0008
F1 value	0.8445	0.8523	0.0078	0.9618	0.9647	0.0029

3.2.3 CNN 支路消融实验

CNN 支路是检测网络的关键结构,增加 CNN 支路数量能够使模型提取更丰富的特征,从而提升对目标的表达能力。多支路架构可并行处理特征,提高检测的准确性和鲁棒性,还可以通过特征融合增强特征的多样性,进而提升模型的检测性能。因此,设计 2 组消融实验进行验证:第一组在单通道单尺度条件下,对比分析单支路 CNN 和 3 支路 CNN 的网络

性能,网络分别为模型 1 和模型 3;第二组在 3 通道单尺度条件下,分析单支路 CNN 和 3 支路 CNN 的性能,网络分别为模型 2 和模型 4。模型参数设置如表 1 所示。

图 14(a)、(b)分别为训练过程中模型 1 和模型 3 的准确率对比曲线、损失对比曲线。在单通道和单尺度点云输入的条件下,经过多轮训练,3 支路 CNN 的准确率逐渐高于单 CNN 支路,且损失逐渐低于单支路 CNN。




图 14 单通道输入和单尺度点云的 CNN 分支消融实验结果。(a)训练集准确率;(b)训练集损失

Fig. 14 CNN branch ablation experimental results based on single-channel input and single-scale point cloud. (a) Accuracy of training set; (b) loss of training set

图 15(a)、(b)分别对应训练过程中模型 2 和模型 4 的准确率对比曲线、损失对比曲线。在多通道和单尺度点云输入的条件下,训练过程中,3 支路 CNN 的准确率始终高于单支路 CNN,损失始终低于单支路 CNN。2 组对比实验验证了多支路架构的有效性,证

实了 3 支路 CNN 通过特征融合与互补机制,实现了对单支路结构的性能提升。

2 组模型的评估结果如表 5 所示。在单通道输入与单尺度点云的约束下,与模型 1 相比,3 支路 CNN 的模型 3 精确度微降 0.0030,但准确率、召回率和 F1 值




图 15 3 通道输入和单尺度点云的 CNN 分支消融实验结果。(a)训练集准确率;(b)训练集损失

Fig. 15 CNN branch ablation experimental results based on three-channel input and single-scale point cloud. (a) Accuracy of training set; (b) loss of training set

分别提升了 0.0014、0.0041 和 0.0010。当输入通道扩展至三维时,3 支路的模型 4 相比单支路的模型 2 在各项指标上均有所提升,准确率、精确度、召回率和 F1 值分别提升了 0.0064、0.0109、0.0024 和 0.0066。实验结

果表明,支路数量的增加可使模型综合性能平均提升,特别是在高维输入条件下提升幅度较为明显,这验证了多支路架构可以通过层次化特征融合增强模型表征能力。

表 5 CNN 支路消融实验的评价指标

Table 5 Evaluation indexes for CNN branch ablation experiments

Index	Single-channel input and single-scale point cloud			Three-channel input and single-scale point cloud		
	Model 1 (single-branch CNN)	Model 3 (three-branch CNN)	Difference	Model 2 (single-branch CNN)	Model 4 (three-branch CNN)	Difference
Accuracy	0.8317	0.8331	0.0014	0.9542	0.9606	0.0064
Precision	0.8830	0.8800	-0.0030	0.9511	0.9620	0.0109
Recall	0.8079	0.8120	0.0041	0.9594	0.9618	0.0024
F1 value	0.8435	0.8445	0.0010	0.9552	0.9618	0.0066

3.2.4 与其他算法对比

通过系统化消融实验,从激光强度表征、多尺度点云特征融合及 CNN 支路拓扑结构 3 个维度验证了关键参数对模型性能的增益效应,最终确立了模型 6 作为行人检测的最优方案。为全面评估所提算法的先进性,选取随机森林和支持向量机(SVM)2 类广泛应用的经典机器学习算法进行对比。

所提算法在分类准确率上展现出显著优势,达到 96.38%,相较于随机森林(90.75%)和 SVM(51.62%) 2 类传统机器学习基准模型分别提升 5.63 百分点和

44.76 百分点。该对比结果不仅验证了所提算法架构的有效性,也展现出其在目标识别任务中的高水平,具有在动态环境中识别行人的实际应用价值。

3.3 建图实验

3.3.1 点云预处理

建图前,针对原始点云开展一系列预处理操作:首先采用基于自适应阈值的欧氏聚类法有效剔除离散噪声点,随后借助 CNN libtorch 库精准识别行人并剔除对应点云。图 16 通过 8 个场景的对比直观呈现了点云滤波效果,其中绿框圈定了行人对应的点云区域。




图 16 原始点云与行人滤除点云对比

Fig. 16 Comparison between raw point cloud and pedestrian-filtered point cloud

图 16(a)~(h)展示了室内大厅 8 个不同区域中的行人去除效果。实验结果表明,无论是在结构化场景(如门厅区域),还是在非结构化场景(如含大型圆柱体的开阔大堂),所提方法均能有效识别行人特征,并精准剔除对应点云,提升剩余点云数据的纯净度与相关性。该优化方法可为后续地图构建提供高质量、高精度的点云数据。

3.3.2 基于点云闭环检测匹配优化的建图实验

设定距离阈值为 0.5 m,角度阈值为 0.05 rad,优化前后节点约束匹配性能如图 17 所示。由图 17(a)可知,

在整个匹配过程中包含 28 个子图,优化前,每次子图生成时,当前插入节点需与此前所有子图节点进行匹配,运算时间随子图数量的增加而增加。通过设定阈值优化后,除了个别子图生成时运行时间略微超出优化前外,整体时间明显降低,尤其在最后一个子图生成中,从优化前的 1140.98 μs 降低至 227.37 μs 。由图 17(b)可知,优化前的匹配数量与子图呈线性关系,而设定阈值后呈非线性关系,整体匹配数量减少了 4/5。因此,通过引入闭环阈值可有效缩短后端匹配时间。




图 17 优化前后节点约束匹配性能。(a)节点约束匹配时间;(b)节点约束匹配数量

Fig. 17 Performances of node constraint matching before and after optimization. (a) Node constraint matching time; (b) node constraint matching quantity

图 18(a)展示了 Cartographer 使用原始点云构建的地图,而图 18(b)呈现了改进的 Cartographer 使用优化后的点云构建的地图。通过点云滤除和建图优化,原始点云地图中存在的未闭环区域(红色方框标注区

域)在优化后的地图中得到显著改善。实验结果表明:基于动态物体剔除算法与自适应闭环优化算法在复杂动态环境中具有鲁棒性。




图 18 优化前后地图对比。(a)Cartographer原始点云地图;(b)改进 Cartographer滤波点云地图

Fig. 18 Comparison of maps before and after opzimization. (a) Raw point cloud map by Cartographer; (b) filter point cloud map by optimized Cartographer

为测试优化算法在真实环境中的映射精度,如图 19 所示,选取 6 条直线,对比其真实值与测试值。根据表 6 所示结果,6 条线的最大绝对误差为 6.18 cm,平均绝对误差 (MAE) 为 3.32 cm,最大相对误差为 2.54%,平均相对误差为 1.25%,以上结果证明了所提改进算法具有良好的建图能力。

4 结 论

针对动态场景中行人对机器人 SLAM 造成干扰的问题,提出一种基于行人检测与闭环阈值的二维激光 SLAM 方法,通过优化 SLAM 算法的前端和后端




图 19 测试线条

Fig. 19 Test lines

表 6 优化算法建图误差

Table 6 Mapping errors of optimization algorithm

Line	True value /cm	Map value /cm	Absolute error /cm	Relative error /%
1	124.22	125.90	1.68	1.35
2	715.70	709.52	6.18	0.86
3	128.67	125.40	3.27	2.54
4	597.11	593.57	3.54	0.59
5	241.42	240.83	0.59	0.24
6	241.13	245.81	4.68	1.94

2 个步骤实现。首先,前端动态滤波通过自适应阈值滤波剔除离散噪点,拓展多维、多尺度的点云特征,并利用 CNN 实现行人点云的实时检测与剔除,检测准确率达到 96.38%。其次,引入基于闭环阈值的图优化算法,减少回环匹配次数,有效提升了地图构建的一致性与连贯性。在商业楼大厅的实验结果表明,所提算法在动态环境中也能较好地完成建图任务。

参 考 文 献

- [1] Shi Y L, Zhang W M, Yao Z, et al. Design of a hybrid indoor location system based on multi-sensor fusion for robot navigation[J]. *Sensors*, 2018, 18(10): 3581.
- [2] Zhang L, Li S, Zhang E Z, et al. Improved square root adaptive cubature Kalman filter[J]. *IET Signal Processing*, 2019, 13(7): 641-649.
- [3] Sun H, Yeop D, Hwang J H, et al. Mobile robot navigation under duct environment[C]//2011 IEEE Applied Imagery Pattern Recognition Workshop (AIPR), October 11-13, 2011, Washington, DC, USA. New York: IEEE Press, 2012: 1-3.
- [4] Wang C C, Thorpe C, Thrun S, et al. Simultaneous localization, mapping and moving object tracking[J]. *The International Journal of Robotics Research*, 2007, 26(9): 889-916.
- [5] Cadena C, Carlone L, Carrillo H, et al. Past, present, and future of simultaneous localization and mapping: toward the robust-perception age[J]. *IEEE Transactions on Robotics*, 2016, 32(6): 1309-1332.
- [6] 邓文轩, 党建武, 雍玖, 等. 基于目标检测和点线特征关联的动态 SLAM 算法[J]. *激光与光电子学进展*, 2025, 62(10): 1015007.
Deng W X, Dang J W, Yong J, et al. Dynamic SLAM algorithm based on object detection and point-line feature association[J]. *Laser & Optoelectronics Progress*, 2025, 62(10): 1015007.
- [7] 陈凯翔, 刘冉, 赵宾, 等. 基于直线端点方向匹配的激光定位方法[J]. *激光与光电子学进展*, 2024, 61(4): 0428010.
Chen K X, Liu R, Zhao B, et al. Laser positioning method based on line endpoint direction matching[J]. *Laser & Optoelectronics Progress*, 2024, 61(4): 0428010.
- [8] Xavier J, Pacheco M, Castro D, et al. Fast line, arc/circle and leg detection from laser scan data in a player driver[C]//Proceedings of the 2005 IEEE International Conference on Robotics and Automation, April 18-22, 2005, Barcelona, Spain. New York: IEEE Press, 2006: 3930-3935.
- [9] Arras K O, Mozos O M, Burgard W. Using boosted features for the detection of people in 2D range data[C]//Proceedings 2007 IEEE International Conference on Robotics and Automation, April 10-14, 2007, Rome, Italy. New York: IEEE Press, 2007: 3402-3407.
- [10] Leigh A, Pineau J, Olmedo N, et al. Person tracking and following with 2D laser scanners[C]//2015 IEEE International Conference on Robotics and Automation (ICRA), May 26-30, 2015, Seattle, WA, USA. New York: IEEE Press, 2015: 726-733.
- [11] David V L. ROS leg_detector package[EB/OL]. [2025-05-11]. https://wiki.ros.org/leg_detector.
- [12] 王天玺. 基于 2D 激光雷达的行人检测和追踪研究[D]. 北京: 北京邮电大学, 2021.
Wang T X. Research of people detection and tracking based on 2D laser scanner[D]. Beijing: Beijing University of Posts and Telecommunications, 2021.
- [13] Wang T X, Xue F, Zhou Y, et al. MARF: multiscale adaptive-switch random forest for leg detection with 2-D laser scanners[J]. *IEEE Transactions on Cybernetics*, 2023, 53(10): 6200-6210.
- [14] Glas D F, Miyashita T, Ishiguro H, et al. Laser tracking of human body motion using adaptive shape modeling [C]//2007 IEEE/RSJ International Conference on Intelligent Robots and Systems, October 29-November 2, 2007, San Diego, CA, USA. New York: IEEE Press, 2007: 602-608.
- [15] Jung E J, Lee J H, Yi B J, et al. Marathoner tracking algorithms for a high speed mobile robot[C]//2011 IEEE/RSJ International Conference on Intelligent Robots and Systems, September 25-30, 2011, San Francisco, CA, USA. New York: IEEE Press, 2011: 3595-3600.
- [16] Hashimoto M, Matsui Y, Takahashi K. People tracking with in-vehicle multi-laser range sensors[C]//SICE Annual Conference 2007, September 17-20, 2007, Takamatsu, Japan. New York: IEEE Press, 2008: 1851-1855.
- [17] Carballo A, Ohya A, Yuta S. Fusion of double layered multiple laser range finders for people detection from a mobile robot[C]//2008 IEEE International Conference on Multisensor Fusion and Integration for Intelligent Systems, August 20-22, 2008, Seoul, Korea, 2008, 677-682.
- [18] Mozos O M, Kurazume R, Hasegawa T. Multi-part people detection using 2D range data[J]. *International Journal of Social Robotics*, 2010, 2(1): 31-40.
- [19] Beyer L, Hermans A, Leibe B. DROW: real-time deep learning-based wheelchair detection in 2-D range data[J]. *IEEE Robotics and Automation Letters*, 2017, 2(2): 585-592.
- [20] Beyer L, Hermans A, Linder T, et al. Deep person detection in two-dimensional range data[J]. *IEEE Robotics and Automation Letters*, 2018, 3(3): 2726-

- 2733.
- [21] Jia D, Hermans A, Leibe B. DR-SPAAM: a spatial-attention and auto-regressive model for person detection in 2D range data[C]//2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), October 24-January 24, 2021, Las Vegas, NV, USA. New York: IEEE Press, 2021: 10270-10277.
- [22] Aguirre E, Garcia-Silvente M. Using a deep learning model on images to obtain a 2D laser people detector for a mobile robot[J]. International Journal of Computational Intelligence Systems, 2019, 12(2): 476-484.
- [23] Jia D, Steinweg M, Hermans A, et al. Self-supervised person detection in 2D range data using a calibrated camera[C]//2021 IEEE International Conference on Robotics and Automation (ICRA), May 30-June 5, 2021, Xi'an, China. New York: IEEE Press, 2021: 13301-13307.
- [24] Efstathiou D, Chalvatzaki G, Dometios A, et al. Deep leg tracking by detection and gait analysis in 2D range data for intelligent robotic assistants[C]//2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), September 27-October 1, 2021, Prague, Czech Republic. New York: IEEE Press, 2021: 2657-2662.
- [25] 张陆峰, 吕青, 张秋菊. 基于改进 YOLOX 的 2D 激光雷达行人检测技术研究[J]. 应用激光, 2023, 43(8): 112-121.
- Zhang L F, Lü Q, Zhang Q J. Research on 2D lidar pedestrian detection technology based on improved YOLOX[J]. Applied Laser, 2023, 43(8): 112-121.
- [26] 张陆峰. 基于隐形防护围栏的工业机器人安全技术研究[D]. 无锡: 江南大学, 2023.
- Zhang L F. Research on safety technology of industrial robot based on invisible protective fence[D]. Wuxi: Jiangnan University, 2023.
- [27] Zheng K S, Wu F, Chen X P. Laser-based people detection and obstacle avoidance for a hospital transport robot[J]. Sensors, 2021, 21(3): 961.
- [28] Zhang Q, Xiao J Y, Tian C W, et al. A robust deformed convolutional neural network (CNN) for image denoising[J]. CAAI Transactions on Intelligence Technology, 2023, 8(2): 331-342.
- [29] Peng D D, Wang H, Liu Z L, et al. Multibranch and multiscale CNN for fault diagnosis of wheelset bearings under strong noise and variable load condition[J]. IEEE Transactions on Industrial Informatics, 2020, 16(7): 4949-4960.
- [30] Wang H, Liu Z L, Peng D D, et al. Understanding and learning discriminant features based on multiattention 1DCNN for wheelset bearing fault diagnosis[J]. IEEE Transactions on Industrial Informatics, 2020, 16(9): 5735-5745.
- [31] Jasim H A, Ahmed S R, Ibrahim A A, et al. Classify bird species audio by augment convolutional neural network[C]//2022 International Congress on Human-Computer Interaction, Optimization and Robotic Applications (HORA), June 9-11, 2022, Ankara, Turkey. New York: IEEE Press, 2022: 1-6.
- [32] Kurz G, Scherer S A, Biber P, et al. When geometry is not enough: using reflector markers in lidar SLAM[C]//2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), October 23-27, 2022, Kyoto, Japan. New York: IEEE Press, 2022: 4880-4887.
- [33] Khan S, Wollherr D, Buss M. Modeling laser intensities for simultaneous localization and mapping[J]. IEEE Robotics and Automation Letters, 2016, 1(2): 692-699.
- [34] Wang L Y, Chen H X, You Z. Combining geometrical and intensity information to recognize vehicles from super-high density UAV-LiDAR point clouds[J]. Scientific Reports, 2024, 14: 25097.
- [35] Kataoka R, Suzuki R, Ji Y, et al. ICP-based SLAM using LiDAR intensity and near-infrared data[C]//2021 IEEE/SICE International Symposium on System Integration (SII), January 11-14, 2021, Iwaki, Fukushima, Japan. New York: IEEE Press, 2021: 100-104.
- [36] Yoshitaka H, Hirohiko K, Akihisa O, et al. Mobile robot localization and mapping by scan matching using laser reflection intensity of the SOKUIKI sensor[C]//IECON 2006-32nd Annual Conference on IEEE Industrial Electronics, November 6-10, 2006, Paris, France. New York: IEEE Press, 2007: 3018-3023.
- [37] Guivant J, Nebot E, Baiker S. Localization and map building using laser range sensors in outdoor applications[J]. Journal of Robotic Systems, 2000, 17(10): 565-583.
- [38] Carballo A, Ohya A, Yuta S. People detection using range and intensity data from multi-layered laser range finders[C]//2010 IEEE/RSJ International Conference on Intelligent Robots and Systems, October 18-22, 2010, Taipei, China. New York: IEEE Press, 2010: 5849-5854.
- [39] 徐孝彬. 脉冲激光引信近程周向探测技术研究[D]. 南京: 南京理工大学, 2017.
- Xu X B. Research on short-range circular-viewing detection technology of pulsed laser fuze[D]. Nanjing: Nanjing University of Science and Technology, 2017.
- [40] 黄凯, 赵君峤, 冯甜甜, 等. 激光雷达同时定位与建图中的局部几何信息表征与不确定度分析探究[J]. 中国激光, 2025, 52(6): 0600003.
- Huang K, Zhao J Q, Feng T T, et al. Local geometric information representation and uncertainty analysis in LiDAR SLAM[J]. Chinese Journal of Lasers, 2025, 52(6): 0600003.
- [41] Steinvall O. Effects of target shape and reflection on laser radar cross sections[J]. Applied Optics, 2000, 39(24): 4381-4391.

Two-Dimensional Laser SLAM Method Based on Pedestrian Detection and Closed-Loop Threshold

Ran Yingying^{1,2}, Xu Xiaobin^{1,*}, Chen Ziheng^{1,2}, Yang Jian³, Luo Minzhou^{1,2}

¹College of Mechanical & Electrical Engineering, Hohai University, Changzhou 213200, Jiangsu, China;

²Jiangsu Key Laboratory of Special Robot Technology, Hohai University, Changzhou 213200, Jiangsu, China;

³School of Mechanical Engineering, Yangzhou University, Yangzhou 225009, Jiangsu, China

Abstract

Objective In recent years, service robots have been widely deployed in indoor environments. Their reliable operation fundamentally depends on environmental mapping and self-localization, known as simultaneous localization and mapping (SLAM). Due to its wide field of view, high accuracy, and strong environmental adaptability, two-dimensional (2D) lidar is commonly employed for environmental perception in indoor robot SLAM. However, the inherently limited scanning range of 2D lidar renders 2D laser SLAM systems vulnerable to disturbances from dynamic objects. Passing pedestrians or moving furniture, such as chairs and tables, may introduce instability into SLAM, generating erroneous features or ghost artifacts in the constructed map, causing local map-matching failures due to localization errors, and resulting in incomplete map alignment during loop closure. To address the challenges of localization failure and degraded map quality in dynamic indoor environments, this paper proposes a 2D laser SLAM method based on pedestrian removal and adaptive-threshold graph optimization, thereby enhancing both mapping and localization performance in dynamic scenario.

Methods The method comprises two stages: front-end pedestrian filtering and back-end map optimization. In the front-end pedestrian filtering stage, an improved adaptive clustering algorithm segments the raw point cloud, eliminating stray noise points and refining the clustering results. The raw point cloud is then down-sampled by 1/2 and 1/3 to generate a multi-scale representation with three channels. Because laser echo intensity depends on target surface properties—such as material composition, surface roughness, and incident angle—geometric features are fused with intensity information to form geometric-intensity multi-modal point cloud inputs. Subsequently, a multi-branch convolutional neural network (CNN) architecture processes these multi-scale and multi-modal features, enabling real-time pedestrian detection and precise removal of the corresponding point clouds. In the back-end optimization phase, an adaptive threshold graph optimization strategy reduces unnecessary matching constraints by applying matching node thresholds, thereby enhancing computational efficiency during graph optimization.

Results and Discussions To evaluate the performance of the pedestrian detection model, a leg dataset is collected from point clouds gathered in two scenarios: public halls and rooms. Three ablation studies are conducted to assess the effects of feature modality, point cloud scale, and CNN branch configuration. Quantitative metrics including accuracy, precision, recall, and F1-score are employed. Results indicate that recognition accuracy increases with higher laser intensity (Table 2), higher point cloud resolution (Table 4), and more CNN branches (Table 5). The proposed model, which integrates multi-modal features, multi-scale representations, and a multi-branch CNN architecture, achieves 96.38% recognition accuracy, 5.63 percentage points higher than the random forest method.

To validate pedestrian removal effectiveness, point cloud elimination tests are performed in a dynamic commercial building hall. Experimental results demonstrate that the proposed algorithm effectively detects and removes pedestrian points during mapping (Fig. 16). To assess adaptive-threshold graph optimization, distance (0.5 m) and angle (0.05 rad) thresholds are used as constraints. With 28 sub-maps in the matching graph, the adaptive threshold reduces the total number of matches by 80% [Fig. 17(b)] and decreases optimization time from 1140.98 μ s to 227.37 μ s [Fig. 17(a)], significantly reducing computational load. By integrating front-end pedestrian point cloud filtering and back-end adaptive threshold graph optimization, the point clouds are processed and fed into the improved Cartographer to generate a map. The resulting map exhibits reduced ghost artifacts and improved loop closure performance (Fig. 18), confirming the robustness of the proposed 2D SLAM method in dynamic indoor environments.

Conclusions To mitigate pedestrian-induced interference in dynamic SLAM scenarios, this paper proposes a 2D laser SLAM method that integrates pedestrian detection with adaptive loop-closure thresholds, refining both the front-end and back-end of the SLAM pipeline. The front-end employs adaptive thresholding to eliminate stray noise points, expands multi-dimensional and multi-scale point cloud features, and achieves real-time detection and removal of pedestrian point clouds through CNNs with 96.38% accuracy. A graph optimization algorithm incorporating loop-closure thresholds is introduced to reduce the computational complexity of matching operations, significantly enhancing map consistency and coherence. Validation tests in a commercial building hall confirm the mapping robustness of the proposed algorithm in dynamic environments.

Key words dynamic scenario; point cloud; multi-scale; laser intensity; convolutional neural network; closed-loop threshold