

基于频域增强与注意力协同的光伏板红外缺陷检测

李思琦^{1*}, 肖军杰^{1,2,3}, 张 壮¹

(1. 北京印刷学院 机电工程学院, 北京 102600; 2. 数字化印刷装备北京市重点实验室(北京印刷学院), 北京 102600;

3. 印刷装备北京市高等学校工程研究中心(北京印刷学院), 北京 102600)

(*通信作者电子邮箱 13287315783@163.com)

摘 要:针对无人机(UAV)航拍光伏板红外图像中缺陷目标尺度小、特征弱和背景干扰强等导致的检测精度低和漏检率高问题,提出一种基于频域增强与注意力机制协同的检测网络——MFP-YOLOv11n。首先,采用多尺度组间交互融合(MSGI_FCM)模块,替换主干网络中的C3k2模块,增强多尺度特征提取与通道语义-空间信息融合能力;其次,在颈部网络中设计频率选择性残差注意力(FSRA)模块,在频域中强化目标区域和抑制背景噪声,提升小目标感知能力;最后,增加小目标检测头并融合并行分块感知注意力(PPA),从而增强模型的红外小目标定位能力。在PV-HSD-2025公开数据集上的实验结果表明,MFP-YOLOv11n的准确率、召回率和0.5交并比(IoU)下的平均精度均值(mAP)相较于基线模型YOLOv11n分别提升了6.3、7.8和7.0个百分点,且参数量与计算量处于合理范围。

关键词:光伏板;红外图像;YOLOv11n;小目标检测;注意力协同

中图分类号:TP391.41 **文献标志码:**A

Infrared defect detection for photovoltaic panels based on frequency-domain enhancement and attention collaboration

LI Siqi^{1*}, XIAO Junjie^{1,2,3}, ZHANG Zhuang¹

(1. School of Mechanical and Electrical Engineering, Beijing Institute of Graphic Communication, Beijing 102600, China;

2. Beijing Key Laboratory of Digital Printing Equipment (Beijing Institute of Graphic Communication), Beijing 102600, China;

3. Beijing Higher Institute Research Center of Printing Equipment (Beijing Institute of Graphic Communication), Beijing 102600, China)

Abstract: To solve the problems of low detection precision and high missed detection rate caused by the small scale, weak features, and strong background interference of defect objects in infrared images of photovoltaic panels captured by Unmanned Aerial Vehicles (UAVs), a detection network — MFP-YOLOv11n based on frequency-domain enhancement and attention mechanism collaboration was proposed. First, a Multi-Scale Group Interaction_Feature Complementary Mapping (MSGI_FCM) module was adopted to replace the C3k2 module in the backbone network, which enhanced the abilities of multi-scale feature extraction and channel semantic-spatial information fusion. Then, a Frequency-Selective Residual Attention (FSRA) module was designed in the neck network, which strengthened the object area and suppressed background noise in the frequency domain, thereby improving the model's perception ability of small objects. Finally, a small object detection head was added and the Parallelized Patch-aware Attention (PPA) was fused, thereby improving the model's infrared small target localization ability. Experimental results show that MFP-YOLOv11n achieves improvements of 6.3, 7.8, and 7.0 percentage points in precision, recall, and mean Average Precision (mAP) with IoU (Intersection over Union) of 0.5, respectively, on the PV-HSD-2025 public dataset compared to the baseline model YOLOv11n, while maintaining parameters and computational load within a reasonable range.

Key words: photovoltaic panel; infrared image; YOLOv11n; small object detection; attention collaboration

0 引言

当前,全球能源结构加速向可再生能源转型,太阳能光伏发电作为清洁能源的核心技术之一,对推动“双碳”目标的实现具有重要意义。作为能量转换系统的关键部件,光伏板的转换性能与表面质量直接关系到整个系统的发电效率与运维安全。然而,在生产制造、交通运输及长期运行过程中,光伏板存在易出现热斑、微裂纹等缺陷,容易造成发电效率下降^[1],严重时可导致电池局部烧毁形成暗斑、焊点熔化等永久性损坏,甚至造成整个太阳能组件的报废或重大火灾。因此,及时、快速地检测光伏组件局部热斑区域成为一项重要的工作环节^[2]。红外热成像技术通过精准捕捉组件表面温度分布,实现光伏板缺陷检测识别,具有高效、非接触式等特点,尤其在热斑异常诊断中具有独特优势,有效弥补了传统检测方式的不足。

目前,基于传统机器视觉的缺陷检测方法和基于深度学习的缺陷检测算法是光伏板缺陷检测的两个主要方法,后者在特征提取方面具有更强的能力,可以利用大量的数据样本来获得更深层次的特征,更准确和高效地表示数据样本所包含的信息^[3]。在技术架构方面,目标检测算法可以分为两阶段目标检测和单阶段目

标检测:前者包括R-CNN(Regions with Convolutional Neural Network)^[4]、Faster-RCNN^[5]等,检测精度较高,但它具有复杂的网络结构会导致检测效率偏低;后者包括YOLO^[6]、SSD(Single Shot multiBox Detector)^[7]等,在速度与精度之间取得了更好平衡,尤其YOLO系列算法因具有优异的性能,成为光伏板缺陷检测的重要工具。刘承毅等^[8]通过添加DnBlock降噪模块到YOLOv7主干网络,提高了模型的检测精度和降噪能力。李冰等^[9]基于CSWin Transformer构建了高效路径聚合网络(Efficient Path Aggregation Network,EPAN),结合视觉自注意力机制改进YOLOv7,有效解决了航拍光伏图像复杂背景下小目标缺陷漏检的问题。韩涛等^[10]通过引入通道注意力机制(Squeeze-and-Excitation Attention,SEAttention),并重构YOLOv11n检测头,提高了模型的检测精度。刘巧等^[11]基于YOLOv11n设计了高效主干网络Rep-HGNetV2,构建了一个双向特征金字塔网络(Bidirectional Feature Pyramid Network,BiFPN)与全局-局部自注意力(Global-Local Self-Attention,GLSA)机制协同架构,在保证精度的前提下显著降低了计算成本。陶志勇等^[12]在YOLOv5中设计了CViT-Net-S和CViT-Net-L结构,相较于经典轻量级分类模型具有特征提取能力强、分类准确率高的特性。此外,苏俊等^[13]在YOLOX

收稿日期:2025-11-03;修回日期:2026-01-07;录用日期:2026-01-13。 基金项目:北京印刷学院校级项目(KYCPT202508);北京印刷学院2024年度学科建设与研究生教育专项(21090324011);北京印刷学院横向研究项目(HXDK2022089)。

作者简介:李思琦(2000—),男,山东东营人,硕士研究生,主要研究方向:计算机视觉检测;肖军杰(1979—),男,陕西洋县人,副教授,博士,主要研究方向:生产过程数字建模及其智能化;张壮(1999—),男,四川巴中人,硕士研究生,主要研究方向:数字化设计与制造。

模型中设计了双分支主干网络,并融合了基于Transformer编码器的检测头,显著提升了模型小目标检测性能。

上述研究虽在光伏板缺陷检测领域取得了较大进展,但对红外热成像这一关键模态的深入研究仍较有限。现有研究多集中在可见光图像方面,而该领域缺乏公开可用的红外缺陷数据集,多数实验均在自建数据集进行,导致不同方法难以在统一基准下进行公平比较与验证。此外,红外图像本身存在对比度低、目标尺度多样、背景干扰复杂等问题,现有检测模型一般侧重于微小缺陷识别、轻量化、泛化能力等单一性能目标,缺乏多性能间的协同平衡,从而限制了它在真实复杂场景中的综合应用效果。因此,本文以YOLOv11n为基准模型进行改进,提出一种改进算法模型MFP-YOLOv11n,并在公开数据集上进行实验。

本文的主要工作如下:

1) 设计多尺度组间交互融合(Multi-scale Spatial-Group Interaction_Feature Complementary Mapping, MSGI_FCM)模块替换主干网络中的C3k2模块,融合多尺度感知与双向注意力增强机制,通过扩大有效感受野,增强了模型对红外图像中不同尺度缺陷的特征感知能力。

2) 设计频率选择性残差注意力(Frequency-Selective Residual Attention, FSRA)模块,引入颈部网络中,强化高频细节信息并抑制低频背景干扰,不仅降低网络计算量,还提升模型对低对比度红外图像中的缺陷识别精度。

3) 增加专用小目标检测头,融合并行分块感知注意力(Parallelized Patch-aware Attention, PPA)^[14],基于多分支策略实现多尺度特征的高效融合,提高对红外图像中微小缺陷的检测精度与鲁棒性。

1 YOLOv11 算法

YOLOv11^[15]的网络基于YOLOv8构建,采用了一种轻量级的目标检测网络结构,兼具高效的一阶段检测器,全面提升了计算精度和速度。与YOLOv8相比,YOLOv11在模型架构、训练策略和损失函数设计方面均有显著改进。YOLOv11的模型架构主要由输入模块(Input)、主干特征提取网络(Backbone)、多尺度特征融合层(Neck)和预测头部(Head)组成。其中,Backbone部分共包含13个卷积层,关键改进集中于C3k2、SPPF与C2PSA这3个模块。C3k2模块借助小卷积核结构提高信息传递效率、减少参数量;SPPF模块通过融合不同尺度的池化操作,提取图像中多区域特征,从而提升模型对多尺度目标的感知能力;C2PSA模块则引入局部空间注意力机制,使模型聚焦于关键特征区域,强化对感兴趣区域的判别与特征提取能力。Neck部分共有6个卷积层,采用路径聚合网络(Path Aggregation Network, PANet)替代传统特征金字塔网络(Feature Pyramid Network, FPN),利用金字塔结构动态调整通道与分辨率,在保留几何细节精度的基础上增大语义信息密度。Head部分采用端到端双分支设计:回归分支(空间坐标精确定位)和分类分支(障碍类别判别^[16])。




图2 MSGI_FCM模块结构

MSGI_FCM模块的核心融合策略是通过双向的注意力权重交换实现动态交互。首先,通过1×1、3×3、5×5这3种尺度卷积并行提取输入特征,扩大有效感受野,提升模型对不同尺度目标的建模能力。其次,采用并行的空间位置路径与通道语义路径分别处理输入特征,空间位置路径会生成一个强调关键位置的空间注意力图,用来调制通道语义路径的信息处理,引导它关注重要空间区域对应的语义;而通道语义路径则会计算出一个代表各通道重要性的

2 MFP-YOLOv11n 算法模型

2.1 YOLOv11n模型改进

为适应不同的检测场景需求,YOLOv11根据参数数量和复杂度划分为n、s、m、l、x这5个量级的模型^[17]。考虑光伏板红外缺陷检测实时性的需要,选择精度和模型较均衡的YOLOv11n为基准模型,提出MFP-YOLOv11n模型,模型框架如图1所示。




图1 MFP-YOLOv11n的网络结构

2.2 多尺度组间交互融合模块MSGI_FCM

传统卷积操作耦合处理空间与通道信息会导致网络浅层高分辨率特征与深层语义特征难以有效对齐,无法有效协调细节保持与语义提取之间的平衡,严重影响了小目标检测的精度。Xiao等^[18]提出的FCM(Feature Complementary Mapping)模块,通过双分支结构和交叉注意力机制在一定程度上缓解了这一问题,它的通道分割策略增强了特征多样性,空间与通道注意力的协同使用提升了特征表征能力。

然而,在光伏板红外缺陷检测过程中,待检测目标具有特征微弱、与背景热辐射差异小、易受复杂背景干扰等特点,FCM模块存在明显不足:固定的1:3通道分割比例会破坏微小目标的特征完整性;缺乏频域感知能力,难以有效利用红外小目标的高频特性;简单的乘法交互机制对低信噪比的红外图像处理能力有限。为此,改进FCM模块,提出MSGI_FCM模块,该模块替代YOLOv11n主干网络中的C3k2模块,将目标的空间位置信息隐式编码为高维向量,促进浅层空间位置信息与深层语义信息的高效融合,增强空间和语义表征的一致性,它的结构如图2所示。

通道注意力向量,该向量会直接与空间路径的输出特征进行逐元素相乘,用语义重要性校准空间特征。最后,对2条路径实施通道-空间双向增强策略,这2条路径中经过相互增强的特征不再只是简单相加,而是在特征聚合阶段进行加权融合,确保几何信息和语义信息深度结合,从而实现对小尺度目标更精准的建模。

MSGI_FCM的通道-空间双向增强策略可分为通道分割(Channel Split)、方向变换(Orientation Transformation)、互补映射

(Complementary Mapping)和特征聚合(Feature Aggregation)。

1)通道分割。对输入特征 $X^{\text{input}} \in \mathbf{R}^{C \times H \times W}$ 的通道按分割比 $\alpha (0 \leq \alpha \leq 1)$ 分割为 αC 个通道和 $(1 - \alpha)C$ 个通道,随着网络深化,低层次空间信息会逐渐被隐式编码为高维向量,以便更好地获取和处理低层次空间信息,表示如下:

$$(X^1, X^2) = \text{Split}(X^{\text{input}}) \quad (1)$$

其中: $X^1 \in \mathbf{R}^{\alpha C \times H \times W}$, $X^2 \in \mathbf{R}^{(1-\alpha)C \times H \times W}$ 。

2)方向变换。经分割后的两部分通道特征分别送入不同的分支进行处理, X^1 通过标准 3×3 卷积,提取更丰富的特征信息,表示为 X^c ; X^2 通过逐点卷积(1×1 卷积),保留大量浅层空间位置信息,表示为 X^s 。此转换过程表示为:

$$(X^c, X^s) = \Phi_1(X^1, X^2) \quad (2)$$

其中 Φ_1 表示学习空间信息和语义信息的映射关系。

3)互补映射。通过通道交互和空间交互,对 X^c 和 X^s 进行互补映射,分别为重要信息分配权重并映射到另一分支,实现特征的互补融合,有效解决特征离散导致的目标特征匹配不精确问题。通道交互使用深度可分离卷积(DWConv)对每个通道进行卷积运算,公式为:

$$X_i^D = \Phi_2(k_i, X_i^c) \quad (3)$$

其中: Φ_2 表示每个特征层通道的映射; k_i 代表第 i 个卷积核; X_i^c 为第 i 个输入通道; X_i^D 为对应的单个输出通道。经 DWConv 后的输出结果为 $X^D \in \mathbf{R}^{C \times H \times W}$ 。

然后进行全局平均池化(Global Average Pooling, GAP),获取各通道的全局信息。最后,通过全连接网络(Fully Connected Network)与 Sigmoid 线性单元生成通道信息权重 ω_1 。 ω_1 表示如下:

$$\omega_1 = R\left(\frac{1}{H \times W} \sum_{i=0}^H \sum_{j=0}^W X^D(i, j)\right) \quad (4)$$

其中 R 表示激活函数。

空间交互生成空间注意力图,并将它映射到 7×7 卷积的分支,使它更专注于空间信息。生成的空间信息权重 ω_2 表达式为:

$$\omega_2 = R(F(X^s)) \quad (5)$$

其中: F 表示具有空间聚集性的卷积映射; $\omega_2 \in \mathbf{R}^{1 \times H \times W}$ 。

4)特征聚合。将经过互补映射后的通道信息权重 ω_1 和空间信息权重 ω_2 分别映射到包含 X^s 和 X^c 的特征上,随后连接这两个分支,得到包含空间和语义关系双重映射特征 X^{FCM} ,公式计算为:

$$X^{\text{FCM}} = (X^c \otimes \omega_2) \oplus (X^s \otimes \omega_1) \quad (6)$$

其中 $\otimes$ 代表逐元素相乘。

MSG1_FCM 模块采用双向注意力协同增强机制,在通道和空间两个维度上联合抑制背景噪声,最终通过自适应特征融合实现红外小目标特征增强,从而有效解决深浅层特征不匹配问题。

2.3 频率选择性残差注意力模块 FSRA

YOLOv11n 采用的 FPN 虽然能有效融合多尺度特征,但在处理无人机(Unmanned Aerial Vehicle, UAV)航拍光伏板图像中的微小缺陷时仍存在明显不足,由于微小目标的特征只占特征映射的很小比例,经过多次下采样后,它的有效特征通常被稀释甚至丢失,并且特征金字塔网络未能直接增强或丰富微小目标的特征,导致它在微小目标检测任务中精度受限。针对该问题,Shi 等^[19]提出了高频感知(High Frequency Perception, HFP)模块,通过高通滤波器提取特征图中的高频响应,有效去除低频背景,保留并强化微小目标的边缘与细节信息。

HFP 模块虽然在可见光图像上对小目标检测表现出良好性能,但它在红外场景下的应用存在一定局限性。HFP 模块依赖固定的高通滤波阈值增强高频特征,这种设计在红外场景中面临两个关键挑战:首先,红外图像中微小目标与背景的热辐射差异较小,它的高频特征强度可能低于固定阈值,导致有效目标特征被滤波器抑制;其次,红外图像中广泛存在的热噪声和背景纹理会产生大量无关高频成分,固定阈值的高通滤波会同时增强这类干扰信号,反而降低信噪比,这种频谱特性的不匹配性,使得 HFP 模块在复杂红外背景中难以高效区分真实目标特征与背景噪声,从而导致红外小目标检测任务中出现大量漏检现象。因此,对 HFP 模块进行改进,设计 FSRA 模块,结构如图 3 所示。




图3 FSRA模块结构

FSRA 模块由高频特征发生器、通道路径(Channel Path, CP)和空间路径(Spatial Path, SP)组成。首先,对输入特征 $C_i \in \mathbf{R}^{C \times H_i \times W_i}$ 进行离散余弦变换(Discrete Cosine Transform, DCT),将特征信息从空间域转换到频域,使用软高通滤波器(Soft High-Pass Filter)进行滤波处理,再通过逆离散余弦变换(inverse Discrete Cosine Transform, iDCT)使滤波后的特征信息还原回空间域,得到与 C_i 大小相同的高频响应 F_i 。其次,分别用 F_i 作为 CP 和 SP 的输入,进行全局最大池化(Global Max Pooling, GMP)和全局平均池化(Global Average Pooling, GAP)得 F_i^{GMP} 和 F_i^{GAP} ,再应用 GELU(Gaussian Error Linear Unit)函数以保留正值,并沿着每个通道进行求和与逐点卷积操作,生成 2 个一维特征向量。再次,这 2 个向量通过特征拼接操作进行融合,拼接后的特征分别送入不同的处理分支:在通道路径中,通过 1×1 卷积和 Sigmoid 函数生成通道注意力权重 $u^{\text{CP}} \in \mathbf{R}^{C \times 1 \times 1}$;在空间路径中,通过深度可分离卷积和 Sigmoid 函数生成空间注意力权重 $u^{\text{SP}} \in \mathbf{R}^{1 \times H \times W}$ 。最后,这 2 个注意力权重通过哈达玛积进行交互融合,生成的空间-通道注意力权重与原始输入特征进行加权融合,将 CP 和 SP 的结果相加后,进一步通过 3×3 卷积与组归一化(Group Normalization, GN)处理,最终输出增强后的特征 C_i^{FSRA} ,从而实现了关键特征的精准增强与背景噪声的有效抑制。

为了有效区分红外背景下的目标特征,设计可学习的软高通滤波器替代传统的硬阈值滤波方式,如图 4 所示。该滤波器在频域中生成一个平滑的掩码,它的值由可学习的参数化函数确定:

$$M(u, v) = 1 - \sigma(\beta \times (\alpha_h - u/H)) \times \sigma(\beta \times (\alpha_w - v/W)) \quad (7)$$

其中: α_h, α_w 分别为高度和宽度方向上可学习的归一化截止频率,用于控制频谱抑制范围; β 为可学习的陡度系数,用于调节频带

过渡区的平滑程度; σ 为 Sigmoid 函数,用于实现从抑制到保留的连续过渡。




图4 软高通滤波器示意图

根据 DCT 的频谱分布特性,软高通滤波器通过参数化方式实现自适应频带分离,当频率坐标满足 $u/H \ll \alpha_h$ 且 $v/W \ll \alpha_w$ 时,2 个 Sigmoid 函数的输出值均趋近于 1,使得掩码值 $M(u, v)$ 趋近于 0,代表均匀背景和缓慢变化的低频热辐射信息被显著抑制;当频率坐标满足 $u/H \gg \alpha_h$ 或 $v/W \gg \alpha_w$ 时,至少有一个 Sigmoid 函数的值趋近于 0,因此掩码值 $M(u, v)$ 趋近于 1,图像的高频细节信号(如缺陷边缘、纹理)被最大限度地保留和增强。并且,在 α_h 和 α_w 附近的区域, Sigmoid 函数提供了平滑的权重过渡。由于它的连续可微的特性,频率权重可实现渐变调整,有效避免了传统二值化滤波引发的吉布斯现象。

2.4 并行分块感知注意力机制模块PPA

PPA 模块通过引入多尺度分支结构与局部-全局注意力协同机制,显著增强了红外小目标在复杂背景下的特征表征能力。本文将它融合于检测头,解决传统检测头因多次下采样导致的小目标语义信息稀释与定位精度下降的问题。

PPA 模块采用分层特征融合和注意力机制维持和增强小目标的表示,保证通过多个下采样后的关键信息能够保留;利用局部、全局和串行卷积分支处理输入特征张量。通过控制 Patch-Aware 参数实现局部和全局分支的区分,计算非重叠 Patch-Aware 之间的注意力矩阵,以实现局部和全局特征提取与交互。在特征提取过程中,选择特征和调整权重,最终将 3 个分支的结果求和,得到融合后的特征。在提取多分支特征后,采用注意力机制进行自适应特征增强。注意力模块包括高效的通道注意力和空间注意力,通过一维通道注意力和二维空间注意力依次处理特征,然后经过随机性失活(Dropout)、批次归一化(Batch

Normalization, BN)、激活函数(Rectified Linear Unit, ReLU)等操作,获得最终输出,具体结构如图 5 所示。

Patch-Aware 将特征划分为一组空间上连续的斑块($P \times P, H'/P, W'/P, C'$),通过控制斑块大小参数 P 区分局部分支和全局分支,通过在空间维度上对不重叠的斑块进行聚集和位移。随后,进行通道平均以获得($P \times P, H'/P, W'/P$),再使用前馈网络(Feed-Forward Network, FFN)^[20]进行线性计算,最后,利用激活函数得到线性计算特征在空间维度上的概率分布,调整它的权重,从而实现局部和全局特征的提取和交互。Attention 采用一系列有效通道注意^[21]和空间注意^[22]组件,进行自适应特征增强。

检测头融合设计时,PPA 模块被深度整合至边界框回归分支,输入特征首先经过三重卷积路径提取局部特征,并且通过跳跃连接保留原始特征,其次对通道注意力和空间注意力进行加权融合,最后通过卷积层输出边界框分布参数。该设计既强化了多尺度特征交互,又提升了对小目标的细粒度感知能力,具体设计如图 6 所示。




图5 PPA 模块结构




图6 融合 PPA 模块的检测头

3 实验与结果分析

3.1 数据集

本文实验采用昆明理工大学团队制作并发布的 PV-HSD-2025 公开数据集^[23],共含有 4025 张带有缺陷的红外图像,涵盖热斑单一类别缺陷,共计 25 181 个缺陷标注框,超小目标占比 52%,小目标占比 39%,合计高达 91%。图像分辨率为 640 像素×512 像素,红外图像保存格式为“R-JPEG”(16 bit),符合光伏产业对光伏板热斑缺陷检测的实际要求。实验按 7:2:1 将数据集划分为训练集、验证集和测试集。在训练和验证的过程中,输入图像均通过线性插值法统一缩放至 640 像素×640 像素。

3.2 实验环境与参数设置

实验环境选择 Windows 11 操作系统,采用 Python3. 8. 10、PyTorch2. 0. 1 和 CUDA11. 7 作为深度学习框架,CPU 为 AMD Ryzen 7 8845H w/Radeon 780M Graphics, GPU 为 RTX4050,显存为 6 GB。实验的训练阶段启用 Mosaic 数据增强以丰富样本多样性,并在最后 10 个 epoch 关闭该增强策略以优化检测精度^[24]。超参数设置如表 1 所示,全部实验均采用相同的超参数进行训练和验证。

表1 超参数设置

参数名称	配置值	参数名称	配置值
输入图像尺寸	640×640	学习率动量	0. 937
批处理大小	9	权重衰减因子	0. 000 5
初始学习率	0. 01	训练总轮次	300
优化器	SGD	早停耐心值	50

3.3 模型评价指标

实验采用准确率 P (Precision)、召回率 R (Recall)、平均精度 (mean Average Precision, mAP)、参数量 (Params)、计算量 (GFLOPs) 这 5 个指标,客观评估改进后的 MFP-YOLOv11n 模型对光伏板热斑缺陷的检测效果。

准确率 P 代表模型的查准率;召回率 R 代表模型的查全率;mAP 代表各类缺陷平均精度 (Average Precision, AP) 指标的平均值,mAP 值越大表示模型识别效果越好,mAP₅₀ 是交并比 (Intersection over Union, IoU) 为 0. 5 时的平均精度均值,mAP₅₀₋₉₅ 是 IoU 从 0. 5 到 0. 95 的 mAP,值越高,模型精度越好;Params 用于衡量模型规模与内存

占用,体现模型的轻便程度,值越低占内存越小;GFLOPs 表示模型计算复杂度。各指标相关计算公式如下所示:

$$P = \frac{TP}{TP + FP}; R = \frac{TP}{TP + FN}$$
$$V_{mAP} = \frac{1}{m} \sum_{i=1}^m V_{AP}^i; V_{AP} = \int_0^1 P(R) dR$$

其中: TP 表示检测结果中正确的目标数; FN 表示检测结果中错误的目标数; FP 表示未被检测出来的目标数^[25]。

3.4 实验结果

3.4.1 主干网络模块对比实验

为系统评估设计的 MSGI_FCM 模块引入 YOLOv11n 主干网络后的集成效果,针对光伏板红外缺陷检测任务,设计与多种轻量化主干网络及主流模块的对比实验。实验结果如表 2 所示。

表2 基准模型为 YOLOv11n 下不同主干网络模块对比实验结果

主干网络	$P/\%$	$R/\%$	mAP ₅₀ $/\%$	mAP ₅₀₋₉₅ $/\%$	Params/ 10^6	计算量/ GFLOPs
HyperNet	69. 2	63. 6	67. 3	29. 2	3. 20	8. 2
StartNet	69. 6	64. 5	68. 2	28. 9	2. 19	7. 1
MobileNetV4	70. 7	68. 5	69. 9	29. 3	5. 42	21. 3
GhostNetV2	69. 8	69. 1	70. 3	29. 5	3. 41	6. 8
PConv	68. 8	65. 1	67. 5	28. 7	2. 53	6. 9
HWD	69. 5	63. 9	67. 6	29. 1	3. 35	10. 1
FCM	72. 2	70. 6	72. 8	31. 1	2. 88	15. 5
MSGI_FCM	72. 9	70. 8	73. 2	31. 8	3. 81	12. 7

结果表明,MSGI_FCM 模块在继承 FCM 模块优势的基础上,通过结构改进实现了性能的全面提升。mAP₅₀ 和 mAP₅₀₋₉₅ 分别达到 73. 2% 和 31. 8%,相较于原始 FCM 模块的 72. 8% 和 31. 1%,分别提升了 0. 4 和 0. 7 个百分点;召回率从 70. 6% 提升至 70. 8%,准确率从 72. 2% 提升至 72. 9%。MSGI_FCM 在提升检测精度的同时,也成功将计算复杂度从 15. 5 GFLOP 降低到 12. 7 GFLOPs,而参数量仅从 2. 88×10⁶ 增加到 3. 81×10⁶。综合来看,MSGI_FCM 明显优于其他轻量化主干网络和模块,极大提高了光伏板的缺陷检测效果。

3.4.2 颈部网络模块对比实验

根据上述实验分析发现,尽管在 YOLOv11n 中引入 MSGI_FCM 模块后 mAP 显著提升,但召回率仍然较低,模型对红外图像中目标与噪声的区分能力有限。为此,进一步引入 FSRA 模块,通过增强频谱特性感知与匹配能力,有效提升真实目标与背景噪声的区分度,改善红外小目标检测性能。为验证 FSRA 模块的有效性,分别在未添加和添加 MSGI_FCM 的模型基础上,与

其他不同颈部特征融合方法进行了对比实验,结果如表3所示。
分析表3可知,FSRA模块在颈部网络结构中性能提升效果优异。YOLOv11n基准模型在融合FSRA模块后,准确率、召回率和 mAP_{50} 分别达到71.1%、71.4%和72.6%,与其他特征融合方法相比,提升效果显著。特别是在引入MSGI_FCM模块后,FSRA进一步将准确率和召回率提升至72.6%和71.9%, mAP_{50} 达到73.8%。尽管FSRA模块的参数量和计算复杂度略有增加,但它在复杂背景下增强频谱特性感知与目标-噪声区分能力的效果十分显著,为红外小目标检测任务提供了一种新的颈部网络解决方案。

表3 颈部网络模块对比实验结果

基准模型	颈部网络	P/%	R/%	$mAP_{50}/\%$	$mAP_{50-95}/\%$	Params/ 10^6	计算量/GFLOPs
YOLOv11n	BiFPN	69.1	65.4	67.8	29.3	2.18	6.7
	MAFPN	66.8	62.6	65.6	27.5	2.25	5.9
	MASAG	70.1	62.8	66.8	28.9	3.99	12.1
	RCM	66.6	62.4	65.4	28.1	3.99	12.3
	MFM	68.9	61.8	66.3	28.3	2.58	6.5
	SDI	65.9	61.8	64.8	27.2	2.64	6.8
	HFP	70.8	70.5	72.3	31.4	3.69	17.1
	FSRA	71.1	71.4	72.6	31.8	3.78	17.7
YOLOv11n+	HFP	71.9	71.1	73.4	32.2	3.60	13.6
MSGI_FCM	FSRA	72.6	71.9	73.8	32.2	3.89	18.5

3.4.3 检测头对比实验

为系统评估不同检测头结构在光伏板红外缺陷检测任务中的性能,针对传统检测头因多次下采样所导致的小目标语义信息稀释与定位精度下降问题,以YOLOv11n及其增强版本(引入小目标检测头)为基础,设计对比实验,重点分析PPA模块在增

强红外小目标特征表征及复杂背景区分能力方面的作用效果。对比结果如表4所示。

PPA检测头在YOLOv11n基准模型上取得了70.2%的准确率与67.8%的 mAP_{50} ,综合性能优于ASFF、MultiSEAM Head和AFPN4等结构。尤其是在引入小目标检测头后,模型整体性能得到进一步提升,其中PPA检测头表现极为突出,准确率、召回率及 mAP_{50} 分别达到72.4%、72.1%和73.3%,较未引入前分别提升2.2、7.2和5.5个百分点,验证了PPA检测头在增强小目标特征表征与复杂背景的出色区分能力。

表4 检测头对比实验结果

基准模型	检测头	P/%	R/%	$mAP_{50}/\%$	$mAP_{50-95}/\%$	Params/ 10^6	计算量/GFLOPs
YOLOv11n	ASFF	68.8	66.8	67.9	28.9	3.99	12.1
	MultiSEAM Head	70.1	70.3	69.8	28.4	4.25	5.7
	AFPN4	68.9	67.4	67.1	28.1	2.97	8.2
	PPA	70.2	64.9	67.8	29.3	3.21	9.4
YOLOv11n + 小目标检测头	ASFF	70.4	69.7	69.8	29.7	8.56	25.7
	MultiSEA Head	71.4	70.5	71.5	30.6	8.65	16.1
	AFPN4	70.3	70.9	70.2	30.0	3.04	21.5
	PPA	72.4	72.1	73.3	31.8	3.48	22.3

3.4.4 消融实验

通过消融实验系统验证所提改进方案在光伏组件热成像缺陷识别任务中的有效性。通过逐步引入各改进模块,定量分析它的对检测性能的影响,从而明确各模块的作用与效果。具体实验结果如表5所示,其中“√”表示使用此模块。

表5 消融实验结果

YOLOv11n	Xsmall	Detect_PPA	MSGI_FCM	FSRA	P/%	R/%	$mAP_{50}/\%$	$mAP_{50-95}/\%$	Params/ 10^6	计算量/GFLOPs
√					68.4	65.6	68.3	29.7	2.58	6.3
√	√				71.8	70.7	73.5	31.6	2.82	11.7
√	√	√			72.4	72.1	73.3	31.8	3.48	22.3
√	√	√	√		73.6	72.9	74.7	32.2	4.31	23.1
√	√	√	√	√	74.7	73.4	75.3	33.5	4.55	25.5

通过依次引入Xsmall(小目标检测头)、Detect_PPA、MSGI_FCM和FSRA模块,模型检测精度获得系统性提升。单独引入Xsmall, mAP_{50} 和 mAP_{50-95} 分别提升5.2和1.9个百分点;在此基础上引入Detect_PPA结构,在计算量略有上升的情况下进一步增强多尺度缺陷识别能力;随后融合MSGI_FCM模块, mAP_{50} 再度提升1.4个百分点,有效强化了复杂背景下的特征判别能力;最终引入FSRA模块, mAP_{50} 和 mAP_{50-95} 进一步提升0.6和1.3个百分点,同时计算效率获得优化。整体地,改进模型与基准模型相比,准确率与召回率分别提升6.3和7.8个百分点, mAP_{50} 和 mAP_{50-95} 分别提升7.0和3.8个百分点,模型复杂度保持在合理范围内,验证了各阶段的改进均有助于提高模型的学习能力。

3.4.5 不同模型对比实验

为系统评估本研究提出模型的综合性能,在相同实验环境下与当前主流目标检测模型进行横向对比分析,实验结果如表6所示。

表6 不同模型对比实验结果

模型	P/%	R/%	$mAP_{50}/\%$	$mAP_{50-95}/\%$	Params/ 10^6	计算量/GFLOPs
Faster R-CNN	67.9	62.4	66.1	28.3	40.31	108.5
SSD	66.8	63.0	65.5	27.9	8.95	21.7
MobileNetV4 ^[26]	70.7	68.5	69.9	29.3	5.42	21.3
GhostNetV2 ^[27]	69.8	69.1	70.3	29.5	3.41	6.8
YOLOv5s	66.3	62.6	65.6	27.5	7.87	18.5
YOLOv8s	67.3	64.7	66.1	28.3	11.10	28.7
YOLOv10s	68.8	66.8	67.8	28.9	7.22	23.4
YOLOv11n	68.4	65.6	68.3	29.7	2.58	6.3
YOLOv11s	69.3	64.8	68.5	29.3	9.40	24.5
YOLOv12n	68.7	65.1	67.8	28.9	2.61	6.2
本文模型	74.7	73.4	75.3	33.5	4.55	25.5

MFP-YOLOv11n模型在检测精度方面明显优于其他对比模型,它的 mAP_{50} 和 mAP_{50-95} 分别达到了75.3%和33.5%;相较于基准模型YOLOv11n,本文模型分别提高了7.0和3.8个百分点。同时,准确率与召回率分别提升至74.7%和73.4%,有效改善了光伏板红外图像中缺陷漏检与误检的问题。相较于Faster R-CNN、SSD、YOLOv5s、YOLOv8s及YOLOv11s等主流模型,本文模型在 mAP_{50} 上分别提升9.2、9.8、9.7、9.2和6.8个百分点;在 mAP_{50-95} 上,分别提升5.2、5.6、6.0、5.2和4.2个百分点。尽管模型参数量和计算量相较于YOLOv11n略有上升,但仍明显低于Faster R-CNN与SSD等传统架构,在保持较高检测精度的同时具有更高的计算效率,为光伏板红外缺陷检测提供了一种高效可靠的算法模型。

3.5 模型可视化分析

为了直观对比本文模型与基准模型在光伏板红外缺陷检测任务中的性能差异,对检测效果进行可视化展示。

如图7所示,在训练损失方面,MFP-YOLOv11n在训练过程中各项损失函数(包括定位损失、分类损失和目标性损失)均呈更高的收敛速度和更早的收敛行为,它的平滑曲线在整个训练周期中始终处于更低水平,且最终趋于更稳定的数值,表明它的在优化过程中梯度下降更为平稳,泛化能力更强,有效缓解了过拟合现象。同时,在验证指标方面,MFP-YOLOv11n在准确率、召回率和不同IoU阈值下的 mAP 均优于基准模型,验证了改进模型在定位精度、分类置信度与背景判别能力上实现了全面提升。

图8进一步展示了2种模型在红外图像上的检测效果对比。可视化结果表明,MFP-YOLOv11n在红外图像缺陷检测任务中具有更优的特征提取与语义感知能力,能够更准确地识别和定位光伏板热斑缺陷(hot spot),在面对弱对比度目标、复杂背景干扰等挑战时,仍能保持较高的检测鲁棒性。与基准模型相比,改进模型不仅减少了漏检和误检现象,对热斑的置信度评分总体更高且分布更为合理,验证了MFP-YOLOv11n改进策略在提升光伏板红外缺陷检测性能方面的综合有效性。




图7 YOLOv11n与MFP-YOLOv11n性能对比




图8 YOLOv11n与MFP-YOLOv11n可视化对比

4 结语

本文提出一种基于频域增强与注意力机制协同的改进算法网络 MFP-YOLOv11n,通过在主干网络引入 MSGF-FCM 多尺度组间交互融合模块,采用通道-空间双向增强策略提升对微小缺陷的特征表征能力,相较于基准模型准确率提升 4.5 个百分点;在颈部网络设计 FSRA 频率选择性残差注意力模块,通过可学习参数化滤波方式实现了对红外图像频谱特性的自适应优化,有效强化了频域目标特征并抑制了背景噪声;增加融合 PPA 并行分块感知注意力机制的专用小目标检测头,通过局部-全局注意力协同机制显著提升了微小缺陷的定位精度。在 PV-HSD-2025 数据集的实验结果表明, MFP-YOLOv11n 模型的准确率、召回率和 mAP_{50} 分别达到 74.7%、73.4% 和 75.3%,较基准模型提升 6.3、7.8 和 7.0 个百分点,尽管模型在计算资源方面有所增加,但参数数量和计算量仍被严格控制在合理范围内。同时,在与 Faster R-CNN、SSD、YOLOv8s、YOLOv11s 等主流模型的横向对比中,也展现出更高的检测精度和综合性能优势。未来工作可聚焦于多模态数据融合机制、轻量化频域-空域联合建模以及边缘智能研究,提升 MFP-YOLOv11n 算法在复杂场景下的识别精度和鲁棒性。

参考文献 (References)

- [1] 王小宇,刘波,孙凯,等. 光伏阵列故障诊断技术综述[J]. 电工技术学报, 2024, 39(20): 6526-6543.
- [2] 郎庆凯,高方玉,吴琼,等. 基于改进 YOLOv7 的光伏组件红外图像热斑目标检测方法[J]. 计算机应用, 2023, 43(S2): 191-195.
- [3] 简献忠,熊惠民,郭强. YOLO11-EMFL:一种太阳能电池表面缺陷检测方法[J]. 光电工程, 2025, 52(8): No. 250102.
- [4] GIRSHICK R, DONAHUE J, DARRELL T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]// Proceedings of the 2014 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2014: 580-587.
- [5] REN S, HE K, GIRSHICK R, et al. Faster R-CNN: towards real-time object detection with region proposal networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(6): 1137-1149.
- [6] REDMON J, DIVVALA S, GIRSHICK R, et al. You only look once: unified, real-time object detection[C]// Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2016: 779-788.
- [7] LIU W, ANGUELOV D, ERHAN D, et al. SSD: single shot multiBox detector [C]// Proceedings of the 2016 European Conference on Computer Vision, LNCS 9905. Cham: Springer, 2016: 21-37.
- [8] 刘承毅,董效杰,刘三军,等. 基于改进 Dn-YOLOv7 算法的光伏板表面小目标缺陷检测[J]. 湖北民族大学学报(自然科学版), 2024, 42(2): 212-218.
- [9] 李冰,赵宽,白云山,等. 基于 YOLOv7-EPAN 的光伏板红外图像缺陷检测[J]. 红外技术, 2024, 46(11): 1315-1324.
- [10] 韩涛,于帅帅,马玲,等. 基于改进 YOLOv11n 的光伏板异物与缺陷检测模型研究[J]. 计算机工程与应用, 2025, 61(14): 123-134.
- [11] 刘巧,章翔峰,姜宏. 基于 HBGF-YOLO 的无人机航拍光伏板红外小目标缺陷检测[J]. 激光与光电子学进展, 2026, 63(4): 170-184.
- [12] 陶志勇,何燕,林森,等. 局部和全局特征融合的太阳能电池片表面缺陷检测[J]. 光电工程, 2024, 51(1): No. 230292.
- [13] 苏俊,唐潮龙,刘智权,等. 基于全局与局部特征提取增强的光伏板缺陷检测算法[J]. 计算机工程与应用, 2025, 61(12): 299-310.
- [14] XU S, ZHANG S, XU W, et al. HCF-Net: hierarchical context fusion network for infrared small object detection [C]// Proceedings of the 2024 IEEE International Conference on Multimedia and Expo. Piscataway: IEEE, 2024: 1-6.
- [15] KHANAM R, HUSSAIN M. YOLOv11: an overview of the key architectural enhancements [EB/OL]. [2025-08-25]. <https://arxiv.org/pdf/2410.17725>.
- [16] 纪文杰,宋廷伦,容小洛,等. PATD-YOLO:基于 YOLOv11 的道路障碍目标检测算法[J]. 计算机工程与应用, 2025, 61(21): 129-143.
- [17] 李巨虎,徐玉立,路佳,等. 基于改进 YOLOv11n 的轻量级多尺度水稻害虫识别模型[J]. 农业工程学报, 2025, 41(17): 175-183.
- [18] XIAO Y, XU T, XIN Y, et al. FBRT-YOLO: faster and better for real-time aerial image detection[C]// Proceedings of the 39th AAAI Conference on Artificial Intelligence. Palo Alto: AAAI Press, 2025: 8673-8681.
- [19] SHI Z, HU J, REN J, et al. HS-FPN: high frequency and spatial perception FPN for tiny object detection[C]// Proceedings of the 39th AAAI Conference on Artificial Intelligence. Palo Alto: AAAI Press, 2025: 6896-6904.
- [20] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]// Proceedings of the 31st International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2017: 6000-6010.
- [21] WANG Q, WU B, ZHU P, et al. ECA-NET: efficient channel attention for deep convolutional neural networks [C]// Proceedings of the 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2020: 11531-11539.
- [22] WOO S, PARK J, LEE J Y, et al. CBAM: convolutional block attention module [C]// Proceedings of the 2018 Computer Science, Computer Vision and Pattern Recognition, LNCS 11211. Cham: Springer, 2018: 3-19.
- [23] 刘沅林,金建辉,李盛洪,等. PV-HSD-2025:面向光伏热斑检测的红外基准数据集与 YOLOv8-P1 增强架构[J]. 计算机工程与应用, 2026, 62(6): 240-252.
- [24] 郭敬博,黄晓辉. MFDF-YOLO:复杂场景下的轻量级棉花检测算法[J]. 计算机工程与应用, 2026, 62(2): 126-137.
- [25] 王育欣,张志,张家亮,等. 基于改进 YOLOv5 算法的光伏缺陷检测[J]. 太阳能学报, 2024, 45(12): 139-145.
- [26] QIN D, LEICHNER C, DELAKIS M, et al. MobileNetV4: universal models for the mobile ecosystem [C]// Proceedings of the 2024 European Conference on Computer Vision, LNCS 15098. Cham: Springer, 2025: 78-96.
- [27] TANG Y, HAN K, GUO J, et al. GhostNetV2: enhance cheap operation with long-range attention [C]// Proceedings of the 36th International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2022: 9969-9982.