

改进 YOLOv8 的在轨非合作目标轻量化特征提取模型

郭力为^{1,2,3}, 杨中光¹, 余金培^{1,2,3*}

(1. 中国科学院微小卫星创新研究院, 上海 201304; 2. 上海科技大学 信息科学与技术学院, 上海 201210;

3. 中国科学院大学, 北京 100049)

(*通信作者电子邮箱 yujinpei@mail.sim.ac.cn)

摘要: 针对在轨资源受限的非合作目标识别场景, 为了降低视觉特征提取模型的计算复杂度, 满足目标检测和局部特征识别对精度和实时性的要求, 提出一种基于改进 YOLOv8 的轻量化检测模型 SatYOLO。首先, 提出 Starlight 模块替换 YOLOv8 主干, 以减少计算量与参数量; 其次, 设计上下文引导重构融合 (CGRF) 颈部网络替换原模型颈部, 以融合多尺度特征注意力并提升检测性能; 最后, 提出一种轻量化检测头 ShareLN 替换原模型检测头, 在保证准确性的条件下减少运算量, 加快检测速度, 并引入层归一化 (LN) 方法缓解轻量化设计导致的性能下降。仿真实验结果表明, 相较于基准模型 YOLOv8n, SatYOLO 参数量减少了 40.9%, 计算量减少了 50.0%, 而识别精度相当。所提模型可有效实现在轨非合作目标特征提取系统的轻量化目标。

关键词: 特征提取; 轻量化; 非合作目标; YOLOv8; 在轨感知

中图分类号: TP391.4 **文献标志码:** A

Lightweight feature extraction model for on-orbit non-cooperative targets with improved YOLOv8

GUO Liwei^{1,2,3}, YANG Zhongguang¹, YU Jinpei^{1,2,3*}

(1. Innovation Academy for Microsatellites of Chinese Academy of Sciences, Shanghai 201304, China;

2. School of Information Science and Technology, ShanghaiTech University, Shanghai 201210, China;

3. University of Chinese Academy of Sciences, Beijing 100049, China)

Abstract: To address the on-orbit resource-constrained, non-cooperative target feature extraction problem, a lightweight detection model based on improved YOLOv8, SatYOLO, was proposed to reduce the computational complexity of the visual feature extraction model, thereby ensuring the accuracy and real-time requirements for target detection and local feature recognition. Firstly, the Starlight module was proposed to replace the YOLOv8 backbone to reduce computational cost and parameters. Secondly, a Context-Guided Reconstruction Fusing (CGRF) neck was designed to replace the original model's neck to fuse multi-scale feature attention and improve detection performance. Finally, a lightweight ShareLN head was proposed to replace the original model's head to reduce computation while maintaining accuracy, thereby accelerating detection, and Layer Normalization (LN) was introduced to alleviate performance degradation caused by the lightweight design. Simulation results show that, compared with the original model YOLOv8n, SatYOLO reduces parameters by 40.9% and computation by 50.0%, while maintaining essentially equivalent accuracy. The proposed model effectively achieves the lightweight goal of on-orbit non-cooperative target feature extraction system.

Key words: feature extraction; lightweight; non-cooperative target; YOLOv8; on-orbit monitoring

0 引言

在轨非合作目标视觉特征检测与提取技术是航天科技发展的重要方向之一。随着越来越多的卫星、火箭等被发射至太空, 产生了许多在轨失效卫星、故障卫星、火箭残骸等航天器目标^[1]。通常把没有已知标记信息、无法提供自身位姿信息的目标称为非合作目标。大量空间非合作目标的存在造成了卫星轨道的拥挤, 显著增加了发生碰撞的风险, 对未来航天器的发射和在轨航天器的正常运行构成了巨大的挑战。在空间交会对接、在轨操控、碎片清除、空间攻防等应用场景中, 非合作目标特征提取是需要重点研究的关键技术之一^[2]。

为了完成对非合作目标的识别、定位、抵近、控制等主要任务, 对目标的局部视觉特征进行精准、快速的检测成了一个重要的挑战。典型方法是利用激光雷达、定标装置、非可见光成像器件等设备, 完成空间目标的检测与识别。然而, 在非合作目标特征提取任务中存在诸多问题: 非合作目标通常没有配合测量任务的光标、反射器等装置; 由于空间光照条件复杂, 成像效果易受干扰, 鲁棒性较差; 目标探测信号可能被检测对象吸收或侦测; 设备成本高、质量与功耗大、特征提取方法复杂度较高等。

针对上述问题, 有学者提出基于视觉的在轨特征提取方案,

即通过星上的光学相机在轨采集图像, 并使用星上计算平台搭载的轻量化卷积神经网络 (Convolutional Neural Network, CNN) 对图像进行实时处理以完成非合作目标特征提取任务^[3]。该方案具有成本低、鲁棒性强、实时性好、无需向地面端上传数据等优点^[4]。基于卷积神经网络的目标检测算法可以根据结构和处理过程分为以 YOLO (You Only Look Once)^[5]、SSD (Single Shot MultiBox Detector)^[6]、RetinaNet^[7] 等为代表的单阶段 (One-Stage) 算法和以 R-CNN (Region-CNN)^[8]、Faster R-CNN^[9]、Sparse R-CNN^[10] 等为代表的两阶段 (Two-Stage) 算法, 也可按是否使用锚框 (Anchor Box) 分为基于锚框 (Anchor-Based) 算法和无锚框算法 (Anchor-Free) 两类。相较于两阶段算法, 单阶段算法直接在图像的多个位置和尺度上进行目标检测, 通常具有简单的结构、更快的检测速度、更小的内存占用和良好的泛化能力。随着单阶段算法性能的不断改善, 目前在实时性和轻量化要求较高的任务场景中, 通常以具有代表性的 YOLO 系列视觉算法框架作为主要方法。

近年来, 此类目标检测算法从主干模块设计、颈部网络设计、检测头特征融合、损失函数和归一化方法等方面进行了改进和轻量化设计。Yang 等^[11] 通过采用深度可分离卷积技术对普通卷积模块进行替换, 以较少的计算量生成大量特征图, 进而利用

收稿日期: 2025-03-10; 修回日期: 2025-04-02; 录用日期: 2025-04-14。

基金项目: 国家重点研发计划项目 (2020YFC2200901); 上海市青年科技英才扬帆计划项目 (20YF1446700)。

作者简介: 郭力为 (1999—), 男, 山西长治人, 硕士研究生, 主要研究方向: 模型压缩、计算机视觉; 杨中光 (1989—), 男, 山东潍坊人, 副研究员, 博士, 主要研究方向: 科学卫星总体技术; 余金培 (1965—), 男, 浙江衢州人, 研究员, 博士, 主要研究方向: 通信与信息系统、卫星通信。

轻量化模块替换的方法降低了计算复杂度,使模型大小从 22 MB 压缩至 16 MB。徐云飞等^[12]提出一种名为 NCDN 的非合作目标局部特征检测网络,通过在 SSD 模型中引入特征融合策略来适应不同距离下的检测需求,将检测头中的相似深层结构进行特征融合,提高模型在局部特征分辨率降低时的鲁棒性,并对特征提取网络 MobileNetV2 的内部卷积通道进行压缩而实现轻量化,将存储空间压缩超 70%,精度只下降约 5%。吕晓宁等^[13]基于 YOLOv4^[14]网络模型,对空间金字塔池化(Spatial Pyramid Pooling, SPP)模块与 PANet 模块进行改进,合并了卷积层与批归一化(Batch Normalization, BN)层以降低模型参数量,参数量较性能相近的模型减少了超 20×10^6 ,显著降低了模型计算量;并重新设计了损失函数以减缓样本失衡问题,实现了对遥感图像的高效处理。Tian 等^[15]采用对训练批次大小更不敏感的组归一化(Group Normalization, GN)方法,在增强训练稳定性的同时^[16],提升了检测头的定位与分类能力,证实了归一化方法对于目标检测模型的性能表现具有一定影响。

目前,已有较多工作提出了多种在轨目标检测算法及其轻量化设计方案,但对于在轨非合作目标特征提取算法设计,依然存在着进一步研究的需要^[4]。一方面,在轨计算平台通常是采集、存储、处理一体化的近数据端计算平台,即边缘计算平台,其计算与存储能力通常受到较为严格的限制,无法支持高能耗神经网络计算,而轻量级模型通常存在精度过低问题,故有必要在压缩参数量的同时探索尽量不损失识别精度的模型设计方法。另一方面,对于非合作目标的视觉特征提取任务对实时性有较高要求,除模型尺寸带来的计算负担外,计算量较大的运算也会给算法实时性带来负面影响,因此探索对边缘计算平台计算能力友好的运算操作是优化在轨目标特征提取算法的重要方向之一。

基于上述背景,本文采用公开的 SPEED+ 卫星数据集^[17],针对 PRISMA 任务^[18]中 TANGO 卫星构建了包含 2 000 张图像、10 261 个视觉特征的非合作目标局部视觉特征数据集 TangoData,设计一种基于 YOLOv8 模型的在轨非合作目标轻量化视觉特征提取模型 SatYOLO。提出一种计算成本更低的 Starlight 模块替换原有 C2f 模块以有效压缩网络主干结构;设计了一种新的上下文引导重构融合(Context-Guided Reconstruction Fusing, CGRF)颈部网络,有效提升了模型检测性能;提出一种新型轻量化检测头 ShareLN,在优化识别性能的情况下大幅减小了模型尺寸,并利用层归一化(Layer Normalization, LN)方法有效缓解了原方法在经过模型压缩后性能损失严重的现象。仿真结果表明,本文模型有效提高了算法的轻量化程度,具有优秀的特征提取性能,可为在轨非合作目标特征提取算法的星上部署提供有效的设计思路和改进方案。

1 YOLOv8 网络结构

在基于锚框的单阶段目标检测算法中,具有代表性的 YOLO 系列算法因其独特的架构及优异的检测性能成为目标检测领域备受关注的标杆。其中 YOLOv5 版本凭借其成熟的工程化实现与优越的性能,已在工业界得到大量应用并取得显著效果。2023 年, Ultralytics 公司推出改进的 YOLOv8 算法,在 YOLOv5 的基础上进一步减小模型尺寸并提升了检测的精度。

YOLOv8 的模型结构如图 1 所示。该模型主要由主干网络(Backbone)、颈部(Neck)和头部(Head)三部分组成,头部通过检测头(Detection Head)输出检测的损失结果。YOLOv8 的主干网络采用了一系列的卷积层来完成图像特征提取任务,其中采用瓶颈结构和残差连接模块,以提升网络性能并减少模型参数量。该部分从输入端开始,由一系列堆叠的卷积批归一化激活层(Convolution Batch normalization SiLU, CBS)模块、C2f 模块和最后的空间金字塔快速池化(Spatial Pyramid Pooling Fast, SPPF)模块共同组成。C2f 模块基于 YOLOv5 中 C3 模块进行了重新设计,C3 模块中的输入特征分为两部分,分别进行单 CBS 处理和 CBS 与瓶颈结构混合处理,而 C2f 则将瓶颈结构设计为类似特征金字塔网络的级联结构,使每一个瓶颈结构的输出分别传递给下一个瓶

颈结构和特征融合模块。该设计相较于 C3 模块有更少的参数量和更强的特征提取能力。SPPF 模块由 k 值相同的最大值池化层级级联组成,用于实现全局尺度信息融合。在 YOLOv8 头部结构中,抛弃了 YOLOv5 中所沿用的耦合式检测头,转而采用目前常见的解耦头结构,分离检测与分类任务。在损失函数方面, YOLOv8 中的损失主要由分类损失(Classification Loss, Cls. Loss)和边界框回归损失(Bounding Box Loss, Bbox. Loss)组成。分类损失采用二元交叉熵(Binary Cross-Entropy Loss, BCE)损失,而回归损失由分布聚焦损失(Distribution Focal Loss, DFL)损失和交并比(Intersection over Union, IoU)边界框损失共同组成。边界框损失的计算方式如下:

$$L_{\text{Bbox}} = L_{\text{IoU}} + L_{\text{DFL}} \quad (1)$$

其中 L_{IoU} 由预测框 A 和真实框 B 取交集与并集的面积相除得到,表现了预测框与真实框的重叠程度。设 S 表示面积,则 L_{IoU} 的计算方法为:

$$L_{\text{IoU}} = \frac{S_{A \cap B}}{S_{A \cup B}} \quad (2)$$

DFL 损失 L_{DFL} 则计算了目标框的 2 个相邻内外网格边框与预测框的加权距离 S_i, S_{i+1} , 并计算其交叉熵之和,用于学习最接近 y 的 y_i 与 y_{i+1} 的分布, y 为预测概率,计算方法为:

$$L_{\text{DFL}}(S_i, S_{i+1}) = -((y_{i+1} - y) \log(S_i) + (y - y_i) \log(S_{i+1})) \quad (3)$$

分类损失 L_{cls} 则直接由 BCE 计算得到,用于计算分类结果的损失,计算方法为:

$$L_{\text{cls}} = \frac{1}{C} \sum_{i=1}^C (y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)) \quad (4)$$

其中 C 为目标的类别数。




图1 YOLOv8网络模型结构

为了更好地适应边缘计算平台的资源限制,同时尽可能保证模型精度,本文模型尺寸参数选用 YOLOv8 模型中微缩(nano)版本(即 YOLOv8n)的配置,致力于在尽量不损失模型精度的情况下使特征提取算法的计算成本进一步降低。

2 改进的轻量化特征提取方法

为了在兼顾精度的同时有效减小模型计算量,本文从三方面对 YOLOv8 模型进行了改进,改进后的模型结构如图 2 所示,图中使用实线框标明了本文所设计的结构。

第一,设计了更轻量化、算子计算效率更高的 Starlight 模块替换 YOLOv8 主干网络中堆叠的 C2f 模块。该模块中采用 ADown 算子优化下采样计算复杂度,利用逐元素乘法的星型算子,在有效扩展网络维度的同时压缩了参数数量和计算成本,舍去了包含大量参数和卷积计算的原卷积模块,以期在牺牲较小精度的

情况下大幅压缩模型尺寸,简化运算过程。

第二,设计了新的CGRF颈部网络结构。基于矩形自校准注意力(Rectangular self-Calibration Attention, RCA)机制^[19]对全局特征信息和前景目标进行提取,并引入插值卷积融合(Interpolate Convolution Fuse, ICF)和卷积插值点积融合(Convolution Interpolate Dot Fuse, CIDF)两种特征融合模块对多尺度特征图信息进行融合,进一步提升模型的前景目标提取性能。

第三,设计了新型的轻量化检测头 ShareLN。进一步压缩CBS模块和二维卷积模块,采用参数共享方法重新设计模型检测头结构,合并原有特征图分支,使检测头参数量大幅减小。引入层归一化方法,在解决批归一化方法对批次大小敏感问题的同时,有效缓解主干和颈部结构替换带来的模型受损现象,使模型更好地兼具轻量化特性与良好的视觉特征提取效果。




图2 改进的SatYOLO网络模型结构

2.1 Starlight主干网络模块

YOLOv8主干网络中使用的C2f模块虽然通过在C2模块中增加更多残差连接提高了检测精度,但也导致网络具有卷积层过多、结构过于复杂的缺点,难以被用于计算资源受限的设备。目前有许多工作融合GhostNet^[20]、MobileNet^[21]等轻量化网络的方法降低模型复杂度,但是这些方法利用了大量幻影卷积、深度可分离卷积等技术进行特征提取,增加了额外的数据处理操作和对内存的频繁访问,给检测任务的实时性带来了不利影响。在许多视觉任务中,研究人员通过融合Transformer模型^[22],利用自注意力机制对图像建模,如Vision Transformer(ViT)^[23]和Swin Transformer^[24],然而该机制进行高维映射的实现方法是将特征映射到不同空间后再利用点积运算构建注意力矩阵,存在计算复杂度较高的问题,同样不适用于计算资源有限的设备。

为解决上述问题,本文基于Starnet网络^[25]提出一种新的轻量化模块Starlight,采用更节约计算资源的ADown算子,移除计算成本较高的大卷积核运算层,通过双路径下采样技巧实现计算量的减少。利用“星运算”(即逐元素乘法)以出色的性能和效率完成从输入特征空间到高维非线性特征空间的映射。两种算子的结合使Starlight模块进一步展现出低延迟、高准确率的特点。Starlight模块的内部结构如图3所示,其中Conv表示卷积层,GAP/FC表示全局平均池化(Global Average Pooling, GAP)层和全连接(Fully Connected, FC)层。

Starlight采用计算上更高效的ADown算子对特征图进行下采样操作。ADown算子先对特征图进行平均池化,然后将特征图切分为大小相同的两个部分,其中一个通过经过池化操作,然后两者均进行卷积运算,最后将这两个子特征图合并输出,图4展示了ADown算子内部的计算过程。

设特征图尺寸为 $H \times W$, H 和 W 分别为特征图的高度和宽度。输入、输出通道数分别为 C_{in} 和 C_{out} ,那么对于原卷积批归一化模块,其中包含了1个 3×3 卷积层和1个批归一化层。由于BN层计算量较小,总计算量约为:

$$C_{ConvBN} \approx C_{3 \times 3} = 4.5C_{in}C_{out}HW \quad (5)$$

对于ADown算子,其中包含1个 3×3 卷积分支和1个 1×1 卷积分支,可计算得出计算量分别为:

$$C_{3 \times 3} = \left(\frac{H}{2} \times \frac{W}{2}\right) \times \left(3^2 \times \frac{C_{in}}{2} \times \frac{C_{out}}{2}\right) \times 2 = 1.125C_{in}C_{out}HW \quad (6)$$

$$C_{1 \times 1} = \left(\frac{H}{2} \times \frac{W}{2}\right) \times \left(1^2 \times \frac{C_{in}}{2} \times \frac{C_{out}}{2}\right) \times 2 = 0.125C_{in}C_{out}HW \quad (7)$$

由于平均池化和最大池化操作中仅包含索引和比较操作,总计算量较小,故忽略不计。因此ADown算子总计算量为:

$$C_{ADown} = C_{3 \times 3} + C_{1 \times 1} = 1.25C_{in}C_{out}HW \quad (8)$$

对于卷积批归一化模块,它的参数量 P_{ConvBN} 为:

$$P_{ConvBN} = 3^2 \times C_{in} \times C_{out} + 2 \times C_{out} \approx 9C_{in}C_{out} \quad (9)$$

ADown算子的参数量 P_{ADown} 可由卷积层和BN层参数计算得到:

$$P_{ADown} = C_{3 \times 3} = \left(3^2 \times \frac{C_{in}}{2} \times \frac{C_{out}}{2}\right) + \left(1^2 \times \frac{C_{in}}{2} \times \frac{C_{out}}{2}\right) = 2.5C_{in}C_{out} \quad (10)$$

结合以上计算可知,ADown算子在计算量和参数量都比原模块更少,理论上具有约3.6倍的加速效果。通过采用通道拆分+异构下采样取代标准卷积和批归一化方法,ADown算子以双轻量化分支进一步降低了原模块的访存压力。




图3 Starlight模块结构示意图




图4 ADown算子计算示意图

Starlight网络中引入的星运算也为特征提取模型提供了更高效的计算性能。设星运算的输入矩阵为 X ,含偏置项的权重矩阵为 W ,用下标表示2个参与运算对象的权重项,那么在单层星运算中的计算过程为:

$$(W_1^T X) * (W_2^T X) \quad (11)$$

对于任意一个输出通道,以 X 中的一个输入 x 为例,设 x 为 $d+1$ 维向量,2个计算分支的权重为 w_1 和 w_2 ,则星运算可展开为如下过程:

$$w_1^T x * w_2^T x = \left(\sum_{i=1}^{d+1} w_1^i x^i\right) * \left(\sum_{j=1}^{d+1} w_2^j x^j\right) = \alpha_{(1,1)} x^1 x^1 + \dots + \alpha_{(4,5)} x^4 x^5 + \dots + \alpha_{(d+1,d+1)} x^{d+1} x^{d+1} \quad (12)$$

其中: i 和 j 表示通道序号, α 表示系数,如式(13)所示。

$$\alpha_{(i,j)} = \begin{cases} w_1^i w_2^j, & i = j \\ w_1^i w_2^j + w_1^j w_2^i, & i \neq j \end{cases} \quad (13)$$

式(13)中的多项式共有 $(d+2)(d+1)/2$ 项,整理得到项数为 $(0.5d^2 + 1.5d + 1)$,即在 d 维空间以高效的方式得到了约为 $(d/\sqrt{2})^2$ 维的隐空间特征图表示,可在不引入其他复杂计算的情况下有效利用单层运算对特征空间进行扩展。类似地,可通过叠加星运算层实现隐空间维度的指数级增长。使用 O_l 表示第 l 层星运算,那么初始维度为 d 的网络层在经过 O_l 后隐空间维度增长至 $(d/\sqrt{2})^{2^l}$ 维,进一步可推导出第 l 层的维度为 $(d/\sqrt{2})^{2^l}$ 维。因此,堆叠星运算层使我们能在仅使用若干层星运算的情况下大幅提升隐空间表示的维度。例如,宽度为 128 的网络在堆叠 10 层后它的隐空间维度数可达到近似无穷大。本文参考 starnet_s050 的尺寸大小配置 Starlight 模块,以最大程度提升其轻量化特性。

2.2 CGRF 颈部网络设计

受文献[19]所提 RCA 机制的启发,本文设计了一种基于矩形自校准模块(Rectangular self-Calibration Module, RCM)且与 YOLOv8 颈部 C2f 金字塔特征提取网络相结合的 CGRF 颈部网络结构。如图 2 所示,CGRF 选用 Starlight 主干网络中 Stage2、Stage3 和 Stage4 所输出的不同尺寸特征图 P3、P4、P5 进行以 RCM 模块为核心的金字塔上下文提取(Pyramid Context Extraction, PCE)操作。RCM 模块、PCE 模块结构如图 5 所示。




图 5 RCM 模块、PCE 模块结构

在 RCM 模块中,组合 RCA 机制、批归一化和多层感知机(Multi-Layer Perception, MLP),用于从特征图中提取前景语义信息。矩形自校准注意力机制首先在水平和垂直方向对特征图进行平均池化得到 2 个方向上的向量表示,利用广播加法得到扩展特征图后在 2 个方向上分别进行条形卷积,得到全局图像的前景注意力信息,最后计算与原特征图的 Hadamard 积。图 6 展示了不同尺度特征下 RCM 模块的注意力分布,在融合小尺度特征条件下,RCA 机制有效地对前景目标视觉特征进行了提取。




图 6 多尺度下 RCA 机制注意力分布

设输入特征图为 X ,则 RCA 机制的计算方式为:

$$V_{RCA} = \delta \left(\psi_{k \times 1} \left(\phi \left(\psi_{1 \times k} \left(H_p(X) \oplus V_p(X) \right) \right) \right) \right) \odot \psi_{3 \times 3}(X) \quad (14)$$

其中: H_p 和 V_p 分别表示水平和垂直方向的平均池化; $\oplus$ 表示广播加法; ϕ 表示批归一化; δ 表示 Sigmoid 函数; $\psi_{m \times n}$ 表示卷积核大小为 $m \times n$ 的卷积运算; $\odot$ 表示 Hadamard 积。

为了将 RCM 模块得到的多尺度注意力融合并应用于

YOLOv8 颈部网络中,设计插值卷积融合(Interpolate Convolution Fuse, ICF)和卷积插值点积融合(Convolution Interpolate Dot Fuse, CIDF)两种多尺度特征融合模块。ICF 模块将输入的主、副特征图相加,其中副特征图在相加前进行双线性插值,再通过卷积运算和主特征图的尺寸进行对齐,最后再将 2 个特征图相加。CIDF 模块则对输入的 2 个特征图都进行卷积,然后将副特征图进行 h-Sigmoid 函数和双线性插值运算,最后计算 2 个特征图的 Hadamard 积并输出。ICF 和 CIDF 两个多尺度特征融合模块的计算过程如图 7 所示。




图 7 ICF 和 CIDF 模块内部结构

引入 ICF 和 CIDF 模块后,可利用动态双线性插值和多尺度特征融合将不同尺度特征图下的 RCM 注意力信息进行综合,有效增强模型的特征表示能力和复杂背景下的目标识别能力。

2.3 轻量化检测头 ShareLN

为进一步减小模型参数数量和推理成本,提出 ShareLN 轻量化检测头,并对 YOLOv8 原 Detect 检测头进行替代。采用参数共享方式,对检测头中模块进行合并与压缩:如图 1 所示,原 Detect 检测头在边界框损失和分类损失计算中对每个损失都设置 3 个卷积层——2 个 CBS 层和 1 个 conv2d 层(即标准二维卷积)。而在 ShareLN 中,2 种损失共享 CBS 层和各通道计算结果,即先进行逐通道卷积运算,最后再将结果用于单通道 CBS 层和 conv2d 层,且共享所有 CBS 层。修改前后的检测头结构如图 8 所示。




图 8 Detect 检测头与 ShareLN 检测头设计结构

在 Detect 检测头中,由 2 支堆叠的卷积层完成边界框损失和分类损失计算,分别称其为 cv2 和 cv3。每支由 2 个输出通道数为 c 、卷积核大小为 3 的卷积批归一化激活层 CBS1、CBS2 和 1 个卷积核大小为 1 的 conv2d 卷积层组成,设它们的参数数量分别为 P_{CBS1} 、 P_{CBS2} 和 P_{conv2d} 。设通道数为 N ,每个通道的维度大小为 x ,cv2 和 cv3 的隐藏通道数分别为 c_2 和 c_3 , R 为超参数,目标种类数为 C ,那么对边界框损失,它的检测头参数数量 P_{Bbox} 为:

$$P_{Bbox} = N(P_{CBS1} + P_{CBS2} + P_{conv2d}) = (9xc_2 + 9c_2^2 + Rc_2)N = (9x + 9c_2 + R)c_2N \quad (15)$$

类似地,可以得到分类损失的检测头参数数量 P_{Cls} 为:

$$P_{Cls} = N(P_{CBS1} + P_{CBS2} + P_{conv2d}) = (9xc_3 + 9c_3^2 + Cc_3)N = (9x + 9c_3 + C)c_3N \quad (16)$$

在 ShareLN 中,设计了隐藏通道数为 c 的共享卷积层参数,相当于共享的参数量 P_{Share} 为:

$$P_{Share} = xNc + 18c^2 \quad (17)$$

加上分别用于边界框损失和分类损失的单通道卷积层后, ShareLN 检测头总参数量 P_{ShareLN} 为:

$$P_{\text{ShareLN}} = 18c^2 + (R + C + xN)c$$

(18)

综上所述,当检测头中卷积层的隐藏通道数近似为 c 时,相较于原 Detect 检测头,ShareLN 检测头的参数量减少:

$$P_{\text{Reduction}} = P_{\text{Detect}} - P_{\text{ShareLN}} = (N - 1) \times (c^2 + R + C) + 17xNc$$

(19)

因此,采用参数共享方法的 ShareLN 结构可有效压缩检测头中卷积层参数量。由于若干堆叠的多通道卷积层被替换为了单一的多通道卷积层,通道数越多,则压缩比例越大、节约的参数量越多。通过采用轻量化的 ShareLN 结构,大幅降低了检测头中的参数量,有效减小了模型尺寸,为目标特征提取模型的轻量化和边缘部署提供了可行性。经过重新设计的检测头在目标特征提取的总体性能上仅有很小的损失,有效结合了轻量化和高精度的特点。

此外,检测头也对归一化方法进行了改进。YOLOv8 中原有的卷积层中采用批归一化作为归一化方法。批归一化的方法通过在每个小批量数据上计算均值和方差来实现归一化,能够缓解神经网络在训练时可能出现的梯度消失和梯度爆炸问题,有利于网络的加速收敛。然而批归一化对批次大小具有依赖性,其性能在计算资源受限和批量较小的情况下会受到影响。组归一化和层归一化则具有更好的灵活性和适应性,能够减小对批次大小的敏感性。本文使用 LN 层对检测头中的 BN 层进行替换,不仅能提高模型在计算资源受限环境下的性能和适用性,还可有效缓解主干颈部替换等轻量化设计给模型带来的性能损伤。实验结果表明 LN 层比 BN 层和 GN 层具有更好的检测性能表现,并且新的归一化层设计应用于 ShareLN 后能够显著提高检测的召回率,大幅消除了主干替换对性能带来的负面影响,更好地解决了特殊光学场景下其他模型出现的漏检情况。

3 实验准备与验证

3.1 自建 TangoData 数据集

本文实验采用的数据集源于斯坦福大学 SLAB 实验室 2021 年公开的非合作目标数据集 SPEED+^[17]。该数据集主要由瑞典 PRISMA 技术任务中 TANGO 卫星的合成图像与姿态标签组成,并被用于第二届国际卫星姿态估计挑战赛(the 2nd Satellite Pose Estimation Competition, SPEC2021)中。数据集包含各种角度和光照条件下的 TANGO 卫星图像。除深空背景外,部分图像还带有地球背景作为视觉特征提取的干扰因素。

TANGO 卫星的主要视觉特征包括:卫星本体(Satellite)、3 个用于射频导航的编队飞行射频(Formation Flying Radio Frequency, FFRF)天线、位于卫星侧面的 2 个全球定位系统(Global Positioning System, GPS)装置,以及 1 个星上传感器(Sensor)。对该数据集的图像进行标注后,得到 2000 张可用于训练和测试的 TANGO 卫星图像,构建了名为 TangoData 的非合作目标视觉特征自建数据集,并支持 YOLO 和 VOC XML 两类主流数据集格式规范。TangoData 数据集图像的示例与标签分布如图 9 和图 10 所示。TangoData 数据集中总共有卫星本体实例 2000 个,FFRF 天线实例 5 120 个,GPS 装置实例 1 699 个,传感器实例 1 442 个,总计 10 261 个视觉特征目标实例。实例的真实框尺寸比例较均匀,无显著的几何比例特征,位置主要分布在图像视野的中央区域,且绝大部分实例为归一化尺寸小于 0.1 的小尺寸目标对象。本文按照 8:1:1 的比例将 TangoData 数据集随机划分为训练集、验证集和测试集 3 个部分进行模型实验。

3.2 实验环境

本文所采用实验平台基于 Ubuntu 22.04 操作系统,计算机硬件配置为 Intel Xeon Platinum 8352V CPU @2.10 GHz 处理器、64 GB 内存、NVIDIA GeForce RTX 4090 显卡,显卡内存为 24 GB。开发语言为 Python 3.12.4,深度学习框架采用 PyTorch 2.3.1,使用 CUDA 12.1 和 cuDNN 8 加速神经网络的训练和推理。所使用

的实验参数如表 1 所示,文中未提到的参数使用 YOLOv8 官方框架所提供的默认参数配置。




图9 TangoData数据集图像示例




图10 TangoData数据集目标位置尺寸分布图

表 1 实验参数配置

参数	数值/配置	参数	数值/配置
图片尺寸	640	优化器	随机梯度下降(SGD)
训练轮次	400	学习率	0.01
训练批次大小	32	耐心值	50
最大装载线程数	16		

3.3 评估指标

目标检测任务的主要评估指标为精确率 P (Precision)、召回率 R (Recall)、F1 值(F1-Score)和平均精度均值(mean Average Precision, mAP)。其中,mAP 指标采用 mAP@50,即 IoU 阈值设置为 0.5 时的 mAP 值。精确率、召回率和 mAP 的计算公式如下所示:

$$P = \frac{TP}{TP + FP}$$

(20)

$$R = \frac{TP}{TP + FN}$$

(21)

$$V_{AP} = \int_0^1 P(R) dR$$

(22)

$$V_{mAP} = \frac{1}{N} \sum_{i=1}^N AP_i$$

(23)

其中: TP (True Positive)表示真正例, FP (False Positive)表示假正例, FN 表示假负例(False Negative)。

轻量化任务还对模型的参数量(Parameters)、浮点运算次数(Floating point Operations, FLOPs)、模型大小(Size)、每秒帧数(Frame Per Second, FPS)和加速比(Speed-up)等指标进行评估。

4 实验结果与分析

4.1 模型训练

实验利用数据集对同时采用 Starlight 主干、CGRF 颈部网络和 ShareLN 检测头的 SatYOLO 模型进行训练,经过 300 次训练后,模型趋于收敛。模型训练的损失曲线如图 11 所示。训练完成后, SatYOLO 模型在测试集上的 P 为 92.6%, R 为 88.6%, mAP@50 为 85.8%, F1 值为 90.5%,性能相较于基准模型 YOLOv8n 仅有微小下降。与原模型相比, SatYOLO 模型的参数量减少 40.9%、计算量减少 50.0%,模型大小约为原先的 60%。综上所述,本文成功设计并训练出性能相近、轻量化程度显著优于原模型的非合作目标特征提取模型 SatYOLO。




图 11 SatYOLO模型损失曲线

4.2 模块有效性实验

4.2.1 归一化机制效果实验

在ShareLN检测头设计中采用LN层缓解批次敏感和主干颈部替换导致的性能损失问题。为验证该策略的有效性,在新型检测头中分别采用BN、GN和LN方法,同时将上述方法应用于YOLOv8n基准模型以及进行了网络结构替换的各个模型,并进行对比,实验结果如表2所示,其中第1组为原基准模型。

由表2数据可知,在采用默认BN层时,尽管新检测头能改善检测精确率,主干和颈部替换仍会导致召回率出现严重损失。当采用完整的SatYOLO网络结构且不引入LN层时,召回率跌至41.0%。而采用GN归一化时,虽然召回率下降情况得到缓解,但仍存在精确率下降的问题。综合对比3种归一化方法,采用LN层的第8~10组模型除精确率稍低于BN层外,在平均精度均值、召回率和F1值等方面均优于第2~4组的BN方法和第5~7组的GN方法,在改进模型性能方面具有优异效果。

表 2 归一化方法效果实验结果 单位:%

序号	归一化方法	主干改进	颈部改进	检测头改进	mAP@50	P	R	F1值
1	BN				90.2	95.1	88.6	91.7
2	BN			√	91.0	99.1	75.0	85.4
3	BN	√		√	86.3	99.1	61.3	75.7
4	BN	√	√	√	78.1	98.6	41.0	57.9
5	GN			√	91.6	93.8	89.7	91.7
6	GN	√		√	88.1	91.7	87.4	89.5
7	GN	√	√	√	84.6	89.4	85.2	87.3
8	LN			√	91.7	95.4	90.0	92.6
9	LN	√		√	88.3	90.2	87.6	88.9
10	LN	√	√	√	85.8	92.6	88.6	90.5

综上,本文选用LN层解决训练过程中数据和特征稳定性问题,在轻量化条件下实现了与原模型完全持平的召回率,且mAP@50、R和F1值均显著高于相同轻量化设计下其他归一化方法,证实该方法的有效性。

4.2.2 轻量化设计效果实验

为验证各项轻量化设计方法实际效果,在数据集上应用本文方法对YOLOv8n模型依次进行改进,并测试各模型轻量化效果。首先以YOLOv8n模型为基准,然后采用Starlight模块替换基准模型主干网络,再引入CGRF结构替换原颈部网络,最后使用ShareLN检测头替换原Detect检测头并得到SatYOLO模型。实验结果如表3所示。

表 3 SatYOLO轻量化设计方法效果

模型	参数量/ 10^6	计算量/GFLOPs	模型大小/MB	加速比
YOLOv8n	3.01	8.2	5.98	1.0
Starlight	2.14	6.2	4.33	1.4
Starlight+CGRF	2.18	4.5	4.46	1.4
Starlight+CGRF+ShareLN	1.78	4.1	3.66	1.7

由表3可得,Starlight模块、CGRF颈部网络和ShareLN检测头均能大幅减小模型计算量,其中Starlight模块和ShareLN检测头显著减少了模型参数量。引入Starlight模块,模型参数量由原来的 3.01×10^6 下降至 2.14×10^6 ,减少28.9%,计算量从8.2 GFLOPs降至6.2 GFLOPs,减少24.4%,加速比为1.4。引入

CGRF网络后,参数量回增1.8%,但计算量减少至原先的54.9%,达到4.5 GFLOPs。最后引入ShareLN轻量化检测头得到SatYOLO模型,参数量减少至 1.78×10^6 ,较YOLOv8n减少40.9%,计算量减少50.0%,加速比达到1.7。经过3种改进之后,模型的大小从5.98 MB减小至3.66 MB,压缩了40.8%。

综上所述,3种轻量化设计方法在减少参数量、计算量方面有显著效果。同时应用3种改进方法可大幅减小模型尺寸、节省模型计算消耗、有效降低模型的算力和内存开销。SatYOLO模型设计方法成功实现了模型轻量化目标。

4.2.3 检测头改进消融实验

模型压缩通常会在性能方面带来不利影响。验证SatYOLO轻量化效果后应考察模型的特征提取能力,以确保轻量化模型保持良好的精度。因此,在采用前述各种改进方法及其组合的模型上进行性能实验,并与YOLOv8n基准模型进行对比,以验证ShareLN检测头对特征提取任务的优化效果。实验结果如表4所示。

表 4 采用不同轻量化方法的ShareLN检测头消融实验 单位:%

Starlight	CGRF	ShareLN	mAP@50	P	R	F1值
			90.2	95.1	88.6	91.7
		√	91.7	94.2	90.3	92.2
√			87.5	92.8	87.7	90.2
√		√	88.8	91.9	87.7	89.7
	√		89.0	93.0	89.1	91.0
	√	√	91.4	93.6	90.0	91.8
√	√		86.0	91.9	84.8	88.2
√	√	√	85.8	92.6	88.6	90.5

由表3和表4数据可知,Starlight模块使模型压缩近25%,但对精度影响较大,使精确率和召回率都出现一定程度的下降。CGRF和ShareLN的引入在降低参数量和计算量的同时提升了模型性能,主要体现在模型召回率的提高。在分别单独引入CGRF和ShareLN结构时,模型召回率均高于YOLOv8n。ShareLN检测头的设计更在压缩参数和计算量的同时提升了mAP@50、召回率和F1值3项指标。由消融实验的结果能够看出,ShareLN的引入不仅对模型性能几乎没有较大影响,反而在多个指标上使模型性能得到进一步提升,实现了性能和轻量化的良好平衡。在同时应用3种改进方法的SatYOLO上,mAP@50仅降低4.4个百分点,F1值降低1.2个百分点,P下降2.5个百分点,R与原模型持平。

综上,同时应用本文所提的3种改进方法得到了在轨非合作目标轻量化特征提取模型SatYOLO。SatYOLO在TangoData目标数据集上的mAP@50为85.8%,P为92.6%,R为88.6%,F1值达到90.5%。在性能损失微小的同时,参数量减少40.8%,计算量减少50.0%,模型大小减少38.8%,加速比为1.7。SatYOLO成功地在保证性能的前提下实现了轻量化目标。

4.3 对比实验

为验证SatYOLO模型的优势,将SatYOLO模型与一系列其他主流轻量化技术和目标检测算法在TangoData数据集上进行对比实验。实验结果如表5所示。

表 5 不同视觉模型性能实验

模型	mAP@50/%	参数量/ 10^6	计算量/GFLOPs	FPS	模型大小/MB
Faster R-CNN	56.8	41.31	63.6	42.8	158.10
YOLOv5n	89.6	2.51	7.2	133.3	5.10
YOLOX	81.0	2.24	6.9	160.3	17.40
YOLOv8n	90.2	3.01	8.2	155.5	6.00
YOLOv10n	90.7	2.27	6.5	90.3	5.50
GSyolov8n ^[26]	90.5	2.92	8.1	150.7	5.82
SatYOLO	85.8	1.78	4.1	175.2	3.66

根据表5的结果进行分析,认为改进得到的SatYOLO模型在确保精度受损较小的前提下,相较于其他主流目标检测技术体现出显著的轻量化、高性能特点。在mAP@50指标上,SatYOLO

模型低于最优的小型化模型 YOLOv10n 不到 5 个百分点,而模型参数量 1.78×10^6 ,计算量 4.1 GFLOPs 和模型大小 3.66 MB 均达到了最低,同时在 FPS 表现上也达到了最高值 175.2,相较于原始模型降低了 50.0% 的计算量,参数量压缩了超过 40%,精度为原先的 95%,在具备良好性能和轻量化特征的同时,为在轨非合作目标特征提取任务提供了出色的实时性。当前星上存储资源通常在几兆到上百兆字节,留给智能检测模型的存储空间可在 5~20 MB,对比实验中的视觉模型仅有 SatYOLO 的大小在 5 MB 以下,其余模型在最小尺寸下的体积仍为 5 兆到上百兆字节,因此本文模型的压缩效果对于在轨计算平台部署具有重要的实用

意义。综合评估,在面对在轨边缘计算平台资源约束下的在轨非合作目标视觉特征提取任务中,本文 SatYOLO 模型在良好的检测精度下实现了最低的计算资源开销,从而在总体性能上脱颖而出。

图 12 展示了 SatYOLO 模型与 YOLOv5n、YOLOv8n 和 YOLOv10n 在测试集图片上的检测结果示例,其中用白色框标出了漏检的目标特征。经测试发现,SatYOLO 对于图片中暗部的 FFRF 天线与传感器等细节有更好的特征提取效果,并且检出率稳定,不易出现边缘位置和暗部漏检等情况,尤其对于天线特征具有很好的敏感性和检出效果。




图 12 4 种模型特征提取效果示例

为进一步体现 SatYOLO 模型在算力敏感环境下的优越性和应用意义,在 NVIDIA Jetson Nano 平台上使用 TensorRT 框架对 SatYOLO 模型进行了 FP32 和 INT8 格式量化部署实验,并与 YOLOv8n 基准模型进行对比,实验结果如表 6 所示。

表 6 SatYOLO 硬件部署实验结果

模型	框架	精度格式	模型大小/MB	mAP@50/%	FPS
YOLOv8n	PyTorch	FP32	6.0	90.2	12
SatYOLO	PyTorch	FP32	3.7	85.8	15
YOLOv8n	TensorRT	FP32	9.8	90.2	22
SatYOLO	TensorRT	FP32	5.7	85.7	28
YOLOv8n	TensorRT	INT8	6.2	80.7	27
SatYOLO	TensorRT	INT8	3.1	82.4	35

由表 6 可知,经过轻量化设计的 SatYOLO 模型对于数值量化具有良好的适应性,尤其在采用 INT8 数值精度格式时,SatYOLO 的平均精度损失较小,相较于 YOLOv8n 高出 1.7 个百分点,而模型大小为 YOLOv8n 的 50%。此外,SatYOLO 模型在 TensorRT 框架下能够得到有效的加速,相较于 YOLOv8n 模型在加速和量化后帧率为 22 到 27 FPS,经过 INT8 量化之后的 SatYOLO 可以实现超过 30 FPS 的推理速度,并且未出现严重的性能损失情况,这为面向在轨边缘计算平台的特征提取任务提供了十分可靠的实时性保障。

5 结语

针对在轨非合作目标视觉特征提取任务中计算资源受限、

对实时性和计算开销敏感的问题,本文提出基于 YOLOv8 改进的 SatYOLO 模型。首先,提出 Starlight 主干网络模块,通过替代原 C2f 模块减少了模型参数量与计算量,压缩了模型大小;其次,基于 RCA 机制设计了新的 CGRF 颈部网络结构,通过 ICF 和 CIDF 两种多尺度特征融合模块实现了 RCM 特征图的融合与前景目标提取性能优化,提高了模型的检测能力;最后,设计了新型轻量化检测头 ShareLN,通过参数共享方法减少了检测头参数量,进一步压缩了模型尺寸并提升了识别效果,引入 LN 归一化层缓解了轻量化结构设计带来的性能损失问题,增强了模型的目标视觉特征提取能力。分析表明,以上 3 种方法对参数量降低和模型压缩的轻量化效果较为明显。

实验结果表明,当模型平均精度 mAP@50 为 85.8% 时,相较于基准方法,参数压缩幅度超过 40%,计算量压缩达到 50%,可以较好满足边缘计算的环境需求。虽然 SatYOLO 模型对于在轨非合作目标有良好的特征提取效果,但仍有可研究的工作,可以考虑综合模型量化和结构化剪枝等技术优化压缩效果,进一步探索模型在异构计算平台上的部署效果和计算性能指标,为空间任务场景中的实际应用继续开展技术预研。

参考文献 (References)

[1] CHEN L, HUANG P, CAI J, et al. A non-cooperative target grasping position prediction model for tethered space robot [J]. Aerospace Science and Technology, 2016, 58: 571-581.
[2] 罗亚中,李振瑜,祝海. 航天器轨道追逃微分对策研究综述[J]. 中国科学:技术科学, 2020, 50(12): 1533-1545.
[3] ZHANG Y, WANG J, CHEN J, et al. A space non-cooperative target recognition method for multi-satellite cooperative observation systems

- [J]. Remote Sensing, 2024, 16(18): No. 3368.
- [4] 何英姿,杜航,张海博. 基于深度学习的非合作目标感知研究进展[J]. 飞控与探测, 2023, 6(1): 1-14.
- [5] REDMON J, DIVVALA S K, GIRSHICK R, et al. You only look once: unified, real-time object detection[C]// Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2016: 779-788.
- [6] LIU W, ANGUELOV D, ERHAN D, et al. SSD: single shot MultiBox detector [C]// Proceedings of the 2016 European Conference on Computer Vision, LNCS 9905. Cham: Springer, 2016: 21-37.
- [7] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020, 42(2): 318-327.
- [8] GIRSHICK R, DONAHUE J, DARRELL T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]// Proceedings of the 2014 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2014: 580-587.
- [9] REN S, HE K, GIRSHICK R, et al. Faster R-CNN: towards real-time object detection with region proposal networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(6): 1137-1149.
- [10] SUN P, ZHANG R, JIANG Y, et al. Sparse R-CNN: an end-to-end framework for object detection [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 45(12): 15650-15664.
- [11] YANG G, WANG J, NIE Z, et al. A lightweight YOLOv8 tomato detection algorithm combining feature enhancement and attention [J]. Agronomy, 2023, 13(7): No. 1824.
- [12] 徐云飞,张笃周,王立,等. 非合作目标局部特征识别轻量化特征融合网络设计[J]. 红外与激光工程, 2020, 49(7): No. 20200170.
- [13] 吕晓宁,夏玉立,赵军锁,等. 在轨光学目标检测模型轻量化研究[J]. 遥感学报, 2024, 28(4): 1041-1051.
- [14] BOCHKOVSKIY A, WANG C Y, MARK LIAO H Y. YOLOv4: optimal speed and accuracy of object detection [EB/OL]. [2025-01-01]. <https://arxiv.org/pdf/2004.10934>.
- [15] TIAN Z, SHEN C, CHEN H, et al. FCOS: a simple and strong anchor-free object detector [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 44(4): 1922-1933.
- [16] WU Y, HE K. Group normalization [C]// Proceedings of the 2018 European Conference on Computer Vision, LNCS 11217. Cham: Springer, 2018: 3-19.
- [17] PARK T H, MÄTENS M, LECUYER G, et al. SPEED+ : next-generation dataset for spacecraft pose estimation across domain gap [C]// Proceedings of the 2022 IEEE Aerospace Conference. Piscataway: IEEE, 2022: 1-15.
- [18] GALEAZZI C, SACCHETTI A, CISBANI A, et al. The PRISMA program [C]// Proceedings of the 2008 IEEE International Geoscience and Remote Sensing Symposium. Piscataway: IEEE, 2008: IV-105-IV-108.
- [19] NI Z, CHEN X, ZHAI Y, et al. Context-guided spatial feature reconstruction for efficient semantic segmentation [C]// Proceedings of the 2024 European Conference on Computer Vision, LNCS 15110. Cham: Springer, 2024: 239-255.
- [20] HAN K, WANG Y, TIAN Q, et al. GhostNet: more features from cheap operations [C]// Proceedings of the 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2020: 1577-1586.
- [21] HOWARD A G, ZHU M, CHEN B, et al. MobileNets: efficient convolutional neural networks for mobile vision applications [EB/OL]. [2025-01-01]. <https://arxiv.org/pdf/1704.04861>.
- [22] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need [C]// Proceedings of the 31st International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2017: 6000-6010.
- [23] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16x16 words: Transformers for image recognition at scale [EB/OL]. [2025-01-01]. <https://arxiv.org/pdf/2010.11929>.
- [24] LIU Z, LIN Y, CAO Y, et al. Swin Transformer: hierarchical Vision Transformer using shifted windows [C]// Proceedings of the 2021 IEEE/CVF International Conference on Computer Vision. Piscataway: IEEE, 2021: 9992-10002.
- [25] MA X, DAI X, BAI Y, et al. Rewrite the stars [C]// Proceedings of the 2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2024: 5694-5703.
- [26] LI H, LI J, WEI H, et al. Slim-neck by GSConv: a lightweight-design for real-time detector architectures [J]. Journal of Real-Time Image Processing, 2024, 21(3): No. 62.