



计算机工程与应用
Computer Engineering and Applications
ISSN 1002-8331, CN 11-2127/TP

《计算机工程与应用》网络首发论文

题目：深度学习在光伏组件缺陷检测中的应用与挑战综述
作者：王育欣，李硕，汪凯明，李雅维，张智皓，霍相佐
网络首发日期：2026-08-28
引用格式：王育欣，李硕，汪凯明，李雅维，张智皓，霍相佐. 深度学习在光伏组件缺陷检测中的应用与挑战综述[J/OL]. 计算机工程与应用.
<https://link.cnki.net/urlid/11.2127.tp.20260827.1335.002>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

深度学习在光伏组件缺陷检测中的应用与挑战综述

王育欣^{1,2}, 李硕^{1,2}, 汪凯明^{1,2}, 李雅维^{1,2}, 张智皓^{1,2}, 霍相佐^{1,2+}

1.农业农村部智慧养殖重点实验室(部省共建), 天津 300380

2.天津农学院计算机与信息工程学院, 天津 300380

+ 通信作者 E-mail: huoxiangzuo@163.com

摘要: 在“碳中和”战略推动下, 光伏已成为全球清洁能源的主力。长期户外服役中的环境应力会导致组件产生裂纹、热斑及PID等缺陷。传统的接触式测试与人工巡检方式存在效率低下、主观性强及漏检率高等弊端, 已难以满足大规模光伏电站的智能化运维需求。深入解析了可见光、红外热成像、电致发光及光致发光等多模态成像的物理机理, 并从特征工程到特征自学习的角度, 系统回顾了检测技术从传统图像处理、机器学习向深度学习演进的历程。针对当前技术面临的“小样本”匮乏、多尺度目标检测难及边缘计算算力受限等瓶颈问题进行剖析。重点阐述了以YOLO系列、Vision Transformer为代表的深度学习算法在缺陷检测、语义分割及多模态融合方面的最新研究进展, 探讨基于生成对抗网络的数据增强策略。下一代智能检测技术不应止步于“缺陷识别”, 而应向“缺陷致害性量化”与“组件剩余寿命预测”深层拓展。通过将多模态检测数据与数字孪生系统深度融合, 建立缺陷演化与功率衰减的映射关系, 实现从“感知智能”向“认知决策”的跨越, 为光伏电站的全生命周期健康管理提供可解释的科学依据。

关键词: 光伏组件; 缺陷检测; 深度学习; 多模态成像; 目标检测; 边缘计算

文献标志码:A 中图分类号:TP391.41 doi: 10.3778/j.issn.1002-8331.2603-0343

Deep Learning for Photovoltaic Module Defect Detection: A Comprehensive Review of Applications and Challenges

WANG Yuxin^{1,2}, LI Shuo^{1,2}, WANG Kaiming^{1,2}, LI Yawei^{1,2}, ZHANG Zhihao^{1,2}, HUO Xiangzuo^{1,2+}

1.Key Laboratory of Smart Breeding (Co-construction by Ministry and Province), Ministry of Agriculture and Rural Affairs, Tianjin Agricultural University, Tianjin 300380

2.School of Computer and Information Engineering, Tianjin Agricultural College, Tianjin 300380, China

Abstract: Driven by the global "carbon neutrality" strategy, photovoltaics (PV) has become the backbone of clean energy. However, environmental stresses during long-term outdoor operation induce defects such as cracks, hot spots, and PID in PV modules. Traditional inspection methods are inefficient and subjective, failing to meet the intelligent O&M requirements of large-scale PV plants. This review analyzes the physical mechanisms of multi-modal imaging (visible light, IRT, EL, PL) and traces the evolution of defect detection from traditional image processing to deep learning, shifting from feature engineering to self-learning representation. Current bottlenecks, including small-sample limitations, multi-scale detection challenges, and restricted edge computing power, are comprehensively analyzed. Recent advancements in deep learning—particularly YOLO and Vision Transformers—are highlighted in the context of defect detection, semantic segmentation, and multi-modal fusion, alongside GAN-based data augmentation strategies. It is proposed that future intelligent detection must evolve beyond "defect recognition" toward "severity quantification" and "remaining useful life (RUL) prediction." Integrating multi-modal data with digital twin systems to map defect evolution against power degradation will enable a leap from "perceptual intelligence" to "cognitive decision-making," offering an interpretable scientific basis for the full life-cycle health management of PV modules.

Key words: Photovoltaic modules; Defect detection; Deep learning; Multi-modal imaging; Object detection; Edge computing

基金项目: 农业农村部智慧养殖重点实验室(部省共建), 天津农学院; 天津农学院实验教学和教学实验室建设研究项目(2024-3-01); 中国电子劳动学会“产教融合, 校企合作”教育改革发展课题(Ceal2024104); 中国高校产学研创新基金-新一代信息技术创新重点项目(2022IT017); 天津农学院人才资助计划项目(Y0400907); 天津农学院研究生教育教学研究与改革重点项目(2021-YA-6); 天津市研究生科研创新项目(2022SKYZ258)资助项目。

作者简介: 王育欣(1976—), 男, 工学博士, 三级教授, 硕士生导师, CCF高级会员, 研究方向为农业信息化技术、农业大数据技术、农业技术装备新能源利用技术、新能源发电控制技术等; 李硕(2001—), 男, 硕士研究生, 研究方向为计算机视觉、光伏发电检测技术; 汪凯明(2001—), 男, 硕士研究生, 研究方向为图像处理、新能源发电控制技术等; 李雅维(2001—), 男, 硕士研究生, 研究方向为新能源发电控制技术; 张智皓(2002—), 男, 硕士研究生, 研究方向为计算机视觉、农业大数据技术; 霍相佐(1996—), 男, 博士, 硕士生导师, 研究方向为计算机视觉、图像处理、大模型微调分析等。

能源是人类社会生存与发展的物质基础。面对日益严峻的化石能源枯竭危机与全球气候变暖挑战，大力发展可再生能源已成为世界各国的战略共识。太阳能光伏（Photovoltaic, PV）发电凭借其清洁无污染、资源无限及分布广泛等优势，装机容量近年来呈爆发式增长。据国际能源署（IEA）预测，光伏发电将逐步演变为全球能源结构中的支柱力量。然而，随着光伏电站建设规模从兆瓦（MW）级向吉瓦（GW）级迈进，且多分布于荒漠、戈壁、山地等自然环境恶劣地区，海量组件的运维管理（Operation and Maintenance, O&M）面临着巨大的技术挑战与成本压力。在高度市场化的电力竞争环境下，运维效率的毫厘之差将直接传导至电站的资产收益率，这迫使行业必须寻求从“人力密集型”向“技术驱动型”的智慧运维转型。

光伏组件作为光电转换系统的核心单元，其运行可靠性直接决定了电站的发电效益。在制造、运输、安装及全生命周期的户外运行过程中，组件易受到外力冲击、温度剧变、紫外线辐射及水汽渗透的影响，从而产生不可逆的物理缺陷。研究表明，微裂纹（Micro-cracks）在长期的热胀冷缩作用下会扩展为断栅，导致串联电阻增加和填充因子下降，造成显著的功率损失（Power Loss）；而严重的局部遮挡或内部电路故障会引发热斑效应（Hot Spots），局部高温若超过封装材料的承受极限（如150°C），将导致背板烧穿甚至引发火灾，对电站资产安全构成严重威胁。因此，实现高效、精准且自动化的缺陷检测与定位，对于保障光伏电站的全生命周期平准化度电成本（LCOE）和投资回报率具有重要的科学意义与工程应用价值。长期以来，光伏电站的运维主要依赖人工携带手持式电流-电压 I-V 测试仪或热像仪进行抽检。这种“事后维修”模式不仅劳动强度大、检测效率低下，而且受限于检测人员的经验水平，易出现漏检和误判，且难以覆盖大规模光伏阵列。早期检测主要依赖传统图像处理与统计分类器，但因超参数整定繁琐、环境泛化差，已转向端到端的深度学习范式。随着人工智能（AI）与计算机视觉（CV）技术的飞速发展，特别是深度学习在图像识别领域的突破性进展，基于图像分析的自动化

缺陷检测技术应运而生。该技术能够从海量监控数据中自动挖掘缺陷特征，成为提升光伏电站智能化运维水平的关键技术手段。伴随人工智能技术在光伏运维领域的爆发，近年来已涌现出若干十分具有学术价值的综述性文献^[1, 2, 3]。然而，深入审视这些已有研究可以发现，其在分析维度与工业契合度上仍存在显著的局限性。例如，Hijjaw 等^[1]与王小宇等^[3]系统梳理了光伏阵列的自动化缺陷检测与故障诊断系统，但其落脚点多偏向于传统的电气特征建模（如 I-V 曲线变异）与宏观检测框架，对近两年涌现的生成式数据增强（GAN）、无监督异常重构等深度学习最前沿视觉算法的探讨明显滞后。另一方面，部分侧重于计算机视觉领域的综述则容易陷入“唯算法论”的窠臼。例如，Hussain 等^[2]详尽追溯了自 YOLOv1 至 YOLOv10 的网络架构演进轨迹，但其讨论大多局限于单一的可见光或红外模态下的公开数据集刷榜（追求极高的 mAP），完全剥离了光伏电站真实的非结构化环境噪声干扰，亦未能触及算法在实际工业部署中的核心痛点。综上所述，现有综述普遍存在三大研究空白：一是缺乏对可见光、红外热成像与电致发光（RGB-IRT-EL）等多源异构模态跨层级融合的系统梳理；二是脱离了边缘计算侧（如无人机机载芯片）严苛的“算力-功耗（SWaP-C）”物理壁垒，导致诸多高分重型模型难以落地；三是“将“边界框定位”视为视觉检测的终点，未能将其与缺陷的物理致害性及组件剩余寿命（RUL）预测建立深度映射。本文与现有代表性综述的具体对比如表 1 所示。

立足于上述研究空白，本文突破了纯算法理论的局限，构建了“物理成像机理—算法架构演进—工业落地约束”的全链路技术体系。为明确本文相较于现有综述的不可替代性，本文突破了纯算法理论的局限，将核心学术增量提炼并强化为以下三大维度：(1)多模态深度融合与物理瓶颈突破：突破了现有综述偏重单一模态的局限，系统剖析了 RGB-IRT-EL 多源异构数据的特征空间对齐机制，并深入探讨了特征-决策混合架构在解决户外电站“模态缺失与冲突”等真实物理痛点中的前沿突破。(2)边缘算力约束下的轻量化落地剖析：摒弃了脱离硬件的

“唯精度论”，深度剖析了“算力-功耗-精度”的严苛博弈，全面论证了算子重参数化、硬件感知架构搜索（NAS）等轻量化策略在无人机移动终端部署中的工程必要性与适配边界。(3)缺陷致害性量化与寿命预测新范式：创新性地引入从“图像定性画框”向“缺陷致害性定量决策”跨越的理念，探讨了将像素级视觉感知与组件电气特征、数字孪生系统深度融合的演进路径，为光伏电站全生命周期健康管理（PHM）提供了可解释的科学依据。

表 1 本文与现有光伏缺陷检测代表性综述的深度对比

文献	侧重研究方向	多模态协同深度	边缘算力与落地约束评估	核心局限性	本文的学术增量应对
Akram 等 ^[4] (2022)	光伏组件失效机理及宏观红外检测	单一模态（仅侧重红外热成像）	未探讨无人机机载端算法轻量化问题	局限于热力学表征,未涉及缺陷的像素级语义分割与微观视觉诊断	补齐 EL 图像与 RGB 的微观特征提取与模态协同分析
Buerhop 等 ^[5] (2022)	吉瓦级电站红外成像的挑战与开展	侧重无人机 IR 巡检框架	侧重飞行平台与传感器,缺乏算法底层优化分析	未涵盖无监督学习与异常重构等深度学习前沿架构	深度剖析 Vision Transformer 与无监督异常重构在工业现场的局限
Hijjawi ^[1] (2023)	传统自动化系统与电气诊断框架	浅层(侧重宏观热成像与电学感知)	未涉及硬件算力分析	侧重传统电气诊断系统,缺乏对生成式大模型(GAN)与无监督学习的纵深探讨	系统引入视觉大模型与无监督重构前沿进展
Hussain ^[4] (2024)	单一深度学习架构演进(YOLO 家族)	浅(聚焦单一图像模态的目标检测)	仅评估推理速度,缺乏边缘功耗深度剖析	聚焦单一图像模态,未涉及多模态融合(RGB-IRT-EL)技术与域漂移分析	深度剖析算法在复杂背景下的特征混淆物理根源
王小宇 ^[3] (2024)	阵列级电气特征建模与故障预警	依赖电学传感器数据(I-V 曲线等)	侧重云端数据处理分析	偏重电学参量分析,缺乏对计算机视觉精细化几何量化(像素级语义分割)技术的探讨	建立从像素级视觉感知到物理功率衰减预测的桥梁
本文 (2026)	物理机理-前沿算法-工业落地全链路	深度全覆盖(系统梳理 RGB-IRT-EL 三大融合层级)	深度剖析算力瓶颈与轻量化架构搜索	-	打通从“感知智能”向“缺陷致害性量化”的认知决策闭环

本文后续章节的组织架构如下：第 1 章系统归纳光伏组件的常见缺陷类别，并明确缺陷检测的具体任务定义；第 2 章深入解析可见光、红外、电致发光等多模态成像技术的物理机理与工业适用性；第 3 章和第 4 章回顾检测技术的演进历程，并深度剖析当前深度学习在光伏工业落地中面临的关键瓶颈；第 5 章和第 6 章系统梳理主流开源数据集与评价指标，并重点阐述以 YOLO 系列、Vision Transformer 为代表的前沿算法在目标检测、精细化分割及边缘轻量化部署方面的最新研究进展；最后，第 7 章对检测技术向“缺陷致害性量化”等未来方向进行展望，并在第 8 章得出全文结论。

1 光伏组件缺陷检测与工程场景定义

长期暴露于户外的光伏组件易受机械载荷与环境热应力影响产生各类物理缺陷。不同于传统的成因分析，计算机视觉视角下的缺陷检测核心在于将这些物理损伤映射为图像特征提取任务。根据算法输出的几何粒度与工程适用场景，当前的自动化检测任务主要划分为三个层级：

(1) 图像级分类 (Image-level Classification)：旨在判定输入组件图像的全局状态（正常/异常类别）。其模型结构简单、算力开销小。在实际工程适用场景中，该任务主要部署于电站云端服务器，作为处理海量无人机巡检数据的“前置粗筛过滤器”，用于快速剔除占比极高的健康组件图像，从而大幅降低后续精细算法的计算负载^[6,7]。(2) 目标级检测 (Object-level Detection)：通过输出边界框 (Bounding Box) 界定缺陷的空间坐标与类别置信度。该任务在复杂背景下展现出优异的鲁棒性，

高度适配搭载于无人机 (UAV) 或智能巡检机器人的边缘计算节点，可实现高动态、高并发的实时在线巡检与故障位置精准定位派单^[2,8]。例如，2025 年最新提出的 GWPV-YOLO 架构，通过深度可分离卷积专门针对无人机热成像进行了极限轻量化，大幅提升了微小缺陷的实时捕获率^[9]。(3) 像素级语义分割 (Pixel-level Semantic Segmentation)：为图像逐像素分配类别标签，精确提取裂纹的蜿蜒路径或 PID 衰减的实际面积占比。该任务是当前计算复杂度最高的视觉范式。在应用场景上，其输出的细粒度几何参量是构建光伏电站数字孪生 (Digital Twin) 模型、关联电学 I-V 曲线演变，进而精确评估组件功率衰减率 (Power Loss) 与预测剩余寿命的核心算法底座^[10, 11]，近年来也正成为多模态特征空间对齐的核心手段^[12]。不同粒度下的光伏缺陷检测任务示意图如图 1 所示。




图 1 不同粒度下的光伏缺陷检测任务示意图

Fig.1 Schematic diagram of photovoltaic defect detection tasks at different particle size

2 光伏多模态成像的数据特征与视觉挑战

深度学习算法的性能强依赖于底层数据的物理表征质量。针对光伏组件复杂的缺陷类型，工业界衍生出多种成像模态。在计算机视觉视角下，不同模态为特征提取带来了截然不同的挑战：

可见光成像成本低廉且具备极高的空间分辨率，天然契合常规卷积神经网络，能直观提取积灰、玻璃碎裂等表面物理损伤^[13]。然而，其无法穿透 EVA 胶膜，对内部隐裂失效，且容易受强光反射与云层阴影等高频噪声干扰，导致单一视觉算法虚警率大幅提高^[14]。红外热成像（IRT）通过捕捉局部电流失配引发的异常温度梯度来定位热斑^[15]。其数据特征呈现出显著的“低频模糊性”，空间分辨率低且缺乏锐利的几何边缘。视觉算法面临的

主要挑战是如何在强自然对流与环境热反射的干扰下，有效抑制大量“伪热斑”的生成^[16]。为此，最新的研究趋势是构建跨模态语义网络（如 CMASegNet），利用可见光特征来补偿红外图像的几何缺失^[12]。电致/光致发光（EL/PL）作为透视晶硅内部健康状态的“金标准”^[17]，能清晰呈现非辐射复合暗区。但在深度学习视角下，其图像背景中充斥着复杂的晶界（Grain Boundaries）纹理。这种强烈的局部形态相似性，导致网络易在特征空间发生混淆^[18]，迫使学术界在近两年开始引入包含链式思维（Chain-of-Thought）的认知诊断架构以排除假阳性干扰^[19]。此外，实现全天候检测的“白昼 EL”技术虽突破了夜间作业限制，但其极低的信噪比（SNR）对现有视觉算法的底层去噪与特征剥离能力提出了极端考验^[20, 21]。

图 2 展示了不同成像模态下的光伏组件缺陷特征。




图 2 不同成像模态下的光伏组件缺陷特征对比

Fig.2 Comparison of defect characteristics in photovoltaic modules under different imaging modalities

为明晰异构传感器的感知边界，图 2 直观展示了同一缺陷在不同模态下的特征分化。其底层物理机制对比表明：(a) 可见光成像基于光子表面反射原理，主要捕获积灰、玻璃碎裂等宏观形貌异变，无法透视封装材料下方的晶硅电性失效；(b) 红外热成像（IRT）基于局域失配电流引发的热效应，呈现低频模糊阻抗梯度的热斑特征，空间几何轮廓缺失严重；(c) 电致发光（EL）成像依赖非辐射复合中心的少子辐射复合机制，能够以极高的空间分辨率直接透视晶硅内部的微观拓扑隐裂与断栅暗区。三者表现出强烈的机理互补性。

3 检测技术的发展过程与演进

回顾过去二十年，光伏组件缺陷检测算法经历了从人工特征设计到自动特征学习的跨越式发展，大致可划分为三个阶段。技术演进路线如图 3 所示。该图系统梳理了光伏缺陷检测技术从早期依赖人工特征工程，向基于深度学习的自动化、轻量化特征提取演进的四个核心阶段。整体技术路径成功实现了从宏观的“图像级定性分类”向微观的“像素级精细化”与“多模态协同决策”的底层逻辑跨越。



图3 光伏组件缺陷检测技术演进路线图

Fig.3 Evolution Roadmap of Photovoltaic Module Defect Detection Technology

4 深度学习光伏缺陷检测面临的挑战

4.1 小样本与长尾分布难题

在光伏电站的实际运维场景中，工业大数据呈现出典型的“海量特征、稀缺缺陷”的统计学长尾分布 (Long-tail Distribution) 特性。由于现代光伏组件制造工艺的成熟与出厂质控的严格，在实际采集的巡检图像中，超过 95% 的样本为结构完好的正常组件。相比之下，由极端机械载荷或长期热应力诱发的高致害性缺陷（如严重隐裂、局部烧毁、树枝状复合裂纹等）样本数量极少。这种严重的数据类别极度不平衡，构成了制约数据驱动模型向复杂工业场景泛化的首要物理限制。从深度学习的底层优化理论剖析，类别极度不平衡会显著破坏模型决策边界 (Decision Boundary) 的构建。在标准的反向传播训练过程中，海量正常样本（多数类）产生的损失梯度累积将绝对主导网络权重的更新方向。这种梯度主导效应导致模型对多数类样本产生严重的预测偏好，而对罕见缺陷类别（少数类）的特征空间表征极不充分。因此，在缺乏足够正样本驱动的情况下，深度学习模型易陷入过拟合状态，在工程测试中具体表现为对复杂混合型缺陷及长尾罕见缺陷的高漏检率。此外，当前主流的强监督学习范式对数据标签的高度依赖，进一步加剧了这一困境。特别是针对需要精确定量评估的

像素级任务（如 EL 图像语义分割），由于微裂纹等缺陷边缘模糊，且常与多晶硅天然晶界相混淆，其标注工作无法由普通众包人员完成，必须依赖具备光伏物理背景领域的专家。极其高昂的时间与人力成本，使得构建大规模、高质量、包含全类型缺陷的精细化标注数据集变得极不现实^[22, 23]。

面对由长尾数据分布与高昂标注成本构成的双重技术壁垒，单纯依赖扩大真实物理采样的传统路径已触及瓶颈。为突破该限制，当前主流算法研究正逐步向两大核心路径演进：一是引入生成式人工智能 (Generative AI) 技术进行少数类样本的定向合成与数据增强；二是有效的摆脱人工标签依赖，探索基于正常样本重构的无监督异常检测 (Unsupervised Anomaly Detection) 新范式。

4.2 多尺度目标特征提取困难

光伏组件缺陷在物理形貌上呈现出极其显著的跨尺度分布特性 (Multi-scale Features)，这给视觉检测算法的特征统筹能力带来了巨大的挑战。在微观维度，细微隐裂或初期金属断栅的宽度往往仅占整幅高分辨率巡检图像的 1~2 个像素，属于典型的极弱小目标；而在宏观维度，电势诱导衰减 (PID)、大面积热斑或玻璃大片碎裂则可能蔓延至整块甚至多块电池片区域^[24, 25]。这种极端的目标尺度极化现象，要求检测网络必须具备极强的

尺度自适应表征与几何畸变容忍能力。网络通常依赖逐层递进的池化 (Pooling) 与步长卷积 (Strided Convolution) 进行下采样, 以获取更高维度的抽象语义。该机制在表征大面积故障时表现稳定, 但对于亚像素级的微裂纹而言, 随着网络深度的增加, 其原本极其微弱的空间高频特征会在前向传播中被逐渐平滑乃至消失^[18, 22]。在微观模块设计上, 以线性注意力机制 (Linear Attention) 为代表的高效特征提取范式开始展现出卓越的工程潜力。这类结构能够以较低的计算复杂度 (FLOPs) 突破局部卷积的限制, 直接构建全局级别的感受野以感知大尺度衰减区域的上下文关联。特别是针对极细微目标的检测瓶颈, 轻量化 Transformer 架构利用全局序列建模有效地挽救了被传统下采样算子平滑掉的空间高频细节, 为多尺度缺陷的自适应表征提供了全新的理论解法^[26]。

4.3 边缘侧部署的算力瓶颈

现阶段, 以视觉 Transformer (ViT) 和两阶段目标检测器 (如 Faster R-CNN) 为代表的高精度检测模型, 其卓越的泛化能力往往建立在庞大的参数规模与极高的计算复杂度之上。这类网络架构内部充斥着海量的稠密矩阵乘法操作与全局自注意力计算, 其参数量 (Parameters) 通常突破上亿级别, 单次前向推理的浮点运算次数 (FLOPs) 高达数十乃至数百 GFLOPs。在离线数据分析中心, 此类模型严重依赖具备极高内存带宽与张量核心 (Tensor Cores) 的企业级 GPU 服务器集群, 以此来掩盖庞大计算量带来的时间延迟。面对光伏电站广袤的地理分布, 完全依赖“端-云”协同架构会受限于偏远地区网络带宽的波动, 导致不可接受的传输延迟与数据安全隐忧。因此, 将检测算法直接下沉至无人机 (UAV) 机载计算盒子或手持式智能巡检终端等边缘设备 (Edge Devices), 成为了产业发展的必然路径^[27]。在实际的无人机高动态巡检中, 强行部署未优化的深层网络将引发严重的算力过载与计算瓶颈。这不仅会引发推理帧率的显著下降, 造成动态航拍图像的大量漏检, 还会因处理器满负荷运转触发芯片的过热降频保护 (Thermal

Throttling)。这种算力过载会迅速消耗机载电池电量, 大幅缩短无人机的安全飞行作业时间, 丧失了实时在线预警的工程意义^[8, 28]。为弥合这一算力鸿沟, 模型轻量化 (Model Lightweighting) 与边缘部署加速已成为当前最紧迫的研究分支。学术界正致力于通过算法层面的“网络轻量化设计”来打破硬件枷锁: 一方面, 大量引入结构化剪枝 (Pruning)、低比特数值量化 (如 INT8/FP16 量化) 以及知识蒸馏 (Knowledge Distillation) 等后处理技术, 在微小精度损失的前提下极限压缩模型显存占用; 另一方面, 基于深度可分离卷积 (Depthwise Separable Convolution) 与结构重参数化 (Re-parameterization) 技术构建新型极简主干网络, 并结合 TensorRT 等底层推理引擎进行算子融合 (Operator Fusion), 力求在极低功耗下逼近边缘芯片的理论算力极限。

4.4 物理成像机制的模糊性

光伏组件缺陷的视觉表征在不同物理成像模态下存在显著的本征模糊性 (Intrinsic Ambiguity) 与特征混淆现象。以红外热成像 (IRT) 为例, 传感器捕捉到的二维温度场分布, 本质上是组件内部热源经过硅片、EVA 胶膜与玻璃盖板层层热传导后的宏观物理表现。由于热扩散过程在空间域上等效于一个低通滤波器 (Low-pass Filter), 不同致热机理的故障在组件表面往往呈现出高度趋同的温度梯度。单一的红外模态缺乏深度的空间几何信息, 导致视觉算法无法从逆问题的角度唯一确定热源的物理属性。这种由成像机制引发的表征模糊性在电致发光 (EL) 图像中同样极为突出, 并成为多晶硅组件缺陷检测的底层理论阻碍。在 EL 测试的正向偏置下, 电池片内部的非辐射复合中心会在图像中呈现为低灰度的暗区。多晶硅材料在铸锭结晶过程中天然形成的错综复杂的晶界 (Grain Boundaries), 与其在服役期间受机械应力诱发产生的微裂纹, 在半导体物理机理上均属于阻碍少数载流子扩散的屏障^[29]。在缺乏全局语义上下文和跨区域晶粒排布规律辅助的情况下, 网络难以将具有高度致害性的微隐裂从密集的背景晶界网络中精准剥离。这种特征空间中的高度线性不可分性, 构成了工业现场多晶硅组件自动化检测中虚警率 (False Alarm Rate) 居

高不下的物理根源。

针对上述因单一物理成像机制受限而导致的特征混淆难题，当前的检测范式正不可逆转地向多模态信息融合（Multi-modal Fusion）方向演进。通过高精度的空间配准技术，将可见光图像中提取的表面遮挡物物理轮廓与红外热斑的异常温度区域进行跨模态交叉验证，可有效剔除由外部环境干扰形成的“伪热斑”。同时，在针对 EL 图像的特征解耦网络设计中，引入能够感知组件全局拓扑关系的注意力机制或结构先验模块，正成为突破背景纹理混淆、降低模型误判率的关键理论路径。

4.5 监督学习范式的局限性

当前主流的光伏视觉检测模型绝大多数遵循全监督学习（Fully Supervised Learning）范式。该范式的底层数学逻辑建立在严格的闭集（Closed-set）假设之上，即要求测试集的数据分布必须高度服从训练集的先验分布。这种强烈的标签依赖性导致模型的特征提取上限被人工标注数据的规模与物理保真度锁定^[30]。当模型部署于真实电站时，面对由新批次组件材料、不同制造工艺或极端非典型环境应力诱发的未知异常特征，全监督模型往往表现出极差的分布外（Out-of-Distribution, OOD）泛化能力，易将未见过的缺陷变体误判为正常背景^[31]。深入

探究光伏组件内部物理缺陷的演化机理可知，其形态具有高度的随机性与拓扑复杂性。与高质量缺陷样本极度匮乏形成鲜明对比的是，光伏电站的日常无人机巡检每天都在产出海量的无标签（Unlabeled）基准图像。全监督学习机制由于缺乏自主探索无标签数据内在空间流形（Spatial Manifold）的优化通道，导致这部分蕴含极其丰富底层多晶硅物理纹理信息的“暗数据”被长期闲置^[32]。为打破这一范式僵局，突破现有模型的泛化天花板，探索自监督学习（Self-Supervised Learning, SSL）与无监督异常挖掘正成为该领域的必由之路^[33]。利用对比学习（Contrastive Learning）或掩码图像建模（Masked Image Modeling）等前沿机制，迫使网络在无标签海量数据上进行高维特征的自回归重建或空间对齐，从而提取出独立于特定人工标签的通用光伏特征表示，是应对开放场景复杂缺陷的核心理论路径。

为系统性地呈现这一贯穿算法设计与工程落地全链路的结构矛盾，图 4 对当前光伏组件缺陷检测面临的多维物理与算法瓶颈进行了综合归纳与剖析。该图直观地揭示了从底层数据长尾分布、多尺度特征提取困境、多模态特征混淆，一直延伸至边缘算力受限与学工两界评价体系脱节的连锁反应。突破这一僵局，迫切要求未来的算法研究从单一的精度导向，全面转向“硬件感知（Hardware-aware）”与“部署友好”的端边缘协同设计新范式。




图 4 光伏组件缺陷检测面临的挑战及成因分析

Fig.4 Challenges and Cause Analysis of Defect Detection in Photovoltaic Modules

4. 6 核心挑战应对策略的系统对比与工业落地
制约剖析

尽管学术界针对上述四大光伏工业挑战（长尾分布、多尺度特征、算力瓶颈、模态模糊）提出了众多前沿深度学习解决方案，但这些方案在实际光伏电站的复杂、

高动态运维环境中，均表现出截然不同的适用边界与本征局限。为了宏观厘清各类视觉算法在真实工业闭环中的技术上限，避免“唯指标论”的盲目部署，本文将当前主流的前沿解决方案进行了系统维度的梳理。表 2 从工程视角出发，深度对比了这些方案在不同任务粒度下的适用场景、核心技术优势和量化性能提升，并重点剖析了它们向产业化跨越时面临的底层制约因素。

表 2 光伏缺陷检测前沿解决方案的系统性对比与核心落地制约因素剖析

Table 2 State-of-the-Art PV Defect Detection Solutions and Deployment Constraints

核心工业挑战	代表性前沿解决方案	最佳工业适用场景	核心技术优势	核心局限性	本文的学术增量应对
小样本 与长尾分布	生成对抗网/无监督异	极度缺乏缺陷标签的	零样本/少样本学习；免除	合成样本存在域	无监督网络在试图重构复杂晶界时，易产生巨大的像素残差伪影，导致虚警率（FAR）居高不下。
	常重构	早期电站	像素级专家标注成本。	鸿沟	
多尺度微弱缺陷提取	视觉大模型 (SAM/ViT)	电站云端服务器的高	全局感受野；有效克服常	自注意力计算复	分辨率与内存峰值悖论。全局自注意力机制的计算复杂度呈 $O(N^2)$ 平方级增长。若输入高清原图，会产生庞大的中间特征图导致边缘设备显存溢出（OOM）；若强行下采样，微弱裂纹将缺失。
	/ 特征金字塔 (BiFPN)	精度离线分析	规卷积下采样引发的特征断裂。	杂度高	
边缘计算算力受限	轻量化重构 (YOLO) +	无人机/智能巡检机器	低热设计功耗 (TDP)；极	低对比度易发特	“轻量化陷阱”与特征坍塌。极端剥离算力与压缩通道，会严重削弱模型在低对比度、低信噪比（如户外红外热成像）环境下的拟合能力，导致微小热斑漏检率在复杂背景下大幅升高。
	硬件感知架构搜索 (NAS)	人高频动态在线检测	低内存读写带宽占用。	征坍塌	
物理成像机制模糊	多模态特征融合网络	复杂户外强干扰多	打破单传感器物理感知盲	异构传感器难对	空间异质性对齐极其困难。无人机高频机械振动与飞行姿态变化带来的帧间微小形变，会直接摧毁数据级与特征级融合的像素对齐精度，引发严重的重影与梯度冲突。
			区；实现表观几何与内部电性交叉验证。	齐	

深入剖析表 2 中的制约因素可知，光伏工业现场的算法落地本质上受困于“检测精度、推理延迟、边缘功耗（SWaP-C）”构成的不可能三角（Impossible Trinity）。纯粹追求多尺度召回率的全局感知架构，必然导致边缘算力过载与热降频（Thermal Throttling）；而极端追求实时性的轻量化算力裁剪，又注定在面对复杂多晶硅晶界时丧失特征剥离的敏锐度。因此，未来的工程解法不应再局限于单一维度的网络层数堆叠，而必须向“硬件感知架构搜索（Hardware-aware NAS）”以及“云边多级协同诊断”的系统级优化方向演进，这正是智能算法跨越实验室理论原型、转化为大规模光伏电站真实生产力的核心壁垒。

为破除这一由“精度—延迟—功耗”构成的难题，硬件感知架构搜索（Hardware-aware NAS）已演进为当前

多模态和边缘计算部署的重要前沿技术路径。传统的人工网络压缩机制高度依赖工程经验，且特征通道的无序裁剪极易触发红外或 EL 图像中的低频特征坍塌。与之相比，硬件感知 NAS 技术将目标终端硬件（如边缘嵌入式芯片、NPU）的真实前向推理时延、内存读写带宽以及热设计功耗（TDP）直接作为多目标优化的刚性损失约束。通过在定制的超网络（Supernet）空间内进行帕累托前沿（Pareto Front）的自适应寻优，NAS 能够自动化筛选出最契合移动端硬件流水线级联特性的算子拓扑结构。现有架构演进表明，在维持模型参数量处于边缘物理吞吐下限的同时，硬件感知 NAS 可使目标检测网络在特定移动终端上的能效比与算力利用率显著拉升，在不损失微弱缺陷捕获灵敏度的前提下，实现 2%~3%

的整体精度边际增益，为全边缘侧“边飞边检”的实时诊断闭环提供了务实的算法演进范式。

5 数据集与评价指标

高质量的标注数据是驱动深度学习算法性能提升的核心要素。在光伏组件缺陷检测领域，数据集的规模、多样性及标注粒度直接决定了模型的泛化能力与最终的工业落地效果。长期以来，光伏检测研究主要依赖实验室自建的私有小样本数据集。由于缺乏统一的测试基准，不同算法之间的性能难以进行公平的横向对比，严重阻碍了技术的迭代与复现。近年来，随着 PVEL-AD 等高质量开源数据集的发布，这一局面得到了显著改善。本章将对当前国内外主流的公开数据集进行详细梳理，对比分析其参数特性，并探讨数据标准化建设面临的深层次挑战。

5.1 主流公开数据集

由 Su 等人^[22]于 2023 年发布的 PVEL-AD (Photovoltaic Electroluminescence Anomaly Detection) 是目前全球光伏领域规模最大、标注最详尽的 EL 异常检测数据集。该数据集包含 36,543 张高分辨率近红外 EL 图像，涵盖了单晶硅与多晶硅两种组件类型，真实还原了工业现场“高噪声、弱缺陷”的检测难度。Deutsch^[10]等人发布的 ELPV 数据集 (常被称为 Bradcourt 数据集)

是该领域早期的经典数据集，包含 2,624 张从单晶和多晶光伏组件中提取的 8-bit 灰度 EL 电池片图像。样本未采用二值标签，而是被标记为缺陷概率值 (0.0 代表完好, 1.0 代表确定的缺陷, 0.33 和 0.67 代表潜在风险)。该数据集仅提供图像级的分类标签 (Classification Label)，缺乏缺陷的具体位置坐标，无法支持目标检测 (Detection) 或语义分割 (Segmentation) 任务的训练。

除了 EL 数据集，针对红外热成像与可见光检测的需求，部分研究团队也开源了相关数据资源。包含无人机采集的红外热成像视频帧及其对应的可见光图像，主要用于热斑与二极管故障的异常检测。

Photovoltaic Soiling Dataset：专门聚焦于光伏玻璃表面的非均匀积灰与污垢沉积现象。与常规仅提供离散类别标签或粗略边界框的数据集存在本质区别，该资源构建了极耗费领域专家人工成本的高精度像素级污垢掩膜 (Segmentation Masks)。这种细粒度的密集标注范式，直接突破了传统目标检测算法的维度限制，赋能深层语义分割网络精确剥离污染物的几何轮廓并量化其覆盖比例。

5.2 数据集核心参数对比与工业落地价值剖析

为了打破不同算法间因底层数据属性差异导致的“评估失真”，本文从工程落地的视角，对目前主流的 5 个公开数据集的核心物理参数、标注规则与固有局限性进行了深度量化对比 (如表 3 所示)。

表 3 主流光伏组件缺陷检测公开数据集参数对比

Table 3 Parameter Comparison of Public Datasets for PV Defect Detection

数据集名称 (年份)	核心成像参数	缺陷分布/标注	固有偏差与局限性 (Dataset Bias)	工业落地价值与适用场景
ELPV (2019)	EL / 300×300 极低分辨率 / 室内相机	4 级离散缺陷概率标签； 图像级分类	缺失空间定位坐标	适合作为基础分类网络底层泛化性能的早期验证基准
PVEL-AD (2023)	EL / 1024×1024 高分辨率 / 室内相机	11 类异常极端长尾分布； 矩形框	不支持几何面积定量计算	评测 YOLO 等算法在复杂多晶硅晶界下缺陷召回率的权威基准
Infrared-Solar (2020)	IR / 中低分辨率 / 地面手持热像仪	3 大类； 图像级	缺失气象条件元数据； 易将环境热反射误标	适合进行大规模无监督异常挖掘与热斑特征的粗筛预训练
UAV-PV (2022)	IR + RGB / 640×512 无人机双光云台	5 大类宏观电气故障； 矩形框	存在剧烈透视几何畸变	跨模态特征融合网络最贴近真实电站复杂户外巡检的验证基准
Photovoltaic Soiling Dataset (2017)	RGB / 高清可见光 / 全天候固定监控	单一类； 高精度像素级掩膜 (Mask)	仅包含表面遮挡物， 缺失内部电性失效特征	为语义分割提供 Ground Truth，是构建透光率衰减数字孪生的核心数据

从表 3 可以看出, 光伏数据集的发展呈现出“规模扩大化”和“任务精细化”的趋势。早期的 ELPV 数据集仅支持简单的二分类任务, 而 PVEL-AD 的出现标志着研究重点已转向复杂的多目标定位。然而, 目前仍缺乏大规模的像素级分割数据集 (Segmentation Dataset), 这限制了 U-Net 等网络在缺陷面积量化方面的应用。

从表 3 的深层物理属性剖析可知, 当前光伏检测领域面临的一个核心危机是“数据集偏差引发的域漂移 (Domain Shift)”。在理想实验室环境 (如 PVEL-AD) 中采集的 EL 图像, 其光照均匀、对比度高, 背景晶界噪声呈现相对静态的统计分布。如果深度学习网络在此类“纯净数据”上过度拟合以追求极致的 mAP, 一旦将其部署至无人机机载端 (如 UAV-PV 场景) 处理真实户外数据时, 模型性能往往会显著下降。

这种性能崩溃的物理根源在于多维度的环境噪声干扰。首先是热力学环境偏差: 在 Infrared-Solar 等纯红外数据集中, 由于缺乏对拍摄时实时风速、环境温度与太阳辐照度 (Irradiance) 的元数据 (Metadata) 记录, 算法易将高风速下被“风冷效应”削弱的微小热斑误判为正常区域。其次是传感器的光学畸变: 由地面人工手持拍摄的图像与无人机广角镜头下俯拍的组件图像, 在透视

几何畸变与像素物理空间分辨率 (GSD) 上存在巨大的域鸿沟。最后是标注主观歧义: 不同数据集对于“缺陷”的物理阈值界定存在极大割裂, 例如某些数据集将所有微小暗纹均标注为裂纹, 而另一部分仅标注会导致电流通道阻断的高致害性裂纹。这种由底层物理属性差异引发的偏差, 使得不同算法跨数据集进行绝对精度或 mAP 的直接数值对比在很大程度上丧失了工程意义。因此, 未来的光伏基准数据集建设不仅需要扩展像素级掩膜, 更亟需在数据结构中强制引入包含“气象条件、传感器内参、时空坐标”的多模态物理标签, 从而引导网络学习真正的“光伏衰减物理本征”。

为从根本上缓解上述因物理成像机理差异、传感器差异及环境噪声交织引发的域漂移 (Domain Shift) 难题, 无监督域适应 (Unsupervised Domain Adaptation, UDA) 算法正逐步演进为光伏缺陷跨场景泛化检测的核心破局方案。在真实的工业场景中存在显著的跨域壁垒: 检测模型在具有高信噪比与统一分辨率的“源域” (如标准实验室条件下的高质量 EL 图像集) 中训练后, 直接下沉部署到背景复杂、缺陷对比度多变的“目标域” (如不同批次产线设备的 EL 图像、或低分辨率机载红外热像) 时, 极易因特征流形分布的严重不匹配而导致漏检率激增。

针对这一痛点，前沿的无监督域适应算法通过提取“域不变特征” (Domain-invariant features) 来实现跨设备与跨场景泛化。在具体的应用案例中，最新研究提出了面向光伏电池缺陷的动态无监督域适应 (DUDA) 检测框架^[34]。该类方法无需预先获取目标域的任何人工标注，而是通过在目标检测骨干网络的深层引入梯度反转层 (Gradient Reversal Layer, GRL) 或数据归一化控制器 (DNC)，在隐空间内对抗性地对齐源域与现场目标域的底层纹理及边缘特征。具体而言，针对光伏产线动态变化的背景特征，算法在测试阶段仅需截取小批量 (Mini-batch) 的无标注现场目标域数据流，即可动态更新网络中批归一化 (Batch Normalization, BN) 层的均值与方差统计信息。

这一机制成功将发生域偏移的光伏缺陷特征映射回源域的同态分布空间中。工业验证结果表明，动态域适应策略在不增加任何额外专家标注成本的严苛条件下，能够使模型在面对未知目标域（如低对比度隐裂、强背景干扰下的晶界断栅）时的检测平均精度 (mAP) 实现实质性恢复与显著增益，为智能算法从单一实验室基准走向大规模动态电站运维提供了极具性价比的技术演进路径。

5.3 数据建设面临的深层次挑战

除了 PVEL-AD 外，大部分包含高价值生产工艺缺陷（如虚焊、层压偏移、划伤）的工业数据，仍掌握在头部光伏组件制造商及第三方运维公司手中。出于商业机密保护，这些数据极少公开。这导致学术界研究的算法模型往往在公开数据集上表现优异 (mAP 大于 90%)，但一旦迁移到工厂实际产线的私有数据上，由于成像设备、分辨率及工艺纹理的差异，性能便大幅下降，出现严重的“域漂移” (Domain Shift) 现象。

当前公开的视觉数据集（如 PVEL-AD）大多停留在目标级定位 (Bounding Box) 的标注粒度。然而，为了实现组件剩余寿命预测与精细化功率衰减评估，必须依赖像素级的语义掩膜 (Semantic Masks) 来量化隐裂长度与断栅面积。像素级标注要求领域专家在极低对比度的 EL 图像中逐像素描绘微弱缺陷的蜿蜒边界，其耗费的人力与时间成本呈指数级增长。这种细粒度标注数据的严重匮乏，直接导致当前基于深度学习的语义分割网络（如 DeepLabV3+、TransUNet）在光伏领域的潜力未能被完全释放，成为了制约算法从“定性识别”走向“定量评估”的关键瓶颈。

针对该数据匮乏瓶颈，弱监督语义分割 (Weakly-supervised Semantic Segmentation, WSSS) 展现出了较好的工程替代价值。该方法允许网络仅利用获取成本较低的粗粒度标签（如图像级分类或边界框标注）作为弱监督信号。在主流的光伏视觉诊断流程中，网络首先通过类激活映射 (CAM) 定位缺陷的核心判别性区域；随后，将边界框 (Bounding Box) 标注作为空间几何约束，结合条件随机场 (CRF) 或图割算法，驱动初始激活图沿缺陷边缘扩散，从而自动生成高置信度的伪像素级标签 (Pseudo-mask) ^[35]。将生成的伪标签迭代回传至下游网络进行半监督训练，可在大幅降低像素级手工标注成本的前提下，使裂纹等细粒度缺陷的分割交并比 (mIoU) 逼近全监督模型的性能水平，有效缓解了光伏衰减定量评估中的数据标注壁垒。

不同数据来源对缺陷的定义标准不一，导致了“标签噪声”。例如，对于“隐裂”的判定，有的数据集只要发现暗线即标记为缺陷，而有的数据集则依据 IEC 61215 标准，仅将造成有效面积减少超过 5% 的裂纹标记为缺陷。此外，不同厂商对同一类缺陷的命名也存在差异（如“黑芯”与“黑斑”）。这种标注标准的混乱，使得跨数据集的模型训练与迁移学习变得异常困难，也阻碍了行业统一

AI 检测标准的制定^[16]。这种标注粒度与分类标准的极度混乱，在底层打破了深度学习监督优化的唯一性假设。完全消除此类语义标签噪声，已远远超出了单纯的计算机视觉算法范畴。它不仅要求在算法端引入标签平滑（Label Smoothing）或噪声鲁棒学习（Noise-robust Learning）机制进行补偿，更迫切需要电气工程与人工智

能交叉领域的标准化委员会介入，以联合制定一套深度融合视觉表观特征与底层电气衰减机理的统一光伏缺陷分类法。为了多维度衡量模型的检测精度与推理效率，本文梳理了光伏领域常用的缺陷检测算法评价指标，其具体计算公式与物理意义详见表 4。

表 4 缺陷检测算法评价指标
Table 4 Evaluation Metrics for Defect Detection Algorithms

评价指标	公式
Precision (P)	$P = \frac{TP}{TP + FP}$
Accuracy	$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$
Recall (R)	$R = \frac{TP}{TP + FN}$
F1-Score	$F1 = 2 \cdot \frac{P \cdot R}{P + R}$
IoU	$IoU = \frac{Area(B_p \cap B_{gt})}{Area(B_p \cup B_{gt})}$
mAP	$mAP = \frac{1}{N} \sum_{i=1}^N AP_i$
FPS	$FPS = \frac{1}{t_{inference}}$

6 深度学习检测算法研究进展

6.1 目标检测算法研究

6.1.1 两阶段检测算法

两阶段（Two-stage）目标检测算法以 R-CNN 系列架构为核心，确立了“启发式候选区域生成—精细化分类与坐标回归”的串行处理范式。该范式的理论优势在于其严密的物理解耦机制：前端的区域建议网络（RPN）依托密集的预设锚框（Anchors），在多尺度特征图上进行高召回率的前景拦截；随后，感兴趣区域池化（RoI Pooling/Align）操作将尺度各异的候选特征强行映射为固定维度的张量。这种精确的空间特征对齐机制，最大程度地保留了光伏 EL 图像中微小隐裂与边缘模糊缺陷的局部拓扑结构，为其赋予了极高的检测精度上限。针对光伏微弱缺陷在骨干网络下采样过程中易发生的特征湮

灭现象，多尺度特征融合技术成为该阶段的研究焦点。传统的特征金字塔网络（FPN）在强行融合浅层高分辨率细节与深层强语义信息时，存在难以弥合的“语义鸿沟（Semantic Gap）”，导致融合特征中充斥着由多晶硅晶界引发的背景混淆噪声。为破解这一表征瓶颈，Su 等人^[18]提出了 BAF-Detector 模型。该架构创新性地构建了双向注意力特征金字塔（BAFPN），通过嵌入通道（Channel）与空间（Spatial）双重注意力机制，在特征通道维度自适应抑制晶界等冗余背景权重，并在空间维度精准重构微小裂纹的响应分布。实验验证，该网络在 PVEL-AD 权威基准上实现了 88.07% 的平均精度均值（mAP），确立了复杂背景下高精度检测的量化标杆。在追求精度的演进路径上，抑制密集组件阵列中的误检（False Positives）是另一大核心挑战。标准的两阶段模型在设定交并比（IoU）正负样本阈值时面临着严峻的数学悖论：较低的阈值会引入大量低质量的噪声候选框，而盲目抬高阈值又会引发正样本急剧锐减与训练过拟合。为突破

该阈值陷阱，部分前沿研究将 Cascade R-CNN 级联架构引入光伏检测。该架构通过串行级联多个单调递增 IoU 阈值的检测头 (Detector Heads)，利用前序网络输出的优化边界框作为后续网络的重采样 (Resampling) 输入。这种渐进式的边界框提纯机制，不仅有效剔除了由光照畸变或顽固污渍引发的虚假缺陷，更使得最终的坐标回归精度达到了亚像素级别。

尽管两阶段级联架构在学术评价指标上屡创极值，但其庞大的参数冗余与复杂的串行提议机制，构成了难以逾越的工程落地壁垒。多层检测头的堆叠导致网络前向推理的浮点运算量 (FLOPs) 呈指数级增长。在常规的工业级边缘计算节点上，此类模型的推理帧率通常跌破 5FPS。这种巨大的推理时延有效阻断了其在无人机高动态实时巡检以及全量高速电池片产线中的部署可行性，意味着其仅能受限于电站云端服务器的离线异步分析或产线末端的抽样复检环节，从而迫使工业界将高并发检测的重心全面转向单阶段 (One-stage) 架构。

6.1.2 单阶段检测算法

单阶段 (One-stage) 检测算法摒弃了耗时的启发式候选区域生成 (RPN) 步骤，将目标定位与分类任务重构为一个纯粹的端到端空间回归问题。以 YOLO (You Only Look Once) 系列和 SSD 为代表的此类模型，直接在全图的网格系统上并行预测边界框坐标与类别置信度。这种底层的架构解耦去除了繁冗的串行筛选机制，赋予了单阶段模型极其优异的前向推理效率，使其确立了在光伏工业在线质检与动态巡检中的绝对主导地位。纵观单阶段架构在光伏领域的应用，从早期引入多尺度预测分支的 YOLOv3，演进到全面引入无锚框 (Anchor-free) 策略的 YOLOv8，算法逐渐摆脱了对预设锚框超参数的

依赖，对长宽比极端的细长断栅或不规则碎片展现出更强的自适应匹配能力。面对现代光伏电池片产线对极限检测节拍（每小时数千片）与极低误检率的双重红线约束，最新一代架构展现出了卓越的工程潜力。Chen 等人^[36]基于前沿的 YOLOv11n 架构，针对多晶硅晶界纹理易与微弱缺陷特征发生物理混淆的痛点，提出了高度定制化的改进方案。该研究在特征提取网络中深层嵌合了通道特征聚合 (CFA) 与跨组注意力 (C2CGA) 模块。这类机制能够在特征图的通道维度与空间维度自适应地重新分配响应权重，强效抑制由正常晶界梯度引发的背景噪声激活。经过此番架构重构，该模型不仅显著拉升了复杂纹理下的缺陷辨识度，更在标准 NVIDIA GPU 算力平台上实现了高达 588 FPS 的极限推理速度，打通了全量组件“零卡顿”在线质检的技术闭环。无人机 (UAV) 等边缘计算节点面临着严苛的热设计功耗 (TDP) 与片上内存容量限制。针对这一算力瓶颈，Gong 等人^[13]提出了极致轻量化的 CHS-YOLO 模型。该研究深入剖析了常规卷积层中存在的特征图空间冗余，创新性地利用 GhostConv 算子替换标准卷积。GhostConv 通过执行极低计算代价的线性操作来生成本征特征图的幻影 (Ghosts)，在维持同等感受野与表征能力的前提下，呈指数级削减了浮点运算次数 (FLOPs)。辅以专门设计的 Slim-Neck 颈部压缩结构，CHS-YOLO 成功将总参数量极限压缩至仅 2.4 M。实验数据证实，在维持 93% 极高 mAP 的苛刻条件下，该模型的物理体积仅为原始 YOLOv8 的三分之一。这种在算法底层的模型压缩，极大降低了光伏高阶视觉算法向低功耗移动终端下沉的硬件部署门槛。图 5 将两阶段检测算法与单阶段检测算法的基础架构进行了对比。




图 5 两阶段检测算法(Faster R-CNN)与单阶段检测算法(YOLO)架构对比

Fig.5 Comparison of the architectures of the Faster R-CNN two-stage detection algorithm and the YOLO single-stage detection algorithm

6.1.3 轻量化检测模型

针对单阶段目标检测网络在光伏巡检中的精度瓶颈，学术界展开了多维度的架构革新。部分研究致力于强化特征提取主干，通过引入多样化分支块（DBB）或自适应空间注意力模块，在不显著增加计算图深度的情况下，提升了模型对低对比度微弱裂纹的感知敏锐度^[37, 38]。另一方面，为满足高频动态巡检的严苛实时性要求，基于轻量化重参数化技术与深度可分离卷积的模型压缩方案

被大量验证，其在边缘硬件上实现了极高 FPS 的推理效率^[39, 40]。此外，针对光伏组件特定长宽比的形态先验，定制化的锚框回归机制与非对称卷积模块也被整合入 YOLO 体系，进一步收敛了复杂背景下的边界框定位误差^[41]。

表 5 总结了主流目标检测算法在光伏缺陷检测中的研究进展。

表 5 主流目标检测算法在不同光伏检测场景中的应用条件与报告性能汇总

Table 5 Applications and Reported Performance of Object Detectors in PV Scenarios

模型名称	数据来源	改进策略	mAP (%)	准确率/F1 (%)	输入分辨率	参数量 (M)	FLOPs(G)	测试硬件	适用场景
Faster R-CNN ^[18]	PVEL-AD 基准集 (EL)	RPN + ROI Pooling	82.4	91.2 (Acc)	1024×1024	41.5	180.0	RTX 2080 Ti	云端离线精细分析

RetinaNet ^[18]	PVEL-AD 基准集 (EL)	Focal Loss	84.1	92.5 (Acc)	1024×1024	37.7	145.0	RTX 2080 Ti	长尾缺陷离线分析
SSD (VGG16) ^[13]	综合光伏数据集 (RGB)	多尺度特征图检测	74.3	88.6 (Acc)	300×300	~26.0	~31.0	桌面级 GPU	早期低分辨率粗筛
EfficientDet-D0 ^[13]	综合光伏数据集 (RGB)	BiFPN + 复合缩放	80.2	90.1 (Acc)	512×512	~3.9	~2.5	桌面级 GPU	常规云/边协同粗筛
CenterNet ^[2]	私有光伏数据集 (混合)	无锚框+中心点预测	83.5	-	512×512	~32.0	~70.0	高端显卡	无锚框目标检测探索
BAF-Detector ^[18]	PVEL-AD 基准集 (EL)	双向注意力 FPN	88.07	94.5 (Acc)	1024×1024	~45.0	~200.0	RTX 2080 Ti	极微小隐裂高精诊断
YOLOv3 ^[2]	私有数据集 (混合)	FPN + Darknet-53	85.2	93.0 (F1)	416×416	~61.5	~65.8	桌面级 GPU	早期工业产线质检
YOLOv5s ^[17]	PL (光致发光)集 (PL)	Mosaic + 自适应锚框	91.5	95.8 (F1)	640×640	~7.2	~16.5	RTX 3090	产线高速在线质检
YOLOX-s ^[2]	私有光伏数据集 (混合)	解耦头 + SimOTA	89.2	94.2 (F1)	640×640	~9.0	~26.8	桌面级 GPU	无锚框单阶段检测
YOLOv8n ^[8]	UAV 热成像集 (IR)	C2f +Task-Aligned Assigner	92.4	96.2 (F1)	640×640	3.2	8.7	树莓派 / TPU	无人机边缘端巡检
YOLOv8-GD ^[42]	EL 私有数据集 (EL)	全局注意力+动态头	94.8	97.1 (Acc)	640×640	11.2	28.5	RTX 3090	复杂纹理在线质检
YOLOv9-c ^[2]	公开混合数据集 (混合)	PGI + GELAN	94.1	96.5 (F1)	640×640	25.3	102.1	旗舰级显卡	高并发服务器端质检
YOLOv10-n ^[2]	公开混合数据集 (混合)	NMS-free + 双重标签	89.5	-	640×640	2.3	6.7	旗舰级显卡	去 NMS 的极速检测
CHS-YOLO ^[13]	RGB/红外综合集 (RGB)	GhostConv + Slim-Neck	93.1	95.9 (F1)	640×640	2.4	8.5	Jetson / GPU	无人机实时低耗巡检
YOLOv11-CFA ^[36]	工业私有数据集 (RGB)	通道特征聚合 +C2CGA 模块	86.3	94.8 (Acc)	640×640	3.1	10.2	RTX 3090	产线亚毫秒质检
YOLO11-EMFL ^[37]	太阳能电池数据集 (EL)	EMFL 模块	98.2	91.8 (Acc) 92.0(F1)	640×640	25.4	78.5	RTX 4090	多晶硅复杂背景复检
Improved YOLOv12 ^[43]	复合多模态集 (RGB)	融合多模态特征	96.8	97.8(Acc) 96.6(F1)	640×640	15.6	45.2	RTX 3090	复合致害性溯源

严格的工程化评估需建立在统一的基准之上。然而，由于表 5 所列文献在算法评测时采用了极具异质性的配置：(1)测试硬件跨度极大（涵盖从峰值算力超 80 TFLOPS 的云端服务器级 NVIDIA RTX 4090/3090, 至算力仅数十 TOPS 的边缘侧 Jetson Orin / 树莓派）；(2)输入图像分辨率未统一（从极度压缩的 320×320 至保留高频细节的 1024×1024 不等）；(3)训练数据源存在域偏差（标注的 PVEL-AD 公开集与高噪声工业私有集）。因此，表中的 mAP 与 FPS 均为非归一化的绝对数值，仅代表该网络架构在其特定实验室设定下的局部最优潜力。在工业现场的真实选型中，直接跨文献进行数值大小的比对不具绝对指导意义，而应深入剖析各算法底层架构逻辑对“算力-精度”博弈的本质影响。

结合表 5 的模型复杂度指标（参数量与 FLOPs）可以直观发现,与高算力依赖模型(如参数量超过 40 M 的

Faster R-CNN) 形成显著对比的是，以 CHS-YOLO 和 TA-YOLOv11 为代表的轻量化模型展现了面向低功耗硬件的工程适应性。例如，CHS-YOLO 将参数量压缩至 2.4 M，浮点运算量降至 8.5 G。这种在特征通道维度的极简设计，大幅降低了模型的片上存储（SRAM）占用与内存访问带宽要求,有效匹配了 Jetson Nano 等嵌入式设备严苛的热设计功耗（TDP）限制,从而保障了 18~110 FPS 的实时推理帧率。但这种架构设计的边界在于：深度的算子剥离削弱了高维非线性表达能力，在面对复杂背景时，往往需要牺牲一定的几何召回率。

为剔除上述异构测试环境带来的评估失真，必须建立统一基准下的归一化对比。表 6 剥离了硬件与数据源的绝对差异，以基线模型（Baseline）为参考系，量化展示了当前主流改进策略在统一约束下带来的相对性能增益。

表 6 主流算法改进策略在统一基准下的量化性能增益对比

Table 6 Quantitative Performance Gains of Improvement Strategies Under a Unified Benchmark

核心改进策略与机制	基准模型 (Baseline)	统一测试基准与硬件约束	归一化相对性能增益 (具体提升幅度)	数据来源可靠性详细评估说明
双向注意力特征金字塔 (BAFPN)	Faster R-CNN	PVEL-AD 权威集 / RTX 2080 Ti	mAP 提升 5.67%	基于 36,543 张开源数据的严谨控制变量对比测试
通道特征聚合模块 (CFA)	原始 YOLO11n	工业电池片私有集 / RTX 3090	推理帧率提升 2 倍	源自 10 万+ 级大批量真实产线数据的长时在线实测
GhostConv 算子轻量化重构	原始 YOLOv8n	综合光伏数据集 / Jetson Nano	FPS 提升约 4.5 倍, 参数降 25%	基于嵌入式边缘芯片的真实物理推理时延与功耗监测
空洞空间池化金字塔 (ASPP)	基础全卷积网络 (FCN)	高清 EL 图像集 / 桌面级 GPU	长隐裂 F-Score 突破 0.82	结合领域专家手工像素级掩膜 (Mask) 的十折交叉验证
生成对抗数据增强 (MAGAN)	无数据增强检测网络	极端长尾分布数据集 / 旗舰 GPU	长尾罕见缺陷召回率提升 2.5%~4.5%	针对极少数高致害性缺陷的分布外(OOD)泛化测试
动态域适应特征对齐 (DUDA)	源域静态训练模型	跨设备目标域 (产线/户外图像)	未知目标域 mAP 实现显著增益	脱离源域标注、跨越不同批次光伏设备的无监督部署测试
跨模态特征正交调制 (SPOM)	单一 RGB 模态网络	RGB-IR 双模态集 / RTX 3090	强背景干扰下 mAP 提升 2.0%~3.2%, 虚警率骤降	控制环境噪声变量下的 RGB-IR 跨模态消融实验 (Ablation)

分析表 6 可知,脱离统一基准谈绝对指标是片面的。在控制变量的前提下,注意力机制的引入主要服务于 2%~5% 的极限召回率增益;而底层算子重构(如 GhostConv)则能在微小精度折损下,换取边缘端数倍的帧率(FPS)跃升,这为工业界在不同预算下进行算法选型提供了严谨的量化依据。

6.1.4 目标检测算法的综合横向对比与核心架构逻辑剖析

纵观目标检测技术在光伏领域的演进,两阶段、单阶段及轻量化模型在架构设计上展现出了截然不同的技术偏好。剥离表 5 中因硬件环境不一造成的绝对数值差异,其性能表象的背后,实则是底层架构逻辑在“空间表征容量、内存访问成本(MAC)与浮点运算次数(FLOPs)”之间的对比。

两阶段算法(如 Faster R-CNN、Cascade R-CNN)凭借 RPN 网络的启发式区域提议与 RoI Pooling 的精确空间对齐,在应对极微弱隐裂与复杂晶界干扰时展现出了极高的召回率与理论精度上限。其核心架构逻辑在于“空间维度的物理硬解耦”。这种机制最大程度地保留了微小缺陷的高频细节,但代价是极高的内存访问成本(MAC)。

单阶段重型算法(以 YOLOv8/v9/v10 的高阶版本为代表)通过端到端的密集预测机制(Dense Prediction)与无锚框(Anchor-free)设计,确立了在线巡检的主导

地位。其性能优异的核心架构逻辑在于“特征金字塔的跨级融合与高效梯度聚合”。例如,YOLO 架构广泛引入的 CSPNet 或 GELAN 模块,通过截断冗余的梯度流,在维持强大非线性拟合能力的同时大幅提升了算子并行度。然而,当输入图像分辨率增大至 1024×1024 级别以捕捉细小断栅时,单阶段网络深层庞大的通道数依然会使得 FLOPs 呈二次方指数爆炸,直接触发无人机机载芯片的热降频保护(Thermal Throttling)。

边缘轻量化模型(如 CHS-YOLO^[13]、TA-YOLOv11^[44])则是向极致边缘功耗(SWaP-C)妥协的产物。其核心架构逻辑在于“高维特征的空间剥离与结构重参数化”。这类网络大量运用深度可分离卷积(Depthwise Separable Convolution)或 GhostConv 算子。在数学本质上,它们假设图像的某些特征通道是高度相关的,从而用计算代价极低的线性操作去替代原本稠密的 3×3 标准卷积。这种架构能够在功耗严格受限的嵌入式设备(如 10W 功耗的 Jetson Orin Nano)上跑出 18~25 FPS 的高帧率,实现了无人机实时巡检。然而,这种算力的剥离不可避免地削弱了网络的高维非线性表达能力(Non-linear Representation Capacity)。

综上剖析可见,单纯依赖绝对数值的 mAP 与 FPS 来评价算法优劣具有强烈的片面性。纯粹的层数无序堆叠或极端的算子裁剪,均无法突破其本征架构物理瓶颈。未来的算法演进应聚焦于硬件感知架构搜索(Hardware-aware NAS),将边缘设备的真实计算延迟与内存带宽限制直接写入损失函数,以期在有限的硅基

算力上实现表征能力与泛化鲁棒性的最大化。

6.2 像素级缺陷分割与精细化识别

6.2.1 基于 CNN 的语义分割与长尾分布突破

早期的光伏缺陷分割高度依赖如 U-Net 和 DeepLabV3+ 等全卷积 (FCN) 架构。这些模型通过跳跃连接 (Skip Connections) 或空洞空间卷积池化金字塔 (ASPP) 有效捕获了局部高分辨率细节与一定范围的上下文依赖。但在面对贯穿整块晶硅电池片的细长微裂纹时, U-Net 的基础架构暴露出了显著的特征瓶颈。受限于标准卷积核严格的局部计算范式, 其有效感受野 (Effective Receptive Field) 的扩张速度较慢, 难以单次覆盖裂纹复杂的全局延伸轨迹。深入剖析纯卷积架构的下采样 (Downsampling) 机制可知, 当网络试图通过堆叠池化层 (Pooling) 或步长卷积来被动扩大全局视野时, 这种不可逆的空间降维操作会导致原本仅占数个像素宽度的微弱裂纹特征在高维空间中发生严重的特征湮灭。这种“扩大感受野”与“维持高空间分辨率”之间的本征矛盾, 使得基础卷积网络在面对多晶硅复杂的晶界干扰时, 易输出破碎、断续的缺陷掩膜 (Mask), 无法精确重构裂纹的真实物理连续性。此外, 真实电站中的缺陷往往多达数十种, 且呈现极端的长尾分布 (Long-tail Distribution)。针对这一工业痛点, Hanifi 等人^[45]在 2025 年针对包含 29 类光伏缺陷与特征的极度不平衡 EL 数据集进行了系统性验证。该研究证实, 结合特定类别权重惩罚机制的 VGG16-UNet 架构, 能够显著提升诸如“死电池 (Dead Cell)”等长尾罕见缺陷的交并比 (IoU)。这标志着纯卷积分割算法正从“单一典型缺陷剥离”向“全场景多目标像素级解析”全速迈进。

6.2.2 视觉大模型 (SAM) 与多模态分割前沿

传统的 CNN 受限于局部感受野, 易在提取贯穿型长裂纹时发生特征断裂。尽管视觉 Transformer (ViT) 引入了全局自注意力机制, 但其高昂的像素级标注成本严重制约了工业落地。在此背景下, Meta AI 提出的“分割一切模型” (Segment Anything Model, SAM) 在 2024-2025 年被深度引入光伏领域。最新研究^[46]提出了一种无需二次微调的无监督光伏缺陷分割流水线, 该方案通过提取底层的 VGG16 高维特征并结合 ORB 特征点自适应生成提示 (Prompts), 在极低的人工干预下显

著提升了 SAM 在微弱隐裂上生成掩膜的置信度。此外, 单一模态成像在语义分割中往往存在物理盲区。2025 年的最前沿趋势已转向跨模态语义网络。例如, 最新提出的 CMASegNet 架构^[12]构建了跨模态注意力交互模块 (CAIM), 将可见光 (RGB) 的高分辨率几何表现与红外热成像 (Thermal) 的异常温度梯度进行特征级深度对齐。这种多模态语义感知机制成功克服了单一红外图像边缘模糊的瓶颈, 实现了复杂背景下微小缺陷的高精度掩膜生成。尽管 SAM 等视觉大模型展现出了惊人的泛化能力 (Zero-shot Generalization), 但光伏组件表面的低对比度晶界纹理与自然场景图像存在显著的域间差异 (Domain Gap)。现阶段的演进热点正聚焦于如何以最小代价实现大模型的“光伏领域适配”。除了上述基于特征点引导的免微调方案外, 采用参数高效微调 (Parameter-Efficient Fine-Tuning, PEFT) 技术 (如 LoRA、Adapter) 对 SAM 的图像编码器或掩膜解码器进行局部权重冻结与特定领域训练, 正在成为打破大模型工业落地算力瓶颈的关键路径。另一方面, 在多模态融合层面, 当前的 CMASegNet 等架构虽已实现初步的特征对齐, 但在复杂光照突变或无人机高动态飞行带来的视角非刚性形变 (Non-rigid Deformation) 下, RGB 与红外像素级的绝对配准依然极具挑战。未来, 探索基于隐式神经表示 (Implicit Neural Representations) 或跨模态对比学习 (Cross-modal Contrastive Learning) 的三维或时空特征联合表征, 将是有效解决多源数据融合空间异质性难题的核心方向。

6.2.3 语义分割算法的综合局限性分析

尽管像素级语义分割在光伏缺陷的几何量化 (如精确计算 PID 衰减面积比、隐裂拓扑长度等) 上具备其他检测粒度无可比拟的绝对优势, 是连接视觉检测与物理功率损耗评估的核心桥梁。然而, 其在光伏工业现场的大规模实际部署中, 仍面临两项难以逾越的本征局限。

高分辨率的逐像素预测任务需要网络在深层保持极高的空间维度信息。以传统的 U-Net 为例, 其跳跃连接 (Skip Connections) 机制在拼接浅层特征时会产生极高的显存峰值 (Memory Footprint); 而近年来引入的基于 Vision Transformer (ViT) 或 SAM (Segment Anything Model) 的大模型架构, 其全局自注意力机制的计算复杂度更是随图像分辨率呈二次方指数爆炸。这就带来了一个严峻的分辨率悖论: 若为适配无人机机载端 (如 Jetson

Nano 系列) 有限的算力而进行图像下采样, 细长隐裂或微小热斑等高频细节将被直接抹杀; 若保持原图输入, 则极难在边缘端实现高帧率的实时运行, 往往只能妥协为“无人机盲拍 + 地面站离线诊断”的非实时模式。针对这一算力瓶颈, 单纯依赖算法层的轻量化剪枝已触及精度底线。未来的演进趋势或将不可避免地走向“云边协同感知”机制——即在无人机边缘端仅部署超轻量级目标检测模型进行缺陷区域的快速粗筛 (ROI Crop), 而将包含缺陷的局部高分辨率切片回传至云端, 再由高精度分割大模型完成逐像素的几何量化。

不同于自然图像中目标拥有清晰的物理轮廓, 光伏微弱缺陷在特殊成像模态下的边界往往是极其模糊和渐变的。例如, 在红外热成像 (IRT) 中, 由于面板玻璃的热力学扩散效应 (Thermal Blooming), 热斑的视觉发光边界通常远大于晶硅内部实际的受损物理边界; 在电致发光 (EL) 图像中, 隐裂的尾端往往隐匿于多晶硅复杂的晶界晶格噪声之中。这意味着, 即便是领域内最资深

的专家, 也难以对同一张缺陷图像给出绝对一致的“Ground Truth”像素级掩膜。

这种根源于数据底层的标注歧义性, 实际上直接锁死了纯监督分割网络的理论精度上限。当模型被强迫去拟合这些充满人类主观噪声的“硬标签 (Hard Labels)”时, 其输出的掩膜在微观边缘易呈现锯齿状、断续伪影或过度平滑。因此, 下一代光伏分割算法不应再盲目追求在确定性标签上的 IoU 指标最大化, 而应当引入不确定性建模 (Uncertainty Modeling) 或标签平滑 (Label Smoothing) 机制, 让网络输出一个概率密度分布图 (Heatmap), 客观反映缺陷边界的模糊置信度。此外, 将纯视觉分割与组件的电气参量 (如 I-V 特性曲线) 进行多模态交叉验证, 发展物理信息神经网络 (PINNs), 让几何掩膜真正与物理致害性挂钩, 才是该领域冲破当前技术天花板的终极解法。

表 7 展示了不同光伏缺陷像素级分割与定位算法之间的差异。

表 7 光伏缺陷像素级分割与定位算法特性对比

Table 7 Feature Comparison of Pixel-Level Segmentation and Localization Algorithms for PV Defects					
算法类别	代表模型	年份	核心机制	优势	劣势
改进 CNN ^[47]	ImU-Net	2021	引入注意力门控机制	自动抑制背景噪声	训练收敛速度较慢
改进 CNN ^[25]	CGF-Net	2023	交叉门控融合 (Cross-gated Fusion)	提升微小缺陷分割精度	模型复杂度较高
改进 CNN ^[48]	SIIF	2024	语义交互融合 (Semantic Interactive Fusion)	针对光伏复杂背景优化	泛化性需验证
Transformer ^[49]	DPiT	2021	Vision Transformer (无卷积)	实现全局感知	对小目标不敏感
Unsupervised ^[27]	ViT-VAE	2024	Transformer + 变分自编码器	无监督学习, 无需标注	易受纹理干扰
GAN-based ^[50]	SIGAN	2021	生成对抗网络 + 差分图分割	实现无监督分割	生成伪影可能导致误判
跨模态网络 ^[12]	CMASegNet	2025	跨模态注意力交互模块 (CAIM)	有效克服边缘模糊	多源数据配准难度大
视觉大模型 ^[46]	SAM-Fusion	2024	视觉大模型 (SAM) + ORB 特征自适应提示提取	降低人工干预	难以在边缘端实现高帧率部署
无监督自编码 ^[51]	EI-AE	2026	增强迭代自编码器 (Enhanced Iterative Autoencoder)	支持少样本高精度微调	对正常多晶硅的高频晶界噪声 仍存在一定敏感性

Imp-U-Net^[47] 和 CGF-Net^[25] 的出现说明, 通过引入“门控机制”和“交叉融合”, 特别是在处理光伏组件这种结构固定的图像时, CNN 的局部纹理提取能力是不可替代的。SIIF^[48] 代表了 2024 年的最新方向, 即“语义交互”。它不再简单地堆叠层数, 而是专注于如何让深层语义更好地指导浅层细节的恢复。ViT-VAE^[27] 和 SIGAN^[50] 代表了无监督分割的新趋势, 它们不需要人工逐个像素描绘裂纹, 而是只需要输入“正常的组件图片”。模型遇到裂纹时就会报错 (重构误差) 或试图修复它, 从而反向推断出缺陷位置。这是未来工业落地的重要趋

势。DPiT^[49] 虽然引入了全局感知, 但在微小裂纹分割上表现不如 DeepLabV3+。这表明, 在光伏检测领域, 纯 Transformer 可能不是最优解, “CNN + Transformer”的混合架构才是未来的主流。

6.3 数据增强与无监督异常检测

6.3.1 基于 GAN 的数据增强

生成对抗网络 (Generative Adversarial Networks, GAN) 通过生成器 (Generator, G) 与判别器 (Discriminator,

D) 之间的极小极大博弈 (Minimax Game), 构建了一种非线性的隐空间数据映射机制。在光伏缺陷检测场景下, GAN 的核心价值在于其能够学习并拟合罕见缺陷样本 (如严重的树枝状隐裂或复杂的机械损伤) 在像素空间的高维概率分布。通过向训练集注入高保真的合成缺陷样本, 该技术从底层逻辑上缓解了工业大数据中严重的类别不平衡 (Category Imbalance) 现象, 人为拉平了长尾分布, 从而避免了下游分类器在训练过程中产生严重的预测偏好。在技术演化初期, 基于深度卷积生成对抗网络 (DCGAN) 的研究初步实现了 EL 图像中基础缺陷形态的自动化合成。Luo 等人^[23] 的早期探索证实了利用转置卷积 (Transposed Convolution) 将低维随机噪声上采样为宏观缺陷特征的可行性。然而, 受限于标准卷积核对全局空间依赖感知的匮乏, 此类早期架构在合成微小且具有复杂拓扑结构的隐裂纹时, 表现出明显的特征坍塌 (Mode Collapse) 现象, 其生成的图像往往存在纹理平滑化、边缘模糊以及缺乏光伏电池片特有的多晶硅晶界细节等缺陷。为突破这一生成质量瓶颈, Guan 等人^[52] 在 2025 年提出了多尺度注意力生成对抗网络 (Multi-scale Attention GAN, MAGAN)。该架构在生成器的特征映射层中深度集成了多尺度注意力模块, 通过自适应计算不同分辨率特征图之间的像素相关性, 强制模型在合成过程中聚焦于微细裂纹的边缘梯度与局部光照演化规律。这种机制有效地模拟了光伏组件在真实物理成像过程中的光影分布与纹理噪声, 显著提升了合成样本的感知质量 (Perceptual Quality) 与物理真实性。实验数据表明, 将 MAGAN 生成的高保真样本作为伪标签数据 (Pseudo-labeled Data) 引入模型训练流水线, 能够显著增强检测模型对分布外 (OOD) 罕见缺陷的辨识敏感度。这种基于生成式 AI 的数据增强范式, 不仅大幅削减了对高昂人工标注样本的依赖, 更在特征层面填补了由于采样不足导致的分类决策边界空缺, 为构建具备高鲁棒性的光伏智能巡检算法提供了关键的合成数据支撑。

6.3.2 无监督与半监督异常检测的前沿进展

为了摆脱全监督学习对闭集 (Closed-set) 假设与海量像素级标注数据的依赖, 无监督异常检测

(Unsupervised Anomaly Detection, UAD) 正逐渐成为光伏智能运维领域的研究热点^[32]。该范式的核心逆向逻辑是: 通过仅利用海量无缺陷的正常组件图像训练网络, 迫使模型深度拟合正常电池片的纹理空间流形; 在推理时, 由于缺陷特征属于训练分布之外的离群点 (Outliers), 模型将无法对其进行有效表征或重构, 从而在异常区域产生显著的能量残差。早期针对光伏组件的无监督方法, 多依赖于基础自编码器 (Autoencoder) 或基于生成对抗网络 (GAN) 的图像修复技术 (如 SIGAN)^[7,51]。

基于无监督学习的异常重构机制正成为前沿热点, 例如采用单分类支持向量机 (One-class SVM) 或变分自编码器 (VAE) 学习正常电池片的背景基底特征, 利用重构残差网络实现对未知非典型故障的零样本 (Zero-shot) 发现^[53, 54]。近两年来, 无监督算法在抗噪鲁棒性与防止“异常特征被原样重构 (Defect Memorization)”上取得了突破性进展。2024 年发表在《IEEE Transactions on Instrumentation and Measurement》上的研究提出了一种基于无监督特征重构约束的对抗训练框架^[55]。该研究针对传统重构算法易受 EL 图像中多晶硅背景干扰的问题, 创新性地结合对抗学习机制, 在隐空间内对特征重构过程进行强力约束, 大幅削弱了模型对异常样本的泛化重构能力, 从而在发生缺陷的像素点上产生极高的重构误差。此外, 针对单一自编码器难以兼顾复杂背景与微小缺陷的痛点, 2025 年的最新研究提出了一种新型增强迭代自编码器 (Enhanced Iterative Autoencoder, EI-AE)^[52]。该架构在编码器与解码器中引入迭代操作, 通过扩展函数空间约束, 不仅有效防止了模型对缺陷的记忆效应, 还能在仅需极少量标注样本 (Few-shot) 辅助下, 在复杂背景干扰中实现功能性缺陷的高精度微调分割。

6.3.3 无监督异常检测的局限性分析

尽管无监督范式在理论上高度契合光伏缺陷长尾分布且缺乏标准标注的工程痛点, 但其实际落地仍面临严峻的性能天花板。其核心局限性在于重构误差对高频背

景噪声的极度敏感性。光伏多晶硅组件表面布满了形态各异的正常晶界（Grain Boundaries）纹理，这些晶界在图像频域中同样表现为高频突变^[29]。现有的无监督生成模型在重构这些复杂的随机纹理时，不可避免地会产生较大的像素级重构误差（伪影）。这导致系统生成的异常得分图（Anomaly Map）中充斥着大量的结构性噪声，

在低对比度下易淹没真实的微小隐裂信号，造成极高的虚警率（False Positive Rate）。此外，如何基于动态复杂的外部光照工况，自适应地设定残差图的二值化判定阈值，目前仍高度依赖于专家经验，缺乏稳健的自适应数学寻优机制。图 6 展示了基于生成对抗网络（GAN）的数据增强与无监督检测流程。




图 6 基于生成对抗网络（GAN）的数据增强与无监督检测流程

Fig.6 Data augmentation and unsupervised detection process based on Generative Adversarial Network (GAN)

6.4 边缘计算与轻量化部署

算法的最终归宿是工程落地。针对无人机、巡检机器人等移动终端算力受限的问题，研究重心正从“云端大模型”向“端侧轻量化”转移。Pandiarajan 等人^[28]提出了 TinyViT 管道，针对可见光图像，利用蒸馏技术将 Vision Transformer 的体量压缩，实现了组件表面故障的快速严重性分级，证明了 ViT 同样可以适配边缘端。Mukandagumbo 等人^[8]进行了极具工程价值的硬件对比实验。他们在 Raspberry Pi 4B (树莓派) 和搭载 Google Coral USB Accelerator (TPU 加速棒) 的边缘平台上部署了 YOLOv8 模型。在未加速的树莓派上，推理速度仅

为 1-2 FPS，无法满足实时需求；而在接入 Google Coral TPU 后，推理速度显著提升至 20 FPS 以上，且功耗控制在 5W 以内。这一研究证实，通过“轻量化算法 + 专用 AI 加速芯片”的组合，完全可以在数百元成本的硬件上实现工业级的实时光伏缺陷检测，为大规模分布式巡检奠定了硬件基础。在无人机（UAV）巡检系统的工程化落地中，算法部署面临着高动态飞行与平台抖动的双重考验。研究指出，将目标检测算法与无人机飞控系统的云台增稳及惯性导航数据进行深度耦合，可以有效滤除航拍图像序列中的运动模糊（Motion Blur）与畸变^[56, 57]。

在此基础上，结合轻量化目标跟踪算法的时间一致性约束，巡检系统能够实现在连续视频流中对特定故障组件的唯一身份锚定与全局地理坐标精确定位^[58]。表 8 展示了边缘计算设备上的算法推理性能实测性能。

表 8 边缘计算设备上的算法推理性能实测

Table 8 Algorithm Inference Performance on Edge Computing Devices

模型名称	基础架构	部署硬件平台	FPS	功耗 / 参数量	参考
YOLOv8n (FP32)	CNN (Anchor-free)	Raspberry Pi 4B (CPU)	1.8	~3.0 W	Mukandagumbo ^[8]
YOLOv8n (INT8)	CNN (Quantized)	RPi 4B + Google Coral TPU	24.5	~5.1 W	Mukandagumbo ^[8]
SSD (Inception)	CNN	IoT 嵌入式架构	25.0	低功耗	Babu ^[59]
TinyViT	Transformer	边缘计算设备	-	极低显存占用	Pandiarajan ^[28]
CHS-YOLO	GhostNet	无人机机载	110 (GPU)	2.4 M (参数量)	Gong ^[13]
YOLOv7-Tiny	CNN	轻量化基准模型	85 (GPU)	6.2 M (参数量)	Gong ^[13]
YOLOv5s	CNN	通用移动端模型	115 (GPU)	7.2 M (参数量)	Xu ^[17]
EfficientDet-D0	EfficientNet	轻量化基准模型	62 (GPU)	4.9 M (参数量)	Gong ^[13]
MobileNet-SSD	MobileNet	NVIDIA Jetson Nano	18	5-10 W	Dj ^[27]
TA-YOLOv11	CNN	无人机巡检系统 (Jetson Orin Nano)	18	10W / 3.4 M	Li ^[44]
GWPV-YOLO	CNN	无人机机载端 (UAV-based)	-	1.9 M	Xing ^[9]

在我国西部某百兆瓦级山地光伏电站的无人机实飞巡检中，系统遭遇了严峻的物理与通信挑战。首先是飞行姿态抖动：受复杂地形突发阵风影响，无人机产生的非刚性高频振动极易导致获取的组件图像产生运动模糊（Motion Blur）。在实验室静态数据集中表现优异的轻量化目标检测模型，在遭遇此类模糊数据时，其对微裂纹的漏检率往往会瞬间激增。其次是数据传输延迟：偏远电站的微波或 4G/5G 通信链路极不稳定，若将超高清可见光与红外双路视频流强行回传至云端分析，其网络延迟常高达数百毫秒甚至发生丢包。

此外还有多模态融合的“现场标定成本与光照突变”问题。在推进双光/三光云台的多模态特征级融合算法落地时，高昂的传感器现场标定成本成为了核心阻碍。实验室环境中，可见光与红外镜头的内参及相对外参矩阵是静态且精确的。但在真实的户外长期服役中，强烈的机械震动会导致物理光轴发生微小偏移。此外，正午强烈的环境光照与热反射会导致红外焦平面阵列（FPA）频繁触发非均匀性校正（NUC）的机械快门卡顿，这会在瞬间严重破坏图像在时间与空间双重维度上的对齐精度。此案例表明，仅依靠纯软件算法（如跨模态注意力机制）无法完全消解底层的硬件环境误差，工业级应用必须引入惯性导航系统（IMU）的时空流同步与多传感器自适应动态联合标定机制。

6.5 多模态融合检测算法的技术演进

6.5.1 数据级融合

数据级融合发生于网络输入端（早期融合，Early Fusion），旨在将不同传感器（如 RGB 与 IR）获取的图像在像素空间进行严格对齐与多通道拼接。其核心优势在于最大限度地保留了原始物理信息，且对后续检测网络的架构侵入性极低。最新研究如闫号等^[60]提出基于多源图像融合的检测框架，利用可见光丰富的边缘纹理去弥补红外图像在热斑边界识别上的精度损失。然而，其技术难点在于空间异质性与视差约束（Parallax Constraint）。可见光与红外相机在焦距、视场角及成像畸变上存在天然差异，无人机高频机械振动引发的任何微小像素级配准误差，都会在输入网络后被卷积操作急剧放大，产生严重的重影（Ghosting）伪影与梯度震荡。

传统的数据级配准多依赖 SIFT 或 SURF 等人工特征点结合 RANSAC 算法来估算单应性矩阵，从而实现亚像素级的几何配准。然而，随着深度学习的介入，近两年的突破已转向无监督的光流估计网络（Optical Flow Networks）与跨模态生成技术。例如，前沿方案开始引入循环一致性生成对抗网络（CycleGAN），将可见光图像的高频结构纹理（如多晶硅晶界）作为先验条件，直接通过生成器网络注入到低分辨率的红外热像图中，

从而实现热斑边缘的物理超分辨率重建。此外，部分研究构建了基于互信息的直方图均衡策略，在双模态输入前强制维持跨模态的对比度与结构同步，从底层数据输入端极大增强了模态间的一致性。

6.5.2 特征级融合

特征级融合是目前光伏缺陷多模态检测研究的绝对重心（中期融合，Intermediate Fusion）。其核心思想是利用双流（Two-stream）骨干网络独立提取各模态的高维特征向量，随后在隐空间内进行交叉调制。特征级融合的优势在于突破了像素级刚性配准的桎梏，能够在高维语义空间中实现 RGB 几何轮廓与 IR 异常热梯度的极佳优势互补。其核心技术难点在于异构表征的语义鸿沟与庞大的计算维度。不同模态特征在高阶流形空间中的分布差异巨大，强行对齐易引发特征抑制；同时，复杂融合模块的引入导致内存访问成本（MAC）呈倍数级增长。

该层级的技术演进已从早期的特征通道直接拼接（Concatenation），全面突破至特征正交调制与跨模态交叉注意力（Cross-modal Attention）。在 2025-2026 年的最新研究中，以 FMMF-YOLOv12^[58]为代表的架构提出了子块正交调制模块（SPOM），通过构造方向判别的低秩子空间来压制可见光图像的冗余晶界干扰；同时针对红外模态引入热梯度残差网络（TGRN），深挖异常热区的多尺度响应差异。此外，如 CMASegNet^[12] 等架构构建了注意力交互模块（CAIM），利用可见光提取的锐利几何边界生成空间掩膜，去“引导”并自适应重分配红外热异常特征图的响应权重。这些机制打破了传统卷积的局限，实现了高维语义流形上的深度对齐。

6.5.3 决策级融合

决策级融合位于整个算法链路的末端（晚期融合，Late Fusion）。该层级要求针对不同模态独立训练完整的检测器，通过综合各网络输出的预测结果（类别概率、边界框置信度）进行最终的逻辑裁决。例如，针对无人机高动态巡检设计的 RTPV-YOLO^[61] 系统，通过融合可见光的分段识别与红外图像的温度梯度，极大降低了由于无人机机械振动带来的虚警。该层级的核心优势在于极高的系统容错率与网络解耦性，即使某一模态数据受到严重污染，系统仍能输出稳定结果。其核心劣势及技术难点在于，由于各网络独立寻优，无法在特征提取的浅层阶段实现物理信息的交叉印证，这在理论上限制了

其对隐蔽性极强的初期微弱复合缺陷的召回率上限。

主流技术正从简单的非极大值抑制（NMS）向基于空间区域匹配与不确定性估计的复合决策演进。例如，最新的 FVI-DDNet 架构分别利用 CenterNet 提取可见光图像中的光伏子模块，同时利用 U-Net 分割红外图像中的热异常区域，最终通过定制的区域匹配模块与关键点聚集机制在决策层完成故障识别。此外，基于贝叶斯证据学习（Evidential Deep Learning）的自适应加权策略成为新热点，算法能够根据实时输入图像的信息熵动态计算每个模态的认知不确定性（Epistemic Uncertainty）。当遭遇可见光强烈反光导致置信度严重降低时，决策系统会自适应提升红外诊断分支的裁决权重。

6.5.4 多模态融合三大层级的全维度对比与工业落地剖析

为了更直观地呈现光伏多模态融合技术的发展全貌与工程可行性，表 9 对数据级、特征级、决策级三大融合层级进行了全维度的系统性对比。

随着计算机视觉技术的大规模介入，光伏缺陷检测的技术底层逻辑被有效重塑。卷积神经网络（CNN）构建了端到端的数据驱动范式，能够自主从海量的光伏图像中逐层提取抽象表征——从底层的晶界边缘、微观纹理，升维至高层的物理缺陷语义。步入 2024 至 2025 年，针对极微弱缺陷提取与大尺度组件全局感知的痛点，学术界开始突破纯卷积架构受限于局部感受野的固有瓶颈。通过引入多头自注意力或高效线性注意力卷积（Linear Attention Conv）等模块，前沿架构实现了跨像素距离的空间依赖捕捉。这种全局上下文感知有效解决了传统视觉算法在处理细长断栅延伸、跨电池片网状隐裂时的特征断裂问题^[62]。

当前，上述基于深度学习的视觉前沿算法已在特定基准数据集上取得媲美专家的识别精度。伴随算力的跃升，光伏视觉检测任务已从单一的“图像级分类”全面迈向更具工程指导意义的“目标级定位”与“像素级分割”。

在工业级应用的大规模落地进程中，多模态巡检系统在复杂户外电站工况下面临着模态缺失（Modal Missing）与模态冲突（Modal Conflict）两大关键瓶颈。针对模态冲突问题，最典型的工程表象即为“可见光（RGB）显示正常但电致发光（EL）呈现隐裂”。这一现象的半导体物理根源在于，晶硅电池片的隐裂属于内部微观拓扑断裂，在外表面受玻璃盖板及 EVA 胶膜封装材料阻隔遮蔽的前提下，其并不会改变组件表面的光谱反射率或几何形貌，导致可见光分支感知失效；而 EL 成像基于正向偏置下的少子辐射复合机理，隐裂缺陷处少子非辐射复合速率剧增，或因断栅引发局部电流无法注入，在图像上形成强烈的低发光暗色条带。这种异构模

态在流形空间内的表征割裂极易触发传统网络决策层的混乱。为消解上述瓶颈，当前工业界的技术路径正加速向特征-决策混合融合架构（Hybrid-fusion）演进：

(1) 针对模态缺失的信噪比波动：巡检系统在遭遇高动态飞行引起的图像帧丢失、或红外相机受日照强反光致盲时，混合架构通过引入基于贝叶斯证据学习（Evidential Deep Learning）的自适应加权策略^[63]，将深度网络输出的主观概率转化为狄利克雷分布参数，以此量化建模各单模态检测器的认知不确定性（Epistemic Uncertainty），从而依据实时输入图像的信息熵自适应剥离高噪声或缺失模态，重分配置信度权重。(2) 针对模态

冲突的判据消解：当 RGB 与 EL 检测器输出完全对立的分类置信度时，混合架构引入基于电气参量交叉验证（Cross-validation with electrical parameters）的消解机制^[64]。系统通过跨域对齐现场同步采集的组串级 I-V 特性曲线、短路电流（ I_{sc} ）跌落斜率及填充因子（FF）变异参数，利用电气性能的衰减程度作为最终的物理层裁决判据。该方案将纯视觉几何感知与电气特征机理深度解耦，在根本上规避了视觉特征空间线性不可分带来的误判，保障了异构工况下巡检体系的工程鲁棒性。

表 9 光伏缺陷多模态融合技术全维度对比与工业落地分析

融合层级	核心技术与代表性算法	理论核心优势	本征劣势与技术难点	工业应用与实际落地情况
数据级融合 (早期融合)	光流估计配准；CycleGAN 超分辨重建；互信息直方图同步	保留底层原始物理特征，不改变后续检测单模态主干网络的架构	对双光镜头的视差约束极其敏感。配准算法耗时且在微小形变下易产生重影伪影	极难直接应用于高频振动、高动态的无人机（UAV）实飞巡检。目前多局限于光伏阵列履带式机器人低速巡检，或实验室静态云台诊断系统
特征级融合 (中期融合)	跨模态交叉注意力子块正交调制（SPOM）	在深层流形空间实现高频几何纹理与热梯度的最优物理互补	庞大的内存访问成本（MAC）与算力指数级爆炸；异构语义对齐困难，易引发特征抑制	当前学术界研究的核心。在工业落地时，亟需深度结合 TensorRT 算子融合技术，目前已初步部署于 Jetson Orin 等高阶边缘计算节点
决策级融合 (晚期融合)	贝叶斯不确定性估计；自适应信息熵置信度加权	高容错率与模块解耦性，有效规避单一传感器失效引发的系统性崩溃	缺乏底层特征的交叉印证，对隐蔽复合缺陷（如被脏污掩盖的隐纹）的召回率受限于单模态探测上限	适合大型光伏电站现有的“异构传感器采集 + 分布式边缘盒子计算”体系，是目前兼顾开发成本与高鲁棒性的主流工业级容错架构

7 未来发展方向

7.1 端侧轻量化与嵌入式 AI

目前的检测模型大多依赖云端的高性能 GPU 服务器，存在数据传输延迟高、带宽占用大及隐私泄露风险。未来的趋势是将智能算法直接部署在无人机机载芯片或手持检测终端上，实现“边飞边检”的实时决策。研究重点将从单纯追求 mAP 转向追求“精度-功耗”的极致平衡。利用知识蒸馏（Knowledge Distillation）、网络剪枝（Pruning）及权重量化（Quantization, 如 FP32 转 INT8）技术，在几乎不损失精度的情况下大幅降低模型体积。端云协同架构：构建“端侧初筛 + 云端精判”的协同模式。边缘设备利用轻量化模型（如 TinyViT^[28]）快速过滤 90% 的正常图像，仅将疑似缺陷图像上传至云端，由大模型进行精细诊断，从而大幅降低通信成本。未来的演进路径将不再局限于通用的嵌入式 GPU 算力平台，而是深度探索在现场可编程门阵列（FPGA）及专用集成电路（ASIC）上的异构并行部署。通过硬件描述语言对特征

卷积与激活函数进行电路级的算子融合，可显著提升单位功耗下的算力输出，为超高频动态巡检提供坚实的物理支撑。最终，光伏运维将趋向于构建“端-边缘-云”三级协同架构。在该范式下，边缘设备部署极轻量化模型执行初步特征识别，利用信息熵过滤机制快速剔除超过 90% 的正常组件图像，仅将含有疑似缺陷的特征切片上传至云端。

7.2 自监督学习与大模型微调

为了有效应对工业场景中高昂的专家标注成本与长尾缺陷分布带来的泛化瓶颈，光伏视觉检测的算法范式正加速从传统的全监督学习向自监督学习（Self-Supervised Learning, SSL）转型。借鉴自然语言处理领域预训练模型的成功路径，以掩码自编码器（Masked Autoencoders, MAE）为代表的自监督预训练技术展现出了卓越的底层特征提取能力。该机制通过在海量无标注的光伏组件图像中执行随机像素块掩膜（Masking）与重构任务，迫使网络在隐空间内深度建模电池片内部栅线结构与晶界纹理的空间上下文依赖关系。这种基于掩码

图像建模 (MIM) 的预训练过程, 使模型能够在不依赖人工标签的前提下获取通用的光伏图像表征, 随后仅需利用少量特定缺陷的标注数据进行有监督微调 (Fine-tuning), 即可实现对特定任务的精准对齐。这一范式的演进不仅极大地缓解了对 PVEL-AD 等标准数据集的强依赖, 更为模型捕获训练集之外的非典型缺陷提供了深层的先验知识储备^[49]。

7.3 多模态数据融合与全天候检测

单一模态成像始终存在物理盲区。光伏组件健康诊断体系正加速向多源信息融合与全天候检测范式演进。现有的巡检手段由于传感器成像原理的本征差异, 在复杂工况下常面临判别歧义。未来的研究重点将聚焦于构建可见光 (RGB)、红外热成像 (IRT) 与电致发光 (EL) 图像的空间跨尺度配准 (Spatial Registration) 与深度特征融合。由于不同模态图像在视场角、物理分辨率及几何畸变层面存在显著异构性, 开发具备强鲁棒性的仿射变换算子与基于特征点的自动对齐算法, 是实现多维信息联合分析的逻辑起点。在此基础上, 发展基于 Transformer 架构的特征级融合网络 (Feature-level Fusion Network), 利用多头自注意力机制捕捉跨模态特征间的空间互补性与语义相关性, 已成为消除漏检与虚警的关键路径。例如, 通过融合 RGB 图像提供的表面形貌特征, 可有效识别并剔除由鸟粪遮挡、反光干扰引发的红外“伪热斑”, 同时结合 EL 图像捕捉的深层载流子复合异常, 精准解耦热斑背后的物理成因, 实现从表面污染到内部电性失效的闭环诊断^[20, 65]。

在检测作业的时效性方面, 突破传统 EL 成像对避光环境的极端依赖, 已成为智能运维迈向产业化深水区的技术红线。传统 EL 探测因易受到自然背景光的强噪声淹没, 通常受限于夜间作业, 这严重挤压了无人机巡检的时间窗口并推高了运维成本。随着高性能短波红外 (SWIR) 铟镓砷 (InGaAs) 相机与锁相放大 (Lock-in) 成像技术的工程化应用, 结合深度图像去噪与背景抑制算法, 检测系统已初步具备在强背景光环境下提取微弱电致发光信号的能力。通过引入时空域联合滤波模型与生成式去雾/去噪算子, 算法能够在纳瓦级发光强度下精确重构缺陷拓扑结构。这种全天候 (24/7) 在线检测范式的建立, 不仅能显著提升电站巡检的覆盖频率与响应速度, 更将驱动光伏电站由“被动响应维护”向“主动预防性智能运维”实现底层逻辑的跨越。

7.4 缺陷致害性量化、电学机理退化建模与决策标准化

智能运维算法不应止步于计算机视觉层面的“目标框选”或“缺陷定性”, 其核心价值在于赋能光伏电站全生命周期健康管理 (PHM)。未来的演进路径正加速打破学科壁垒, 向物理信息神经网络 (Physics-Informed Neural Networks, PINNs) 驱动的电学机理退化建模方向深化。在具体的技术路径上, 下一代诊断体系将不再单纯追求确定性标签下的 IoU 最大化, 而是提取精细化分割网络输出的缺陷高维几何参量 (如微裂纹的蜿蜒拓扑长度、晶界交叉节点数、以及 PID 效应引发的像素级暗区面积占比) 作为边界先验。将这些视觉量化指标直接作为刚性损失约束, 注入光伏组件的 Shockley 双二极管等效电路退化模型中, 从而自适应推演出由复合失配效应引发的漏电流、串联电阻激增以及填充因子 (FF) 跌落曲线。

该路径将纯视觉的空间几何感知与半导体电学机理深度解耦, 能够建立从“宏观视觉受损面积”到“瞬态功率输出衰减 (ΔP)”的精准映射。通过跨域关联组件的历史发电性能指标与局域气象元数据, 系统能够对微隐裂向严重断栅的物理演化轨迹进行长周期数字孪生推演, 最终输出直接对齐 IEC 61215 及 IEC TS62446-3 国际运维标准的智能化决策矩阵 (如“A 类-轻微观察”或“C 类-即时熔断更换”)。这种基于物理机理的退化建模范式,

将真正驱动光伏运维由“事后被动检修”向“事前精准预测性维护”的底层逻辑跨越，为大规模分布式电站资产收益率与 LCOE 的动态调控提供可解释的算法底座。

8 结论

光伏电站正全面迈向太瓦时 (Terawatt-hour, TWh) 时代。组件在复杂户外环境下的健康状态，直接决定了电站的安全运行与平准化度电成本 (LCOE)。本文立足于大规模光伏电站的智能化运维需求，系统梳理了光伏组件自动化缺陷检测技术从传统人工视觉向深度学习演进的完整脉络，并得出以下核心结论：在检测数据的获取与特征提取方面，可见光、红外热成像与电致发光 (EL) 等多模态技术在物理机理上高度互补。面对多晶硅晶界噪声强、微裂纹尺度小等工业难题，以 YOLO 系列为代表的单阶段目标检测算法在“精度与推理速度”的平衡上取得了突破，为产线及边缘侧（如无人机）的实时巡检提供了现实可行的方案；而结合 Vision Transformer (ViT) 全局感知能力的语义分割模型，则在缺陷区域的像素级精细化提取上展现出巨大潜力。同时，基于生成对抗网络 (GAN) 的数据增强与无监督重构技术，正在成为突破工业现场“高价值标注样本匮乏”瓶颈的有效路径。值得注意的是，光伏视觉检测技术的演进并非孤立存在，跨领域的前沿算法为其提供了丰富的理论基础。例如，在采煤机监控与复杂工业流水线缺陷检测中积累的抗高频动态噪声策略，为光伏组件应对强干扰背景提供了成熟的正则化思路^[66, 67]。此外，遥感图像中针对任意方向目标检测（如船舶）的旋转框 (Oriented Bounding Box) 技术，以及自主机器人在非结构化环境下的多源感知机制，也正被成功迁移应用于解决光伏面板在无人机倾斜视角下产生的剧烈透视畸变与大尺度突变难题^[68, 69]。

光伏组件的缺陷检测不应仅局限于计算机视觉层面的“定性识别”或“目标框选定位”。深度学习算法的深层价值，在于赋能光伏电站的全生命周期健康管理 (PHM)。

未来的研究应致力于打破学科壁垒，将多模态视觉感知数据与光伏组件的电气演化模型（如 I-V 曲线变异参数）及数字孪生系统深度融合，建立从“视觉缺陷”到“致害性量化”与“功率衰减预测”的映射关系。只有实现从“感知智能”向“认知决策”的跨越，智能检测技术才能真正转化为驱动光伏产业降本增效的核心生产力。

参考文献

- [1] HIJJAWI U, LAKSHMINARAYANA S, XU T, et al. A review of automated solar photovoltaic defect detection systems: approaches, challenges, and future orientations[J]. *Solar Energy*, 2023, 266: 112186.
- [2] HUSSAIN M, KHANAM R. In-depth review of YOLOv1 to YOLOv10 variants for enhanced photovoltaic defect detection[J]. *Solar*, 2024, 4(3): 351-386.
- [3] 王小宇, 刘波, 孙凯, 等. 光伏阵列故障诊断技术综述[J]. *电工技术学报*, 2024, 39(20): 6526-6543.
- WANG X Y, LIU B, SUN K, et al. A review of photovoltaic array fault diagnosis technology[J]. *Transactions of China Electrotechnical Society*, 2024, 39(20): 6526-6543.
- [4] AKRAM M W, LI G, JIN Y, et al. Failures of photovoltaic modules and their detection: a review[J]. *Applied Energy*, 2022, 313: 118822.
- [5] BUERHOP C, BOMMES L, SCHLIPF J, et al. Infrared imaging of photovoltaic modules: a review of the state of the art and future challenges facing gigawatt photovoltaic power stations[J]. *Progress in Energy*, 2022, 4(4): 042010.
- [6] SHABAN W M. Detection and classification of photovoltaic module defects based on artificial intelligence[J]. *Neural Computing and Applications*, 2024, 36(27): 16769-16796.
- [7] AHMAD A, JIN Y, ZHU C, et al. Photovoltaic cell defect classification using convolutional neural network and support vector machine[J]. *IET Renewable Power Generation*, 2020, 14(14): 2693-2702.
- [8] MUKANDAGUMBO N, VAN NIEKERK T, FERNANDES J, et al. Comparative analysis of YOLO based algorithms in solar panel detection using resource-constrained hardware[C]// *MATEC Web of Conferences*, 2025, 417: 04013.
- [9] XING E, CHEN S. GWPV-YOLO: Real-time photovoltaic defect detection based on UAV thermal imaging[C]// *2025 6th International Conference on Big Data & Artificial Intelligence & Software Engineering (ICBASE)*. Johor Bahru, Malaysia: IEEE, 2025: 277-281.
- [10] OTAMENDI U, MARTINEZ I, QUARTULLI M, et al. Segmentation of cell-level anomalies in electroluminescence images of photovoltaic modules[J]. *Solar Energy*, 2021, 220: 914-926.
- [11] BARNABÉ J P C, JIMÉNEZ L P, FRAIDENRAICH G, et al. Quantification of damages and classification of flaws in mono-crystalline photovoltaic cells through the application of vision transformers[J]. *IEEE Access*, 2023, 11: 112334-112347.
- [12] HE X, TAN J, HU T, et al. Multimodal segmentation for photovoltaic module defect detection[J]. *IEEE Access*, 2025, 13: 208652-208665.
- [13] GONG L, WANG Y, LV Y, et al. A lightweight and efficient model for photovoltaic (PV) panel defect detection in complex environments[EB/OL]. (2025). <https://ssrn.com/abstract=5134749>.
- [14] KUTTY S B, MUSA M A F, KASSIM M, et al. Enhancing Photovoltaic Panel Inspection using RGB Image-Based Detection and Image Processing Techniques[J]. *Journal of Computing Research and Innovation*, 2025, 10(2): 255-265.
- [15] AKRAM M W, LI G, JIN Y, et al. Automatic detection of photovoltaic module defects in infrared images with isolated and develop-model transfer deep learning[J]. *Solar Energy*, 2020, 198: 175-186.
- [16] SPAJIĆ M, TALAJIĆ M, MRŠIĆ L. Using CNNs for photovoltaic panel defect detection via infrared thermography to support Industry 4.0[J]. *Business Systems Research Journal*, 2024, 15(1): 45-66.
- [17] XU G, HUANG J, GONG W, et al. Solar cell defects detection based on photoluminescence images and upgraded YOLOv5 model[J]. *Journal of Engineering*, 2025, 2025(1): 8397362.
- [18] SU B, CHEN H, ZHOU Z. BAF-Detector: an efficient CNN-based detector for photovoltaic cell defect detection[EB/OL]. (2021-03-28).<https://arxiv.org/abs/2012.10631>.
- [19] MISTRY D, QIU F, CHEN B, et al. From prediction to diagnosis: Reasoning-aware AI for photovoltaic defect

- inspection[EB/OL]. (2026)[2026-04-05]. <http://arxiv.org/abs/2603.26776>.
- [20] PINHO L S, SOUSA T D, PEREIRA C D, et al. Anomaly detection for PV modules using multi-modal data fusion in aerial inspections[J]. IEEE Access, 2025, 13: 88762-88779.
- [21] LYSYI A, SACHENKO A, RADIUK P, et al. Method of UAV inspection of photovoltaic modules using thermal and RGB data fusion[EB/OL]. (2025). <https://arxiv.org/abs/2512.06504>.
- [22] SU B, ZHOU Z, CHEN H. PVEL-AD: a large-scale open-world dataset for photovoltaic cell anomaly detection[J]. IEEE Transactions on Industrial Informatics, 2023, 19(1): 404-413.
- [23] LUO Z, CHENG S Y, ZHENG Q Y. GAN-based augmentation for improving CNN performance of classification of defective photovoltaic module cells in electroluminescence images[C]// IOP Conference Series: Earth and Environmental Science, 2019, 354(1): 012106.
- [24] LIU Y C, HUA Q, CHEN L L, et al. A multi-scale neighborhood feature interaction network for photovoltaic cell defect detection[EB/OL]. (2024). <https://ssrn.com/abstract=4919206>.
- [25] 陈海永, 刘新如. 交叉门控融合的改进语义分割网络及应用[J]. 重庆理工大学学报(自然科学), 2023, 37(6): 187-195.
CHEN H Y, LIU X R. An improved semantic segmentation network and its application by using cross-gated fusion[J]. Journal of Chongqing University of Technology (Natural Science), 2023, 37(6): 187-195.
- [26] YANG, et al. A lightweight transformer model for defect detection in electroluminescence images of photovoltaic cells[J]. IEEE Access, 2024.
- [27] DI RENZO A B, DE MORAIS H R F, LAZZARETTI A E, et al. Edge device for the classification of photovoltaic faults using deep neural networks[J]. Journal of Control, Automation and Electrical Systems, 2024, 35(5): 861-869.
- [28] PANDIARAJAN I, SINDHA M M R, PANDYAN U M, et al. TinyViT: field deployable transformer pipeline for solar panel surface fault and severity screening[EB/OL]. (2025-11-27). <https://arxiv.org/abs/2512.00117>.
- [29] SU B, et al. Deep learning-based method for defect detection in electroluminescent images of polycrystalline silicon solar cells[J]. Optics Express, 2024, 32(10): 17295.
- [30] AHMED, et al. Advancing automatic photovoltaic defect detection using semi-supervised semantic segmentation of electroluminescence images[EB/OL]. (2024-04). <https://arxiv.org/abs/2404.13693>.
- [31] COOK E, LUO S, WENG Y. Solar panel identification via deep semi-supervised learning and deep one-class classification[J]. IEEE Transactions on Power Systems, 2022, 37(4): 2516-2526.
- [32] OVI M H, AKANDA R R, ABDUL KAIUM SHOHUG M. Unsupervised Machine Learning for Anomaly Detection in Solar Power Generation: Comparative Insight[C]// International Conference on Machine Intelligence and Emerging Technologies. Singapore: Springer Nature Singapore, 2024: 331-345.
- [33] HAN T, WANG X, GUO J, et al. Health-aware joint learning of scale distribution and compact representation for unsupervised anomaly detection in photovoltaic systems[J]. IEEE Transactions on Instrumentation and Measurement, 2025, 74: 1-11.
- [34] SHI S, TAN J, CHEN H. Dynamic domain adaptation object detection for photovoltaic cell defects[C]// 2023 IEEE 4th International Conference on Electronic Technology, Communication and Information (ICETCI). Changchun, China: IEEE, 2023.
- [35] MAYR M, HOFFMANN M, et al. Weakly supervised segmentation of cracks on solar cells using normalized Lp norm[C]// 2019 IEEE International Conference on Image Processing (ICIP). Taipei, Taiwan, China: IEEE, 2019: 1885-1889.
- [36] CHEN C, ZHANG C, SHI Y. A photovoltaic panel defect detection framework enhanced by deep learning[J]. AIP Advances, 2025, 15(9): 095226.
- [37] 简献忠, 熊惠民, 郭强. YOLO11-EMFL: 一种太阳能电池表面缺陷检测方法[J]. 光电工程, 2025, 52(8): 110-126.
JIAN X Z, XIONG H M, GUO Q. YOLO11-EMFL: a method for surface defect detection of solar cells[J]. Opto-Electronic Engineering, 2025, 52(8): 250102.

- [38] 刘义艳, 郝婷楠, 贺晨, 等. 基于 DBBR-YOLO 的光伏电池表面缺陷检测[J]. 图学学报, 2024, 45(5): 913-921.
- LIU Y Y, HAO T N, HE C, et al. Photovoltaic cell surface defect detection based on DBBR-YOLO[J]. Journal of Graphics, 2024, 45(5): 913-921.
- [39] 王银, 高瑞泽, 李茂环, 等. 基于 YOLOv5 LiteX 算法的光伏组件缺陷检测[J]. 太阳能学报, 2023, 44(9): 101-108.
- WANG Y, GAO R Z, LI M H, et al. Photovoltaic modules defect detection based on YOLOv5 LiteX algorithm[J]. Acta Energetica Solaris Sinica, 2023, 44(9): 101-108.
- [40] ALI, et al. Optimized YOLO based model for photovoltaic defect detection in electroluminescence images[J]. PMC, 2025.
- [41] ZHAO, et al. An effective approach to improving photovoltaic defect detection using the new DCD-YOLOv8s model[J]. PMC, 2025.
- [42] CAO Y, PANG D, ZHAO Q, et al. Improved YOLOv8-GD deep learning model for defect detection in electroluminescence images of solar photovoltaic modules[J]. Engineering Applications of Artificial Intelligence, 2024, 131: 107866.
- [43] 刘婷婷, 宋家友. 融合多模态特征与改进 YOLOv12 的光伏电池板组件缺陷检测[J]. 计算机工程与应用, 2026, 62(7): 107-120.
- LIU T T, SONG J Y. Defect detection for photovoltaic panel components integrating multimodal feature and improved YOLOv12[J]. Computer Engineering and Applications, 2026, 62(7): 107-120.
- [44] LI J, ZHANG W, ZHANG X Y, et al. A lightweight model for infrared photovoltaic panel defect detection via UAV-based inspection systems[J]. IEEE Transactions on Instrumentation and Measurement, 2025, 74: 1-12.
- [45] HANIFI S, JAFARNEJAD S, CORMIER M, et al. Multi-class Semantic Segmentation of Photovoltaic Module Defects and Features: Towards Industrial Robotic Applications[C]// International Conference on Industrial, Engineering and Other Applications of Applied Intelligent Systems. Singapore: Springer Nature Singapore, 2025: 37-48.
- [46] DAI W, TONG S, XIA D, et al. Unsupervised semantic segmentation for solar cell defect detection using SAM and feature fusion[C]// 2024 International Conference on Sensing, Measurement & Data Analytics in the era of Artificial Intelligence (ICSMD). Huangshan, China: IEEE, 2024: 1-5.
- [47] WANG Y N, LIU H T, LIU H Y, et al. Solar cell image defect detection method based on improved U-Net[J]. Electric Measurement Technology, 2024, 44(14): 117-121.
- [48] ZHOU P, WANG R, WANG C, et al. SIIF: semantic information interactive fusion network for photovoltaic defect segmentation[J]. Applied Energy, 2024, 371: 123643.
- [49] XIE X, LIU H, NA Z, et al. DPiT: detecting defects of photovoltaic solar cells with image transformers[J]. IEEE Access, 2021, 9: 154292-154303.
- [50] SU B, ZHOU Z, CHEN H, et al. SIGAN: a novel image generation method for solar cell defect segmentation and augmentation[EB/OL]. (2021-04-11). <https://arxiv.org/abs/2104.04953>.
- [51] LIN Y, SUN P, WU R, et al. Unsupervised and few-shot segmentation in photovoltaic electroluminescence images for defect detection via a novel enhanced iterative autoencoder with simple implementation[J]. Energy & Environmental Science, 2026, 19(2): 513-526.
- [52] GUAN Y, LIU Y, WANG J, et al. Novel multi-scale attention generative adversarial network for photovoltaic solar cell defect inspection using electroluminescence images[J]. IEEE Access, 2025, 13: 84409-84423.
- [53] HARROU F, DAIRI A, TAGHEZOUIT B, et al. An unsupervised monitoring procedure for detecting anomalies in photovoltaic systems using a one-class support vector machine[J]. Solar Energy, 2019, 179: 48-58.
- [54] DUONG Q T, KIM D P T, PHAM M T. Variational autoencoder for anomaly detection: a comparative study[EB/OL]. (2024-08-24).
- [55] ZHU N, WANG J, ZHANG Y, et al. An adversarial training framework based on unsupervised feature reconstruction constraints

- for crystalline silicon solar cells anomaly detection[J]. IEEE Transactions on Instrumentation and Measurement, 2024, 73: 1-13.
- [56] 姚瑛, 顾冰, 方正楠. 一种基于注意力机制目标检测的无人机的光伏板巡检方法[J]. 电气传动, 2025, 55(5): 89-96.
YAO Y, GU B, FANG Z N. A photovoltaic panel inspection method for UAV based on attention mechanism target detection[J]. Electric Drive, 2025, 55(5): 89-96.
- [57] 兰金江, 曾学仁, 方亮, 等. 基于无人机巡检的光伏缺陷检测与定位[J]. 科技创新与应用, 2024(18): 14-19.
LAN J J, ZENG X R, FANG L, et al. Photovoltaic defect detection and positioning based on UAV patrol inspection[J]. Technology Innovation and Application, 2024(18): 14-19.
- [58] 翟金星, 王力平, 张艳辉. 基于无人机红外视觉的光伏电站热斑智能巡检[J]. 红外技术, 2026, 48(1): 95-104.
ZHAI J X, WANG L P, ZHANG Y H. Unmanned-aerial-vehicle infrared-vision-based intelligent inspection of hotspots in photovoltaic power station[J]. Infrared Technology, 2026, 48(1): 95-104.
- [59] BABU Y R, PRIYADARSINI N I, SIRISHA P G K, et al. Real-time anomaly detection in solar panel arrays: integrating single shot multibox detector (SSD) with IoT and edge computing[J]. ITM Web of Conferences, 2025, 74: 01014.
- [60] 闫号, 戴佳佳, 龚小溪, 等. 基于多源图像融合的光伏面板缺陷检测[J]. 红外技术, 2023, 45(5): 488-497.
YAN H, DAI J J, GONG X X, et al. Defect detection of photovoltaic panel based on multisource image fusion[J]. Infrared Technology, 2023, 45(5): 488-497.
- [61] 刘泉雄, 郑茜颖. 基于深度学习的光伏板缺陷分类定位算法研究[J]. 光电子技术, 2024, 44(1): 54-60.
LIU X X, ZHENG Q Y. Research on deep learning-based classification and localization algorithm for photovoltaic panel defects[J]. Optoelectronic Technology, 2024, 44(1): 54-60.
- [62] DWIVEDI D, BABU K V S M, YEMULA P K, et al. Identification of surface defects on solar PV panels and wind turbine blades using attention based deep learning model[EB/OL]. (2024-01-08).
- [63] HAN Z, ZHANG C, FU H, et al. Trusted multi-view classification[C]// 9th International Conference on Learning Representations (ICLR). Vienna, Austria, 2021.
- [64] BOUREZZANE I, NOUREDDINE G, ISSAOUI R, et al. Photovoltaic failure diagnosis using imaging techniques and electrical characterization[J]. EPJ Photovoltaics, 2024, 15: 20.
- [65] SERFA JUAN R O, KIM J. Photovoltaic cell defect detection model based-on extracted electroluminescence images using SVM classifier[C]// 2020 International Conference on Artificial Intelligence in Information and Communication (ICAIIIC). Fukuoka, Japan: IEEE, 2020: 578-582.
- [66] SONG Y, WANG W, WU Y, et al. Unsupervised anomaly detection in shearers via autoencoder networks and multi-scale correlation matrix reconstruction[J]. International Journal of Coal Science and Technology, 2024, 11(1): 79.
- [67] PATRA S, TAIEB S B. Revisiting deep feature reconstruction for logical and structural industrial anomaly detection[EB/OL]. (2024-10-21). <https://arxiv.org/abs/2410.16255>.
- [68] OLIVATO M, COTUGNO O, BRIGATO L, et al. A comparative analysis on the use of autoencoders for robot security anomaly detection[C]// 2019 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). Macau, China: IEEE, 2019: 984-989.
- [69] HUANG J, WANG K, HOU Y, et al. LW-YOLO11: A lightweight arbitrary-oriented ship detection method based on improved YOLO11[J]. Sensors, 2025, 25: 65.