



计算机工程与应用
Computer Engineering and Applications
ISSN 1002-8331, CN 11-2127/TP

《计算机工程与应用》网络首发论文

题目: 视觉 SLAM 算法及主传感器综述
作者: 郭晓栋, 陶奋杰, 唐术锋, 吕彩霞, 王鑫, 赫然
网络首发日期: 2026-07-16
引用格式: 郭晓栋, 陶奋杰, 唐术锋, 吕彩霞, 王鑫, 赫然. 视觉 SLAM 算法及主传感器综述[J/OL]. 计算机工程与应用.
<https://link.cnki.net/urlid/11.2127.TP.20260716.1110.010>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

视觉 SLAM 算法及主传感器综述

郭晓栋^{1,2}, 陶奋杰^{1,2}, 唐术锋^{1,2+}, 吕彩霞³, 王鑫^{1,2}, 赫然^{1,2}

1. 内蒙古工业大学 机械工程学院, 呼和浩特 010051

2. 内蒙古自治区机器人与智能装备技术重点实验室, 呼和浩特 010051

3. 内蒙古农业大学 职业技术学院, 内蒙古 包头 014109

+ 通信作者 E-mail: tangshufeng@imut.edu.cn

摘要: 针对视觉同步定位与地图构建 (visual simultaneous localization and mapping, vSLAM) 中主传感器类型多样、算法路线差异明显、评价维度不统一等问题, 围绕主传感器及其相关算法进行了综述分析。介绍了 vSLAM 系统的基本流程, 按照特征点法、直接法和基于学习的方法梳理了主要技术路线; 从单目、双目、RGB-D、全景相机和事件相机等主传感器角度出发, 归纳了典型算法的工作原理、技术特点和适用场景, 并结合轨迹精度、尺度稳定性、系统完整性、实时性与资源占用、建图质量等指标, 对不同方法的优势与局限进行了比较。分析结果表明, 特征点法和直接法在实时性、可解释性和工程部署方面具有优势, 适合计算资源受限和实时定位需求较高的场景; 基于学习的方法在稠密匹配、动态场景理解和高质量地图表达方面表现出较强潜力, 但对训练数据、图形处理器算力和跨场景泛化能力依赖较强。双目、RGB-D、全景和事件相机分别能够从尺度约束、深度观测、大视场覆盖和高动态感知等方面改善 vSLAM 性能。综合来看, 几何约束、学习表示、语义理解和多模态融合是提高 vSLAM 鲁棒性、实时性和工程适应性的重要途径。

关键词: 视觉 SLAM; 相机; 特征点法; 直接法; 深度学习

文献标志码:A **中图分类号:** TP242.6+2 **doi:** 10.3778/j.issn.1002-8331.2601-0194

A Review of Visual SLAM Algorithms and Primary Sensors

GUO Xiaodong^{1,2}, TAO Fenjie^{1,2}, TANG Shufeng^{1,2+}, LYU Caixia³, WANG Xin^{1,2}, HE Ran^{1,2}

1. School of Mechanical Engineering, Inner Mongolia University of Technology, Hohhot 010051, China

2. Inner Mongolia Key Laboratory of Robotics and Intelligent Equipment Technology, Hohhot 010051, China

3. Vocational and Technical College, Inner Mongolia Agricultural University, Baotou, Inner Mongolia 014109, China

Abstract: A review of primary sensors and related algorithms is conducted to address the diversity of sensor types, differences among algorithmic routes, and inconsistent evaluation dimensions in visual simultaneous localization and mapping (vSLAM). The basic workflow of a vSLAM system is introduced, and the main technical routes are summarized according to feature-based methods, direct methods, and learning-based methods. From the perspective of primary sensors, including monocular, stereo, RGB-D, panoramic, and event-based cameras, representative algorithms are reviewed in terms of their working principles, technical characteristics, and applicable scenarios. The advantages and limitations of different methods are compared using evaluation metrics such as trajectory accuracy, scale stability, system completeness, real-time performance, resource consumption, and mapping quality. The analysis shows that feature-based and direct methods have advantages in real-time performance, interpretability, and engineering deployment, making them suitable for scenarios with limited computational resources and high real-time localization requirements. Learning-based methods show strong potential in dense matching, dynamic scene understanding, and high-quality map representation, but they strongly depend

基金项目: 内蒙古自治区自然科学基金 (2025MS06034), 锡林郭勒盟科技计划项目 (202405), 自治区一流学科科研专项项目 (YLXKZX-NGD-020), 内蒙古自治区高层次人才支持计划项目 (DC2400002158), 内蒙古工业大学科研启动金项目 (BS2024002), 内蒙古自治区直属高校基本科研业务费项目 (JY20250076), 国家自然科学基金 (52465003), “英才兴蒙”工程团队 (2025TEL02)。

作者简介: 郭晓栋 (1993—), 男, 博士, 讲师, 研究方向为图像处理与计算机视觉; 陶奋杰 (2001—), 男, 硕士研究生, 研究方向为目标检测与 SLAM 技术; 唐术锋 (1981—), 男, 博士, 教授, 研究方向为特殊服役机器人技术; 吕彩霞 (1990—), 女, 硕士, 讲师, 研究方向为智能装备技术; 王鑫 (1994—), 男, 博士, 副研究员, 研究方向为图像处理与计算机视觉; 赫然 (2002—), 男, 硕士研究生, 研究方向为机器人定位建图导航。

on training data, graphics processing unit computing resources, and cross-scene generalization capability. Stereo, RGB-D, panoramic, and event-based cameras can improve vSLAM performance through scale constraints, depth observation, wide-field coverage, and high-dynamic sensing, respectively. Overall, geometric constraints, learned representations, semantic understanding, and multimodal fusion are important approaches for improving the robustness, real-time performance, and engineering adaptability of vSLAM.

Key words: visual SLAM; camera; feature-based method; direct method; deep learning

传感器作为 SLAM 系统的“眼睛”，负责采集环境的原始数据，其性能优劣直接关乎整个系统定位与建图的精度及可靠性。从早期简单的单目相机，到能获取深度信息的双目相机、RGB-D 相机，再到具备高动态范围、低延迟特性的事件相机，视觉传感器历经了持续的革新与演进。不同类型的视觉传感器在成像方式、深度获取、动态范围和实时性方面具有差异化优势，可在室内服务机器人、自动驾驶、无人机和工业巡检等场景中发挥作用。

1 算法分类与评价体系

1.1 vSLAM 基本流程

vSLAM 系统通常由前端跟踪、后端优化、回环检测、重定位和地图构建等模块组成。前端根据连续图像或事件流估计相机短时运动，并向后端提供特征点、像素误差、深度约束或学习特征等观测信息；后端通过滤波、局部 BA、位姿图优化或因子图优化降低累计误差；回环检测用于识别相机是否回到已访问区域，并通过全局优化提升地图一致性；地图构建则根据任务需求形成稀疏点云、半稠密地图、稠密点云、神经隐式场或 3D Gaussian 地图。不同主传感器和算法路线的差异，主要体现在前端观测形式、深度获取方式、后端约束构建和地图表达形式上。

1.2 主要技术路线

从算法机制看，vSLAM 方法可分为特征点法、直接法和基于学习的方法。特征点法通过提取角点、线特征或局部描述子建立帧间关联，并结合 PnP、三角化、BA 和位姿图优化完成定位与建图，具有实时性好、可解释性强、工程应用成熟等优点，但在弱纹理、重复纹理和动态场景中容易出现特征不足或误匹配。典型特征点法包括 EKF-SLAM^[1]、PTAM^[2]、ORB-SLAM^[3]、ORB-SLAM2^[4]和 ORB-SLAM3^[5]等。其中，EKF-SLAM 代表早期基于滤波的状态估计思想，PTAM 将跟踪与建图线程分离，推动了关键帧式单目 SLAM 框架的发展；ORB-SLAM 系列则通过 ORB 特征、关键帧管理、词袋回环检测、重定位和 BA 优化形成了较完整的 vSLAM 系统框架。

直接法不依赖显式特征匹配，而是通过最小化像素灰度误差或光度误差估计相机位姿，能够利用更多图像信息，适合特征点不足但光度连续的场景，但对曝光变化、运动模糊、非朗伯表面和光照不一致较敏感。典型直接法包括 DTAM^[6]、LSD-SLAM^[7]、SVO^[8]和 DSO^[9]等。其中 DTAM 代表稠密直接法，LSD-SLAM 代表半稠密直接法，SVO 和

DSO 则分别体现了半直接法和稀疏直接法在实时视觉里程计中的应用。

基于学习的方法利用深度网络进行位姿估计、深度预测、特征匹配、动态目标剔除或神经地图表达，能够增强复杂场景下的感知能力和地图表达能力，但其性能通常依赖训练数据、GPU 算力和跨场景泛化能力。典型基于学习的方法包括 DeepVO^[10]、CNN-SLAM^[11]、DROID-SLAM^[12]、Nicer-SLAM^[13]、MonoGS^[14]、Photo-SLAM^[15]和 MAST3R-SLAM^[16]等，它们分别从端到端视觉里程计、学习型深度估计、可微稠密优化、神经隐式地图和三维高斯泼溅（3D Gaussian Splatting, 3DGS）地图表达^[17]等方面扩展了传统 vSLAM 的技术路线。此外，vSLAM 的系统性能还依赖于回环检测、重定位和后端优化等基础模块。FAB-MAP^[18]和 DBow^[19]系列方法推动了基于外观词袋模型的位置识别和回环检测研究；g2o^[20]和 Ceres^[21]等通用优化工具则为 BA、位姿图优化和非线性最小二乘求解提供了常用实现框架；卡尔曼滤波^[22]及其扩展形式^[23]、关键帧重定位与回环检测方法^[24]为后续特征点法、直接法、视觉惯性融合和学习增强 SLAM 系统提供了重要支撑。

1.3 学习方法的技术路线

随着深度学习、神经隐式表示和 3DGS 的发展，基于学习的方法逐渐被引入 vSLAM 系统。与特征点法和直接法主要依赖人工特征、光度误差和几何优化不同，基于学习的方法通过神经网络学习特征、深度、位姿、语义或地图表达，从而提高系统在弱纹理、动态环境、复杂光照和高质量建图场景中的适应能力。

从技术路线看，基于学习的 vSLAM 方法可概括为四类。第一类是学习型视觉里程计与深度估计辅助 SLAM，代表方法包括 DeepVO、PoseNet^[25]和 CNN-SLAM 等，主要通过网络估计相机运动、重定位结果或单目深度信息，但长期运行时仍容易受到累计漂移和训练数据泛化能力的影响。第二类是学习型匹配与可微优化 SLAM，代表方法包括 DROID-SLAM、SLAM3R^[26]和 MAST3R-SLAM 等，主要通过学习型光流、稠密相关性、点图预测或可微 BA 提高数据关联和位姿估计能力，但通常需要较高 GPU 算力。第三类是语义动态 SLAM，代表方法包括 DS-SLAM^[27]、DynaSLAM^[28]和 DDN-SLAM^[29]等，主要通过语义分割、动态目标检测或动态区域建模剔除运动物体影响，但会增加系统计算开销。第四类是神经隐式 SLAM 与 3DGS-

SLAM, 代表方法包括 iMAP^[30]、Nicer-SLAM、EN-SLAM^[31]、MonoGS、Photo-SLAM、SpliTAM^[32]、RGBDGS-ICP-SLAM^[33]和 WildGS-SLAM^[34]等, 能够提升稠密重建、真实感渲染和新视角合成能力, 但对显存、计算资源和长期地图维护提出了更高要求。

综合来看, 基于学习的方法主要从学习位姿与深度、学习型匹配与可微优化、语义动态理解以及神经地图表达四个方面扩展传统 vSLAM。与传统几何方法相比, 其优势主要体现在弱纹理、动态场景和高质量地图表达中; 其不足则集中在训练数据依赖、跨场景泛化不足、计算资源需求高和工程部署复杂等方面。

1.4 主要评价指标

为比较不同主传感器和不同算法路线下的 vSLAM 性能, 本文主要从轨迹精度、尺度稳定性、系统完整性、实时性与资源占用、建图质量等方面进行评价。其中, 轨迹精度反映定位结果与真实轨迹之间的误差; 尺度稳定性衡量系统在长期运行中的尺度保持能力; 系统完整性关注回环检测、重定位、全局优化和地图维护能力; 实时性与资源占用反映算法在 CPU、GPU、显存和嵌入式平台上的部署难度; 建图质量则用于评价地图表达形式、几何完整性和场景细节恢复能力。

1.4.1 轨迹精度

在视觉 SLAM 算法评价中, 轨迹精度主要用于衡量系统估计相机位姿与真实位姿之间的误差。

绝对轨迹误差 ATE (ATE, Absolute Trajectory Error) 是用于衡量估计轨迹与真实轨迹之间的全局偏差^[35]。它反映的是 SLAM 系统在整个运行过程中的整体定位精度。

则 ATE-RMSE 的计算公式为:

$$ATE_{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n \left\| \text{trans}(T_i^{-1} S \hat{T}_i) \right\|^2}$$

其中, n 为轨迹帧数, $\text{trans}(\cdot)$ 表示取位姿误差矩阵中的平移部分。ATE-RMSE 数值越小, 说明估计轨迹与真实轨迹越接近。

相对位姿误差 RPE (Relative Pose Error), 用于衡量相邻帧或固定时间间隔内的相对运动估计误差。与 ATE 关注全局轨迹偏差不同, RPE 更关注 SLAM 系统的局部运动估计精度。

计算方法为设真实轨迹在第 i 帧到第 $i + \Delta$ 帧之间的相对运动为 $\Delta T_i = T_i^{-1} T_{i+\Delta}$

估计轨迹对应的相对运动为: $\Delta \hat{T}_i = T_i^{-1} \hat{T}_{i+\Delta}$

则相对位姿误差为: $E_i^{RPE} = (\Delta T_i)^{-1} \Delta \hat{T}_i$

其平移误差可表示为:

$$RPE_{trans} = \sqrt{\frac{1}{m} \sum_{i=1}^m \left\| \text{trans}(E_i^{RPE}) \right\|^2}$$

旋转误差可表示为:

$$RPE_{rot} = \frac{1}{m} \sum_{i=1}^m \text{angle}(\text{rot}(E_i^{RPE}))$$

其中, $\text{angle}(\cdot)$ 表示由旋转矩阵计算得到的旋转角误差, m 为参与计算的相对位姿对数量。

RPE 主要用于评价算法的局部漂移和短时间运动估计能力。对于 VO 和 VIO 算法来说, RPE 比 ATE 更能反映算法本身的帧间运动估计能力。因为 VO 和 VIO 通常不具备完整回环检测和全局优化能力, 长期轨迹会出现累计漂移, 此时仅用 ATE 评价可能会过分强调全局误差, 而 RPE 能更好地反映局部跟踪精度。

1.4.2 尺度稳定性

尺度稳定性主要用于评价 SLAM 系统在运动过程中是否能够保持正确物理尺度。单目 SLAM 和单目 VO 无法直接观测绝对深度, 容易出现尺度不确定和尺度漂移; 双目、RGB-D 和 VIO 系统由于引入固定基线、深度图或 IMU 信息, 通常具有更好的尺度可观测性。漂移率用于衡量单位距离或总路程中的误差累积, 常用于长距离 VO、VIO 和自动驾驶场景评价。

1.4.3 系统完整性

回环检测召回率用于衡量相机重新回到曾经到达过的位置时, 系统能否成功识别这是一个回环。回环召回率越高, 说明系统越不容易漏检回环, 长期运行时越有可能及时修正累计误差。对于大范围移动机器人、自动驾驶和室内巡检任务, 回环召回率直接影响轨迹和地图的全局一致性。

1.4.4 实时性与部署

实时性与部署指标主要用于评价 vSLAM 算法能否在实际机器人、无人机或嵌入式平台上稳定运行。与轨迹精度指标不同, 实时性指标更关注算法的计算效率、硬件需求和工程可部署性。对于 SLAM 系统而言, 算法不仅需要获得较高定位精度, 还需要在相机连续输入数据时及时完成前端跟踪、后端优化、回环检测和地图更新, 否则会造成系统延迟增大、跟踪失败或无法在线运行。

(1) Tracking 和 Mapping

完整 SLAM 系统一般包含前端跟踪和后端建图两个部分。Tracking 频率表示系统每秒能够完成多少次相机位姿估计, Mapping 频率表示系统每秒能够完成多少次地图更新或关键帧优化。

Tracking 频率主要反映系统能否实时输出位姿, Mapping 频率反映系统能否及时更新地图。对于多线程 SLAM 系统, 跟踪线程通常需要高频运行, 而建图线程可以低频运行。比如一些神经隐式 SLAM 和 3DGS-SLAM 方法可能 Tracking 较快, 但 Mapping 或渲染优化较慢, 因此需要分别报告 Tracking Hz 和 Mapping Hz。

(2) 事件处理速率

对于事件相机 SLAM, 输入数据不是传统帧图像, 而是异步事件流。因此除了 FPS, 还可以使用事件处理速率

评价系统实时性,常用单位为 Mev/s,即每秒处理百万事件数。

事件处理速率适合评价事件相机 SLAM 在高速运动和高动态场景下的实时能力。事件相机在剧烈运动或光照变化时会产生大量事件,如果算法事件处理速率不足,就会导致事件堆积、延迟增大或跟踪失败。

1.4.5 建图质量

建图质量用于衡量 SLAM 系统构建地图的几何准确性、完整性和表达能力。传统稀疏 SLAM 主要构建稀疏特征点地图,服务于定位和回环检测;RGB-D、稠密重建和直接法通常可生成半稠密或稠密地图;神经隐式 SLAM 和 3DGS-SLAM 进一步提升了场景细节表达、新视角合成和真实感渲染能力,但通常伴随更高的计算和存储成本。因此,评价不同 SLAM 方法时,不应只比较轨迹误差,还应结合地图表示形式、系统完整性和部署代价进行综合分析。

2 主传感器类型

2.1 单目相机

2.1.1 单目相机的特点

单目相机结构简单、成本低、体积小,适合预算和功耗受限的应用场景,但无法直接获得绝对深度,容易产生尺度不确定和长期尺度漂移。

2.1.2 单目 vSLAM 代表算法

单目 SLAM 特征点法的代表算法包括 VINS-Mono^[36]、MonoSLAM^[37]、PTAM、ORB-SLAM 等。其中,MonoSLAM

是早期实时单相机 SLAM 的代表系统;PTAM 通过跟踪线程与建图线程并行化,奠定了关键帧式单目 SLAM 框架;ORB-SLAM 进一步引入统一 ORB 特征、关键帧管理、词袋回环检测、重定位和 BA 优化,形成较完整的特征点单目 SLAM 系统。

直接法和半直接法的代表算法包括 DTAM、LSD-SLAM、SVO 和 DSO。其中,DTAM 实现了基于全像素光度一致性的稠密跟踪与建图,LSD-SLAM 利用半稠密深度图和 Sim3 图优化提升了大尺度单目建图能力;SVO 属于半直接视觉里程计,突出实时性;DSO 属于直接稀疏视觉里程计,通过光度标定、稀疏像素选择和滑动窗口优化提高了单目 VO 精度。

基于学习的算法中,DeepVO 代表学习型 VO 方向,通过深度网络、深度估计或运动先验增强位姿估计能力。DROID-SLAM 通过学习型光流、循环迭代更新和可微稠密 BA 提升位姿与深度估计;CNN-SLAM、Nicer-SLAM 等将深度网络或神经隐式表达引入稠密建图;MonoGS 和 WildGS-SLAM 则将 3DGS 用于单目 SLAM 地图表达,提高了渲染质量和稠密表达能力;SLAM3R 和 MAST3R-SLAM 进一步利用三维重建先验或前馈点图预测,推动单目 SLAM 向大场景稠密重建发展。为比较不同单目 SLAM 算法在轨迹精度、尺度稳定性、系统完整性和实时部署方面的差异,表 1 对典型完整单目 SLAM 算法进行归纳。

表 1 完整单目 SLAM 算法指标表

Table 1 Complete Monocular SLAM Algorithm Metrics Table

算法名称	位姿精度	尺度稳定性	系统完整性	实时性和部署情况
MonoSLAM ^[37]	局部 RMSE 在实验室环境约 <1cm	依靠 EKF 维持尺度	未明确报告	在 2.4 GHz CPU 可 30FPS 实时运行
PTAM ^[2]	真值对齐后的轨迹标准差约 6 mm	未明确报告	未明确报告	Intel Core 2 Duo 2.66 GHz; 典型跟踪约 19.2 ms/frame; 约 6000 点、150 关键帧规模下较实用
LSD-SLAM ^[7]	在 TUM 室内序列中: 1.2cm 到 2.5cm 之间	采用 Sim3 约束,使其在长距离运动中对尺度漂移的控制力远强于早期的单目算法。	采用外观描述子进行初选,随后使用直接法图像对齐进行几何验证。	在 Intel i7-2600 上可以 30-60FPS 运行,储存半稠密点云,内存消耗高于稀疏特征点云。
ORB-SLAM ^[3]	在 TUM 中: 1cm 到 5cm 之间	依赖 7 自由度 Sim3 的回环校正	基于 DBoW2 的位置识别模块,在与当时的标杆算法 FAB-MAP 对比时,ORB-SLAM 在相同准确率下的召回率明显更高。	Intel Core i5 等桌面级 CPU 也可 25-30FPS 实时运行
DROID-SLAM ^[12]	EuroC MAV 中: 平均 5cm TUM 中: 1cm 到 3cm 之间	通过 DBA 维持的全局一致性也能极大地抑制尺度收缩。	基于视觉相似性的稠密图结构比传统的稀疏特征匹配更不容易漏掉回环	在 RTX 3090 上,它也仅能维持在 10 到 15 FPS,显存需求至少 8G 可处理 640×480 视频流,几乎无法在普通的 CPU 上运行。
MASt3R-SLAM ^[16]	EuroC MAV 中: 平均 4cm TUM 中: 平均 3cm	未明确报告	未明确报告	实验平台为 i9-12900K, GPU 为 RTX 4090 可以 15 FPS 实时运行

从表 1 可以看出,传统特征点法和直接法在 CPU 平台上具有较好的实时性,适合低成本在线定位任务;DROID-SLAM、MASt3R-SLAM 等学习型方法在轨迹精度、稠密匹配和复杂场景适应性方面具有优势,但对 GPU 和显存依赖较强,工程部署成本较高。因此,单目 SLAM 在实际应用中需要在轨迹精度、实时性、尺度稳定性和硬件

资源之间进行权衡。随着单目 SLAM 从稀疏定位逐渐扩展到稠密重建、神经隐式表示和 3DGS 地图表达,仅依靠轨迹精度已难以全面评价算法性能。因此,表 2 从位姿精度、地图表示形式、资源占用和系统完整性等方面,对单目稠密重建、神经场和 3DGS 类方法进行比较。

表 2 单目稠密重建、神经场、3DGS 指标评价表

Table 2 Monocular Dense Reconstruction, Neural Fields, 3DGS Metric Evaluation Table

算法名称	位姿精度	地图表示形式	资源占用	系统情况
DTAM ^[6]	通过与 PTAM 的跟踪对比曲线展示, 指出 DTAM 在快速运动、图像退化时更稳定	稠密关键帧逆深度图、RGB 参考图、三角网格和纹理表面拼接	在 CPU i7, GPU GTX480 上以 30FPS 实时运行	未明确报告
CNN-SLAM ^[11]	在 ICL-NUIM 与 TUM 序列上的平均 ATE 为 24cm	地图是关键帧式稠密深度地图、不确定性图和全局三维模型	实验平台为 Intel Xeon 2.4 GHz CPU、NVIDIA Quadro K5200 GPU, CNN 深度预测和语义分割在 GPU 上运行, 其他 SLAM 线程在 CPU 上运行	实时运行 需要学习深度辅助稠密建图 不严格实时 不支持显式回环 需要预训练模型 不需要 RGB-D 深度传感器, 但需要单目先验 实时运行
NICER-SLAM ^[13]	在 Replica 数据集平均 1.88 cm; 7-Scenes 平均 8.55 cm。论文评价方式是用估计轨迹与真值轨迹对齐后计算 ATE-RMSE。	采用 hierarchical neural implicit representation	需 24GB 显存 GPU, 实验平台在 A100GPU	不支持显式回环 单目模式不需要外部深度 实时运行
MonoGS ^[14]	单目版本在 TUM RGB-D 数据集平均 4cm	地图是 3DGS 表示	实验平台为 Intel Core i9-12900K 3.50 GHz + NVIDIA RTX 4090; CUDA 实现关键 rasterisation 和梯度计算, 其余 SLAM 管线用 PyTorch。	不支持显式回环 单目模式不需要外部深度 实时运行
SLAM3R ^[26]	在 Replica 中测试 ATE 平均 6.61 cm	稠密 3D pointmaps I2P 局部重建和 L2W 全局注册	在 GPU 4090D 可以 15-20FPS 实时运行	需要预训练 需要学习几何先验 实时运行 支持回环和全局优化 需要预训练 可无标定运行
MASt3R-SLAM ^[16]	EuroC MAV 中: 平均 4cm TUM 中: 平均 3cm	基于两视图 3D reconstruction prior	实验平台在 i9-12900K, RTX 4090	

从表 2 可以看出, 单目 SLAM 已由稀疏定位扩展到稠密重建、神经隐式表示和 3DGS 地图表达。CNN-SLAM 等早期学习型方法主要依赖深度预测辅助建图, 定位精度和地图表达能力仍有限; Nicer-SLAM、MonoGS、MASt3R-SLAM 和 WildGS-SLAM 等方法进一步提升了场景细节表达和真实感渲染能力, 但通常依赖 GPU、预训练模型或较高显存资源, 更适合高质量重建任务, 而不一定适合低功耗实时部署场景。

2.1.3 单目算法路线分析

从特征点法来看, MonoSLAM、PTAM 和 ORB-SLAM 等方法主要依靠角点或局部描述子建立帧间匹配关系, 与直接法和基于学习的方法相比, 特征点法的优势主要体现在实时定位、低算力部署和长期回环维护等场景中。该方法通常计算量较低, 系统结构成熟, 回环检测和重定位机制完善, 能够在 CPU 平台上稳定运行。因此, 在纹理较丰富、光照相对稳定、地图稠密程度要求不高, 但需要长期定位、实时运行和低成本部署的场景中, 更适合采用传统特征点法。

从直接法来看, DTAM、LSD-SLAM、SVO 和 DSO 等方法主要通过像素灰度、图像梯度或光度误差估计相机位姿。与特征点法相比, 直接法不需要完全依赖显式特征点和描述子匹配, 能够利用更多像素级信息; 与基于学习的

方法相比, 直接法仍保持较强的几何可解释性和相对轻量的计算框架。因此, 直接法的优势区间主要体现在局部精细跟踪、半稠密建图和高频视觉里程计等场景中。

从基于学习的方法来看, DeepVO、CNN-SLAM、DROID-SLAM、Nicer-SLAM、MonoGS、SLAM3R、MASt3R-SLAM 和 WildGS-SLAM 等方法通过神经网络学习位姿、深度、匹配关系或场景表达。与特征点法相比, 基于学习的方法能够利用数据驱动的特征、深度和稠密匹配能力, 提高复杂场景中的感知能力; 与直接法相比, 其优势不仅限于光度误差优化, 还可以进一步扩展到神经隐式地图、3D Gaussian 地图和高质量场景表达。因此, 基于学习的方法优势区间主要体现在弱纹理复杂场景、稠密匹配、高质量地图表达和真实感重建等任务中。

2.1.4 单目 vSLAM 算法局限

总体来看, 单目 vSLAM 的主要局限在于尺度不可观、弱纹理和长期漂移问题。传统几何方法实时性和工程部署能力较好, 但在动态场景、复杂光照和弱纹理环境中容易退化; 学习型和神经表示方法能够提升稠密匹配和地图表达能力, 但依赖训练数据、GPU 算力和较高显存资源。VIO 通过引入 IMU 缓解尺度漂移问题, 是单目系统提升长期运动估计稳定性的重要方案。

2.2 双目相机

2.2.1 双目相机特点

双目 vSLAM 算法通过配备两个固定位置的摄像头同步获取图像,利用左右图像视差恢复场景深度,估计相机运动轨迹并构建具有尺度信息的环境地图。

2.2.2 双目 vSLAM 代表算法

在双目 SLAM 算法中,特征点法的代表算法包括 S-PTAM^[38]、ORB-SLAM2、ORB-SLAM3 和 DynaSLAM。其中,ORB-SLAM2 利用 ORB 特征、词袋回环检测和 BA 优化实现了较高精度与鲁棒性,是经典双目 SLAM 系统;PL-SLAM^[39]通过融合点特征与线特征缓解低纹理场景中特征点不足的问题。

直接法双目 SLAM 利用双目固定基线获得真实尺度,

能够缓解单目直接法中的尺度漂移问题,在纹理梯度充足、光照稳定的场景中具有较高精度,但对曝光变化、光照不一致、运动模糊和动态物体较敏感,且多数方法缺少完整回环检测和长期地图维护能力。

基于学习的双目 SLAM 算法中,DynaSLAM 引入语义分割、多视图几何和背景修复机制,用于降低动态物体对跟踪和建图的影响,可支持主要双目和 RGB-D 相机,是学习型视觉 SLAM 的重要代表。

为比较双目完整 SLAM 系统在定位精度、尺度稳定性、系统完整性和实时部署方面的差异,表 3 对典型双目 SLAM 算法进行归纳。

表 3 双目完整 SLAM 指标评价表
Table 3 Stereo Full SLAM Metrics Evaluation Table

算法名称	位姿精度	尺度稳定性	系统完整性	实时性和部署情况
S-PTAM ^[38]	在 KITTI 数据集中,最大绝对定位误差 < 15 m	双目真实尺度,可以避免尺度漂移	KITTI 序列平均误差约 6%	CPU: Intel i7
ORB-SLAM2 ^[4] (双目配置)	KITTI: 0.2 到 10.4m EuRo: 0.018 到 0.119m TUM: 0.004 到 0.047m	相比单目系统,双目系统尺度可观性更强,通常不存在单目固有尺度模糊问题。	未明确报告	CPU: Intel i7 EuRoC: 相机 20Hz, 系统实时跟踪 KITTI: 相机 10Hz, 系统实时跟踪 TUM RGB-D: 相机 30Hz, 系统实时跟踪
ORB-SLAM3 ^[5]	在 Stereo-Inertial 序列中,平均 ATE 在 4cm	在 Stereo-Inertial 配置下系统具有较好的尺度可观性	支持回环检测与地图融合	CPU: Intel i7 系统可实时运行,约 30 - 40 FPS、3 - 6 keyframes/s 在 Stereo-Inertial 33.05 ms
DynaSLAM ^[28] (双目配置)	TUM 动态序列: 0.006 到 0.040m KITTI: 0.2 到 9.4m	双目配置可提供米制尺度,能够显著缓解单目尺度不确定问题。	未明确报告	GPU: NVIDIA Titan X Mask R-CNN 单帧: 195ms 无实时运行能力
DROID-SLAM ^[12]	在 EuRoC 数据集中平均 0.024m	未明确报告	通过稠密帧间关联和全局优化增强长序列一致性	系统需用 2 张 RTX 3090 GPU 可实时运行,需 TartanAir 合成数据的单目视频训练

从表 3 可以看出,双目完整 SLAM 的主要优势是通过固定基线恢复真实尺度,从而明显减轻单目系统的尺度不确定和尺度漂移问题。S-PTAM、ORB-SLAM2 和 ORB-SLAM3 等传统几何方法在实时性、系统完整性和工程部署方面较成熟,其中 ORB-SLAM3 通过多地图、地图融合和视觉惯性紧耦合机制,提高了系统在跟踪丢失、快速运动和短时纹理不足场景下的鲁棒性。DynaSLAM 和 DROID-SLAM 分别从动态目标处理和学习型稠密匹配角度提升系统性能,但前者依赖语义分割,后者依赖高性能 GPU,因此更适合对动态鲁棒性或精度上限要求较高的应用场景。

2.2.3 双目算法路线对比

双目相机算法的特征点法与直接法和基于学习的方法相比,其优势主要体现在尺度稳定、实时运行、系统完整和工程部署成熟等方面。由于双目相机能够通过固定基线提供真实尺度,特征点法在双目条件下可以有效减轻单目系统中的尺度漂移问题,同时保留传统几何 SLAM 计算量低、可解释性强和回环检测机制成熟的特点。

从直接法来看,双目直接法主要利用左右图像视差、像素灰度一致性和局部光度误差约束估计相机运动与场景结构。与特征点法相比,直接法能够更充分利用图像中的像素级信息;与基于学习的方法相比,直接法仍保持较强几何解释性和相对轻量的优化框架。因此,双目直接法的优势区间主要体现在局部精细跟踪、半稠密建图和短时

高精度运动估计等场景中。

从基于学习的方法来看,DynaSLAM 和 DROID-SLAM 分别代表了双目 SLAM 中语义增强和学习型稠密优化两类方向。DynaSLAM 在传统双目几何 SLAM 基础上引入语义分割和动态目标处理,更适合行人、车辆或可移动物体较多的动态场景;DROID-SLAM 则通过学习型稠密匹配、循环更新和可微优化提高位姿估计与深度恢复能力,更适合复杂纹理、弱纹理、快速运动和高精度稠密估计任务。与特征点法和直接法相比,基于学习的方法优势区间主要体现在复杂场景鲁棒匹配、动态环境处理、稠密深度估计和高精度轨迹优化等方面。

2.2.4 双目 vSLAM 算法局限

总体来看,双目完整 SLAM 方法可以分为三类发展路线。第一类是 S-PTAM、ORB-SLAM2 和 ORB-SLAM3 代表的传统几何特征点法,其优势是框架成熟、实时性好、可解释性强,适合机器人和移动平台部署。第二类是动态场景增强方法,其核心优势是能够剔除或修复动态物体影响,提高非静态环境中的鲁棒性,但计算代价较高。第三类是学习型稠密优化方法,其精度和匹配鲁棒性较强,但依赖高性能 GPU 和大规模训练数据,工程部署成本明显高于传统方法。

2.3 RGB-D 相机

2.3.1 RGB-D 相机特点

陈世浪等^[40]在 RGB-D 相机的 SLAM 技术研究综述中指出 RGB-D SLAM 算法结合了 RGB 相机和深度传感器, 以实现像素深度信息的直接测量, 从而简化了场景深度的获取过程。RGB-D 相机能够直接提供像素级深度观测, 在室内近距离场景中具有较好的适用性, 因此常用于室内机器人定位、三维重建和增强现实等任务。但 RGB-D 相机在户外易受阳光干扰, 测距范围和深度噪声也会影响建图稳定性。

2.3.2 RGB-D 相机 SLAM 算法对比

RGB-D 相机 SLAM 的特征点法以 RGB-D SLAM v2^[41]、ORB-SLAM2、ORB-SLAM3、DynaSLAM 和 SLAM++^[42]为代表, 主要利用 RGB 图像中的 ORB 等局部特征, 结合深度图提供的尺度信息, 通过 PnP、BA 优化、

ORB-SLAM2 在 TUM RGB-D 数据集上的平均 ATE-RMSE 约为 1.8 cm, 相比 RGB-D SLAM v2 精度较好, DynaSLAM 在 RGB-D 配置下在 TUM 数据集上的平均 ATE 约为 2 cm, 精度与 ORB-SLAM2 接近, DS-SLAM 在 TUM RGB-D 数据集上的平均 ATE 也约 2 cm, 定位精度略低于 ORB-SLAM2, 但通过语义分割剔除动态目标特征点, 提高了动态场景下的位姿估计稳定性, 虽然语义理解能够增强鲁棒性, 但会牺牲一部分实时性能。

总体来看, RGB-D 完整 SLAM 的发展重点已经不只是降低 ATE-RMSE, 而是在真实尺度、回环检测、动态场景鲁棒性和实时性之间取得平衡。RGB-D SLAM v2 体现了早期完整 RGB-D SLAM 框架; DynaSLAM 和 DS-SLAM 则进一步面向动态环境和语义理解扩展。其共同问题是地图表达仍以点云、关键帧或稀疏结构为主, 难以满足高质量稠密重建和真实感渲染需求。

2.3.3 RGB-D 相机下不同算法路线对比分析

从不同算法路线看, RGB-D 特征点法主要利用 RGB 图像特征和深度图三维坐标, 通过 PnP、BA、回环检测和位姿图优化完成定位与建图, 优势在于尺度稳定、实时性较好、系统完整度高, 适合室内机器人、仓储巡检和增强现实定位等任务。KinectFusion、ElasticFusion 等直接法或稠密几何法则利用深度图 ICP、光度—几何一致性约束、TSDF 或 Surfel 融合实现稠密建图, 适合室内三维重建和交互式建模。iMAP、Photo-SLAM、SplaTAM、RGBDGS-ICP-SLAM 和 OpenGS-SLAM 等学习型方法进一步引入神经隐式表示或 3DGS, 提高了地图细节表达、新视角合成和真实感渲染能力, 但对 GPU、显存和深度输入依赖较强, 工程部署成本较高。

回环检测和重定位机制完成位姿估计与地图构建。

直接法或稠密几何法以 KinectFusion^[43]、ElasticFusion^[44]为代表, 主要利用深度图 ICP 配准、光度—几何一致性约束以及 TSDF 体素或面元融合构建稠密三维地图。该类方法能够获得较完整的场景几何结构, 适合室内机器人、增强现实和三维重建等应用。

基于学习的算法以 iMAP、DS-SLAM、Photo-SLAM、SplaTAM、RGBDGS-ICP-SLAM 和 OpenGS-SLAM^[45]等为代表, 主要将神经隐式表示、神经点云或 3DGS 引入地图表达与位姿优化中, 使地图从传统点云、体素或面元扩展为可渲染、可优化的高保真连续场景表示。该类方法在稠密重建、细节表达和新视角渲染方面具有明显优势。

2.3.4 RGB-D 相机 SLAM 算法的局限性

总体来看, RGB-D SLAM 的优势在于能够直接获得真实尺度, 适合室内定位、三维重建和增强现实等任务; 其局限主要体现在测距范围、阳光干扰、深度噪声和户外适应性不足。传统稠密几何方法如 KinectFusion、ElasticFusion 具有较强实时性, 但地图表达和回环维护能力有限; iMAP、Photo-SLAM、SplaTAM 和 RGBDGS-ICP-SLAM 等神经隐式或 3DGS 方法提升了地图细节和渲染质量, 但依赖 GPU 和深度输入, 工程部署成本较高。

2.4 全景相机

2.4.1 全景相机特点

全景相机 vSLAM 的核心优势是通过大视场角图像覆盖更广阔的环境信息, 减少传统窄视场相机的视野盲区, 降低特征匹配失败和回环检测遗漏的概率。其算法重点解决全景图像畸变校正、大视场角下的运动估计以及全景地图拼接与一致性问题。

2.4.2 全景相机 SLAM 算法比较

特征点法是全景 SLAM 中应用较多的一类方法, 其核心思想是在全景图像中提取稳定特征点, 并结合球面投影模型、统一相机模型、多鱼眼标定模型或多相机外参约束完成位姿估计、稀疏建图和回环检测。PAN-SLAM^[46]、Fisheye-ORB-SLAM^[47]、OpenVSLAM^[48]等方法将 ORB 特征、关键帧管理、词袋回环检测、BA 优化和多相机约束扩展到鱼眼、全景或环视系统中, 提高了大视场条件下的跟踪稳定性、回环检测能力和长期运行鲁棒性。

直接法的代表方法包括 Omnidirectional DSO^[49]、360VO^[50]等。这类方法能够充分利用全景图像的大视场和连续像素信息, 在特征点不足、视野受限或相机快速旋转场景下具有一定优势。360VO 将 DSO 扩展到球面相机模型, 直接处理等距柱状全景图像, 无需先进行透视图像裁剪或校正。

基于学习的方法通过深度网络增强全景 SLAM 的特征提取、深度估计、深度补全、语义理解等能力。代表性

方法包括 360ORB-SLAM^[51]、HDPV-SLAM^[52]、MCVO^[53]、360DVO^[54]等。360ORB-SLAM 在 ORB-SLAM 框架基础上引入全景三角化和深度补全网络,以获得更稠密的全景深度并缓解尺度模糊与深度稀疏问题;MCVO 通过学习型特征提取与跟踪缓解多相机系统的数据处理压力,并利用多相机刚性约束改善尺度估计和鲁棒性;360DVO 则是

较新的深度学习型全景视觉里程计方法,引入畸变感知球面特征提取和可微分全向 BA。

全景相机通过扩大视场范围提高了环境覆盖能力,但也带来了畸变建模、尺度估计和计算负担等问题。表 4 对典型全景完整 SLAM 算法在位姿精度、尺度稳定性、系统完整性和实时部署方面进行比较。

表 4 全景相机完整 SLAM 指标评价表
Table 4 Complete SLAM Evaluation Table for Panoramic Cameras

算法名称	位姿精度	尺度稳定性	系统完整性	实时性和部署情况
Fisheye-ORB-SLAM ^[47]	文中为关键帧轨迹与真值轨迹估计对比图	在室内测试尺度漂移低于 0.1%,在大场景中低于 1.5%	未明确报告	测试平台在 Intel i5 跟踪线程平均耗时约 30 ms/frame
OpenVSLAM ^[48]	在 EuRoC 单目中测试 ATE 大多约 0.03 到 0.10 m	含有回环模块	未明确报告	测试平台在 Intel i7 跟踪线程平均耗时约 23 ms/frame
PAN-SLAM ^[46]	在 Kashiwa 中测试 ATE 平均 14cm	轨迹通过 7-DoF 相似变换对齐	在 Kashiwa 中测试回环召回率平均 4%	测试平台在 Intel i7 约 1 frame/s 处理 5 张 4000 × 2000 全景图
360ORB-SLAM ^[51]	在数据集中测试 ATE 平均 7 到 18cm	文中给出 Scale Factor 比例因子,越接近 1 尺度越准确,其测试平均在 1.11	支持回环模块	测试平台在 Intel i7

从表 4 可以看出,OpenVSLAM 在精度和实时性方面表现较均衡,其在 EuRoC 单目测试中的 ATE 大多为 3 到 10cm,跟踪线程平均耗时约 23ms,并且包含回环模块。Fisheye-ORB-SLAM 在室内测试中的尺度漂移低于 0.1%,在大场景中低于 1.5%,跟踪线程平均耗时约 30 ms,说明其具有较好的尺度稳定性和实时性。相比之下,PAN-SLAM 在 Kashiwa 数据集上的平均 ATE 为 14 cm,回环召回率仅 4%,且处理 5 张 4000 × 2000 全景图约为 1frame/s,说明多全景图像虽然扩大了视场覆盖范围,但也带来了显著计算负担。360ORB-SLAM 的 ATE 为 7 到 18cm, Scale Factor 平均为 1.11,存在一定尺度偏差,说明其通过全景三角化和深度补全改善了深度估计,但尺度稳定性和轨迹精度仍有提升空间。总体来看,完整全景 SLAM 的优势主要体现在大视场带来的跟踪稳定性和潜在回环可见性,但其瓶颈集中在畸变建模、尺度漂移、回环检测有效性和高分辨率全景图像带来的计算代价。

对于全景 VO/VIO 方法而言,其优势主要体现在大视场连续跟踪和快速旋转场景中的鲁棒性,但仍需面对尺度漂移、球面模型标定、图像畸变和高分辨率输入带来的计算负担。OmniDSO、360VO 等直接法具有较好的局部跟踪能力,MCVO 通过多相机刚性约束提升尺度稳定性,360DVO 等学习型方法则增强了全景深度和位姿联合估计能力,但实时性和泛化能力仍需进一步提高。

2.4.3 全景相机下不同算法路线对比分析

从特征点法来看,Fisheye-ORB-SLAM、OpenVSLAM、

PAN-SLAM 和 360ORB-SLAM 等方法主要将传统特征提取、特征匹配、关键帧管理、BA 优化和回环检测扩展到鱼眼、全景或多相机系统中。与直接法和基于学习的方法相比,全景特征点法的优势区间主要体现在大视场实时定位、长期回环检测和工程部署成熟性等方面。由于全景图像能够提供更大的视野范围,特征点法可以在相机快速旋转、视野遮挡或局部纹理不足时获得更多可匹配区域,从而提高跟踪连续性和回环候选场景的可见性。

从直接法来看,OmniDSO 和 360VO 等方法主要利用球面投影模型、全景图像灰度信息和局部光度误差约束完成相机位姿估计。与特征点法相比,全景直接法能够更充分利用大视场图像中的连续像素信息,不完全依赖显式特征点匹配;与基于学习的方法相比,其优化过程仍然以几何和光度约束为主,具有较强可解释性。因此,全景直接法的优势区间主要体现在大视场局部连续跟踪、球面光度优化和高频视觉里程计等任务中。

从基于学习的方法来看,360ORB-SLAM、HDPV-SLAM、MCVO 和 360DVO 等方法通过深度网络、学习型特征、深度补全、畸变感知特征提取或可微分全向 BA 增强全景 SLAM 性能。与特征点法相比,基于学习的方法能够利用网络学习全景图像中的深度、特征和结构先验,提高复杂场景下的匹配和建图能力;与直接法相比,其优势不仅体现在光度误差优化,还可以进一步扩展到全景深度估计、多相机约束建模和稠密几何恢复。因此,基于学习的全景 SLAM 方法优势区间主要体现在全景深度恢复、复杂场景匹配、多相机协同定位和稠密地图表达等方面。

2.4.4 全景相机 SLAM 算法的局限性

总的来看,全景相机 SLAM 的优势主要体现在大视场带来的跟踪鲁棒性和场景覆盖能力,适合大范围、强转

向、视野遮挡频繁的应用场景；其不足则集中在畸变建模复杂、尺度漂移控制困难、回环检测稳定性不足以及高分辨率图像带来的计算代价。当前较成熟的传统特征点方法更适合实时定位与工程部署，而学习型的全景方法在深度恢复和复杂场景适应性方面具有潜力，但仍需要在实时性、泛化能力和系统完整性方面进一步提升。

2.5 事件相机

2.5.1 事件相机特点

事件相机异步监测像素亮度变化，并仅在亮度变化超




图1 事件相机示意图

Fig.1 Schematic diagram of event camera

2.5.2 事件相机 SLAM 算法对比

事件相机的特征点法原理为从事件流中提取角点、线特征、事件轨迹或时间表面特征，并通过特征跟踪、匹配和几何约束完成相机运动估计。Mueggler 等提出的高速 6-DoF 事件位姿跟踪^[56]方法较早证明了事件相机在高速运动估计中的可行性；Kueng 等^[57]利用事件特征轨迹实现低延迟视觉里程计，体现了事件特征跟踪在 VO 中的应用价值；Event-based Line SLAM^[58]通过事件线特征增强结构化场景中的跟踪能力，是事件线特征 SLAM 的典型方法；ES-PTAM^[59]则将事件相机 SLAM 扩展到双目事件并行跟踪与建图框架，体现了事件特征法从单目跟踪向双目建图系统的发展。PL-EVIO^[60]通过融合事件点特征、线特征和 IMU 约束实现鲁棒单目事件 VIO；ESVIO^[61]将双目事件观测与 IMU 约束结合，以提高尺度稳定性；Ultimate SLAM^[62]则将事件、普通图像和 IMU 进行紧耦合融合，体现了事件相机与帧式相机、惯性传感器协同提升高速运动和高动态范围场景鲁棒性的典型思路。

事件相机的直接法不依赖显式特征匹配，而是通过事件对齐误差、时间表面误差、亮度增量误差或事件生成模型估计相机位姿。连续时间轨迹估计方法^[63]利用事件流异步输出特点，将相机运动表示为连续时间曲线，为事件相

机后端优化提供了重要思路；Gallego 等^[64]提出的基于光度深度图的事件相机 6-DoF 跟踪方法，体现了事件观测与场景结构约束结合的可行性；Kim 等^[65]实现了仅依靠事件相机的实时三维重建与 6-DoF 跟踪；EVO^[66]、ESVO^[67]和 EDS^[68]则分别代表了纯事件几何对齐、双目事件直接法和事件辅助直接稀疏里程计等方向。

从基于学习的方法来看，DEVO^[69]、DEIO^[70]、EN-SLAM 和 EventVLAD^[71]等方法分别代表了学习型事件 VO、事件惯性里程计、神经隐式地图表达和事件地点识别等方向。其中 DEVO 利用深度网络从事件流中学习运动和深度信息，代表了学习型事件视觉里程计方向；DEIO 进一步将学习型事件特征与惯性约束结合，提高事件 VIO 的状态估计能力；EN-SLAM 将事件、RGB-D 和神经隐式场景表示结合，体现了事件相机 SLAM 向多模态神经地图表达发展的趋势；EventVLAD 是一种事件地点识别方法，说明学习特征也可以用于事件相机回环检测和长期地图维护。

上述完整事件 SLAM 方法，如 EVO、Event-based Line SLAM 和 ES-PTAM 等，体现了事件相机在低延迟和高速运动估计中的优势，但其回环检测、长期全局一致性和复杂场景稳定性仍有待提升。与完整事件 SLAM 相比，事件

机后端优化提供了重要思路；Gallego 等^[64]提出的基于光度深度图的事件相机 6-DoF 跟踪方法，体现了事件观测与场景结构约束结合的可行性；Kim 等^[65]实现了仅依靠事件相机的实时三维重建与 6-DoF 跟踪；EVO^[66]、ESVO^[67]和 EDS^[68]则分别代表了纯事件几何对齐、双目事件直接法和事件辅助直接稀疏里程计等方向。

上述完整事件 SLAM 方法，如 EVO、Event-based Line SLAM 和 ES-PTAM 等，体现了事件相机在低延迟和高速运动估计中的优势，但其回环检测、长期全局一致性和复杂场景稳定性仍有待提升。与完整事件 SLAM 相比，事件

VO/VIO 方法更关注短时连续状态估计,其评价重点包括轨迹误差、尺度稳定性、漂移率、初始化与标定依赖和资源占用。表 5 对典型事件 VO/VIO 方法进行比较。

从事件 VO、VIO 类算法来看,EDS 在 RPG Stereo DAVIS 数据集上的平均 ATE 约为 1.5 cm,定位精度较高,但其不严格实时,且需要单目初始化和人为设定初始深度范围。ESVO 的 ATE 为 2 到 14 cm,最低误差可达到 2 cm,但误差上限较高,说明其在不同序列中的稳定性仍

有限。ESVIO 的单目事件版本误差为 15 到 45 cm,而双目版本降低至 5 到 10 cm,表明双目事件相机和 IMU 对尺度恢复与稳定跟踪具有重要作用。DEVO 通过深度学习维持尺度,在 MVSEC 数据集上的 ATE 为 4 到 10 cm,其漂移率优于 ESVIO 和 DEIO,但需要 GPU 辅助计算且实时性不佳。DEIO 虽然精度低于 DEVO,但无需 GPU,可在消费级 CPU 上达到 50 FPS 实时运行,体现了较好的工程实时性。

表 5 事件 VO/VIO 指标评价表

Table 5 Event VO/VIO Index Evaluation Form

算法名称	绝对轨迹误差	尺度漂移	漂移率	初始化与标定依赖	资源占用
PL- EVIO ^[60]	在 UZH-FPV 数据集中平均误差 0.70%/m 在 DAVIS240C 数据集中平均误差 0.24%/m。	算法融合 IMU,系统具备公制尺度估计能力	系统支持事件角点描述子的回环检测	需要事件相机、普通图像相机和 IMU 的标定与时间同步。	测试平台在 Intel i7 算法可实时运行
ESVIO ^[61]	在 MVSEC 数据集中,单目事件通常在 15cm 到 45cm,双目为 5 到 10cm	不存在严重的尺度随机漂移	漂移率维持在总路径长度的 1.5%	初始化要求设备进行非等速直线运动,通过 IMU 的激励来解算尺度因子、重力方向和 IMU 偏置。 对标定依赖高。	在 i7 的 CPU 上可 30-50FPS 实时运行
ESVO ^[67]	测试 ATE 在 2 到 14cm 之间	作为双目事件相机系统,尺度主要由双目标定基线提供	未明确报告	未明确报告	测试平台在 Intel i7 算法可实时运行
EDS ^[68]	在 RPG Stereo DAVIS 数据集上的 ATE 平均在 1.5cm	未明确报告	无显式回环	需要单目初始化和人为设定初始深度范围	不严格实时,约 60 FPS 的自适应事件帧率,普通灰度帧为 20 FPS
DEVO ^[69]	在 MVSEC 数据集中:平均 4 到 10cm 之间	通过学习深度辅助尺度维持。	漂移率通常低于总路程的 1.2%	初始化要求只要足够的事件流产生就能迅速收敛并产生位姿,在标定方面,由于深度学习模型容错,可以允许轻微畸变。	需 RTX 3080 及以 GPU,显存不少于 4 GB,可维持 15 至 20 FPS 运行。
DEIO ^[70]	在 MVSEC 数据集中:平均 5 到 15cm 之间	在初始化成功后,其尺度表现稳定	漂移率约为总路径长度的 1.5%。	初始化要求设备进行非等速直线运动,通过 IMU 的激励来解算尺度。对标定依赖高。	无需 GPU,在笔记本 i5CPU 可以 50FPS 实时运行

2.5.3 事件相机算法路线对比

从特征点法来看,Mueggler 等的高速 6-DoF 事件位姿跟踪、Kueng 等的事件特征轨迹视觉里程计、Event-based Line SLAM 和 ES-PTAM 等方法主要从事件流中提取角点、线特征、事件轨迹或局部结构特征,并通过特征跟踪、几何匹配和位姿估计完成定位与建图。与直接法和基于学习的方法相比,事件特征点法的优势区间主要体现在结构化场景、高速运动跟踪、低延迟视觉里程计和轻量化几何估计等方面。该类方法能够将传统 SLAM 中的特征匹配、几何约束和并行跟踪建图思想迁移到事件数据中,具有较强的可解释性和实时性。

从直接法来看,连续时间轨迹估计、Gallego 等的事件 6-DoF 跟踪方法、Kim 等的实时事件三维重建、EVO、ESVO 和 EDS 等方法主要利用事件对齐误差、时间表面、亮度增量误差或事件生成模型估计相机运动。与特征点法相比,直接法不完全依赖离散事件特征提取和匹配,而是

能够更充分利用事件流中的时空连续变化信息;与基于学习的方法相比,直接法仍以几何模型和优化误差为核心,具有较强的物理解释性。因此,事件直接法的优势区间主要体现在高速运动、强光照变化、运动模糊抑制、局部高频跟踪和半稠密三维重建等任务中。

从基于学习的方法来看 DEVO、DEIO、EN-SLAM 和 EventVLAD 等方法主要利用神经网络学习事件表示、运动信息、深度信息、地点识别特征或神经地图表达。与特征点法相比,基于学习的方法能够从事件流中学习更加鲁棒的时空特征和深度先验;与直接法相比,其优势不仅体现在局部事件对齐,还可以扩展到事件表示学习、复杂运动估计、事件惯性融合、神经隐式地图和地点识别等方面。

2.5.4 事件相机 SLAM 后端优化

事件相机 SLAM 的后端优化与传统帧式 vSLAM 存在明显差异。传统 vSLAM 通常以图像帧为基本单位,通过重投影误差、光度误差、PnP、BA 或位姿图优化降低累

计误差；而事件相机输出的是异步、稀疏且由亮度变化触发的事件流，因此其后端优化需要围绕事件时间、事件空间分布、事件对齐关系和连续运动模型重新构建优化目标。

从连续时间轨迹优化来看，Mueggler 等提出的连续时间轨迹估计方法利用事件流异步输出的特点，将相机运动表示为连续时间曲线，并通过事件观测约束轨迹参数。这类方法的代表意义在于，它不再强制把事件流转换为固定帧，而是从时间连续性的角度建模相机运动，能够更好地适应事件相机高时间分辨率和异步触发的传感器特性。因此，连续时间轨迹优化是事件相机后端优化区别于传统帧式 SLAM 的重要方向。

从事件直接对齐优化来看，EVO、ESVO 和 EDS 等方法主要通过事件边缘、时间表面、亮度增量误差或事件生成模型构建优化目标。EVO 利用事件边缘与局部地图投影之间的几何对齐实现位姿估计；ESVO 通过双目事件时间表面进行直接对齐，并结合深度估计实现局部建图；EDS 则将事件生成模型与直接稀疏里程计结合，利用事件补充普通图像帧之间的运动信息。这类方法的优势在于能够充分利用事件数据的低延迟和高时间分辨率特性，适合高速运动、运动模糊和强光照变化场景中的局部位姿优化。

从事件和惯性紧耦合优化来看，PL-EVIO、ESVIO、DEIO 等方法将事件观测与 IMU 预积分约束加入滑动窗口或因因子图优化框架中，联合估计相机位姿、速度、IMU 偏置和尺度等状态量。与纯事件方法相比，事件惯性融合能够利用 IMU 提供的高频运动先验，缓解事件流稀疏、短时约束不足和尺度不稳定等问题。因此，该类方法更适合无人机、高速机器人和强光照变化环境中的连续状态估计任务。但事件惯性后端也对时间同步、外参标定、IMU 初始化和噪声建模提出了更高要求。

学习增强方法则将事件特征、深度估计或神经隐式地图引入后端优化。DEVO、DEIO 和 EN-SLAM 等方法分别从学习型事件运动估计、事件惯性融合和神经地图表达角度增强系统鲁棒性，但通常需要 GPU、多模态输入或预训练模型支持。

2.5.5 事件相机 SLAM 回环检测

事件相机 SLAM 的后端优化与传统帧式 vSLAM 存在明显差异。传统 vSLAM 通常以图像帧为基本单位，通过重投影误差、光度误差、PnP、BA 或位姿图优化降低累计误差；事件相机输出的是异步、稀疏且由亮度变化触发的事件流，因此其后端优化需要围绕事件时间、空间分布、事件对齐关系和连续运动模型重新构建优化目标。

从事件累积图像路线来看，LATIFY 等^[72]较早尝试将事件流在一定时间窗口内累积为类图像表示，结合拓扑地图的思想进行地点识别。这类方法证明了事件数据可以用于视觉地点识别和回环检测，但其性能容易受事件累积窗口、相机运动速度和场景边缘结构变化的影响。

从多时间窗口事件表征路线来看，Fischer^[73]等进一步研究了不同时间窗口组合对事件视觉地点识别的影响。该

类方法的代表意义在于，它指出事件地点识别不能简单沿用固定帧图像的处理方式，而需要根据事件流密度、运动速度和场景结构选择合适的时间窗口或多尺度事件表示。多时间窗口方法能够在一定程度上缓解单一事件图像不稳定的问题，提高事件地点识别对速度变化和事件稀疏性的适应能力。

从学习型事件地点识别路线来看，EventVLAD 等方法将事件流重建为边缘图像，并借鉴传统视觉地点识别中的 VLAD 特征聚合思想，实现事件相机地点识别。与简单事件累积图像相比，学习型或特征聚合方法能够提取更稳定的事件场景描述，提高跨时间、跨速度和跨视角条件下的匹配能力。近期将回环检测引入事件 SLAM 的研究也说明，事件相机回环检测正在从单独的地点识别任务，逐步向完整 SLAM 系统中的全局一致性维护模块发展。

3 不同算法与传感器条件下的共性问题分析

vSLAM 算法虽然已在机器人导航、自动驾驶和三维重建等任务中取得较多进展，但在实际应用中仍面临位姿漂移、动态环境干扰、光照变化、弱纹理退化、实时部署受限和跨场景泛化不足等共性问题。不同算法路线对这些问题的敏感性不同：特征点法通常依赖稳定特征匹配和回环优化，直接法依赖光度一致性和图像梯度，基于学习的方法则依赖训练数据、模型泛化能力和计算资源。因此，有必要从共性问题角度分析不同方法在实际应用中的局限。

3.1 位姿漂移与全局一致性

位姿漂移主要出现在缺少有效回环检测、全局优化或绝对尺度约束的算法中。对于单目 SLAM 和单目 VO 而言，尺度不可观是造成长期漂移的重要原因。MonoSLAM、PTAM、SVO、DSO 等方法虽然能够完成实时位姿估计，但在长时间运行中容易产生尺度漂移和累计误差，尤其是 SVO、DSO 等偏视觉里程计的方法，通常缺少完整回环检测和全局地图优化机制。

ORB-SLAM 等特征点法通过关键帧管理、词袋回环检测、局部 BA 和位姿图优化缓解累计漂移，但在重复纹理、外观变化或特征匹配不稳定时仍可能出现回环误检或漏检。LSD-SLAM 通过 Sim3 图优化处理单目尺度漂移，但其前端仍依赖光度一致性。DROID-SLAM、MASt3R-SLAM 等学习型方法利用稠密匹配和可微优化提高轨迹估计能力，但全局一致性仍受帧间关联质量、算力资源和跨场景泛化能力影响。因此，位姿漂移问题本质上反映了局部估计、尺度约束和全局优化之间的平衡关系。

3.2 动态环境干扰

动态环境问题主要影响依赖静态场景假设的 vSLAM 算法。ORB-SLAM、PTAM、LSD-SLAM、DSO 等传统几何方法通常默认大多数观测点来自静态环境。当行人、车辆、机械臂或其他移动物体占据图像较大区域时，系统可能将动态区域中的特征点或像素误差错误用于位姿估计，从而导致轨迹偏移、地图污染甚至跟踪失败。

DynaSLAM、DS-SLAM 等方法通过语义分割、动态目标检测或特征剔除减少动态物体影响,但这类方法依赖分割精度,误检和漏检可能导致有效静态特征被删除或动态特征被保留。同时,语义分割和动态建模会增加计算开销,降低实时性。神经隐式表示和 3DGS 类方法虽然可以进一步处理动态场景表达问题,但通常需要 GPU 支持,长时间在线建图和地图维护仍较困难。因此,动态环境问题的关键在于如何在动态目标识别、静态结构保持和实时计算之间取得平衡。

3.3 光照变化与光度一致性

光照变化对直接法和半直接法影响最明显。DTAM、LSD-SLAM、SVO、DSO 以及部分全景和事件相机直接法都在不同程度上依赖灰度、光度误差或事件对齐误差。当环境中出现曝光变化、强光、阴影、反光表面或运动模糊时,图像灰度不再满足稳定的光度一致性假设,容易造成残差异常、优化不收敛或错误收敛。

DSO 等方法通过光度标定、曝光补偿和仿射亮度模型缓解光照变化影响,但仍要求较好的相机光度标定。3DGS 类方法可在渲染和跟踪过程中引入亮度修正机制,但计算资源需求较高。事件相机利用亮度变化事件而非传统帧图像,在高动态范围和快速光照变化场景中具有优势,但其事件流也会受到噪声、运动方式和触发阈值影响。因此,光照变化问题仍是视觉 SLAM 跨环境应用中的重要退化因素。

3.4 弱纹理问题

弱纹理问题主要影响依赖角点、边缘或局部描述子的特征点法。MonoSLAM、PTAM、ORB-SLAM、S-PTAM 和 Fisheye-ORB-SLAM 等方法需要提取足够数量且分布均匀的稳定特征。当场景中存在白墙、走廊、地面、矿区巷道、天空、水面或重复纹理结构时,可用特征数量减少,容易导致初始化失败、匹配不足、误匹配增加或跟踪丢失。

直接法能够利用像素灰度和图像梯度信息,在一定程度上缓解稀疏特征不足的问题,但当场景大面积纹理平坦或光照剧烈变化时,光度约束同样会变弱。学习型方法通过稠密匹配、学习式光流或点图预测提高弱纹理场景的数据关联能力,但依赖训练数据和 GPU 资源。视觉惯性融合、RGB-D、事件相机和点线特征融合等方法可以为弱纹理环境提供额外几何或运动约束,是缓解该问题的重要方向。

3.5 实时性、算力限制与资源消耗

实时性与算力资源消耗是 vSLAM 从实验验证走向工程应用时必须面对的重要问题。传统几何 SLAM 通常采用稀疏特征、关键帧筛选、滑动窗口优化和多线程结构,能够在 CPU 平台上实现较好的实时性,因此更适合低成本、低功耗机器人和嵌入式平台部署。

相比之下,学习型 SLAM、语义动态 SLAM、神经隐式 SLAM 和 3DGS-SLAM 通常需要更高计算资源。语义动态 SLAM 需要引入目标检测或语义分割网络;DROID-SLAM、MASt3R-SLAM、SLAM3R 等方法依赖稠密匹配、

循环更新或可微优化;Nicer-SLAM、iMAP、MonoGS、Photo-SLAM 等方法虽然提升了稠密建图和真实感表达能力,但地图优化和渲染计算通常需要 GPU 和较高显存。因此,实时性与算力消耗问题反映了 vSLAM 在定位精度、地图质量、算法复杂度和硬件资源之间的矛盾。SLAM 系统评价不应只关注轨迹精度,还应综合考虑运行时间、内存占用和能耗等工程指标。

3.6 环境泛化能力与跨场景鲁棒性

许多 vSLAM 算法在特定数据集或受控实验环境中能够取得较高精度,但在真实复杂环境中容易受到光照、天气、弱纹理、动态目标、传感器噪声和相机模型差异等因素影响。长期定位与 vSLAM 评价研究表明,昼夜、天气和季节变化会显著影响视觉定位系统的稳定性。

从不同算法路线看,特征点法的鲁棒性受场景纹理质量和特征分布影响较大;直接法依赖光度一致性,在曝光变化、阴影、强反光和非朗伯表面条件下容易退化;基于学习的方法虽然提高了复杂场景下的精度上限,但当测试环境与训练数据差异较大时,可能出现深度预测偏差、特征匹配不稳定和位姿漂移增大等问题。因此,环境泛化能力不足并不是某一类算法独有的问题,而是 vSLAM 从受控数据集走向真实复杂环境时普遍面临的共性难点。提高跨场景鲁棒性需从前端特征、光度建模、学习匹配、传感器融合和长期地图更新等多个层面共同改进。

4 未来解决方向与发展趋势

4.1 多传感器融合 SLAM

在面对上述提到的问题时,单一视觉传感器通常只能从某一方面缓解上述问题,而多传感器融合 vSLAM 可以利用不同传感器之间的互补观测,从尺度约束、光照鲁棒性等方面提高系统鲁棒性。任泽裕等^[74]对多模态数据融合进行了综述,指出多模态融合的核心在于整合不同来源和不同形式的信息,通过不同模态之间的互补性提高系统对复杂环境的感知能力。

从融合方式看,视觉惯性融合主要利用 IMU 提供的高频角速度、加速度和重力方向信息,补充视觉在短时运动预测和尺度估计方面的不足,代表方法包括 VINS-Mono 和 ORB-SLAM3 等;视觉—深度融合利用 RGB-D、双目或 LiDAR 提供的几何尺度约束,能够缓解单目尺度不确定和弱纹理场景下的深度估计困难;视觉—事件融合利用事件相机高动态范围、低延迟和对亮度变化敏感的特点,适合高速运动、强光照变化和运动模糊场景;视觉—语义融合则通过动态目标检测、语义分割和场景理解降低动态物体对定位和建图的影响。

从应用角度看,多传感器融合并不意味着传感器数量越多越好,而应根据任务退化类型选择互补性强、计算代价可接受的组合。对于低功耗移动机器人,轻量级视觉惯性融合和 RGB-D 融合更适合实时部署;对于高速运动或高动态范围场景,事件相机与 IMU、普通图像融合更具优势;对于低照度、水下、烟尘或弱纹理环境,则可结合热

红外、声学、LiDAR 或深度传感器增强观测约束。因此,未来多传感器融合 SLAM 的发展重点应从单纯叠加传感器转向任务驱动的传感器选择、紧耦合状态估计和轻量化在线优化。

4.2 新型视觉传感器与多模态融合感知

随着 vSLAM 应用场景从室内静态环境扩展到矿区巡检、自动驾驶、水下探测和人机交互等复杂任务,单一视觉传感器在光照变化、动态遮挡、弱纹理、低能见度和长期运行等场景中容易出现退化。因此,新型视觉传感器与多模态融合感知逐渐成为提高 SLAM 系统鲁棒性的重要方向。其核心不是简单增加传感器数量,而是根据环境退化类型选择互补观测,使 RGB 图像、IMU、RGB-D、LiDAR、事件相机、红外热成像相机、声学传感器和语义网络分别从纹理、运动、深度、几何结构、亮度变化、热辐射、声源方向和目标类别等角度为 SLAM 系统提供约束。




图2 声纹相机示意图

Fig.2 Schematic diagram of the voiceprint camera

从多模态融合的角度来看,声学 SLAM 主要包括三类作用:第一,声源定位与视觉融合,可为动态目标、人机交互和遮挡目标提供方位或位置约束;第二,声学里程计、IMU 与视觉融合,可在水下低能见度、光照不足和纹理缺失环境中补充运动与尺度约束,提高位姿估计稳定性;第三,声学相机与 SLAM 结合,可在传统视觉图像退化甚至不可用时提供局部结构观测,用于水下局部稠密地图构建。因此,声学模态在 vSLAM 中的主要价值体现在为视觉系统提供额外空间约束和退化场景补偿。

4.2.2 热红外相机与低光照 SLAM

红外热成像仪通过检测物体发出的红外辐射生成热图像,对可见光依赖较低,因此可用于夜间、低照度、烟尘和复杂照明场景下的 SLAM。Vidas 等^[81]提出了单目红外热成像 SLAM 方法,Chen W 等^[82]将红外相机与 LiDAR 结合以缓解多尘、低纹理和黑暗环境下的视觉退化问题,Buemi 等^[83]将 ORB-SLAM 与红外图像和光流数据结合,Chen X 等^[84]指出 RGB-D 与热红外融合有助于提升复杂照明条件下的视觉感知能力,李程远等^[85]则将深度相机、ORB-SLAM2 和红外热像仪结合,用于巡检机器人自主定位与故障检测。

热红外模态的主要价值在于为低照度、复杂照明和可见光退化环境提供跨模态补充观测。一方面,热红外相机

4.2.1 声纹相机与声学 SLAM

声纹相机、声学相机等跨模态感知设备可以通过声源方向、声源位置和声学里程计为 SLAM 系统提供视觉以外的空间约束。与 RGB 相机主要依赖纹理和光照信息不同,声学模态对光照和低能见度环境不敏感,因此适合与 RGB 相机、IMU、DVL 或深度传感器融合,用于缓解动态目标干扰、水下低能见度和弱纹理等问题。

Zhang T 等^[75]将声源定位与 vSLAM 结合,用于减少动态障碍物对机器人定位与建图的影响;Michaud 等^[76]通过移动麦克风阵列与视觉 SLAM 结合,实现声源三维定位和地图构建;Chau 等^[77]将单目视觉和麦克风阵列结合,用于室内人机交互中的人体跟踪与 SLAM;Vargas 等^[78]、Wang 等^[79]以及 Xu 等^[80]则面向水下场景,将声学里程计、声学相机、DVL、视觉和 IMU 信息融合,以提高低能见度和弱纹理环境下的状态估计鲁棒性。

与 RGB 相机融合,可在低光照、强光照变化和烟尘环境中补充目标轮廓与热辐射信息,从而提高前端跟踪稳定性;另一方面,热红外相机与 LiDAR、深度相机或 IMU 融合,可在低纹理、黑暗和特殊巡检场景中补充几何、深度和运动约束。但热红外图像通常分辨率较低、纹理细节不足,并受目标热对比度、环境温度和传感器噪声影响,因此仍需与可见光、深度或惯性信息配合使用。

5 总结

近年来,随着深度学习、神经隐式表示和人工智能技术的发展,vSLAM 从早期以几何约束为核心的定位与建图,发展到融合语义理解、场景理解与自主决策的综合智能体系。但几何方法并未被学习方法完全取代,而是与学习方法融合,共同推动 SLAM 发展,使其不再只是独立的前端定位模块,而是演化为支撑机器人导航、感知与交互的基础。

从发展趋势上看,未来 SLAM 的研究重点将集中在以下几个方向:其一,机器学习、神经隐式表示和开放世界语义理解的持续融合,基于神经隐式表示提升地图的表达能力,通过开放词汇识别、语义先验和持续学习等方式,使 SLAM 系统逐步从封闭集语义理解走向开放世界语义感知,使其具备对未知物体、动态语义和复杂场景的持续认知能力;其二,新型传感器与传统视觉传感器的融合,

以开发在高速运动、动态环境和复杂光照条件下更高鲁棒性的传感器；其三，发展多传感器融合框架，通过联合视觉、IMU、LiDAR、深度和其他新型传感器，提升系统在动态环境、退化场景和长时运行等条件下的可靠性。

总的来说，未来 vSLAM 的发展方向并不仅仅是追求更高的定位精度，而是朝着几何、语义、导航以及任务决策融合的统一框架发展，最终推动未来的机器人系统向智能化、实时化、长期自主化和多模态协同化迈进。

参考文献

- [1] LEONARD J J, DURRANT-WHYTE H F. Simultaneous map building and localization for an autonomous mobile robot[C]//Proceedings of the 1991 IEEE/RSJ International Workshop on Intelligent Robots and Systems (IROS '91). Osaka, Japan: IEEE, 1991: 1442-1447.
- [2] KLEIN G, MURRAY D. Parallel tracking and mapping for small AR workspaces[C]//2007 6th IEEE and ACM International Symposium on Mixed and Augmented Reality. Los Alamitos, CA: IEEE Computer Society, 2007: 225-234.
- [3] MUR-ARTAL R, MONTIEL J M M, TARDOS J D. ORB-SLAM: A versatile and accurate monocular SLAM system[J]. IEEE Transactions on Robotics, 2015, 31(5): 1147-1163.
- [4] MUR-ARTAL R, TARDÓS J D. ORB-SLAM2: An open-source SLAM system for monocular, stereo, and RGB-D cameras[J]. IEEE Transactions on Robotics, 2017, 33(5): 1255-1262.
- [5] CAMPOS C, ELVIRA R, RODRÍGUEZ J J G, et al. ORB-SLAM3: An accurate open-source library for visual, visual inertial, and multi map slam[J]. IEEE Transactions on Robotics, 2021, 37(6): 1874-1890.
- [6] NEWCOMBE R A, LOVEGROVE S J, DAVISON A J. DTAM: Dense tracking and mapping in real-time[C]//2011 International Conference on Computer Vision (ICCV). Barcelona, Spain: IEEE, 2011: 2320-2327.
- [7] ENGEL J, SCHÖPS T, CREMERS D. LSD-SLAM: Large-scale direct monocular SLAM[C]//European Conference on Computer Vision. Cham: Springer International Publishing, 2014: 834-849.
- [8] FORSTER C, PIZZOLI M, SCARAMUZZA D. SVO: Fast semi-direct monocular visual odometry[C]//2014 IEEE International Conference on Robotics and Automation (ICRA). Hong Kong, China: IEEE, 2014: 15-22.
- [9] ENGEL J, KOLTUN V, CREMERS D. Direct sparse odometry[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 40(3): 611-625.
- [10] WANG S, CLARK R, WEN H, et al. DeepVO: Towards end-to-end visual odometry with deep recurrent convolutional neural networks[C]//2017 IEEE International Conference on Robotics and Automation (ICRA). Singapore: IEEE, 2017: 2043-2050.
- [11] TATENO K, TOMBARI F, LAINA I, et al. CNN-SLAM: Real-time dense monocular SLAM with learned depth prediction[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Los Alamitos, CA: IEEE Computer Society, 2017: 6243-6252.
- [12] TEED Z, DENG J. DROID-SLAM: Deep visual SLAM for monocular, stereo, and RGB-D cameras[C]//Proceedings of the 34th International Conference on Neural Information Processing Systems. La Jolla, CA: Curran Associates, Inc., 2021: 16558-16569.
- [13] ZHU Z, PENG S, LARSSON V, et al. Nicer-SLAM: Neural implicit scene encoding for RGB SLAM[C]//2024 International Conference on 3D Vision (3DV). Piscataway, NJ: IEEE, 2024: 42-52.
- [14] MATSUKI H, MURAI R, KELLY P H J, et al. Gaussian splatting SLAM[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE, 2024: 18039-18048.
- [15] HUANG H, LI L, CHENG H, et al. Photo-SLAM: Real-time simultaneous localization and photorealistic mapping for monocular, stereo and RGB-D cameras[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE, 2024: 21584-21593.
- [16] MURAI R, DEXHEIMER E, DAVISON A J. MAST3R-SLAM: Real-time dense SLAM with 3D reconstruction priors[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Nashville, TN, USA: Computer Vision Foundation (CVF), 2025: 16695-16705.
- [17] KERBL B, KOPANAS G, LEIMKÜHLER T, et al. 3D Gaussian splatting for real-time radiance field rendering[J]. ACM

- Transactions on Graphics, 2023, 42(4): 139:1-139:14.
- [18] CUMMINS M, NEWMAN P. FAB-MAP: Probabilistic localization and mapping in the space of appearance[J]. The International Journal of Robotics Research, 2008, 27(6): 647-665.
- [19] GÁLVEZ-LÓPEZ D, TARDOS J D. Bags of binary words for fast place recognition in image sequences[J]. IEEE Transactions on Robotics, 2012, 28(5): 1188-1197.
- [20] KÜMMERLE R, GRISETTI G, STRASDAT H, et al. g2o: A general framework for graph optimization[C]//2011 IEEE International Conference on Robotics and Automation (ICRA). Shanghai, China: IEEE, 2011: 3607-3613.
- [21] AGARWAL S, MIERLE K. Ceres solver: Tutorial & reference[EB/OL]. Mountain View: Google Inc., 2012(2023-10-15)[2026-03-17]. <https://ceres-solver.readthedocs.io/latest/tutorial.html>.
- [22] KALMAN R E. A new approach to linear filtering and prediction problems[J]. Journal of Basic Engineering, 1960, 82(1): 35-45.
- [23] HO T S, FAI Y C, MING E S L. Simultaneous localization and mapping survey based on filtering techniques[C]//2015 10th Asian Control Conference (ASCC). Kota Kinabalu, Malaysia: IEEE, 2015: 1-6.
- [24] MUR-ARTAL R, TARDÓS J D. Fast relocalisation and loop closing in keyframe-based SLAM[C]//2014 IEEE International Conference on Robotics and Automation (ICRA). Hong Kong, China: IEEE, 2014: 846-853.
- [25] KENDALL A, GRIMES M, CIPOLLA R. PoseNet: A convolutional network for real-time 6-DOF camera relocalization[C]//Proceedings of the IEEE International Conference on Computer Vision. Los Alamitos, CA: IEEE Computer Society, 2015: 2938-2946.
- [26] LIU Y, DONG S, WANG S, et al. SLAM3R: Real-time dense scene reconstruction from monocular rgb videos[C]//Proceedings of the Computer Vision and Pattern Recognition Conference. [S.l.]: IEEE, 2025: 16651-16662.
- [27] YU C, LIU Z, LIU X J, et al. DS-SLAM: A semantic visual SLAM towards dynamic environments[C]//2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). Piscataway, NJ: IEEE, 2018: 1168-1174.
- [28] BESCOS B, FÁCIL J M, CIVERA J, et al. DynaSLAM: Tracking, mapping, and inpainting in dynamic scenes[J]. IEEE Robotics and Automation Letters, 2018, 3(4): 4076-4083.
- [29] LI M, GUO Z, DENG T, et al. DDN-SLAM: Real time dense dynamic neural implicit SLAM[J]. IEEE Robotics and Automation Letters, 2025, 10(5): 4300-4307.
- [30] SUCAR E, LIU S, ORTIZ J, et al. iMAP: Implicit mapping and positioning in real-time[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. Piscataway, NJ: IEEE, 2021: 6229-6238.
- [31] QU D, YAN C, WANG D, et al. Implicit event-RGBD neural SLAM[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE, 2024: 19584-19594.
- [32] KEETHA N, KARHADE J, JATAVALLABHULA K M, et al. SplatAM: Splat track & map 3d gaussians for dense rgb-d slam[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, WA, USA: Computer Vision Foundation (CVF), 2024: 21357-21366.
- [33] HA S, YEON J, YU H. RGBD GS-ICP SLAM[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2024: 180-197.
- [34] ZHENG J, ZHU Z, BIERI V, et al. Wild GS-SLAM: Monocular gaussian splatting SLAM in dynamic environments[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: Computer Vision Foundation/IEEE, 2025: 11461-11471.
- [35] STURM J, ENGELHARD N, ENDRES F, et al. A benchmark for the evaluation of RGB-D SLAM systems[C]//2012 IEEE/RSJ International Conference on Intelligent Robots and Systems. [S.l.]: IEEE, 2012: 573-580.
- [36] QIN T, LI P, SHEN S. VINS-mono: A robust and versatile monocular visual-inertial state estimator[J]. IEEE Transactions on Robotics, 2018, 34(4): 1004-1020.
- [37] DAVISON A J, REID I D, MOLTON N D, et al. MonoSLAM: Real-time single camera SLAM[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2007, 29(6): 1052-1067.

- [38] PIRE T, FISCHER T, CASTRO G, et al. S-PTAM: Stereo parallel tracking and mapping[J]. Robotics and Autonomous Systems, 2017, 93: 27-42.
- [39] GOMEZ-OJEDA R, ZUÑIGA-NOËL D, MORENO F A, et al. PL-SLAM: A stereo SLAM system through the combination of points and line segments[R/OL]. Ithaca, NY: arXiv, 2017[2026-03-17]. <https://arxiv.org/abs/1705.09479>.
- [40] 陈世浪, 吴俊君. 基于 RGB-D 相机的 SLAM 技术研究综述[J]. 计算机工程与应用, 2019, 55(7): 30-39, 126.
CHEN S L, WU J J. RGB-D SLAM: a survey[J]. Computer Engineering and Applications, 2019, 55(7): 30-39, 126.
- [41] ENDRES F, HESS J, ENGELHARD N, et al. An evaluation of the RGB-D SLAM system[C]//2012 IEEE International Conference on Robotics and Automation. [S.l.]: IEEE, 2012: 1691-1696.
- [42] SALAS-MORENO R F, NEWCOMBE R A, STRASDAT H, et al. SLAM++: Simultaneous localisation and mapping at the level of objects[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Portland, OR, USA: IEEE, 2013: 1352-1359.
- [43] IZADI S, KIM D, HILLIGES O, et al. KinectFusion: real-time 3D reconstruction and interaction using a moving depth camera[C]//Proceedings of the 24th Annual ACM Symposium on User Interface Software and Technology. New York, NY: ACM, 2011: 559-568.
- [44] WHELAN T, SALAS-MORENO R F, GLOCKER B, et al. ElasticFusion: Real-time dense SLAM and light source estimation[J]. The International Journal of Robotics Research, 2016, 35(14): 1697-1716.
- [45] YU S, CHENG C, ZHOU Y, et al. RGB-only Gaussian Splatting SLAM for unbounded outdoor scenes[C]//2025 IEEE International Conference on Robotics and Automation (ICRA). [S.l.]: IEEE, 2025: 11068-11074.
- [46] JI S, QIN Z, SHAN J, et al. Panoramic SLAM from a multiple fisheye camera rig[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2020, 159: 169-183.
- [47] LIU S, GUO P, FENG L, et al. Accurate and robust monocular SLAM with omnidirectional cameras[J]. Sensors, 2019, 19(20): 4494.
- [48] SUMIKURA S, SHIBUYA M, SAKURADA K. OpenVSLAM: A versatile visual SLAM framework[C]//Proceedings of the 27th ACM international conference on multimedia. New York, NY: ACM, 2019: 2292-2295.
- [49] MATSUKI H, VON STUMBERG L, USENKO V, et al. Omnidirectional DSO: Direct sparse odometry with fisheye cameras[J]. IEEE Robotics and Automation Letters, 2018, 3(4): 3693-3700.
- [50] HUANG H, YEUNG S K. 360VO: Visual odometry using a single 360 camera[C]//2022 International Conference on Robotics and Automation (ICRA). Piscataway, NJ: IEEE, 2022: 5594-5600.
- [51] CHEN Y, PAN Y, LIU R, et al. 360orb-slam: A visual slam system for panoramic images with depth completion network[C]//2024 27th International Conference on Computer Supported Cooperative Work in Design (CSCWD). [S.l.]: IEEE, 2024: 717-722.
- [52] AHMADI M, NAEINI A A, SHEIKHOLESAMI M M, et al. HDPV-SLAM: Hybrid depth-augmented panoramic visual SLAM for mobile mapping system with tilted LiDAR and panoramic visual camera[C]//2023 IEEE 19th International Conference on Automation Science and Engineering (CASE). Piscataway, NJ: IEEE, 2023: 1-8.
- [53] U H, WANG J, HE Y, et al. MCVO: A generic visual odometry for arbitrarily arranged multi-cameras[EB/OL]. Ithaca, NY: arXiv, 2024[2026-03-17]. <https://arxiv.org/abs/2412.03146>.
- [54] GUO X, XU Y, HUANG H, et al. 360DVO: Deep visual odometry for monocular 360-degree camera[J]. IEEE Robotics and Automation Letters, 2026, 11(3): 3079-3086.
- [55] 赵军阳, 喻涵, 张志利, 等. 多模态融合事件相机 SLAM 技术研究综述[J/OL]. 计算机工程与应用, 1-22 (2023-11-24) [2026-03-17].
ZHAO J Y, YU H, ZHANG Z L, et al. Review of research on multimodal fusion event camera SLAM technology[J/OL]. Computer Engineering and Applications, 1-22(2023-11-24)[2026-03-17]. <https://link.cnki.net/urlid/11.2127.TP.20251024.1646.025>.
- [56] MUEGGLER E, HUBER B, SCARAMUZZA D. Event-based, 6-DOF pose tracking for high-speed maneuvers[C]//2014

- IEEE/RSJ International Conference on Intelligent Robots and Systems. Chicago, IL, USA: IEEE, 2014: 2761-2768.
- [57] KUENG B, MUEGGLER E, GALLEGGO G, et al. Low-latency visual odometry using event-based feature tracks[C]//2016 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). [S.l.]: IEEE, 2016: 16-23.
- [58] CHAMORRO W, SOLA J, ANDRADE-CETTO J. Event-based line SLAM in real-time[J]. IEEE Robotics and Automation Letters, 2022, 7(3): 8146-8153.
- [59] GHOSH S, CAVINATO V, GALLEGGO G. ES-PTAM: Event-based stereo parallel tracking and mapping[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2024: 70-87.
- [60] GUAN W, CHEN P, XIE Y, et al. Pl-evio: Robust monocular event-based visual inertial odometry with point and line features[J]. IEEE Transactions on Automation Science and Engineering, 2023, 21(4): 6277-6293.
- [61] CHEN P, GUAN W, LU P. ESVIO: Event-based stereo visual inertial odometry[J]. IEEE Robotics and Automation Letters, 2023, 8(6): 3661-3668.
- [62] VIDAL A R, REBECQ H, HORSTSCHAEFER T, et al. Ultimate SLAM? Combining events, images, and IMU for robust visual SLAM in HDR and high-speed scenarios[J]. IEEE Robotics and Automation Letters, 2018, 3(2): 994-1001.
- [63] MUEGGLER E, GALLEGGO G, SCARAMUZZA D. Continuous-time trajectory estimation for event-based vision sensors[C]//Robotics: Science and Systems XI. Rome, Italy: Robotics: Science and Systems Foundation, 2015.
- [64] GALLEGGO G, LUND J E A, MUEGGLER E, et al. Event-based, 6-DOF camera tracking from photometric depth maps[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2018, 40(10): 2402-2412.
- [65] KIM H, LEUTENEGGER S, DAVISON A J. Real-time 3D reconstruction and 6-DoF tracking with an event camera[C]//European Conference on Computer Vision. Cham: Springer International Publishing, 2016: 349-364.
- [66] REBECQ H, HORSTSCHAEFER T, GALLEGGO G, et al. EVO: A geometric approach to event-based 6-DOF parallel tracking and mapping in real time[J]. IEEE Robotics and Automation Letters, 2017, 2(2): 593-600.
- [67] ZHOU Y, GALLEGGO G, SHEN S. Event-based stereo visual odometry[J]. IEEE Transactions on Robotics, 2021, 37(5): 1433-1450.
- [68] HIDALGO-CARRIÓ J, GALLEGGO G, SCARAMUZZA D. Event-aided direct sparse odometry[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. [S.l.]: IEEE, 2022: 5781-5790.
- [69] KLENK S, MOTZET M, KOESTLER L, et al. Deep event visual odometry[C]//2024 International Conference on 3D Vision. Piscataway, NJ: IEEE, 2024: 739-749.
- [70] GUAN W, LIN F, CHEN P, et al. DEIO: Deep event inertial odometry[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops. Piscataway, NJ: IEEE, 2025: 4665-4674.
- [71] LEE A J, KIM A. EventVLAD: Visual place recognition with reconstructed edges from event cameras[C]//2021 IEEE/RSJ International Conference on Intelligent Robots and Systems. Piscataway, NJ: IEEE, 2021: 2247-2252.
- [72] LATIF Y, GALLEGGO G, REBECQ H, et al. Towards visual SLAM with event-based cameras[C]//The Problem of Mobile Sensors Workshop. [S.l.]: [s.n.], 2017.
- [73] FISCHER T, MILFORD M. Event-based visual place recognition with ensembles of temporal windows[J]. IEEE Robotics and Automation Letters, 2020, 5(4): 6924-6931.
- [74] 任泽裕, 王振超, 柯尊旺, 等. 多模态数据融合综述[J]. 计算机工程与应用, 2021, 57(18): 49-64.
- REN Z Y, WANG Z C, KE Z W, et al. Survey of multimodal data fusion[J]. Computer Engineering and Applications, 2021, 57(18): 49-64.
- [75] ZHANG T, ZHANG H, LI X. Vision-audio fusion SLAM in dynamic environments[J]. CAAI Transactions on Intelligence Technology, 2023, 8(4): 1364-1373.
- [76] MICHAUD S, FAUCHER S, GRONDIN F, et al. 3D localization of a sound source using mobile microphone arrays referenced by SLAM[C]//2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). Piscataway, NJ: IEEE, 2020: 10402-10407.
- [77] CHAU A, SEKIGUCHI K, NUGRAHA A A, et al. Audio-visual slam towards human tracking and human-robot interaction

- in indoor environments[C]//2019 28th IEEE International Conference on Robot and Human Interactive Communication (RO-MAN). Piscataway, NJ: IEEE, 2019: 1-8.
- [78] VARGAS E, SCONA R, WILLNERS J S, et al. Robust underwater visual SLAM fusing acoustic sensing[C]//2021 IEEE International Conference on Robotics and Automation (ICRA). Piscataway, NJ: IEEE, 2021: 2140-2146.
- [79] WANG Y, JI Y, WOO H, et al. Acoustic camera-based pose graph slam for dense 3-D mapping in underwater environments[J]. IEEE Journal of Oceanic Engineering, 2020, 46(3): 829-847.
- [80] XU S, ZHANG K, WANG S. AQUA-SLAM: Tightly coupled underwater acoustic-visual-inertial SLAM with sensor calibration[J]. IEEE Transactions on Robotics, 2025, 41: 2785-2803.
- [81] VIDAS S, SRIDHARAN S. Hand-held monocular SLAM in thermal-infrared[C]//2012 12th International Conference on Control Automation Robotics & Vision (ICARCV). Piscataway, NJ: IEEE, 2012: 859-864.
- [82] CHEN W, WANG Y, CHEN H, et al. EIL - SLAM: depth - enhanced edge - based infrared - lidar SLAM[J]. Journal of Field Robotics, 2022, 39(2): 117-130.
- [83] BUEMI A, BRUNAA, PETINOT S, et al. ORB-SLAM with near-infrared images and optical flow data[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. Piscataway, NJ: IEEE, 2021: 1799-1804.
- [84] CHEN X, DAI W, JIANG J, et al. Thermal-depth odometry in challenging illumination conditions[J]. IEEE Robotics and Automation Letters, 2023, 8(7): 3988-3995.
- [85] 李程远, 郭晓栋, 常宏, 等. 隧道巡检机器人自主定位及巡检策略研究[J]. 内蒙古工业大学学报(自然科学版), 2025, 44(1): 17-22.
- LI C Y, GUO X D, CHANG H, et al. Research on autonomous positioning and inspection strategy of tunnel inspection robot[J]. Journal of Inner Mongolia University of Technology (Natural Science Edition), 2025, 44(1): 17-22.