



计算机应用
Journal of Computer Applications
ISSN 1001-9081, CN 51-1307/TP

《计算机应用》网络首发论文

题目：面向水表读数识别的混淆感知对抗训练方法
作者：刘文斌，耿艳兵，廉永健，崔方舒
收稿日期：2026-04-21
网络首发日期：2026-07-14
引用格式：刘文斌，耿艳兵，廉永健，崔方舒. 面向水表读数识别的混淆感知对抗训练方法[J/OL]. 计算机应用.
<https://link.cnki.net/urlid/51.1307.TP.20260714.1229.006>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

面向水表读数识别的混淆感知对抗训练方法

刘文斌, 耿艳兵*, 廉永健, 崔方舒

(中北大学 计算机科学与技术学院, 太原 030000)

(*通信作者电子邮箱 gyb@nuc.edu.cn)

摘要: 易混淆数字对因结构相似性引发的问题是水表智能识别在复杂场景下提升识别鲁棒性与准确率的核心瓶颈。对抗训练作为增强对抗鲁棒性的一种有效方式, 由于现有全局均匀扰动和局部扰动方法缺乏引导, 难以生成针对特定易混淆数字对的定向扰动, 且易导致检测框抖动, 防御策略难以聚焦易混淆方向。针对这一问题, 本文提出一种基于混淆感知的对抗训练方法。在攻击侧, 针对易混淆数字对的混淆特征, 基于投影梯度下降(PGD)提出融合分支解耦扰动与语义形态约束的 PGD 攻击方法(PGD-BS), 该方法通过引入分支解耦对抗扰动(BDAP)与语义形态约束(SMC), 实现分类误导与定位回归解耦的语义结构化扰动。在防御侧, 基于替代损失最小化的权衡启发式对抗防御框架(TRADES), 提出基于混淆感知的 TRADES 对抗训练(CA-TRADES)方法, 该方法仅对正样本易混淆类对引入带非对称混淆权重的方向性 Kullback-Leibler(KL)散度损失, 并将它与 YOLO 损失耦合。实验结果表明, PGD-BS 攻击成功率相较于传统 PGD 提升了 9.66 个百分点, 定位偏移显著降低; 在本文定向混淆攻击下, CA-TRADES 相较于 TRADES 的鲁棒性精度提升了 2.46 个百分点; 识别准确率相较于 Baseline 模型(标准训练的 YOLOV11 模型)提升了 2.5 个百分点。以上结果验证了该方法在水表读数识别工程中的有效性。

关键词: 目标检测; 对抗攻击; 对抗防御; 对抗训练; 混淆结构

中图分类号: TP391.4 **文献标志码:** A

Confusion-aware adversarial training method for water meter reading recognition

LIU Wenbin, GENG Yanbing*, LIAN Yongjian, CUI Fangshu

(School of Computer Science and Technology, North University of China, TaiYuan Shanxi 030000, China)

Abstract: The problem caused by the structural similarity of easily confused number pairs is the core bottleneck for improving the robustness and accuracy of intelligent water meter recognition in complex scenarios. Adversarial training, as an effective way to enhance adversarial robustness, is difficult to generate directional perturbations for specific pairs of easily confused numbers due to the lack of guidance in existing global uniform perturbation and local perturbation methods. Moreover, it is prone to cause the detection frame to jitter, and the defense strategy is hard to focus on the direction of confusion. To address this issue, an adversarial training method based on confusion awareness was proposed. On the attack side, aiming at the confusion characteristics of easily confused number pairs, a Projected Gradient Descent (PGD)-based attack method, namely Projected Gradient Descent with Branch-Decoupled Adversarial Perturbation (BDAP) and Semantic Morphological Constraints Alignment (SMTCA) (PGD-BS) was proposed. Branch-Decoupled Adversarial Perturbation (BDAP) and Semantic Morphological Constraints (SMC) were introduced to generate structured adversarial perturbations that decouple classification misguidance from localization regression. On the defense side, building upon the TRAdedoff-inspired Adversarial DEfense via Surrogate-loss minimization (TRADES) framework, a Confusion-Aware TRADES (CA-TRADES) method was proposed. Directional Kullback-Leibler (KL) divergence losses with asymmetric confusion weights were introduced only for positive-sample easily confused class pairs and coupled with YOLO losses. Experiments show that the success rate of PGD-BS attack is 9.66 percentage points higher than that of traditional PGD, and the positioning offset is significantly reduced. Under the directed obfuscation attack in this paper, the robustness precision of CA-TRADES is improved by 2.46 percentage points compared with that of TRADES. The single-digit accuracy rate has increased by 2.5 percentage points compared to the Baseline model (Standard trained YOLOV11 model). The effectiveness of this method in the water meter reading recognition project has been verified.

收稿日期: 2026-04-21; 修回日期: 2026-07-01; 录用日期: 2026-07-06。

基金项目: 山西省基础研究计划 (202303021222084)

作者简介: 刘文斌(2002—), 男, 山西临汾人, 硕士研究生, CCF 学生会会员, 主要研究方向: 目标检测、对抗训练; 耿艳兵(1980—), 女, 河南漯河人, 讲师, 博士, CCF 会员, 主要研究方向: 图像处理、模式识别、人工智能; 廉永健(1975—), 男, 山西平遥人, 讲师, 博士, 主要研究方向: 图像处理、模式识别、人工智能、虚拟现实; 崔方舒(1983—), 女, 山东淄博人, 讲师, 博士, CCF 会员, 主要研究方向: 复杂系统预测与健康健康管理、机器学习。

Keywords: target detection; adversarial attack; adversarial defense; adversarial training; confusion structure

0 引言

近年来,深度神经网络在表计读数^[1]、工业质检、交通监控等小目标视觉任务中得到广泛应用,但在易混淆样本下仍容易产生误检与误分类^[2]。水表读数场景中存在显著的结构性混淆(如3→8、6→8、1→7),它的业务代价高于一般漏检,且常伴随小目标、低清晰度与光照变化等挑战。

从任务属性看,水表读数识别本质上属于受限场景下的数字光学字符识别(Optical Character Recognition, OCR)问题。现有研究通常采用字符序列识别、目标检测或检测后读数排序等方式完成表盘数字识别,在清晰、规则的读数场景中已取得较好效果。然而,通用 OCR 方法更关注整体字符序列建模,目标检测方法更关注数字定位与分类精度,二者通常缺乏对特定易混淆数字对的方向性错误建模,难以显式约束模型关注局部差异笔画区域。因此,在水表读数任务中,仅依赖常规 OCR 或检测模型仍难以充分解决结构相似数字之间的细粒度混淆问题。

对抗训练(Adversarial Training, AT)被认为是提升鲁棒性的有效途径之一^[3],但在小目标且以易混淆数字为主的水表数字检测场景中,现有的方法仍存在明显局限,难以直接满足实际业务对高精度与高鲁棒性的双重需求。对抗训练对模型鲁棒性的提升主要取决于两方面因素:一是对抗样本生成的质量,二是防御侧训练框架的有效性。在对抗样本生成方面,Goodfellow 等^[4]提出的快速梯度符号法(Fast Gradient Sign Method, FGSM)计算高效但攻击强度有限,Madry 等^[5]提出的投影梯度下降(Projected Gradient Descent, PGD)方法通过多步迭代生成了更强的对抗样本,成为当前基准。在此基础上,Kurakin 等^[6]提出的基本迭代法(Basic Iterative Method, BIM)确立了多步梯度更新的基础范式,Carlini 等^[7]提出的 Carlini-Wagner(Carlini-Wagner Attack, C&W)攻击则通过优化定制化损失函数进一步突破了防御机制。然而,这些方法多采用全局均匀扰动,未聚焦水表数字的关键笔画差异,易导致检测框漂移。此外,近年来虽出现了局部可见对抗噪声(Localized and Visible Adversarial Noise, LaVAN^[8])、对抗补丁(Adversarial Patch, AP)^[9]及单像素攻击(One Pixel Attack, OPA)^[10]等局部对抗攻击方法,通过限制扰动作用范围来生成对抗样本,但它在水表读数识别场景下仍存在明显局限。LaVAN 所生成的扰动虽具有局部性,但通常以可见噪声形式作用于图像局部区域,缺乏对数字关键判别笔画的语义约束;Adversarial Patch 通过在图像中引入显著局部贴片诱导模型误判,在小目标数字场景中易干扰读数区域定位或遮挡关键笔画,从而导致漏检或整体识别失稳,而非针对特定数字对产生语义混淆;OPA 则通过极少量离散像素修改实现误导,它的扰动形式过于稀疏,难以表征水表数字混淆中常见的笔画断裂、缺口、粘连等局部形态变化。

因此,现有局部攻击方法普遍缺乏对“易混淆数字对差异笔画”的建模能力,难以直接生成既符合视觉自然性、又能稳定诱导特定数字混淆的对抗样本。

在防御框架方面,Madry 等^[5]建立的极小-极大优化框架奠定了理论基础,Zhang 等^[11]提出的基于替代损失最小化的权衡启发式对抗防御框架(Tradeoff-inspired Adversarial DeFense via Surrogate-loss minimization, TRADES)方法进一步平衡了自然准确率与鲁棒性。随后,Wang 等^[12]提出的误分类感知对抗训练(Misclassification Aware adveRsarial Training, MART)方法通过重加权误分类样本增强难例学习,Zhang 等^[13]提出的友好对抗训练(Friendly Adversarial Training, FAT)方法则通过搜索最小必要扰动降低训练难度。然而,现有框架通常在所有锚点上均匀施力,巨量背景锚点稀释了训练资源,且缺乏对“特定混淆方向”错误的针对性强化。

针对水表读数识别中关键易混淆数字对误判突出、且现有方法难以对该类结构性错误进行定向扰动和定向防御的问题,本文提出一种面向水表读数识别的混淆感知对抗训练方法,从攻击侧与防御侧同时进行针对性改进。在攻击侧,针对现有方法扰动缺乏语义指向、且易引发定位不稳定的问题,本文在 PGD 基础上提出 PGD-BS(Projected Gradient Descent with Branch-Decoupled Adversarial Perturbation and Semantic Morphological Constraints),引入分支解耦对抗扰动与语义-形态约束,通过将分类误导与定位回归扰动解耦,并利用易混淆数字对的差异笔画信息生成局部结构化扰动,使对抗样本更聚焦于真实易混淆区域,同时抑制检测框抖动;在防御侧,针对传统对抗训练难以区分混淆风险方向、且易受大量背景锚点稀释的问题,本文在 TRADES^[11]框架基础上提出 CA-TRADES(Confusion-Aware TRADES),通过在正样本易混淆类对上施加带非对称混淆权重的方向性 KL(Kullback-Leibler)散度约束,使鲁棒训练资源集中于最关键的错误模式。实验结果表明,本文方法在保持较高自然精度的同时,能够有效提升对抗鲁棒性并降低关键易混类对错误率,从而为水表读数识别场景下的高精度、高稳定性鲁棒建模提供了一种可行方案。

1 相关工作

1.1 水表读数识别相关方法

水表读数识别任务需要在复杂成像条件下准确定位表盘数字区域,并进一步识别和组合得到完整读数。现有方法主要包括基于序列识别的 OCR 方法、基于目标检测的数字识别方法以及基于 Transformer 的端到端识别方法。卷积循环神经网络(Convolutional Recurrent Neural Network, CRNN)^[14]、PP-OCR (PaddlePaddle Optical Character Recognition)^[15]等 OCR 方法通常将读数区域作为字符序列进行识别,适用于字

符排列较规则的场景；YOLO 系列等检测方法则将单个数字视为独立目标，通过定位、分类和排序得到最终读数；基于 Transformer 的光学字符识别方法(Transformer-based Optical Character Recognition, TrOCR)^[16]等 Transformer 方法进一步增强了字符区域或目标区域的全局建模能力。

上述方法在清晰、规则的水表读数场景中能够取得较好效果，但在实际应用中仍面临小目标、反光、污渍、磨损、遮挡和成像模糊等问题。尤其是 3/8、6/8、1/7 等结构相似数字对，容易因局部笔画缺失、粘连或形态相似产生方向性误判。现有通用 OCR 和检测模型通常以整体识别准确率或检测精度为优化目标，缺乏对特定易混淆数字对的显式建模。因此，本文进一步从对抗攻击与对抗训练角度出发，引入混淆矩阵先验、差异笔画掩膜和混淆感知鲁棒约束，以提升模型对关键易混淆数字对的细粒度判别能力。

1.2 对抗攻击方法

对抗攻击旨在通过生成肉眼难以察觉的扰动误导深度学习模型，它的技术演进始终围绕着如何在有限扰动预算下最大化攻击成功率与效率。FGSM 利用单步沿损失函数梯度方向施加扰动，实现了高效生成。然而，FGSM 的单步线性近似假设忽略了损失函数的非线性曲率，导致生成的对抗样本攻击强度有限，难以突破具有较强鲁棒性的模型。针对 FGSM 攻击强度不足的问题，Kurakin 等^[6]提出了基本迭代法(BIM)，确立了多步梯度更新的基础范式，通过多次小步长迭代累积扰动显著增强了攻击效果，但缺乏对扰动范围的严格约束。

为进一步完善多步迭代机制并确保扰动不可察觉，Madry 等^[5]提出了 PGD 方法。PGD 在 BIM 基础上引入投影操作，将每次迭代结果约束在以原始样本为中心、半径为 r 的 L_∞ 范数球内，它的更新规则为：

$$\mathbf{x}_{\text{adv}}^{t+1} = \Pi_{\mathbf{x}+S} \left(\mathbf{x}_{\text{adv}}^t + \alpha_{\text{step}} \cdot \text{sign}(\nabla_{\mathbf{x}_{\text{adv}}} J(\theta, \mathbf{x}_{\text{adv}}^t, y)) \right) \quad (1)$$

其中： α_{step} 为单步扰动步长； $\mathbf{x}_{\text{adv}}^t$ 表示第 t 步迭代生成的对抗样本； $\nabla_{\mathbf{x}_{\text{adv}}}$ 表示对当前对抗样本求导子； J 表示攻击目标函数； y 表示样本真实类别标签； θ 表示模型参数； $\text{sign}(\cdot)$ 为符号函数用来提取梯度方向； $\Pi_{\mathbf{x}+S}$ 为投影操作， $\mathbf{x}$ 为原始输入样本（原始水表图像）， S 为扰动约束集合。

PGD 因具有在有限预算下生成强对抗样本的能力，成为当前评估模型鲁棒性的统一基准。然而，PGD 仍采用全局均匀扰动策略，未考虑图像语义结构，易破坏目标的几何特征。针对防御机制的进一步增强，Carlini 等^[7]提出了 C&W 攻击。该方法针对 PGD 等基于梯度范数的攻击易被防御过滤的问题，将对抗样本生成转化为约束优化问题，通过设计定制化损失函数最小化扰动范数同时迫使模型误分类。C&W 攻击能够生成扰动极小且欺骗性极强的样本，常被视为评估防御有效性的强基准。但它的优化过程计算复杂度极

高，难以应用于大规模数据训练。此外，为避免单一攻击方法评估鲁棒性时的片面性，Crocker 等^[17]提出了自动攻击(AutoAttack, AA)框架。该框架针对现有评估标准不统一的问题，集成了 APGD-CE(Auto Projected Gradient Descent with Cross-Entropy loss)、APGD-DLR(Auto Projected Gradient Descent with Difference of Logits Ratio loss)、FAB(Fast Adaptive Boundary attack)^[18]及 Square Attack^[19]等多种自适应攻击策略，形成了鲁棒性评估的综合框架。然而，AA 框架本质上仍是多种全局扰动策略的组合，缺乏对特定语义区域的聚焦。

除全局扰动攻击外，部分研究关注局部区域攻击。LaVAN^[8]通过在图像局部窗口内优化可见噪声实现攻击，扰动区域集中，但缺乏语义约束，容易在背景区域产生无意义噪声。Adversarial Patch 通过粘贴通用对抗补丁误导模型，但在水表读数场景中，大面积补丁可能直接遮挡数字，导致检测失败而非产生更具业务风险的数字混淆。OPA^[10]仅修改单个像素，隐蔽性较强，但对于分辨率较低的水表数字小目标，它的扰动强度有限，攻击成功率通常较低。

综上所述，对抗攻击方法虽在不断演进，但普遍存在以下问题：多采用全局均匀扰动，未聚焦水表数字的关键笔画差异；扰动能量分散导致对混淆数字对的针对性不足；且无约束的扰动易破坏边界框回归的几何一致性，造成定位偏移剧烈抖动，难以直接使用在水表读数识别场景中。

1.3 对抗防御方法

面对对抗样本的威胁，对抗训练被公认为最有效的防御策略之一，它的核心思想是将对抗样本纳入训练过程以提升模型鲁棒性。Madry 等^[5]针对模型易受扰动影响的问题，将对抗训练形式化为一个极小-极大优化问题，内层最大化生成最具破坏力的对抗样本，外层最小化优化模型参数。然而，该方法过度关注对抗样本可能导致模型在干净样本上的自然准确率下降，且易出现鲁棒过拟合现象。针对自然准确率与鲁棒性之间的权衡问题，Zhang 等^[11]提出了 TRADES 方法。该方法通过理论分析揭示了二者内在关系，设计了兼顾平衡的损失函数，约束模型对原始样本与对抗样本输出分布的差异：

$$L(\theta) = \mathbb{E}_{(\mathbf{x}, y) \sim \mathcal{D}} \left[\text{CE}(f_\theta(\mathbf{x}), y) + \frac{1}{\lambda} \text{KL}(f_\theta(\mathbf{x}) \parallel f_\theta(\mathbf{x}_{\text{adv}})) \right] \quad (2)$$

其中， $L(\theta)$ 为模型参数 θ 的总损失函数； $\mathbb{E}_{(\mathbf{x}, y) \sim \mathcal{D}}$ 表示关于数据分布 $\mathcal{D}$ 的期望， $(\mathbf{x}, y)$ 为从训练集中采样的样本及其真实标签； $\text{CE}(\cdot, \cdot)$ 为交叉熵损失函数； $f_\theta(\mathbf{x})$ 和 $f_\theta(\mathbf{x}_{\text{adv}})$ 分别为模型对干净样本 $\mathbf{x}$ 和对抗样本 $\mathbf{x}_{\text{adv}}$ 的输出分布； $\text{KL}(\cdot \parallel \cdot)$ 为 Kullback-Leibler 散度^[20]，用于约束两者分布的一致性； $\lambda > 0$ 为平衡自然准确率与鲁棒性的权重系数。但 TRADES

在所有锚点上均匀计算 KL 散度，未区分锚点重要性，海量背景锚点稀释了正样本的训练信号。

为进一步增强难例学习，Wang 等^[12]提出了 MART 方法。针对简单样本主导训练导致模型难以学习复杂决策边界的问题，MART 引入误分类感知机制，依据当前训练批次中样本的实时误分类状态施加动态重加权。然而，MART 的动态加权策略在水表读数目标检测场景中存在两点局限，其一，目标检测中正样本锚点稀疏且单批次样本有限，基于瞬时误分类状态的权重估计方差较大，易引发训练震荡；其二，MART 对所有误分类样本一视同仁，无法区分“因笔画结构相似导致的系统性方向混淆（如 3→8）”与“因遮挡或噪声引发的偶然性误判”。相比之下，本文 CA-TRADES 摒弃了即时状态反馈，转而采用基线 YOLOV11 模型^[21]在完整训练集上离线推理得到并静态冻结的混淆矩阵先验进行方向性加权。该先验机制不仅有效过滤了高频偶发噪声，精准聚焦于真实的结构性混淆模式，更通过将加权约束严格限制于正样本锚点，从根本上规避了海量背景锚点对鲁棒训练信号的稀释，实现了难例聚焦与训练稳定性的统一。

同时，FAT 方法针对强扰动破坏自然特征表示的问题，主张寻找“最友好”的对抗样本，即能够导致误分类但损失最小的样本。该策略旨在降低训练难度，避免强扰动破坏自然特征。但 FAT 需要在扰动空间内搜索最小必要扰动，计算开销较大，且它的“友好”标准仅基于损失值，缺乏对语义混淆方向的感知，难以区分易混淆样本的不同风险等级。

综上所述，现有对抗防御框架普遍存在以下局限性：通常在所有锚点上均匀施力，巨量背景锚点稀释了训练资源；未区分不同类别对的混淆风险差异；缺乏对水表场景中少数易混淆数字对的针对性防御，难以满足水表读数识别的高精度与高鲁棒性双重需求。

2 本文方法

2.1 问题描述

在水表读数自动识别任务中，深度学习模型面临数字混淆导致的识别精度瓶颈。尽管已通过数据标注校正与常规数据增强手段优化训练集，但模型在测试阶段仍频繁出现特定数字对的误判。究其根源，这些易混淆数字对在视觉表征上存在局部笔画相似性，而标准训练范式难以迫使模型学习区分此类细微差异的判别性特征。

对抗训练作为一种有效的鲁棒性增强手段，理论上可通过引入对抗扰动迫使模型关注关键判别区域。然而，现有的对抗攻击方法在目标检测场景下面临两大挑战：其一，全局像素级扰动生成策略未聚焦于数字笔画的关键差异区域，扰动能量分散导致对混淆数字对的针对性不足；其二，无约束的扰动易破坏边界框回归的几何一致性，造成定位偏移剧烈抖动（实测偏移可达 5 像素以上），进而损害模型在干净样

本上的检测性能。给定水表图像 $\mathbf{x}$ 及其标注 $\{(\mathbf{b}_i, c_i)\}_{i=1}^N$ （其中 $\mathbf{b}_i$ 为边界框坐标， c_i 为数字类别， N 是图像中标注数字目标的数量），传统对抗攻击可表述为：

$$\begin{aligned} \delta^* = \operatorname{argmax}_{\|\delta\|_p \leq \varepsilon} & \mathcal{L}_{\text{cls}}(f_{\theta}(\mathbf{x} + \delta), \{c_i\}) + \\ & \lambda_{\text{attack}} \mathcal{L}_{\text{loc}}(f_{\theta}(\mathbf{x} + \delta), \{\mathbf{b}_i\}) \end{aligned} \quad (3)$$

其中： δ^* 为最优对抗扰动； δ 为通用对抗扰动变量； $\|\delta\|_p \leq \varepsilon$ 为扰动预算约束， ε 是融合扰动的预算上限； $\mathcal{L}_{\text{cls}}$ 与 $\mathcal{L}_{\text{loc}}$ 分别为分类损失与定位损失，为区别于通用分类公式中的样本标签 y ，在目标检测任务中，本文使用 c_i 表示图像中第 i 个目标的真实类别标签。 $\{c_i\}$ 与 $\{\mathbf{b}_i\}$ 分别为图像中所有目标的真实类别标签与边界框坐标集合， $\lambda_{\text{attack}} > 0$ 为平衡两项损失的权重系数， $f_{\theta}(\mathbf{x} + \delta)$ 为模型对对抗样本的输出。

该优化目标未显式建模数字混淆的语义先验，且分类与定位损失的耦合优化导致扰动方向难以兼顾攻击有效性 with 定位稳定性，制约了对抗训练在水表识别场景中的实用性，如图 1 所示，其中，图 1(a)是真实水表图片，显示真实读数为 12696，图 1(b)是采用标准训练的 YOLOV11 模型的预测结果图，读数为 12896，其中第 3 位数字“6”被误判为“8”，这是典型的易混淆数字对（6→8）错误，表明标准训练难以区分相似笔画结构；图 1(c)是采用 PGD 对抗训练方法的预测结果，读数为 12596，虽然引入了对抗训练，但第 3 位数字仍被误判（6→5），检测框也出现明显偏移与抖动，表明传统 PGD 对抗训练应用在水表读数场景中存在两大缺陷：一是未能有效聚焦于关键易混淆数字对的判别性特征，导致误判从 6→8 转变为 6→5；二是全局均匀扰动策略破坏了几何一致性，造成定位框不稳定。



图 1 标准训练与 PGD 对抗训练在水表读数识别中的预测对比

Fig. 1 Prediction comparison between standard training and PGD adversarial training in water meter digit recognition

2.2 研究动机

针对上述问题，本文从水表图像的物理特性与数字混淆的语义规律出发，提出 3 项核心设计原则：

1) 语义引导的扰动生成: 水表数字混淆具有明确的方向性, 且混淆主要源于特定笔画区域的缺失或畸变。因此, 对抗扰动应聚焦于易混淆数字对的差异笔画区域, 并模拟真实场景中白点遮挡、边缘磨损等物理伪影, 而非施加全局均匀扰动。

2) 任务解耦的扰动控制: 目标检测包含分类与定位两个子任务, 二者对扰动的敏感性存在本质差异。分类任务需强扰动以暴露模型脆弱性, 而定位任务对扰动极为敏感。若采用统一扰动策略, 将导致定位性能严重退化。理想方案应解耦两类任务的扰动生成过程, 独立优化后再进行可控融合。

3) 混淆感知的防御机制: 传统 TRADES 等防御方法在目标检测中面临“信号稀释”问题——海量背景锚点的 KL

散度计算稀释了正样本锚点的训练信号, 且未区分不同类别对的混淆风险差异。水表场景中仅少数数字对构成易混淆, 防御策略应聚焦此类方向性错误模式, 避免算力浪费于低风险类别对。

基于上述动机, 本文提出面向水表读数识别的混淆感知对抗训练框架, 包含 3 个组件: 分支解耦对抗扰动 (Branch-Decoupled Adversarial Perturbation, BDAP)、语义形态约束 (Semantic Morphological Constraints, SMC) 及混淆感知 TRADES (Confusion-Aware TRADES, CA-TRADES)。

2.3 整体框架




图2 基于混淆感知的对抗训练整体框架

Fig. 2 Overall framework of confusion-aware adversarial training method

图2展示了本文提出的混淆感知对抗训练方法在单轮训练迭代中的整体流程。首先, 在攻击侧, 输入水表图像 $\mathbf{x}$ 经 YOLOV11 提取多尺度特征; 与此同时, 利用未经对抗训练的基线 YOLOV11 模型对完整训练集进行一次全量前向推理, 离线计算初始混淆矩阵 $\mathbf{M}$ 并预构建差异模板库 $\mathcal{T}$, 二者在后续训练中保持静态冻结。随后, SMC 模块结合当前正样本区域的类别信息, 从差异模板库中检索对应的差异笔画模板, 并通过空间映射生成语义掩膜, 用于高亮易混淆数字对的关键判别区域。在此基础上, BDAP 模块分别依据分类损失、定位损失和分布焦点损失 (Distribution Focal Loss, DFL) 计算并得到三路扰动。三路扰动经加权融合后, 再施加基于差异笔画和可微形态运算的语义形态约束, 从而生成兼顾攻击有效性与定位稳定性的对抗样本 $\mathbf{x}_{adv}$ 。在防御侧, 将干净样本 $\mathbf{x}$ 与对抗样本 $\mathbf{x}_{adv}$ 共同输入 YOLOV11 检测网络, 分别计算自然检测损失与仅作用于正样本易混淆类别对的方向性 KL 鲁棒损失, 其中方向性 KL 项由基于混淆矩阵和混淆阈值 τ 构建的非对称混淆权重进行加权。最终, 两部分损失共同组成总损失, 并通过反向传播计算梯度, 之后优化器更新模型参数, 从而得到鲁棒模型。

2.4 对抗攻击框架及组件

2.4.1 对抗攻击框架

基于上述动机, 本文从攻击侧与防御侧同时进行改进。图3给出了传统 PGD 攻击与本文 PGD-BS 攻击框架的对比。与传统方法主要依赖全局扰动不同, 本文方法通过分支解耦对抗扰动 (BDAP) 与语义-形态约束 (SMC) 协同生成扰动, 在保持攻击强度的同时显著抑制定位偏移。




图3 传统的 PGD 对抗攻击方法与本文方法的对比

Fig. 3 Comparison between traditional PGD adversarial attack method and proposed method

本文方法的整体流程如下。给定输入水表图像 $\mathbf{x}$ ，首先通过预训练的 YOLOV11^[21]模型提取多尺度特征图。随后，基于混淆矩阵 $\mathbf{M} \in \mathbb{R}^{10 \times 10}$ 生成语义引导的对抗掩膜，该掩膜高亮易混淆数字字的差异笔画区域。在掩膜约束下，分别基于分类损失 $\mathcal{L}_{\text{cls}}$ 、定位损失 $\mathcal{L}_{\text{loc}}$ 及分布焦点损失 $\mathcal{L}_{\text{df}}$ 生成 3 组独立扰动 δ_{cls} 、 δ_{loc} 与 δ_{df} 。通过加权融合得到最终扰动 δ_{adv} ：

$$\begin{aligned} \delta_{\text{adv}} &= \alpha \cdot \delta_{\text{cls}} + \beta \cdot \delta_{\text{loc}} + \gamma \cdot \delta_{\text{df}} \\ \text{s.t. } \|\delta_{\text{adv}}\|_{\infty} &\leq \varepsilon \end{aligned} \quad (4)$$

其中： α 、 β 、 γ 为对应的任务感知融合权重系数， $\alpha \gg \beta, \gamma$ 以确保分类扰动主导攻击强度，同时 δ_{loc} 的方向由定位损失梯度显式约束以抑制框偏移。

该约束使扰动能量集中于差异笔画区域，而在非关键区域通过腐蚀操作弱化扰动，生成符合水表物理特性的白点/缺口伪影。最终得到对抗样本 $\mathbf{x}_{\text{adv}}$ 。

2.4.2 混淆矩阵构建与差异模板库静态冻结协议

攻击侧结构化扰动的定向生成紧密依托于混淆矩阵所蕴含的类别混淆先验。为确保混淆先验统计的可靠性与训练流程的一致性，本文确立如下构建准则与静态冻结机制：

1) 统计粒度与匹配规则：混淆矩阵严格基于检测框级别统计。采用与基础检测器一致的匹配策略，设定交并比 (Intersection over Union, IoU) 阈值为 0.5。当预测框与真实框 $\text{IoU} \geq 0.5$ 时视为正样本匹配，按预测类别与真实类别计入混淆矩阵对应位置；当预测框与所有真实框 IoU 均 < 0.5 时视为误检，计入背景类至该预测类别的混淆项；当真实目标未被任何预测框匹配时视为漏检，计入该真实类别至背景类的混淆项。

2) 离线校准与静态冻结机制：为避免训练过程中因先验动态变化引起的统计漂移与优化不稳定，本文采用“离线基线评估+静态先验固定”策略。在对抗训练启动前，使用未经对抗训练的基线 YOLOV11 模型对完整训练集进行一次全量前向推理，据此计算初始混淆矩阵 $\mathbf{M}^{(0)}$ 并预构建全量差异笔画模板库 $\mathcal{T}$ 。该先验信息在后续所有对抗训练轮次中保持完全冻结，不参与任何梯度更新或动态调整。

3) 差异模板库的固定策略：由于本文采用静态混淆矩阵策略，训练过程中的混淆风险分布已被预先锁定。因此，在计算得到初始混淆矩阵 $\mathbf{M}^{(0)}$ 后，仅针对满足混淆概率 $\mathbf{M}_{m,n}^{(0)} \geq \tau$ 的易混淆类别对 (m, n) 生成对应的差异笔画掩膜 $\mathbf{T}_{m,n}$ 。构建完成后，模板库 $\mathcal{T}$ 与混淆矩阵 $\mathbf{M}^{(0)}$ 同步冻结，在后续对抗训练全程保持不变。

该设计实现了“先验筛选-定向构建-静态复用”的闭环，最大程度压缩了预处理阶段的计算成本。

2.4.3 分支解耦对抗扰动 (BDAP)

为解决分类与定位任务对抗扰动敏感性的冲突，本文在 PGD 攻击基础上设计分支解耦对抗扰动生成机制。具体而言，针对每个正样本锚点 i ，分别计算 3 类损失的梯度：

$$\begin{aligned} \mathbf{g}_{\text{cls}}^{(i)} &= \nabla_{\mathbf{x}} \mathcal{L}_{\text{cls}}(f_{\theta}(\mathbf{x}), c_i) \\ \mathbf{g}_{\text{loc}}^{(i)} &= \nabla_{\mathbf{x}} \mathcal{L}_{\text{loc}}(f_{\theta}(\mathbf{x}), b_i) \\ \mathbf{g}_{\text{df}}^{(i)} &= \nabla_{\mathbf{x}} \mathcal{L}_{\text{df}}(f_{\theta}(\mathbf{x}), b_i) \end{aligned} \quad (5)$$

其中： $\mathbf{g}_{\text{cls}}^{(i)}$ 、 $\mathbf{g}_{\text{loc}}^{(i)}$ 、 $\mathbf{g}_{\text{df}}^{(i)}$ 分别为第 i 个样本在分类、定位及分布焦点这 3 个分支上相较于输入 $\mathbf{x}$ 的梯度； $\nabla_{\mathbf{x}}$ 表示对输入样本求梯度算子； $f_{\theta}(\mathbf{x})$ 为参数 θ 的模型对输入 $\mathbf{x}$ 的前向输出。

通过分别计算 3 个分支的梯度，本文实现了多任务扰动的解耦生成，为后续的任务感知加权融合奠定基础。其中，分布焦点损失 $\mathcal{L}_{\text{df}}$ 用于对边界框左、上、右、下这 4 个方向到锚点的距离进行离散概率分布监督，它定义为：

$$\begin{aligned} \mathcal{L}_{\text{df}} &= - \sum_{d=1}^4 [(q_d + 1 - l_d) \ln(p_d(q_d)) + (l_d - q_d) \ln(p_d(q_d + 1))] \end{aligned} \quad (6)$$

其中： $\mathcal{L}_{\text{df}}$ 为分布焦点损失； $d \in \{1, 2, 3, 4\}$ 分别对应边界框的左、上、右、下这 4 个方向； l_d 为第 d 个方向上真实框边到锚点的连续距离； q_d 为离散化后的下界整数， $q_d + 1$ 为相邻上界整数； $p_d(\cdot)$ 为模型输出的对应距离离散概率值。

基于上述梯度，通过 K 步 PGD 迭代分别生成 3 组扰动：

$$\begin{aligned} \delta_k^{(t+1)} &= \text{clip}_{\mathbf{x}, \varepsilon}(\delta_k^{(t)} + \eta \cdot \text{sign}(\mathbf{g}_k)) \\ k &\in \{\text{cls}, \text{loc}, \text{df}\}, t = 0, 1, \dots, K-1 \end{aligned} \quad (7)$$

其中， $\delta_k^{(t)}$ 为第 t 次迭代时分支 k 的对抗扰动， $\mathbf{g}_k$ 为对应分支的梯度， η 为扰动更新步长， $\text{clip}_{\mathbf{x}, \varepsilon}(\cdot)$ 为裁剪操作。

之后在扰动融合阶段引入任务感知权重：

$$\begin{aligned} \alpha &= 1.0 \\ \beta &= \kappa \cdot \frac{\|\mathbf{g}_{\text{loc}}\|_2}{\|\mathbf{g}_{\text{cls}}\|_2 + \xi} \\ \gamma &= 0.3 \end{aligned} \quad (8)$$

其中 $\kappa \in [0.05, 0.15]$ 为缩放系数， ξ 为数值稳定项。 α 和 γ 的具体取值依据前期预实验结果与任务需求进行设定，以平衡攻击强度与定位稳定性。该设计使定位扰动 δ_{loc} 的贡献被压缩至分类扰动的 5%~15%，同时它的方向由 $\mathbf{g}_{\text{loc}}$ 显式控制，确保框偏移被抑制在 2~4 像素范围内，而分类攻击强度保持不变。

需要明确的是，分布焦点损失 (DFL) 在攻击阶段与防御阶段的优化目标具有本质差异。在防御阶段，DFL 通过梯度下降优化边界框距离分布，旨在提升定位细粒度精度；而在攻击阶段，本文通过对 DFL 计算反方向梯度 (梯度上升)，生成能够定向破坏模型对边界框边缘分布拟合能力的结构化扰动。从多任务优化视角看，目标检测的分类与定位分支共

享底层特征，存在显著的“跨任务域攻击转移”现象——即单一任务分支的扰动易通过共享参数传播并干扰另一任务的性能。传统 PGD 将分类与定位损失耦合优化，易导致梯度方向冲突与定位框剧烈抖动。为此，本文在攻击侧引入任务域解耦约束：分别沿分类损失梯度方向最大化分类误差，沿定位损失与 DFL 梯度方向最大化定位误差，并通过任务感知权重独立控制各分支扰动强度。该设计使对抗样本在保持强分类攻击性的同时，将定位扰动严格约束在 2~4 像素的合理范围内，避免全局扰动导致的几何结构崩塌。

2.4.4 语义形态约束 (SMC)

为使对抗扰动聚焦于易混淆数字对的差异笔画区域并符合物理可解释性，本文在 PGD 攻击基础上提出语义形态约束机制。首先，基于混淆矩阵 $\mathbf{M}$ 构建类别对差异模板库 $\mathcal{T}$ ： $\{\mathbf{T}_{m,n}\}_{m,n=0}^9$ ，其中 $\mathbf{T}_{m,n} \in \{0,1\}^{h \times w}$ 为数字 m 与 n 的笔画差异掩膜，9 表示下标 m 和 n 的取值范围上界。具体构建过程为：在训练开始前，利用基线模型在训练集上生成类别 m 和 n 的类激活映射 (Class Activation Mapping, CAM) [22]；随后计算两者的注意力差异图，并通过自适应阈值分割与形态学平滑处理，提取出最具判别性的笔画差异区域作为掩膜。为直观展示 SMC 如何从易混淆数字对中提取关键判别区域，本文以数字对 3/8 为例，给出了原始图像、注意力热力图对比以及差异笔画掩膜的可视化结果，如图 4 所示。




图 4 SMC 对易混淆数字对 3/8 的差异笔画提取示意图

Fig. 4 Illustration of discriminative stroke extraction by SMC for confusing digit pair 3/8

由图 2 可见，SMC 关注的并非数字整体区域，而是集中在导致 3 与 8 发生混淆的关键闭合/缺口笔画位置，由此生成的差异掩膜能够将扰动限制在高判别性局部区域。

给定图像中检测到的数字区域 $\mathbf{B}_i$ 及其类别 c_i ，计算它的最易混淆目标类别：

$$c_i^* = \arg \max_{j \neq c_i} m_{c_i, j} \quad (9)$$

其中： c_i^* 为最易混淆的目标类别； $m_{c_i, j}$ 为混淆矩阵中类别 c_i 被误分类为类别 j 的概率。

给定第 i 个正样本区域的真实类别 c_i 及其最易混淆目标类别 c_i^* ，从差异模板库 $\mathcal{T}$ 中检索对应的差异掩膜 $\mathbf{T}_{c_i, c_i^*}$ ，并通过仿射变换将它映射到当前目标区域 $\mathbf{B}_i$ 上，得到第 i 个正样本区域在图像 $\mathbf{x}$ 上对应的局部对抗掩膜：

$$\mathbf{T}_i^{\text{local}}(\mathbf{x}) = \mathcal{W}(\mathbf{T}_{c_i, c_i^*}; \mathbf{B}_i), \quad \mathbf{T}_{c_i, c_i^*} \in \mathcal{T} \quad (10)$$

其中， $\mathcal{W}(\cdot; \mathbf{B}_i)$ 表示依据第 i 个目标区域边界框进行尺度对齐与空间映射的仿射变换。

进一步地，将所有正样本区域的局部掩膜叠加并归一化，得到全局语义掩膜：

$$\mathbf{A} = \text{Norm} \left(\sum_{i \in \mathcal{P}} \mathbf{T}_i^{\text{local}}(\mathbf{x}) \right) \quad (11)$$

其中： $\mathcal{P}$ 表示图像中所有正样本区域的索引集合； $\text{Norm}(\cdot)$ 表示归一化算子，用于将所有局部掩膜叠加结果缩放到 $[0,1]$ 区间。

该掩膜为模拟真实水表图像中的白点遮挡与边缘磨损，引入可微形态学运算生成物理可信扰动。定义可微膨胀算子 $\mathcal{D}_\sigma(\cdot)$ 与腐蚀算子 $\mathcal{E}_\sigma(\cdot)$ ：

$$\begin{aligned} \mathcal{D}_\sigma(\mathbf{A}) &= \mathbf{A} \oplus \mathcal{N}(0, \sigma^2 \mathbf{I}) \\ \mathcal{E}_\sigma(\mathbf{A}) &= \mathbf{1} - \mathcal{D}_\sigma(\mathbf{1} - \mathbf{A}) \end{aligned} \quad (12)$$

其中： $\oplus$ 表示卷积操作， σ 表示形态学平滑尺度， $\mathcal{N}(0, \sigma^2 \mathbf{I})$ 为高斯核， $\mathbf{I}$ 表示单位矩阵， $\mathbf{1}$ 表示全 1 矩阵。最终扰动生成过程约束为：

$$\delta_{\text{adv}} = \mathbf{A} \odot \delta_{\text{raw}} + (\mathbf{1} - \mathbf{A}) \odot \mathcal{E}_\sigma(\delta_{\text{raw}}) \quad (13)$$

其中： $\odot$ 为逐元素乘法， δ_{raw} 为原始 PGD 扰动。该约束使扰动能量集中于差异笔画区域（ $\mathbf{A}=\mathbf{1}$ 处保留强扰动），而在非关键区域（ $\mathbf{A}=\mathbf{0}$ 处）通过腐蚀操作弱化扰动，生成符合水表物理特性的白点/缺口伪影。

2.5 混淆感知对抗训练框架 (CA-TRADES)

在防御侧，本文针对传统 TRADES 在目标检测场景中存在的背景锚点信号稀释和易混淆方向刻画不足等问题，提出混淆感知对抗训练方法。为便于说明二者在优化路径上的差异，图 5 给出了传统 TRADES 与本文 CA-TRADES 训练框架的对比。




图 5 传统的 TRADES 对抗训练方法与本文方法的对比

Fig. 5 Comparison between traditional TRADES adversarial training methods and proposed method

标准 TRADES 损失如式(2)所示。该损失在所有锚点上均匀计算 KL 散度，未区分锚点重要性及类别混淆风险。需要指出的是，混淆矩阵中的非零项并不都对应值得重点建模的真实易混淆。若不引入混淆阈值 τ ，而是对所有类别对一视同仁地施加混淆加权约束，则大量低频、偶然性的混淆项也会被纳入鲁棒训练过程，导致权重矩阵过于稠密，使训练

信号重新分散到大量低风险类别对上, 削弱模型对关键易混淆方向的针对性强化。相反, 若 τ 设定过大, 则部分虽出现频率不高但具有稳定语义相似性的真实易混淆对会被错误剔除, 造成有效监督信号缺失。因此, 混淆阈值 τ 本质上是连接“混淆统计”与“鲁棒约束分配”的门控参数, 它的作用是在覆盖范围与聚焦程度之间取得平衡, 仅保留需要重点建模的易混淆类别对, 从而使 CA-TRADES 的方向性分布对齐真正集中于水表识别中最关键的混淆模式。本文设计了非对称混淆权重矩阵 $\mathbf{W} \in \mathbb{R}^{10 \times 10}$:

$$w_{ij} = \begin{cases} \frac{m_{ij}}{\max_{r \in \mathcal{C}, r \neq i} m_{ir}} & i \neq j \text{ 且 } m_{ij} > \tau \\ 0 & \text{其他情况} \end{cases} \quad (14)$$

其中, w_{ij} 表示真实类别 i 指向类别 j 的非对称混淆权重, τ 为混淆阈值, $\mathbf{W} = [w_{ij}]$ 为非对称混淆权重矩阵, m_{ij} 表示混淆矩阵中第 i 类被误判为第 j 类的频率, r 表示用于归一化时遍历第 i 行混淆值的类别索引。

接着仅对正样本锚点 $i \in \mathcal{P}$ 计算加权 KL 散度:

$$\mathcal{L}_{\text{rob}} = \sum_{i \in \mathcal{P}} \sum_{j \in \mathcal{C}} w_{c_i, j} \cdot p_{i, j}(\mathbf{x}) \cdot \ln \left(\frac{p_{i, j}(\mathbf{x})}{p_{i, j}(\mathbf{x}_{\text{adv}})} \right) \quad (15)$$

其中, $\mathcal{L}_{\text{rob}}$ 为鲁棒性损失, $w_{c_i, j}$ 表示当前真实类别 c_i 指向类别 j 的混淆权重, $p_{i, j}(\mathbf{x})$ 表示第 i 个正样本锚点在干净样本上属于类别 j 的预测概率, $p_{i, j}(\mathbf{x}_{\text{adv}})$ 表示第 i 个正样本锚点在对抗样本上属于类别 j 的预测概率。

该设计具有三重优势: (1) 仅在正样本锚点上施加约束, 避免背景锚点稀释; (2) 权重 $w_{c_i, j}$ 非对称, 符合混淆方向性; (3) 仅对符合 $m_{ij} > \tau$ 的易混淆类别对施加约束, 聚焦训练资源。

最终损失函数为:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{cls}} + \lambda_{\text{rob}} \mathcal{L}_{\text{rob}} + \lambda_{\text{loc}} \mathcal{L}_{\text{loc}}(\mathbf{x}_{\text{adv}}) + \lambda_{\text{df}} \mathcal{L}_{\text{df}}(\mathbf{x}_{\text{adv}}) \quad (16)$$

其中, $\mathcal{L}_{\text{total}}$ 为总损失函数, λ_{rob} 表示鲁棒分布对齐项的损失权重, λ_{loc} 为定位损失权重, λ_{df} 为分布焦点损失权重, 用于进一步约束对抗样本的框回归稳定性。

2.6 训练算法

算法 1 总结了本文提出的混淆感知对抗训练流程。

算法 1 混淆感知对抗训练 (CA-TRADES)。

输入: 训练集 D_{train} , 初始模型参数 θ , 最大扰动 ε , 迭代步数 K , 混淆阈值 τ ;

输出: 鲁棒模型参数 θ^* 。

- 1) 初始化混淆矩阵: 使用 θ 在 D_{train} 上进行推理, 计算初始混淆矩阵 $\mathbf{M}$
- 2) 构建差异模板库 $\mathcal{T}$ 并在后续全部训练轮次中保持静态冻结
- 3) For 每个易混淆类别对 (m, n) do

- 4) 利用 θ 生成类别 m 与 n 的注意力热力图 $\mathbf{H}_i, \mathbf{H}_j$
- 5) 计算差异图 $\Delta \mathbf{H} = |\mathbf{H}_i - \mathbf{H}_j|$, 经阈值分割与形态学平滑得到掩膜 $\mathbf{T}_{mn}$
- 6) 存入模板库 $\mathcal{T}$
- 7) end for
- 8) for $t = 1$ to N_{max} do (N_{max} 为总训练轮数)
- 9) for 每个批次 $B \subset D_{\text{train}}$ do
- 10) for 每个样本 do
- 11) 基于 $\mathbf{M}$ 获取最易混淆目标 c_i^* (式(9)), 从 $\mathcal{T}$ 中提取对应掩膜经变换后得到 $\mathcal{A}$ (式(11))
- 12) 通过 BDAP 生成 3 组扰动 $\delta_{\text{cls}}, \delta_{\text{loc}}, \delta_{\text{df}}$
- 13) 融合扰动得到 δ_{adv} (式(4))
- 14) 施加 SMC 约束
- 15) 生成对抗样本 $\mathbf{x}_{\text{adv}}$
- 16) end for
- 17) 计算 CA-TRADES 总损失 $\mathcal{L}_{\text{total}}$ (式(16))
- 18) 基于 $\mathcal{L}_{\text{total}}$ 进行反向传播
- 19) 优化器更新模型参数
- 20) end for
- 21) end for
- 22) return θ^*

3 实验与结果分析

3.1 实验设定

3.1.1 数据集构建与标定

本文实验基于自建的水表数据集, 通过实地采集获得, 覆盖多个居民小区、工业园区及公共建筑中的机械式水表和智能水表, 如图 6 所示。具体的构建过程包括以下 5 个方面。

1) 采集设备与光照控制。

所有图像均使用专业抄表器拍摄, 设备内置双侧对称补光灯管, 可有效消除表盘玻璃反光。由于不同水表表盘底色、材质及安装环境存在差异, 原始图像仍存在局部光照波动与色温偏移, 该类不一致性后续统一交由数据增强模块进行解决。

2) 清晰度筛选与标注原则。

原始图像经人工初筛, 遵循“人眼可辨识即标注”原则: 数字主体轮廓与笔画结构可被正常人眼清晰识别则纳入标注, 否则直接剔除该图片。确保标注质量与模型学习目标的一致性。

3) 标注流程与格式转换。

标注工作采用 labelimg 工具完成, 初始格式为 VOC 格式, 增强阶段统一转换为 YOLO 标准格式。

4) 标注准确性校验机制。

针对水表读数单向递增的物理特性, 本文设计了基于时间序列的自动化校验方法: 对同一设备、同一水表在连续周期拍摄的图片, 校验"后一周周期读数 $\geq$ 前一周周期读数"。若出现反向跳变则触发人工复核, 以此来确保标注结果的准确性。

5) 数据增强与极端场景模拟。

所有图像在增强前均先经过摆正预处理, 消除因拍摄角度导致的整体倾斜, 为模拟实际抄表中的真实场景, 本文实施了一系列的增强策略: ①引入小幅度随机旋转与缩放, 模拟抄表器安装过程中存在的角度偏差与高度差异, 使模型适应非严格正视角的拍摄条件; ②HSV 色彩扰动与明暗调节模拟光照变化、白平衡差异及表盘底色导致的光照不均; ③脏背景叠加与整体压暗还原水垢、灰尘、污斑等老化特征; ④鱼眼膨胀模拟近距离拍摄或弧形玻璃盖引起的局部形变; ⑤大气泡遮挡与区域噪声注入模拟水滴冷凝、划痕反光及传感器噪声。上述增强均以物理可解释性为原则, 严格控制参数范围。

在增强样本构成上, 本文保留约 30% 的原始图像, 以维持真实采集场景下的图像分布; 其余约 70% 的样本由不同类型的物理退化增强生成, 包括光照扰动、局部遮挡、污渍叠加、轻微形变和区域噪声等。该设置使训练数据在保持数字类别总体均衡的同时, 覆盖更多复杂成像条件下的水表读数样本。由于结构相似数字在模糊、反光、磨损或遮挡情况下更容易出现判别边界模糊, 该增强比例有助于增加模型对实际难例场景的学习机会。

最终, 原始 98000 张图像 (320×240) 经增强与后变为 320×320 , 随机划分为训练集 (80000 张) 与测试集 (18000 张)。



图 6 水表图像示例

Fig. 6 Water meter image samples

3.1.2 对比方法

为验证本文方法在水表读数识别任务中的有效性, 本文首先选取多种具有代表性的读数识别方法进行对比, 包括 CRNN^[14]、TrOCR^[16]、RobustScanner^[23]和 PP-OCRv3^[24]等 OCR 类方法, 以及 YOLOv11 检测模型。其中, CRNN^[14]是基于 CNN、RNN 和 CTC 的经典序列识别方法; TrOCR^[16]采用 Transformer 编码器—解码器结构进行端到端文本识别; RobustScanner^[23]通过融合视觉特征与位置信息增强无语义

字符序列的识别鲁棒性, 适用于数字串等弱语义文本识别场景; PP-OCRv3^[24]是 PaddleOCR 系列中较成熟的轻量化工程 OCR 方法, 在文本检测、方向分类和文本识别方面具有较好的工程化部署能力。对于 OCR 类方法, 本文将水表读数区域裁剪为单行数字图像, 并根据数字标注框的横坐标顺序生成读数字符串标签进行训练或评价; 对于 YOLOV11 及本文方法, 则采用数字框标注进行检测式训练, 并在推理阶段按照预测框横坐标排序得到最终读数。

在对抗攻击方法对比方面, 为全面评估本文提出的 PGD-BS 攻击方法的有效性, 本文选择了一系列具有代表性的对抗攻击方法进行比较。这些方法包括 FGSM^[4]、PGD^[5]、C&W^[7]和 AA^[17]等经典攻击方法, LaVAN^[8]、AP^[9]、OPA^[10]等局部扰动攻击方式, 以及近年来提出的具有代表性的改进攻击方法, 如 DiffAttack^[25]、DifAttack^[26]和 AFOG(Attention-Focused Offensive Gradient)^[27]。与这些攻击方法不同, 本文提出的 PGD-BS 攻击方法在保持定位稳定性的同时, 通过语义引导的扰动生成机制聚焦于易混淆数字对的差异笔画区域, 模拟真实场景中的白点遮挡、边缘磨损等物理伪影, 使扰动具有物理可解释性。

在对抗训练方法对比方面, 本文选取了多种主流的对抗训练方法进行比较。包括 PGD-AT^[28]、TRADES^[11]、MART^[12]、FAT^[13]、平滑对抗训练(Smooth Adversarial Training, SAT)^[29]、Adversarial Training with Learnable Attack Strategy(LAS-AT)^[30]等经典方法, PGD-AT 采用标准 PGD 攻击生成对抗样本进行训练; SAT 则引入课程学习策略平滑损失曲面以稳定训练过程; MART 引入误分类感知机制, 对导致模型误判的对抗样本施加更高的惩罚权重以增强难例学习; LAS-AT 利用强化学习自动搜索最优攻击参数以实现自适应对抗训练。这些方法虽然在通用图像分类任务中表现良好, 但在水表读数识别这一特定场景下存在局限性, 尤其是无法有效处理易混淆数字对的分类错误和定位稳定性问题。

3.1.3 实验细节

本文所有实验在一台搭载 Intel Xeon Silver 4210R 处理器和 NVIDIA Tesla P40 图形计算卡的 Linux 平台上进行。

在实验实现方面, 本文采用 YOLOV11 作为基础检测模型, 在自建的水表读数识别数据集上进行对抗训练实验。优化器选用随机梯度下降 (Stochastic Gradient Descent, SGD) 优化器, 动量大小设置为 0.937, 权重衰减系数为 5×10^{-4} 。训练过程共进行 60 轮, 初始学习率设为 0.01, 批量大小设置为 48。在训练方式上, 本文采用在线对抗样本生成策略, 即在每次迭代中针对当前 mini-batch 中的每个干净样本生成 1 个对应的对抗样本, 因此干净样本与对抗样本按 1:1 的配对方式参与训练; 模型更新时同时计算干净样本上的自然检测损失以及干净样本与对抗样本之间的方向性鲁棒损失, 并通过损失权重系数进行联合优化。针对攻击策略参数, 扰动边界上限初始值设为 2, 当训练阶段的鲁棒损失连续 5 轮不下

降时,提升一次攻击强度,每次需要增加2直至最大值8;迭代次数初始值设为1,每次增强时增加1直至最大值10;每次迭代的攻击步长固定为2,最终将扰动边界和攻击步长除以255进行归一化处理。在阈值设置上,本文通过多次实验确定了混淆阈值为0.005。此外,为保证公平比较,本文在统一扰动预算 $\epsilon=8/255$ 下比较各方法,保持其余训练设置一致,对于 L_∞ 范数下的所有攻击方法,扰动边界上限统一设置为8,这些实现细节共同确保了实验结果的可靠性。

为保证对比实验的公平性,所有基于图像分类设计的对抗训练基线(TRADES、MART、FAT、SAT、LAS-AT)均按照目标检测任务的标准范式进行适配。具体而言:

1) 损失作用域:基线方法的对抗正则化项仅作用于检测网络的分类头,不直接耦合至边界框回归与置信度分支,以避免破坏YOLO系列默认的几何回归稳定性;

2) 正负样本处理:基线损失计算严格遵循YOLOV11的标签分配策略,仅将对抗正则化施加于IoU匹配成功的正样本预测单元,背景预测点仅参与原始检测损失计算,从而避免海量负样本稀释鲁棒训练信号;

3) 超参数对齐:基线方法的对抗预算、迭代步数及平衡系数均与本文方法保持一致,并通过预实验确定统一的参数配置。

上述适配策略遵循了近期目标检测对抗训练工作的通用实践^{[31][32]},保障了基线对比的公平性与可复现性。

3.2 OCR与目标检测方法在水表读数识别中的性能对比

为全面评估本文方法在水表读数识别任务中的性能,本文选取经典OCR模型CRNN^[14],以及近年来具有代表性的TrOCR^[16]、RobustScanner^[23]和PP-OCrv3^[24]等OCR方法进行对比,以及YOLOV11模型和本文方法进行对比。对于OCR类方法,将水表读数区域裁剪为单行数字图像,并根据数字标注框的横坐标顺序生成读数字符串标签;对于目标检测类方法,使用数字框标注进行训练,并在推理阶段按照预测框横坐标排序得到最终读数。实验结果如表1所示。

表1 不同读数识别方法在水表测试集上的性能对比

单位: %

Tab. 1 Performance comparison of different reading recognition methods on water meter test set

unit: %		
方法类型	方法	识别准确率
OCR 方法	CRNN ^[14]	57.00
	TrOCR ^[16]	86.00
	RobustScanner ^[23]	85.20
	PP-OCrv3 ^[24]	93.00
	YOLOV11	93.30
目标检测方法	本文方法	95.80

由表1可见,不同读数识别方法在水表测试集上的识别准确率存在明显差异。其中,CRNN作为经典序列识别模型,识别准确率最低,说明传统CNN-RNN-CTC结构在复杂水表图像中对数字序列特征的表达能力有限。相比之下,TrOCR、RobustScanner和PP-OCrv3分别通过Transformer序列建模、视觉与位置信息融合以及工程化OCR框架提升了读数字符串的识别能力,其中在水表数据集上目前PP-OCrv3在OCR类方法中取得了最高识别准确率。YOLOV11通过检测式建模保留了单个数字的空间位置信息,取得了较好的识别效果;本文方法在YOLOV11基础上进一步增强了对水表数字特征的判别能力,识别准确率达到95.80%,在所有方法中表现最优,说明本文方法能够有效提升水表读数识别性能。

3.3 不同对抗攻击方法的攻击成功率对比

为验证本文提出的对抗攻击方法在水表读数识别场景下的有效性,本节对比了多种对抗攻击方法在自建水表数据集上的攻击成功率,结果如表2所示。实验采用经过标准训练的YOLOV11模型作为目标模型,评估各攻击方法在固定扰动预算($\epsilon=8/255$)下生成对抗样本的能力。攻击成功率定义为:在测试集上,对抗样本导致模型预测结果与原始标签不一致的样本比例;攻击有效率的定义:要求误判结果主要集中在易混淆数字对上,避免引入无关错误类别。

表2 不同对抗攻击方法在自建水表数据集上的攻击效果对比

Tab. 2 Comparison of attack effects of different adversarial attack methods on self-built water meter datasets

方法类型	攻击方法	攻击成功率/%	攻击有效率/%	定位偏移量/px(像素)
全局扰动	FGSM ^[4]	68.23	46.15	5.2
	PGD ^[5]	76.85	58.42	4.8
	C&W ^[7]	82.17	63.58	4.0
	AA ^[17]	85.64	65.73	4.3
	DiffAttack ^[25]	84.57	67.21	3.6
	DifAttack ^[26]	82.11	61.34	4.0
	AFOG ^[27]	85.97	66.41	5.3
局部扰动	LaVAN ^[8]	65.30	41.27	4.7
	API ^[9]	78.15	52.64	4.1
	OPA ^[10]	12.45	5.38	0.5
	本文方法	86.51	75.84	2.2

从表2可以看出,本文方法在攻击成功率、攻击有效率与定位稳定性三方面均取得了最优的综合性能。在攻击成功率方面,本文方法达到86.51%,优于各类全局扰动方法(如AA的85.64%、AFOG的85.97%)及局部扰动方法,展现出更强的攻击有效性。

在攻击有效率方面，现有方法普遍表现不佳。全局扰动方法中攻击有效率最高的 AFOG 仅为 66.41%，AA 为 65.73%，DiffAttack 为 67.21%；局部扰动方法中 LaVAN 和 AP 分别仅为 41.27% 和 52.64%。造成这一现象的原因主要有两方面：

一，扰动生成缺乏语义引导。现有全局扰动方法采用均匀扰动策略，未聚焦于易混淆数字对的关键差异笔画区域，导致扰动能量分散，误判方向随机，难以稳定诱导特定数字混淆；局部扰动方法虽限制扰动范围，但未考虑数字笔画的语义结构，易在背景区域生成无意义噪声，同样无法精准聚焦于易混淆方向。

二，定位偏移过大导致检测框失稳。从表 2 可见，全局扰动方法的定位偏移量普遍在 4.0~6.0 像素之间，目标区域定位失准，即使扰动成功误导分类，也可能因检测框偏移而误判为无关类别，而非预定义的易混淆数字对。局部扰动方法中，OPA 虽定位偏移极小，但单像素扰动强度过弱，攻击成功率仅 12.45%，攻击有效率更是低至 5.38%。

相比之下，本文方法通过分支解耦与语义形态约束的协同作用，在保持最高攻击成功率的同时，将定位偏移严格控制在 2.2 像素，并使攻击有效率达到 75.84%，显著优于其他方法。这表明本文方法生成的对抗样本能够更精准地聚焦于易混淆数字对的差异笔画区域，避免引入无关错误类别，同时抑制定位框抖动，更适用于水表读数识别这一定位精度要求较高的场景。



图 7 同一水表样本在不同攻击方法下的对抗扰动可视化与模型输出对比

Fig. 7 Comparison of adversarial perturbation visualization and model outputs of same water meter sample under different attack methods

为更直观地比较不同攻击方法在同一样本上的作用差异，图 7 给出了该水表样本在不同攻击方式下的对抗扰动可视化结果及对应的模型输出。可以看出，在该示例中，部分传统攻击方法虽然对目标局部区域产生了扰动，并引起置信度下降或检测中心位置的轻微变化，但模型仍保持对原类别的判别；相比之下，本文提出的 PGD-BS 能够在关键数字区域形成更具针对性的局部扰动，使模型输出沿预设易混淆方向发生改变。与此同时，它的检测中心位置变化相对有限，说明该方法在增强定向混淆攻击能力的同时，仍较好地保持了定位稳定性。该可视化结果与表 1 中本文方法在攻击有效率和定位偏移量上的优势是一致的。

3.4 不同对抗防御方法的鲁棒性对比

为验证本文提出的对抗防御方法在水表读数识别场景下的有效性，对比多种对抗训练方法在干净样本和对抗样本上的性能表现，结果如表 3 所示。

表 3 自建水表数据集上不同对抗训练框架鲁棒性测试结果 单位：%

Tab. 3 Robustness test results of different adversarial training frameworks on self-built water meter dataset unit: %

方法	干净样本和不同攻击下的对抗鲁棒性精度					
	Clean	FGSM	PGD	AA	C&W	本文对抗攻击方法
Baseline	93.30	-	-	-	-	-
PGD-AT ^[28]	89.45	42.38	48.26	36.84	41.92	35.72
TRADES ^[11]	91.60	45.76	42.23	39.53	41.78	44.01
LAS-AT ^[30]	90.97	47.21	43.89	45.05	43.27	39.64
MART ^[12]	90.12	45.85	42.12	40.76	42.68	40.55
FAT ^[13]	89.20	48.45	44.06	42.59	40.03	41.88
SAT ^[29]	90.55	46.92	43.50	41.76	43.50	40.20
本文方法	95.80	51.87	46.54	43.29	47.63	46.47

从表 3 数据可以看出，本文提出的 CA-TRADES 训练方法在水表读数识别任务中展现出显著的性能优势。首先，与未经对抗训练的 Baseline 模型（YOLOV11 标准训练）相比，

在干净样本测试中，本文方法的准确率达到 95.8%，较 Baseline 的 93.30% 提升了 2.50 个百分点，为所有对比方法中最高。在对抗鲁棒性方面，本文方法在 5 项评估指标中的 3

项取得最优性能,在 PGD 和 AA 攻击下虽略低于部分对比方法(PGD-AT 在 PGD 攻击下为 48.26%, LAS-AT 在 AA 攻击下为 45.05%),但仍保持在较高水平。与 TRADES 相比,本文方法在 FGSM 攻击下的准确率比 TRADES 高出 6.11 个百分点,在 PGD 攻击下比之高出 4.31 个百分点,在 AA 攻击下比之高出 3.76 个百分点,在 C&W 攻击下比之高出 5.85 个百分点,在本文对抗攻击下比之高出 2.46 个百分点。这些数据充分证明了该方法能够有效抵御多种标准对抗攻击,显著提升了模型的鲁棒性。

为进一步验证本文方法对自建水表数据集中关键难例样本的改善效果,在整体测试集鲁棒性对比的基础上,本文进一步构建易混淆难例子集进行对比分析。具体而言,首先依据离线混淆矩阵统计结果确定高频易混淆数字对,然后从测试集中筛选真实数字类别属于这些易混淆数字对的水表图片构成难例子集,约 11000 张。实验结果如表 4 所示。

由表 4 可以看出,在易混淆难例子集上,Baseline 模型的 Clean 精度为 88.40%,易混淆误判率为 10.90%,说明标准训练模型对结构相似数字对的细粒度判别能力仍然不足。PGD-AT 和 MART 虽然引入了对抗训练,但它的优化目标主要面向一般扰动鲁棒性,缺乏对具体混淆方向的约束,因此易混淆误判率仍分别达到 13.25%和 14.07%。相比之下,本文方法在 Clean、PGD 和 PGD-BS 指标上均取得最优结果,分别达到 91.85%、44.92%和 45.11%,同时易混淆误判率最低,仅为 7.85%。与 TRADES 相比,本文方法在 Clean、PGD 和 PGD-BS 下分别提升 4.93、5.17 和 3.79 个百分点,易混淆误判率降低 4.51 个百分点。结果表明,CA-TRADES 能够将鲁棒训练重点集中于高风险易混淆类别对,有效降低结构相似数字之间的方向性误判概率,进一步验证了本文方法在自建水表数据集关键难例场景下的有效性。

表 4 易混淆难例子集上不同对抗训练方法的鲁棒性对比 单位: %

Tab. 4 A comparison of robustness of different adversarial training methods on confusing and difficult example sets unit: %

方法	干净样本和不同攻击下的鲁棒性精度			Clean-易混淆误判率
	Clean	PGD	PGD-BS	
Baseline	88.40	-	-	10.90
PGD-AT ^[28]	84.75	41.36	33.46	13.25
TRADES ^[11]	86.92	39.75	41.32	12.36
MART ^[12]	85.63	40.04	38.67	14.07
本文方法	91.85	44.92	45.11	7.85

这些结果表明通过将分支解耦对抗扰动、语义形态约束与混淆感知 TRADES 相结合,实现了针对水表读数识别场景中易混淆数字对问题的定制化对抗训练框架,既保持了良好的自然准确率,又显著提升了模型对定向混淆攻击的抵抗能力。

为更直观地展示本文方法对关键易混淆类别对误判模式的抑制效果,图 8 展示了不同模型在典型易混淆数字样本上的预测情况。可以看出,除本文方法外,其余模型均将结构相似数字误判为其他类别,而本文方法能够给出正确预测,进一步验证了 CA-TRADES 对易混淆数字对的判别能力。

图 9 展示了 Baseline、TRADES 与本文方法在测试集上的归一化混淆矩阵对比结果。由图 9 可见,相较于 Baseline 和 TRADES,本文方法在若干关键易混类别对对应的非对角元素处混淆程度明显降低,而相关类别在对角线位置的响应则有所增强,表明模型对结构相似数字的判别能力得到了有效提升。上述结果说明,本文提出的混淆感知训练策略能够将鲁棒优化更有针对性地集中于高风险混淆方向,从而有效降低易混淆数字之间的误判概率。该观察结果与表 2 中本文方法在干净样本及多种攻击条件下取得更优鲁棒性精度的实验结论相互印证。




图 8 不同模型在易混淆数字样本上的预测结果对比

Fig. 8 Comparison of prediction results of different models on confusing digit samples




图 9 Baseline、TRADES 与本文方法在测试集上的归一化混淆矩阵对比

Fig. 9 Comparison of normalized confusion matrices of Baseline, TRADES and proposed method on test set

3.5 消融实验

3.5.1 对抗攻击方法消融实验

为验证本文方法中各组件的有效性，本节进行了全面的消融实验。表 5 展示了不同攻击方法变体在水表读数识别数据集上的攻击效果对比结果。

表 5 自建水表数据集上不同对抗攻击方法效果对比

Tab. 5 Comparison of effects of different adversarial attack methods on self-built water meter dataset

攻击方法	攻击成	攻击有效	定位偏移量
------	-----	------	-------

	功率/%	率/%	/px(像素)
PGD ^[5]	76.85	58.42	4.8
PGD+BDAP	78.72	60.20	2.8
PGD+SMC	80.17	69.44	5.0
PGD-BS	86.51	75.84	2.2

从表中可以看出，本文提出的攻击方法在攻击成功率方面显著优于其他对比方法，比传统方法 PGD 高出 9.66 个百分点。同时，本文方法在定位偏移量上表现出色，仅为 2.2 像素，比 PGD 攻击降低了 2.6 像素，表明本文方法在保持攻击有效性的同时有效控制了定位稳定性。值得注意的是，仅添加 BDAP 组件的 PGD+BDAP 方法虽然降低了定位偏移量至 2.8 像素，但攻击成功率仅比 PGD 提高了 1.87 个百分点；

而仅添加 SMC 组件的 PGD+SMC 方法虽然提高了攻击成功率至 82.17%，但定位偏移量反而增加至 5.0 像素。相比之下，本文方法通过将 BDAP 和 SMC 两个组件有机结合，实现了攻击成功率和定位稳定性的双重优化，验证了本文提出的对抗攻击方法在水表读数识别场景中的有效性。

3.5.2 对抗防御方法消融实验

为验证 CA-TRADES 中各防御组件的必要性，本文设计了递进式消融实验，从 TRADES 基线出发，逐步引入仅正样本 KL、非对称混淆权重、方向性 KL 散度更新等组件，最终形成完整的 CA-TRADES 方法。表 6 展示了各变体在干净样本及不同攻击下的鲁棒精度对比。

表 6 自建水表数据集上防御侧组件消融实验结果对比
单位：%

Tab. 6 Ablation study results of defense-side components on self-built water meter dataset
unit: %

实验配置	干净样本和不同攻击下的鲁棒性精度			
	Clean	PGD	AA	本文攻击方法
TRADES ^[1]	91.60	42.23	39.53	44.01
TRADES+仅正样本 KL	92.15	43.85	40.90	44.09
TRADES+正样本 KL+非对称权重	93.20	45.10	42.15	45.75
本文方法	95.80	46.54	43.29	46.47

表 6 的消融实验结果表明，CA-TRADES 各防御组件的引入均带来显著的性能增益。在 TRADES 基线上仅施加正样本 KL 约束后，干净样本的精度与 PGD/AA 攻击下的鲁棒精度均有提升，验证了规避背景锚点信号稀释的有效性；进一步引入非对称混淆权重后，模型训练资源向高频易混淆对倾斜，各项指标继续优化。最终完整的 CA-TRADES 通过融合方向性 KL 散度与阈值门控机制，较基线在干净精度、PGD、AA 及本文定向攻击下分别提升 4.20、4.31、3.76 和 2.46 个百分点。该递进式结果充分证明，本文策略有效克服了传统防御中信号分散与混淆方向感知不足的缺陷，在维持自然准确率的同时增强了定向对抗鲁棒性。

表 8 不同方法的训练成本与推理效率对比

Tab. 8 Comparison of training cost and inference efficiency among different methods

方法	单 epoch 耗时/h	预处理开销/h	推理速度/fps	单张耗时/ms
YOLOV11	0.75-0.8	0	98.5 ± 5.7	10.15 ± 0.58
PGD-AT	4.8-5.6	0	96.0 ± 7.4	10.41 ± 0.80
TRADES	5.2-6.0	0	99.6 ± 4.2	10.04 ± 0.43
本文方法	5.8-7.1	1.2	98.1 ± 7.7	10.19 ± 0.80

从工程实用性角度分析，本文方法具有以下特点：

为验证本文提出的混淆阈值 τ 对模型性能的影响，本文进行了系统的参数敏感性分析。表 7 展示了在不同混淆阈值下，本文方法在干净样本和各类攻击下的鲁棒精度对比结果。由于混淆阈值 τ 直接决定非对称混淆权重矩阵的稀疏程度及方向性约束的作用范围，因此它的取值将显著影响模型对关键易混淆类别对的聚焦能力。通过系统地调整混淆阈值 τ ，能够评估它对模型训练效果的敏感性，从而确定最优参数设置。

表 7 不同混淆阈值 τ 下本文方法的鲁棒精度对比结果
单位：%

Tab. 7 Comparison results of robustness precision of proposed method under different confusion thresholds

τ	干净样本和不同攻击下的鲁棒性精度			
	Clean	PGD	AA	本文攻击方法
0.003	91.12	42.21	42.76	42.18
0.004	93.61	44.53	41.89	44.56
0.005	95.80	46.54	43.29	46.47
0.006	92.49	44.98	42.37	43.43
0.007	92.22	45.71	42.93	41.62

实验结果表明，随着混淆阈值 τ 的变化，模型性能呈现出规律性变化。当 τ 值过小时，过多低风险混淆对被纳入训练，导致训练信号分散；当 τ 值过大时，部分真实易混淆对被忽略，降低了训练效果。在所有测试的 τ 值中，当 $\tau=0.005$ 时，本文方法在 PGD 和 AA 攻击下均取得最佳性能，同时保持最高的干净样本精度。这一结果表明，适当的混淆阈值能够有效平衡训练信号的聚焦性与覆盖范围。最终，本文选择 $\tau=0.005$ 作为最佳混淆阈值，因为它在保证干净样本精度的同时，最大化了模型的对抗鲁棒性。

3.5.3 计算复杂度与部署分析

为全面评估本文方法的工程实用性，本节从训练成本与推理效率两个维度，对比了本文方法与其他方法的计算特性，如表 8 所示。训练成本包括单轮 epoch 耗时与离线预处理开销，其中预处理开销指混淆矩阵构建与差异模板库生成的一次性离线计算成本；推理效率通过推理速度与单张图像平均耗时衡量。

(1) 训练成本可控：单 epoch 耗时约是基线单 epoch 耗时的 7~9 倍，但该量级与 TRADES 等主流对抗训练框架相当，属于对抗训练的正常计算代价；此外，1.2 h 的预处理环节为一次性离线任务，在 60 轮完整训练周期中的时间占比极低（不足 3%），整体训练投入完全在工程可接受范围内；

(2) 推理零开销：本文方法的推理速度与单帧耗时均与基线 YOLOV11 无显著差异，充分印证了“训练阶段定向增强、推理阶段零额外计算”的设计原则，支持直接替换现有部署模型权重，无需重构推理流水线；

(3) 部署友好：所有方法推理阶段模型结构完全一致，仅训练策略不同，本文方法在保持实时性的同时显著提升了鲁棒性，符合水表识别系统“一次训练、长期部署、高频调用”的典型应用场景需求。

3.6 基础模型适配性分析

本文选择 YOLOV11 作为基础检测模型，主要是因为水表读数识别属于小目标工业视觉任务，对检测精度、推理速度和部署便利性均有较高要求。YOLOV11 具有多尺度特征表示和解耦检测头结构，能够较清晰地区分分类预测、边界框回归和分布焦点损失回归过程，便于在训练阶段分别构建分类扰动、定位扰动和 DFL 扰动。因此，YOLOV11 适合作为验证本文混淆感知对抗训练框架有效性的基础检测器。

需要指出的是，本文提出的 PGD-BS 与 CA-TRADES 并非仅适用于 YOLOV11。该框架主要依赖目标检测模型中的类别概率输出、边界框回归结果、正样本匹配机制以及分类/定位损失接口，而不依赖 YOLOV11 的特定网络层结构。只要基础检测器能够提供上述信息，本文方法在原则上即可通过调整输出解析、正样本索引和损失接口进行迁移。

对于 YOLOV8、YOLOV10 等与 YOLOV11 结构相近的单阶段检测模型，由于它们同样具有解耦检测头和 DFL 回归机制，适配难度相对较低，主要需要调整输出张量格式、正样本匹配索引和损失函数调用方式。对于 YOLOV5、YOLOV7 等 anchor-based 检测器，迁移时需要额外考虑 objectness 分支的影响，避免对抗扰动过度作用于置信度分支而导致目标被误判为背景，从而偏离本文关注的数字间方向性混淆问题。

对于 Faster R-CNN、Mask R-CNN 等两阶段检测器，迁移难点主要在于它们包含区域候选网络（Region Proposal Network, RPN）候选区域生成和感兴趣区域（Region of Interest, ROI）分类回归两个阶段，正样本定义和混淆统计对象与 YOLO 系列不同，因此需要重新界定扰动作用位置、混淆矩阵统计粒度和方向性 KL 约束范围。对于 DETR(Detection Transformer)、RT-DETR(Real-Time Detection Transformer)等 query-based 检测器，由于它们依赖 object query 和匈牙利匹配机制，正样本分配方式、类别预测过程和

损失计算方式均与 YOLO 系列差异较大，直接迁移可能引入匹配不稳定和鲁棒损失难以对齐等问题，适配难度更高。

综上，本文方法在思想上具有较好的模型无关性，但在工程实现上需要根据不同基础检测器的检测头结构、标签分配策略和损失组成进行适配。

4 结语

本文针对水表读数识别中易混淆数字对导致的精度瓶颈问题，提出了一种混淆感知的攻防一体对抗训练框架，从理论层面揭示了传统对抗攻击方法在目标检测场景下全局扰动与定位稳定性冲突的本质矛盾，以及传统对抗防御方法因背景锚点稀释而难以聚焦方向性混淆模式的局限性；在方法层面，通过在 PGD 攻击基础上引入分支解耦对抗扰动与语义形态约束，实现了定向的攻击生成机制，并加入了混淆感知的 TRADES 防御框架，将训练资源集中于真实易混淆对，形成了有效的攻防闭环协同。然而，本研究仍存在一定局限：混淆阈值依赖人工设定，未来可探索基于训练反馈的自适应调整机制；可微形态学约束对复杂光照与遮挡变化的泛化能力有待提升；且计算开销相比标准对抗训练有所增加（主要源于离线预计算阶段）。未来工作将探索轻量化形态约束设计以降低计算成本，并将本方法扩展至其他存在方向性混淆的视觉识别任务，进一步提高本文方法的泛化能力与工程实用性。

参考文献

- [1] 傅松寅, 王让定, 姚灵, 等. 适用于多层住宅楼结构的无线智能水表抄表系统[J]. 计算机应用, 2017, 37(1): 170-174. (Fu Songyin, Wang Rangding, Yao Ling, et al. Smart wireless water meter reading system for multi-story residential buildings[J]. Journal of Computer Applications, 2017, 37(1): 170-174.)
- [2] Zhang S, Chen S, Liu X, et al. Detecting adversarial samples for deep learning models: a comparative study[J]. IEEE Transactions on Network Science and Engineering, 2021, 9(1): 231-244.
- [3] Chen T, Wei J, He S Y, et al. Adversarial training method with adaptive attack strength[J]. Journal of Computer Applications, 2024, 44(1): 94-100.
- [4] Goodfellow I J, Shlens J, Szegedy C. Explaining and harnessing adversarial examples[PP/OL]. V3. arXiv (2015-03-20) [2025-11-10]. <https://arxiv.org/pdf/1412.6572.pdf>.
- [5] Madry A, Makelov A, Schmidt L, et al. Towards deep learning models resistant to adversarial attacks[PP/OL]. V4. arXiv (2019-09-04) [2025-11-10]. <https://arxiv.org/pdf/1706.06083.pdf>.
- [6] Kurakin A, Goodfellow I, Bengio S. Adversarial examples in the physical world[PP/OL]. V4. arXiv (2017-02-11) [2025-09-21]. <https://arxiv.org/pdf/1607.02533.pdf>.
- [7] Carlini N, Wagner D. Towards evaluating the robustness of neural networks[C]// 2017 IEEE Symposium on Security and Privacy. Piscataway: IEEE, 2017: 39-57.
- [8] Karmon D, Zoran D, Goldberg Y. LaVAN: localized and visible adversarial noise[C]// ICML 2018. New York: JMLR.org, 2018: 2507-2515.

- [9] Brown T B, Mané D, Roy A, et al. Adversarial patch[PP/OL]. V2. arXiv (2018-05-17) [2025-11-10]. <https://arxiv.org/pdf/1712.09665.pdf>.
- [10] Su J, Vargas D V, Sakurai K. One pixel attack for fooling deep neural networks[J]. IEEE Transactions on Evolutionary Computation, 2019, 23(5): 828-841.
- [11] Zhang H, Yu Y, Jiao J, et al. Theoretically principled trade-off between robustness and accuracy[C]// ICML 2019. New York: JMLR.org, 2019: 7472-7482.
- [12] Wang Y, Zou D, Yi J, et al. Improving adversarial robustness requires revisiting misclassified examples[C/OL]// ICLR 2020. [2026-06-01]. <https://openreview.net/forum?id=rkIOg6EFwS>.
- [13] Zhang J, Xu X, Han B, et al. Attacks which do not kill training make adversarial learning stronger[C]// ICML 2020. New York: JMLR.org, 2020: 11278-11287.
- [14] Shi B G, Bai X, Yao C. An end-to-end trainable neural network for image-based sequence recognition and its application to scene text recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(11): 2298-2304.
- [15] Du Y N, Li C X, Guo R Y, et al. PP-OCR: a practical ultra lightweight OCR system[PP/OL]. V3. arXiv (2020-10-15) [2026-06-01]. <https://arxiv.org/pdf/2009.09941.pdf>.
- [16] Li M H, Lv T C, Chen J Y, et al. TrOCR: transformer-based optical character recognition with pre-trained models[C]// AAAI 2023. Palo Alto: AAAI Press, 2023: 13094-13102.
- [17] Croce F, Hein M. Reliable evaluation of adversarial robustness with an ensemble of diverse parameter-free attacks[C]// ICML 2020. New York: JMLR.org, 2020: 2206-2216.
- [18] Croce F, Hein M. Minimally distorted adversarial examples with a fast adaptive boundary attack[C]// ICML 2020. New York: JMLR.org, 2020: 2196-2205.
- [19] Andriushchenko M, Croce F, Flammarion N, et al. Square attack: a query-efficient black-box adversarial attack via random search[C]// ECCV 2020. Cham: Springer, 2020: 484-501.
- [20] Kullback S, Leibler R A. On information and sufficiency[J]. The Annals of Mathematical Statistics, 1951, 22(1): 79-86.
- [21] Khanam R, Hussain M. YOLOv11: an overview of the key architectural enhancements[PP/OL]. V1. arXiv (2024-10-23) [2025-11-10]. <https://arxiv.org/pdf/2410.17725.pdf>.
- [22] Pham T M A. Overview of class activation maps for visualization explainability[PP/OL]. V1. arXiv (2023-09-25) [2025-11-10]. <https://arxiv.org/pdf/2309.14304.pdf>.
- [23] Yue X Y, Kuang Z H, Lin C H, et al. RobustScanner: dynamically enhancing positional clues for robust text recognition[C]// ECCV 2020. Cham: Springer, 2020: 135-151.
- [24] Li C X, Liu W W, Guo R Y, et al. PP-OCRv3: more attempts for the improvement of ultra lightweight OCR system[PP/OL]. V2. arXiv (2022-06-14) [2026-06-01]. <https://arxiv.org/pdf/2206.03001.pdf>.
- [25] Chen J Q, Chen H, Chen K Y, et al. Diffusion models for imperceptible and transferable adversarial attack[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2025, 47(2): 961-977.
- [26] Liu J, Zhou J T, Zeng J D, et al. DifAttack: query-efficient black-box adversarial attack via disentangled feature space[C]// AAAI 2024. Palo Alto: AAAI Press, 2024: 3666-3674.
- [27] Yahn Z, Tekin S F, Ilhan F, et al. Adversarial attention perturbations for large object detection transformers[C]// ICCV 2025. Piscataway: IEEE, 2025: 3184-3193.
- [28] Rice L, Wong E, Kolter J Z. Overfitting in adversarially robust deep learning[C]// ICML 2020. New York: JMLR.org, 2020: 8093-8104.
- [29] Sitawarin C, Chakraborty S, Wagner D. SAT: improving adversarial training via curriculum-based loss smoothing[C]// Proceedings of the 14th ACM Workshop on Artificial Intelligence and Security. New York: ACM, 2021: 25-36.
- [30] Jia X J, Zhang Y, Wu B Y, et al. LAS-AT: adversarial training with learnable attack strategy[C]// CVPR 2022. Piscataway: IEEE, 2022: 13388-13398.
- [31] Chen P C, Kung B H, Chen J C. Class-aware robust adversarial training for object detection[C]// CVPR 2021. Piscataway: IEEE, 2021: 10415-10424.
- [32] Choi J I, Tian Q. Adversarial attack and defense of YOLO detectors in autonomous driving scenarios[C]// IV 2022. Piscataway: IEEE, 2022: 1-8.

This work is partially supported by Shanxi Provincial Basic Research Program (202303021222084).

LIU WenBin, born in 2002, M. S. candidate. His research interests include deep learning, object detection, adversarial examples, and adversarial training.

GENG Yanbing, born in 1980, Ph. D., lecturer. Her research interests include image processing, pattern recognition, artificial intelligence.

LIAN Yongjian, born in 1975, Ph. D., lecturer. His research interests include image processing, pattern recognition, artificial intelligence, virtual reality.

CUI FangShu, born in 1983, Ph. D., lecturer. Her research interests include prediction of complex systems and machine learning.