



计算机工程与应用
Computer Engineering and Applications
ISSN 1002-8331, CN 11-2127/TP

《计算机工程与应用》网络首发论文

题目：面向法庭科学图像检验的生成式人工智能技术研究综述
作者：孟利，李欣，郝宇，贺娇君
网络首发日期：2026-08-05
引用格式：孟利，李欣，郝宇，贺娇君. 面向法庭科学图像检验的生成式人工智能技术研究综述[J/OL]. 计算机工程与应用.
<https://link.cnki.net/urlid/11.2127.TP.20260805.1022.006>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

面向法庭科学图像检验的生成式人工智能技术研究综述

孟利^{1,2}, 李欣¹⁺, 郝宇², 贺娇君¹

1.中国人民公安大学 信息网络安全学院, 北京 100038

2.河南警察学院, 郑州 450046

+ 通信作者 E-mail:lixin@ppsuc.edu.cn

摘要：生成式人工智能（generative artificial intelligence, GenAI）正推动法庭科学图像检验从被动像素增强向主动语义重构转变。针对法庭科学图像检验，围绕生成式结果的法庭可采性、证据效力与适用边界，构建贯通模型路线、应用场景、法庭效力与风险控制的分析框架。以保真度与生成能力之间的关系为评价标准综述了 GAN、VAE、扩散模型、Transformer 与多模态大模型的技术原理与适用边界；梳理 GenAI 在涉案车牌超分辨重构、面部增强与重建、潜在指纹恢复、深度伪造检测、图像篡改检测与定位及多模态证据融合等任务的主流技术路线，并经横向对比明确其适用条件与局限。提出了面向法庭科学的像素保真度、感知质量、下游任务、法庭可解释性的四层评估体系，使方法比较不再依赖单一感知指标；依据生成操作的性质提出辅助证据与侦查线索的分层证据效力划分，厘清增强类与生成类结果在司法程序中的差异化定位与审查标准；总结不同退化程度证据的技术适配边界，指出退化的数学不适定性越强、采信边界越应收紧，并据此提出侦查阶段拓宽线索、诉讼阶段坚守极小失真的双轨制逻辑。最后，针对生成幻觉控制、模型可解释性与证据可接纳性等问题，梳理可解释人工智能与不确定性量化、端侧轻量化部署、多模态证据协同融合、隐私保护联邦训练与人机协同决策等未来研究方向，以期在法治框架下推动 GenAI 在法庭科学实战中的规范化应用。

关键词：生成式人工智能；法庭科学；图像检验；深度伪造检测；图像篡改定位；分层证据效力；可解释人工智能；多模态证据融合

文献标志码: A 中图分类号: TP391 doi: 10.3778/j.issn.1002-8331.2605-0240

A Survey of Generative Artificial Intelligence Technologies for Forensic Image Examination

MENG Li^{1,2}, LI Xin¹⁺, HAO Yu², HE Jiaojun¹

1.School of Information Network Security, People's Public Security University of China, Beijing 100038, China

2.Henan Police College, Zhengzhou 450046, China

Abstract: Generative artificial intelligence (GenAI) is shifting forensic image examination from passive pixel enhancement toward active semantic reconstruction. Centered on the admissibility, evidentiary weight, and applicable boundaries of generated results, this paper builds an analytical framework linking model routes, application scenarios, forensic weight, and risk control. Taking the fidelity-generative-capability trade-off as the criterion, it reviews the principles and boundaries of GANs, VAEs, diffusion models, Transformers, and multimodal large models, and compares the mainstream routes for license-plate super-resolution, facial enhancement and reconstruction, latent fingerprint restoration, deepfake detection, image tampering localization, and multimodal evidence fusion. On this basis, it proposes a four-tier evaluation framework spanning pixel fidelity, perceptual quality, downstream-task performance, and forensic interpretability; establishes a graded evidentiary scheme distinguishing auxiliary evidence from investigative leads according to the nature of the generative operation; and summarizes the technical adaptation boundaries across degradation levels, indicating that the more ill-posed the degradation, the tighter the admissibility boundary should be. Finally, addressing hallucination control, interpretability, and evidence admissibility, it reviews future directions including explainable AI and uncertainty quantification, on-device deployment, multimodal evidence fusion, privacy-preserving federated training, and human-machine collaborative decision-making, aiming to promote the standardized application of GenAI in forensic science within the rule-of-law framework.

Key words: generative artificial intelligence; forensic science; image examination; deepfake detection; image tampering localization; graded evidentiary weight; explainable artificial intelligence; multimodal evidence fusion

基金项目：河南省高等教育研究项目（2025SXHLX263）；2026 年度河南省高等教育教学改革研究与实践项目（2026SJGLX569）

作者简介：孟利（1990—），男，在读博士生，讲师，CCF 学生会员，研究方向为网络安全、人工智能、图像处理；李欣（1977—），男，教授，博士生导师，研究方向为人工智能、大数据；郝宇（1991—），男，博士，副教授，研究方向为图像处理、凝聚态物理；贺娇君（1998—），女，在读博士生，研究方向为人工智能、大数据。

图像证据历来是刑事司法体系中的核心要素^[1]，贯穿侦查、诉讼与审判的全过程。法庭科学图像检验不仅涉及退化图像的复原与增强，还涵盖真实性鉴定、篡改痕迹检测与生成内容溯源。实际获取的图像证据往往处于复杂环境中：一方面因低分辨率、遮挡、噪声及物理损毁导致信息缺失；另一方面因恶意篡改与伪造引发信任危机，严重制约其在司法实践中的利用效率与证明效力。如何最大限度提取并恢复有效信息，构建涵盖真实性鉴定、篡改痕迹检测及生成内容溯源的完整分析链路，始终是该领域的关键挑战。

近年来，以生成对抗网络（Generative Adversarial Network, GAN）、变分自编码器（Variational Autoencoder, VAE）、扩散模型（Diffusion Models）和 Transformer 架构为代表的 GenAI 技术快速发展，借助大规模数据先验实现对缺失语义的合理推断与主动重建，为图像检验带来语义重构层面的转变。从 2014 年 Goodfellow 等人^[2]提出 GAN，到 2020 年 Ho 等人^[3]提出去噪扩散概率模型（Denoising Diffusion Probabilistic Model, DDPM），再到 2022 年 Rombach 等人^[4]提出潜在扩散模型（Latent Diffusion Model, LDM），GenAI 在图像超分辨率、修补、内容重建与深伪检测等任务上的性能远超传统方法。

然而，现有成果分散于不同任务、模型和场景中，缺少一个以法庭科学为中心、贯通技术路线—应用场景—证据效力—部署应用的统一框架。为此，本文系统综述法庭科学图像检验中的 GenAI 技术，重点分析不同技术路线分别适合哪些检验任务；不同方法在保真度、可解释性与证据风险方面存在哪些差异；以及生成式结果应如何被理解、使用和审查。全文据此逻辑展开：首先对 GAN、扩散模型、Transformer 与多模态模型的能力边界进行比较；其次结合图像增强、修复补全、篡改检测定位、深度伪造检测与多模态融合等任务，分析其适用场景与局限；再从法庭视角讨论不同生成操作的证据属性和审查标准，并结合端侧轻量化部署与实战需求，总结当前局限与未来发展方向。

1 GenAI 技术路线与法庭科学适应性

1.1 GenAI 技术路线

Goodfellow 等^[2]提出 GAN 通过生成器与判别器对抗训练实现数据生成，其数学本质是求解 Min-Max 博弈的纳什均衡。GAN 生成图像写实度高，但存在模式崩溃与梯度消失等不稳定性问题^[5]。在法庭科学中更关键的问题是其幻觉倾向——可能生成统计合理却与事实不符的虚假纹理，影响重建可靠性^[6]。VAE 以贝叶斯变分推断为基础^[7]，通过最大化证据下界学习潜在分布，训练稳定、潜在空间可控，可合成指纹或人脸样本以扩充数据集^[8]。但其生成图像偏模糊、细微纹理精度不及 GAN，难以满足高精度物证鉴定的需求^[9]。扩散模型以非平衡热力学为基础，经前向加噪与反向去噪实现高保真重建^[10]。以 DDPM 和 LDM 为代表的模型，在生成质量和训练稳定性上优势显著，

为严重损毁物证修复与低质量视频还原提供了路径^[11]。但其计算成本高、推理慢，制约实时勘查部署。Transformer^[12]依赖自注意力机制实现对图像全局依赖的深度建模，弥补了传统卷积神经网络（Convolutional Neural Network, CNN）局部感受野的不足，擅长捕捉指纹脊线等全局结构并具跨模态融合潜力。但计算复杂度随分辨率呈平方级增长，在典型小样本场景下需额外预训练^[13]。

本文所涉方法按建模目标划分为两类。生成式模型（如 GAN、VAE、扩散模型及生成式多模态大模型）学习数据的联合分布或条件分布，能够主动合成、补全或重建图像内容；判别式模型（如 CNN 分类器、检测器与分割网络）学习类别边界或后验概率，仅对已有内容作出真伪、类别或像素归属的判断，不引入新的视觉信息。二者在法庭语境下的差异具有本质意义：前者生成新信息，直接触及证据的客观真实性与同一性，采信需格外审慎；后者不改变原始内容，直接服务于证据审查。本文据此分别讨论，并在涉及检测任务的各表中标注方法所属范式。

1.2 传统图像检验与 GenAI 的协同

生成式方法并非完全取代传统技术，而是与传统增强方法互补协同^[14]。传统方法通过直方图均衡、限制对比度自适应直方图均衡（Contrast-Limited Adaptive Histogram Equalization, CLAHE）、降噪滤波和边缘检测（如 Sobel、Canny 算子）改善图像清晰度。这些方法计算成本低、操作简便，不生成新信息，仅对已有内容进行清晰化处理，这一透明性使其在法律审查中易于辩护^[15]。但当局部区域严重损坏或原始数据不可逆丢失时效果有限^[16]。

当前，图像处理流程正从单一技术手段向传统增强与生成式重构相结合的协同方式转变。先以 CLAHE 优化局部对比度、挖掘暗区细节，再将预处理图像输入生成模型，借其语义补全、超分辨率与降噪能力修复缺失信息，如图 1 所示。




图 1 传统图像处理技术与 GenAI 协同

Fig.1 Synergy between Traditional Image Processing Techniques and GenAI

技术专家须通过详尽参数记录、多级专家审核及标准操作规程（standard operating procedure, SOP），确保生成图像在科学逻辑上可靠、法律伦理上可接受^[17]。二者对比如表 1 所示。

表 1 法庭科学传统图像检验与生成式图像检验对比

Table 1 Comparison of Traditional and Generative Image Examination in Forensic Science

维度	传统方法	生成式方法
信息来源	利用已有像素	可生成新的视觉信息
处理能力	增强/去噪/锐化	语义补全/超分辨率/内容重构
透明度	高（过程可解释）	低（黑盒模型）
法庭可采性	成熟（易于辩护）	存疑（需额外验证）
适用场景	轻度退化	严重退化/信息缺失
技术成本	低	高

不同生成操作对应不同的证据效力等级：图像增强类处理（如超分辨率、去噪）可作辅助证据，用于提升已有证据的可辨识度；图像生成类处理（如面部去遮挡、缺失区域补全）应严格限定为侦查线索，不得直接用作定案依据。建立这种分层证据效力体系，是 GenAI 在法庭科学中规范化应用的前提。

1.3 技术适应性与证据边界探讨

法庭科学以客观真实为核心，强调证据的客观真实性、同一性、可重复性及科学有效性；GenAI 的底层逻辑在于基于概率分布对缺失信息进行推断与重构。这一本质冲突是评估其适用性的关键基点：生成模型求解逆问题时高度依赖概率先验，其幻觉易生成客观不存在的结构性伪影，与客观真实性相悖；高维非线性映射导致的黑盒不透明性及训练分布失衡引发的算法偏见，使输出难以满足质证对科学可靠性、误差可测性与司法公正的要求，从而丧失可采性。据此，GenAI 更适宜转向受限增强与对抗检测两类路径，并在不同退化类型下实现功能降级与边界重构。具体如表 2 所示：

表 2 不同退化类型下 GenAI 技术路线的适配差异、应用场景与风险边界
Table 2 Differences in the Adaptation of GenAI Technical Routes, Scenarios, and Risk Boundaries under Different Levels of Degradation

退化类型	典型图像表现	技术路线	应用场景	核心风险	法庭应用边界限定
确定性空间退化 ^{[18][19]}	运动拖影、严重离焦	视觉 Transformer (Vision Transformer, ViT)	远距离车牌识读、工具/鞋印宏观恢复	模式坍塌，将模糊字符强行重构为形近清晰字符	不作司法证据，仅作侦查线索
高度随机性退化 ^[20]	极低照度、强噪声	扩散模型 (Diffusion)	夜间事故现场还原、雨雾监控增强	重渲染全局光照，破坏色彩恒常、抹除微弱反光痕迹	丧失物理时空同一性，仅作宏观布局参考
信源不可逆缺失 ^[21]	极低分辨率、极端压缩	潜空间先验 GANs	极低像素人脸超分重建与修复	以数据库他人五官拼凑面孔，抹除痣、疤痕等个体特征	极危操作，仅限协查通报等非鉴定环节
多源信息瓶颈与跨域异构退化 ^[22]	单一视觉近乎归零，需跨源补全	多模态大语言模型与跨模态注意力网络	笔录引导的极模糊人像重建、红外-可见光融合、3D 颅面复原	生成符合侦查员先入预期的伪造特征	结果可作辅助鉴定参考

注：“法庭应用边界限定”判定标准见附录 A（1）和 A（4）。

法庭科学图像检验中的技术选择并非单纯取决于感知质量上，而是建立在退化物理属性、模型数学映射逻辑与证据规则的严格匹配上：确定性空间退化下，图像物理连续性并未彻底断裂，宜用保守的物理反演或在严格保真约束下以 ViT 聚合空间高频信息，并防范模型模式崩塌引起的语义反转。高度随机性退化下扩散模型虽提升信噪比，但其易改变全局光照等物理属性，输出宜限定为宏观环境参考、不用于颜色或光照鉴定。信源不可逆缺失时图像的微观物理特征已丧失，潜空间先验依赖外部数据集补全，易导致身份漂移与特征伪造，仅可作为侦查初期的辅助线索。多源信息瓶颈与跨域异构退化下须协同分析，并严格隔离异构数据源、防范语义挟持与确证偏差，确保交叉验证的客观独立。

由此，GenAI 应用原则并非生成能力越强适用越广，而是退化的数学不适定性越强、法庭采信边界越需收紧——随着退化从局部扩散向信源断裂演进，重构所依赖的先验成分呈指数级攀升，失真风险也随之增加。法庭科学需确立基于感知-失真权衡的双轨制：侦查阶段可利用感知增益拓宽线索，诉讼阶段坚守极小失真的物理底线。

2 GenAI 在图像增强与重建中的应用

2.1 涉案车牌超分辨重构

生成式方法使车牌图像增强从像素级滤波转向主动特征重建。早期基于感知损失的 GAN 超分辨率框架(如 SRGAN^[23]与 ESRGAN^[24])，以视觉纹理逼真度为目标奠定基础。随后研究转向扩散模型，通过优化数据分布拟合过程提升了保真度、缓解 GAN 训练不稳定与模式崩塌，成为复杂车牌图像重建的主要研究方向。

为满足车牌字符可读性，优化目标由全局视觉质量转向局部语义：GAN 框架引入了区域判别 (PatchGAN) 与渐进式上采样^[25]，或结合复合退化模拟与感知光学字符识别 (Optical Character Recognition, OCR) 损失^[26]以优先重建字符的拓扑结构，并经级联轻量级目标检测算法在质量与速度间取得平衡^[27]。扩散方法则倾向于多维先验融合，如以掩码交叉注意力机制整合字符语义^[28]，或结合多帧时序拟合真实退化分布^[29]。

此类方法虽改善了视觉质量与识别率，但仍存两点局限：多依赖合成的退化数据训练，面对真实场景的光照、运动等复杂退化时，易出现泛化下降与域偏移。固有幻觉可能导致错误重建字符拓扑，从而影响识别。未来应集中于利用大规模真实场景数据、结合时序与多模态先验缩小域间隙并抑制幻觉以及扩散模型的轻量化部署。相关工作总结对比如表 3 所示。

表 3 车牌超分辨重构的 GenAI 技术对比分析

Table 3 Comparative Analysis of GenAI Techniques for Super-Resolution Reconstruction of License Plates Involved

文献	年份	模型	数据集	代表结果	局限性/风险	法庭典型退化验证
[23]	2017	SRGAN	通用集(Set5/14 等)	4×放大逼真度突破，MOS 领先	会幻化不真实细节	否
[24]	2018	ESRGAN	DIV2K,Flickr2K	PIRM2018-SR 冠军，纹理需手动权衡感知与保理更锐利	真	否
[25]	2021	RDN+PatchGAN	CCPD	PSNR 26.80/SSIM 0.77，兼顾速度	难辨真实与复杂机生数据	部分
[26]	2024	LPSRGAN	真实采集+自定义退化	识别率+12.48%，综合达 93.90%	上限受退化模拟程度限制	部分
[27]	2025	DeblurGAN+YOLO v5	自建 ALPR/去模糊集	检测/识别 95%/97%，模糊识别+约 40%	依赖特定国别数据，预处理增开销	部分
[28]	2025	CharDiff-LP	Roboflow-LP	CER 较 TCDM 降 28.3%(至 8.1%)	依赖外部分割/OCR，极端退化下失效	部分
[29]	2025	LP-Diff	MDLP	准确重建易混字符(Q/0 等)，少样本强	依赖连续帧，单张极模糊受限	部分

注：“法庭典型退化验证”的判定标准见附录 A（2）。

2.2 面部图像重建与增强

法庭面部图像重建技术经历了从局部缺失修复、复合退化恢复到跨模态特征生成的发展。早期以 GAN 结合分割掩码的双阶段框架补全遮挡区域^[30]，继而转向离散代码本先验与 Transformer 重建复合退化人脸^[31]，再以 LDM 结合身份保持策略增强^[32]。当图像证据严重受限时进一步拓展至跨模态生成，包括基于颅骨解剖学约束的三维面部推演^[33]与由 DNA 序列直接映射的三维面部重建^[34]。

其共性挑战在于合成训练数据与真实现场的分布差异，性能上限受限于先验知识库完备性制约。基于统计先验的生成机制存在固有不确定性，可能产生偏离客观事实的局部特征、影响同一认定的严谨性。因此，当前生成式面部重建结果仅宜作为侦查阶段缩小排查范围的辅助线索，尚不能作为身份确认的直接证据。未来将向多模态生物证据联合驱动与真实复杂环境下的泛化能力提升发展。相关工作总结对比如表 4 所示。

表 4 面部图像重建与增强的 GenAI 技术对比分析

Table 4 Comparative Analysis of GenAI Technologies for Facial Image Reconstruction and Enhancement

文献	年份	模型	数据集	代表结果	局限性/风险	法庭典型退化验证
[30]	2026	M2UNet	MaskTheFace	PSNR 31.34/SSIM 0.96, 消除结构模糊	身份失真	部分
[31]	2022	CodeFormer	WIDER/CelebA-HQ 等	真实盲复原保真与连贯性高	稀有特征表征瓶颈	部分
[32]	2025	Latent Diffusion + Facezoom LoRA	LFW 子集	严重退化识别率 29.1%→84.5%	生成式幻觉危险	部分
[33]	2024	Stable Diffusion XL + FLAME	真实颅-面三维扫描配对	解剖约束下高逼真 3D, 误差 3.464mm	极高不确定性	不适用
[34]	2025	Transformer+ 螺旋卷积+扩散模型	汉族人群特征库	3D 误差 3.52mm(加性别/年龄/BMI 降至 2.93); Rank-1 3.33%	环境表达漂移	不适用

注：“法庭典型退化验证”的判定标准见附录 A（2）。

2.3 潜在指纹恢复与增强

GAN 推动潜在指纹增强从传统的信号滤波转向结构生成：FingerGAN^[35]将增强转化为受限生成，融合骨架图、方向场等拓扑约束，并以卡通-纹理分解等策略缓解真实训练数据稀缺。FingerRT^[36]等进一步引入 Transformer 全局注意力与多层次特征点监督以稳健结构重建。该类方法模型训练不稳定、依赖高质量的成对监督数据，在极端背景干扰下难以保持全局拓扑一致性。

为此，DDPM 提供了新思路：GenPrint^[37]以多模态条件解耦并可控合成指纹身份与传感器属性，为数据匮乏场景提供增强途径。后续研究进一步构建多材质风格库以支持零样本跨域适配^[38]。但扩散方法易产生细节点伪影与全局脊线外推偏差，且多样性与身份一致性难以兼顾，限制了其在高精度比对中的应用。近期研究将扩散与多种特征机制结合，如以扩散模型建立全局脊线基线，再辅以 GAN 进行高频纹理细化，并引入伪彩色解码机制以强化脊线对比度^[39]；或将小波包变换融入扩散过程，以在频域层级上恢复受损的脊线结构^[40]。此类复合架构灵活性高，尤其适用于从重度降质指纹中提取关键身份线索。未来应在提升高频细节恢复的同时，结合物理与拓扑先验抑制伪影，确保增强结果的可靠性与身份一致性。相关工作总结对比如表 5 所示。

表 5 潜在指纹恢复与增强的 GenAI 技术对比分析

Table 5 Comparative Analysis of GenAI Technologies for Latent Fingerprint Recovery and Enhancement

文献	年份	模型	数据集	代表结果	局限性	法庭典型退化验证
[35]	2022	FingerGAN	SD14 训练; SD27/MOLF 测试	SD27 Rank-1 59.69%; 恢 复真实细节点 1982、引 入虚假 11152	极端损坏区约束 不足	是
[36]	2024	FingerRT	SD14+FVC+10 万犯罪现场 潜指等	SD27 匹配显著提升, F1 78.9%, 每枚多恢复 6.9 点	FingerNet 精度 不足, 依赖 FingerNet 精度	是
[37]	2024	GenPrint	聚合 15 公开集约 43 万图; SD27/LFIW 等测试	SD4 TAR 97.85%, 身份 泄漏率仅 0.03%	推理慢(1.13s/ 张), 提示不匹配 生成失真	是
[38]	2026	GenPrint 扩展	28,357 枚潜指 (SD27/MSP/LFIW 等)	合成配对 TMR≈真实; 细节点增 21.45%/移除 12.42%, 全局幻觉达 30.04%	错误输入经 ControlNet 放大 致全局幻觉	是
[39]	2025	混合扩散-GAN 着色模型	SD27/MOLF/FVC/MSP 潜 指	SSIM+15~30%, PSNR+5~10dB, NFIQ 等 级提升	计算成本高, 约 束不足易生虚假 脊线	是
[40]	2024	WPT-DDPM	SOCOFing、NIST SD4	SOCOFing FID 61.64; SD4 SSIM 0.495	仅 64×64, 无身 份保持	否

注：“法庭典型退化验证”的判定标准见附录 A（2）和 A（3）。

需要注意的是：潜在指纹的司法应用以同一认定为目标，而同一认定建立在脊线细节点的类型、位置及其相互关系之上，对特征客观性与唯一性要求极高。生成式增强在补全脊线、提升对比度的同时，存在凭空生成、迁移或抹除细节点的风险，所以结果不得直接作用于个体识别。表 5 数据揭示：FingerGAN 在 NIST SD27 上恢复 1982 个真实细节点的同时，引入了多达 11152 个虚假细节点^[35]；GenPrint 的扩展方法虽使合成配对的匹配率与真实配对高度可比，但其细节点增加误差达 21.45%、移除误差达 12.42%，CrossMatch 风格下全局幻觉

率高达 30.04%^[38]。可见生成模型可能在视觉修复指纹的同时，系统性地伪造或破坏用于同一认定的关键特征，使增强结果与原始检材在身份意义上发生偏离。

因此，对生成式增强的潜在指纹必须设定严格的应用边界：其结果不得直接录入自动指纹识别系统（Automated Fingerprint Identification System, AFIS）检索比对，亦不得作为同一认定的比对底图；任何由模型生成或重构的细节点均应显式标注并与原始可见特征相区分。此类结果可用于引导侦查或提示对原始指印重新提取、显现与复核，但禁止替代原始检材进入鉴定比对环节。这与本文所主张的分层证据效力体系一致：生成类结果应严格限定为侦查线索，须经独立证据交叉印证，不得单独作为定案依据。

2.4 跨模态生物先验引导的图像增强与重建

前述重建与增强均是在图像模态内部恢复退化信息，但在重度缺失或极端退化下（见 1.3 节）检材自身已不足以支撑可靠重建，问题转为由异模态先验约束的欠定生成——引入文本、DNA、颅骨等先验以施加结构约束、压缩解空间。

文本先验将自然语言描述转化为面部语义约束：FLP-GAN^[41]为先由描述文本预测面部关键点与分割图，作为语义再引导合成，可依据目击者的口头描述批量生成候选面像，作用近似于人工模拟画像但效率更高，其约束强度受描述的主观性与粒度限制。

基因先验对应 DNA 表型推断：Difface^[34]结合 Transformer、螺旋卷积与扩散模型，仅依据 DNA 数据重建三维人脸，并可外推不同年龄阶段的样貌，可为无名尸或生物痕迹提供容貌方向的排查线索。但研究表明^[42]其重建主要由性别与族群决定，呈现群体近似而非个体精确还原。

骨骼先验对应颅面复原，将颅骨到人脸转化为图像翻译：CR-GAN^[43]在大规模配对颅面数据上学习映射；From Skulls to Faces^[44]以条件 GAN 在二维深度图上实现三维颅面复原，兼顾局部细节与整体轮廓，主要用于无名颅骨的身份线索生成。相关工作总结对比如表 6 所示。

从模型类型看：颅面复原以 GAN 的成对图像翻译见长，DNA 重建则依赖扩散模型与 Transformer 的组合获得更丰富的样本多样性与细节表达。三者存在共同局限：输出是受训练数据分布与族群偏置约束的统计近似容貌，在法庭语境下只能作为缩小排查范围的侦查线索，不能作为同一认定的直接证据。

表 6 跨模态生物先验引导的图像增强与重建技术对比分析

Table 6 Comparative Analysis of Image Enhancement and Reconstruction Techniques Guided by Cross-Modal Biological Priors

文献	年份	模型	数据集	代表结果	主要局限/风险	法庭可接受度
[41]	2025	FLP-GAN	Face2Text	FFD 较前最优改善约 22.7%，文本-人脸结构一致	受描述主观性限制，难唯一对应个体	侦查线索、缩小排查，不作同一认定
[34]	2025	Difface	DNA(汉族 9674 配对)	SNP 误差 3.52mm（加性别/年龄/BMI 降至 2.93）	由性别/族群主导，群体近似；涉基因隐私	侦查线索、缩小排查，不作同一认定
[43]	2022	CR-GAN	颅骨(4551 对颅-面)	经多种人脸识别验证可用于身份排查	依赖大规模配对 CT，个体特异性有限	侦查线索、缩小排查，不作同一认定
[44]	2024	条件 GAN	颅骨(颅-面深度图)	重建真实感优于传统统计法，兼顾细节与轮廓	二维深度图近似三维，精度受限	侦查线索、缩小排查，不作同一认定

注：“法庭可接受度”判定标准见附录 A（1）

2.5 核心生成模型在图像增强中的对比分析

法庭科学以客观性、真实性与同一认定为核心，而生成模型固有的幻觉、随机采样以及黑盒属性与司法证据对严谨性和可重复性的要求存在本质冲突。因此，脱离具体应用边界而单纯追求视觉保真度，不仅无益于司法鉴定，反而容易引入具有高度欺骗性的伪造证据，引发司法风险。

三个案例印证了审慎采信的重要性。2024 年美国华盛顿州金县高等法院审理的 State v. Puloka 案，是已知首例就人工智能增强视频可采性作出裁决的刑事案件^[45]。该案中，辩方专家使用商用 AI 工具对一段低分辨率、存在明显运动模糊的手机视频进行增强，试图作为庭审证据提交。法院依据 Frye 标准（要求科学证据须在相关的科学领域内获得“普遍接受”）认定：该 AI 增强方法未获普遍接受，且其以不透明方式生成模型“认为”应呈现的画面、等于加入原始记录中不存在的信息，故采纳原始视频、排除增强视频。

基于 DNA 表型推断的容貌合成技术已作为侦查线索发挥作用：从生物检材的 DNA 推断外貌特征并生成合成面像，用于在缺乏数据库命中时缩小排查范围，其身份最终均由独立的短串联重复（Short Tandem Repeat, STR）比对确证^[46]。然而，该方向同样印证了“仅作参考、不作认定”的必要性：已有批评指出，此类专有模型多缺乏公开同行评审，面部形态预测的可靠性尤具争议，若被过度采信则可能

导致误指认并强化群体偏见。这与本文 2.4 节关于 DNA—人脸重建呈群体近似而非个体精确还原、不可作同一认定的结论一致。此外，2020 年美国底特律的 Robert Williams 误捕案中，警方将一帧画质粗糙的监控图像送入人脸识别系统比中嫌疑人并实施逮捕，后因证据不足撤诉，成为有记录以来首例因人脸识别误报导致无辜者被捕的案例^[47]，揭示了过度依赖 AI 图像分析的风险。

基于文献实证数据，从生成质量、推理速度、法庭应用、风险局限与法庭可接受度五个维度分析得出：不存在普遍最优模型，且生成能力强并不等于证据效力高；五类模型的法庭可接受度均低于可作为同一认定的层级——Transformer 最高仅为需受控使用、可作高维宏观特征参考，GAN 仅限线索初筛、VAE 仅作数据补充、扩散模型受限制辅助侦查与多模态模型仅作侦查线索。这说明在图像增强重建任务上，现阶段 GenAI 整体只能定位为侦查线索或受控辅助，不能作为证据来使用。具体对比分析如表 7 所示：

表 7 核心生成模型在图像增强任务中的对比分析

Table 7 Comparative Analysis of Core Generative Models in Image Enhancement Tasks

模型架构	核心机制	生成质量/ 速度	典型法庭应用	主要风险与局限	法庭可接受度
GAN (SRGAN/ESRGAN/FingerGAN)	Min-Max 对抗博弈	高（写实）/快	人脸修复、监控超分增强	模式坍塌；局部约束弱，易凭空伪造纹理或引入逾万虚假细节点（局部幻觉）	仅限线索初筛，严禁作同一认定证据
VAE	变分推断/ELBO	中（偏模糊）/快	样本扩充、大规模预警筛选	过平滑致关键纹理（如指纹脊线）模糊	仅作数据扩充/预筛，不作物证还原依据
Diffusion (LP-Diff/GenPrior/Latent Diffusion)	迭代去噪	极高/慢	受损物证高保真重建、低质视频还原	采样慢、算力依赖重；随机采样不可复现；全局风格漂移（生成式幻觉）	受限辅助侦查，严禁录入 AFIS、须标注 AI 推演
Transformer 及混合架构 (CodeFormer/FingerRT)	自注意力	高保真/中（显存瓶颈）	帧间一致性检验、复杂场景拓扑还原	复杂度随分辨率平方增长、依赖预训练；多模态引导时推理难溯源；训练偏置致表达漂移	需受控使用，可作高维宏观特征参考
Multimodal (FLP-GAN/Difface/CR-GAN)	跨模态融合	群体近似（个体保真有限）/因骨干而异	案发现场语义重建、多源证据关联、容貌排查	黑盒较强、跨模态映射严谨性待质证；个体特异性多为统计推断	仅作侦查线索，不作同一认定；DNA 类另受隐私伦理规制

注：“法庭可接受度”判定标准见附录 A（1）和 A（3）。

2.6 共性技术逻辑与多层效能评估

生成式重建在法庭科学图像增强中遵循：“标准化预处理-针对性生成重建-系统化效能评估”的共性技术流程：预处理使图像已有特征得到充分显现以提供高质量输入，再按需引入生成模型执行低分辨率、补全或重建，最后根据系统化评估判断是否纳入证据链。

鉴于法庭科学对证据的特殊要求，通用图像质量指标不足以反映实际效能。本文建议建立面向法庭场景的四层评估体系：第一层为像素保真度，以峰值信噪比（Peak Signal-to-Noise Ratio, PSNR）、结构相似度（Structural Similarity, SSIM）衡量重建结果与基准图像在像素分布上的吻合程度，适用于具备真值参考的实验性评估^[48]。第二层为感知质量，以学习感知图像块相似度（Learned Perceptual Image Patch Similarity, LPIPS）、弗雷歇初始距离（Fréchet Inception Distance, FID）、自然图像质量评价器（Natural Image Quality Evaluator, NIQE）衡量视觉与深度特征空间中的真实性，避免“过平滑”陷阱。第三层为下游任务性能，按物证类别采用差异化指标——车牌用识别准确率与字符错误率（Character Error Rate, CER）、面部用首位命中率（Rank-1）与给定误接受率下的真接受率（True Accept Rate @ a Fixed false Accept Rate, TAR@FAR）、指纹用细节点恢复 F1 值与 VeriFinger 匹配准确率、深伪检测用曲线下面积（Area Under the Curve, AUC）与等错误率（Equal Error Rate, EER）（见第 3 章）。第四层为法庭可解释性，以似然比（Likelihood Ratio, LR）^[59]、不确定性置信区间、Grad-CAM 一致性等指标量化证据强度与可质证性。

四层体系之间存在内在权衡：高感知质量未必对应高保真度，高下游识别率也未必对应高法庭可接受度。例如，Ugail 等^[32]报告识别率从 29.1% 跃升至 84.5%，本质上是第三层指标的提升，并不直接证明重建结果可作为身份确认依据；LP-Diff^[29]在 MDLP 上的字符重建准确率提升，需结合第四层的似然比与置信区间方可作为法庭辅助证据使用。

3 GenAI 在图像真实性检验中的应用

3.1 深度伪造检测

GenAI 在图像合成领域的突破，使得深度伪造（Deepfake）图像的逼真度已超越人类鉴别阈值，这对数字证据真实性构成系统性威胁——伪造面部图像可被用于捏造现场证据、虚构嫌疑人身份与篡改视听资料^[49]，动摇数字多媒体证据的可信根基^[50]。本节所综述的检测方法是对真伪作出判断的判别式模型。

当前深度伪造方式主要有人脸交换、重演、属性编辑与全脸合成四类^[51]。无论采用何种生成机制，所有合成图像在微观数据分布上均呈现异于真实成像的统计异常。现有检测技术主要沿着空间域、频率

域与语义域三个维度展开^{[52][53]}。早期以空间域 CNN 直接提取像素级异常特征（如 XceptionNet^[54]）；为缓解其易过拟合特定生成器特征的问题，Kashiani 等^[55]转向频率域，以动态重组多源频率特征与双一致性正则化构建去偏见模型；为提升跨域泛化，研究进一步拓展至语义域与泛化表征：或借预训练视觉大模型结合潜在空间噪声增强^[56]，或以双分支网络提取抗几何扰动的共有痕迹^[57]并辅以增强与蒸馏模拟伪影变异^[58]。针对取证需求，检测方法又从二元分类扩展为基于分数的似然比框架，通过分布建模与边界校准提高证据的可量化度与可解释性^[59]，相关工作总结对比如表 8 所示。

各类方法使用边界不同：空间域方法适用同源或已知生成算法的受控环境；频率域分析适用规避表层语义、挖掘底层生成特征的跨域检验；语义域方法在未知生成算法、域偏移或样本受限的开放场景中更具鲁棒性；似然比框架则符合司法对证据严谨度与透明度的审查要求，可将黑盒输出转化为可解释的量化证据。但挑战仍存：空间域跨域鲁棒性较弱；频率域高频痕迹易被强压缩、模糊等后处理破坏；基于大模型与泛化表征的方法计算开销较大、其普适伪影难以细粒度溯源。

表 8 深度伪造检测的 GenAI 技术对比分析

Table 8 Comparative Analysis of GenAI Technologies for Deepfake Detection						
文献 年份	模型	数据集	代表结果	主要局限/风险	模型范式	法庭典型退化验证
[54] 2019	XceptionNet	FF++（三档压缩）	FF++ raw 99.26%，低质压缩降至 81.00%，超人类	NeuralTextures 最难，仅面部操纵	判别式	部分
[55] 2025	FreqDebias	FF++训练，CDF/DFD/DFDC 跨域	跨域平均 AUC 82.88%，鲁棒性 AUC 97.6%	依赖预训练检测器，忽略相位信息	判别式	部分
[56] 2025	CLIP ViT-L/14+MLP等	Celeb-DF/FF++/DFDC	AUC 0.969，准确率 91.37%	MLP 超 3 层即过拟合，验证集单一	判别式	部分
[57] 2025	D ³	UFD+GenImage（20 种生成器）	未见生成器 Mean Acc 86.7%，JPEG/模糊下鲁棒	CLIP 双推理成本翻倍	判别式	部分
[58] 2024	LSDA	FF++训练，CDF/DFDC 跨域	跨域平均 AUC 82.6%，GAN/扩散检测均优	每类需独立教师，全脸合成检测弱	判别式	部分
[59] 2026	Capsule(似然比)	FF++扩展，Celeb-DF/UADFV 泛化	校准后 Cllr 0.29→0.16，含取证量化指标	跨域泛化不足，AUC 最低仅 0.621	判别式	部分

注：“法庭典型退化验证”的判定标准见附录 A（2）。

3.2 图像篡改检测与定位

扩散模型图像修补^[60]在物证擦除、监控元数据篡改与文档伪造中的应用，使传统人工审查难以应对，而 JPEG 重压缩、缩放与社交媒

体自动处理等后处理操作进一步加大了检测难度。该任务分为面向图像整体真实性的图像级检测与逐像素勾勒篡改掩码的像素级定位，后者是审查证据效力的核心，为质证提供微观判定依据。本节方法以判别式模型为主体，其中条件扩散类定位（如 InpDiffusion）属生成式范式，基于生成式多模态大模型的方法（如 ForgeryGPT、FakeShield）则属判别取证与生成式推理相结合的混合范式。

3.2.1 技术演进脉络

早期依赖对成像与编辑过程留痕的显式建模，分为相机内线索（色彩滤波阵列、PRNU 噪声、镜头像差）与相机外线索（JPEG/离散余弦变换（Discrete Cosine Transform, DCT）压缩痕迹、误差水平分析、噪声不一致）两类^[50]，可解释性强但依赖先验、适用有限。沿频域工程化分支至今仍具实践价值，如 Ferreira 等^[61]提出的 DFT+SVM 方案部署简便、已集成进开源取证工具 Autopsy。数据驱动方法将取证特征由手工设计转向端到端学习：RGB-N^[62]以双流结构分别建模 RGB 语义与空域富模型（Spatial Rich Model, SRM）噪声残差，ManTra-Net^[63]以局部异常实现无需篡改类型标注的端到端定位，Noiseprint^[64]则以孪生网络学习相机型号指纹替代手工残差，奠定“噪声视图+异常建模”的主干。

其后转向多线索融合与架构强化：频域深化为对 DCT 分布与压缩历史的可学习刻画并与 RGB 融合（CAT-Net^[65]），空间域转向多视角融合、以多级监督平衡敏感性与特异性（MVSS-Net^[66]），并将相机指纹与 RGB 经 Transformer 跨模态融合，输出定位图与可信度图（TruFor^[67]）。密集特征交互思路打破逐层传递的壁垒，使低层特征与高层语义双向互通，提升对复杂边缘与异构修补的刻画（DeFI-Net^[68]）。

针对判别式方法过度自信、跨域失效的问题。一是将定位重塑为条件掩码生成，借助扩散模型的迭代去噪逼近真实边界并兼顾不确定性表达与边界保真（InpDiffusion^[69]）。二是以监督对比损失学习可迁移的类间分离结构、追求类间可分与类内紧凑（MPC^[70]）。两者表明取证建模的重心已从设计新线索转向提升跨域泛化。随着视觉-语言大模型的发展，多模态方法将像素级取证线索与自然语言推理相结合，在定位之外识别被篡改对象、判断篡改类型并给出推理过程（ForgeryGPT^[71]）或借“图像-掩码-描述”三元组监督陈述判断依据（FakeShield^[72]）。相关工作总结对比如表 9 所示。

表 9 图像篡改检测与定位的 GenAI 技术对比分析

Table 9 Comparative Analysis of GenAI Techniques for Image Tampering Detection and Localization

文献	年份	模型	数据集	代表结果	主要局限/风险	模型范式	法庭典型退化验证
[61]	2021	SVM+DFT	CASIA/Columbia/COV ERAGE 等	图片篡改 F1 99.53%， 视频深伪 F1 79.55%	篡改内容判别弱，泛化受训练集限	判别式	部分
[65]	2022	CAT-Net v2	CASIA/NIST16/Columbia 等	首次联合 RGB-DCT， 跨域像素 F1≈60.1%	管线痕迹退化敏感，对全图合成弱	判别式	部分
[66]	2023	MVSS-Net++	CASIAv2 训练， NIST16/DEFACTO 等	跨域像素 F1≈71.8%， 显著优于 FCN	训练集小，对高质扩散修复捕获有限	判别式	部分
[67]	2023	TruFor	合成训练， CASIA/NIST16/DSO-1 等	跨域像素 F1 69.6%， 社媒压缩后领先约 16-19%	无法检测全图生成，需完整像素监督	判别式	部分
[68]	2025	DeFI-Net	IID 训练， DEFACTO/Korus 等	域内 AUC 98.61%， DEFACTO IoU 领先 23.3%	梯度平滑 AIGC 修复检测弱	判别式	部分
[69]	2025	InpDiffusion	Inpaint32K 训练， IMD/NIST 等	各类修复 AUC SOTA， IMD AUC 85.5%	推理时间较高	生成式	部分
[70]	2024	MPC	CASIA/CAT-Net 子集， NIST/IMD 测试	大规模 F1 61.2%，OSN 传输后鲁棒性超基线	极端低光与全新 AI 篡改仍不足	判别式	部分
[71]	2024	ForgeryGPT	CASIA/NIST16/IMD20 20/DSO-1 等	定位多集最优 (IMD2020 AUC 91.4%)，含解释	细微痕迹敏感度有限，开销大	混合	部分
[72]	2025	FakeShield	MMTD-Set(CASIA/IMD/Columbia 等)	DeepFake/AIGC 检测 Acc 0.93/0.98，定位多集最优	受分割能力约束，细微篡改捕获有限	混合	部分

注：“法庭典型退化验证”的判定标准见附录 A（2）

3.2.2 场景应用分析

各方法适配不同场景：轻量频域统计方案（DFT+SVM^[61]）契合海量证据的快速初筛与工具链嵌入；频域深度双流（CAT-Net^[65]）对可分析 JPEG 编码、压缩历史的拼接篡改稳健；噪声指纹与异常建模（Noiseprint^[64]、TruFor^[67]、MVSS-Net^[66]）刻画语义无关的低层物理线索，跨域迁移性好且可信度图便于质证；密集特征交互（DeFI-Net^[68]）适于语义与尺度跨度大、边界模糊的修补；扩散式生成（InpDiffusion^[69]）适于需高边界精度与不确定性表达的精细核验；对比学习（MPC^[70]）适于未知篡改与社媒退化并存的开放环境。ForgeryGPT^[71]、FakeShield^[72]对细微痕迹的敏感度与定位精度通常弱于专用模型，更宜作解释与质证沟通的辅助、与专用方法级联。

3.2.3 局限性分析

现有方法受四类彼此交织的共性问题制约。一是取证线索脆弱：噪声指纹与 JPEG/DCT 压缩痕迹在重压缩、滤波、缩放或非 JPEG 管线下明显退化，压缩了适用范围。二是判别式方法的结构性缺陷与泛化不足：逐像素二分类易过度自信、丢失细微边界，且训练域内有效、跨域泛化失效，面对全新生成器性能骤降。三是算力与时延代价：扩散采样、密集特征交互与对比预训练在提升精度或泛化的同时带来推理慢、显存占用高、训练流程复杂，使部分方法更适合离线精核。四是图像级检测与像素级定位之间存在精度、监督成本与证据价值的权衡：高精度像素级定位依赖完整逐像素标注，标注成本高；而以扩散修补、全图合成为代表的 AIGC 篡改因统计分布接近真实图像，仍是检测定位的薄弱环节。四类方法在效率、精度、泛化间各有取舍，实践中需依据证据来源、篡改类型与时效要求组合使用。

需要指出的是，本文按统一标准（见附录 A）来核验“法庭典型退化验证”后发现，除潜在指纹外，车牌、人脸、深伪与篡改类方法在真实办案或公安、司法采集数据上的验证，多在公开学术基准或人工合成退化上评估。合成退化与真实退化在噪声、压缩、模糊与光照等特性上并不一致，前者表现未必能迁移至真实检材；因此各表性能列均为原始文献自报数据，仅供把握方法的能力上限与适用边界，不构成跨数据集的严格横向对比。未来建设公安与司法机关采集的真实退化基准，是推动 GenAI 进入法庭科学的关键前提。

3.3 多模态证据融合与跨模态一致性核验

与 2.4 节“由异模态先验约束的单图重建”不同，本节关注图像、文本、音频及其他生物模态的联合建模与交叉验证：前者生成原检材中并不存在的内容，后者利用模态间冗余与互证提升真伪判别、篡改定位与线索关联的可靠性与可解释性。其作用不是增加信息量，而是将彼此独立的证据维度组织为可相互印证的核验关系，抑制单一模态的幻觉与偏置风险。多模态证据融合演进体现为：检测对象由单模态表层伪造指纹转向模态间一致性，建模方式由真伪判别扩展为判别与可解释推理并重，模态范围则由图文拓展至音视频乃至跨生物模态。

图文一致性核验依据语义矛盾即篡改信号：HAMMER^[73]以对比式跨模态对齐与分层聚合，将整体真伪判断细化为对人脸与文本替换/属性篡改区分，并分别定位被篡改区域与文本词，使融合由粗粒度二分类走向细粒度跨模态定位。其后融合重心转向判别与解释并重，或在定位之外识别被篡改对象、判断篡改类型并给出推理过程^[71]；或借助“图像-掩码-描述”三元组监督陈述像素痕迹与语义依据^[72]。模态范围向音视频扩展，依据真实录像中音、视频在情感与节律上的一致性：先以孪生网络提取视觉、语音与情感特征^[74]；继而利用音视频同步联合建模，对单通道部分伪造亦可判别^[75]。证据链的多源交叉印证，是未来研究的重要方向。当 DNA 表型推演面貌、目击者描述与监控低分辨率图像彼此印证时，证据链可信度高于任何单一来源，若出现系统性偏移，则提示需审慎对待。相关比对如表 10 所示。

表 10 多模态证据融合典型模型对比分析

Table 10 Comparative Analysis of Representative Methods for Multimodal Evidence Fusion						
文献	年份	模型	融合模态	核心能力	法庭适应性	局限性
[71]	2024	ForgeryGPT	图像像素取证线索+语	定位+被篡改对象识别+类型判	可解释质证辅助	细微痕迹弱、开销大

[72]	2025	FakeShield (MMTD-Set)	言 图像+掩码+ 文本描述	断+推理文本 检测+定位+自 然语言判断依据 真伪+细粒度类 型+图文双重定 位	便于质证	受分割约束、开 销大
[73]	2024	HAMMER	图像+文本		图文一致性核 验	依赖图文成对 样本
[74]	2020	Emotions Don't Lie	视频+音频	依据音画情感一 致性判别深伪	视听证据真伪 初筛与一致性 核验辅助	多语种下情感 区分度下降
[75]	2021	Joint Audio-Visual Detection	视频+音频	同时检测视觉与 音频篡改，含部 分伪造判别	视听证据跨模 态同步核验辅 助	强压缩/低帧率/ 音画失步时削 弱

3.4 图像真实性检验的基准数据集

构建兼具泛化代表性与标准化的基准数据集与评测体系，是推动 GenAI 在图像真实性检验中走向实用的重要前提。深度伪造检测方面：FaceForensics++^[54]模拟社交媒体画质衰减，便于考察压缩退化的鲁棒性，Celeb-DF^[76]提高伪造逼真度与检测难度，DFDC^[77]规模最大，常用于非约束开放场景的跨域泛化评估。篡改检测定位方面：早期以 CASIA^[78]、Columbia^[79]与 COVERAGE^[80]为标准测试集，分别侧重拼接、未压缩拼接与复制移动，但规模较小。NIST16/MFC^[81]规模更大、涵盖拼接/复制移动/擦除并以第三方评测统一口径，对工具可信度评估具有参考价值。IMD2020^[82]兼具真实与合成篡改图像并提供像素级掩码；DEFACTO^[83]基于 MS COCO 自动生成二十余万张篡改图像，类型齐全、规模较大。IMDL-BenCo^[84]是首个较完整的基准与开源代码库，统一了数据处理、模型训练与评测全流程并集成多模型、标准协议与鲁棒性测试。面向多模态，DGM4^[73]标注图像与文本各自篡改及类型并提供被篡改图像区域与文本词的定位；MMTD-Set^[72]以 GPT-4o 扩充“图像-掩码-描述”三元组，支撑可解释篡改检测与定位。相关工作总结对比如表 11 所示。

表 11 图像真实性检验常用评测基准的横向对比

Table 11 Comparison of Common Benchmarks for Image Authenticity Verification

文献	年份	基准/数据集	规模与构成	篡改/伪造类型	标注层次	法庭科学中的应用
[54]	2019	FaceForensics++	1000 真+ 4000 伪	Deepfakes、Face2Face、 FaceSwap、NeuralTextures	视频/帧 级	深伪检测标准训 练测试集
[72]	2025	MMTD-Set	GPT-4o 扩充 的图像-掩码-	Photoshop、DeepFake、 AIGC	图像+像 素+文本	可解释定位与质 证沟通

			描述三元组			
[73]	2024	DGM4	约 23 万图文对	图像+文本	类型+区域+文本词	图文一致性核验与跨模态融合
[76]	2020	Celeb-DF (v2)	590 真+5639 高保真伪造	人脸替换	视频级	更贴近真实流通的伪造威胁
[77]	2020	DFDC	逾 10 万段视频	多种深度伪造、GAN 及非学习篡改方法	视频级	开放条件下跨域泛化评估
[78]	2013	CASIA (v1/v2)	5123 篡改+7491 真	拼接、复制移动	图像级	拼接/复制移动基础测试
[79]	2006	Columbia	183 真+180 拼接	拼接	图像级	无压缩干扰下拼接基线
[80]	2016	COVERAGE	100 对原始/篡改图像	复制移动	像素级	相似目标复制移动判别
[81]	2019	NIST16 / MFC	564 篡改	拼接、复制移动、擦除	像素级	法庭工具可信度认证参考
[82]	2020	IMD2020	约 2010 真	拼接、复制移动、擦除、GAN 及修复	像素级	真实未知篡改泛化评估
[83]	2019	DEFACTO	约 22.9 万张	拼接、复制移动、擦除、人脸篡改	像素级	多篡改类型像素级定位
[84]	2024	IMDL-Ben Co	集成多模型与多源数据	拼接、复制移动、擦除等通用篡改	图像+像素	数字证据鉴定质控

4 挑战与未来研究方向

4.1 生成幻觉控制与不确定性量化

生成模型在重建过程中可能引入与事实不符的虚假内容，这是在法庭科学应用中不可接受的风险^[85]。如 GAN 在车牌字符重建中可能生成统计上合理但与真实字符不同的边缘特征。现有研究主要沿两条路径展开：一是在生成过程中显式引入物理退化先验或拓扑约束，使重建结果偏向信息保留而非感知优先（如 CodeFormer 的可控特征变换模块^[31]与 LPSRGAN 的感知 OCR 损失^[26]）；二是借助贝叶斯神经网络、蒙特卡罗 Dropout 或多次采样为每个重建像素提供置信度估计^{[86][87]}。未来需要将二者统一到面向法庭科学的不确定性量化框架中，输出“重建结果+置信度热力图+可接受置信阈值”的标准化产物，使鉴定人员在知悉可靠性的前提下做出判断^[88]。

多模态融合带来新的不确定性：图文语义不对齐会使解释与图像证据错配；训练偏差会影响判别的公平性；视觉-语言大模型可能生成看似合理却不忠实于图像的结构性幻觉。HallusionBench^[89]系统刻画了大模型中语言幻觉与视觉错觉相互交织的现象。对于法庭科学而言，一段流畅却错误的解释比直接误判更具误导性，因其更易被采信，故多模态输出应配合置信度估计、热力图与区间预测，设定阈值并强制人工复核，避免将语言输出直接等同于鉴定结论。此外，应进一步探索 DNA 序列、3D 骨骼、语音、步态等多模态信息与图像证据的协同重建^[90]，借交叉验证机制增强可信度。

4.2 可解释人工智能在法庭科学中的深化

GAN 与扩散模型虽能产出视觉逼真结果，却在很大程度上仍属于黑盒，难以解释特定输出的生成逻辑。这与质证对证据透明度的要求相矛盾，使可解释人工智能（Explainable Artificial Intelligence, XAI）成为生成式技术进入质证环节的前提与主要挑战。

现有面向法庭场景的 XAI 多为判别模型设计的事后归因，移植到生成式重建时仍有明显局限：Grad-CAM^[91]、SHAP^[92]与注意力可视化等揭示的多是模型关注了哪里，而非为何生成出这一具体内容，对生成式模型的忠实性有限；且不同方法乃至不同参数常给出并不一致的热力图或贡献排序，稳定性与可重复性难以保证，难以支撑质证所需的确定性表述。更深层的挑战是解释缺乏可量化、可在法庭语境下比较的统一尺度，热力图与特征贡献多为定性或相对的呈现，难以直接转化为证据强度。似然比框架^[59]将分类器输出转化为可量化解释的证据强度，为弥合这一缺口提供了思路，但其在生成式结果上的适用性、稳健性与校准方法仍有待建立。

未来研究可从三个方向推进：一是发展面向生成过程忠实性更高，并经一致性与稳定性评估约束的解释方法。二是推动解释与证据强度的量化对接，在似然比等框架基础上构建过程可追溯、结果可量化、强度可比较的 XAI 体系^[93]。三是发展标准化的解释呈现与人机协同评估机制，使技术人员与法官都能在统一口径下理解并评估生成式重建结果。

4.3 分层证据效力体系与差异化法律审查标准

法庭科学检验须严格区分侦查线索与物证的法律边界，当前 GenAI 面临三方面的挑战。

一是结果的法律定性不清。生成式重建本质是基于训练分布的概率性估计，并非对客观事实的直接记录，而现行证据规则多面向对真实痕迹的提取分析。尤其是图像增强类处理（超分辨率、去噪）仅提升已有证据的可辨识度；生成类处理（去遮挡、缺失补全、文本/DNA/颅骨容貌推演）则补全检材中并不存在的信息，二者信息来源根本不同，现有研究却将二者笼统看待，缺乏匹配的分层证据效力体系，导致采信尺度不一。

二是生成类结果难以满足可靠性与可重复性要求。《司法鉴定程序通则》^[94]第二十三条所确立的方法选用顺序，要求方法须成熟、稳定、可复现；而 GenAI 重建尚无对应的国家或行业标准，输出具有概率性、随机性与不可完全复现的特点，也缺乏领域内公认的成熟方法。故现阶段难以进入鉴定意见，却因其直观性极易被高估，形成“技术能力超前、效力认定滞后”的现状。

三是过程可追溯性与结果可解释性不足。多模态模型多以端到端方式输出，缺乏对不确定性的量化，难以还原推理依据；GA/T 976-2012^[95]强调的数据完整性校验与全流程可复现，在生成式管线中尚无成熟的实现。模型版本、参数、随机性与输入输出若无完整记录，结果便无法独立核验。

针对上述挑战，未来研究可从以下三个方面进行研究：建立区分增强类与生成类的分层证据效力框架并细化差异化审查标准；发展面向取证的可信度与不确定性量化方法，以置信度、误差区间或空间不确定性图显式呈现结果的概率性与用途边界；构建贯穿生成式管线的留痕与标准化机制，覆盖模型版本、参数、随机种子与输入输出的全流程记录，结合 SOP 与多级专家审核，推动相关国家或行业标准制定，使重建结果在技术与制度层面均可追溯、可复现、在法律与伦理上可接受^[96]。

4.4 实时现场勘查与端侧模型轻量化部署

开发可用于勘查现场的实时生成式工具是未来的重要方向。配备嵌入式 AI 芯片的便携式设备可在现场执行基本的图像补全或分辨率增强，对绑架、走私、突发公共安全事件等时效性强的案件具有实际价值，可降低证据灭失风险。但生成式模型尤其是扩散模型参数大、算力与显存需求高、推理依赖多步迭代，与现场设备在算力、内存、功耗和时延上的约束相矛盾，是端侧部署的首要挑战。

知识蒸馏^[97]、模型量化^[98]、网络剪枝^[99]与低秩适配（low-rank adaptation, LoRA）^[100]等以精度换取效率，一致性模型^[101]与潜在一致性模型^[102]则将数十步采样压缩到一步或数步以提速；但在法庭科学场景中，压缩与加速引入细节损失或伪影可能改变关键证据特征，且采样步数、随机种子等设置的改变会影响结果的可复现性。端侧即时处理还面临记录缺乏的困境，轻量化后模型行为难以复现，进一步加大了留痕难度。因此不应以牺牲可追溯性换取实时性，所有现场处理操作仍须在元数据中完整留痕。

未来研究重点：一是发展面向取证保真度的轻量化与加速方法，建立兼顾效率与证据特征保真的压缩准则与评估指标。二是推动软硬件协同的现场部署，在算力、时延与功耗约束下研究现场即时增强的部署与调度。三是构建端侧可追溯机制，完整记录模型版本、参数、随机种子、输入输出、操作人员及时间并可审计、与实验室标准流程衔接，同时将现场输出定位为侦查线索或初筛，重要证据仍返回实验室标准化复核。

4.5 隐私保护联邦协作与公平性保障

法庭科学数据涉及个人隐私与案件机密，跨机构数据共享受限，

单一机构可用数据规模有限，制约模型的训练。联邦学习^[103]让各方在本地训练、仅交换参数而不共享原始数据。将其与生成式模型结合，有望同时缓解训练数据匮乏与隐私保护的双重困难^[104]。但其在法庭科学应用中仍存在数据异质（设备、人群与案件类型分布不均）影响收敛、参数或梯度的交换可能经梯度反演泄露隐私，以及数据合规、责任归属与过程审计等还未有解决方案。

同时，生成式模型可能继承并放大训练数据中的偏见^[105]，人脸识别已被证实不同种族与性别群体间存在准确率差异^[106]，生成式人脸重建面临类似且更隐蔽的风险：输出看似合理的容貌，群体性偏差不易直接察觉，一旦用于排查可能造成系统性歧视；而现有公平性评估多面向识别分类，缺乏针对生成式取证的偏差度量与审计。

未来可从以下三个方面研究：一是发展适应数据异质性、结合差分隐私与安全聚合并配套合规、责任与审计制度的联邦学习。二是建立面向生成式取证的公平性审计与偏见缓解机制，对模型在不同群体上的表现进行系统评估、定期验证并约束其偏差。三是构建人机协同决策框架^[107]，明确技术辅助与专家判断的边界，将模型输出定位为辅助而非替代，由专家结合公平性审计结果作出最终判断^[108]。

5 结语

GenAI 提升了对退化、缺失与伪造图像的处理能力，但能力提升并不等于证据效力，技术可行并不等于法庭可采。结果能否使用、在何种程度上使用，最终取决于其可解释性、可验证性与可审查性，而非感知指标的高低。

本文主张分层证据效力体系：图像增强类结果在过程合规、可复现且原始证据完整时可作辅助证据；图像生成类结果须严格限定为侦查线索，经独立证据交叉印证，不得单独作为定案依据；检测定位结果须可靠、可重复并满足可解释性方可质证。并坚持侦查阶段拓宽线索、诉讼阶段坚守极小失真的双轨制逻辑，对全过程完整留痕。

面向未来，需把技术能力转化为证据能力。在方法层面，持续深化可解释人工智能与不确定性量化技术，发展面向法庭科学典型退化的端侧轻量化模型与多模态证据协同重建框架；在生态层面，建设法庭科学专用基准数据集与统一评测标准，推动隐私保护下的跨机构联邦协作训练；在制度层面，依托 SOP、算法审计与人机协同决策框架，确保技术应用的透明度、公平性与证据链的完整性。在上述法治轨道的约束下，GenAI 有望真正成为法庭科学工作者可信赖、可质证的辅助工具，为“让每一起案件都经得起法律检验”的目标发挥应有的作用。

附录:A 相关评价维度的判定标准

为使正文各表关于法庭应用的评价具有可核验依据,现统一说明“法庭可接受度”“法庭典型退化验证”及若干边界判断的标准。各标准依据 1.2 节分层证据效力原则、1.3 节退化不适定性逻辑与 2.5 节多维评估框架确立,并在各表(表 2、表 6、表 7 的法庭应用边界列,表 3、表 4、表 5、表 8、表 9 的法庭典型退化验证列)中一致使用。

(1) 法庭可接受度/应用边界列

衡量某方法输出在司法程序中可被采用的最高层级,综合考量五项因素:是否产生原检材中不存在的新信息、过程是否可复现、结果是否可解释、是否影响同一性认定,以及对应退化的数学不适定性程度,自高至低分四级:

可作辅助证据:不产生新信息,仅作增强、去噪、锐化等提升可辨识度的处理,且过程合规、可复现、原始证据完整,依附原始证据使用。**受控辅助/需受控使用:**产生有限新信息或依赖外部先验,在严格验证、全流程留痕与防偏见约束下可作高维或宏观特征参考,不得独立定案。**仅作侦查线索/线索初筛:**产生新信息且幻觉或偏置风险较高,仅用于缩小排查范围、引导侦查,须经独立证据印证,不得用于同一认定。**不可作证据使用:**重渲染全局物理属性或可能伪造同一认定特征,使输出丧失与现场的客观对应关系,仅作宏观空间布局参考或协查通报等非鉴定环节。

(2) 法庭典型退化验证(是/部分/否)

因各工作的数据集、退化设置与评测协议不一,表中性能列均为原始文献自报数据,仅供把握能力上限与适用边界,不构成严格横向对比。“是”表示在 ≥ 1 个法庭典型数据集上系统评估(仅说明完成验证,不等同于已具法庭可采性);“部分”指在合成退化、公开数据集或子集上评估;“否”指仅在通用图像数据集上评估。“不适用”指方法属跨模态生成,不涉及图像退化复原,故不作此项评估。

(3) 严禁录入 AFIS

专用于潜在指纹增强方法。指纹同一认定建立在脊线细节点之上,凡方法可能生成、迁移或抹除细节点者,其输出即存在伪造或破坏同一认定特征的风险,若录入 AFIS 检索比对将污染结果、危及认定可靠性,故标注“严禁录入 AFIS”,其结果仅用于引导侦查或提示对原始指印重新提取复核。本项与 2.3 节相互印证。

(4) 丧失物理时空同一性

主要针对高度随机性退化下的扩散模型重建。当方法以概率推断重渲染场景的全局光照、色彩或几何属性,致输出不再与案发现场保持物理时空对应关系时,即认定其丧失物理时空同一性。此类结果不可用于颜色、光照等物理属性鉴定,仅作宏观空间布局参考。

参考文献

- [1]李晓龙,俞能海,张新鹏,等.数字媒体取证技术综述[J].中国图象图形学报,2021,26(06):1216-1226.
- LI X L, YU N H, ZHANG X P, et al. Overview of digital media forensics technology[J]. Journal of Image and Graphics, 2021, 26(06): 1216-1226.
- [2]GOODFELLOW I J, POUGET-ABADIE J, MIRZA M, et al. Generative adversarial nets[J]. Advances in Neural Information Processing Systems, 2014, 27.
- [3]HO J, JAIN A, ABBEEL P. Denoising diffusion probabilistic models[J]. Advances in Neural Information Processing Systems, 2020, 33: 6840-6851.
- [4]ROMBACH R, BLATTMANN A, LORENZ D, et al. High-resolution image synthesis with latent diffusion models[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 10684-10695.
- [5]GOZALO-BRIZUELA R, MERCHAN E E G. A survey of generative AI applications[J]. Journal of Computer Science, 2024, 20(8): 801-818.
- [6]LIU H, ZHENG X, HAN J, et al. Survey on GAN-based face hallucination with its model development[J]. IET Image Processing, 2019, 13(14): 2662-2672.
- [7]DOERSCH C. Tutorial on variational autoencoders[EB/OL]. arXiv, 2021[2026-04-11]. <http://arxiv.org/abs/1606.05908>.
- [8]KINGMA D P, WELING M. An introduction to variational autoencoders[J]. Foundations and Trends in Machine Learning, 2019, 12(4): 307-392.
- [9]ZENG Y, XUE D. An overview of generative adversarial networks[C]//2022 IEEE 2nd International Conference on Electronic Technology, Communication and Information (ICETCI). 2022: 550-552.
- [10]SOHL-DICKSTEIN J, WEISS E, MAHESWARANATHAN N, et al. Deep unsupervised learning using nonequilibrium thermodynamics[C]//International Conference on Machine Learning. PMLR, 2015: 2256-2265.
- [11]DHARIWAL P, NICHOL A. Diffusion models beat GANs on image synthesis[J]. Advances in Neural Information Processing Systems, 2021, 34: 8780-8794.
- [12]VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[J]. Advances in Neural Information Processing Systems, 2017, 30.
- [13]DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[EB/OL]. arXiv preprint arXiv:2010.11929, 2020[2026-04-11]. <https://arxiv.org/abs/2010.11929>.
- [14]WANG X, LI Y, ZHANG H, et al. Towards real-world blind face restoration with generative facial prior[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 9168-9178.
- [15]EDUPUGANTI V, MARDANI M, CHENG J, et al. VAE-GANs for

probabilistic compressive image recovery: Uncertainty analysis[EB/OL]. arXiv preprint arXiv:1901.11228, 2019[2026-04-11]. <https://arxiv.org/abs/1901.11228>.

[16]PASHINE S, MANDIYA S, GUPTA P, et al. Deep fake detection: survey of facial manipulation detection solutions[EB/OL]. arXiv preprint arXiv:2106.12605, 2021[2026-04-11]. <https://arxiv.org/abs/2106.12605>.

[17]TORTORA L. Beyond discrimination: Generative AI applications and ethical challenges in forensic psychiatry[J]. *Frontiers in Psychiatry*, 2024, 15: 1346059.

[18]FERGUS R, SINGH B, HERTZMANN A, et al. Removing camera shake from a single photograph[C]//ACM SIGGRAPH 2006 Papers. 2006: 787-794.

[19]RICHARDSON W H. Bayesian-based iterative method of image restoration[J]. *Journal of the Optical Society of America*, 1972, 62(1): 55-59.

[20]RUDIN L I, OSHER S, FATEMI E. Nonlinear total variation based noise removal algorithms[J]. *Physica D: Nonlinear Phenomena*, 1992, 60(1-4): 259-268.

[21]HE K, SUN J, TANG X. Single image haze removal using dark channel prior[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2010, 33(12): 2341-2353.

[22]DONG C, DENG Y, LOY C C, et al. Compression artifacts reduction by a deep convolutional network[C]//Proceedings of the IEEE International Conference on Computer Vision. 2015: 576-584.

[23]LEDIG C, THEIS L, HUSZÁR F, et al. Photo-realistic single image super-resolution using a generative adversarial network[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 4681-4690.

[24]WANG X, YU K, WU S, et al. ESRGAN: Enhanced super-resolution generative adversarial networks[C]//Proceedings of the European Conference on Computer Vision (ECCV) Workshops. 2018: 0-0.

[25]LIN M, LIU L, WANG F, et al. License plate image reconstruction based on generative adversarial networks[J]. *Remote Sensing*, 2021, 13(15): 3018.

[26]PAN Y, TANG J, TIAHJADI T. LPSRGAN: Generative adversarial networks for super-resolution of license plate image[J]. *Neurocomputing*, 2024, 580: 1-11.

[27]SHAFIEZADEH B, MASHMOOL A, ESHGHI F, et al. A new hybrid model of generative adversarial network and you only look once algorithm for automatic license-plate recognition[EB/OL]. arXiv preprint arXiv:2509.06868, 2025 [2026-04-11]. <https://arxiv.org/abs/2509.06868>.

[28]NA K, PARK G, KIM I. CharDiff-LP: A diffusion model with character-level guidance for license plate image restoration[EB/OL]. arXiv preprint arXiv:2510.17330, 2025[2026-04-11]. <https://arxiv.org/abs/2510.17330>.

[29]GONG H, ZHANG Z, FENG Y, et al. LP-Diff: Towards improved restoration of real-world degraded license plate[C]//Proceedings of the IEEE/CVF Conference on

Computer Vision and Pattern Recognition. 2025: 17831-17840.

[30]MAHMOUD M, SENUSSI M F, ABDALLA M, et al. M2UNet: A segmentation-guided GAN with attention-enhanced U2-Net for face unmasking[J]. Mathematics, 2026, 14(3): 477.

[31]ZHOU S, CHAN K, LI C, et al. Towards robust blind face restoration with codebook lookup transformer[J]. Advances in Neural Information Processing Systems, 2022, 35: 30599-30611.

[32]UGAIL H, ALAWAR H M, ZEHI A N A, et al. Latent diffusion based face enhancement under degraded conditions for forensic face recognition[EB/OL]. arXiv preprint arXiv:2508.00941, 2025[2026-04-11]. <https://arxiv.org/abs/2508.00941>.

[33]LIANG Y, ZHANG C, ZHAO J, et al. Skull-to-face: Anatomy-guided 3D facial reconstruction and editing[J]. IEEE Transactions on Visualization and Computer Graphics, 2024, 31(9): 6425-6436.

[34]JIAO M, LI J, ZHONG B, et al. De novo reconstruction of 3D human facial images from DNA sequence[J]. Advanced Science, 2025, 12(29): 2414507.

[35]ZHU Y, YIN X, HU J. FingerGAN: A constrained fingerprint generation scheme for latent fingerprint enhancement[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 45(7): 8358-8371.

[36]JIA Z, HUANG C, WANG Z, et al. Finger recovery transformer: Toward better incomplete fingerprint identification[J]. IEEE Transactions on Information Forensics and Security, 2024, 19: 8860-8874.

[37]GROSZ S A, JAIN A K. Universal fingerprint generation: Controllable diffusion model with multimodal conditions[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024, 47(2): 1028-1041.

[38]HUSSEIN N, JAIN A K, NANDAKUMAR K. Intra-finger variability of diffusion-based latent fingerprint generation[EB/OL]. arXiv preprint arXiv:2604.10040, 2026[2026-04-11]. <https://arxiv.org/abs/2604.10040>.

[39]KATE A. Generative colorization models for latent fingerprint enhancement using diffusion and GAN-based medical imaging techniques[D]. 2025.

[40]CHEN L, CHAN H Y. Denoising diffusion probabilistic model with wavelet packet transform for fingerprint generation[J]. Jordanian Journal of Computers and Information Technology, 2024, 10(4).

[41]WANG K, CHEN L, CAO B, et al. Text-to-face synthesis based on facial landmarks prediction[J]. Machine Vision & Applications, 2025, 36(1): 1.

[42]SERO D, ZAIDI A, LI J, et al. Facial recognition from DNA using face-to-DNA classifiers[J]. Nature Communications, 2019, 10(1): 2557.

[43]LI Y, WANG J, LIANG W, et al. CR-GAN: Automatic craniofacial reconstruction for personal identification[J]. Pattern Recognition, 2022, 124: 108400.

[44]PAN Y, WANG J, LIU G, et al. From skulls to faces: A deep generative framework for realistic 3D craniofacial reconstruction[C]//International Conference on Multimedia Modeling. Cham: Springer Nature Switzerland, 2024: 314-326.

[45]STATE OF WASHINGTON v. PULOKA[EB/OL]. Superior Court of Washington for King County, No. 21-1-04851-1, 2024-03-29[2026-04-11]. <https://wsbaflec.squarespace.com/s/State-v-Puloka.pdf>.

[46]GREYTAK E M, MOORE C C, ARMENTROUT S L. Genetic genealogy for cold case and active investigations[J]. Forensic Science International, 2019, 299: 103-113.

[47]HILL K. Wrongfully accused by an algorithm[N/OL]. The New York Times, 2020-06-24[2026-04-11]. <https://www.nytimes.com/2020/06/24/technology/facial-recognition-arrest.html>.

[48]KAWAR B, ELAD M, ERMON S, et al. Denoising diffusion restoration models[J]. Advances in Neural Information Processing Systems, 2022, 35: 23593-23606.

[49]TOLOSANA R, VERA-RODRIGUEZ R, FIERREZ J, et al. DeepFakes and beyond: A survey of face manipulation and fake detection[J]. Information Fusion, 2020, 64: 131-148.

[50]VERDOLIVA L. Media forensics and deepfakes: An overview[J]. IEEE Journal of Selected Topics in Signal Processing, 2020, 14(5): 910-932.

[51]PEI G, ZHANG J, HU M, et al. Deepfake generation and detection: A benchmark and survey[J]. ACM Computing Surveys, 2024, 56(11): 1-42.

[52]OJHA U, LI Y, LEE Y J. Towards universal fake image detectors that generalize across generative models[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 24480-24489.

[53]CORVI R, COZZOLINO D, POGGI G, et al. On the detection of synthetic images generated by diffusion models[C]//IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2023: 1-5.

[54]RÖSSLER A, COZZOLINO D, VERDOLIVA L, et al. FaceForensics++: Learning to detect manipulated facial images[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 1-11.

[55]KASHIANI H, TALEMI N A, AFGHAH F. FreqDebias: Towards generalizable deepfake detection via consistency-driven frequency debiasing[C]//2025 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2025: 8775-8785.

[56]KRUBHA Y S, HOU A, VESTER B, et al. Robust AI-generated face detection with imbalanced data[C]//2025 IEEE 8th International Conference on Multimedia Information Processing and Retrieval (MIPR). IEEE, 2025: 470-476.

[57]YANG Y, QIAN Z, ZHU Y, et al. D³: Scaling up deepfake detection by learning from discrepancy[C]//Proceedings of the Computer Vision and Pattern Recognition Conference. 2025: 23850-23859.

[58]YAN Z, LUO Y, LYU S, et al. Transcending forgery specificity with latent space augmentation for generalizable deepfake detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 8984-8994.

[59]GUO T, LI J, TANG Y. A score based likelihood ratio framework for deepfake image identification in forensic science[J]. Scientific Reports, 2026.

[60]LUGMAYR A, DANELLJAN M, ROMERO A, et al. RePaint: Inpainting using denoising diffusion probabilistic models[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 11461-11471.

[61]FERREIRA S, ANTUNES M, CORREIA M E. Exposing manipulated photos and videos in digital forensics analysis[J]. Journal of Imaging, 2021, 7(7): 102.

[62]ZHOU P, HAN X, MORARIU V I, et al. Learning rich features for image manipulation detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 1053-1061.

[63]WU Y, ABDALMAGEED W, NATARAJAN P. MANTRA-Net: Manipulation tracing network for detection and localization of image forgeries with anomalous features[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 9543-9552.

[64]COZZOLINO D, VERDOLIVA L. Noiseprint: A CNN-based camera model fingerprint[J]. IEEE Transactions on Information Forensics and Security, 2019, 15: 144-159.

[65]KWON M J, NAM S H, YU I J, et al. Learning JPEG compression artifacts for image manipulation detection and localization[J]. International Journal of Computer Vision, 2022, 130(8): 1875-1895.

[66]DONG C, CHEN X, HU R, et al. MVSS-Net: Multi-view multi-scale supervised networks for image manipulation detection[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 45(3): 3539-3553.

[67]GUILLARO F, COZZOLINO D, SUD A, et al. TruFor: Leveraging all-round clues for trustworthy image forgery detection and localization[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 20606-20615.

[68]YAO Y, HAN T, JIA S, et al. Dense feature interaction network for image inpainting localization[J]. IEEE Transactions on Information Forensics and Security, 2025, 20: 1636-1648.

[69]WANG K, NIU S, HAO Q, et al. INPDiffusion: Image inpainting localization

via conditional diffusion models[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2025, 39(7): 7771-7779.

[70]LOU Z, CAO G, GUO K, et al. Exploring multi-view pixel contrast for general and robust image forgery localization[J]. IEEE Transactions on Information Forensics and Security, 2025.

[71]LIU J, ZHANG F, ZHU J, et al. ForgeryGPT: Multimodal large language model for explainable image forgery detection and localization[EB/OL]. arXiv preprint arXiv:2410.10238, 2024[2026-04-11]. <https://arxiv.org/abs/2410.10238>.

[72]XU Z, ZHANG X, LI R, et al. FakeShield: Explainable image forgery detection and localization via multi-modal large language models[C]//International Conference on Learning Representations. 2025: 31186-31216.

[73]SHAO R, WU T, WU J, et al. Detecting and grounding multi-modal media manipulation and beyond[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024, 46(8): 5556-5574.

[74]MITTAL T, BHATTACHARYA U, CHANDRA R, et al. Emotions don't lie: An audio-visual deepfake detection method using affective cues[C]//Proceedings of the 28th ACM International Conference on Multimedia. 2020: 2823-2832.

[75]ZHOU Y, LIM S N. Joint audio-visual deepfake detection[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 14800-14809.

[76]LI Y, YANG X, SUN P, et al. Celeb-DF: A large-scale challenging dataset for deepfake forensics[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 3207-3216.

[77]DOLHANSKY B, BITTON J, PFLAUM B, et al. The deepfake detection challenge (DFDC) dataset[EB/OL]. arXiv preprint arXiv:2006.07397, 2020[2026-04-11]. <https://arxiv.org/abs/2006.07397>.

[78]DONG J, WANG W, TAN T. CASIA image tampering detection evaluation database[C]//2013 IEEE China Summit and International Conference on Signal and Information Processing. IEEE, 2013: 422-426.

[79]HSU Y F, CHANG S F. Detecting image splicing using geometry invariants and camera characteristics consistency[C]//2006 IEEE International Conference on Multimedia and Expo. IEEE, 2006: 549-552.

[80]WEN B, ZHU Y, SUBRAMANIAN R, et al. COVERAGE—A novel database for copy-move forgery detection[C]//2016 IEEE International Conference on Image Processing (ICIP). IEEE, 2016: 161-165.

[81]GUAN H, KOZAK M, ROBERTSON E, et al. MFC datasets: Large-scale benchmark datasets for media forensic challenge evaluation[C]//2019 IEEE Winter Applications of Computer Vision Workshops (WACVW). IEEE, 2019: 63-72.

[82]NOVOZAMSKY A, MAHDIAN B, SAIC S. IMD2020: A large-scale

annotated dataset tailored for detecting manipulated images[C]//Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision Workshops. 2020: 71-80.

[83]MAHFOUDI G, TAJINI B, RETRAINT F, et al. DeFacto: Image and face manipulation dataset[C]//2019 27th European Signal Processing Conference (EUSIPCO). IEEE, 2019: 1-5.

[84]MA X, ZHU X, SU L, et al. IMDL-BenCo: A comprehensive benchmark and codebase for image manipulation detection & localization[J]. Advances in Neural Information Processing Systems, 2024, 37: 134591-134613.

[85]JI Z, LEE N, FRIESKE R, et al. Survey of hallucination in natural language generation[J]. ACM Computing Surveys, 2023, 55(12): 1-38.

[86]ANGELOPOULOS A N, BATES S. Conformal prediction: A gentle introduction[J]. Foundations and Trends in Machine Learning, 2023, 16(4): 494-591.

[87]ABDAR M, POURPANAH F, HUSSAIN S, et al. A review of uncertainty quantification in deep learning: Techniques, applications and challenges[J]. Information Fusion, 2021, 76: 243-297.

[88]TANG N, YANG C, FAN J, et al. VerifAI: Verified generative AI[EB/OL]. arXiv preprint arXiv:2307.02796, 2023[2026-04-11]. <https://arxiv.org/abs/2307.02796>.

[89]GUAN T, LIU F, WU X, et al. HallusionBench: An advanced diagnostic suite for entangled language hallucination and visual illusion in large vision-language models[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 14375-14385.

[90]XU P, ZHU X, CLIFTON D A. Multimodal learning with transformers: A survey[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 45(10): 12113-12132.

[91]SELVARAJU R R, COGSWELL M, DAS A, et al. Grad-CAM: Visual explanations from deep networks via gradient-based localization[J]. International Journal of Computer Vision, 2020, 128(2): 336-359.

[92]LUNDBERG S M, LEE S I. A unified approach to interpreting model predictions[J]. Advances in Neural Information Processing Systems, 2017, 30.

[93]ARRIETA A B, DÍAZ-RODRÍGUEZ N, DEL SER J, et al. Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI[J]. Information Fusion, 2020, 58: 82-115.

[94]司法鉴定程序通则[J].中华人民共和国国务院公报,2016,(16):26-31.

General Rules for Forensic Identification Procedures [J]. Bulletin of the State Council of the People's Republic of China, 2016, (16): 26-31.

[95]公安部信息系统安全标准化技术委员会.电子数据法庭科学鉴定通用方法:GA/T 976-2012[S].中国标准出版社,2012.

Technical Committee on Information System Security Standardization under the Ministry of Public Security. *General Methods for Forensic Examination of Electronic Data: GA/T 976-2012* [S]. Standards Press of China, 2012.

[96]REMOLINA N, SOCOL DE LA OSA D. AI at the bench: Legal and ethical challenges of informing-or misinforming-judicial decision-making through generative AI[J]. Singapore Management University School of Law Research Paper Forthcoming, 2024.

[97]GOU J, YU B, MAYBANK S J, et al. Knowledge distillation: A survey[J]. International Journal of Computer Vision, 2021, 129(6): 1789-1819.

[98]GHOLAMI A, KIM S, DONG Z, et al. A survey of quantization methods for efficient neural network inference[M]//Low-Power Computer Vision. Chapman and Hall/CRC, 2022: 291-326.

[99]HAN S, POOL J, TRAN J, et al. Learning both weights and connections for efficient neural network[J]. Advances in Neural Information Processing Systems, 2015, 28.

[100]HU E J, SHEN Y, WALLIS P, et al. LoRA: Low-rank adaptation of large language models[J]. ICLR, 2022, 1(2): 3.

[101]SONG Y, DHARIWAL P, CHEN M, et al. Consistency models[J]. 2023.

[102]LUO S, TAN Y, HUANG L, et al. Latent consistency models: Synthesizing high-resolution images with few-step inference[EB/OL]. arXiv preprint arXiv:2310.04378, 2023[2026-04-11]. <https://arxiv.org/abs/2310.04378>.

[103]MCMAHAN B, MOORE E, RAMAGE D, et al. Communication-efficient learning of deep networks from decentralized data[C]//Proceedings of the 20th International Conference on Artificial Intelligence and Statistics. PMLR, 2017: 1273-1282.

[104]MENG Q, ZHOU F, REN H, et al. Improving federated learning face recognition via privacy-agnostic clusters[C]//International Conference on Learning Representations. 2023.

[105]BUOLAMWINI J, GEBRA T. Gender shades: Intersectional accuracy disparities in commercial gender classification[C]//Conference on Fairness, Accountability and Transparency. PMLR, 2018: 77-91.

[106]MEHRABI N, MORSTATTER F, SAXENA N, et al. A survey on bias and fairness in machine learning[J]. ACM Computing Surveys, 2021, 54(6): 1-35.

[107]XU Q, ZHANG Z, HUANG Z, et al. Advancements in AI-generated content forensics: A systematic literature review[J]. ACM Computing Surveys, 2025, 57(8): 1-45.

[108]RAJI I D, SMART A, WHITE R N, et al. Closing the AI accountability gap: Defining an end-to-end framework for internal algorithmic auditing[C]//Proceedings

of the 2020 Conference on Fairness, Accountability, and Transparency. 2020: 33-44.

