

面向轻量级目标检测的多尺度特征融合算法

王海超, 李金凤⁺, 刘志超

(沈阳化工大学 信息工程学院, 辽宁 沈阳 110142)

摘要: 为解决在目标检测网络中使用特征融合方法带来的参数量大、计算复杂度高的问题, 提出了一种融合无参注意力机制 (SimAM) 的特征融合方法。对动态蛇形卷积 (DSConv) 进行轻量化处理 (Light-DSConv)。利用该结构自主学习目标几何形状的能力, 对小目标的特征进行二次提取。利用 SimAM 模块对特征图空间域的重要性进行划分并与通道域权重相结合, 进一步提升模型性能。在 Pascal VOC 2007 测试集上测试融合模块的有效性。结果表明: 轻量化后, 单个 DSConv 结构参数量下降 85.6%。模型平均精度 (mean average precision, mAP) 比基线模型增加了 4.41%, 比添加现有特征融合方法模型平均增加 3.78%。所提出模块的参数量、计算量、检测速度与现阶段其它方法相比均具有一定优势。

关键词: 特征融合; 目标检测; 轻量化; 卷积神经网络; 嵌入式; 平均精度; 注意力机制

中图法分类号: TP391 **文献标识码:** A **文章编号:** 1000-7024 (2025) 09-2494-08

doi: 10.16208/j.issn1000-7024.2025.09.008

Multi-scale feature fusion algorithm for lightweight object detection

WANG Hai-chao, LI Jin-feng⁺, LIU Zhi-chao

(School of Information Engineering, Shenyang University of Chemical Technology, Shenyang 110142, China)

Abstract: To solve the issue of large parameter sizes and high computational complexity caused by using feature fusion methods in object detection networks, a feature fusion method incorporating a parameter-free attention mechanism (SimAM) was proposed. Dynamic snake convolution (DSConv) was lightweighted to form Light-DSConv, leveraging its autonomous geometric-shape learning capability for secondary feature extraction of small targets. By integrating SimAM modules that partition spatial-domain importance and combine it with channel-domain weights on feature maps, the model performance was further enhanced. The effectiveness of the fusion module was validated on the Pascal VOC 2007 test set. Results demonstrate that after lightweight processing, the parameter count of a single DSConv structure decreases by 85.6%. The model's mean average precision (mAP) increases by 4.41% compared to the baseline model and by 3.78% compared to models with existing feature fusion methods. The proposed module demonstrates advantages in parameter count, computational complexity, and detection speed compared to other methods currently available.

Key words: feature fusion; object detection; lightweight; convolutional neural network; embedded; mean average precision (mAP); attention mechanism

0 引言

基于深度神经网络的目标检测算法为目标检测提供了新的解决方案、新的网络结构, 被广泛的应用在智能交通^[1]、智慧城市^[2]、辅助驾驶^[3]等领域, 是近年来计算机视觉领域最具挑战的研究任务之一。目标检测网络主要由

骨干网络和检测网络组成。骨干网络主要负责对输入图像特征提取, 检测网络对特征图进行目标的定位、分类等操作。检测网络主要有基于锚框的单阶段目标检测和两阶段目标检测。与两阶段目标检测算法相比单阶段目标检测权衡检测准确率与算法计算复杂度、参数量的关系。以提高算法在平台上的部署。然而实际应用中所采用的移动终端

收稿日期: 2024-06-02; 修订日期: 2025-09-01

基金项目: 辽宁省教育厅基本科研基金项目 (JYTMS20231500)

作者简介: 王海超 (2000-), 男, 山东潍坊人, 硕士研究生, CCF 学生会员, 研究方向为深度学习、目标检测; ⁺通讯作者: 李金凤 (1979-), 女, 辽宁大石桥人, 博士, 副教授, 研究方向为集成电路设计、FPGA、嵌入式系统设计; 刘志超 (1996-), 男, 河北邯郸人, 硕士研究生, 研究方向为移动机器人路径规划。E-mail: 1875116671@qq.com

或边缘设备计算资源有限、储存能力弱。因此, 如何在提高模型性能的同时保证其轻量化成为亟待解决的问题。特征融合作为提升目标检测网络性能的一种关键技术, 但是以往的特征融合方法在提高模型性能的同时往往会使模型变得臃肿。这也就需要研究者在检测精度、检测速度与模型大小三者之间做出权衡。

1 研究现状及本文工作

基于卷积神经网络的目标检测算法中, 骨干网络对图像进行目标提取时, 会把最终提取到的特征图输入到检测网络中。这种单一的特征图会使模型的检测效果不理想。有效的特征交互可以使特征获得更丰富的表征^[4], 从而使目标检测模型能学习到图像中更全面的信息。由于目标尺寸的不确定性, P. Doll'ar等提出了在网络上进行特征金字塔的融合方法 (FFP), 对每个不同大小的对象分配具有适当上下文信息的感兴趣区域。加入特征融合方法使这些对象在不同大小的特征层中被识别。这种融合方法给模型带来了一定的参数量和计算量, 但对模型的性能有较大提升。Chen等^[5]对FPN结构进行改进 (HS-FPN), 在编码器操作中融合多尺度可变形注意力机制, 利用通道注意力产生的权重信息对低级特征进行筛选, 达到有效提取图像全局特征并筛选有用特征的目的。FPT^[6]提出层内融合和层间跨空间融合的特征融合方法, 并取得了显著效果。在InceptionNet^[7]系列网络中, 以 1×1 大小的卷积降低特征厚度, 使用多个尺寸的卷积核达到对输入图像提取不同尺寸特征的目的, 以应对目标大小的变化。但模型结构和参数设置较为复杂, 对计算资源消耗较大。在残差网络 (ResNet)^[8,9]中, 通过shortcut连接将等价映射特征和残差学习特征融合为输出, 解决网络退化问题的同时实现层与层之间的特征融合。Y. Quan等^[10]注意到图像的角落区域对密集预测任务的重要性, 利用最深层的层内特征获得的显示视觉中心信息来调节正面浅层特征。杨扬等^[11]提出一种多特征融合改进FPN的多尺度目标检测算法, 这种方法改善了FPN通过 1×1 卷积统一通道数会丢失通道信息的问题。然而在考虑使用特征融合方法提高模型性能的同时, 考虑到特征融合模块带来的计算成本问题, 优化卷积方式是有效权衡特征提取与计算成本的措施。Li等^[12]提出一种简化的卷积操作, 该卷积由空间重建单元 (SRU) 与信道重建单元 (CRU) 组成, 这种方法可以有效的降低计算量并有效的提取特征。Qi等^[13]提出可变形卷积可以在特征融合阶段增强感知, 可以准确捕捉弯曲的局部结构。MobileNetV3^[14]利用深度可分离卷积结构大幅度降低网络的参数量与计算量。Liu等^[15]设计了一种自校准卷积, 自适应的在每个空间位置周围构建远程空间和通道空间的依赖关系, 在不改变模型架构的前提下, 改进卷积特征转换过程。H. Li等^[16]把标准卷积和深度可分

离卷积相结合, 设计了一种GSConv的卷积方式, 降低了计算量。

小目标物体在图像中所占比例较小, 像素构成有限而难以捕捉, 小目标物体的特征不够明显, 导致小目标物体检测精度低, 为了模型能有效注意到小目标物体的关键特征, 捕获小目标物体特征之间的相关性, 卢志刚等^[17]使用一种允许网络执行特征重新校准的机制 (squeeze-and-dexcitation, SE) 模块, 解决图像分割时存在的孔洞问题, 这使网络能够融合特征图局部的通道信息, 使模型的性能有效提升。Zhang等^[18]提出一种注意力机制, 解决把空间注意力和通道注意力融合在一起时带来的较大计算开销问题。Yang等^[19]基于神经科学理论, 提出了一种不向原始网络中添加参数的情况下加强层内特征映射的3D注意力权重 (SimAM), 此结构有效提升了网络的表达能力。

综上所述, 本文对如何使特征融合模块有效提升网络性能加以研究, 主要创新点有:

(1) 设计多阶段级联特征融合模块 Light-DS-fusion, 使最终特征图更好的融合多尺度特征, 提高模型对不同宽高比物体的检测能力;

(2) 引入无参注意力机制 SimAM, 把 SimAM 融合到设计的特征融合模块, 同时抓取特征图之间的通道与空间的重要性关系, 提升特征融合效果;

(3) 对动态蛇形卷积进行优化, 有效降低整体模块的参数量与计算量。

2 相关算法

在实际应用中, 常需要把算法部署到嵌入式平台或者移动终端中。由于硬件资源受限, 需要大量内存资源和计算能力的模型部署困难。由此, 一种轻量级的无锚框网络架构应运而生 (ConerNet^[20]、CenterNet^[21])。无锚框检测方法是对关键点的检测, 通过关键点的位置信息来生成预测边界框, 再根据损失函数和偏移量对方框的大小进行回归。这种无锚框的检测方法通过减少模型参数量, 提高模型在训练时的计算效率。

2.1 检测端网络

CenterNet 是一种无锚框目标检测算法, 如图 1 所示。算法主要通过左上点、右上点和中心点对目标进行识别。得到骨干特征图后, 使用 3 个上采样 (Deconvolution) 对特征图进行步长为 4 的卷积采样, 实现更高分辨率的输出。使用该算法可以有效提高算法的运行速度。CenterNet 的损失函数 L_{det} 可以分为 3 部分: 热图损失 $L_k (\alpha=2, \beta=4)$ 、尺寸损失 L_s 和偏移损失 L_{off} 。由此模型总损失为

$$L_{\text{det}} = L_k + \lambda_s L_s + \lambda_{\text{off}} L_{\text{off}} \quad (1)$$

式中: λ_s 、 λ_{off} 是自定义的权重参数。进一步优化损失函数, 使模型能更好更快的收敛

$$L_K = \frac{-1}{N} \sum_{xyc} \begin{cases} (1 - \hat{Y}_{xyc})^\alpha \log(\hat{Y}_{xyc}), & \text{if } Y_{xyc} = 1 \\ (1 - Y_{xyc})^\beta (\hat{Y}_{xyc})^\alpha \log(1 - \hat{Y}_{xyc}), & \text{otherwise} \end{cases} \quad (2)$$

式中: $\hat{Y}$ 为关键点热图 $\hat{Y} \in [0, 1]^{\frac{W}{R} \times \frac{H}{R} \times C}$, α 和 β 是焦点损失的超参数, N 是图像 I 中的关键点数量, $Y_{xyc} = \exp\left(-\frac{(x - \tilde{p}_x)^2 + (y - \tilde{p}_y)^2}{2\sigma_p^2}\right)$ 是高斯核函数, σ_p 为对象尺寸自适应标准差




图1 CenterNet 目标检测流程

2.2 利用 SimAM 注意力机制增强特征提取

大多数注意力机制只能沿通道维度或者空间维度进行权重更新, 这限制了网络学习的灵活性。Yang 等^[19] 提出了一个无参注意力机制 SimAM, 如图 2 所示。这种注意力机制模仿视觉神经科学同时学习通道域与空间域的权重, 通过测量一个神经元目标与其它神经元之间的线性可分性寻找更高优先级的神经元, 并为每个神经元定义能量函数

$$e_i(\omega_i, b_i, y, x_i) = (y_i - \hat{t})^2 + \frac{1}{M-1} \sum_{i=1}^{M-1} (y_o - \hat{x}_i)^2 \quad (5)$$

式中: $\hat{t} = \omega_i t + b_i$, $\hat{x}_i = \omega_i x_i + b_i$ 是 t 与 x_i 的线性变换, 其中 t 与 x_i 是输入特征 X 的目标神经元和单个通道中的神经元, i 是空间维度上的索引, M 是输入特征图的大小, ω_i 与 b_i 是网络学习到的权重与偏置。为了简化, 对 y_i 与 y_o 进行二值标记 (即 1 与 -1), 并加入正则化

$$e_i(\omega_i, b_i, y, x_i) = \frac{1}{M-1} \sum_{i=1}^{M-1} (-1 - (\omega_i x_i + b_i))^2 + \quad (6)$$

$$(1 - (\omega_i t + b_i))^2 + \lambda \omega_i^2$$

$$\omega_i = -\frac{2(t - \mu_i)}{(t - \mu_i)^2 + 2\sigma_i^2 + 2\lambda} \quad (7)$$

$$b_i = -\frac{1}{2}(t + \mu_i)\omega_i \quad (8)$$

μ_i 与 σ_i^2 是该通道中除 t 之外的所有神经元上计算的平均值和方差。

2.3 提出的级联特征融合算法

为解决特征融合时参数过多导致模型体积过大、部署困难的问题, 利用多尺度、级联特征融合的方式, 使输入检测端的特征图获得高分辨率的语义特征。目标的纹理、

$$L_{size} = \frac{1}{N} \sum_{k=1}^N |\hat{S}_{p_k} - s_k| \quad (3)$$

式中: $s_k = (x_2^{(k)} - x_1^{(k)}, y_2^{(k)} - y_1^{(k)})$ 为物体大小, $p_k = (\frac{x_1^{(k)} + x_2^{(k)}}{2}, \frac{y_1^{(k)} + y_2^{(k)}}{2})$ 为类别为 c_k 的对象 k 的边界框的中心点

$$L_{off} = \frac{1}{N} \sum_{k=1}^N SmoothL_1Loss(o_k, \hat{o}_k) \quad (4)$$

式中: $SmoothL_1Loss$ 为平滑 L_1 损失函数, o_k , $\hat{o}_k$ 分别为目标框的中心坐标、预测目标框的中心坐标。




图2 SimAM 注意力机制

线条等信息大多包含在低层特征中。低层特征经过卷积抽象后, 得到更丰富的语义信息也就是高层特征。

首先将输入图像送入骨干网络 (即 ResNet18), 输出特征层 $X_i (i=0, 1, 2, 3, 4)$, 其中每组特征层 $X_i (i=0, 1, 2, 3, 4)$ 的空间大小分别是输入图像的 $1/2, 1/4, 1/8, 1/16, 1/32$ 。基于这 4 组特征层, 并且利用两个级联阶段对低层特征图进行语义抽象。使低层特征中的纹理、线条信息尽可能地被利用, 提升模型性能。为降低计算成本, 设计了一种轻量的级联特征融合策略, 如图 3 所示: 利用 layer_4 输出特征后先经过 SimAM 注意力机制得到高层特征,

layer_2、layer_3的输出特征图经过轻量化之后的动态卷积结构学习目标的几何形状得到低层特征并拼接, 得到两个低层特征图的综合信息。低层特征经过平均池化层后与高

层特征按元素相乘, 输入到后续卷积层做多尺度特征提取, 最后由 Conv1×1 调整特征图通道数并输入到检测网络。




图3 网络整体结构

2.4 动态蛇形卷积轻量化设计

为使神经网络对目标的形状变化更敏感, 王登科等^[22]使用了空洞卷积 (dilated convolution), 提升模型对裂隙结构的识别能力。Li 等^[23]使用可变形卷积 (deformable convolution) 扩大模型感受野, 增强网络提取不规则分布特征的能力。这些卷积结构允许网络自主学习目标结构的几何变化。但考虑到卷积时的过度随机性给网络带来的收敛难度大的问题, Qi 等^[13]在前两种卷积结构的基础上提出了动态蛇形卷积 (dynamic snake convolution, DSConv)。该卷积分别在 x 、 y 方向上把标准卷积核拉直。以 x 方向为例, 定义一个标准卷积核 K , 设卷积核中心为 $K_i = (x_i, y_i)$ 则在 DSConv 中, K 中每个网格可具体地表示为: $K_{i \pm c} = (x_i \pm c, y_i \pm c)$, $c = \{0, 1, 2, 3, 4\}$

$$K_{i \pm c} = \begin{cases} (x_{i+c}, y_{i+c}) = (x_i + c, y_i + \sum_{j=i}^{i+c} \Delta y_j) \\ (x_{i-c}, y_{i-c}) = (x_i - c, y_i + \sum_{j=i-c}^i \Delta y_j) \end{cases} \quad (9)$$

式中: $c = \{0, 1, 2, 3, 4\}$ 表示卷积核 K 中位置与卷积核中心的水平距离, 卷积核 K 中每个网格的位置 $K_{i \pm c}$ 是一个累积的过程, K_{i+1} 与 K_i 之间增加一个偏移量 $\Delta = \{\delta | \delta \in [-1, 1]\}$ 。同理, 在 y 方向上为

$$K_{j \pm c} = \begin{cases} (x_{j+c}, y_{j+c}) = (x_j + \sum_{i=j}^{j+c} \Delta x_i, y_j + c) \\ (x_{j-c}, y_{j-c}) = (x_j + \sum_{i=j-c}^j \Delta x_i, y_j - c) \end{cases} \quad (10)$$

动态蛇形卷积 (DSConv) 结构如图4所示, 把输入特征图分别输入到线性卷积核 Conv0x、Conv0y 和标准卷积核中, 经过组归一化和激活函数后, 利用 1×1 卷积核将三者通道维度上融合, 融合后输出再经过组归一化和激活函数。

4种卷积核卷积方式对比如图5所示。动态蛇形卷积的卷积核可以通过偏置量在 x 、 y 方向上改变形状, 达到捕捉目标边界的目的。




图4 DSConv 结构

DSConv 卷积结构伴随着大量的参数产生。本文在 DSConv 的基础上使用深度可分离卷积对其轻量化设计, 把 DSConv 中卷积核大小为 3×3 的标准卷积替换为卷积核大小为 3×3 , 步长为 1, 扩展为 1 的逐通道卷积和卷积核大小为 1×1 , 步长为 1, 扩展为 0 的逐点卷积。在保证结构性能的同时减少该卷积结构带来的参数量, 轻量化之后的卷积结构 (Light-DSConv) 的参数量比原结构降低了 85.6%。内存占用降低了 86.3%。表 1 为当输入图像为 $3 \times 512 \times 512$ 、输出 channel 为 64 时, 标准卷积、深度可分离卷积、DSConv、Light-DSConv 的参数量及占用内存情况对比。




图5 卷积方式对比

表1 4种卷积参数量对比

卷积方式	参数量/ 10^3	内存占用/MB
标准卷积	1.792	0.01
深度可分离卷积	0.286	—
DSConv	114.6	0.44
Light-DSConv	16.482	0.06

3 实验验证

本实验在处理器: 12th Gen Intel(R) Core(TM) i5-12400F, 显卡: NVIDIA GeForce RTX 3060, 内存为16 G的台式机上运行, CUDA版本为12.3, 其中各个脚本在Pytorch2.1.2架构下编写。本实验网络模型在PASCAL

VOC 2007+PASCAL VOC 2012 训练集上训练, 在PASCAL VOC 2007测试集上进行测试。选择ResNet18作为骨干网络提取特征, 检测网络选择CenteNet。Warm up epoch设为2。每5个epoch进行一次测试集测试, 初始学习率为 1×10^{-3} , epoch大于2小于90时学习率为 1×10^{-3} , epoch大于90且小于150时学习率为 1×10^{-4} , epoch大于150时为 1×10^{-5} 。共训练200个epoch。优化器选择SGD, Weight decay设为 1×10^{-3} , momentum设为0.98。batch size为16。输入图像大小为 512×512 。文中所涉及到的mAP均为IOU=0.5时的各类精度的平均。

为验证本文提出特征融合方法的有效性和优越性, 本文进行两组对比实验。在第一组对比实验中, 即表2中列出本文所用网络与当前各种先进方法在Pascal voc 2007测试集上的所有类别的平均精确度(mAP)与检测速度对比。由表2可知, 基准模型使用Light-DS-fusion算法进行特征融合后平均精度比基准模型提高了9.01%。如表2所示, 经过轻量化设计的动态蛇形卷积结构(Light-DSConv)加入到网络中, 网络整体参数量下降了17.5%, 计算量下降了18%, 性能没有受到负面影响, 表明提出的轻量化方案是有效的。在特征融合模块中加入SimAM注意力机制后, Light-DS-fusion算法的参数量的增长几乎可以忽略不计, 但模型性能提升了0.5%, 表明注意力模块的引入可以有效地用函数衡量特征映射中的每个神经元的重要性。本文特征融合方法(Light-DS-fusion)与文献[10]、文献[11]相比, mAP分别上涨了5.74%、2.22%, 测试时间缩短了2 ms。虽然本文检测准确率与文献[24]的有微小差距, 但本文检测速度比文献[24]的检测速度快将近18倍。虽然文献[25]中使用的模型体积比本文更小, 但本文模型检测速度与检测准确率比文献[25]分别提高31%、7.62%。

表2 模型性能对比

方法	网络结构	测试集/07test	参数量/ 10^6	FLOPs/ 10^9	mAP@.5/%	Test time/(ms/image)
基准模型	ResNet18	✓	15.82	40.45	68.01	12
文献[10]	ResNet18	✓	18.80	44.69	71.28	15
文献[11]	ResNet50	✓	44.80	336.3	74.80	—
文献[24]	VGG16	✓	—	—	77.50	234
文献[25]	MobileNet V3-Large	✓	14.14	35.21	69.40	19
基准模型+DSConv	ResNet18	✓	22.68	53.04	76.43	—
基准模型+Light-DSConv	ResNet18	✓	18.70	43.42	76.50	11.2
基准模型+Light-DS-fusion	ResNet18	✓	18.79	43.42	77.02	13

本方法可以很好地对目标进行定位, 在检测不同宽高比的物体具有明显优势。模型输出热力图结果如图6所示, 由图6可知, 图6(c)、图6(d)的模型的注意力只定位在

判别性最强的区域, 这有利于模型对目标的准确分类。

第二组对比实验将本文方法与文献[10]方法分别放入Resnet18-CenterNet网络中对比, 即表3。表3为特征融




图 6 模型的输出热力图对比

表 3 Pascal VOC 2007 中各类别准确率对比

模型	aero table	bike dog	bird horse	boat mbike	bottle person	bus plant	car sheep	cat sofa	chair train	cow tv	mAP@. 5/%
基准模型	72.07	75.25	68.04	59.89	56.29	73.80	76.57	67.88	55.33	80.10	68.01
	49.16	69.42	79.88	72.59	72.42	47.11	77.32	60.13	73.67	73.28	
文献[10]	75.49	77.50	70.51	62.31	59.43	78.72	82.44	74.42	55.95	83.66	71.28
	53.24	74.48	82.38	79.70	76.29	49.02	78.30	61.85	76.68	73.18	
基准模型+ DSConv	78.19	82.61	76.01	68.83	57.47	84.07	85.26	84.21	61.55	85.27	76.43
	68.83	82.17	86.45	80.38	79.36	52.73	83.86	72.01	81.38	77.99	
基准模型+ Light-DS-fusion	77.99	83.17	76.55	71.14	58.15	85.11	85.85	84.60	60.87	86.12	77.02
	71.70	83.13	86.92	83.23	78.43	54.10	83.04	71.10	81.85	77.31	

合模块进行消融实验时对数据集中 20 个分类的结果展示。对于 Pascal VOC 2007 数据集中比较难检测的小目标物体, 例如 plant、bird, 在应用本文的算法后, 较基准模型准确率分别有 6.99% 与 8.51% 的提升。较文献 [10] 方法, 准确率分别提升 5.08%、6.04%。这表明使用本文设计的特

征融合算法可以加强网络对小目标物体的检测能力。有效提高小目标的检测准确率。

应用本文特征融合方法后, 在 Pascal VOC 2007 数据集上目标检测的整体准确率有所上升。文献 [10] 对被遮挡物体检测能力不足的问题也得到改善, 如图 7 所示。使




图7 基准模型+Light-DS-fusion检测结果

用本文的特征融合方法, 图像中的目标被有效的检测出来, 有效避免了漏检和误检情况。如图8所示。使用文献[10]的方法, 图8(a)中男性胸前的狗由于被遮挡, 并没有被网络识别。图8(c)中还将路边杂物错误的识别为Car类别。当图像中目标为单个物体时如图7(e)、图8(e), 本文方法定位区域与目标轮廓的紧凑程度有待提高。

4 结束语

本文提出了一种特征融合结构Light-DS-fusion。利用级联融合的方式, 深度融合多尺度特征, 获得了更丰富的多尺度特征表示。较大幅度提升目标检测网络的性能。利用深度可分离卷积对动态蛇形卷积(DSConv)结构进行轻量化, 减少参数量与计算量, 并在模块中引入SimAM注意力机制, 在特征图空间上与通道中都引入权重函数。在Pascall VOC 2007测试集上验证算法的有效性, mAP值可达77.02%。在不改变模型结构的前提下, 本文设计的特征融合模块即插即用, 在复杂场景进行目标检测时仍具有良好的效果。如何在优化模块结构的同时更好的增加模型的性能将成为未来研究方向。




图8 文献[10]检测结果

参考文献:

- [1] CHEN Dongdong, REN Xiaoming, LI Dengpan, et al. Research on binocular vision vehicle detection and ranging method based on improved YOLOv5s[J]. Journal of Optoelectronics·Laser, 2024, 35(3): 311-319 (in Chinese). [陈冬冬, 任晓明, 李登攀, 等. 基于改进的YOLOv5s的双目视觉车辆检测与测距方法研究[J]. 光电子·激光, 2024, 35(3): 311-319.]
- [2] Anwer S, Samar MA, Akshay V, et al. FireNet-v2: Improved lightweight fire detection model for real-time IoT applications[J]. Procedia Computer Science, 2023, 218: 2233-2242.
- [3] Wen L, Du D, Cai Z, et al. UA-DETRAC: A new benchmark and protocol for multi-object detection and tracking[J]. Computer Vision and Image Understanding, 2020, 193: 102907.
- [4] Vashishth S, Sanyal S, Nitin V, et al. InteractE: Improving convolution-based knowledge graph embeddings by increasing feature interactions[C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2020: 3009-3016.
- [5] Chen YF, Zhang CY, Chen B, et al. Accurate leukocyte detection based on deformable-DETR and multi-level feature fusion for aiding diagnosis of blood diseases[J]. Computers in Biology and Medicine, 2024, 170: 170-917.
- [6] Zhang D, Zhang H, Tang J, et al. Feature pyramid transformer

- [C]//Computer Vision-ECCV 2020: 16th European Conference. Glasgow: Springer International Publishing, 2020: 323-339.
- [7] JIANG Shen, YIN Shirong, LUO Tianhong, et al. Multi-object vehicle detection algorithm based on improved YOLOv4 [J]. Computer Engineering and Design, 2024, 45(4): 1181-1188 (in Chinese). [江岫, 殷时蓉, 罗天洪, 等. 基于改进YOLOv4的多目标车辆检测算法[J]. 计算机工程与设计, 2024, 45(4): 1181-1188.]
- [8] Chander Racha S, Deb T, Sahu I, et al. Domain-principled inference with ResNet-transformer model for 12-lead ECG classification[C]//International Joint Conference on Neural Networks. Padua, IEEE, 2022: 1-8
- [9] Zhang Z, Zhang S. Towards understanding residual and dilated dense neural networks via convolutional sparse coding[J]. National Science Review, 2021, 8(3): 127-139.
- [10] Quan Y, Zhang D, Zhang L, et al. Centralized feature pyramid for object detection[J]. IEEE Transactions on Image Processing, 2023, 32: 4341-4354.
- [11] YANG Yang, TANG Xiaofen. ResFPN: A multi-scale object detection algorithm for expanding the actual receptive field and improving FPN[J]. Computer Engineering and Applications, 2025, 61(10): 247-257 (in Chinese). [杨扬, 唐晓芬. ResFPN: 扩增实际感受野和改进FPN的多尺度目标检测方法[J]. 计算机工程与应用, 2025, 61(10): 247-257.]
- [12] Li J, Wen Y, He L. Sconv: Spatial and channel reconstruction convolution for feature redundancy [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Vancouver: IEEE, 2023: 6153-6162.
- [13] Qi Y, He Y, Qi X, et al. Dynamic snake convolution based on topological geometric constraints for tubular structure segmentation [C]//Proceedings of the IEEE/CVF International Conference on Computer Vision, 2023: 6070-6079.
- [14] Howard A, Sandler M, Chu G, et al. Searching for mobilenetv3 [C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. Seoul: IEEE, 2019: 1314-1324.
- [15] Liu JJ, Hou Q, Cheng MM, et al. Improving convolutional networks with self-calibrated convolutions[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Seattle: IEEE, 2020: 10096-10105.
- [16] Li H, Li J, Wei H, et al. Slim-neck by GSConv: A better design paradigm of detector architectures for autonomous vehicles[EB/OL]. [2024-06-28]. <https://arxiv.org/pdf/2206.02424>.
- [17] LU Zhigang, CHEN Fangmiao, YUAN Chao, et al. Research on extracting special plant planting plots from high-resolution remote sensing images using I-PSPNet semantic segmentation model[J]. Remote Sensing Technology and Application, 2024, 39(1): 222-233 (in Chinese). [卢志刚, 陈芳淼, 袁超, 等. 采用I-PSPNet语义分割模型的高分辨率遥感影像某种植物种植地块提取研究[J]. 遥感技术与应用, 2024, 39(1): 222-233.]
- [18] Zhang QL, Yang YB. Sa-net: Shuffle attention for deep convolutional neural networks[C]//IEEE International Conference on Acoustics, Speech and Signal Processing. Toronto: IEEE, 2021: 2235-2239.
- [19] Yang L, Zhang RY, Li L, et al. Simam: A simple, parameter-free attention module for convolutional neural networks[C]//International Conference on Machine Learning. Online: PMLR, 2021: 11863-11874.
- [20] Law H, Deng J. CornerNet: Detecting objects as paired keypoints[J]. International Journal of Computer Vision, 2020, 128(2): 642-656.
- [21] Duan K, Bai S, Xie L, et al. Centernet: Keypoint triplets for object detection[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. Seoul: IEEE, 2019: 6569-6578.
- [22] WANG Dengke, FANG Yu, WEI Jianping, et al. Intelligent extraction of Micro-CT fissures in coal based on deep learning and its application[J]. Journal of China Coal Society, 2024, 49(8): 3439-3452 (in Chinese). [王登科, 房禹, 魏建平, 等. 基于深度学习的煤岩Micro-CT裂隙智能提取与应用[J]. 煤炭学报, 2024, 49(8): 3439-3452.]
- [23] Li Z, Tai Y, Huang Z, et al. MPFANet: A multipath feature aggregation network for steel surface defect detection [J]. Measurement Science and Technology, 2024, 35(4): 045409.
- [24] LI Zhixin, CHEN Shengjia, ZHOU Tao, et al. Combining cascaded network and adversarial network for object detection [J]. Journal of Frontiers of Computer Science and Technology, 2022, 16(1): 217-230 (in Chinese). [李志欣, 陈圣嘉, 周韬, 等. 协同级联网络和对抗网络的目标检测[J]. 计算机科学与技术探索, 2022, 16(1): 217-230.]
- [25] Li Y, Xiong X, Xin W, et al. MobileNetV3-CenterNet: A target recognition method for avoiding missed detection effectively based on a lightweight network[J]. Journal of Beijing Institute of Technology, 2023, 32(1): 82-94.