

顾及场景先验信息的大规模室内环境激光雷达建图

罗俊奇¹, 叶勤^{1,2*}, 杨泽鑫³, 张绍明¹, 曾亮¹¹同济大学测绘与地理信息学院, 上海 200092;²自然资源部城市国土资源监测与仿真重点实验室, 广东 深圳 518034;³广州市城市规划勘测设计研究院有限公司, 广东 广州 510060

摘要 针对大规模室内环境激光雷达建图过程中帧间配准精度低、累积误差大的问题,本团队提出了一种融合多类型场景先验信息的移动建图方法。通过构建融合文本、图像与模型等多源场景先验信息的建筑骨架特征提取框架,形成了支持室内定位建图的高效辅助数据;通过设计建筑骨架特征模式,并研究基于它的两阶段检索与配准机制,实现了全局定位与位姿优化约束的构建;通过引入骨架丰富度引导机制,提升了不同场景下激光里程计方法的鲁棒性;提出了点云地图轻量化表征策略,该策略兼顾语义结构与表达效率,可以提升轻量化点云地图在辅助定位与环境感知方面的效率。实验结果表明,本文方法在办公楼、展览厅、地下车库等典型场景中均可实现精度优于 10 cm 的点云地图在线构建,算法效率优于现有主流激光里程计方法,可以更好地满足移动机器人定位与环境感知需求。

关键词 激光雷达; 移动建图; 场景先验信息; 室内全局定位

中图分类号 TP79

文献标志码 A

DOI: 10.3788/CJL241471

1 引言

近年来,智能无人系统发展迅猛,其通过移动平台搭载感知设备获取影像和点云,实现自主定位与建图,已被广泛应用于自动驾驶、智慧物流等领域^[1-3]。其中,移动激光扫描凭借机动灵活、对光照变化不敏感等优势,成为室内主流建图方案^[4-5]。然而,现有系统多依赖高线束激光雷达获取稠密点云,存在设备昂贵、体积庞大等问题,限制了其大规模应用。为适应大规模室内环境低成本、泛场景建图应用,亟须构建适用于低线束激光雷达的高效室内移动建图方法。

基于激光雷达的室内移动建图的核心在于通过感知点云实现全局定位、估计帧间位姿与构建点云地图。然而,低线束激光雷达获取的点云稀疏,结构信息弱,导致建图面临以下挑战:

1) 全局定位困难。现有室内全局定位多依赖于外置辐射源和点云参考图^[6]。前者基于蓝牙、Wi-Fi 等信号^[7-8]实现米级定位,定位精度受限;后者的点云参考图依赖于架站式激光扫描仪构建^[9],成本高,而且难以覆盖大规模场景。部分研究尝试通过引入建筑平面图^[10-11]、三维模型^[12-13]等场景先验信息来辅助定位,但这些先验信息仅局限于少量特定类型的辅助数据。

2) 稀疏点云配准困难。帧间点云配准是移动位姿估计的核心。迭代最近点(ICP)及其改进算法^[14-15]

虽然被广泛应用,但其配准精度严重依赖于高质量的初值。部分研究通过构建建筑平面基元^[16]等几何特征模式来提升配准的稳健性,但难以解决稀疏点云结构表征不明显的问题。近年来,深度学习在异源、低重叠率等特殊情形的点云配准中展现出优势^[17],但其计算复杂度高,场景泛化能力有限,制约了它的实际应用。

3) 大规模场景累积误差难以有效校正。回环优化是移动建图校正累积误差的关键技术,现有方法可分为基于点特征^[18]的方法和基于全局描述符^[19-20]的方法。此外,深度学习技术,如 LCDNet^[21],结合特征编码器、全局描述符提取与位姿估计模块,实现了端到端的累积误差校正。然而,在长走廊等对称场景中,回环构建困难,导致回环优化难以校正累积误差。

为了解决上述问题,本团队提出了一种融合场景先验信息的低成本激光雷达室内建图方法,该方法通过引入场景先验信息实现更准确、更稳健的大规模室内环境移动建图。该方法的创新之处在于:① 融合了建筑平面图等多类型场景先验信息,以构建高效的参考数据,提升全局定位精度;② 设计了兼顾回环与非回环情形的位姿优化策略,结合局部建筑骨架特征,提高了对累积误差的校正能力;③ 生成了融合建筑部件语义信息的轻量化点云地图,以提升智能无人系统调用建图结果的效率。

收稿日期: 2024-12-26; 修回日期: 2025-03-31; 录用日期: 2025-05-13; 网络首发日期: 2025-05-19

基金项目: 自然资源部城市国土资源监测与仿真重点实验室开放基金资助课题(KF-2023-08-14)、国家自然科学基金(41771480)

通信作者: *yeqin@tongji.edu.cn

2 原理与方法

本团队提出的顾及场景先验信息的大规模室内环

境激光雷达建图方法包括场景先验信息特征提取与组织、室内全局定位、帧间位姿确定与优化、点云地图生成 4 个阶段,如图 1 所示。




图 1 所提方法的流程图

Fig. 1 Flow chart of the proposed method

2.1 场景先验信息特征提取与组织

室内环境常伴随有大量易获取的场景先验信息, 这些信息通常包括三种类型: ① 文本类, 如建筑规范和工程验收报告中关于室内空间布局的文字描述; ② 图像类, 如应急疏散图、商场导览图等功能性示意图; ③ 模型类, 如建筑平面图、建筑信息模型(BIM)等标准化的室内测绘结果。不同类型的场景先验信息在精度与可靠性上差异明显, 并且模型类场景先验信息的精度和可靠性通常优于图像类和文本类。为了克服场景先验信息与感知点云间的模态差异, 本团队提取该信息中墙体、梁柱等形状与位置固定的建筑构件并将其作为可靠的建筑骨架特征, 用于辅助后续的定位与位姿优化。具体处理方法如下:

1) 文本类。本研究采用语言大模型 Claude-3.5-Sonnet, 从工程验收报告等文本中提取建筑骨架特征。通过构建典型大规模室内场景建筑骨架几何属性提取训练集, 并结合人工标注与关键词检索, 明确线状构件长度、柱状构件半径等参数的提取规则, 将该规则作为提示信息输入该大模型, 引导其完成语义识别与属性抽取。通过关键词匹配与建筑信息规范比对, 实现多源文本信息的统一配准。此外, 对于结构较弱或存在歧义的文本, 通过结构化预处理与规则优化来提升其鲁棒性。

2) 图像类。采用 OpenCV 集成的 Hough 圆检测与 Canny 边缘检测算法提取图像特征, 并结合特征匹配方法确定图像特征间的变换矩阵, 实现先验信息配准与建筑骨架特征提取。

3) 模型类。基于 DWG、IFC 等格式的模型, 解析并读取建筑骨架基元及其属性。模型类信息通常存储有标准参考坐标系, 因此可以直接利用其坐标信息进行不同模型的自动配准。

为高效组织所提取的特征, 本研究将特征属性文件与格网图作为特征组织形式(如图 2 所示), 分别记录属性参数与空间布局投影。此外, 对于多源信息提取过程中可能出现的冗余或重复建筑骨架特征, 通过加权融合其空间位置与几何属性, 以提升特征数据整体准确性。其中, 权重依据信息类型的可靠性与提取精度设定, 结合实验验证(见 3.2 节)确定文本类、图像类、模型类信息的权重比为 1:1:3(适当提高模型类信息的权重)。该配置可根据实际场景灵活调整。大量实验表明, 在遵循“高质量信息赋予更高权重”的原则下, 具体权重对建图效果影响有限, 说明该方法具有良好的鲁棒性与泛化能力。


2.2 室内全局定位

本研究在低成本激光雷达获取的稀疏点云上提取建筑骨架特征, 构建特征模式与描述符, 并通过描述符

Element line: 87		
No.	End point 1	End point 2
#1	(2.757, 3.029)	(17.302, 2.961)
#2	(5.682, 8.190)	(5.677, 7.854)
...	...	...

Element circle: 10		
No.	Center	Radius /m
#1	(31.251, 26.095)	0.151
#2	(38.710, 34.605)	0.147
...	...	...

feature attribute file



raster graphic file

图 2 在场景先验信息中提取的可靠特征的组织形式

Fig. 2 Organization format of the robust features extracted from the prior scene information

检索与点云击中率核验实现由粗到精的室内全局定位。具体过程如下:

1) 预处理。考虑到室内场景通常比较平坦,因此定位任务仅需解算二维平面坐标和朝向角。使用统计滤波剔除噪声与离群点,通过奇异值分解提取点云的主方向,从而实现坐标轴校正。

2) 建筑骨架特征提取。采用随机样本一致性算法(RANSAC)分割线状结构(根据激光雷达分辨率,本研究设置内点阈值为 0.02 m),结合欧氏聚类与最小二乘法拟合直线模型。针对建筑骨架特征的长线性与曲线特性,本团队提出了一种“先截断后合并”的策略:首先,根据典型室内建筑骨架的最小尺寸,对超过 0.1 m 长度阈值的线状特征进行截断;其次,通过构建线段支撑区域实现特征合并,当线段 L_i, L_j 的支撑区域 R_i, R_j 存在

交集(即满足合并指标 $J_b = 1$)时,进一步分析线段间的几何关系。这里设置几何判断指标 J_k 的阈值为 0.05,对满足平行条件的线段进行合并,同时对垂直线段进行延长直至交汇。合并指标和几何判断指标的定义为

$$J_b = R_i \cap R_j \in \{0, 1\} \quad (1)$$

$$J_k = \min \{ |d_i - d_j|, |d_i \cdot d_j + 1| \} \quad (2)$$

式中: d_i, d_j 分别为线段方向向量。对线状提取后的点云再次执行聚类操作,并根据类高度筛选低矮的非建筑骨架目标。然后,采用随机样本一致性算法拟合圆参数,最终实现圆柱状建筑骨架特征的精准提取。

3) 建筑骨架特征模式构建。为增强感知点云与场景先验信息配准的稳健性,将线状建筑骨架特征两两组合,定义为平行、垂直和共线线对,并结合圆柱状建筑骨架构建建筑骨架的特征模式(如图 3 所示)。




图 3 建筑骨架特征模式。(a)平行线对;(b)垂直线对;(c)共线线对;(d)圆柱状

Fig. 3 Architectural skeleton feature patterns. (a) Parallel line pair; (b) vertical line pair; (c) collinear line pair; (d) cylinder

文献[4]提出的建筑骨架特征矩阵描述符是感知点云与场景先验信息的共性特征,本文采用该描述符将线对之间的几何关系(平行、垂直、共线)及其间距编码为矩阵元素,如图 4 所示。考虑到非模型类场景先验信息存在不同区域尺度不一致的问题,本研究用局部归一化策略替代原有的全局归一化,以提升描述符在多类型场景信息比例尺不一致时的匹配能力。

4) 室内全局定位。本研究提出了两阶段定位方法,该方法包括基于描述符检索的粗定位以及基于点云击中率核验的精定位。实时感知点云中建筑骨架特征矩

阵描述符为 M_1 ,场景先验信息描述符为 M_2 ,通过滑动窗口在 M_2 中提取与 M_1 尺寸相同的子矩阵 M_2' ,并计算 M_1 与 M_2' 之间的曼哈顿距离 $D(M_1, M_2')$ 。计算公式为

$$D(M_1, M_2') = \sum_{i,j} |M_1(i,j) - M_2'(i,j)| \quad (3)$$

当 $D(M_1, M_2')$ 小于设定阈值 τ_D (本文中 $\tau_D = 0.1$) 时,认为检索成功,记录此时滑动窗口位置并将其作为粗定位结果,如图 5 所示。

由于大规模室内结构具有高度相似性,仅依赖粗定位难以准确定位。为此,本团队提出了基于点云击




图 4 建筑骨架特征矩阵描述符

Fig. 4 Matrix descriptor of architectural skeleton feature




图 5 基于矩阵描述符检索的粗定位

Fig. 5 Coarse localization via matrix descriptor retrieval

中率核验的精定位:将粗定位点云投影至格网图,依据建筑骨架特征点 (x_0, y_0) 与格网图中建筑骨架特征的距离,构建解算位姿 (X, Y, θ) 的误差方程,如式(4)所示;然后基于误差项 $V(X, Y, \theta)$ 最小原则解算修正坐标 (x_1, y_1) ,并统计点云击中率(即建筑骨架特征点落在格网图上的比例),选取击中率最高的位姿作为全局定位结果。误差及修正坐标计算公式为

$$V(X, Y, \theta) = \frac{|kx_1 - y_1 + b|}{\sqrt{k^2 + 1}} \quad (4)$$

$$\begin{cases} x_1 = (x_0 + X) \cdot \cos \theta + (y_0 + Y) \cdot \sin \theta \\ y_1 = (x_0 + X) \cdot \sin \theta + (y_0 + Y) \cdot \cos \theta \end{cases} \quad (5)$$

式中: k 为线状建筑骨架特征的斜率; b 为线状建筑骨架特征的截距; (X, Y) 为全局定位中平面坐标的修正值; θ 为全局定位的朝向角。


2.3 帧间位姿确定与优化

为了克服稀疏点云的帧间配准难题,本团队针对建筑骨架特征的不同丰富度,提出了三类自适应配准策略:基于建筑骨架特征的配准、建筑骨架引导的ICP配准以及原始ICP配准。具体如下:

1) 建筑骨架丰富度统计。定义建筑骨架特征点占整体点云的比例 r 为丰富度指标。多个典型大规模室内场景测试结果表明: $r \geq 50\%$ 表示该帧的建筑骨架特征丰富,该类帧有利于稳定配准; $r \leq 20\%$

表示该帧的建筑骨架特征匮乏,该类帧易导致特征模式配准失效;其余为一般帧,如图 6 所示。此外,丰富度阈值可根据场景结构特点适当调整,以提升

适应性。例如,对于建筑结构密集场景,可以降低丰富帧阈值,而对于结构空旷场景,可以提高匮乏帧阈值。



architectural skeleton feature points

The number of architectural skeleton feature points is 9014, and number of total points is 27888.

The architectural skeleton richness,

$$r_a = \frac{9014}{27888} \times 100\% \approx 32.3\%$$

Since it is between 30% and 50%, this

scan belongs to regular scans.

图 6 依据建筑骨架丰富度的实时感知点云帧分类

Fig. 6 Real scans classification based on the architectural skeleton richness

2) 帧间位姿确定。对于建筑骨架特征丰富帧,采用 2.2 节所提精定位方法提取建筑骨架特征模式,解算帧间相对位姿。对于一般帧,仅提取带有建筑骨架特征索引的点云进行 ICP 解算,以减少非关键点云参与迭代,提高计算效率。对于建筑骨架特征匮乏帧,采用原始 ICP 算法解算帧间位姿。

尽管上述方法能有效解算帧间位姿,但在长距离建图过程中,累积误差难以避免,而且大规模室内场景中回环通常难以构成。为此,本团队提出了结合场景先验信息与建筑骨架特征的位姿优化方法。该方法的具体流程包括:

1) 关键帧选取。采用固定采样间隔提取关键帧(根据点云采集频率及移动速度,这里设置间隔为 50 帧),由于位姿优化依赖全局定位方法的配准策略,而且该全局定位成功率较高(实验表明 90% 以上),因此位姿优化受采样间隔的影响较小。

2) 回环检测与位姿优化。通过建筑特征模式描述符的相似性检测回环。在回环情形下,利用帧间位姿确定方法进行配准,并采用光束法对回环前的位姿进行全局优化。

3) 长距离未回环位姿优化。针对无法形成回环的长距离建图,利用关键帧的室内全局定位结果进行位姿校正,基于全局定位位姿与关键帧累积位姿差异最小的约束,对关键帧前的所有帧进行位姿优化。结合基于全局定位的未回环情形下的位姿优化,可以有效克服现有方法面临的难题:关键帧间隔过小会增加计算耗时,而间隔过大则会易漏检回环。

综上,基于建筑骨架丰富度的帧间位姿自适应确定与优化策略,不仅提升了配准精度与配准效率,还降低了对复杂关键帧确定策略的依赖,为后续建图提供了可靠的位姿支持。

2.4 点云地图生成

基于优化后的位姿 (X_0, Y_0, θ) , 通过简化的三维刚体线性变换实现点云坐标的统一,即

$$\begin{bmatrix} X_{\text{map}} \\ Y_{\text{map}} \\ Z_{\text{map}} \end{bmatrix} = \begin{bmatrix} \cos \theta & -\sin \theta & 0 \\ \sin \theta & \cos \theta & 0 \\ 0 & 0 & 1 \end{bmatrix} \times \begin{bmatrix} X_{\text{scan}} \\ Y_{\text{scan}} \\ Z_{\text{scan}} \end{bmatrix} + \begin{bmatrix} X_0 \\ Y_0 \\ 0 \end{bmatrix} \quad (6)$$

式中: $(X_{\text{scan}}, Y_{\text{scan}}, Z_{\text{scan}})$ 和 $(X_{\text{map}}, Y_{\text{map}}, Z_{\text{map}})$ 分别为感知点云的坐标以及映射到全局点云地图上的坐标。通过逐帧转换与拼接,构建完整的室内点云地图。

然而,在大规模室内场景下,常规点云地图通常点数庞大,内存占用可达数百 GB,严重制约了移动平台的内存和计算资源,而且遍历与调用效率低下。因此,有效的点云地图轻量化处理至关重要。现有轻量化方法主要包括:① 仅保留特征点构建结构索引^[22];② 整体降采样^[23]。前者信息缺失严重,会影响建模与规划;后者不仅易丢失关键结构,还会保留冗余干扰数据。为此,本团队提出了一种基于建筑骨架特征的点云地图轻量化方法,该方法可在建图后的离线阶段执行。

该方法融合了语义分割与骨架索引信息,点云地图中仅保留具有永久性结构的骨架特征点。该方法先将地图点云降采样至百万级点数,而后选用高效且轻量化的 RandLA-Net 网络^[24]进行点云地图语义分割。本研究采用在室内公开数据集 S3DIS 上预训练的 RandLA-Net 网络,其在语义分割过程中的显存占用约为 3.8 GB,适用于大多数移动平台的算力配置。具体处理流程如图 7 所示。

该方法生成的轻量化地图仅包含永久性建筑结构点云,可以作为移动平台室内定位与路径规划的有效辅助信息,避免了噪声、移动目标等对定位的干扰,而且其具备的高完整度的结构点云与语义信息也能较好地满足 VeCIM^[25]等室内三维重建方法的数据需求。




图 7 轻量化点云地图生成


Fig. 7 Lightweight point cloud map generation

3 实验与分析

3.1 实验设置与实验场景

鉴于现有室内激光雷达移动建图数据集普遍缺乏场景先验信息的现状,本团队采用自主搭建的硬件平台

开展算法验证,平台由松灵机器人 SCOUT MINI 搭载 RS-LiDAR-16 激光雷达构成,如图 8 所示。激光雷达安置高度为 0.85 m,平台移动速度约为 5 km/h,运行环境为 Ubuntu 20.04 系统、16 GB 内存、RTX 2080 Ti GPU,算法基于 C++、ROS 框架与 PCL 点云处理库实现。



LiDAR sensor parameters(RS-LiDAR-16):	
Number of channels	16
Scanning frequency	5 Hz
Horizontal angular resolution	0.1°
Vertical angular resolution	2.0°
Distance accuracy	Up to ± 2 cm
Point cloud number	~30000 point/scan

图 8 实验平台与激光雷达传感器参数

Fig. 8 Experimental platform and parameters of LiDAR sensor

选取办公楼、展览厅和地下车库三类典型大规模室内场景,进行点云数据采集与移动建图实证,实验环境均处于真实使用状态,包含行人、车辆等动态目标,增强了实验评估的可靠性。同时,为验证本研究引入场景先验信息的有效性,获取了实验区域的建筑平面图、消防安全疏散图及建筑设计规范等多类型数据。实验场景及相关规模参数如图 9 所示。

3.2 场景先验信息特征提取精度评估

为评估所提场景先验信息特征提取方法的精度,以正确提取建筑骨架特征的占比作为精度(accuracy)指标,采用人为标注方式对从实验数据的场景先验信

息中提取的所有建筑骨架基元进行核验,统计结果见表 1。

对于模型类场景先验信息,由于标准化存储格式和精确参考系的支持,特征提取精度达到了 100%;对于图像类与文本类场景先验信息,特征提取精度相当,均为 90% 左右。这一结果表明,对于不同类型的先验信息,本团队所提建筑骨架特征提取方法均表现出较高的准确性,模型类信息的提取精度最佳,图像类和文本类信息可在感知稀疏时作为有效补充。

3.3 室内全局定位实验结果

从三个实验场景中各选取两帧数据进行室内全局



图9 实验场景及相关规模参数

Fig. 9 Experimental scenes and scale parameters

表1 从场景先验信息中提取的建筑骨架特征的精度评估

Table 1 Accuracy evaluation of architectural skeleton feature extracted from prior scene information

Information type	Experimental scene	Quantity of features	Accuracy / %
Text	Office building	32	84.4
	Exhibition hall	37	94.6
	Underground parking lots	70	91.4
Image	Office building	45	86.7
	Exhibition hall	56	91.1
	Underground parking lots	78	93.6
Model	Office building	98	100
	Exhibition hall	69	100
	Underground parking lots	193	100

定位结果的可视化展示,如图10所示,填充圆形表示平面位置,箭头表示朝向角。图中,感知点云与已有建

筑平面图均贴合紧密,表明本团队所提场景先验信息辅助的室内全局定位方法具有较高的定位准确性。




图10 室内全局定位结果

Fig. 10 Results of indoor global localization

为定量评估所提方法的有效性,从三类场景中随机抽取了100帧点云数据,用于精度评估,参考值选取的是激光雷达与IMU紧耦合的里程计方法LIO-SAM^[26]输出的高精度位姿(在多个公开数据集上已验证其位姿精度普遍优于纯激光雷达里程计方法^[27])。统计了定位误差与算法耗时,选择文献[11]所提的建筑平面图辅助定位方法以及文献[9]和文献[19]所提的点云参考图辅助定位方法作为对比算法,结果如图11所示。

由图11可见,本文方法的定位误差在0.10 m以

内,朝向角误差小于1°,并且算法效率较高,平均每帧点云的全局定位耗时约为7 ms。就定位精度而言,本文方法在平面位置和朝向角精度上明显优于文献[11]所提方法,与文献[9]所提方法的平面位置精度相当,仅在展览厅场景下存在轻微差距。综合考虑参考数据获取难易程度、全局定位精度及算法效率,认为本文方法在性能表现上更具优势。

除精度外,室内全局定位成功率同样可以反映本文方法的适用性与泛化能力,其统计结果如表2所示。将点云在格网图上的击中率作为评估指标,当击中率




图 11 室内全局定位精度与效率对比,其中“fail”表示文献[19]所提方法不适用于不含柱状构件的地下车库场景,“nan”表示文献[9]和文献[19]所提方法未提供朝向角估计结果。(a)位置误差;(b)朝向误差;(c)平均耗时

Fig. 11 Comparison of indoor global localization accuracy and efficiency, where “fail” indicates that the method in Ref. [19] is not applicable to the underground parking lot scene with the absence of cylindrical structures, while “nan” denotes that the methods in Refs. [9] and [19] do not provide orientation estimation results. (a) Position error; (b) orientation error; (c) average computation time

表 2 室内全局定位的成功率

Table 2 Success rate evaluation of indoor global localization

Experimental scene	Quantity of scans	Success rate /%
Office building	1503	92.4
Exhibition hall	4796	90.7
Underground parking lots	10834	94.6

超过设定阈值(本研究设定为 90%)时,即判定为定位成功。结果表明,本文方法的全局定位成功率超过了

90%,在建筑骨架特征丰富的地下车库场景中,成功率更是高达约 95%。

3.4 稀疏点云建图实验结果

3.4.1 建图精度评估

本研究所提点云建图方法在三个实验场景下的建图结果如图 12 所示。其中,黑色为生成的室内地图,红色框选区域对应局部放大细节,放大图中的点云以黄色显示,并叠加了建筑参考平面图(黑色线框)。从

目视效果来看,所生成的点云地图在结构布局上与参考数据高度一致,能够准确且完整地反映真实的室内

环境,展现了所提点云建图方法的良好建图精度与完整性。




图 12 激光雷达建图结果。圈出部分为局部细节图,用于反映建图结果与建筑平面图的一致性

Fig. 12 Results of LiDAR-based mapping. Circled area represents the local details, which reflects the consistency between the mapping result and the floor plan

除了定性评估外,还对建图精度进行了定量评估。不同于常规 SLAM (Simultaneous Localization and Mapping) 算法通过移动轨迹精度间接评价建图结果,本研究通过建筑骨架特征的线段长度来直接评价建图精度。其计算公式为

$$\Delta_{\text{map}} = \sum_{i=1}^n |L_{\text{map}}^{(i)} - L_{\text{GT}}^{(i)}| \quad (7)$$

式中: Δ_{map} 为建图精度评价指标; $L_{\text{map}}^{(i)}$ 和 $L_{\text{GT}}^{(i)}$ 分别为同一线段的测图结果与真实量测长度,真实场景中建筑骨架的特征长度通过架站式激光扫描仪获取场景点云进而量测获得。为评估本文方法的建图精度,选取

KITTI Odometry 榜单中排名靠前的三种纯激光雷达建图方法,即 LOAM^[28]、F-LOAM^[29]和 Traj-LO^[30],作为对比基准。为确保对比结果的一致性,所有对比方法均在与本研究相同的实验平台与硬件环境下运行,并采用其开源实现中适配本研究平台与传感器的默认参数设置。在三个不同的实验场景中,分别选取 10 条、15 条和 25 条建筑骨架特征线段,并统计不同方法生成的点云地图与真实建筑骨架之间的线段长度误差。实验结果如图 13 所示,图中的不同线型对应不同方法的测图误差。顶点越接近圆心,表示误差越小;所




图 13 室内点云建图精度对比

Fig. 13 Comparison of the accuracy of the indoor point cloud-based mapping

围成的面积越小,表明测图方法的精度越高。

统计结果表明,本团队提出的面向大规模室内场景的激光雷达建图方法在所有实验场景中均将建图误差控制在 10 cm 以内,整体精度优于现有 LOAM、F-LOAM 和 Traj-LO 方法。在办公楼和展览厅场景中,本文方法相较于 F-LOAM 和 Traj-LO 的建图精度提升了约 3 cm,表现更为稳定。在结构复杂、建筑骨架特征丰富的地下停车场中,各方法的误差整体上升,其中 F-LOAM 的平均误差为 7 cm,LOAM 和 Traj-LO 的误差略低(约为 6 cm),而本文方法的误差仅为 4 cm,显著低于对比方法。这一结果充分验证了本文方法在大规模复杂室内环境下的高精度与鲁棒性。

3.4.2 建图效率评估

除了精度,算法效率同样是自主测图任务中的关键因素,特别是在大规模室内环境中,计算效率直接影响着单位时间内建图任务的覆盖范围。为此,统计了各方法在三个实验场景下的测图耗时,结果见表 3。可见,与 LOAM、F-LOAM 和 Traj-LO 方法相比,本文方法在所有场景中均展现出更高的计算效率。具体而言,在办公楼和展览厅场景中,本文方法相较于对比方法中最高效的 F-LOAM 方法节省至少 1.9 s,并且明显优于 Traj-LO 方法。在地下车库场景中,各方法的计算耗时普遍增加,但本文方法仍保持着最短的耗时,时间消耗相比 LOAM 减少约 25%,相比 Traj-LO 几乎减少 50%,进一步验证了其在复杂大规模环境中的高效性。该效率优势主要得益于本文方法在骨架特征丰富区域引入了基于建筑骨架匹配的优化策略,从而显著降低了计算开销。

表 3 室内点云建图效率对比

Table 3 Comparison of the efficiency of the indoor point cloud mapping

Experimental scene	Method	Time cost /s
Office building	LOAM	43.7
	F-LOAM	31.0
	Traj-LO	58.4
	Ours	29.1
Exhibition hall	LOAM	219.3
	F-LOAM	185.7
	Traj-LO	325.6
	Ours	178.2
Underground parking lots	LOAM	327.9
	F-LOAM	258.2
	Traj-LO	493.5
	Ours	247.5

3.4.3 点云地图轻量化及辅助定位分析

除了生成常规点云地图外,本研究还通过融合语义信息与建筑骨架特征,构建了轻量化的点云地图。图 14 展示了所生成的轻量化点云地图的俯视投影图。相比于图 12 中的常规点云地图,该轻量化表征结构更简洁,信息组织更高效。

表 4 统计了两类点云地图在不同场景下的点数与内存占用情况。结果显示,轻量化点云地图的点数相比常规地图大幅减少,并且内存占用均控制在 100 MB 以内,大幅降低了数据冗余,有利于移动机器人等平台在运行过程中实现快速加载与高效调用。




图 14 点云地图轻量化结果

Fig. 14 Lightweight point cloud map

表 4 轻量化前后点云地图内存占用情况与点数对比

Table 4 Comparison of the memory cost and point number of point cloud map before and after lightweighting

Experimental scene	Map type	Memory cost /MB	Quantity of points / 10^6
Office building	Original	312	35.12
	Lightweight	29	2.31
Exhibition hall	Original	1007	109.72
	Lightweight	41	4.57
Underground parking lots	Original	2840	218.47
	Lightweight	77	8.71

为评估轻量化处理对地图辅助定位效果的影响,分别对本文全局定位方法以及两种基于点云参考图的定位方法(文献[9]与文献[19]所提方法),在轻量化前后的点云地图上开展定位对比实验,统计结果见表5。由于文献[19]所提方法仅适用于含有圆柱形部件的数据集,故此次对比实验选择了展览厅场景。采用3.3节用于全局定位实验的100帧点云评估定位精度与效率。结果表明,在采用轻量化点云地图的情况下,各类方法的定位精度与常规点云地图基本保持一致,但定位效率显著提升。其原因在于,所有方法在配准过程中均需提取室内结构化部件并将其作为特征,而轻量化地图有效减少了冗余干扰点云,提供了更高效的场景表征。

表5 轻量化前后点云地图辅助室内全局定位效果对比
Table 5 Comparison of the indoor global localization based on original and lightweight point cloud maps

Method	Map type	Position error /m	Time cost /ms
Ref. [9]	Original	0.08	1255
	Lightweight	0.09	935
Ref. [19]	Original	0.11	1197
	Lightweight	0.11	891
Ours	Original	0.09	769
	Lightweight	0.09	650

4 结 论

本团队提出了一种充分利用多类型场景先验信息的大规模室内环境激光雷达建图方法。通过引入多类型场景先验信息,提取稳健的结构特征并构建高效的组织形式,设计建筑骨架特征模式,实现了实时感知数据与场景先验信息的配准,从而克服了点云参考图、无外置辐射源条件下的室内全局定位难题;通过采用建筑骨架丰富度引导点云配准的帧间位姿估计,设计适用于回环以及长距离未形成回环情形下的累积误差纠正策略,克服了大规模室内场景长距离建图中的位姿偏差问题;提出了轻量化点云地图表征方法,在保证定位精度的同时显著减少了内存占用,便于移动平台快速调用。实验结果表明,本文方法在地下车库等典型大规模室内场景中,基于低线束激光雷达可以实现几何精度优于10 cm的室内移动建图,并且在建图精度和建图效率等方面均优于现有主流算法。该方法为低成本室内移动测量系统提供了稳定可靠的技术支撑,并且具备良好的扩展性与实用性。未来拟进一步探索面向大规模室内环境的轻量化语义分割与三维模型在线构建方法,以更好地支撑实景三维建设等快速建模需求。

参 考 文 献

- [1] Ullah I, Adhikari D, Khan H, et al. Mobile robot localization: current challenges and future prospective[J]. Computer Science Review, 2024, 53: 100651.
- [2] 黄凯, 赵君屹, 冯甜甜. 激光雷达同时定位与建图中的局部几何信息表征与不确定度分析探究[J]. 中国激光, 2025, 52(6): 0600003.
- [3] Huang K, Zhao J Q, Feng T T. Local geometric information representation and uncertainty analysis in LiDAR SLAM[J]. Chinese Journal of Lasers, 2025, 52(6): 0600003.
- [3] 杨秀建, 黄甲龙, 张生斌, 等. 基于激光雷达的无人车辆非结构化环境联级点云分割算法[J]. 光学学报, 2025, 45(8): 0815004.
- [3] Yang X J, Huang J L, Zhang S B, et al. Cascaded point cloud segmentation algorithm for unstructured environments based on LiDAR for autonomous vehicles[J]. Acta Optica Sinica, 2025, 45(8): 0815004.
- [4] Luo J Q, Ye Q, Zhang S M, et al. Indoor mapping using low-cost MLS point clouds and architectural skeleton constraints[J]. Automation in Construction, 2023, 150: 104837.
- [5] 张彬, 许晓辉, 李海虹. 一种IMU/LiDAR紧耦合的移动机器人定位与建图算法[J]. 激光与光电子学进展, 2025, 62(10): 1015001.
- [5] Zhang B, Xu X H, Li H H. IMU/LiDAR tightly coupled mobile robot localization and mapping algorithm[J]. Laser & Optoelectronics Progress, 2025, 62(10): 1015001.
- [6] El-Sheimy N, Li Y. Indoor navigation: state of the art and future trends[J]. Satellite Navigation, 2021, 2(1): 7.
- [7] Morgan A A. On the accuracy of BLE indoor localization systems: an assessment survey[J]. Computers and Electrical Engineering, 2024, 118: 109455.
- [8] Panja A K, Karim S F, Neogy S, et al. Improving the sustainability of WiFi-enabled indoor localization systems through meta-heuristic based instance selection approach[J]. Expert Systems with Applications, 2024, 257: 125063.
- [9] 史鹏程, 叶勤, 张绍明, 等. 顾及室内场景特征的多线激光雷达初始定位[J]. 测绘学报, 2021, 50(11): 1594-1604.
- [9] Shi P C, Ye Q, Zhang S M, et al. Localization initialization for multi-beam LiDAR considering indoor scene feature[J]. Acta Geodaetica et Cartographica Sinica, 2021, 50(11): 1594-1604.
- [10] Xie F J, Schwertfeger S. Robust lifelong indoor LiDAR localization using the area graph[J]. IEEE Robotics and Automation Letters, 2024, 9(1): 531-538.
- [11] Boniardi F, Caselitz T, Kümmerle R, et al. A pose graph-based localization system for long-term navigation in CAD floor plans[J]. Robotics and Autonomous Systems, 2019, 112: 84-97.
- [12] 郭中远, 徐锋, 王贵洋, 等. 基于虚拟现实的移动机器人真实环境三维建模系统[J]. 激光与光电子学进展, 2023, 60(2): 0233001.
- [12] Guo Z Y, Xu F, Wang G Y, et al. 3D modeling system of mobile robot based on virtual reality in real environment[J]. Laser & Optoelectronics Progress, 2023, 60(2): 0233001.
- [13] Zhao H, Zhao Y, Tomko M, et al. MoLi-PoseNet: model-based indoor relocation using deep pose regression from synthetic LiDAR scans[J]. IEEE Sensors Journal, 2024, 24(11): 18592-18607.
- [14] Besl P J, McKay N D. A method for registration of 3-D shapes[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1992, 14(2): 239-256.
- [15] 赵龙云, 伞红军, 陈久朋, 等. 基于ICP算法的移动机器人激光定位研究[J]. 激光与光电子学进展, 2024, 61(8): 0811001.
- [15] Zhao L Y, San H J, Chen J P, et al. Laser location of mobile robot based on ICP algorithm[J]. Laser & Optoelectronics Progress, 2024, 61(8): 0811001.
- [16] 孙喜亮, 关宏灿, 苏艳军, 等. 面向高精度城市测绘的激光紧耦合SLAM方法[J]. 测绘学报, 2021, 50(11): 1585-1593.
- [16] Sun X L, Guan H C, Su Y J, et al. A tightly coupled SLAM method for precise urban mapping[J]. Acta Geodaetica et Cartographica Sinica, 2021, 50(11): 1585-1593.
- [17] Zhao Y H, Zhang J G, Xu S B, et al. Deep learning-based low overlap point cloud registration for complex scenario: the review[J]. Information Fusion, 2024, 107: 102305.

- [18] 李兆强, 张岳, 熊福力, 等. 基于优化地面分割与回环检测的激光同时定位与建图算法[J]. 光学学报, 2024, 44(20): 2015001.
- Li Z Q, Zhang Y, Xiong F L, et al. Laser simultaneous localization and mapping algorithm based on optimized ground segmentation and closed-loop detection[J]. Acta Optica Sinica, 2024, 44(20): 2015001.
- [19] 史鹏程, 李加元, 刘欣怡, 等. 室内圆柱引导的激光雷达全局定位与回环检测[J]. 武汉大学学报(信息科学版), 2024, 49(7): 1088-1099.
- Shi P C, Li J Y, Liu X Y, et al. Indoor cylinders guided LiDAR global localization and loop closure detection[J]. Geomatics and Information Science of Wuhan University, 2024, 49(7): 1088-1099.
- [20] Xiang H D, Shi W Z, Fan W Z, et al. FastLCD: a fast and compact loop closure detection approach using 3D point cloud for indoor mobile mapping[J]. International Journal of Applied Earth Observation and Geoinformation, 2021, 102: 102430.
- [21] Cattaneo D, Vaghi M, Valada A. LCDNet: deep loop closure detection and point cloud registration for LiDAR SLAM[J]. IEEE Transactions on Robotics, 2022, 38(4): 2074-2093.
- [22] Shi P C, Li J Y, Zhang Y J. A fast LiDAR place recognition and localization method by fusing local and global search[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2023, 202: 637-651.
- [23] van Oosterom P, van Oosterom S, Liu H C, et al. Organizing and visualizing point clouds with continuous levels of detail[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2022, 194: 119-131.
- [24] Hu Q Y, Yang B, Xie L H, et al. RandLA-net: efficient semantic segmentation of large-scale point clouds[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), June 13-19, 2020, Seattle, WA, USA. New York: IEEE Press, 2020: 11105-11114.
- [25] Han J L, Rong M Q, Jiang H Q, et al. Vectorized indoor surface reconstruction from 3D point cloud with multistep 2D optimization[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2021, 177: 57-74.
- [26] Shan T X, Englot B, Meyers D, et al. LIO-SAM: tightly-coupled lidar inertial odometry via smoothing and mapping[C]//2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), October 24, 2020-January 24, 2021, Las Vegas, NV, USA. New York: IEEE Press, 2020: 5135-5142.
- [27] Zhang Y J, Shi P C, Li J Y. 3D LiDAR SLAM: a survey[J]. The Photogrammetric Record, 2024, 39(186): 457-517.
- [28] Zhang J, Singh S. Low-drift and real-time lidar odometry and mapping[J]. Autonomous Robots, 2017, 41(2): 401-416.
- [29] Wang H, Wang C, Chen C L, et al. F-LOAM: fast LiDAR odometry and mapping[C]//2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), September 27-October 1, 2021, Prague, Czech Republic. New York: IEEE Press, 2021: 4390-4396.
- [30] Zheng X, Zhu J K. Traj-LO: in defense of LiDAR-only odometry using an effective continuous-time trajectory[J]. IEEE Robotics and Automation Letters, 2024, 9(2): 1961-1968.

LiDAR-Based Large-Scale Indoor Environment Mapping Incorporating Prior Scene Information

Luo Junqi¹, Ye Qin^{1,2*}, Yang Zexin³, Zhang Shaoming¹, Zeng Liang¹

¹College of Surveying and Geo-Informatics, Tongji University, Shanghai 200092, China;

²Key Laboratory of Urban Land Resources Monitoring and Simulation, Ministry of Natural Resources, Shenzhen 518034, Guangdong, China;

³Guangzhou Urban Planning & Design Survey Research Institute Company Ltd., Guangzhou 510060, Guangdong, China

Abstract

Objective Point cloud maps serve as a crucial digital foundation for smart city development, underpinning applications such as autonomous driving, 3D reconstruction, and intelligent logistics. Compared to traditional static laser scanning, mobile platforms equipped with perception sensors offer a flexible solution for acquiring point cloud maps. However, mobile mapping in large-scale indoor environments remains challenging due to three key issues: (1) the large number of complex architectural structures, (2) insufficient registration accuracy between sparse scans, and (3) significant pose drift accumulated during long-term mapping. To address these problems, this paper proposes a novel LiDAR-based indoor positioning and mapping method that incorporates prior scene information.

Methods The proposed method consists of four stages: feature extraction and organization of prior scene information, indoor global positioning, scan pose determination and optimization, and point cloud map generation.

(1) Feature extraction and organization of prior scene information. We extract robust features with stable shapes and positions (e.g., walls, beams, and columns) from various prior data sources. For different types of prior information, we adopt customized extraction strategies: large language models (LLMs) for text-type data, edge and circle detection algorithms for image-type data, and file parsing for model-type data. Finally, all extracted features are organized into feature attribute files and grid maps to facilitate easy access (see Fig. 2).

(2) Indoor global positioning. First, we extract similar robust features from real-time scans and establish architectural skeleton

feature patterns, including line pairs and cylindrical shapes. Next, we improve the matrix descriptor to characterize line-pair features. Coarse localization is achieved by matching descriptors using Manhattan distance, followed by fine localization using point hit ratios on the grid map.

(3) Scan pose determination and optimization. Scans are classified into three categories: feature-rich, regular, and feature-sparse. For feature-rich scans, we use our global positioning method to determine poses by matching architectural skeleton feature patterns. For regular scans, we adopt an improved ICP-based method that focuses on indexed skeleton features, while standard ICP is used for feature-sparse scans. Meanwhile, we detect loop closures using the similarity of architectural skeleton feature patterns and optimize poses for looped areas. For scenarios without loop closures, we employ key scan-based global localization and bundle adjustment to correct pose drift.

(4) Point cloud map generation. Scans are stitched using optimal poses to generate a conventional point cloud map. A pre-trained RandLA-Net is applied for semantic segmentation, and the extracted semantic information is combined with architectural skeleton indices to produce a lightweight map. This map provides a compact and efficient representation suitable for large-scale indoor applications.

Results and Discussions The proposed LiDAR-based mapping method was validated in three typical large-scale indoor environments: an office building, an exhibition hall, and an underground parking lot. Since most public datasets lack prior information, we collected scene data using a self-developed low-cost mobile LiDAR system (see Fig. 8). Additionally, we gathered various types of prior scene information for the experimental scenes, including building floor plans, fire evacuation diagrams, and architectural design specifications.

For qualitative evaluation of global positioning, we visualized two randomly selected scan locations overlaid on floor plans across all scenes (see Fig. 10), which demonstrated accurate positioning. For quantitative evaluation, we compared positioning accuracy and efficiency with three existing methods (see Fig. 11). Our method achieved a positioning error within 0.10 m, an orientation error within 1° , and an average time cost of approximately 7 ms per scan—showing a clear performance advantage over the compared methods.

Regarding mapping quality, visualization results (see Fig. 12) confirmed that the generated maps aligned with floor plans. Quantitative comparisons with LOAM, F-LOAM, and Traj-LO (see Fig. 13 and Table 3) indicated that our method achieved a mapping error within 0.1 m and outperformed these comparison algorithms in both accuracy and efficiency. Both qualitative and quantitative results verify the effectiveness of our method for mapping large-scale indoor environments. Furthermore, we confirmed that the offline lightweight point cloud map significantly improved localization efficiency while maintaining positioning accuracy across three tested localization methods (see Table 5).

Conclusions This study presents an innovative LiDAR-based indoor mapping approach that integrates prior scene information to address the challenges of complex large-scale indoor environments. The proposed method effectively improves mapping accuracy, reduces computational complexity, and enhances the usability of point cloud maps for real-time applications. Experimental validations confirm that it can meet the indoor localization and environmental perception needs of mobile robots, highlighting its significant engineering value. Future research will focus on exploring lightweight semantic segmentation and online 3D model construction methods suitable for understanding large-scale indoor environments.

Key words light detection and ranging; mobile mapping; prior scene information; indoor global localization